动态多模型迁移的母线负荷预测方法研究

张 阔[1],高 强[2],蔡健亮[1],方 涛[1],璩志锋[1]
(1. 国网浙江省电力有限公司天台县供电公司,浙江 台州 317200;2. 国网浙江省电力有限公司,浙江 杭州 310063)

摘 要:随着可再生能源大规模并网,电力系统运行的不确定性显著增加,对高精度短期母线负荷预测提出了更高要求。为此,提出一种动态多模型迁移的母线负荷预测方法。首先,进行相关性分析以确定不同数据集之间的迁移可行性,并实施自适应参数迁移策略,以优化数据利用和提升训练效率。其次,构建多模型协作平台,充分发挥各模型的优势,以增强预测的准确性。试验案例研究表明,所提方法在历史负荷数据有限的情况下,能够显著提高预测精度,推动了母线负荷预测技术的发展。该研究有助于在可再生能源整合背景下实现电力系统的高效运行。

关键词:母线负荷预测; 动态模型选择; 多模型融合; 迁移学习; 强化学习; 深度学习
中图分类号: TH-39 **文献标志码**:A DOI:10.16086/j.cnki.issn1000-0380.2025030122

Study of Busbar Load Forecasting Methods Using Dynamic Multi-Model Transfer

ZHANG Kuo[1], GAO Qiang[2], CAI Jianliang[1], FANG Tao[1], QU Zhifeng[1]
(1. Tiantai County Power Supply Company, State Grid Zhejiang Electric Power Co., Ltd., Taizhou 317200, China;
2. State Grid Zhejiang Electric Power Co., Ltd., Hangzhou 310063, China)

Abstract: With the large-scale grid integration of renewable energy, uncertainty in power system operation has been significantly increased, and higher requirements have been imposed on high-precision short-term busbar load forecasting. To address this challenge, a busbar load forecasting method using dynamic multi-model transfer is proposed. Firstly, correlation analysis is conducted to determine the feasibility of transfer between different datasets, and the adaptive parameter transfer strategy is implemented to optimize data utilization and improve training efficiency. Secondly, the multi-model collaborative framework is constructed to fully exploit the advantages of each model and enhance prediction accuracy. Experimental case studies demonstrate that the proposed method can significantly improve prediction accuracy even when historical load data are limited, thereby promoting the development of busbar load forecasting technology. This study provides support for the efficient operation of power systems under renewable energy integration.

Keywords: Busbar load forecasting; Dynamic model selection; Multi-model fusion; Transfer learning; Reinforcement learning; Deep learning

0 引言

母线负荷预测是电力系统运行与调度的核心支撑技术。母线负荷预测精度直接影响发电计划制定、备用容量配置及电网安全运行[1-3]。随着可再生能源的大规模接入和电力市场化改革的深入推进,负荷特性呈现更强的随机性与波动性。这对预测方法提出了更高要求[4-5]。

现有预测方法主要包括统计分析方法与基于深度学习的智能方法[6-7]。近年来,基于深度学习的智能方法已广泛应用于负荷预测[8-9]。汤义勤等[10]针对母线负荷噪声问题,提出结合变分模态分解与长短期记忆(long short-term memory, LSTM)网络的预测方法。丁施尹等[11]考虑高比例分布式电源影响,构建基于互信息分析的混合预测模型。迁移学习[12-14]为解决小样本与分布差异问题提供了新思路。JI等[15]提出混合迁移学习方法以用于风速预测。WANG等[16]提出Q学习迁移方法。Q学习具有高度可扩展性,能够在离

收稿日期:2025-03-22
作者简介:张阔(1985—),男,学士,高级工程师,主要研究方向为电力工程技术、电网规划、新型电力系统,E-mail:qeyw241@163.com;
高强(通信作者),男,硕士,高级工程师,主要从事电网规划、新型电力系统方向的研究,E-mail:p1989102625@163.com

中国知网 https://www.cnki.net

散和连续状态空间中收敛至最优策略[17-18]。CAI 等[19]利用 Q 学习提取有效特征,并通过特征迁移模型将提取的有效特征迁移到目标领域,从而确保算法的实时性能。

然而,深度学习模型普遍依赖大量同分布数据,易受母线间差异与分布漂移影响;迁移学习在源域与目标域差异较大时可能产生负迁移;负荷随时间动态变化,导致单一固定迁移策略难以在各时段保持最优。对此,本文提出动态多模型迁移的母线负荷预测方法。该方法基于相关性分析评估迁移可行性,并采用自适应参数迁移策略以降低负迁移风险;引入基于 Q 学习的动态模型选择机制,实现逐时间步自适应模型选择;构建迁移学习与强化学习结合的两阶段框架,以提升预测精度与泛化能力。

1　母线负荷预测中的迁移学习

母线负荷预测问题的物理机理体现为多因素交互作用。时间序列呈现日周期、周周期和季节性变化规律。天气、节假日等外部因素会对负荷产生显著影响,且负荷数据具有强非线性特征。LSTM 和门控循环单元(gated recurrent unit,GRU)通过门控机制处理时间序列中的长期依赖性问题。LSTM 的遗忘门控制历史信息的保留程度,对应负荷序列中周期性模式的记忆;输入门决定新信息的更新方式,对应突发事件对负荷的影响;输出门调节最终预测输出,可实现多尺度特征融合。迁移学习通过借助源域数据的知识弥补目标域数据的不足。这在电力系统中对应利用数据丰富母线的预测经验指导新建或数据稀缺母线的负荷预测。

在母线负荷预测中,母线负荷数据集可以表示为[7]:

$$D = \{x_1, x_2, \cdots, x_t\}_{t=1}^{N_{\mathrm{All}}} \tag{1}$$

式中:x_t 为包含母线负荷的特征和标签数据;N_{All} 为数据集的总规模。

在预测过程中,本文将特征数据定义为训练集、标签数据定义为测试集。根据迁移学习理论[14],源域与目标域划分可分别表示为:

$$D_1 = \{x_t\}_{t=1}^{N} (N < N_{\mathrm{All}}) \tag{2}$$

$$D_2 = \{x_t\}_{t=N+1}^{N_{\mathrm{All}}} \tag{3}$$

短期母线负荷预测模型 M 从 D_1 中学习特征知识,通过损失函数优化模型的参数 ω。利用优化后的模型 M',可以估计未来 $N_{\mathrm{All}} \sim N$ 个时间步的母线负荷。基于监督学习范式[20],模型训练的目标是最小化预测误差。

$$M: \mathrm{Loss}(\{x_t\}_{t=1}^{N}) \rightarrow \omega \tag{4}$$

式中:Loss( )为损失函数。

$$\{y_t\}_{t=N+1}^{N_{\mathrm{All}}} = M(\{x_t\}_{t=1}^{N}; \omega) \tag{5}$$

在参数优化过程中,M 通常需要大量样本数据,且训练过程耗时。而迁移学习通过利用源域模型 M_S 的参数知识 ω_S 来辅助目标域模型 M_T 的训练,可以有效提高数据利用效率。基于迁移学习的参数共享理论[7],迁移过程可表示为:

$$[\omega_S, \omega_T] \rightarrow M_T, \omega_S \in M_S \tag{6}$$

$$\omega_S = o + \zeta_S \Rightarrow \omega_T = o + \zeta_T \tag{7}$$

式中:o 为模型的公共参数;ζ_S 和 ζ_T 分别为源域和目标域模型的特定参数。

本文提出的迁移学习损失函数综合考虑了源域知识保持与目标域适应。多任务学习理论[21]的构建如下。

$$\mathrm{Loss}(o, \zeta_t) = \sum_{t \in \{S,T\}} \frac{1}{N_t} \sum_{i=1}^{N_t} [y_i^t - f(o + \zeta_t; x_i^t)]^2 \tag{8}$$

式中:y_i^t 为实际的母线负荷值;$f(\cdot)$ 为模型的预测函数,用于模拟模型的预测结果;x_i^t 为输入的母线负荷数据;ζ_t 为模型 M_t 的特定参数,$t \in \{S, T\}$。

2　母线负荷预测方法

负荷预测问题的机理主要体现为多个因素的交互作用(包括时间序列的周期性、趋势性变化),以及外部环境因素(如天气、节假日等)对负荷的影响。此外,负荷数据通常具有显著的非线性特征,传统线性模型难以准确建模。因此,机器学习方法,尤其是深度学习和迁移学习,已经成为解决短期母线负荷预测建模问题的有效工具。深度学习能够捕捉数据的非线性关系。LSTM 和 GRU 模型能够有效处理时间序列中的长期依赖性问题,并提供精准预测。迁移学习借助源域数据的知识,弥补目标域数据的不足。特别是在数据有限的情境下,迁移学习能够显著提高模型的预测精度。

基于此,本文提出 1 种将迁移学习与强化学习相结合的母线负荷预测方法,从而在历史负荷数据有限的情况下提高预测精度。

母线负荷预测方法逻辑如图 1 所示。图 1 中,参数迁移阶段的 2 条迁移路径并非并行选择,而是依据候选模型的结构类型自动执行。对于反向传播(back propagation,BP)网络、极限学习机(extreme learning machine,ELM)、Elman 神经网络(Elman neural network,ENN)和径向基函数(radial basis function,RBF)等浅层模型,可采用网络级参数迁移策略。对于 LSTM 和 GRU 等深层模型,可采用层级参数迁移策略。该策略在同一阶段内对不同模型分别执行。

中国知网　https://www.cnki.net

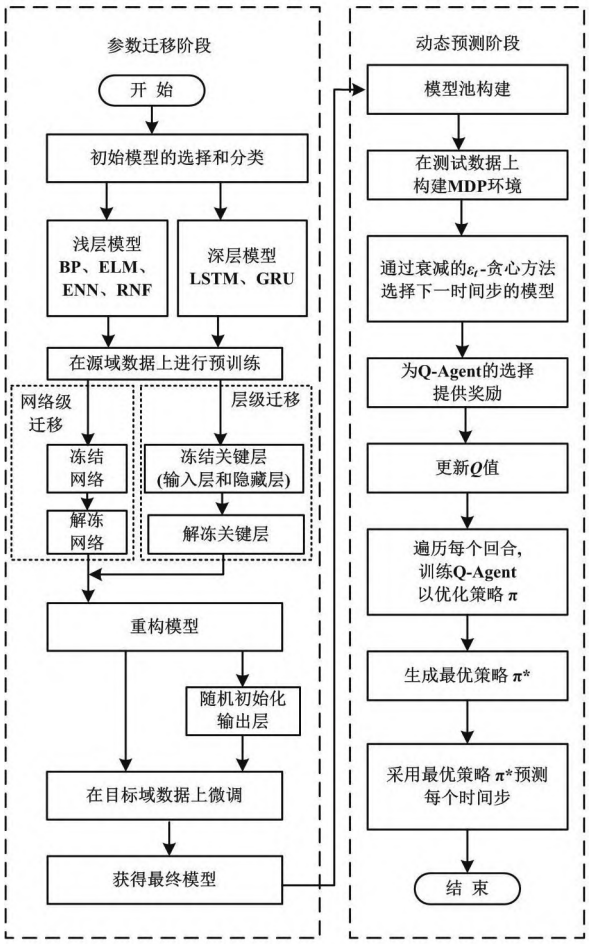


图 1 母线负荷预测方法逻辑图

Fig. 1 Logic diagram of busbar load forecasting method

2.1 参数迁移阶段

本文选择了 6 种自适应模型作为候选模型。这 6 种模型分别为 BP、ELM、ENN、GRU、LSTM 和 RBF，分别记为 M_1、M_2、M_3、M_4、M_5 和 M_6[22]。这些模型的选择基于以下物理考量。

①BP 和 ELM 具有较快的训练速度，适合捕捉负荷的短期波动特征。

②ENN 通过上下文单元保留历史状态信息，对应负荷的短期记忆特性。

③RBF 采用局部逼近策略，适合处理负荷数据中的局部非线性模式。

④LSTM 和 GRU 通过门控机制捕捉长短期依赖，对应负荷的多尺度周期性特征。

2.1.1 网络级迁移

由于候选模型的结构复杂度不同，本文设计了自适应迁移策略。该策略包括网络级迁移和层级迁移。网络级迁移的过程如下。

①构建初始模型。本文构建初始模型 M_i 并在源域数据集 D_S 上进行预训练，从而得到预训练参数 ω_S^i。

②评估有效性。本文使用验证集 D_{val} 评估预训练模型的性能，以确保迁移学习的有效性。

③冻结网络。本文将 M_i 的 ω_S^i 冻结，以保留已学习的知识，即 $\omega_S^i = o + \zeta_S^i$。其中，$\zeta_S^i$ 为 M_i 的特定参数。

④迁移冻结信息。本文将冻结的 ω_S^i 迁移到新的对应模型 M'_i，即重建 1 个完整的对应模型；同时，采用冻结的网络替换新模型中的网络部分，即 $\omega_T^i = o + \zeta_T^i$。其中：$\omega_T^i$ 为 M'_i 的参数；ζ_T^i 为目标域模型的特定参数。

⑤微调模型。本文使用目标域数据集 D_T 对 M'_i 进行微调，并优化相关参数，如学习率 η、动量因子 μ、最大训练迭代次数 E 等，以获得模型 M''_i。

对于 BP、ELM、ENN 和 RBF 等深度不足的神经网络，本文采用网络级迁移策略。这意味着需要冻结源模型的整个网络，以保证已学习特征知识的完整性。通过将冻结的信息迁移到新模型中，可确保自适应模型保留在源域数据中已学习到的知识。

2.1.2 层级迁移

层级迁移主要针对深度神经网络模型实现。首先，本文使用 D_S 预训练 M_i，以生成预训练模型 M_i^{pre}。其次，本文构建新的深度神经网络作为 M'_i。M'_i 继承 M_i^{pre} 中除输出层之外的所有神经网络层（输入层和隐藏层）及其参数 ω_{pre}。

$$\omega_{M_{i'}} = \{\omega_{\text{pre}}^{\text{input}}, \omega_{\text{pre}}^{\text{hidden}}\} \cup \{\omega_{\text{new}}^{\text{out}}\} \tag{9}$$

式中：$\omega_{\text{new}}^{\text{out}}$ 为新输出层的随机初始化参数。

本文假设继承的参数 ω_{pre} 包含了从源域数据中学习到的分布特征知识，且能够应用于目标域数据。M'_i 中集成了与 M_i^{pre} 维度匹配的输出层，且 $\omega_{\text{new}}^{\text{out}}$ 是随机初始化的。LSTM 和 GRU 等深度神经网络仅迁移关键层而非整个网络。

$$\omega_{M_{i'}} = \{\omega_{\text{pre}}\} \cup \{\omega_{\text{new}}^{\text{out}}\} \tag{10}$$

本文使用 D_T 对 M'_i 进行训练和验证，并优化模型的超参数。相关超参数包括 E、初始学习率 η_0、学习率下降周期等。

2.2 动态预测阶段

在强化学习过程中，值函数和智能体设计是提升预测性能的关键。值函数反映智能体在不同状态下采取某动作的长期回报。合理的奖励函数设计能够引导智能体选择最优模型。在负荷预测任务中，通过设计基于误差排名的奖励机制，可以使智能体在每个时刻都能选择误差最小的预测模型。具体而言，模型选择不仅依赖于当前时刻的预测误差，还考虑到相邻时间

中国知网 https://www.cnki.net

步的误差,从而优化整个预测过程。

在此阶段,本文采用基于值函数的强化学习为每个时间步选择最佳预测模型。本文将动态预测问题建模为马尔可夫决策过程。状态对应当前时刻的模型选择情况。动作对应下一时刻选择哪个模型。奖励对应预测误差的负值。这种建模方式将负荷预测的时序决策问题转化为序贯优化问题。在每个回合,智能体从初始状态 s_0 开始,选择动作 a,以概率 p 从当前时刻状态 s_t 转移到下一时刻状态 s_{t+1}。完成转移后,智能体从环境中获得奖励 R,并更新 Q 值[23]。

为实现动态预测,本文定义适用于 Q 学习的自适应马尔可夫决策过程(Markov decision process,MDP)环境框架。t 时刻的状态集合 S_t 和动作集合 A 分别由当前时刻可能的预测模型和下一时刻将要选择的潜在预测模型组成。

$$S_t = \{s_t^1, s_t^2, \cdots, s_t^I\} \tag{11}$$

式中:I 为模型池中预测模型的数量,个;s_t^I 为 t 时刻选择的第 I 个预测模型。

$$A = \{a_1, a_2, \cdots, a_I\} \tag{12}$$

式中:a_I 为在下一时刻选择预测模型的动作。

本文将动态预测任务细化为每个时刻模型的选择,即当每个时刻都选择了最优模型时,动态预测将达到最优解。因此,本文采用了递减的 ε_t-贪心方法来探索和利用下一时刻的模型[24]。在训练初期,本文随机选择 $a \in A$,以获取不同动作的奖励矩阵。随着训练次数的增加,随机性逐渐减小。根据当前观察到的数据,本文选择具有最高奖励的动作 a_j。对于智能体而言,下一时刻采取动作的质量极大地取决于从环境中获得的奖励。因此,有必要优化奖励函数。为保证在每个时间步都能搜索到最佳模型,本文采用了关联相邻时间步误差排名的奖励矩阵设计。

$$R(s_0^i, a_j) = \psi\left(\frac{\hat{y}_1^i - y_1}{y_1}\right) \tag{13}$$

式中:$\psi(\cdot)$ 为模型预测误差的排名,预测误差越小则排名越高。

$$R(s_t^i, a_j) = \psi\left(\frac{\hat{y}_{t-1}^i - y_{t-1}}{y_{t-1}}\right) - \psi\left(\frac{\hat{y}_t^i - y_t}{y_t}\right) \tag{14}$$

式中:$\hat{y}_t^i$ 为模型池中第 i 个预测模型 M_i 在 t 时刻获得的预测值;y_t 为 t 时刻的实际值。

本文通过关联相邻时间步的排名差异,确保模型的改进;对模型性能进行排名,以提高 Q 学习的收敛速度。本文在定义了 MDP 环境后,使用测试集训练智能体以生成总的折扣奖励 Q^* 值。本文根据最优策略 $\pi^* = \text{argmax}_{j \in L} Q_n(M_i^n, M_j)$,将 Q^* 值转换为每个时刻选择的模型集合。本文将 π^* 作为每个时刻步动态预测的依据。

3　数值模拟与结果分析

3.1　试验设置与数据集选择

首先,本文采用预测误差评估指标对候选模型的超参数进行微调。在基于 Q 学习的动态模型选择过程中,本文以最高总折扣回报作为参数设置标准。Q 学习的学习率 α 设置为 0.1,以确保收敛性并加速优化。动态预测训练步数 P 设置为 2,即智能体每 2 个时刻训练 1 次,以降低探索最优模型的时间成本。折扣因子 γ 设置为 1,表示未来奖励与当前奖励同等重要。贪心参数 ε 设置为 0.9,以提高智能体对最佳动作的利用效率,并以 100 次训练为收敛标准。所有试验在 Matlab 2023b 环境下,使用搭载 Intel Core i5-7300HQ CPU、2.50 GHz 及 8 GB RAM 的计算机进行,以确保试验的可重复性和结果的一致性。

试验采用多地区的实际电力负荷数据。数据来源于各城市电力系统运营商。数据涵盖 2019 年前 3 个月的负荷时间序列。

2019 年前 3 个月不同城市的电力负荷时间序列如图 2 所示。

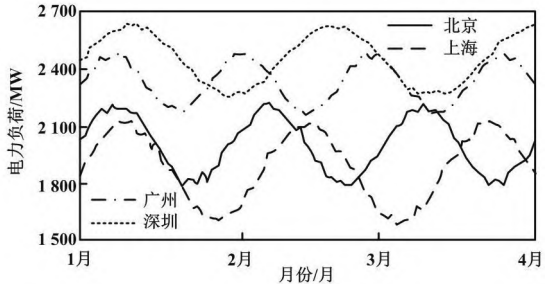


图 2　2019 年前 3 个月不同城市的电力负荷时间序列

Fig. 2　Time series of electricity load in various cities for first three months of 2019

北京、上海、广州和深圳分别代表了中国不同地理区域和气候特征的典型城市,且均为经济发达地区。4 个城市的电力负荷特性具有一定相似性但又存在差异,适用于验证迁移学习方法的有效性。数据集被划分为训练集和测试集。本文在此基础上构建源域和目标域,并开展两阶段预测。为避免负迁移,本文采用皮尔逊相关系数对不同城市间母线负荷数据分布的相似性进行量化评估。

城市间母线负荷数据的皮尔逊相关系数如图 3 所示。

中国知网　https://www.cnki.net

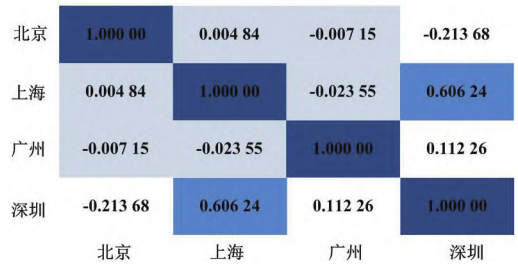


图 3 城市间母线负荷数据的皮尔逊相关系数

Fig. 3 Pearson correlation coefficients of busbar load data between cities

图 3 中的颜色深浅表示皮尔逊相关系数的数值大小:颜色越深表示相关性越强;颜色越浅表示相关性越弱。由图 3 可知,不同城市间的皮尔逊相关系数较高,地理位置相近的城市负荷数据分布更相似。从电力系统角度分析,不同城市间负荷分布的相似性源于相近的经济发展水平、产业结构和用电习惯,而差异性则来源于气候条件、地理位置和季节特征的不同。

3.2 模型的训练过程及性能评估指标

在模型的训练过程中,本文对候选模型进行参数迁移和微调,以确保模型能够适应目标域的数据分布。本文利用 Q 学习算法进行动态模型选择。每个时间步选择最优模型以进行负荷预测。为了评估预测性能,本文采用了 4 种常用的预测误差评估指标:平均绝对误差(mean absolute error,MAE);均方根误差(root mean square error, RMSE);平均绝对百分比误差(mean absolute percentage error, MAPE);对称平均绝对百分比误差(symmetric mean absolute percentage error,SMAPE)。

3.3 试验结果与分析

候选模型的参数迁移学习结果如表 1 所示。

表 1 候选模型的参数迁移学习结果

Tab. 1 Parameter transfer learning results of candidate models

模型代号	模型名称	无迁移学习				迁移学习			
		MAE	RMSE	MAPE/%	SMAPE /%	MAE	RMSE	MAPE/%	SMAPE /%
M_1	BP	23.45	31.23	2.15	2.17	20.58	28.12	1.91	1.88
M_2	ELM	21.76	28.51	1.98	1.95	20.12	27.83	1.85	1.84
M_3	ENN	23.97	29.75	2.15	2.15	21.84	28.32	2.02	2.06
M_4	GRU	19.75	25.57	1.85	1.83	17.83	23.91	1.73	1.68
M_5	LSTM	20.56	26.33	1.96	1.88	18.55	24.05	1.65	1.63
M_6	RBF	21.81	28.06	1.99	1.96	20.23	27.67	1.86	1.85

表 1 给出了以北京为源域、上海为目标域条件下,各候选模型在参数迁移前后的预测误差对比结果。由表 1 可知,经过参数迁移后,6 种候选模型的各项预测误差均有所降低,表明参数迁移能够有效提升模型的预测性能。具体而言,在未采用迁移学习时,GRU 的 MAE、RMSE、MAPE 和 SMAPE 均为 6 种候选模型中的最低值。采用迁移学习后,GRU 的 MAE 和 RMSE 取得最优结果;LSTM 的 MAPE 和 SMAPE 取得最优结果。该结果说明 GRU 和 LSTM 均具有较强的时序特征提取能力。其中,GRU 在绝对误差指标上表现更优,LSTM 在相对误差指标上表现更优,两者整体预测性能较为接近。在 SMAPE 指标上,BP、ELM、ENN、GRU、LSTM 和 RBF 采用迁移学习后,相较于未采用迁移学习分别降低了 13.36%、5.64%、4.19%、8.20%、13.30%和 5.61%。该结果进一步验证了参数迁移学习的有效性。

不同模型的预测结果对比如图 4 所示。由图 4 可知,采用迁移学习的预测曲线与实际负荷曲线更为接近,且波动幅度更小。这表明迁移学习有效地减少了预测误差和过拟合现象。特别是在负荷波动较大的时段,迁移学习后的模型能够更准确地捕捉负荷变化的趋势,进而提升预测的鲁棒性和稳定性。尽管 LSTM 和 GRU 在迁移学习前后均表现出较低的预测误差,但与其他模型相比,LSTM 和 GRU 误差的差异并不显著。这表明选择 LSTM 和 GRU 作为候选模型是合理的。因为它们在具备较强的预测能力的同时具有较高的适应性和泛化能力。此外,BP、ELM、ENN 和 RBF 在迁移学习后的性能提升,进一步证明了这些模型在不同任务和数据域中的适用性。

为了更直观地展示动态预测阶段的性能,本文通过绘制小提琴图进行评估。小提琴图展示了模型在预测母线负荷序列时的表现分布和概率密度。横轴代表候选模型和通过动态模型选择、迁移学习优化的预测模型 M^*,纵轴代表各模型的排名。每个小提琴图描绘了模型在负荷序列每个时间步生成的预测排名频率分布。

中国知网 https://www.cnki.net

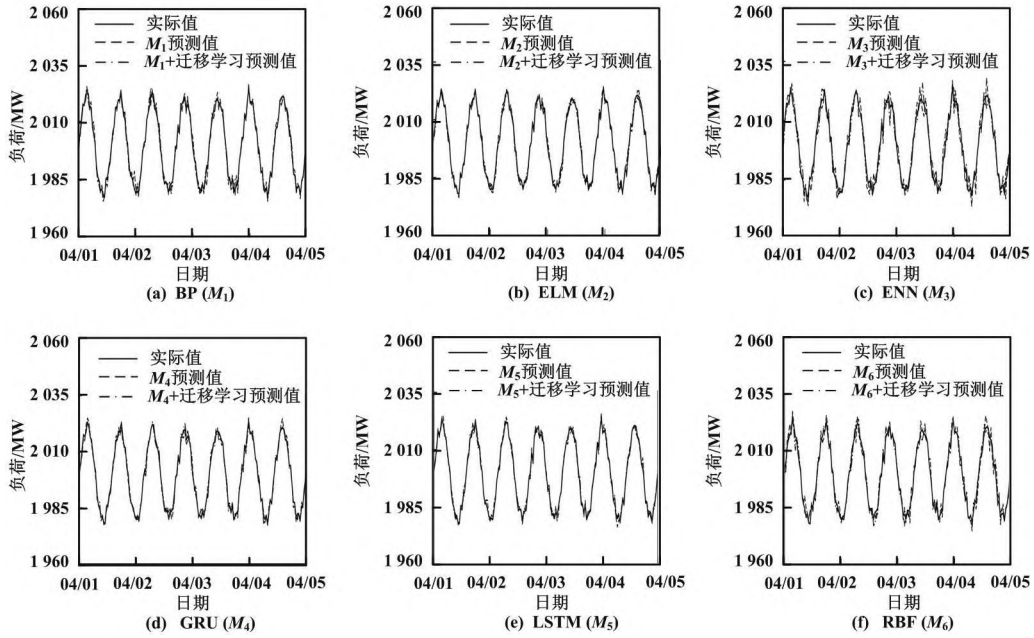


图 4　不同模型的预测结果对比图

Fig. 4　Comparison diagram of prediction results from different models

预测模型排名的小提琴图如图 5 所示。

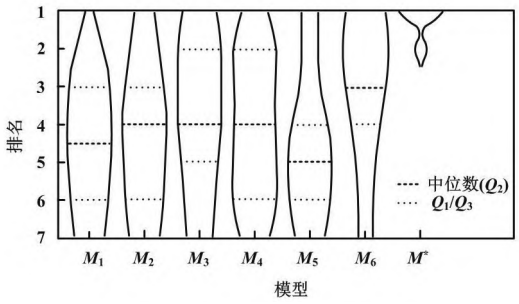


图 5　预测模型排名的小提琴图

Fig. 5　Violin diagram of prediction model rankings

图 5 中:Q_1、Q_2 和 Q_3 分别为排序结果的第一四分位数、中位数和第三四分位数。

由图 5 可知,候选模型的小提琴图呈现出较为均匀的分布。这意味着每个候选模型在某些时间步可能达到最佳预测性能,也可能表现最差。精度提升的机理主要归因于以下几个因素。首先,迁移学习通过将源域的知识迁移至目标域,显著降低了训练时间并提升了预测精度。其次,动态模型选择结合 Q 学习算法能根据实时数据优化模型选择,从而提高预测的稳定性。最后,适当设置 γ 和 ε,能够保证模型在探索和利用之间的良好平衡,并进一步提升模型的精度和鲁棒性。

为全面评估所提方法在不同源域与目标域组合下的泛化能力,所提模型在不同源域与目标域组合下的预测误差如表 2 所示。由表 2 可知,模型 M^* 在所有域对中均表现最佳,MAE 与 RMSE 较其他模型平均降低 40%以上,且预测精度与稳定性均显著提升。值得注意的是,尽管不同城市间的相似性系数从 0.939 91 降至 0.841 35,M^* 的预测误差变化仍极小,即使在相似性最低的域对(如北京 & 深圳)中仍保持优异性能。而传统模型($M_1 \sim M_6$)在相似性较低的域对中误差显著增大、波动明显,进一步凸显了 M^* 在参数迁移与动态预测机制上的优势。在所有域对中,M^* 的 MAPE 与 SMAPE 显著优于其他模型。综上所述,模型 M^* 在多种城市组合下均展现出卓越的预测性能与强泛化能力,能够有效适应不同数据分布并显著降低预测误差。这验证了所提方法在参数迁移与动态预测阶段的有效性与实用性。

线性探测方法被用来评估神经网络的泛化能力,特别是可以评估在迁移学习后网络是否能适应目标域的特征。通过在不同目标域上对神经网络的隐藏层输出进行线性回归,即可验证特征的适应性及其对目标任务的有效性。对于 LSTM 和 GRU 模型,本文提取这 2 个模型在源域和目标域训练后的隐藏层输出,并训练 1 个简单的线性回归模型,以评估它们在目标域上的预测误差。

中国知网　https://www.cnki.net

表2 所提模型在不同源域与目标域组合下的预测误差

Tab. 2 Prediction errors of proposed model under different combinations of source domain and target domain

源域&目标域	模型代号	MAE	RMSE	MAPE/%	SMAPE/%
北京&上海	M_1	23.45	31.20	2.15	2.10
	M_2	21.70	28.50	1.98	1.95
	M_3	23.90	29.70	2.18	2.15
	M_4	19.75	25.50	1.85	1.83
	M_5	20.50	26.30	1.90	1.88
	M_6	21.80	28.00	1.99	1.96
	M^*	10.48	15.83	1.02	1.03
上海&广州	M_1	22.30	30.10	2.10	2.05
	M_2	20.50	27.80	1.90	1.88
	M_3	22.80	28.90	2.12	2.10
	M_4	18.60	24.30	1.75	1.73
	M_5	19.30	25.80	1.85	1.83
	M_6	20.30	27.50	1.95	1.93
	M^*	9.85	14.90	0.98	1.00
北京&广州	M_1	24.10	32.00	2.25	2.20
	M_2	22.50	29.00	2.05	2.00
	M_3	24.50	30.80	2.28	2.25
	M_4	20.10	26.10	1.90	1.88
	M_5	21.00	27.00	1.95	1.93
	M_6	22.20	28.30	2.00	1.98
	M^*	10.15	16.10	1.05	1.07
深圳&北京	M_1	25.00	33.50	2.30	2.25
	M_2	23.00	30.20	2.10	2.05
	M_3	25.50	31.80	2.35	2.30
	M_4	21.00	27.50	1.95	1.93
	M_5	21.80	27.80	2.00	1.98
	M_6	23.00	29.50	2.05	2.00
	M^*	10.80	16.50	1.10	1.12
深圳&上海	M_1	24.50	32.80	2.25	2.20
	M_2	22.80	29.50	2.00	1.95
	M_3	25.00	31.50	2.30	2.25
	M_4	20.50	26.80	1.90	1.88
	M_5	21.30	27.50	1.95	1.93
	M_6	22.50	28.80	2.00	1.98
	M^*	10.60	16.30	1.08	1.10
北京&深圳	M_1	25.50	34.00	2.35	2.30
	M_2	23.50	30.50	2.15	2.10
	M_3	25.80	32.00	2.40	2.35
	M_4	21.50	28.00	2.00	1.98
	M_5	22.20	28.50	2.05	2.03
	M_6	23.50	30.00	2.10	2.05
	M^*	11.00	17.00	1.15	1.17

不同源域和目标域组合下的预测精度评估如表3所示。

表3 不同源域和目标域组合下的预测精度评估

Tab. 3 Prediction accuracy evaluation under different combinations of source domain and target domain

源域&目标域	模型	MAE	RMSE	MAPE/%	SMAPE/%
北京&上海	LSTM	11.2	16.5	1.1	1.2
	GRU	11.3	16.7	1.2	1.3
上海&广州	LSTM	9.8	14.8	0.9	1.0
	GRU	9.9	15.0	1.0	1.1
北京&广州	LSTM	10.0	15.8	1.0	1.1
	GRU	10.2	16.0	1.1	1.2
深圳&北京	LSTM	10.8	16.6	1.1	1.2
	GRU	11.0	16.8	1.2	1.3

由表3可知,LSTM和GRU在源域和目标域之间保持了较为一致的性能。这表明在迁移学习后,神经网络能够较好地保持泛化能力,且目标域的特征通过线性探测得到了较好的适应。

为验证本文方法的有效性,本文选取信息稀疏Transformer(informative sparse Transformer,Informer)、时间卷积网络(temporal convolutional network,TCN)、时空图卷积网络(spatio-temporal graph convolutional network,STGCN)及卷积神经网络-长短期记忆网络-注意力机制模型(convolutional neural network-long short-term memory-attention,CNN-LSTM-Attention)作为基准模型,在以北京为源域、上海为目标域的跨域预测任务中进行对比试验。

与先进模型的对比结果如表4所示。

表4 与先进模型的对比结果

Tab. 4 Comparison results with state-of-art models

模型	MAE	RMSE	MAPE/%	SMAPE/%
Informer	12.85	18.23	1.25	1.28
TCN	13.42	19.15	1.32	1.35
STGCN	14.28	20.05	1.38	1.42
CNN-LSTM-Attention	11.92	17.45	1.18	1.21
M^*	10.48	15.83	1.02	1.03

由表4可知,M^*的指标均优于对比的先进模型。相比表现次优的CNN-LSTM-Attention模型,M^*的MAE降低12.08%、RMSE降低9.28%、MAPE降低13.56%、SMAPE降低14.88%。这主要归因于:动态模型选择机制能够针对不同时间点的负荷特性自适应选择最优模型;迁移学习有效利用了源域数据的知识,弥补了目标域数据的不足;多模型协作充分发挥了各模型的互补优势。

以源域北京、目标域上海为例,各模型的预测时间序列如图6所示。

中国知网 https://www.cnki.net

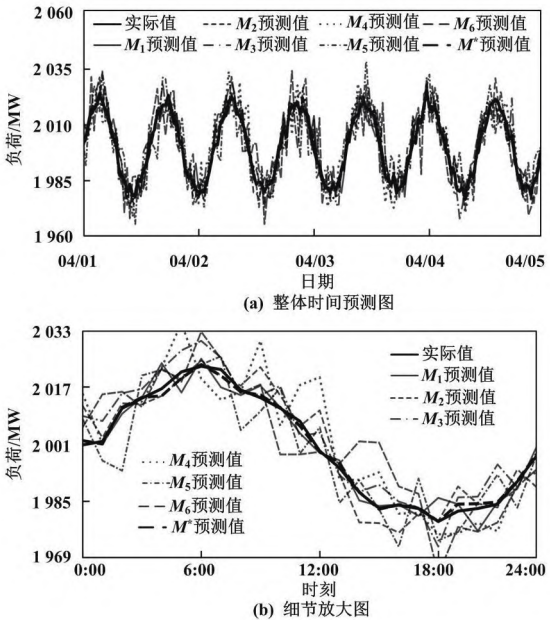


图 6　各模型的预测时间序列图

Fig. 6　Prediction time series diagram for each model

由图 6 可知,各模型的预测值与实际值高度重叠,展示了候选模型在处理时间序列任务上的优势。值得注意的是,所有候选模型在预测峰值和谷值时均与实际负荷曲线存在一定偏差。本文进一步放大 2019 年 4 月 5 日全天的负荷变化(图 6(b))以更清晰地展示预测结果。由图 6(b)可知,本文模型在多数时间步选择了预测性能最佳的候选模型,从而在峰值和谷值点的预测曲线上相比候选模型得到了有效提升。

4　结论

本文提出了 1 种基于动态多模型迁移的母线负荷预测方法,通过结合迁移学习与多模型协作,显著提升了短期负荷预测的精确性和稳定性。试验结果表明,该方法在不同源域与目标域组合下均优于传统模型:MAE 和 RMSE 降低超过 40%;MAPE 和 SMAPE 降至 1.02%~1.15%。该方法显示出卓越的预测性能和强大的泛化能力。尤其在可再生能源广泛整合的复杂电力系统环境中,该方法能够有效应对数据量有限和数据分布变化带来的挑战,从而确保电力系统的高效和可靠运行。后续研究将进一步优化迁移策略,探索更多样化的模型协作机制,并在更大规模和多样化的数据集上验证该方法的应用潜力,以推动电力系统负荷预测技术的持续发展和智能化管理。

参考文献:

[1] 陈毓春,付峰,王忠东,等. 考虑源网荷储互动的台区峰谷负荷平衡方法研究[J]. 自动化仪表,2024,45(9):90-94.

[2] 马玉坤,王泳,梁世锋,等. 考虑储能的 CEEMDAN-LSTM 的工业园区短期负荷预测[J]. 电气自动化,2025,47(1):58-60,63.

[3] 舒舟,欧莉玲,何丰,等. 零碳排放下电-气综合能源系统多能负荷预测[J]. 自动化仪表,2024,45(2):116-121.

[4] 曹帅,尹杰,李艺丰,等. 基于 VMD-SSA-BiLSTM 的多维时序电力负荷预测[J]. 电力需求侧管理,2024,26(6):88-93.

[5] 李强,赵峰,吴金淦,等. 基于融合集成算法的配电网负荷预测研究[J]. 自动化仪表,2024,45(1):111-115,121.

[6] 孙震,徐昊,朱洪志,等. 基于分解重构与特征筛选的短期电力负荷预测[J]. 电气自动化,2025,47(1):61-63.

[7] 冯崇峰,孟春旅,冯积家. 基于混合深度学习的电力负荷预测模型[J]. 电力需求侧管理,2024,26(6):94-100.

[8] 唐滨钧,邝先验,吴丹. 基于改进 BiLSTM-RF 的短期负荷预测研究[J]. 自动化仪表,2024,45(2):59-63,68.

[9] 刘昕明,吉建光,李玮,等. 基于双模态分解的发电站母线短期负荷预测[J]. 电气工程学报,2024,19(1):124-132.

[10] 汤义勤,邹宏亮,蒋旭,等. 基于 VMD 和贝叶斯优化 LSTM 的母线负荷预测方法[J]. 电网与清洁能源,2023,39(2):46-52,59.

[11] 丁施尹,谭锡林,叶萌,等. 含高比例分布式光伏的母线负荷预测方法[J]. 可再生能源,2021,39(1):117-122.

[12] 程明,翟金星,马骏,等. 基于迁移学习的 CNN-GRU 短期电力负荷预测方法[J]. 武汉大学学报(工学版),2024,57(6):812-820.

[13] 卢俊菠,刘俊峰,罗燕,等. 基于改进 WGAN 考虑特征分布相似性的小样本负荷预测方法[J]. 控制理论与应用,2024,41(4):597-608.

[14] 欧阳福莲,王俊,周杭霞. 基于改进迁移学习和多尺度 CNN-BiLSTM-Attention 的短期电力负荷预测方法[J]. 电力系统保护与控制,2023,51(2):132-140.

[15] JI L, FU C, JU Z, et al. Short-term canyon wind speed prediction based on CNN-GRU transfer learning[J]. Atmosphere, 2022, 13(5):813-822.

[16] WANG Y, LIU Y, CHEN W, et al. Target transfer Q-learning and its convergence analysis[J]. Neurocomputing, 2020, 392(1):11-22.

[17] VIVEK V P, BHATNAGAR S. Efficient energy management in smart grids with finite horizon Q-learning[J]. Sustainable Energy, Grids and Networks, 2024, 38(1):101 277-101 288.

[18] DENG Z, CHEN Q. Reinforcement learning of occupant behavior model for cross-building transfer learning to various HVAC control systems[J]. Energy and Buildings, 2021, 238(2): 110 860-110 875.

[19] CAI L, SUN Q, XU T, et al. Multi-AUV collaborative target recognition based on transfer-reinforcement learning[J]. IEEE Access, 2020, 8(5):39 273-39 284.

[20] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521:436-444.

[21] ZHANG Y, YANG Q. An overview of multi-task learning[J]. National Science Review, 2018, 5(1):30-43.

[22] 欧锋,罗醒华,龙经纬,等. 基于图转换和迁移学习的低压配电网户变关系和相位识别方法[J]. 浙江电力,2024,43(3):95-103.

[23] 李志军,徐博,张家安,等. 基于 TD3 可变长度时间窗口最优加权的短期负荷预测策略[J]. 电力建设,2024,45(6):140-148.

[24] 陈渊博,周翔宇,荣发权,等. 基于改进深度强化学习的电力安全调度模型设计[J]. 自动化仪表,2025,46(7):87-91.

中国知网　https://www.cnki.net