基于TimeVAE和迁移学习的综合能源系统负荷预测方法

陈　哲[1,2]，周金辉[1,2]，靳东辉[1,2]，陈积光[1,2]，马恒瑞[3,4]，张嘉鑫[3,4]，朱苏洵[3,4]

（1. 国网浙江省电力有限公司，杭州　310007；
2. 国网浙江省电力有限公司瑞安市供电公司，浙江　温州　317101；
3. 交直流智能配电网湖北省工程中心，武汉　430072；
4. 武汉大学　电气与自动化学院，武汉　430072）

摘　要：提出一种基于TimeVAE（时间变分自动编码器）和TL（迁移学习）的集成学习方法，用于解决IES（综合能源系统）中新建系统因历史数据稀缺导致负荷预测精度下降的问题。通过TimeVAE的变分自编码器生成负荷数据，增强目标域数据集的多样性；利用具有丰富历史数据的源域知识，通过冻结训练策略优化目标域负荷预测模型。基于亚利桑那州立大学不同校区IES的数据，验证了所提方法的有效性。实验结果表明，该方法在小样本情况下显著提升了负荷预测的精度，为实现IES负荷预测的高效性和可靠性提供了重要参考。

关键词：TimeVAE；迁移学习；小样本负荷预测；综合能源系统；数据增强；冻结训练策略；多能负荷预测

DOI: 10.19585/j.zjdl.202509006　　开放科学（资源服务）标识码（OSID）：

A load forecasting method for IESs using TimeVAE and transfer learning

CHEN Zhe[1,2]，*ZHOU Jinhui*[1,2]，*JIN Donghui*[1,2]，*CHEN Jiguang*[1,2]，*MA Hengrui*[3,4]，*ZHANG Jiaxin*[3,4]，*ZHU Suxun*[3,4]

（1. State Grid Zhejiang Electric Power Co.，Ltd.，Hangzhou 310007，China；
2. State Grid Ruian Power Supply Company，Wenzhou，Zhejiang 317101，China；
3. Hubei Engineering Research Center for AC/DC Intelligent Distribution Network，Wuhan 430072，China；
4. School of Electrical Engineering and Automation，Wuhan University，Wuhan 430072，China）

Abstract: In this paper，an integrated learning approach based on time variational autoencoder（TimeVAE）and transfer learning（TL）is proposed to address the accuracy degradation in integrated energy systems（IESs）load forecasting caused by insufficient historical data in newly built systems. The TimeVAE-based variational autoencoder generates load data to enhance the diversity of the target-domain dataset，while the source-domain knowledge with abundant historical data is leveraged to optimize the target-domain load forecasting model through a frozen training strategy. Based on IES data from multiple campuses of Arizona State University，the effectiveness of the proposed method is validated. Experimental results demonstrate that the method significantly improves load forecasting accuracy under few-shot conditions，providing critical references for achieving efficient and reliable IES load forecasting.

Keywords: TimeVAE；transfer learning；few-shot load forecasting；IES；data augmentation；frozen training strategy；multi-energy load forecasting

0　引言

IES（综合能源系统）整合电力、燃气、热能和冷能等多种能源形式，实现能源的高效利用和供需平衡，是应对可再生能源渗透和提升能源效率的重要方法[1-7]。负荷预测在IES中至关重要，直接影响能源供应的经济效益和系统稳定性。然而，可再生能源的间歇性特性和数据不足问题增加了负荷预测的难度。特别是在新建IES中，缺乏足够的历史数据限制了模型训练的效果[8-9]，因此小

基金项目：国家自然科学基金（61933005）；国网浙江省电力有限公司科技项目（2006CB200303）

中国知网　https://www.cnki.net

样本负荷预测成为研究热点。解决小样本问题是实现IES数字化转型和可持续发展的关键之一。

TL（迁移学习）是人工智能领域的先进技术，其核心是通过复用源域（数据充足领域）的知识解决目标域（数据不足领域）的任务[10]。TL广泛应用于图像分类、文本分析等领域，近年来也被用于负荷预测，特别是建筑能源预测[11]。其通常采用共享模型参数的方式实现跨域知识迁移，减少模型在小数据集上的过拟合。例如，文献[12]提出了一种多源迁移学习引导的集成LSTM（长短期记忆网络）预测方法，通过优势比较的源域建筑匹配和基于相似度的模型集成策略，结合多个源域数据为建筑负荷预测生成高精度的基本模型。文献[13]提出了一种基于两层TL的短期负荷预测架构，并构建潜在参数辅助模型学习目标区和源区负荷的关系。文献[14]结合两阶段传递回归模型和TL，对电力负荷数据进行预测。文献[15-16]利用TL优化原模型的热负荷预测性能。文献[17]开发CNN-GRU（卷积神经网络-门控循环单元）组合作为源模型，提出基于最大均差的模型结构调整策略，协同TL实现目标域负荷预测。上述研究表明，基于参数的TL方法能够利用预训练模型提取通用特征，降低目标域对大量标注数据的依赖，从而提升小样本场景下的预测精度。然而，此类TL方法高度依赖源域与目标域的分布相似性，若领域分布差异显著，可能导致负迁移现象[18]。

DA（数据增强）是缓解小样本过拟合的另一重要途径，其通过生成多样化的合成数据[19]，扩充目标域训练样本量，从而提升模型的泛化能力。例如，文献[20]通过结合气象因素和多负荷历史数据，以及基于LSTM构建的生成器和判别器来进行多元负荷预测。文献[21]基于TimeGAN（条件时序生成对抗网络）的楼宇空调负荷场景生成方法，通过结合无监督对抗训练和监督训练，利用楼宇空调负荷的动静态特征作为条件监督项，有效地生成了多个确定性负荷场景。文献[22]采用基于局部融合GAN的小样本图像生成器，通过上下文信息增强细节特征来生成电力缺陷数据。上述基于GAN的方法虽然能缓解模型的过拟合，但存在数据依赖性强、模式崩溃的问题[23]。

值得注意的是，TL与DA在特征空间和输入空间具有互补优化维度[24]：TL可以通过预训练模型提供的跨域特征先验，为增强后的样本提供更鲁棒的特征表示基础；而DA可以通过生成多样化样本，帮助预训练模型更好地适应目标任务的分布差异。例如，文献[25]采用线性插值生成混合样本，扩大训练样本的分布，并迁移其他具有类似消费模式的用户负荷来训练模型。文献[26]将双向的GAN与TL相结合，构建电力负荷预测模型。两种方法的结合形成了双重正则化效应，进一步提升了小样本下的表现[27]。

考虑现有DA和TL方法的局限性以及两者之间的协同潜力，本文提出一种集成TimeVAE（时间变分自动编码器）与基于MMD（最大均值差异）的域适应方法的小样本负荷预测框架。一方面，采用TimeVAE对目标域数据进行增强。相比于GAN及衍生方法，TimeVAE显式地对数据的分布进行建模，能够减少对原始数据的依赖。此外，TimeVAE的潜在空间是连续的，这允许更灵活的随机采样和插值，有助于生成更多样化的样本。另一方面，利用MMD约束跨域知识迁移，筛选出相似度高的源域样本作为模型的预训练数据，缓解负迁移问题。所提方法通过协同DA与TL，进行多维度知识补充，从而优化小样本负荷预测精度。

1　迁移策略和DA策略

1.1　迁移策略

对于新建IES或IES新接入用户，历史负荷数据往往非常有限。在这种情况下，使用现有的负荷预测模型会导致预测准确性显著下降甚至失效。TL可以通过从具有相似负荷消费模式的其他IES或用户转移历史负荷数据来补充数据样本，从而提高预测性能以及避免过拟合。TL定理可描述为：所给定一些源域和任务的数据集$(Dom_{s_i}, Tsk_{s_i})|i=1,2,\cdots,n^{s}$以及一些目标域的数据集和任务$(Dom_{T_i}, Tsk_{T_i})|i=1,2,\cdots,n^{\mathrm{T}}$，TL的目标是将源域知识运用到目标域，以提高学习到的决策函数$f^{\mathrm{T}}j(j=1,2,\cdots,n^{\mathrm{T}})|$的预测性能。

图1展示了TL两种策略：全参数微调和冻结训练。在全参数微调过程中，以源域数据训练得到的源模型作为初始状态，然后在目标域数据上

中国知网　https://www.cnki.net

继续训练来对所有参数进行优化。这种策略可以很好地拟合目标域数据，但需要较多的计算资源和时间。此外，如果目标域数据质量较低可能会导致后继学习对先前学习产生消极影响。因此，全参数微调适合源域和目标域之间差异较大，或者目标域数据较多且质量较高的情况。相比之下，冻结训练中源模型的大部分权重保持不变，仅更新顶层参数权重(通常是输出层)以适应目标任务。这种策略能够继承源模型的有用特征，减少资源消耗及过拟合风险，但也可能因源域和目标域之间的差异较大而产生负迁移现象。在本章中，考虑到目标域是新建的IES，其样本数据量较少，且源域为具有丰富历史负荷数据的同类型IES，选择冻结训练模式进行TL。

为评估源域IES数据和目标IES数据之间的相似性以减少负面迁移，使用MMD度量域之间差异。MMD是一种用于衡量两个概率分布之间差异的方法[28]，通过比较两个分布在特征空间中的均值和协方差来评估它们之间的距离。源域和目标域的分布越相似，则它们在特征空间中的均值和协方差之间的距离越小，MMD值就越接近于0；反之，如果它们之间的分布差异较大，则MMD值较大。

MMD的计算可以通过核函数来实现，通常采用高斯核函数。其计算公式如下：

$$D^2_{\mathrm{MMD}}=\frac{1}{n(n-1)}\sum_{i=1}^{n}\sum_{j=1}^{n}k(x_i,x_j)-\frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m}k(x_i,y_j)+\frac{1}{m(m+1)}\sum_{i=1}^{m}\sum_{j=1}^{m}k(y_i,y_j) \tag{1}$$

式中：n和m分别为源域和目标域的样本数；x_i和y_j分别为源域和目标域的样本；$k(\cdot,\cdot)$为核函数。

1.2 负荷数据生成

负荷序列中复杂的时间依赖性，使得合成数据生成非常具有挑战性。此外，基于GAN的生成模型存在模式崩溃、耗时、训练数据不足等局限性。TimeVAE是一种可以在数据量很小的情况下最大限度地生成真实的时序数据样本的方法[29]。相比于GAN，TimeVAE能够准确表征原始数据的时间属性并且有效减少训练开销。

TimeVAE的模型结构如图2所示。从图2可以看出，输入数据X首先通过一系列卷积层+relu

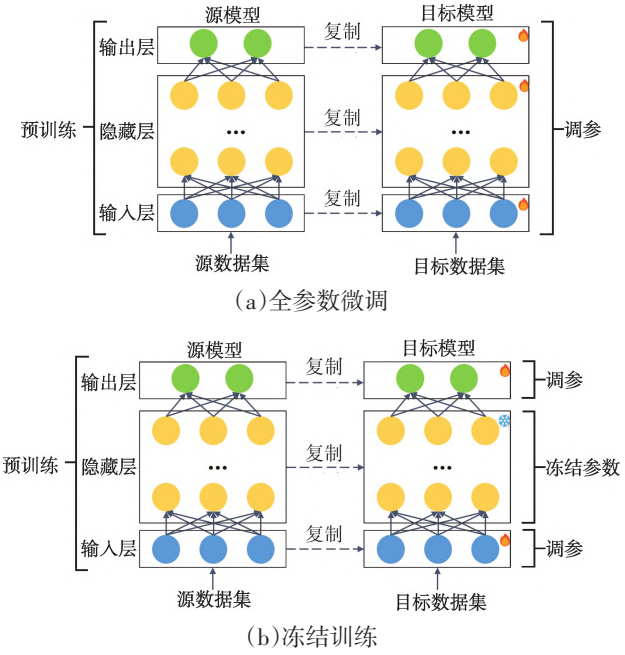


图1 TL策略

Fig.1 Transfer learning strategies

激活函数提取时间序列的特征，接着对卷积层的输出进行flatten(压缩)，送入全连接层。全连接层的输出是潜在变量的分布参数，通常包括均值μ和标准差σ。然后，使用重参数化技巧从多变量高斯分布中采样潜在变量z。解码器接收采样的潜在变量z经过一个全连接层后被reshape(重塑)回三维数组的形状，再通过一系列转置卷积层+relu激活函数重建原始数据，最后利用全连接层生成与原始输入数据X形状相同的输出。假设给定一个输入数据集X，由一些连续或离散变量x的N个样本组成。

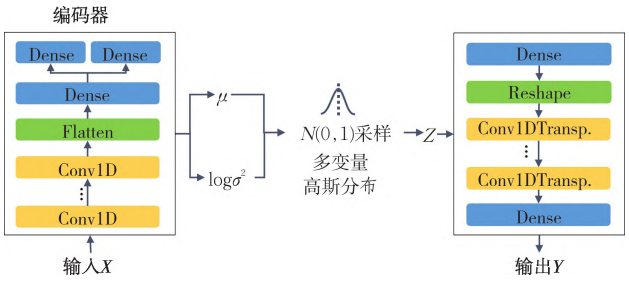


图2 TimeVAE模型架构

Fig.2 Architecture of TimeVAE model

TimeVAE具体工作原理如下。

1)编码器

编码器的输出是输入数据x映射到潜在空间中

中国知网 https://www.cnki.net

的潜在变量z的概率分布。这个分布通常是高斯分布，由编码器网络输出的均值向量μ和方差向量σ^2参数化。假设z是从均值为0，方差为1的标准正态分布中采样得到的噪声。则编码器网络输出的μ和σ^2可以表示为：

$$(\mu, \log\sigma^2)=f_{\text{Encoder}}(x) \tag{2}$$

2)潜在变量采样

为了能够在训练过程中对潜在变量进行采样，需要使用重参数化技巧。先从标准正态分布中采样噪声ϵ，然后利用编码器得到均值μ和标准差σ进行线性变换，计算得到潜在变量z。

$$z=\mu+\epsilon\cdot\sigma \tag{3}$$

式中：ϵ为从标准正态分布中采样。z的采样过程是可微的，这使得VAE可以通过反向传播进行训练。

3)解码器

解码器将潜在变量z映射回原始数据空间，重构出与输入数据x类似的数据样本$\hat{x}$的概率分布。解码器网络的输出表示重构数据的条件分布，则解码器网络输出的条件分布参数θ可以表示为：

$$p_{\theta,}(x|z)=f_{\text{Decoder}}(z) \tag{4}$$

4)损失函数和训练

TimeVAE使用ELBO(证据下界)损失函数进行训练，通过调整网络参数θ和ϕ来最小化损失。该函数由两部分组成：重构误差(负对数似然)和KL散度(正则化项)。ELBO损失函数的公式为：

$$\mathcal{L}_{\text{ELBO}}(\theta,\phi)=-\mathbb{E}_{q\phi}(z|x)[\log p_\theta(x|z)]+D_{\text{KL}}(q_\phi(z|x)\|p_\theta(z)) \tag{5}$$

式中：第一项为重构误差，表示观测数据x的对数似然在后验分布$q_\phi(z|x)$下的期望；第二项为KL散度，表示后验分布$q_\phi(z|x)$与先验分布$p_\theta(z)$之间的KL散度，用于衡量两个分布之间的差异。

2　负荷预测的集成框架

基于此，本文提出了一个基于TimeVAE和TL的集成学习框架，分别执行DA和TL。在TL模块中，基于源域输入集优化模型参数，进行参数的迁移和微调；在DA模块中，通过TimeVAE生成负荷DA目标域数据集，实现模型再训练、参数微调和多能负荷预测。具体流程如图3所示。每个模块的详细计算过程如下。

2.1　DA模块

首先，根据滑动窗口构建原始目标域的真实输入数据集$S^{\text{RAW}}=\{S^{\text{RAW}}_{N_1-a}, S^{\text{RAW}}_{N_1-a+1}, \cdots, S^{\text{RAW}}_{N_1}\}$，以及基于TimeVAE的人工数据集$S^{\text{TVAE}}=\{S^{\text{TVAE}}_{N_2-a}, S^{\text{TVAE}}_{N_2-a+1}, \cdots, S^{\text{TVAE}}_{N_2}\}$。$N_1$和$N_2$分别为真实输入集、人工输入集的样本数量，$a$为滑动窗口长度。则$t$时刻对应的原始样本为：

$$S^{\text{RAW}}_t=[X_{t-a}X_{t-a-1}, \cdots, X_{t-1}] \tag{6}$$

$$X_{t-1}=[f^1_{t-1}, f^2_{t-1}, \cdots, f^m_{t-1}] \tag{7}$$

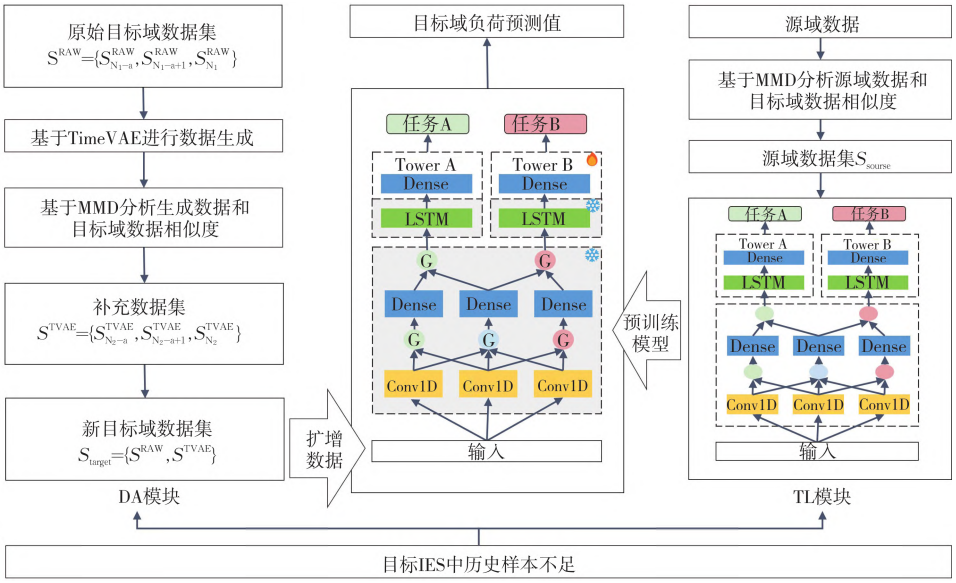


图3　基于TimeVAE和TL的集成学习框架

Fig.3　An integrated learning framework based on TimeVAE and transfer learning

中国知网　https://www.cnki.net

式中：X_{t-1}为t-1时刻的特征序列；m为特征数量。

然后，使用TimeVAE对t时刻输入特征进行增强，生成的数据表示为：

$$S_t^{\mathrm{TVAE}}=[\hat{X}_{t-a},\hat{X}_{t-a-1},\cdots,\hat{X}_{t-n}] \tag{8}$$

为了确保由TimeVAE生成的人工样本与真实样本数据具有相同的分布，使用MMD来衡量人工数据集和真实数据集之间的相似性。当两个数据集的相关系数低于某一阈值时判断生成失败，重新进行生成。最终目标域输入集表示为：

$$S^{\mathrm{target}}=\{S^{\mathrm{RAW}},S^{\mathrm{TVAE}}\} \tag{9}$$

2.2 TL模块

首先，使用S^{target}来训练目标预测模型M^{T}。该模型继承了源模型M^{S}包含的丰富知识，即相似IES的负荷变化模式。考虑可以利用负荷之间的耦合关系来提高小样本负荷的预测性能，源模型采用短期负荷联合预测模型CPLE[30]。根据实验中表现，采用底层共享网络固定、顶层塔式网络微调的迁移策略。其训练框架包括以下两个步骤：

1)采用MMD筛选得到与目标数据S^{target}相似的源数据S^{sourse}。使用S^{sourse}训练负荷预测模型M^{S}最小化损失值函数：

$$\min_{\theta^{\mathrm{T}}}\left\| M^{\mathrm{S}}(\theta^{\mathrm{S}},S_{\mathrm{in}}^{\mathrm{sourse}})S_{\mathrm{out}}^{\mathrm{sourse}}\right\|^2 \tag{10}$$

式中：M^{S}为通过源数据构建的模型；θ^{S}为M^{S}的参数；$S_{\mathrm{in}}^{\mathrm{sourse}}$为预测负荷对应的输入序列；$S_{\mathrm{out}}^{\mathrm{sourse}}$为预测负荷的真实值。

2)使用包括原始数据和人工数据的目标数据来训练目标预测模型M^{T}。其共享层从M^{S}继承并在训练期间固定：

$$\min_{\theta^{T}}\|M^{\mathrm{T}}(\theta^{\mathrm{T}},S_{\mathrm{in}}^{\mathrm{target}}|\theta^{\mathrm{S}*})S_{\mathrm{out}}^{\mathrm{target}}\|^2 \tag{11}$$

式中：θ^{T}为M^{T}的参数；$S_{\mathrm{in}}^{\mathrm{target}}$为目标域预测模型的输入；$S_{\mathrm{out}}^{\mathrm{target}}$为预测负荷的真实值；$\theta^{\mathrm{S}*}$为$M^{\mathrm{S}}$模型共享层的优化参数。

3 算例分析

3.1 数据来源与实验环境

本文实验数据包括美国亚利桑那州立大学IES记录的电负荷、冷负荷，以及温度、露点、湿度和气压等天气数据。亚利桑那州立大学共有4个校区，以坦佩校区的IES为目标域，西校区、理工校区、凤凰城市中心校区的IES为源域。负荷采样间隔均为1 h。使用源域3个校区2020年1—12月的负荷作为源域数据。因源域的IES只包含电、冷负荷数据，所以只针对电、冷负荷任务进行训练。本文的重点是验证TimeVAE的DA模块和TL模块对预测精度的提升，因此目标域不需要大量的数据集。考虑小样本场景下导致结果偶然性，选取坦佩校区2021年1—2月和7—8月的负荷作为目标域数据，其中1月和7月数据用于训练，2月和8月数据用于测试。软件平台采用Tensorflow和Keras框架实现。硬件配置包括两个Xeon 4215R CPU和两个NVIDIA RTX 3090 GPU。

3.2 评价指标

本文采用以下指标来量化所提方法的性能。

1)MAE(平均绝对误差)：MAE是预测值与实际值之间的绝对误差的平均值。MAE越小表明预测模型的性能越好，且MAE对偏差较大的样本更敏感。

$$E_{\mathrm{MAE}}=\frac{1}{N}|\hat{y}_i-y_i| \tag{12}$$

式中：y_i为第i个样本的实际值；$\hat{y}_i$为对应的预测值；N为输入集大小。

2)MAPE(平均绝对百分比误差)：MAPE通过残差的百分比来表达预测的准确性。

$$E_{\mathrm{MAPE}}=\frac{1}{N}\sum_{i=1}^{N}\left|\frac{\hat{y}_i-y_i}{y_i}\right|\times 100\% \tag{13}$$

3)RMSE(均方根误差)：RMSE表示模型预测值和真实值之间的平均平方差的平方根。RMSE越低，说明模型越好。

$$E_{\mathrm{RMSE}}=\sqrt{\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i-y_i)^2} \tag{14}$$

4)R2：R2是衡量模型对观测数据的拟合程度的统计量。R2∈[0,1]，越接近1表示模型拟合得越好。

$$E_{\mathrm{R2}}=\left(1-\frac{\sum_{i=1}^{N}(\hat{y}_i-y_i)^2}{\sum_{i=1}^{N}(\bar{y}_i-y_i)^2}\right)\times 100\% \tag{15}$$

式中：$\bar{y}_i$为实际值的平均值。

3.3 输入数据处理

IES的数据分析和处理可以直接影响多能负荷预测的结果。基于目标域，使用MIC(最大信息系数)对变量之间的相关性进行量化。表1展示了两个变量之间的相关程度。MIC值越大，相关程度

中国知网 https://www.cnki.net

越高。选取MIC大于0.3的变量作为输入特征。确定变量可以减少输入数据的冗余以及提高数据质量，为提高预测精度奠定基础。同样，基于源域IES数据，利用MIC过滤模型训练的输入变量。

表1　基于MIC的相关性分析

Table 1　Correlation analysis using MIC

特征	电负荷	冷负荷	温度	露点温度	湿度	压力
电负荷	1					
冷负荷	0.38	1				
温度	0.37	0.47	1			
露点温度	0.14	0.16	0.08	1		
湿度	0.33	0.32	0.35	0.43	1	
压力	0.15	0.24	0.11	0.13	0.07	1

使用MMD度量源域和目标域之间数据分布的相似性来选择源域数据集。如果MMD太大，说明该源域IES与目标域之间的差异较大，可能会导致负迁移。根据表2中结果，选择中心校区2020年1—12月数据为预训练数据集，并按照9∶1的比例划分为训练集和测试集。最后，对数据进行归一化得到目标域和源域的输入数据集。归一化公式如下：

$$x^{*}=\frac{x-x_{\min}}{x_{\max}-x_{\min}} \tag{16}$$

式中：$x_{\max}$为该输入特征序列最大值；$x_{\min}$为该输入特征序列最小值。

表2　源域和目标域间的MMD

Table 2　MMD between source and target domains

目标域	源域		
	西校区	理工校区	凤凰城市中心校区
坦佩校区	0.586	1.002	0.297

3.4　参数设置

本文通过集成3个模型来进行小样本条件下的短期多能负荷预测，包括人工数据生成模型TimeVAE、负荷预测模型CPLE和TL模型，简称为DA-CPLE-TL。通过网格搜索[31]对这些模型的结构和参数进行优化，具体参数设置如下。

3.4.1　TimeVAE模型

TimeVAE模型由编码器，解码器两部分组成。编码器有3个一维卷积层，卷积核大小分别为3、3、3；卷积步长大小分别为2、2、2；滤波器数量分别为50、100、200。每个卷积层的激活函数均为relu。卷积层后接一个flatten操作和一个全连接层，全连接层的维度大小为8。解码器包括3个转置卷积，卷积核大小分别为3、3、3，卷积步长大小分别为2、2、2；滤波器数量分别为100、50，特征数量。每个卷积层的激活函数同样为ReLU。卷积层后接一个flatten操作、一个全连接层以及一个reshape操作，全连接层的维度大小为序列长度*特征数量。Reshape将全连接层的输出重塑为(序列长度，特征数量)。TimeVAE的两个损失的比例为：5(重构损失)∶1(KL散度损失)，并使用Adam优化器来编译TimeVAE。与此同时，为进一步优化TimeVAE重建结果，设置早停策略和学习率衰减回调。早停策略的设置为：如果损失在连续10个epoch(回合)内没有改善(阈值=0.1)，则停止训练。学习率衰减回调的设置为：如果损失在连续5个epoch内没有改善(初始学习率=0.001)，则将学习率减小为原来的0.1倍。最大epoch为300。

3.4.2　预测模型

以CPLE模型进行负荷联合预测。共有两个负荷预测任务：电负荷、冷负荷。CPLE分为共享层和子任务层。共享层有两层，第一层专家网络由一维卷积构成。其中，共享专家模块包括8个专家子网，任务特定专家模块均包括4个专家子网。所有卷积网络的设置相同：滤波器数量为16，卷积核大小为3，卷积步长为1，激活函数为ReLU。第二层专家网络由全连接构成，共享专家模块包括16个专家子网，任务特定专家模块均包括8个专家子网。全连接网络维度均为8。子任务层由一个LSTM(长短期记忆网络)和一个全连接构成，LSTM神经元数量为16，全连接神经元数量为1。

3.4.3　TL模型

对CPLE共享层的结构和权值进行迁移，对电、冷负荷的子任务层进行微调。源IES和目标IES的训练模型结构相同。

3.5　不同TL策略比较

为了验证TimeVAE和TL的有效性以及所提模型的准确性，进行了以下几组对比实验。

算法1：不进行预训练，直接对目标域数据进行预测。

算法2：在源域预训练后，对源模型所有参数

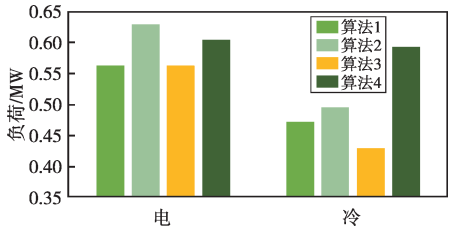
中国知网　https://www.cnki.net

进行微调。

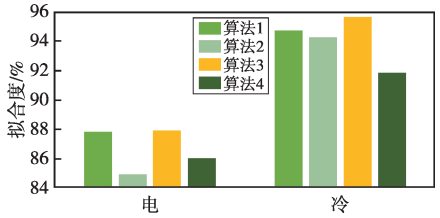
算法3：在源域预训练后，仅冻结源模型共享层参数，对其余参数进行微调。

算法4：在源域预训练后，冻结除输出层之外的所有参数，仅对输出层进行微调。

图4所示为几种算法的对比结果。从图4中可以看出，算法3(本文所提TL方法)的MAPE最小，R2最高。算法2的效果低于算法3，原因是所有参数都被微调，使得网络忘记与源域数据相关的信息。此外，也可能是因为目标域数据量有限，导致模型难以学习到足够信息以适应目标域的数据分布。算法4中出现较为严重的负迁移，这可能是因为保留过多的训练度，使得参数不平衡所导致的。上述结果表明，将包含耦合关系的共享层参数冻结既可以保留较多训练度又可以满足较小目标域数据的需求，从而实现更有效的跨域知识利用。



(a)RMSE



(b)R2

图4 不同TL策略的评价指标

Fig.4 Evaluation metrics of different transfer learning strategies

3.6 不同DA方法比较

同样以CPLE为基线模型，将所提DA方法与其他DA方法进行对比，具体设置如下。

算法5：不进行DA，仅使用目标域数据训练。

算法6：使用TimeGAN对目标域数据进行增强。该模型基于ydata-synthetic库实现。其中，学习率为0.001，epoch为200。其余参数采用默认值。

算法7：使用VAE对目标域数据进行增强。VAE模型由全连接网络组成。其中，编码器维度为[500,250,50]，解码器维度为[50,250,500]。潜在变量z的维度为10，学习率为0.001，epoch为300。

算法8：使用TimeVAE对目标域数据进行增强，参数设置见3.4.1。

图5所示为算法5—8的比较结果。从图5中的结果可以观察到，算法8(所提出的DA方法)在电和冷负荷上的整体指标最好，其次是算法7，算法5和算法6的效果最差。结果表明，基于VAE的DA方法(算法7、8)要优于基于GAN的DA方法(算法6)和不进行DA的方法(算法5)。具体来说，算法5表现较差的原因可能是预测模型仅依赖于目标域有限的原始数据，无法充分捕捉数据分布中的重要特征。而算法6可能受限于GAN生成模型需要足够的数据来训练的特性，当目标域数据量较小时，TimeGAN无法有效地学习到数据分布。相较于算法7，算法8在DA方面表现更加优异的原因在于，其结合了CNN(卷积神经网络)和VAE架构来学习时间序列数据的概率分布。这种结合使得模型能够更加准确地建模时序数据的时间成分，从而更好地生成具有目标域数据特点的合成数据。

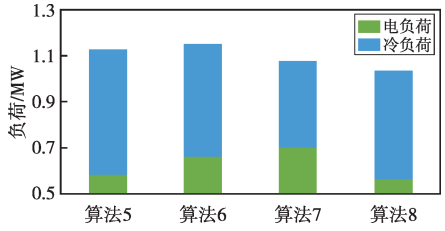
3.7 不同预测模型比较

本文所提模型基于TL和DA，通过模型训练、参数传递、参数微调、DA等优化模型性能。为了验证方案的可行性，将该模型与CNN-LSTM、Transformer[32]、LSTNet-Skip[33]、CNN-BiGRU-Att[34]、MMoE[35]、CPLE[29]模型进行对比。其中，CNN-LSTM是CPLE对应的单任务模型。上述对比模型的参数见表3。对比模型的输入为目标域的原始训练集。

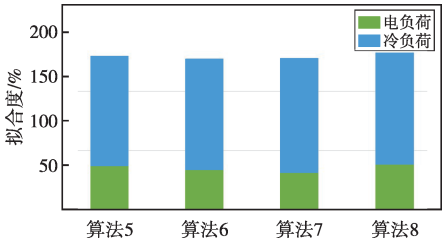
表4对比了不同预测模型在2月测试集上的性能，图6进一步展示了不同模型在连续48 h内的预测曲线。8月测试集结果见表5和图7。从表4和图6中结果可知，所提方案在电、冷负荷预测中更具竞争力，各项指标均优于对比模型，预测曲线最接近真实值。以下对结果进行详细分析。

与基于单任务模型的CNN-LSTM相比，基

中国知网 https://www.cnki.net



(a)RMSE



(b)R2

图5　不同DA策略的评价指标

Fig.5　Evaluation metrics of different data augmentation strategies

表3　对比模型参数

Table 3　Comparison of model parameters

模型类型	模型名称	参数	数值
单任务模型	CNN-LSTM	CNN隐藏单元数量	16
		卷积核大小	3
		Dense隐藏单元的数量	8
		LSTM隐藏单元的数量	16
多任务模型	CNN-BiGRU-Attention	CNN隐藏单元数量	[4,8]
		卷积核大小	[3,3]
		BiGRU隐藏单元的数量	10
		注意力层数	3
		注意力隐藏单元的数量	64
	Transformer	Transformer模块数量	2
		注意力头数	4
		注意力头大小	16
		Dense隐藏单元的数量	16
	LSTNet-Skip	CNN隐藏单元数量	100
		RNN隐藏单元的数量	100
		Skip-RNN层的跳跃长度	4
		卷积核大小	6
		辍学率	0.2
	MMoE	专家数量	4/4/4
		专家隐藏单元数量	32/32/32
		子任务层(LSTM)隐藏单元的数量	[16,8]/[16,8]
		辍学率	0.3

表4　不同预测模型在2月测试集上的预测结果

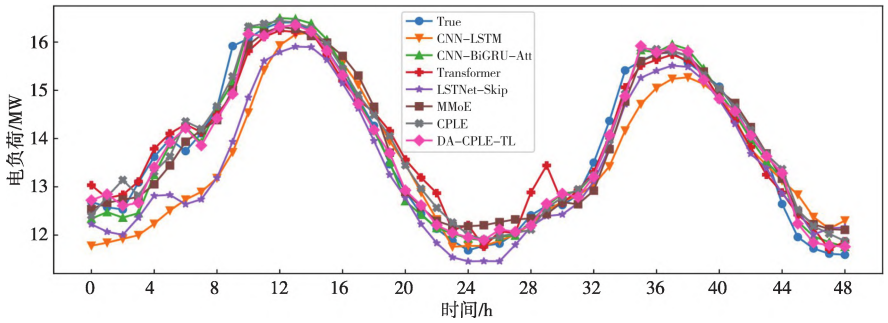
Table 4　Results of different forecasting models on the February test set

模型	MAE/MW		MAPE/%		RMSE/MW		R2/%	
	电	冷	电	冷	电	冷	电	冷
CNN-LSTM	0.60	0.54	3.93	4.87	0.88	0.67	69.7	89.5
Transformer	0.48	0.78	3.21	7.15	0.71	1.06	80.6	74.4
LSTNet-Skip	0.40	0.39	2.64	3.59	0.65	0.57	83.8	92.5
CNN-BiGRU-Att	0.44	0.41	2.90	3.73	0.83	0.63	73.8	90.8
MMoE	0.46	0.40	3.04	3.50	0.66	0.63	83.1	90.9
CPLE	0.40	0.39	2.68	3.56	0.60	0.55	85.9	92.7
DA-CPLE-TL	0.36	0.28	2.39	2.54	0.56	0.43	87.9	95.7

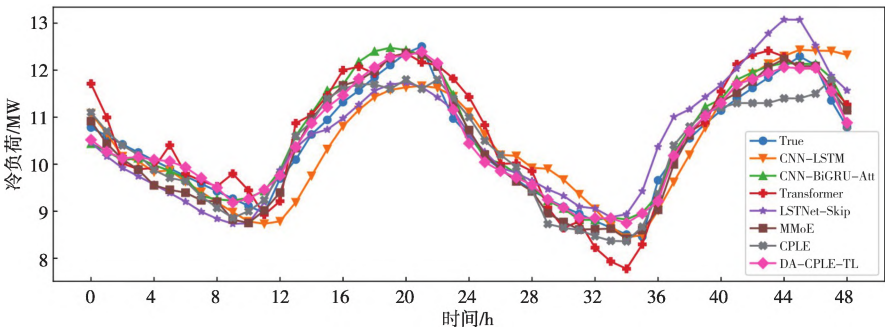
于多任务模型的CPLE在各个评价指标上均表现出优势：电、冷负荷的MAE分别降低了33.72%、29.10%，MAPE分别降低了31.77%、26.89%，RMSE分别降低了32.54%、17.46%，R2分别提高了23.24%、3.58%，表明了多任务架构的优越性。并且与其他对比模型相比，CPLE仍然能够保持出色的性能，验证了CPLE作为基座模型的有效性。多任务架构比单任务架构效果好的原因在于，当样本量较少时，多任务模型可以通过共享层学习任务之间的共性特征，利用相对更多的知识。而单任务模型由于缺乏这种知识共享机制，可利用的信息量有限，从而限制了其预测效果。值得注意的是，在联合预测下，电负荷的改善效果要好于冷负荷，这是由于冷负荷的变化更为规律，相对容易建模，单任务模型已经能够较好地拟合其规律，所以多任务模型对冷负荷的进一步提升空间相对有限。相比之下，电负荷受到更多因素的影响，变化更加复杂和不规律，预测难度显著增加。单任务模型在这种信息量有限且没有额外知识补充的情况下，难以较好地泛化到未知样本，从而使得提升空间较大。

相比于对比模型中预测性能最好的CPLE，DA-CPLE-TL电、冷负荷的MAE分别降低了9.11%、26.23%，MAPE分别降低了10.95%、28.65%，RMSE分别降低了5.38%、22.42%、R2分别提高了2.33%、3.24%。从结果可以看出，冷负荷预测效果提升明显，而电负荷的提升幅度相对较小，这是因为在网络结构相同的情况下，DA-CPLE-TL通过对预测模型特征空间和输入空间的增强，为模型补充了额外的知识，由于冷

中国知网　https://www.cnki.net



(a)电负荷



(b)冷负荷

图6 不同模型在2月测试集上的负荷预测曲线

Fig.6 Load forecasting curves of different models on the February test set

表5 不同预测模型在8月测试集上的预测结果

Table 5 Results of different forecasting models on the August test set

模型	MAE/MW		MAPE/%		RMSE/MW		R2/%	
	电	冷	电	冷	电	冷	电	冷
CNN-LSTM	0.95	2.46	3.90	5.88	1.27	2.91	65.1	73.6
Transformer	0.81	1.25	3.31	2.96	1.09	1.63	74.4	91.7
LSTNet-Skip	0.78	1.24	3.12	2.87	1.11	1.65	73.1	91.5
CNN-BiGRU-Att	0.75	1.32	3.03	3.06	1.07	1.80	75.0	89.8
MMoE	0.80	1.44	3.29	3.38	1.08	1.83	74.5	89.6
CPLE	0.70	1.33	2.87	3.13	0.98	1.68	80.0	91.2
DA-CPLE-TL	0.70	1.04	2.88	2.45	0.91	1.35	81.9	94.3

负荷比电负荷的规律更强，更容易捕捉变化模式，所以在相同信息量补充的情况下，冷负荷提升比电负荷明显。

3.8 消融实验

为验证所提模型每个模块的必要性，逐渐排除组件来观察模型性能是如何下降的。-DA表示所提模型仅去除DA模块，-TL表示所提模型仅去除TL模块，-(DA+TL)表示同时去除DA和TL模块。表6展示了具体实验结果。

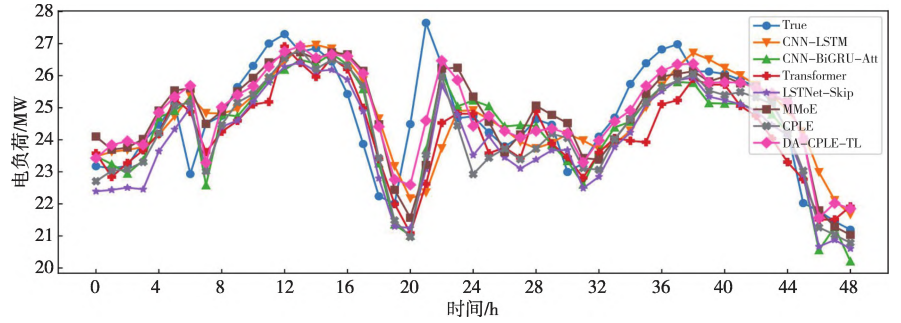
当仅去除TimeVAE生成的人工样本时，相比于所提模型，电负荷的MAE、MAPE、RMSE分别提高了5.57%、7.09%、2.66%，R2降低了0.80%。冷负荷的MAE、MAPE、RMSE分别提高了38.73%、41.02%、28.44%，R2降低了2.82%。在去除人工样本的基础上继续去除源领域知识迁移，相比于所提模型，电负荷的MAE、MAPE、RMSE分别提高了10.03%、12.29%、5.68%，R2降低了2.28%。冷负荷的MAE、MAPE、RMSE分别提高了35.56%、40.15%、28.90%，R2降低了3.13%。上述结果表明，人工样本生成和知识迁移都有助于模型性能的提升，而两者的结合能进一步提升模型的效果。

4 结论

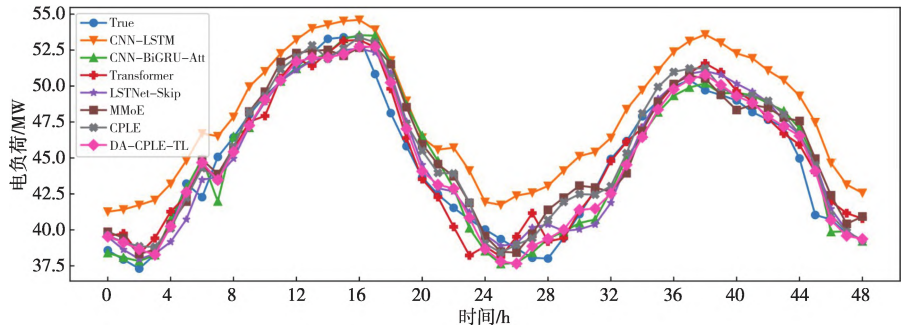
本文提出了一种结合TimeVAE和TL的集成学习方法，以提高小样本数据下短期多能负荷的预测精度。以美国亚利桑那州立大学坦佩校区IES为目标域、其他3个校区IES为源域进行了验证分析。主要结论如下：

1)TimeVAE的DA能够生成人工数据来补偿数据多样性，与TimeGAN相比，MAPE平均降

中国知网 https://www.cnki.net



(a)电负荷



(b)冷负荷

图7　不同模型在8月测试集上的负荷预测曲线

Fig.7　Load forecasting curves of different models on the August test set

表6　基于不同改进模块的预测结果

Table 6　Forecasting results based on different improved modules

类型	MAE/MW		MAPE/%		RMSE/MW		R2/%	
	电	冷	电	冷	电	冷	电	冷
DA-CPLE-TL	0.36	0.28	2.39	2.54	0.56	0.43	87.9	95.7
-DA	0.38	0.39	2.55	3.58	0.58	0.55	87.2	93.0
-TL	0.38	0.32	2.58	2.85	0.56	0.47	87.8	94.8
-(DA+TL)	0.40	0.39	2.68	3.56	0.60	0.55	85.9	92.7

低了16.23%，RMSE平均降低了13.73%。与不增强相比，MAPE平均降低了11.77%，RMSE平均降低了8.42%。

2)TL可以利用来自其他具有丰富数据的相似IES的知识来提高模型预测性能。与不进行迁移相比，MAPE平均降低了13.28%，MAE平均降低了10.91%。

3)DA和TL的集成策略可以进一步提高小样本负荷的预测精度。DA为TL提供了更丰富的训练样本，而TL则为DA后的数据提供了更好的特征提取基础，从而共同提升模型性能。实验结果表明，与其他模型相比，采用TimeVAE数据合成和CPLE迁移参数的模型预测精度最高。与原始预测相比，所提方法的MAPE平均降低了19.79%，RMSE平均降低了12.38%。

参考文献

[1] 雷杨,赵纪峰,丁石川,等.考虑双重不确定性的区域综合能源系统多阶段滚动随机规划[J].电力系统自动化,2023,47(20):53-63.
LEI Yang, ZHAO Jifeng, DING Shichuan, et al. Multi-stage rolling stochastic planning of regional integrated energy system considering dual-uncertainty [J]. Automation of Electric Power Systems, 2023, 47(20): 53-63.

[2] WU J, YAN J Y, JIA H J, et al. Integrated energy systems [J]. Applied Energy, 2016, 167: 155-157.

[3] 王婷,张晶,高冲,等.绿证-碳市场互认抵消下综合能源系统优化调度[J].智慧电力,2025,53(2):104-110.
WANG Ting, ZHANG Jing, GAO Chong, et al. Optimal scheduling of integrated energy system under mutual recognition and offset of green certificate and carbon market [J]. Smart Power, 2025, 53(2): 104-110.

[4] 鲍国栋,宋柯,钱定冬,等.极性反转条件下XLPE空间电荷与电场分布特性研究[J].高压电器,2025,61(8):146-154.
BAO Guodong, SONG Ke, QIAN Dingdong, et al. Study on space charge and electric field distribution characteris-

中国知网　https://www.cnki.net

tics of XLPE under polarity reversal voltage[J].High Voltage Apparatus,2025,61(8):146-154.

[5] 束娜,江山,刘春伶,等.计及灵活性资源多时间尺度协调互济的电-气-热综合能源系统优化调度[J].电力建设,2024,45(12):3-15.
SHU Na, JIANG Shan, LIU Chunling, et al. Optimal scheduling of electricity-gas-heat integrated energy system with flexible resources in multiple time scales[J].Electric Power Construction,2024,45(12):3-15.

[6] 李欣,陈英彰,李涵文,等.考虑碳交易的电-热综合能源系统两阶段鲁棒优化低碳经济调度[J].电力建设,2024,45(6):58-69.
LI Xin, CHEN Yingzhang, LI Hanwen, et al. Two-stage robust optimization of low-carbon economic dispatch for electricity-thermal integrated energy system considering carbon trade [J]. Electric Power Construction, 2024, 45(6):58-69.

[7] 潘廷哲,王宗义,杨晨,等.面向电力需求响应的工业园区综合能源系统优化调控研究[J].电力需求侧管理,2024,26(6):62-67.
PAN Tingzhe, WANG Zongyi, YANG Chen, et al. Research on optimal dispatching of industrial parks integrated energy system for demand-side response [J]. Power Demand Side Management,2024,26(6):62-67.

[8] 朱海南,李丰硕,孙华忠,等.基于改进AlexNet-GRU深度学习网络的配电网短期负荷预测方法[J].电力电容器与无功补偿,2023,44(4):48-54.
ZHU Hainan, LI Fengshuo, SUN Huazhong, et al. Short-term load prediction method of distribution network based on improved AlexNet-GRU deep learning network [J]. Power Capacitor & Reactive Power Compensation,2023,44(4):48-54.

[9] ZHU J,DONG H,LI S,et al.Review of data-driven load forecasting for integrated energy system [J]. Proceedings of the CSEE,2021,41(23):7905-7924.

[10] 欧锋,罗醒华,龙经纬,等.基于图转换和迁移学习的低压配电网户变关系和相位识别方法[J].浙江电力,2024,43(3):95-103.
OU Feng, LUO Xinghua, LONG Jingwei, et al. A household-transformer relationships and phase identification method of low-voltage distribution networks based on graph transformation and transfer learning [J]. Zhejiang Electric Power,2024,43(3):95-103.

[11] YUAN Y, CHEN Z H, WANG Z, et al. Attention mechanism-based transfer learning model for day-ahead energy demand forecasting of shopping mall buildings[J]. Energy,2023,270:126878.

[12] PENG C,TAO Y F,CHEN Z P,et al.Multi-source transfer learning guided ensemble LSTM for building multi-load forecasting [J]. Expert Systems with Applications, 2022,202:117194.

[13] CAI L, GU J, JIN Z J. Two-layer transfer-learning-based architecture for short-term load forecasting [J]. IEEE Transactions on Industrial Informatics,2020,16(3):1722-1732.

[14] XU X Z,MENG Z R.A hybrid transfer learning model for short-term electric load forecasting[J].Electrical Engineering,2020,102(3):1371-1381.

[15] LU Y K, TIAN Z, ZHOU R Y, et al. A general transfer learning-based framework for thermal load prediction in regional energy system[J].Energy,2021,217:119322.

[16] WANG C D, YUAN J J, HUANG K, et al. Research on thermal load prediction of district heating station based on transfer learning[J].Energy,2022,239:122309.

[17] LI C,LI G J,WANG K Y,et al.A multi-energy load forecasting method based on parallel architecture CNN-GRU and transfer learning for data deficient integrated energy systems[J].Energy,2022,259:124967.

[18] WEI N, YIN C, YIN L H, et al.Short-term load forecasting based on WM algorithm and transfer learning model [J].Applied Energy,2024,353:122087.

[19] 韩睿,戴哲仁,蒋鹏,等.基于改进YOLOv8的电力场景通用缺陷检测模型[J].浙江电力,2024,43(4):113-120.
HAN Rui, DAI Zheren, JIANG Peng, et al. A general defect detection model for power scenarios using the improved YOLOv8 [J]. Zhejiang Electric Power, 2024, 43(4):113-120.

[20] SU J N,CHEN F C,QIU Z J,et al.Multi-load short-term prediction of an integrated energy system based on GAN-LSTM [J]. Journal of Physics: Conference Series, 2023, 2564(1):012062.

[21] 曾爽,丁屹峰,李香龙,等.基于条件时序生成对抗网络的楼宇空调负荷场景生成方法[J].电网技术,2022,46(7):2448-2456.
ZENG Shuang, DING Yifeng, LI Xianglong, et al. Scenario generation of air conditioning loads in buildings based on conditional TimeGAN[J].Power System Technology,2022,46(7):2448-2456.

[22] 何宇浩,宋云海,何森,等.面向电力缺陷场景的小样本图像生成方法[J].浙江电力,2024,43(1):126-132.
HE Yuhao, SONG Yunhai, HE Sen, et al. A few-shot image generation method for power defect scenarios[J].Zhejiang Electric Power,2024,43(1):126-132.

[23] 梁俊杰,韦舰晶,蒋正锋.生成对抗网络GAN综述[J].计算机科学与探索,2020,14(1):1-17.
LIANG Junjie, WEI Jianjing, JIANG Zhengfeng. Generative adversarial networks GAN overview [J]. Journal of Frontiers of Computer Science and Technology, 2020, 14

中国知网 https://www.cnki.net

(1):1-17.

[24] LAN J, ZHOU Y Z, GUO Q L, et al. Data augmentation for data-driven methods in power system operation: a novel framework using improved GAN and transfer learning[J]. IEEE Transactions on Power Systems, 2024, 39(5):6399-6411.

[25] LU Y T, WANG G C, HUANG S Q. A short-term load forecasting model based on mixup and transfer learning[J]. Electric Power Systems Research, 2022, 207:107837.

[26] ZHOU D J, MA S X, HAO J R, et al. An electricity load forecasting model for integrated energy system based on BiGAN and transfer learning[J]. Energy Reports, 2020, 6: 3446-3461.

[27] SU J J, YU X J, WANG X R, et al. Enhanced transfer learning with data augmentation[J]. Engineering Applications of Artificial Intelligence, 2024, 129:107602.

[28] LI K J, WEI B R, TANG Q Q, et al. A data-efficient building electricity load forecasting method based on maximum mean discrepancy and improved TrAdaBoost algorithm [J]. Energies, 2022, 15(23):8780.

[29] DESAI A, FREEMAN C, WANG Z H, et al. TimeVAE: a variational auto-encoder for multivariate time series generation [EB/OL]. 2021: 2111.08095. https://arxiv.org/abs/2111.08095v3.

[30] ZHU S X, MA H R, CHEN L J, et al. Short-term load forecasting of an integrated energy system based on STL-CPLE with multitask learning[J]. Protection and Control of Modern Power Systems, 2024, 9(6):71-92.

[31] LIASHCHYNSKYI P, LIASHCHYNSKYI P. Grid search, random search, genetic algorithm: a big comparison for NAS[EB/OL]. 2019: 1912.06059. https://arxiv.org/abs/1912.06059v1.

[32] 李云松，张智晟. 考虑综合需求响应的Trans-GNN综合能源系统多元负荷短期预测[J/OL]. 电工技术学报，2023: 1-11. (2023-12-28). https://kns.cnki.net/KCMS/detail/detail.aspx? filename=DGJS202312260038dbname=CJFD&dbcode=CJFQ.
LI Yunsong, ZHANG Zhisheng. Short-term forecasting of multi-load of Trans-GNN integrated energy system considering comprehensive demand response [J/OL]. China Industrial Economics, 2023: 1-11. (2023-12-28). https://kns.cnki.net/KCMS/detail/detail.aspx? filename=DGJS202312260038dbname=CJFD&dbcode=CJFQ.

[33] 鲁斌，霍泽健，俞敏. 基于LSTNet-Skip的综合能源系统多元负荷超短期预测[J]. 中国电机工程学报，2023，43(6):2273-2283.
LU Bin, HUO Zejian, YU Min. Multi load ultra short-term forecasting of integrated energy system based on LSTNet-skip [J]. Proceedings of the CSEE, 2023, 43(6): 2273-2283.

[34] NIU D X, YU M, SUN L J, et al. Short-term multi-energy load forecasting for integrated energy systems based on CNN-BiGRU optimized by attention mechanism [J]. Applied Energy, 2022, 313:118801.

[35] 吴晨，姚菁，薛贵元，等. 基于MMoE多任务学习和长短时记忆网络的综合能源系统负荷预测[J]. 电力自动化设备，2022，42(7):33-39.
WU Chen, YAO Jing, XUE Guiyuan, et al. Load forecasting of integrated energy system based on MMoE multi-task learning and LSTM [J]. Electric Power Automation Equipment, 2022, 42(7):33-39.

收稿日期：2025-01-14；**修回日期**：2025-03-31

作者简介：

陈　哲(1978)，男，高级工程师，主要从事电网规划设计技术研究与管理工作。

朱苏洵(1999)，女，工学硕士，主要从事电力系统、综合能源系统负荷预测方面的研究工作。(通信作者)

(本文编辑：徐　晗)

中国知网　https://www.cnki.net