文章编号：1007-2322(2026)03-0464-11　　文献标志码：A　　中图分类号：TM73

基于 XGBoost 与多源域迁移学习的贫资料地区负荷预测方法

唐義坤[1]，唐志远[1]，罗同桐[1]，谯傲[2]，刘俊勇[1]

（1. 四川大学 电气工程学院, 四川省 成都市 610065；2. 成都信息工程大学 物流学院, 四川省 成都市 610065）

Load Forecasting in Data-scarce Areas Based on Multi-source Transfer Learning and XGBoost

TANG Yikun[1]，TANG Zhiyuan[1]，LUO Tongtong[1]，QIAO Ao[2]，LIU Junyong[1]

（1. School of Electrical Engineering, Sichuan University, Chengdu 610065, Sichuan Province, China；2. School of Logistics, Chengdu University of Information Technology, Chengdu 610065, Sichuan Province, China）

摘要：准确的负荷预测对保障电力系统安全稳定运行非常关键，贫资料地区由于缺乏相关的有效数据集，难以使用传统的机器学习预测方法。针对小样本条件下的负荷预测问题，提出一种基于极限梯度提升树（extreme gradient boosting，XGBoost）与多源域迁移学习框架。首先，为度量源域与目标域之间的可迁移性，利用 XGBoost 构建域数据的特征–输出映射关系，并引入一种基于夏普利可加性解释（Shapley additive explanations，SHAP）值分布的相似性度量方法，计算域之间特征–输出映射关系的相似性。然后，选择与目标域高度相似的多个源域模型作为迁移模型，并通过最优组合系数将各个源域模型的输出结果集成，以提高整体的迁移效果。最后，使用开源数据对所提出的框架进行性能评估和有效性验证，相比于多层感知机（multi-layer perception，MLP）、支持向量回归（support vector regression，SVR）、长短期记忆网络（long short-term memory network，LSTM）和 XGBoost 方法的直接预测，所提方法能提高至少 10% 的预测精度；相较于基于形态相似性的迁移学习方法，所提方法能提升选择有效源域的准确性。

关键词：负荷预测；迁移学习；极限梯度提升树；可迁移性度量；夏普利可加性解释

Abstract: Accurate electric load forecasting, especially with small sample sets, is a critical topic in the field of power system. In this paper, we propose an attentive multi-source transfer learning framework based on extreme gradient boosting (XGBoost) for load forecasting in data-scarce scenarios. In the proposed framework, a new quantifiable framework is developed by exploiting the feature-output mapping relationship constructed by XGBoost. To effectively assess the transferability across domains, a similarity metric is introduced grounded in SHAP value distribution. Models of multiple sources that exhibit high similarity to the target domain are selected as the transfer models, and attentively integrated using the optimal combining coefficients, aiming to enhance overall transfer performance. Experiments conducted on real-world data sets illustrate that, compared with another popular transfer learning method, the proposed framework not only effectively identifies the potential source tasks that can produce positive transfer, but also achieves improved forecasting accuracy for residential electric load with limited data.

Keywords: load forecasting; transfer learning; extreme gradient boosting (XGBoost); transferability measure; Shapley additive explanations (SHAP)

DOI：10.19725/j.cnki.1007-2322.2024.0038

0　引言

准确的电力负荷预测是新型电力系统的重要保障，对电力系统的规划、运行、控制与调度具有关键作用[1-3]。现有的负荷预测方法大多基于充足的数据资料，然而，许多地区由于数据缺乏，难以应用现有的预测方法。在这些贫资料地区，准确的负荷预测对于电力调度和整体负荷的准确掌握至关重要，具有极高的实用价值。因此，本文聚焦于贫资料地区的负荷预测问题。

基金项目：四川省科技计划项目 (2023YFSY0033)。
Project Supported by Sichuan Science and Technology Program of Sichuan Province (2023YFSY0033).

中国知网　https://www.cnki.net

电力负荷预测方法大致可以分为两类：一类为基于数理统计的传统负荷预测方法，如多元线性回归[4]和自回归移动平均[5]；另一类为人工智能方法，如人工神经网络[6]、支持向量回归（support vector regression，SVR）[7]、长短期记忆网络（long short-term memory network，LSTM）[8]和门控递归单元[9]。人工智能算法以其强大的数据挖掘能力和较高的预测精度，成为近年来负荷预测方法的主流。然而，基于人工智能算法的预测模型必须依靠充足的有效数据进行训练。

在很多贫资料地区，由于数据缺乏、数据收集困难或数据无法访问，很难获得足够多有效的数据，导致构建的人工智能模型出现过拟合现象，对数据中的噪声和细节过于敏感，预测精度下降。例如，一个新建的住宅区，其历史数据很少，直接训练出的人工智能模型很难做出准确预测。针对小样本条件下的负荷预测，使用迁移学习技术[10-11]已成为解决该问题的有效方法之一。迁移学习的主要思想是在与目标域具有相通公有知识的源域中进行学习，将学习到的公有知识迁移至目标领域中来辅助目标任务的训练。近年来，已有许多迁移学习方法被应用于贫资料地区的负荷预测[12-16]。文献 [12] 构建了一个基于两层迁移学习的短期负荷预测方法，将附近区域的负荷数据作为源域，提取源域中的知识，应用于目标模型。文献 [13] 构建了基于图神经网络的迁移学习框架，有效提高了新建小区的负荷预测精度。文献 [14] 为非侵入式负荷预测设计了两种迁移学习方案：设备迁移学习和跨域迁移学习。以上方法都是直接选择与目标域具有相似地理环境或气象条件的领域作为源域，并没有充分分析源域与目标域之间的可迁移性，这样极有可能产生负迁移[17]，即从源域中学习到知识，对目标域产生坏的效果。作为迁移学习的核心，可迁移性度量是避免负迁移现象的重要前提[18]。因此，在进行迁移学习时，有必要设计一种数学度量方法来量化域之间的可转移性，以确定能产生正向迁移的有效源域。

在现有可迁移性度量方法中，相似性是一个重要参考指标。目标域和源域越相似，两者含有的公有知识就越多，产生的迁移效果就越好。文献 [16] 使用余弦系数来筛选与目标城市负荷曲线相似的源域城市。类似地，文献 [19] 使用了 4 个度量方法：欧几里得距离、余弦系数、曼哈顿距离和动态时间弯曲距离，来测量源域和目标域之间的相似性。文献 [20] 以消费模式相似性为指标，选择与目标房屋消费模式相似的房屋作为源域。文献 [21] 提出了一种基于最长公共子序列算法的相似数据匹配方法，识别并过滤出与目标任务相关的相似数据切片。上述所有可转移性度量的方法都实现了正向迁移，但以上方法都只关注数据曲线的形态相似性，没能深度挖掘两个不同域之间特征–输出映射关系的相关性，导致漏选了一些有效源域。正如本文算例所示，在某些情况下，即使两种负荷模式的形态不同，从特征–输出映射关系的角度来看，它们也可能具有很强的相关性，对目标任务的学习也能产生积极影响。此外，几乎上述所有工作都没有考虑多源域知识迁移问题。事实上，与目标域相关的有效源域往往有很多个，它们之间所含有的可转移知识可能是互补或交叉的。因此，如果能将来自多个有效源域的可迁移知识整合利用，便能进一步提升目标任务的学习效果。

为解决上述可迁移性度量和多源域知识迁移问题，本文提出基于极限梯度提升树（extreme gradient boosting，XGBoost）[22]与多源域迁移学习的贫资料地区负荷预测框架。该框架从领域的特征–输出映射关系相似度出发，设计一种基于夏普利可加性解释（Shapley additive explanations，SHAP）[23]值分布的可转移性量化数学方法，旨在为目标域筛选出有效源域。此外，为了充分利用来自各个有效源域的可转移知识，该框架通过给各个源模型分配最优组合系数，来集成各个源域的结果，从而实现更好的迁移学习效果。

1　基于 XGBoost 与多源域迁移学习的负荷预测框架

本文提出的基于 XGBoost 与多源域迁移学习的负荷预测框架如图 1 所示。整体可分为两个阶段：有效源域选择阶段和多源域模型集成阶段。

在有效源域选择阶段，构建一个量化可迁移性的度量方法。首先，利用 XGBoost 构建目标域和源域的特征–输出映射关系。然后，设计一种基于 SHAP 值分布的方法，来量化目标模型和每个源模型之间的特征–输出映射关系的相似性。选择与目标域映射关系高度相似的源模型作为迁

中国知网　https://www.cnki.net

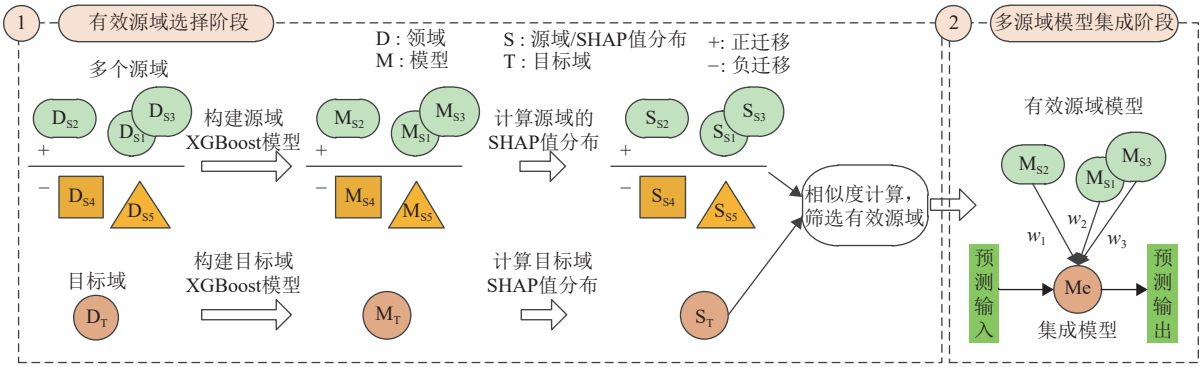


图 1 基于 XGBoost 与多源域迁移学习的负荷预测框架

Fig. 1 Load forecasting framework based on XGBoost and multi-source transfer learning

移学习的有效模型。在多源域模型集成阶段，提出了一种多源集成算法，该算法通过给各个有效源域模型分配最佳的组合系数，以构建针对目标任务的更高性能的集成模型。

2 基于特征–输出映射关系的有效源域选择

迁移学习成功的前提是判断目标域和源域的可迁移性，即要选择出对目标任务有正向作用的有效源域。现有基于形态相似性的可迁移性度量方法只关注数据分布的差异，导致遗漏掉一些有效源域。鉴于此问题，为了更有效地识别有效源域，本文提出一种基于特征–输出映射关系相似度的可迁移性度量方法。

2.1 基于 XGBoost 的特征–输出映射关系构建

基于人工智能方法的模型，由于其强大的数据挖掘能力，可以构建数据集中内含的特征–输出映射关系。然而，由于目标数据稀缺，直接基于有限的目标数据构建的人工智能模型可能会出现过拟合现象，导致构建出不准确的映射关系。XGBoost 通过将正则化项合并到目标函数中，可以有效避免过拟合现象。

XGBoost 由多个弱回归树相加组成，所有树为 CART 回归树模型。XGBoost 算法通过不断迭代，生成一棵新树拟合前一棵树的残差，随着迭代次数的增多，精度不断提高。假设 $D=\{(x_i,y_i):i=1,\cdots,n,x_i\in\mathbf{R}^m,y_i\in\mathbf{R}\}$ 为用于负荷预测的数据集，则用 XGBoost 模型输出的第 i 个样本的预测值 $\hat{y}_i$ 可表示为

$$\hat{y}_i=\sum_{m=1}^{M}f_m(x_i) \tag{1}$$

式中：$f_m(x_i)$ 为第 m 棵弱回归树对第 i 个样本的输出；$\hat{y}_i$ 为所有 M 棵树输出之和。所有树由目标函数 L 确定，目标函数 L 由损失函数 $l(y_i,\hat{y}_i)$ 和正则化项 $\Omega(f_m)$ 相加。损失函数 L 是目标值 y_i 与预测值 $\hat{y}_i$ 的误差，正则化项则可以降低模型的复杂度。目标函数 L 和正则化项 $\Omega(f_m)$ 的表达式为

$$L=\sum_{i=1}^{n}l(y_i,\hat{y}_i)+\sum_{m=1}^{M}\Omega(f_m) \tag{2}$$

$$\Omega(f_m)=\gamma T+\frac{1}{2}\lambda\|w\|^2 \tag{3}$$

式中：T 表示叶子节点的个数；w 表示分配给叶子节点的分数；γ 和 λ 为超参数，用于调整正则项的惩罚力度。

在计算完第 m 棵树得到的分数之后，目标函数可以表示为

$$L^m=\sum_{i=1}^{n}l\left[y_i,\hat{y}_i^{m-1}+f_m(x_i)\right]+\Omega(f_m) \tag{4}$$

使用二阶泰勒展开对式 (4) 进行化简，并设 $g_i=\partial l\left(y_i,\hat{y}_i^{m-1}\right)/\partial\hat{y}_i^{m-1}$，$h_i=\partial^2 l\left(y_i,\hat{y}_i^{m-1}\right)/\partial\hat{y}_i^{2(m-1)}$，则目标函数可以改写为

$$L^m=\sum_{i=1}^{n}\left[g_i f_m(x_i)+\frac{1}{2}h_i f_m(x_i)^2\right]+\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T}(w_j^m)^2 \tag{5}$$

式中 j 表示第 j 片叶子。令 $G_j=\sum_{i\in I_j}g_i$，$H_j=\sum_{i\in I_j}h_i$，其中 $I_j=\{i|q(x_i=j)\}$ 表示叶子节点 j 的实例集，则式 (5) 可以化简为

$$L^m=\sum_{j=1}^{T}\left[G_j w_j+\frac{1}{2}\left(H_j+\lambda\right)(w_j^m)^2\right]+\gamma T \tag{6}$$

中国知网 https://www.cnki.net

可以看出，目标函数是关于 w 的二次方程，求得最优w^m和目标函数值L^m为

$$w_j^m = -\frac{G_j}{H_j+\lambda} \tag{7}$$

$$L^m = -\frac{1}{2}\sum_{j=1}^{T}\frac{G_j^2}{H_j+\lambda}+\gamma T \tag{8}$$

训练过程中，应用贪心算法对子树进行划分，并枚举可行的分割点，模型不断计算节点损失以选择增益损失最大的叶子节点。增益 G 的计算公式为

$$G = \frac{1}{2}\left[\frac{(G_L)^2}{H_L+\lambda}+\frac{(G_R)^2}{H_R+\lambda}-\frac{(G)^2}{H+\lambda}\right]-\gamma \tag{9}$$

式中：$G_L=\sum_{i\in I_L} g_i$；$G_R=\sum_{i\in I_R} g_i$；$G=\sum_{i\in I} g_i$；$H_L=\sum_{i\in I_L} h_i$；$H_R=\sum_{i\in I_R} h_i$；$H=\sum_{i\in I} h_i$；I_L、I_R 分别表示分裂后的左节点和右节点。

2.2　基于 SHAP 值分布相似度的可迁移性度量

包含 XGBoost 在内的人工智能算法构建的模型通常被称为“黑盒子”，因为模型内部的特征–输出映射关系是未知的。SHAP 方法能够量化出每个特征对输出的影响，成为揭示人工智能模型中特征–输出映射关系的一个很好的方法。模型的 SHAP 值分布成为模型特征–输出关系的一个具象体现，这也成为评估域之间可迁移性的一个关键切口，如果两个域模型的 SHAP 值分布是相似的，那么可以认为这两个模型的映射关系是相似的，从而域之间的知识迁移能够带来正向效果。鉴于此，本文提出基于 SHAP 值分布相似度的可迁移性度量方法。

SHAP 值起源于合作博弈论，是一种基于贡献的利润分配方法。它可以通过计算每个样本中每个特征的边际贡献，来为模型提供全局解释和局部解释。如果集合 I 的任何子集 B 具有合作收益函数 v，则 SHAP 值可以定义为

$$\varphi_i(v)=\sum_{B\subset I}\frac{(|B|-1)!(e-|B|)!}{e!}[v(B)-v(B-\{i\})] \tag{10}$$

式中：$\varphi_i(v)$为第 i 个参与者的分配收益；e 为集合 I 的元素数量；$|B|$为子集 B 的元素数量。具体到负荷预测中，SHAP 值为基于预测贡献各个样本中每个特征所分配到的数值。以第 i 个预测样本为例，预测值和 SHAP 值的关系服从

$$y_i = y_{\text{base}}+f(x_{i1})+f(x_{i2})+\ldots.+f(x_{ik}) \tag{11}$$

式中：y_{base} 是基线模型，为所有预测值的平均值；$f(x_{ik})$ 为第 i 个样本中第 k 个元素的 SHAP 值，表征该特征对最终预测值 y_i 的贡献。

SHAP 值量化了人工智能模型中特征对输出的影响，如果一个特征在两个模型中具有相同的 SHAP 值，则表明该特征在两种模型中起到的作用是相同的。因此，如果两个模型的 SHAP 值分布高度相似，意味着这两个领域的特征对预测的贡献是相似的，这两个领域大部分知识是相通公有的。在这种情况下，进行迁移学习会对目标任务产生积极影响。为了准确评估两个模型 SHAP 值分布的相似度，引入最大均方差（maximum mean discrepancy，MMD）[24] 来量化相似度。MMD 可以用于计算两个数据集（即两个向量）的分布距离。令数据集$\boldsymbol{S}_i^{\text{tag}}$和$\boldsymbol{S}_i^{\text{src}}$分别是第 i 个特征的目标域模型的 SHAP 值集和源域模型的 SHAP 值集，那么这个两个数据集的 MMD 可以通过式 (12) 计算得出。

$$V_i = MMD(\boldsymbol{S}_i^{\text{tag}},\boldsymbol{S}_i^{\text{src}}) = \Big[\frac{1}{n^2}\sum_{d=1}^{n}\sum_{d'=1}^{n}k(s_{i,d}^{\text{tag}},s_{i,d'}^{\text{tag}})-\frac{2}{nm}\sum_{d=1}^{n}\sum_{j=1}^{m}k(s_{i,d}^{\text{tag}},s_{i,j}^{\text{src}})+\frac{1}{m^2}\sum_{j=1}^{m}\sum_{j'=1}^{m}k(s_{i,j}^{\text{src}},s_{i,j'}^{\text{src}})\Big]^{\frac{1}{2}} \tag{12}$$

式中：V_i 为 MMD 值；n、m 分别为目标域模型和源域模型的训练样本数；$k(\cdot)$ 为核函数，如式（13）所示。

$$k(x,x') = \mathrm{e}^{-\frac{\|x-x'\|^2}{2\delta^2}} \tag{13}$$

由式（12）和（13）可以得出，V_i 越小，两个数据集的分布越相似。当 V_i=0 时，两个数据集分布相同。

人工智能模型的 SHAP 值分布是二维矩阵，其中矩阵的每一行表示模型中一个特征 SHAP 值集。为了量化目标模型和源模型之间特征–输出映射关系的相似性，必须考虑所有特征 SHAP 值集的 MMD。于是，定义两个模型 SHAP 值分布的相似度（similarity of SHAP value distribution，SSVD）为所有特征 SHAP 值集的 MMD 加权和，如式 (14)、(15) 所示。

$$SSVD=\sum_{i=1}^{K}c_iV_i \tag{14}$$

中国知网　https://www.cnki.net

$$c_i = \frac{\sum_{d=1}^{n} \left| s_{i,d}^{\text{tag}} \right|}{\sum_{i=1}^{K} \sum_{d=1}^{n} \left| s_{i,d}^{\text{tag}} \right|} \tag{15}$$

式中：K 表示特征的数量；c_i 表示第 i 个特征的权重，c_i 值等于第 i 个特征在所有样本的 SHAP 值绝对值之和与所有特征的 SHAP 值绝对值总和之比。SHAP 值越大的特征，其权重越高，对 SSVD 的影响也越大，从而有助于更准确地评估映射关系的相似性。与 MMD 类似，SSVD 值越小，表明两个模型之间的映射关系越相似。

2.3 有效源域模型的选择

基于 2.2 节提出的可迁移性度量方法，提出有效源域的筛选方法，流程如图 2 所示。首先，分别使用目标域样本和多组源域样本训练一个目标 XGBoost 模型和多个源域 XGBoost 模型，确保所有模型的特征空间相同。其次，采用 SHAP 值方法来揭示每个 XGBoost 模型的特征–输出映射关系。然后，计算出每个源域模型与目标模型的 SSVD，SSVD 值较小的源域模型被选择为可迁移模型，即有效源域模型。由于这些模型表现出与目标模型高度相似的映射关系，因此利用它们进行知识迁移，可以有效降低负迁移的风险。

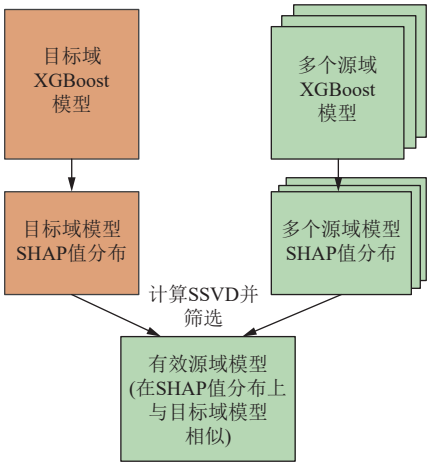


图 2 有效源域选择方法流程

Fig. 2 Flowchart of the effective source domain selection method

3 多源域迁移学习集成框架

在很多情况下，来自多个源域与目标域的知识并不完全相同，而是各有差异。若能有效整合这些多样化的知识，迁移学习的效果将得到进一步提升。为此，本文提出了一个多源域迁移学习集成框架，如图 3 所示。该集成框架的主要思想是给源域模型分配最优权重 w，使得加权相加后的最终结果更加逼近真实值。令 N 个有效源域模型产生的基于目标域训练集的预测为 $y_{\text{tr},1}, y_{\text{tr},2}, \cdots, y_{\text{tr},N}$，则权重 w 可以通过求解以下优化问题来获得，其中优化问题的目标函数是最小化平均绝对误差。

$$\hat{\omega} = \arg\left(\min_{\omega} \sum_{q=1}^{Q} \frac{1}{Q} \left| y_{\text{real}}^{q} - y_{\text{tr}}^{q} \right| \right) \tag{16}$$

$$\text{s.t. } y_{\text{tr}}^{q} = \sum_{n=1}^{N} \omega_n y_{\text{tr},n}^{q} + b \tag{17}$$

式中：y_{real}^{q} 表示目标域中第 q 个训练样本的真实值；$y_{\text{tr},n}^{q}$ 表示第 n 个源域模型对第 q 个训练样本给出的输出；b 表示偏差；Q 表示训练样本的数量。

获得 w 值之后，最终的模型输出为

$$y_{\text{final}} = \sum_{n=1}^{N} \hat{\omega}_n y_{\text{te},n} + b \tag{18}$$

式中 $y_{\text{te},n}$ 为第 n 个源域模型在目标域测试集上的输出。

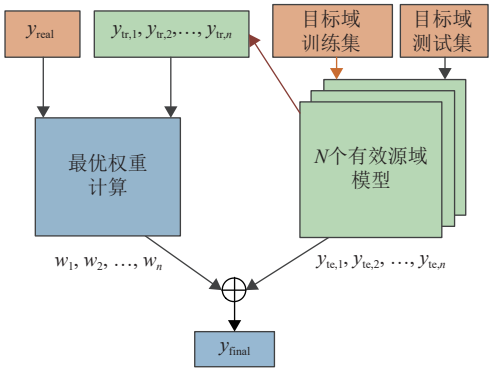


图 3 多源域迁移学习集成框架

Fig. 3 Ensemble framework of multi-source transfer learning

4 算例分析

本文选取来自 OpenEI[25] 的开源数据来验证所提出迁移学习框架的有效性。数据集包含来自美国各个州的 936 户家庭用电数据，每户家庭用电数据时间长度为 1 年，时间分辨率为 1 h，总计 8760 个数据。

中国知网 https://www.cnki.net

4.1　算例设置

随机选取 6 户家庭用电数据作为源域，4 户家庭用电数据作为目标域，以上 10 户家庭分别来自美国不同的州。为了方便起见，上述源域和目标域分别表示为 SRC 1—SRC 6 和 TAG 1—TAG 4。每个源域数据由一年中前 330 天的历史负荷数据组成，即从 1 月 1 日到 11 月 26 日的历史负荷数据（7920 个数据点），并按时间顺序划分为训练集和验证集，比例为 0.7∶0.3。每个目标域数据包含由 11 月 27 日开始之后的 30 天的负荷数据（720 个数据点），也按照时间顺序划分为训练集和测试集，比例为 0.33∶0.67。目标域的训练集数据点只有 240 个，数量足够少。图 4 给出所有目标域的负荷曲线。可以观察到 TAG 1 和 TAG 2 的负荷曲线表现出高度的规律性和相似性。相反，TAG 3 和 TAG 4 的负荷曲线表现出显著的波动性和较大的差异。

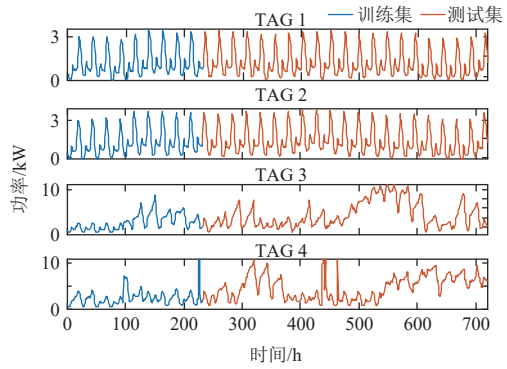


图 4　目标域负荷曲线

Fig. 4　Load data in target domains

在建立源域和目标域所需的特征输出映射关系时，选择小时、星期和过去的 24h 负荷值作为特征空间 X，并选择下一小时的负载值 P_t 作为输出(下标 t 表示时刻)。特征空间 X_t 的索引如表 1 所示。为了确保特征之间的一致性和可比性，所有特征均使用以下方程进行归一化。

$$\hat{x}_i^t = \frac{x_i^t - x_{i,\min}}{x_{i,\max} - x_{i,\min}} \tag{19}$$

式中：x_i^t表示在 t 时刻第 i 个特征的数值；$x_{i,\max}$、$x_{i,\min}$分别表示第 i 个特征的最大值和最小值；$\hat{x}_i^t$ 为 x_i^t归一化后的数值。对于小时数，使用以 0.041 递增的数字表示。对于星期，使用一个布尔变量表示，0 表示工作日，1 表示周末。例如，1:00、24:00、星期一和星期日分别用 0.041、0.984、0 和 1 表示。

表 1　特征空间 X

Table 1　Feature space X

特征序号	特征
特征0	小时
特征1	星期
特征2~特征25	$P_{t\text{-}1}$~ $P_{t\text{-}24}$

所有模型都在配备 Intel i7 CPU 和 8 GB 内存的笔记本电脑上用 Python 进行训练及预测。预测结果使用平均绝对百分误差（mean absolute percentage error，MAPE）、均方根误差（root mean squared error，RMSE）和 R-Squared（R^2）进行评估，计算公式为

$$\mathrm{MAPE} = \frac{1}{Q}\sum_{i=1}^{Q}\frac{|y_i - Y_i|}{Y_i} \times 100\% \tag{20}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{Q}\sum_{i=1}^{Q}(y_i - Y_i)^2} \tag{21}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{Q}(y_i - Y_i)^2}{\sum_{i=1}^{Q}(Y_i - \bar{Y})^2} \tag{22}$$

式中：y_i 为第 i 个预测值；Y_i 为第 i 个真实值；$\bar{Y}$ 为所有真实值的平均值；Q 为预测数目。

4.2　基模型的预测结果

为了验证迁移学习是否取得正向效果，在进行迁移学习之前，仅使用目标域的训练集训练一些常用的人工智能模型进行预测，这些模型被记为基模型。选择多层感知机（multi-layer perceptron，MLP)、SVR、LSTM 和 XGBoost 作为基模型分别进行预测。各个基模型的设置如表 2 所示。

表 3 给出所有基模型的预测结果。可见，由于 TAG 3 和 TAG 4 负荷模式的波动性较大，TAG 3 和 TAG 4 的预测精度在所有模型中的预测精度都比 TAG 1 和 TAG 2 差很多。在所有目标域中，XGBoost 在 MAPE 上均优于其他基模型。按平均数计算，XGBoost 在 4 个目标域中分别比 MLP、SVR 和 LSTM 提升了 17.9%、47.7% 和 20.52% 的 MAPE 预测精度。在 RMSE 和 R^2 指标上，XGBoost 模型在 TAG 3 和 TAG 4 表现上并非表现最优，但也与最优值十分接近。这与 RMSE 和

中国知网　https://www.cnki.net

表 2 基模型的设置
Table 2 Baseline model setting

基模型	基模型设置
MLP	4层神经网络结构（26，32，32，1），激活函数：sigmoid，学习率α=0.05，优化器为Adam，训练次数为200
SVR	gamma=auto，核函数为RBF，惩罚系数C=1.0
LSTM	1层隐藏层，隐藏神经单元数目为50，学习率α=0.01，优化器为Adam，损失函数为MAE，batch size=20，drop-out rate=0.2，epoch=100
XGBoost	booster为‘gbtree’，α=0.05，树的最大深度为5，树的数目为100，gamma=0.005

表 3 基模型的 MAPE 和 RMSE 指标
Table 3 MAPE and RMSE of baselines

目标域	指标	MLP	SVR	LSTM	XGBoost
TAG 1	MAPE/%	6.37	9.69	7.82	**5.35**
	RMSE	0.1215	0.1741	0.1432	**0.1058**
	R^2	0.968	0.934	0.955	**0.975**
TAG 2	MAPE/%	5.27	8.88	6.89	**4.15**
	RMSE	0.1228	0.1791	0.1551	**0.1187**
	R^2	0.968	0.93	0.949	**0.970**
TAG 3	MAPE/%	22.89	32.8	18.93	**17.43**
	RMSE	1.4104	1.7712	**1.2126**	1.3042
	R^2	0.744	0.597	**0.811**	0.781
TAG 4	MAPE/%	20.17	33.44	18.61	**18.09**
	RMSE	1.3610	2.2712	**1.2634**	1.5830
	R^2	0.713	0.201	**0.753**	0.612

注：对最佳性能的数字进行了加黑。

R^2 并没有像 MAPE 一样对误差进行归一化处理有关，在等幅度误差的情况下，数值较大处的误差比数值较小处的误差引起的 RMSE 和 R^2 指标的变化更为显著。综合以上 3 个指标可知，在样本集很小时，XGBoost 的性能比其他基模型更加优越，适合用于目标域的建模。此外，表 4 展示了每个模型进行一次预测所需要的平均预测时间，可以看出，XGBoost 的预测时间在现实操作中是完全可以接受的。

4.3 基于所提迁移学习框架的预测结果

为了选出与目标域相关的有效源域，分别使用目标域和源域的训练集训练，得到各自的 XGBoost 模型，并计算每个源域 XGBoost 模型和目标域 XGBoost 模型的 SSVD，计算结果如表 5 所示。可以观察到，TAG 1-TAG 2 与 SRC 1-SRC 3 之间的 SSVD 相较于其与 SRC 4-SRC 6 之间的 SSVD 明显较低，而 TAG 3-TAG 4 与 SRC 4-SRC 6 之间的 SSVD 相较于其与 SRC 1-SRC 3 之间的 SSVD 明显较低。这表明 TAG 1-TAG 2 的 SHAP 值分布与 SRC 1-SRC 3 的更为相似，与 SRC 4-SRC 6 的有较大不同。类似地，TAG 3-TAG 4 的 SHAP 值分布与 SRC 4-SRC 6 的更为相似，与 SRC 1-SRC 3 则有显著区别。为了更直观地观察，图 5 显示了 TAG 3、SRC 1 和 SRC 4 领域模型的 SHAP 值分布。从图 5 可以看出，TAG 3 的 SHAP 值分布与 SRC 1 的 SHAP 值分布明显相似，与 SRC 4 的 SHAP 分布存在较大差异。通过横向比较前两个模型每个特征的 SHAP 值，可以看出首要特征 2 以及次要特征 25 的 SHAP 值较为一致，这两个特征在两个模型中对输出的影响是大致相同的，可见 TAG 3 模型和 SRC 1 模型的映射关系有很大程度是相似的。这验证了本文所提的 SSVD 指标在验证模型 SHAP 值分布相似性上的准确性。

表 4 基模型的平均预测时间
Table 4 Average forecasting time of base models

基模型	平均预测时间/ms
MLP	1.1
SVR	0.011
LSTM	0.9
XGBoost	0.012

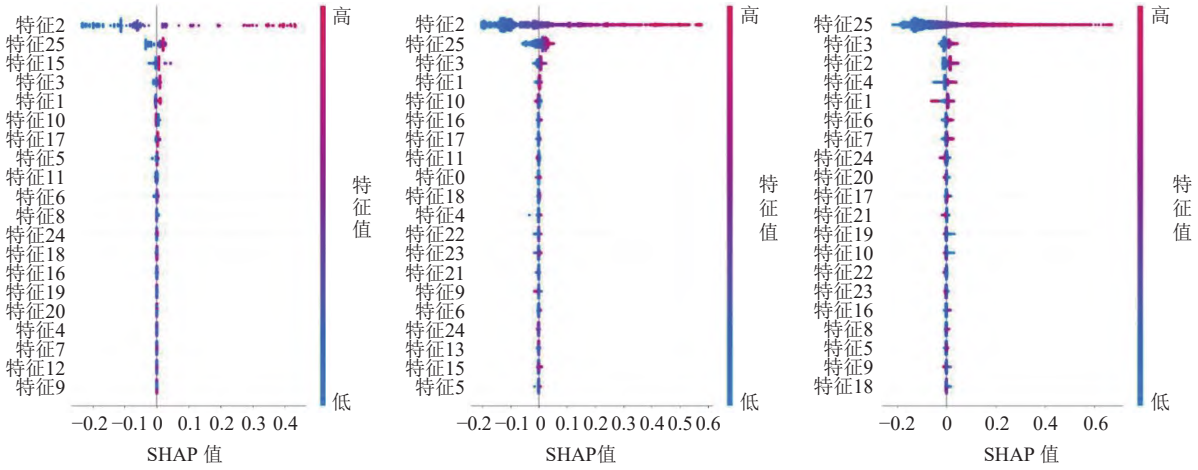
表 5 每个源域模型与每个目标域模型的 SSVD
Table 5 SSVD between each source model and each target model

模型	XGB_{TAG1}	XGB_{TAG2}	XGB_{TAG3}	XGB_{TAG4}
XGB_{SRC1}	0.1046	0.0927	0.1696	0.1812
XGB_{SRC2}	0.1059	0.0971	0.1663	0.1673
XGB_{SRC3}	0.1156	0.1054	0.162	0.1646
XGB_{SRC4}	0.2406	0.2504	0.0547	0.1092
XGB_{SRC5}	0.2474	0.2564	0.0801	0.0763
XGB_{SRC6}	0.2247	0.2307	0.0957	0.0856

注：“XGB”是XBGoost的缩写。

为进一步验证所提可迁移性度量方法的有效性，将所有源域模型都迁移至目标域进行预测，在目标域测试集的预测结果如表 6 所示。在表 6 中，$XGBoost_{base}$ 是只由目标域训练的 XGBoost 基模型。从表 6 可以得出，与 $XGBoost_{base}$的预测结果相比，$XGBoost_{SRC1}$ 至 $XGBoost_{SRC3}$ 能够提高 TAG 1 和 TAG 2 的预测精度，降低 TAG 3 和 TAG 4

中国知网 https://www.cnki.net



(a) TAG 3模型的SHAP值分布　(b) SRC 1模型的SHAP值分布　(c) SRC 4模型的SHAP值分布

图 5　TAG 3、SRC1 和 SRC4 模型的 SHAP 值分布

Fig. 5　SHAP value distribution of TAG 3, SRC1 and SRC 4 models

表 6　迁移模型预测结果的 MAPE 和 RMSE

Table 6　MAPE and RMSE of transfer-learning models' forecasting results

模型	MAPE/%				RMSE				R^2			
	TAG 1	TAG 2	TAG 3	TAG 4	TAG 1	TAG 2	TAG 3	TAG 4	TAG 1	TAG 2	TAG 3	TAG 4
$XGBoost_{base}$	5.35	4.15	17.43	18.09	0.1058	0.1187	1.3042	1.5830	0.97	0.970	0.781	0.612
$XGBoost_{SRC1}$	4.61	4.08	32.54	34.94	0.0975	0.0970	1.7062	2.1183	0.979	0.980	0.626	0.305
$XGBoost_{SRC2}$	4.00	**3.60**	32.54	35.60	0.0866	**0.0843**	1.7324	2.1327	0.984	**0.985**	0.614	0.296
$XGBoost_{SRC3}$	4.44	3.78	31.49	34.80	0.0943	0.0877	1.6930	2.1190	0.981	0.984	0.632	0.305
$XGBoost_{SRC4}$	7.32	6.47	13.66	13.16	0.1952	0.1965	**0.6622**	0.9931	0.916	0.918	**0.944**	0.847
$XGBoost_{SRC5}$	6.86	6.59	16.61	16.02	0.1876	0.1903	0.8368	1.1581	0.923	0.923	0.910	0.792
$XGBoost_{SRC6}$	7.90	7.45	15.92	14.89	0.2332	0.2332	0.8055	1.1723	0.881	0.884	0.917	0.787
本文迁移学习预测方法	**3.89**	3.73	**13.66**	**12.89**	**0.0831**	0.0860	0.6891	**0.9853**	**0.985**	0.984	0.939	**0.850**

的预测精度。反之，$XGBoost_{SRC4}$ 至 $XGBoost_{SRC6}$ 能够提高 TAG 3 和 TAG 4 的预测精度，降低 TAG 1 和 TAG 2 的预测精度。可以看出，TAG 3 和 TAG 4 的预测精度提升不及 TAG 1 和 TAG 2 明显，这是因为 TAG 3 和 TAG 4 的训练负荷曲线与测试负荷曲线之间存在较大差异。尽管如此，本文提出的源域选择方法仍分别帮助 TAG 3 和 TAG 4 提升了至少 4.7% 和 11.4% 的 MAPE 预测精度。

结合表 5 的 SSVD 数据和表 6 的迁移模型预测结果，可以得到，与目标域模型有着相似 SHAP 值分布的源域模型能够带来正向迁移，反之会带来负迁移。因此，本文提出的基于 SSVD 的可迁移性度量方法可以成为迁移学习中筛选有效源域的有效工具。值得注意的是，如图 4 所示，TAG 3 和 TAG 4 的训练集负荷曲线非常不同，如果使用文献 [16] 中提出的方法（即基于形态相似性的源域选择方法），将导致不同的源域的选择。然而，采用基于 SSVD 的可迁移性度量方法，确定了 TAG 3 和 TAG 4 有着相同的有效源域，并都产生了积极的迁移效果。该案例表明，基于 SSVD 的可迁移性度量方法可以通过关注特征–输出映射关系的相似性，来克服基于形态相似性源域选择方法的局限性。

从表 6 还可以得出，在 TAG 1—TAG 4 中，本文提出的多源迁移学习集成模型相较基模型分别提升了 27%、10%、21%、28% 的 MAPE 预测精度，预测效果提升显著。综合 MAPE、RMSE 和 R^2 三个指标来看，本文提出的多源迁移学习集成模型的表现，始终优于或接近于其他迁移学习模型的最佳性能。这得益于该框架能够为有效源模型分配最优权重，从而充分利用所有有效源

中国知网　https://www.cnki.net

域的可转移知识。

此外，通过测试，每进行一步预测时，多源域迁移学习集成模型的时间消耗约为 0.05 ms。计算时间远小于 1 s，也是符合现实操作要求的。

4.4 对比分析

为进一步显示本文提出的可量化迁移性度量方法的优越性，选用文献 [16] 提出的源域选择的方法作为参照方法进行对比分析。文献 [16] 采用余弦系数用于量化目标序列和源序列之间的相关性。余弦系数 M 可计算为

$$M = \frac{\langle l^i, l^j \rangle}{\|l^i\|_2 \|l^j\|_2} \tag{23}$$

式中 l 为负荷序列。

按照文献 [16] 的方法，分别从 SRC 1 到 SRC 6 中提取与 TAG 1 到 TAG 4 相似的负荷序列，训练用于迁移学习的参照 XGBoost模型。形态相似性系数的阈值被设置为 0.97。表 7给出预测结果以及每个参照模型和每个目标域模型之间的 SSVD。与表 6 中 $\text{XGBoost}_{\text{base}}$ 的性能相比，参照模型能够提高 TAG 1 和 TAG 2 的预测精度。然而，该方法却不能成功应用在 TAG 3 和 TAG 4 上，因为在所有源域中都不能提取出与 TAG 3 和 TAG 4 域形态相似的序列，即使 SRC 3 至 SRC 6 可以向 TAG 3 和 TAG 4 的带来正向转移。原因在于，负荷序列的形态无法表征人工智能模型的内部映射关系，仅依靠形态相似可能导致次优的源域选择，阻碍迁移学习的性能。相反，SHAP 值分布揭示了数据整体的映射关系，从而能够更好地识别有效源域。分析表 7 中的 SSVD，在 4.3 节中获得的相似 SHAP 值分布可以导致正向转移的说法仍然成立。然而，当 SSVD 为较大数值时，仍可能发生正转移。例如，来自 SRC 5 的参照模型与 TAG 1 和 TAG 2 的基模型的 SSVD 大于 0.15，但仍给 TAG 1 和 TAG 2 带来了正向迁移的效果。因此，本文提出的基于 SSVD 的可迁移性度量方法可以认为是选择有效源域的一个充分条件，与其他源域选择方法（如基于形态相似性的方法）互相补充，提升选择有效源域的准确性。

4.5 不同训练集大小下的预测精度

为验证本文提出迁移学习框架的有效性，改变 TAG 1 训练样本量，再次进行迁移学习模型和基模型的预测，训练样本量依次设置为 60、120、240、360 和 480。图 6 显示了预测的 MAPE 结果。可以得出，随着训练样本量的增大，基模型的预测精度逐渐提升，这是由于模型能够从更多目标数据中学习到更多知识，有利于提高目标任务的学习效果。同时，相较于其他基模型，XGBoost 基模型表现出较高的预测精度，这是因为 XGBoost 模型在小样本情况下，可以有效规避掉过拟合现象。对比分析基模型和迁移学习模型，在不同的目标域训练样本数量下，本文所提迁移学习框架的预测精度表现稳定且始终优于基模型，尤其是当训练样本量较小时，优越性体现得更加明显。这表明，训练样本集越小，越有必要进行迁移学习。

表 7 参照模型的 MAPE 和 SSVD

Table 7 MAPE and SSVD of benchmarks

域	TAG 1		TAG 2		TAG 3	TAG 4
	MAPE/%	SSVD	MAPE/%	SSVD		
SRC 1	3.90	0.0553	4.33	0.0622	—	—
SRC 2	4.19	0.1153	4.06	0.1173	—	—
SRC 3	4.34	0.1139	3.65	0.1173	—	—
SRC 4	3.80	0.1374	2.90	0.142	—	—
SRC 5	3.15	0.1505	3.63	0.1585	—	—
SRC 6	3.46	0.0597	4.15	0.0833	—	—

注：‘—’表示没有从源域中找到与目标域负荷序列形态相似的序列

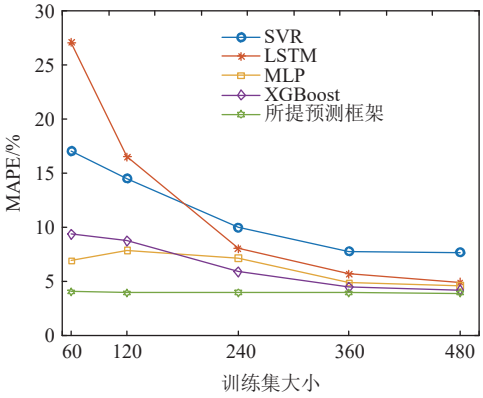


图 6 不同训练集大小下的预测精度

Fig. 6 Forecasting precision across varying training set sizes

5 结论

本文针对贫资料地区的短期电力负荷预测，提出一种基于 XGBoost 和多源域迁移学习的负荷预测框架。在开源数据上对所提框架进行了有效性验证，通过算例分析得到的主要结论如下：

1）本文所提框架通过源域筛选和多源模型迁移的方法，有效解决了贫资料地区数据量过少

中国知网 https://www.cnki.net

的问题，相较于 MLP、SVR、 LSTM 和 XGBoost 方法的直接预测，所提方法能提高贫资料地区至少 10% 的预测精度。

2）在迁移学习前，本文构建一种基于 SHAP 值分布相似性的源域选择度量指标，筛选能产生正迁移的有效源域，与基于形态相似度的源域选择方法相比，能从模型的特征–输出角度分析域之间的相似性，提升选择有效源域的准确性。

3）存在多个源域与目标域有公有知识，本文设计了一种集成算法，能将多个源域的知识进行最优组合。

参考文献

[1] 孔祥玉, 马玉莹, 艾芊, 等. 新型电力系统多元用户的用电特征建模与用电负荷预测综述 [J]. 电力系统自动化, 2023, 47(13): 2−17.
KONG Xiangyu, MA Yuying, AI Qian, *et al*. Review on electricity consumption characteristic modeling and load forecasting for diverse users in new power system[J]. Automation of Electric Power Systems, 2023, 47(13): 2−17(in Chinese).

[2] 方娜, 李俊晓, 陈浩, 等. 基于变分模态分解的卷积神经网络-双向门控循环单元-多元线性回归多频组合短期电力负荷预测 [J]. 现代电力, 2022, 39(04): 441−448.
FANG Na, LI Junxiao, CHEN Hao, *et al*. Multi-frequency combination short-term power load forecasting with convolutional neural networks - bidirectional gated recurrent unit-multiple linear regression based on variational mode decomposition[J]. Modern Electric Power, 2022, 39(04): 441−448(in Chinese).

[3] HAN F , PU T , LI M, *et al*. Short-term forecasting of individual residential load based on deep learning and k-means clustering[J]. CSEE Journal of Power and Energy Systems, 2021, 7(2): 261-269.

[4] 方磊, 楚成博, 何映虹, 等. 基于自适应辛几何模态分解-多元线性回归-卷积长短时记忆的台区电力负荷预测 [J]. 现代电力, 2025, 42(04): 840−846.
FANG Lei, CHU Chengbo, HE Yinghong, *et al*. Power load forecasting in station areas based on asgmd -mlr-clstm[J]. Modern Electric Power, 2025, 42(04): 840−846(in Chinese).

[5] 甘中学, 喻想想, 许裕栗, 等. 基于周期性 ARMA-SVR 模型的空调冷热负荷预测 [J]. 控制工程, 2020, 27(2): 380−385.
GAN Zhongxue, YU Xiangxiang, XU Yuli, *et al*. Air-conditioning cooling and heating load prediction based on periodic arma-svr model[J]. Control Engineering of China, 2020, 27(2): 380−385(in Chinese).

[6] 范士雄, 刘幸蔚, 於益军, 等. 基于多源数据和模型融合的超短期母线负荷预测方法 [J]. 电网技术, 2021, 45(1): 243-250.
FAN Shixiong, LIU Xingwei, YU Yijun, *et al*. Multi-source data and hybrid neural network based ultra-short-term bus load forecasting[J]. Power System Technology, 2021, 45(1): 243− 250(in Chinese).

[7] 李明节, 梁志峰, 许涛, 等. 基于敏感气温空间分布的度夏度冬日最大负荷预测与应用研究 [J]. 电网技术, 2023, 47(03): 1088−1098.
LI Mingjie, LIANG Zhifeng, XU Tao, *et al*. Prediction and application of maximum daily load in summer and winter based on spatial distribution of sensitive temperatures[J]. Power System Technology, 2023, 47(03): 1088−1098(in Chinese).

[8] 胡威, 张新燕, 李振恩, 等. 基于优化的 VMD-mRMR-LSTM 模型的短期负荷预测 [J]. 电力系统保护与控制, 2022, 50(01): 88−97.
HU Wei, ZHANG Xinyan, LI Zhenen, *et al*. Short-term load forecasting based on an optimized VMD-mRMR-LSTM model[J]. Power System Protection and Control, 2022, 50(01): 88−97(in Chinese).

[9] SAJJAD M , KHAN Z , ULLAHET A , *et al*. A novel cnn-gru-based hybrid approach for short-term residential load forecasting[J]. IEEE Access, 2020, 8: 143759-143768.

[10] ZHUANG F, QI Z, DUAN K, *et al*. A comprehensive survey on transfer learning[J]. Proceedings of the IEEE, 2021, 109(1): 43-76.

[11] 欧阳福莲, 王俊, 周杭霞. 基于改进迁移学习和多尺度 CNN-BiLSTM-Attention 的短期电力负荷预测方法 [J]. 电力系统保护与控制, 2023, 51(2): 132−140.
OUYANG Fulian, WANG Jun, ZHOU Hangxia. Short-term power load forecasting method based on improved hierarchical transfer learning and multi-scale CNN-BiLSTM-Attention[J]. Power System Protection and Control, 2023, 51(2): 132−140(in Chinese).

[12] CAI L, GU J , JIN Z. Two-layer transfer-learning-based architecture for short-term load forecasting[J]. IEEE Transactions on Industrial Informatics, 2020, 16(3): 1722-1732.

[13] WU D, LIN W. Efficient residential electric load forecasting via transfer learning and graph neural networks[J]. IEEE Transactions on Smart Grid, 2023, 14(3): 2423−2431.

[14] D'INCECCO M, SQUARTINI S, ZHONG M. Transfer

中国知网　https://www.cnki.net

learning for non-intrusive load monitoring[J]. IEEE Transactions on Smart Grid, 2020, 11(2): 1419−1429.

[15] ZHOU Z, XU Y, REN C. A transfer learning method for forecasting masked-load with behind-the-meter distributed energy resources[J]. IEEE Transactions on Smart Grid, 2022, 13(6): 4961−4964.

[16] ZENG P, WU D, JIN M. Compress-filtering and transfer-expanding of data set for short-term load forecasting[C]// 2017 International Joint Conference on Neural Networks, Anchorage(IJCNN). AK, USA: IEEE, 2017: 1095-1101.

[17] WANG Z, DAI Z, POCZOS B, *et al*. Characterizing and avoiding negative transfer[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA: IEEE, 2019: 11285-11294.

[18] 魏泽涛, 刘友波, 沈晓东, 等. 基于样本数据迁移学习的贫资料地区小水电超短期出力建模及发电预测 [J]. 中国电机工程学报, 2023, 43(07): 2652−2666.
WEI Zetao, LIU Youbo, SHEN Xiaodong, *et al*. Ultra-short term power generation modeling and prediction for small hydropower in data-scarce areas based on sample data transfer learning[J]. Proceedings of the CSEE, 2023, 43(07): 2652−2666(in Chinese).

[19] TIAN Y, SEHOVAC L, GROLINGER K. Similarity-based chained transfer learning for energy forecasting with big data[J]. IEEE Access, 2019, 7: 139895−139908.

[20] WU D, WANG B, PRECUP D, *et al*. Multiple kernel learning-based transfer regression for electric load forecasting[J]. IEEE Transactions on Smart Grid, 2020, 11(2): 1183−1192.

[21] WEI Z, SHEN X, QIN G, LIN Y, LIU J. An integrated transfer learning method for power generation prediction of run-off small hydropower in data-scarce areas[J]. IEEE Transactions on Smart Grid, 2024, 15(1): 1030−1041.

[22] 朱江行, 邹晓松, 熊炜, 等. 基于 Prophet 与 XGBoost 混合模型的短期负荷预测 [J]. 现代电力, 2021, 38(03): 325−331.
ZHU Jiangxing, ZOU Xiaosong, XIONG Wei, *et al*. Short-term power load forecasting based on prophet and xgboost mixed model[J]. Modern Electric Power, 2021, 38(03): 325−331(in Chinese).

[23] WANG M, ZHENG K, YANG Y, *et al*. An explainable machine learning framework for intrusion detection systems[J]. IEEE Access, 2020, 8: 73127−73141.

[24] 王毅星. 基于深度学习和迁移学习的电力数据挖掘技术研究 [D]. 杭州: 浙江大学, 2019.
WANG Yixing. Power data mining technology based on deep learning and transfer learning[D]. Hangzhou: Zhejiang University, 2019(in Chinese).

[25] OpenEI. Open energy information database[DB/OL]. [2023-12-31]. https://data.openei.org/.

收稿日期：2024−03−05

作者简介：

唐義坤 (1997)，男，硕士研究生，研究方向为机器学习和负荷预测，E-mail：tangyikun@stu.scu.edu.cn；

唐志远 (1992)，男，博士，副研究员，通信作者，研究方向为电力系统控制及规划运行、分布式控制及优化，E-mail：tangzhiyuan@scu.edu.cn；

罗同桐 (2000)，女，硕士研究生，研究方向为机器学习在电力系统中的应用，E-mail：905951698@qq.com；

谯傲 (1992)，女，博士，讲师，研究方向为绿色供应链，E-mail：qiaoao@cuit.edu.cn；

刘俊勇 (1963)，男，博士，教授，研究方向为电力市场、智能配电网、电力系统大数据技术，E-mail：liujy@scu.edu.cn。

中国知网 https://www.cnki.net