文章编号：1000-3673（2025）09-3745-11　　中图分类号：TM 715　　文献标志码：A　　学科代码：470·40

基于域对抗迁移网络的短期电力负荷预测方法

缪希仁[1]，刘煜寒[1]，王铭海[2]，江灏[1]，陈静[1]，林蔚青[1]，陈熙[1]
（1．福州大学电气工程与自动化学院，福建省 福州市 350108；
2．国网福建省电力有限公司长乐区供电公司，福建省 福州市 350200）

Short-term Power Load Forecasting Method Based on Domain Adversarial Transfer Network

MIAO Xiren[1], LIU Yuhan[1], WANG Minghai[2], JIANG Hao[1], CHEN Jing[1], LIN Weiqing[1], CHEN Xi[1]
(1. College of Electrical Engineering and Automation, Fuzhou University, Fuzhou 350108, Fujian Province, China;
2. Changle District Electric Power Supply Branch of State Grid Fujian Electric Power Co., Ltd., Fuzhou 350200, Fujian Province, China)

ABSTRACT: Data-driven methods have been widely used in electricity load forecasting to improve forecasting accuracy. However, when the electricity-selling company accesses new customers, the applicability of conventional data-driven methods is somewhat limited due to the lack of customers' historical electricity consumption data. To solve this problem, the paper proposes a short-term power load forecasting method based on Domain adversarial Transfer Network (DATN). The model utilizes the Transformer model as a feature extractor to capture dynamic features and time dependencies in the load data. Subsequently, the load forecaster accurately predicts the future load profile based on these features. Adversarial learning through the domain discriminator and feature extractor ensures that the model learns deep domain invariant features while combining Multi-Kernel Maximum Mean Discrepancy (MK-MMD) and Correlation Alignment (CORAL) to reduce further the distribution difference between source and target domain data. The model is validated on the electricity consumption data of industrial users in a southern province, and the experimental results show that the method has good prediction accuracy and adaptability in small sample scenarios.

KEY WORDS: short term load forecasting; transfer learning; Transformer; domain adaptation

摘要：基于数据驱动的方法已广泛应用于电力负荷预测领域，以提升预测精度。然而，当售电公司接入新用户时，由于缺乏用户历史用电数据，常规数据驱动方法的适用性会受到一定限制。为解决这一问题，文章提出了一种基于域对抗迁移网络(domain adversarial transfer network，DATN)的短期电力负荷预测方法。该模型利用 Transformer 模型作为特征提取器，以捕捉负荷数据中的动态特征和时间依赖性。随后，负荷预测器基于这些特征精准预测未来的负荷情况。通过域判别器与特征提取器的对抗学习，确保模型能够学习到深层域不变特征，同时结合多核最大均值差异(multi-kernel maximum mean discrepancy，MK-MMD)和相关性对齐(correlation alignment，CORAL)进一步减小源域与目标域数据的分布差异。所提模型在南方某省工业用户的用电数据上进行了验证，实验结果表明，在小样本场景下，该方法具备较好的预测精度和场景适应性。

关键词：短期负荷预测；迁移学习；Transformer 模型；领域自适应

DOI：10.13335/j.1000-3673.pst.2024.1798

0　引言

随着“双碳”目标的提出和电力体制改革的深入，电力市场的多元化加剧，需求响应、共享经济、负荷聚合商和虚拟电厂等新技术和角色不断被引入，使得电力负荷呈现出更复杂、多变的新特性[1]。在此背景下，如何掌握用户用电规律并精准预测用户负荷，成为售电公司获得核心竞争力的关键挑战。

目前，用于短期电力负荷预测的方法可分为传统预测方法和机器学习方法两类[2]。传统预测方法如多元线性回归法[3]、卡尔曼滤波法[4]、自回归积分滑动平均法[5]等，这些方法结构简单且预测速度快，能够根据历史负荷序列预测未来负荷变化趋势。然而，它们在处理复杂非线性特征时能力有限，且高度依赖于历史负荷数据，难以应对负荷特性中的复杂波动[6]。因此，相关学者引入了机器学习方法，以增强负荷预测模型对非线性时序数据的处理能力。支持向量机(support vector machines，SVM)[7]、随机森林(random forest regression，RF)[8]以及极限梯度提升(extreme gradient boosting，XGBoost)[9]等模型在负荷预测中表现出色，能够更好地应对非线

基金项目：福建省自然科学基金项目(2022J01566)。
Project Supported by Natural Science Foundation of Fujian Province (2022J01566).

中国知网　https://www.cnki.net

性和多维数据。然而，这些方法对异常值敏感，面对数据突变或不规则行为时容易导致模型性能下降[10]。

近年来，随着深度学习的发展，各种深度学习方法被运用到负荷预测领域中。与传统方法和机器学习方法相比，深度学习方法能够从大量复杂数据中自动提取高层次特征，尤其在处理复杂非线性问题时表现优异。常见的深度学习模型如卷积神经网络(convolutional neural networks，CNN)[11]、长短期记忆网络(long short-term memory，LSTM)[12]、门控循环单元网络(gated recurrent unit，GRU)[13]等，在负荷预测任务中取得了显著成果。文献[14]中，CNN通过结合多尺度空间注意力模块，提取时空特征及多分量间的耦合关系，进而有效学习用户级负荷预测中的多分量特征，提升预测精度。文献[15]中，LSTM集成了特征和时间依赖的注意力机制，通过自适应选择相关特征并捕捉时间依赖性，用于实现短期区域负荷的概率预测。文献[16]中，GRU通过门控机制从经过二维卷积神经网络处理后的多变量信息中进一步提取时间依赖性，减少模型的预测误差。虽然深度学习在负荷预测任务中取得了较好的效果，但通常依赖于大量的历史数据来训练，以提取复杂的负荷特征并捕捉潜在的用电模式。然而，在实际应用中，售电公司往往面临着数据不足的问题，新接入用户的历史用电数据较为有限，这导致深度学习模型无法充分学习用户负荷数据中蕴含的用电行为规律，最终影响模型的泛化能力和预测精度。

为了应对上述挑战，迁移学习(transfer learning，TL)被引入负荷预测领域[17]。迁移学习旨在通过将已学到的知识和经验从一个任务或领域应用到另一个任务或领域中，来提升学习性能[18]。近年来，深度迁移学习方法被逐渐应用于负荷预测领域。文献[19]提出一种改进的分层级迁移学习策略结合多尺度CNN-BiLSTM (bidirectional long short-term memory)-Attention模型，用于解决目标域负荷数据不足的问题，通过逐层迁移学习与微调提高预测精度。文献[20]提出了一种迁移学习引导的变源域LSTM建筑负荷预测方法，通过实时调整源域建筑及其能耗数据，确保源域与目标域在最新窗口保持较高相似度，从而提高负荷预测的精度。文献[21]提出了一种跨建筑能耗预测的迁移学习方法，结合季节和趋势调整，通过合并不同分布的相似建筑数据，在数据不足的新建筑中有效提升能耗预测精度。文献[22]提出基于迁移学习的建筑能耗预测方法，通过在不同的学习场景下多次实验来验证迁移学习的潜力。

尽管上述研究在一定程度解决了数据稀缺性问题，但在实际应用中，电力负荷波动频繁且复杂，受电价政策、天气变化和经济活动等外部因素的影响，数据分布会出现差异。领域自适应(domain adaptation，DA)作为迁移学习的一个子集，它特别关注于在相同任务的场景中处理源域任务和目标域任务之间的领域差异[23]。相比于传统迁移学习方法，领域自适应能够更有效地缩小不同领域数据的分布差异。基于此，本文设计了一个用于小样本场景下的负荷预测任务的域对抗迁移网络(domain adversarial transfer network，DATN)，该网络框架由5个部分构成：特征提取器、负荷预测器、域判别器、多核最大均值差异(multi-kernel maximum mean discrepancy，MK-MMD)以及相关性对齐(Correlation Alignment，CORAL)。本文通过实验分析验证了所提方法的有效性，主要创新点如下：

1）针对新接用户由于历史负荷数据匮乏而难以建立精确的短期负荷预测模型的问题，本文构建了一种基于域对抗迁移网络(DATN)的负荷预测模型，适用于小样本场景下的短期负荷预测任务。通过将含有大量历史样本的源域知识迁移至目标域中，提升了仅有少量历史样本的目标域的负荷预测精度。

2）通过将Transformer网络作为DATN框架的特征提取器，利用其全局依赖和局部特征提取能力，有效捕捉电力负荷随时间变化的动态特征和时间依赖性。此外，通过特征提取器与域判别器构成的对抗学习机制，模型能学习到源域和目标域之间相对稳定且一致的域不变特征，提高模型在跨域情况下特征提取的通用性和稳定性。

3）为了有效减小源域与目标域负荷数据的分布差异，DATN框架在对抗学习的基础上，结合多核最大均值差异(MK-MMD)和相关性对齐(CORAL)，分别从特征分布的均值差异和协方差差异两个尺度进行特征对齐，从而增强了模型在跨域负荷预测中的迁移效果和鲁棒性。

1 基于域对抗迁移网络的短期电力负荷预测方法

本文针对新接用户缺少历史负荷数据导致预测精度不高的问题，考虑到迁移学习中源域和目标域数据分布不一致的情况，提出一种域对抗迁移网络来提高负荷预测精度，网络框架见图1。

中国知网 https://www.cnki.net

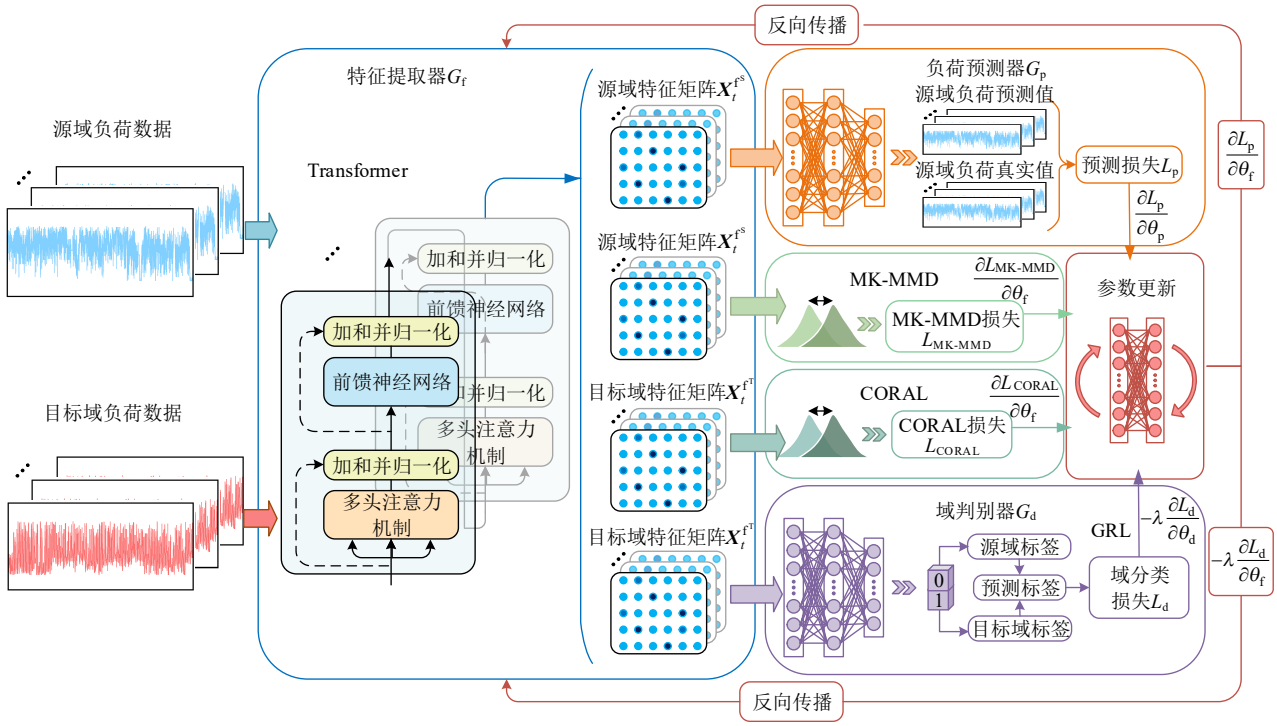


图 1　基于 DATN 的负荷预测模型

Fig. 1　Load forecasting model using DATN

整体上，DATN 网络包含 5 个部分：特征提取器(G_f)、负荷预测器(G_p)、域判别器(G_d)、多核最大均值差异(MK-MMD)和相关性对齐(CORAL)。特征提取器由 Transformer 构成，作为影响预测效果的主干网络，用于提取源域和目标域电力负荷数据随时间变化的动态特征和时间依赖性。负荷预测器由三层全连接层构成，用于生成未来负荷值。域判别器同样由三层全连接层构成，用于判别特征提取器输出的特征是来自源域数据还是目标域数据，并通过与特征提取器的对抗学习，使模型学习到源域和目标域之间一致的领域不变特征。MK-MMD 和 CORAL 模块用于计算经过特征提取器处理后的源域和目标域数据特征之间的多核最大均值差异损失和相关性对齐损失，从多角度评估源域和目标域特征之间的分布差异。

1.1　模型训练阶段

在训练阶段，将来自源域 D^S 和目标域 D^T 的负荷样本 $\boldsymbol{X}_t$ 分别输入到特征提取器 G_f 中提取时序特征。接着，将提取到的时序特征 $\boldsymbol{X}_t^f$ 分别输入到预测器 G_p 和域判别器 G_d 中，分别生成预测值 $\tilde{\boldsymbol{Y}}_t$ 和域标签 $\tilde{\boldsymbol{d}}_t$。这个过程可以表示为

$$\begin{cases} \boldsymbol{X}_t^f = G_f(\boldsymbol{X}_t;\boldsymbol{\theta}_f) \\ \tilde{\boldsymbol{Y}}_t = G_p(\boldsymbol{X}_t^f;\boldsymbol{\theta}_p) \\ \tilde{\boldsymbol{d}}_t = G_d(\boldsymbol{X}_t^f;\boldsymbol{\theta}_d) \end{cases} \tag{1}$$

式中：$\boldsymbol{\theta}_f$、$\boldsymbol{\theta}_p$ 和 $\boldsymbol{\theta}_d$ 为 G_f、G_p 和 G_d 中的权重矩阵。

经由负荷预测器得到的预测损失为 L_p，经由域判别器得到的域分类损失为 L_d，则 L_p、L_d 的定义如下：

$$L_p = \frac{1}{n^S}\sum_{t=1}^{n^S} F_p(\tilde{\boldsymbol{Y}}_t, \boldsymbol{Y}_t) \tag{2}$$

$$L_d = \frac{\lambda}{n^S + n^T}\sum_{t=1}^{n^S+n^T} F_d(\tilde{\boldsymbol{d}}_t, \boldsymbol{d}_t) \tag{3}$$

式中：n^S 和 n^T 为 D^S 和 D^T 的训练样本数；$F_p(\cdot)$ 和 $F_d(\cdot)$ 为 G_p 和 G_d 的损失函数；λ 表示动态权重系数，用于平衡损失；$\boldsymbol{Y}_t$ 为负荷真实值；$\boldsymbol{d}_t$ 为样本标签。

DATN 模型的特征提取器和域判别器通过借鉴生成对抗网络(generative adversarial network，GAN)的原理，进行对抗训练。其中，特征提取器就相当于 GAN 的生成器，而域判别器就相当于 GAN 的鉴别器。域判别器的任务就是负责鉴别特征提取器输出的特征是来自源域数据还是目标域数据，而特征提取器要尽量减小源域数据和目标域数据输出特征的差异，以骗过域判别器，使其无法正确的鉴别[24]。具体来说，DATN 模型训练主要有两个目标：一方面，训练预测器的目标是要使其尽量正确预测出负荷值，即最小化预测损失 L_p；另一方面，训练域判别器的目标就是要使其区分特征是来自源域还是目标域，即最大化域分类损失 L_d，也就是最小化 $-L_d$。为了进行对抗训练，DATN 模型通过梯度反转层(gradient reversal layer，GRL)将特征提

中国知网　https://www.cnki.net

取器与域判别器进行连接。GRL 在前向传播过程中执行恒等变换，不影响数据流的正常传递，而在反向传播过程中会自动反转梯度的方向，从而使得特征提取器和域判别器能够进行联合训练。该框架的总损失函数 L_{TOTAL} 构建如下：

$$L_{\mathrm{TOTAL}}=L_{\mathrm{p}}-L_{\mathrm{d}}+L_{\mathrm{MK\text{-}MMD}}+L_{\mathrm{CORAL}}=\frac{1}{n^{\mathrm{S}}}\sum_{t=1}^{n^{\mathrm{S}}}F_{\mathrm{p}}(\tilde{\boldsymbol{Y}}_t,\boldsymbol{Y}_t)-\frac{\lambda}{n^{\mathrm{S}}+n^{\mathrm{T}}}\sum_{t=1}^{n^{\mathrm{S}}+n^{\mathrm{T}}}F_{\mathrm{d}}(\tilde{\boldsymbol{d}}_t,\boldsymbol{d}_t)+L_{\mathrm{MK\text{-}MMD}}+L_{\mathrm{CORAL}} \tag{4}$$

式中：$L_{\mathrm{MK\text{-}MMD}}$ 和 L_{CORAL} 为多核最大均值差异损失和相关性对齐损失。

因为 L_{p}、L_{d}、$L_{\mathrm{MK\text{-}MMD}}$ 和 L_{CORAL} 具有不同的尺度，因此，使用一种用于联合训练的动态学习策略，其中权重 λ 是动态调整的，并在训练期间从初始的小权重逐渐上升。动态权重 λ 定义如下：

$$p_i=\frac{i}{E} \tag{5}$$

$$\lambda_i=\frac{2}{1+\exp(-10p_i)}-1 \tag{6}$$

式中：p_i 代表学习进度，从 0 到 1 线性上升；i 和 E 分别代表第 i 次迭代数和总迭代数。该策略确保在训练的初始阶段，模型更关注学习源域上的特征，随着训练的进行，模型逐渐加强对抗学习，促进源域和目标域特征的对齐。

1.2 模型预测阶段

在预测阶段，经过训练的 DATN 模型利用特征提取器从目标域数据中提取时间特征，并将这些特征输入负荷预测器以预测未来的负荷值。需要强调的是，域判别器、MK-MMD 和 CORAL 仅在训练阶段用于帮助特征提取器学习域不变特征，因此在预测阶段不再参与。

DATN 模型训练与预测的总体流程如图 2 所示。

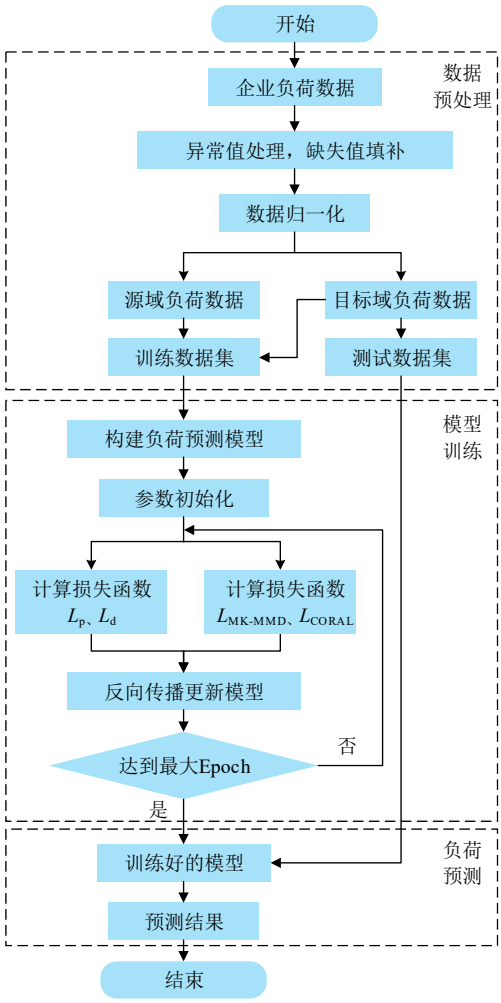


图 2 DATN 模型训练与预测流程

Fig. 2 DATN model training and forecasting process

2 域对抗迁移网络模型及算法原理

2.1 基于 Transformer 的域特征提取

由于 Transformer[25-26]在时间序列处理方面表现出色，本文将其作为 DATN 框架中的特征提取器，用于提取源域和目标域数据中的时序特征。标准的 Transformer 模型是一个序列到序列的结构，由编码器和解码器两部分组成。为了更好地捕捉源域和目标域数据中的动态特性与时间依赖性，本文仅采用编码模块，将输入映射到高维的域不变特征矩阵中。

编码模块由多个结构相同的编码器堆叠组成，如图 3 所示。每个编码器包含两个子层：多头自注

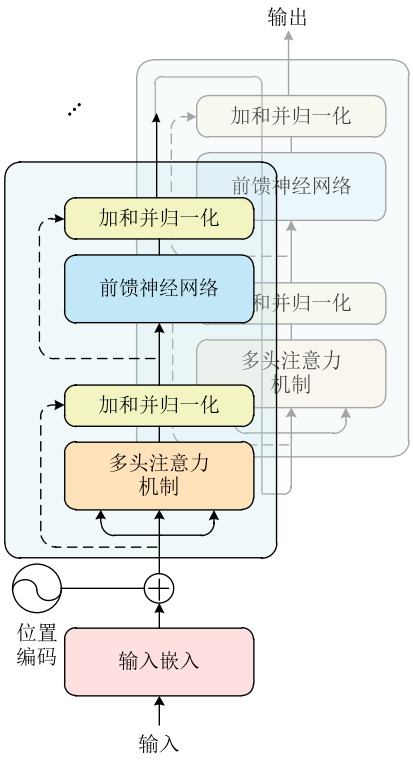


图 3 Transformer 结构

Fig. 3 Structure of Transformer

中国知网 https://www.cnki.net

意力机制和全连接前馈神经网络。每个子层周围通过残差连接，并在加和后进行归一化处理，从而增强模型的稳定性和表达能力。

在输入到多头注意力机制之前，首先需要对输入数据 $\boldsymbol{X}_t$ 进行位置编码。位置编码通过正弦和余弦函数计算，其公式如下：

$$F_{\mathrm{PE}}(F_{\mathrm{pos}},2j)=\sin(F_{\mathrm{pos}}/10000^{\frac{2j}{d_{\mathrm{model}}}}) \tag{7}$$

$$F_{\mathrm{PE}}(F_{\mathrm{pos}},2j+1)=\cos(F_{\mathrm{pos}}/10000^{\frac{2j}{d_{\mathrm{model}}}}) \tag{8}$$

$$\boldsymbol{X}_i=\mathrm{Embedding}(\boldsymbol{X}_t)+F_{PE}(\boldsymbol{X}_t) \tag{9}$$

式中：F_{pos} 表示负荷序列中每个负荷值的位置；j 为位置编码的维度；d_{model} 为模型维度，$d_{\mathrm{model}}=256$；$\boldsymbol{X}_i$ 为编码后的向量。

完成位置编码后，经过位置编码的输入数据 $\boldsymbol{X}_i$ 会被传入多头注意力机制，该机制通过为输入数据中的重要信息分配较高权重、次要信息分配较低权重，从而实现对负荷数据非线性特征的深层提取。如图 4 所示，多头注意力机制由自注意力层、拼接层和线性变换层组成，其中自注意力层包含点积模块和 softmax 函数模块。在多头注意力机制中，经过位置编码的负荷序列将被输入到多个并行的自注意力网络中，以计算每个网络的注意力值矩阵。

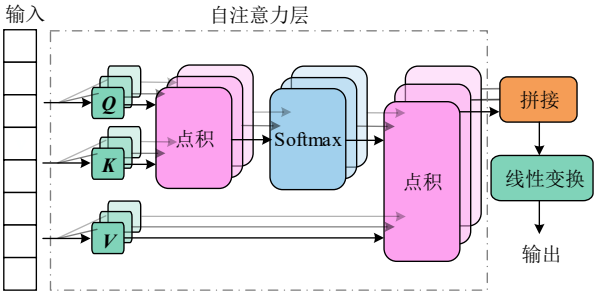


图 4　多头注意力机制结构

Fig. 4　Structure of multi-head attention mechanisms

对第 i 个自注意力网络，初始化 3 个不同的线性投影矩阵 $\boldsymbol{W}_i^{\mathrm{Q}}$、$\boldsymbol{W}_i^{\mathrm{K}}$、$\boldsymbol{W}_i^{\mathrm{V}}$，并将输入负荷样本 $\boldsymbol{X}_i$ 映射到查询 $\boldsymbol{Q}_i$，键 $\boldsymbol{K}_i$ 与值 $\boldsymbol{V}_i$ 矩阵，然后计算每一层的结果[27]。计算公式如下：

$$\begin{cases}\boldsymbol{Q}_i=\boldsymbol{X}_i\boldsymbol{W}_i^{\mathrm{Q}}\\ \boldsymbol{K}_i=\boldsymbol{X}_i\boldsymbol{W}_i^{\mathrm{K}}\\ \boldsymbol{V}_i=\boldsymbol{X}_i\boldsymbol{W}_i^{\mathrm{V}}\\ \boldsymbol{H}_i=\mathrm{softmax}(\dfrac{\boldsymbol{Q}_i\boldsymbol{K}_i^{\mathrm{T}}}{\sqrt{d}})\boldsymbol{V}_i\end{cases} \tag{10}$$

式中：$\boldsymbol{H}_i$ 为第 i 个自注意力网络的输出结果；d 为 3 个线性投影矩阵的维数；softmax 函数用于限制矩阵的数值范围。

随后，将多个自注意力网络的输出结果进行拼接，并通过线性变换处理拼接后的结果，最终输出注意力值矩阵 $\boldsymbol{H}$，公式如下：

$$\boldsymbol{H}=\mathrm{Concat}(\boldsymbol{H}_1,\boldsymbol{H}_2,...,\boldsymbol{H}_i)\boldsymbol{W}^{\mathrm{o}} \tag{11}$$

式中：Concat 为拼接函数；$\boldsymbol{W}^{\mathrm{o}}$ 为权重矩阵。

前馈神经网络在 Transformer 模型中通过对每个位置的上下文向量进行非线性变换，增强模型的表达能力。它与多头注意力机制结合使用，确保模型不仅能够捕捉序列中元素之间的线性关系，还能提取更复杂的非线性特征，从而更好地理解输入负荷序列中的深层次信息。

2.2　MK-MMD 和 CORAL 模块

在源域和目标域的知识迁移过程中，单独使用域对抗策略可能无法取得理想的负荷预测效果。为了进一步缩小不同域之间的分布差异，本文将域对抗策略与多核最大均值差异(MK-MMD)和相关性对齐(CORAL)相结合，以提高迁移学习的效果。

多核最大均值差异(MK-MMD)是最大均值差异(MMD)的多核变体。MMD 通过核函数以内积形式将源域和目标域特征非线性映射到再生核希尔伯特空间(reproducing kernel Hilbert space，RKHS)[28]，并通过计算 RKHS 中的均值差异来量化两者的分布差异，其计算公式如下：

$$D_{\mathrm{MMD}}=\mathrm{MMD}(\boldsymbol{X}^{\mathrm{S}},\boldsymbol{X}^{\mathrm{T}})=\left\|\frac{1}{n^{\mathrm{S}}}\sum_{i=1}^{n^{\mathrm{S}}}\Phi(x_i^{\mathrm{S}})-\frac{1}{n^{\mathrm{T}}}\sum_{j=1}^{n^{\mathrm{T}}}\Phi(x_j^{\mathrm{T}})\right\|_{\mathcal{H}}^2 \tag{12}$$

式中：$\boldsymbol{X}^{\mathrm{S}}=\{x_i^{\mathrm{S}}\}_{i=1,...,n^{\mathrm{S}}}$ 和 $\boldsymbol{X}^{\mathrm{T}}=\{x_j^{\mathrm{T}}\}_{j=1,...,n^{\mathrm{T}}}$ 分别是从不同的分布中提取的源域和目标域数据；$\mathcal{H}$ 表示 RKHS。为了简化计算，特征映射 $\Phi(\cdot)$ 通过核函数 K 来实现，其公式如下：

$$K(x_i^{\mathrm{S}},x_j^{\mathrm{T}})=<\Phi(x_i^{\mathrm{S}}),\Phi(x_j^{\mathrm{T}})> \tag{13}$$

式中：$\langle\cdot,\cdot\rangle$ 表示向量的内积。

MMD 仅使用单一核函数来度量源域和目标域的分布差异，难以全面捕捉复杂的非线性分布。而 MK-MMD 通过多个核函数的加权组合，能够在 RKHS 中捕捉数据分布的不同特性和尺度，相比于 MMD 可以更细致地对齐源域和目标域的分布[29]，MK-MMD 核函数的计算公式如下：

$$K(x_i^{\mathrm{S}},x_j^{\mathrm{T}})=\sum_{i=1}^{k}K_i(x_i^{\mathrm{S}},x_j^{\mathrm{T}}) \tag{14}$$

式中：$K_i(i=1,...,k)$ 表示 k 个核函数的组合。

MK-MMD 损失的定义如下：

中国知网　https://www.cnki.net

$$L_{\text{MK-MMD}}=\sum_{K\in\mathrm{k}}\text{MK-MMD}_K(\boldsymbol{X}_t^{f^{\mathrm{S}}},\boldsymbol{X}_t^{f^{\mathrm{T}}}) \tag{15}$$

式中：$\boldsymbol{X}_t^{f^{\mathrm{S}}}$ 和 $\boldsymbol{X}_t^{f^{\mathrm{T}}}$ 为源域和目标域数据经特征提取器提取得到的特征矩阵。

CORAL 通过计算源域和目标域协方差矩阵之间的 Frobenius 范数来度量分布差异，主要关注特征之间的相关性对齐[30]。

CORAL 损失的定义如下：

$$L_{\text{CORAL}}=\frac{1}{4d^2}\left\|\boldsymbol{C}_{\mathrm{S}}-\boldsymbol{C}_{\mathrm{T}}\right\|_F^2 \tag{16}$$

式中：$\|\cdot\|_F^2$ 为 Frobenius 范数；d 为特征维度；$\boldsymbol{C}_{\mathrm{S}}$ 和 $\boldsymbol{C}_{\mathrm{T}}$ 分别是源域和目标域特征的协方差矩阵，其计算公式如下：

$$\boldsymbol{C}_{\mathrm{S}}=\frac{1}{n^{\mathrm{S}}-1}[\boldsymbol{D}_{\mathrm{S}}^{\mathrm{T}}\boldsymbol{D}^{\mathrm{S}}-\frac{1}{n_{\mathrm{S}}}(\boldsymbol{1}^{\mathrm{T}}\boldsymbol{D}^{\mathrm{S}})^{\mathrm{T}}(\boldsymbol{1}^{\mathrm{T}}\boldsymbol{D}^{\mathrm{S}})] \tag{17}$$

$$\boldsymbol{C}_{\mathrm{T}}=\frac{1}{n^{\mathrm{T}}-1}[\boldsymbol{D}_{\mathrm{T}}^{\mathrm{T}}\boldsymbol{D}^{\mathrm{T}}-\frac{1}{n^{\mathrm{T}}}(\boldsymbol{1}^{\mathrm{T}}\boldsymbol{D}^{\mathrm{T}})^{\mathrm{T}}(\boldsymbol{1}^{\mathrm{T}}\boldsymbol{D}^{\mathrm{T}})] \tag{18}$$

在 DATN 框架中，源域和目标域负荷经过特征提取器提取到特征矩阵，然后通过公式(15)和公式(16)分别计算它们的 MK-MMD 损失和 CORAL 损失。MK-MMD 通过关注特征的均值对齐，更加侧重于捕捉特征在非线性分布上的差异[31]，而 CORAL 对于源域和目标域之间的线性分布差异表现良好，但对复杂的非线性分布差异的适应能力有限[32]。结合 MK-MMD 和 CORAL 损失能够在域自适应任务中提供更全面的分布对齐策略。MK-MMD 利用多个核函数在高维空间中对齐源域和目标域的均值分布，捕捉复杂的非线性分布差异；而 CORAL 则通过对齐协方差矩阵来处理特征间的线性关系，确保特征的二阶统计量一致。两者结合能够同时捕捉源域与目标域在均值和协方差两个方面的分布差异，实现更全面的特征对齐。此外，组合使用能够有效应对线性与非线性分布差异，增强模型的适应性和泛化能力。利用这种双重对齐策略，能够进一步缩小源域和目标域间的分布差异，提升预测精度和稳定性。

3 算例分析

3.1 数据集描述与处理

本文使用的数据集来源于中国南方某省 50 家工业用户的历史负荷数据，采样频率为每小时一次，数据范围为 2022 年 1 月 1 日至 2022 年 10 月 1 日。本文短期负荷预测实验中，采用滑动窗口方法，利用前 3 天的负荷数据(72 个时刻)预测未来一天的负荷数据(24 个时刻)。

在联合训练阶段，随机选择一家企业作为目标域企业，目标域数据为该企业 2022 年 8 月的用电负荷数据，共 31 天，合计 31×24=744 个样本。从其余 49 家企业中选择与目标域企业 MMD 值最小的一家企业作为源域企业，源域数据为该企业 2022 年 1 月至 8 月的用电负荷数据，共 243 天，合计 243×24=5832 个样本。在预测阶段，选用目标域企业 2022 年 9 月的数据进行测试，共 30 天，合计 30×24=720 个样本。

由于选用的数据集的电力负荷值跨度较大，为了模型能够更好地学习数据之间的规律，消除量纲的影响，本文在处理异常数据后，采用最大最小归一化将数据放缩至[0,1]之间。归一化公式为

$$y_i'=\frac{y_i-y_{\min}}{y_{\max}-y_{\min}} \tag{19}$$

式中：y_i' 为归一化后的负荷值；$y_{\min}$ 为负荷序列中的最小值；$y_{\max}$ 为负荷序列中的最大值。

为避免源域企业与目标域企业之间的数据分布相差过大对模型产生负迁移影响，本文根据公式(12)，计算目标域企业 8 月份的数据与 49 家企业 1 至 8 月份数据之间的 MMD 值，计算结果如图 5 所示。根据这些 MMD 值，从 49 家企业中选出与目标域企业 MMD 值最小的企业作为源域企业，其负荷数据将作为源域数据。

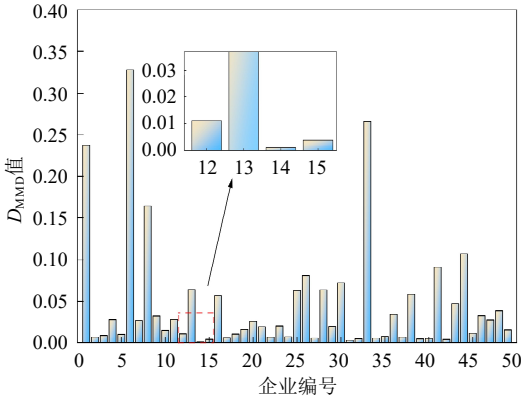


图 5 目标域与各源域 MMD 值计算结果

Fig. 5 Calculation result of the MMD value between the target domain and the source domain

3.2 评价指标选取

本文使用均方根误差(root mean square error，RMSE)、平均绝对误差(mean absolute error，MAE)平均绝对百分比误差(mean absolute percentage error，MAPE)、对称平均绝对百分比误差(symmetric mean absolute percentage error，SMAPE)4 个指标对本文的实验结果进行评价。评价指标的计算公式如式(18)—(21)所示。

$$\delta_{\text{RMSE}}=\sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i-y_i)^2} \tag{20}$$

中国知网 https://www.cnki.net

$$\delta_{\mathrm{MAE}}=\frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i-y_i| \tag{21}$$

$$\delta_{\mathrm{MAPE}}=\frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{\hat{y}_i-y_i}{y_i}\right| \tag{22}$$

$$\delta_{\mathrm{SMAPE}}=\frac{100\%}{n}\sum_{i=1}^{n}\frac{|\hat{y}_i-y_i|}{(|\hat{y}_i|+|y_i|)/2} \tag{23}$$

式中：n 为预测样本数量；$\hat{y}_i=\{\hat{y}_1,\hat{y}_2,\cdots,\hat{y}_n\}$ 为模型预测值；$y_i=\{y_1,y_2,\cdots,y_n\}$ 为真实值。

3.3　模型参数设置

模型的训练与预测过程中涉及众多超参数的调节，这些超参数的选择对最终预测结果具有关键影响。为确定最佳参数设置，本文采用了分步式调参策略。首先，对预测结果影响较小的基础参数，包括输出长度、迭代次数、优化器、Dropout 值和隐含层维度，在合理范围内选择默认值，以减少调参复杂度。然后，对预测结果影响较大的关键参数，包括输入长度、学习率、批次大小、注意力机制头数、编码器层数和核函数个数，使用网格搜索的方法寻求参数的最佳组合。经过多次训练和优化调整，各项超参数设置如表 1 所示。

表 1　模型参数设置
Table 1　Model parameter setting

类型	参数名称	参量值
全局参数	输入长度	72
	输出长度	24
	迭代次数	150
	批次	32
	优化器	Adam
	学习率	0.001
特征提取器	Dropout	0.1
	前馈网络神经元	[32,128,32]
	注意力机制头数	8
	编码器层数	8
预测器	Dropout	0.1
	前馈网络神经元	[32,128,256,24]
域判别器	前馈网络神经元	[32,16,16,2]
MK-MMD	核函数个数	3

3.4　域迁移性能实验

为了验证所提出的 DATN 模型在源-目标域之间迁移知识的有效性，将所提模型与纯源域模型(Source-Only)、纯目标域模型(Target-Only)以及传统迁移学习中常用的微调模型(fine-tuning，FT)进行对比。其中，纯源域模型使用源域数据进行训练，在目标域上进行预测；纯目标域模型使用目标域数据进行训练，在目标域上进行预测；微调模型首先使用源域数据对特征提取器和预测器进行预训练，然后冻结特征提取器的参数，并用目标域数据更新预测器的参数以完成微调，最后在测试集上进行预测。得到各模型的误差指标如表 2 所示。

从表 2 中可以看出，本文所提的方法在各指标结果上均优于其他方法，具体结论可以分为以下几点：

1）Target-Only 模型仅使用目标域数据进行训练，由于无法获取足够的目标域数据，模型的学习能力受到限制，导致预测误差最大。

2）Source-Only 模型依赖大量源域数据进行训练，尽管能够学习到更多的知识，但由于未使用目标域数据，模型难以准确捕捉目标域的特定特征，导致预测精度不足。

3）FT 模型在源域数据上进行预训练，并利用目标域数据以微调模型权重，平衡两个域的特性。然而，由于该方法未能充分处理源域和目标域之间的数据分布差异，导致其在目标域的预测效果仅为次优。这种方式虽能在一定程度上利用源域数据，但由于未能充分适应两域特性的差异性，模型在目标域上的泛化能力仍受到一定限制。

4）相比上述 3 个模型，DATN 模型通过域对抗迁移方法，使模型在训练过程中同时利用源域和目标域数据，并通过域对抗策略结合 MK-MMD 和 CORAL，有效减小源域与目标域负荷数据的分布差异。这种方法不仅保证了模型在源域知识迁移过程中的稳定性，还增强了模型在目标域上的适应能力。因此，DATN 在目标域上达到了更低的误差值。与 Target-Only 模型相比，DATN 方法在目标域上的 MAPE、MAE、RMSE 和 SMAPE 分别减少了 47.29%、52.82%、48.33%和 48.15%。

表 2　不同模型结果对比
Table 2　Comparison results of different methods

模型	δ_{RMSE}/MW	δ_{MAE}/MW	δ_{MAPE}/%	δ_{SMAPE}/%
Target-Only	4.838	5.797	2.423	2.432
Source-Only	3.948	4.745	1.987	1.969
FT	3.220	3.985	1.618	1.610
DATN	**2.550**	**2.735**	**1.252**	**1.261**

通过对比分析实验结果可以看出，本文提出的 DATN 模型有效提升了负荷预测的准确性。为了更直观地展示模型的预测效果，随机选取某日 0 时作为预测起点，将预测结果与真实数据进行对比，如图 6 所示。

从图 6 中可以直观地看出，DATN 方法的预测曲线与真实负荷最为接近，表现出最优的预测效果。相比之下，Target-Only 和 Source-Only 方法的预测偏差较大，其预测曲线波动幅度较为明显。FT 方法虽然在部分时间段表现较好，但整体拟合度不及 DATN。实例实验证明了所提模型能够将源域负

中国知网　https://www.cnki.net

荷数据知识有效迁移至目标域负荷数据上，提升负荷预测精度。

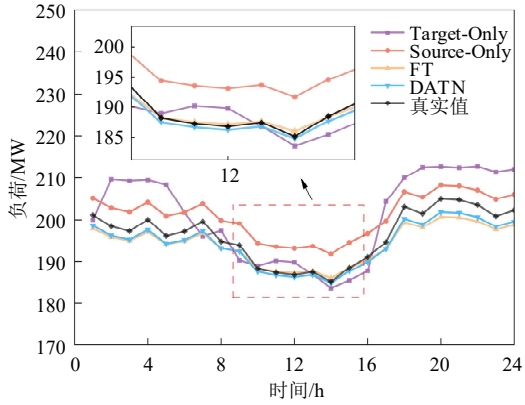


图 6 不同模型预测结果对比

Fig. 6 Comparison prediction results of different models

3.5 特征提取器性能实验

为验证 DATN 模型特征提取器的性能，在相同域自适应策略下，将所提 Transformer 特征提取器与多层感知机(multilayer perceptron，MLP)、RNN、CNN、LSTM、Informer、时序卷积网络(temporal convolutional network，TCN)、Autoformer 这 6 种时间序列特征提取神经网络进行比较，结果如表 3 所示。

表 3 不同特征提取器结果对比

Table 3 Comparison results of different feature extractors

特征提取器	δ_{RMSE}/MW	δ_{MAE}/MW	δ_{MAPE}/%	δ_{SMAPE}/%
MLP	3.057	3.542	1.505	1.515
RNN	2.717	3.310	1.348	1.350
LSTM	2.729	3.125	1.334	1.345
Informer	2.645	3.057	1.296	1.306
TCN	2.566	3.148	1.282	1.269
Autoformer	2.539	2.975	1.259	1.262
Transformer	**2.550**	**2.735**	**1.252**	**1.261**

从表 3 的结果可以看出，采用 Transformer 作为所提模型特征提取器的架构在负荷预测任务中的综合表现优于其他架构。根据表 3 的预测指标结果，具体可以得到如下结论：

1)由于 MLP 无法捕捉时序数据的时间依赖性，其在提取负荷数据特征时的效果有限。相比之下，Transformer 通过自注意力机制，可以在全局范围内灵活捕捉特征和依赖关系，从而能够处理长时间依赖，使得负荷数据的全局特征提取更为全面和准确。

2）RNN 和 LSTM 能够有效处理负荷数据的长期依赖关系，尤其是 LSTM 通过记忆单元和门控机制解决了数据之间的长时间依赖问题。然而，这些模型采用递归计算模式，导致在处理长序列数据时容易出现信息衰减，进而影响特征提取的完整性。相比之下，Transformer 利用自注意力机制，在捕捉序列数据的长距离依赖关系方面表现出色，并且由于其结构无须依赖顺序处理，能够更有效地获取全局特征，使模型在负荷序列的特征提取上具有更高的能力。

3）TCN 通过因果卷积和膨胀卷积的组合能够捕捉到较长的时间依赖关系。然而，TCN 的卷积核感受野有限，导致其在捕捉极长距离依赖和全局信息时表现不如 Transformer。Transformer 的自注意力机制能够灵活捕捉各时间步之间的依赖关系，使其在处理具有复杂时序依赖的负荷数据时更具优势。

4)Informer 的稀疏注意力机制虽然提高了长序列的建模效率，但在捕捉短期依赖和突发波动方面表现不足，忽略了负荷数据中关键的短期信息。Autoformer 通过序列分解模块将时间序列分解为趋势和周期成分，以增强对长期趋势和周期性特征的提取能力，但在域适应场景中，源域和目标域之间的负荷模式差异导致分解结果不够准确，从而影响迁移性能，使得 3 个指标的表现不如 Transformer。相比之下，Transformer 的全局注意力机制能够均衡建模长短期依赖，不依赖特定的趋势或周期假设，对域分布差异具有更好的适应性和鲁棒性。

5）综合上述 4 点，Transformer 利用自注意力机制在全局范围内捕捉数据间的依赖关系，有效提升了负荷数据的特征提取效果，其并行计算能力和多头注意力机制使其在处理长序列时表现出色，能够同时关注负荷数据的全局特征和细节变化。因此，Transformer 作为域自适应特征提取器，强化了域间特征的关联与整合，在负荷预测任务中展现出了比其他特征提取器更卓越的综合性能。

图 7 展示了不同特征提取器在某一天的负荷预测曲线与真实值的对比。可以清晰地看到，采用 Transformer 作为特征提取器时，预测曲线更加贴近真实值，表现出更好的拟合效果。

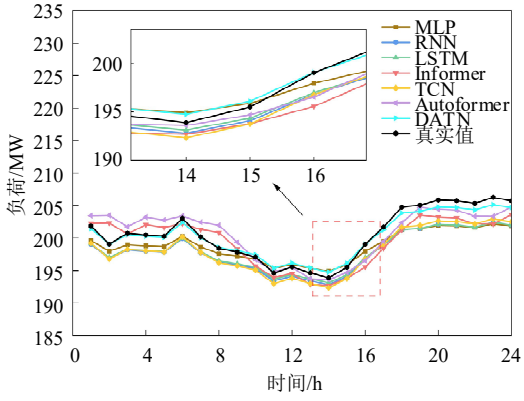


图 7 不同特征提取器在某一天负荷预测结果对比

Fig. 7 Comparison results of different feature extractors in one-day load forecasting

中国知网 https://www.cnki.net

3.6　与其他域自适应方法对比

为验证 DATN 模型在短期负荷预测问题上的优越性，本文将所提模型与迁移学习中 5 种经典域自适应方法进行对比：

1）深度域混淆(deep domain confusion，DDC)[33]：通过最小化源域和目标域特征之间的 MMD 来实现域自适应。

2）深度相关对齐(Deep CORAL)[34]：通过最小化源域和目标域特征之间的 CORAL 来实现特征对齐。

3）深度域自适应(deep domain adaptation，DDA)[32]：通过同时最小化源域和目标域特征之间的 MMD 和 CORAL 来实现特征分布的对齐。

4）域对抗神经网络(domain-adversarial neural networks，DANN)[35]：通过引入一个对抗性的域分类器，运用对抗的思想，使源域和目标域的特征分布对齐。

5）基于教师模型的决策边界迭代强化训练(decision-boundary iterative refinement training with a teacher，DIRT)模型[36]：结合了虚拟对抗训练和域对抗训练来实现域自适应。

域自适应方法的对比结果如表 4 所示。

表 4　不同域自适应方法结果对比

Table 4　Comparison results of different domain adaptation methods

模型	δ_{RMSE}/MW	δ_{MAE}/MW	δ_{MAPE}/%	δ_{SMAPE}/%
DDC	3.163	3.633	1.546	1.561
Deep CORAL	2.963	3.394	1.448	1.461
DDA	2.776	3.211	1.362	1.372
DANN	2.597	3.124	1.325	1.312
DIRT	2.576	3.049	1.283	1.284
DATN	**2.550**	**2.735**	**1.252**	**1.261**

如表 4 所示，本文所提出的方法在各项误差指标上均取得了最优表现，说明该方法在短期负荷预测问题上具有较高的效率和准确性。具体来说，可以得到以下结论：

1）基于统计量的 DDC 和 Deep CORAL 方法虽然在一定程度上减小了源域和目标域企业负荷特征之间的分布距离，但由于它们仅依赖单一的分布对齐标准，因此在减少误差方面的效果有限。

2）DDA 结合了 MMD 和 CORAL，通过更复杂的分布对齐策略来减少域间差异，表现出比 DDC 和 Deep CORAL 更低的误差。

3）基于对抗性训练的 DANN 和 DIRT 方法通过对抗性策略使源域和目标域的负荷特征分布更加接近，特别是 DIRT 方法引入了虚拟对抗训练和条件熵损失，使模型对输入数据的微小扰动更加鲁棒，提升了模型的泛化能力。

4）相比之下，本文提出的 DATN 方法在各项性能指标上表现更加优异。这主要得益于该方法通过域对抗策略，在源域和目标域之间提取共同的深度域不变特征，并结合均值对齐和二阶统计量对齐的方法，减少了两者之间的分布差异。这种双重对齐策略不仅确保了模型在保留源域负荷特征的同时，能够有效适应目标域负荷的分布变化和波动性，从而有效提升了模型的预测精度，使其在跨域负荷预测任务中表现出色。

为了进一步细化分析 MK-MMD 和 CORAL 在减小域间分布差异方面的性能，分别取核函数个数 K 为 1、2、3 以及 3 个核函数加 CORAL 的组合(本文方法)来评估它们的效果，结果如图 8 所示。

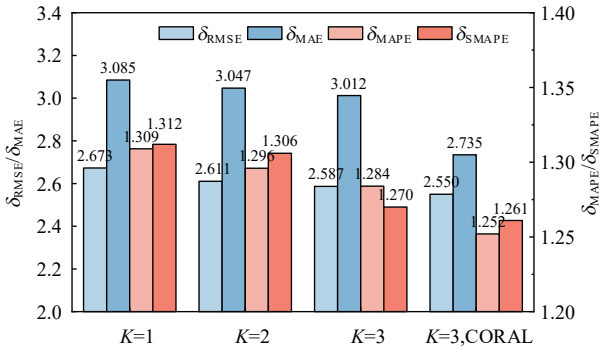


图 8　MK-MMD 和 CORAL 在不同核函数配置下的结果对比

Fig. 8　Comparison results between MK-MMD and CORAL under different kernel configurations

从图 8 可以看出，随着 MK-MMD 核函数数量的增加，模型的预测误差逐渐降低，显示出更好的领域适应性能。此外，结合 CORAL 后，模型的表现进一步提升，RMSE 降至 2.550MW，MAE 降至 2.735MW，MAPE 降至 1.252%，SMAPE 降至 1.261%。这些结果证明了 MK-MMD 与 CORAL 的结合可以更有效地减少源域和目标域之间的分布差异，提高预测精度。

3.7　模型泛化性验证

为验证所提模型具有良好的泛化性，另增设 3 家企业的实际负荷数据进行算例测试。所选 3 家企业在用电规模和用电规律上与前述企业均存在明显差异。3 家企业训练集和测试集的选取时间与上述实验相同。采用第 3.4 节中的实验方法进行实验，实验结果如表 5 所示。

由表 5 可见，本文提出的 DATN 方法在各项误差指标上均表现出优越的性能，优于其他预测方法。这表明，在小样本场景中，DATN 模型在面对

中国知网　https://www.cnki.net

不同用电规模和用电规律的企业时具备很好的适应能力，其通过域对抗与 MK-MMD 和 CORAL 结合的双重对齐策略，成功减少了域间的分布差异，提升了负荷预测的精度和稳定性，在跨域负荷预测任务中表现出出色的泛化性能。

表 5 不同企业用户性能对比
Table 5 Performance comparison of different enterprise users

企业	模型	δ_{RMSE}/MW	δ_{MAE}/MW	δ_{MAPE}/%	δ_{SMAPE}/%
01	Target-Only	0.905	1.149	3.067	2.997
	Source-Only	0.792	1.004	2.682	2.628
	FT	0.748	0.923	2.474	2.450
	DATN	**0.582**	**0.722**	**1.935**	**1.917**
02	Target-Only	0.179	0.209	2.162	2.157
	Source-Only	0.140	0.166	1.658	1.669
	FT	0.127	0.143	1.575	1.559
	DATN	**0.101**	**0.117**	**1.187**	**1.196**
03	Target-Only	0.192	0.228	2.254	2.287
	Source-Only	0.160	0.181	1.974	1.948
	FT	0.141	0.156	1.662	1.679
	DATN	**0.121**	**0.144**	**1.434**	**1.443**

4 结论

针对目标用户历史数据不足，难以进行精准负荷预测的问题，本文提出了一种基于域对抗迁移网络(DATN)的短期电力负荷预测方法。该方法通过将 Transformer 网络作为特征提取器，能有效提取电力负荷的时序特征。此外，结合对抗策略、多核最大均值差异(MK-MMD)和相关性对齐(CORAL)，建立了一种新的域自适应迁移策略，进一步对齐源域和目标域电力负荷数据的特征分布，减少不同企业负荷曲线之间的特征差异。该模型在南方某省多个工业用户用电数据集上验证了其有效性。后续工作可考虑多源域的选取，同时将天气等影响因素考虑进去，进一步提高模型的泛化性和预测精度。

参考文献

[1] 韩富佳，王晓辉，乔骥，等. 基于人工智能技术的新型电力系统负荷预测研究综述[J]. 中国电机工程学报，2023，43(22)：8569-8592.
HAN Fujia，WANG Xiaohui，QIAO Ji，et al. Review on artificial intelligence based load forecasting research for the new-type power system[J]. Proceedings of the CSEE，2023，43(22)：8569-8592(in Chinese).

[2] 范茜茜，王国强，罗贺，等. 基于 N-BEATS 与辅助编码器的短期电力负荷预测[J]. 电网技术，2024，48(4)：1612-1621.
FAN Xixi，WANG Guoqiang，LUO He，et al. Short-term electricity load forecasting based on N-BEATS with auxiliary encoders[J]. Power System Technology，2024，48(4)：1612-1621(in Chinese).

[3] 邓带雨，李坚，张真源，等. 基于 EEMD-GRU-MLR 的短期电力负荷预测[J]. 电网技术，2020，44(2)：593-602.
DENG Daiyu，LI Jian，ZHANG Zhenyuan，et al. Short-term electric load forecasting based on EEMD-GRU-MLR[J]. Power System Technology，2020，44(2)：593-602(in Chinese).

[4] 赵峰，孙波，张承慧. 基于多变量相空间重构和卡尔曼滤波的冷热电联供系统负荷预测方法[J]. 中国电机工程学报，2016，36(2)：399-406.
ZHAO Feng，SUN Bo，ZHANG Chenghui. Cooling，heating and electrical load forecasting method for CCHP system based on multivariate phase space reconstruction and Kalman filter[J]. Proceedings of the CSEE，2016，36(2)：399-406(in Chinese).

[5] ZHANG Jinliang，WEI Yiming，LI Dezhi，et al. Short term electricity load forecasting using a hybrid model[J]. Energy，2018，158：774-781.

[6] 缪希仁，林蔚青，肖洒，等. 基于条件互信息与 LSTNet 的特高压变压器顶层油温预测方法[J]. 电网技术，2022，46(7)：2601-2609.
MIAO Xiren，LIN Weiqing，XIAO Sa，et al. Forecasting method for top oil temperature in ultra-high voltage transformers based on conditional mutual information and LSTNet[J]. Power System Technology，2022，46(7)：2601-2609(in Chinese).

[7] 赵佩，代业明. 基于实时电价和加权灰色关联投影的 SVM 电力负荷预测[J]. 电网技术，2020，44(4)：1325-1332.
ZHAO Pei，DAI Yeming. Power load forecasting of SVM based on Real-time price and weighted grey relational projection algorithm[J]. Power System Technology，2020，44(4)：1325-1332(in Chinese).

[8] 胡兆龙，胡俊建，彭浩，等. 基于深度随机森林算法的短期用户负荷预测——以金华地区为例[J]. 电子科技大学学报，2023，52(3)：430-437.
HU Zhaolong，HU Junjian，PENG Hao，et al. Short-term user load forecasting based on deep random forest：take Jinhua city as an example[J]. Journal of University of Electronic Science and Technology of China，2023，52(3)：430-437(in Chinese).

[9] 唐贤伦，陈洪旭，熊德意，等. 基于极端梯度提升和时间卷积网络的短期电力负荷预测[J]. 高电压技术，2022，48(8)：3059-3067.
TANG Xianlun，CHEN Hongxu，XIONG Deyi，et al. Short-term power load forecasting based on extreme gradient boosting and temporal convolutional network[J]. High Voltage Engineering，2022，48(8)：3059-3067(in Chinese).

[10] 石卓见，冉启武，徐福聪. 基于聚合二次模态分解及 Informer 的短期负荷预测[J]. 电网技术，2024，48(6)：2574-2583.
SHI Zhuojian，RAN Qiwu，XU Fucong. Short-term load forecasting based on aggregated secondary decomposition and Informer[J]. Power System Technology，2024，48(6)：2574-2583(in Chinese).

[11] SEKHAR C，DAHIYA R. Robust framework based on hybrid deep learning approach for short term load forecasting of building electricity demand[J]. Energy，2023，268：126660.

[12] LV Lingling，WU Zongyu，ZHANG Jinhua，et al. A VMD and LSTM based hybrid model of load forecasting for power grid security[J]. IEEE Transactions on Industrial Informatics，2021，18(9)：6474-6482.

[13] 林蔚青，缪希仁，肖洒，等. 基于时空特征挖掘的特高压变压器热状态参量预测方法[J]. 中国电机工程学报，2024，44(4)：1649-1661.
LIN Weiqing，MIAO Xiren，XIAO Sa，et al. Forecasting method for thermal state parameters in ultra-high voltage transformers based on spatial-temporal features mining[J]. Proceedings of the CSEE，2024，44(4)：1649-1661(in Chinese).

[14] 臧海祥，陈玉伟，程礼临，等. 基于多尺度分量特征学习的用户级超短期负荷预测[J]. 电网技术，2024，48(6)：2584-2592.
ZANG Haixiang，CHEN Yuwei，CHENG Lilin，et al. User level ultra-short-term load forecasting based on multi-scale component feature learning[J]. Power System Technology，2024，48(6)：2584-2592(in Chinese).

中国知网 https://www.cnki.net

[15] LIN Jun，MA Jin，ZHU Jianguo，et al．Short-term load forecasting based on LSTM networks considering attention mechanism[J]．International Journal of Electrical Power & Energy Systems，2022，137：107818．

[16] CHEN Yunxiao，LIN Chaojing，ZHANG Yulan，et al．Day-ahead load forecast based on Conv2D-GRU_SC aimed to adapt to steep changes in load[J]．Energy，2024，302：131814．

[17] HIMEUR Y，ELNOUR M，FADLI F，et al．Next-generation energy systems for sustainable smart cities：roles of transfer learning[J]．Sustainable Cities and Society，2022，85：104059．

[18] ZHUANG Fuzhen，QI Zhiyuan，DUAN Keyu，et al．A comprehensive survey on transfer learning[J]．Proceedings of the IEEE，2021，109(1)：43-76．

[19] 欧阳福莲，王俊，周杭霞．基于改进迁移学习和多尺度 CNN-BiLSTM-Attention 的短期电力负荷预测方法[J]．电力系统保护与控制，2023，51(2)：132-140(in Chinese)．
OUYANG Fulian，WANG Jun，ZHOU Hangxia．Short-term power load forecasting method based on improved hierarchical transfer learning and multi-scale CNN-BiLSTM-attention[J]．Power System Protection and Control，2023，51(2)：132-140(in Chinese)．

[20] 张勇，陶一凡，巩敦卫．迁移学习引导的变源域长短时记忆网络建筑负荷预测[J]．控制与决策，2021，36(10)：2328-2338．
ZHANG Yong，TAO Yifan，GONG Dunwei．Load forecasting of buildings using LSTM based on transfer learning with variable source domain[J]．Control and Decision，2021，36(10)：2328-2338(in Chinese)．

[21] RIBEIRO M，GROLINGER K，ELYAMANY H F，et al．Transfer learning with seasonal and trend adjustment for cross-building energy forecasting[J]．Energy and Buildings，2018，165：352-363．

[22] FAN Cheng，SUN Yongjun，XIAO Fu，et al．Statistical investigations of transfer learning-based methodology for short-term building energy predictions[J]．Applied Energy，2020，262：114499．

[23] KOUW W M，LOOG M．A review of domain adaptation without target labels[J]．IEEE Transactions on Pattern Analysis and Machine Intelligence，2021，43(3)：766-785．

[24] RAGAB M，ELDELE E，TAN W L，et al．ADATIME：a benchmarking suite for domain adaptation on time series data[J]．ACM Transactions on Knowledge Discovery from Data，2023，17(8)：106．

[25] WANG Chen，WANG Ying，DING Zhetong，et al．A transformer-based method of multienergy load forecasting in integrated energy system[J]．IEEE Transactions on Smart Grid，2022，13(4)：2703-2714．

[26] 邹念，张颖，苏盛，等．基于小时尺度周期特征自编码器的用户窃电识别方法[J]．电网技术，2023，47(6)：2558-2565．
ZOU Nian，ZHANG Ying，SU Sheng，et al．User electric theft detection method based on hour scale periodic feature LSTM-transformer[J]．Power System Technology，2023，47(6)：2558-2565(in Chinese)．

[27] 陈静，王铭海，刘煜寒，等．基于 Transformer 与单分类支持向量机的窃电时间识别方法[J/OL]．电网技术，2024：1-11[2024-06-28]．http://kns.cnki.net/kcms/detail/11.2410.tm.20240620.1452.002.html．
CHEN Jing，WANG Minghai，LIU Yuhan，et al．Electricity theft time identification method based on transformer and one-class support vector machine[J/OL]．Power System Technology，2024：1-11[2024-06-28]．http://kns.cnki.net/kcms/detail/11.2410.tm.20240620.1452.002.html．(in Chinese)．

[28] ZHU Yongchao，ZHU Caichao，TAN Jianjun，et al．Fault detection of offshore wind turbine gearboxes based on deep adaptive networks via considering spatio-temporal fusion[J]．Renewable Energy，2022，200：1023-1036．

[29] LI Jimeng，YE Zhangdi，GAO Jie，et al．Fault transfer diagnosis of rolling bearings across different devices via multi-domain information fusion and multi-kernel maximum mean discrepancy[J]．Applied Soft Computing，2024，159：111620．

[30] 王鹏，李丹青，王恒．基于改进交替迁移学习的滚动轴承故障诊断算法[J]．振动与冲击，2024，43(5)：239-249．
WANG Peng，LI Danqing，WANG Heng．Rolling bearing fault diagnosis algorithm based on improved alternating transfer learning[J]．Journal of Vibration and Shock，2024，43(5)：239-249(in Chinese)．

[31] HE Ziyang，CHEN Yufei，YUAN Shuaiying，et al．A novel unsupervised domain adaptation framework based on graph convolutional network and multi-level feature alignment for inter-subject ECG classification[J]．Expert Systems with Applications，2023，221：119711．

[32] RAHMAN M M，FOOKES C，BAKTASHMOTLAGH M，et al．Correlation-aware adversarial domain adaptation and generalization [J]．Pattern Recognition，2020，100：107124．

[33] TZENG E，HOFFMAN J，ZHANG Ning，et al．Deep domain confusion：maximizing for domain invariance[Z]．arXiv preprint arXiv：1412.3474，2014．

[34] SUN Baochen，FENG Jiashi，SAENKO K．Correlation alignment for unsupervised domain adaptation[J]．Domain Adaptation in Computer Vision Applications，2017：153-171．

[35] GANIN Y，USTINOVA E，AJAKAN H，et al．Domain-adversarial training of neural networks[J]．The Journal of Machine Learning Research，2016，17(1)：2096-2030．

[36] SHU Rui，BUI H H，NARUI H，et al．A dirt-t approach to unsupervised domain adaptation[C]//6th International Conference on Learning Representations．Vancouver：IEEE，2018．



缪希仁

在线出版日期：2025-05-23。
收稿日期：2024-10-07。

作者简介：

缪希仁(1965)，男，教授，博士生导师，研究方向为电器及其系统智能化技术、电气设备在线监测与诊断等，E-mail：mxr@fzu.edu.cn；

刘煜寒(2000)，女，硕士研究生，研究方向为人工智能在电力领域的应用，E-mail：734472281@qq.com；

陈静(1988)，女，通信作者，博士，副教授，主要研究方向为电力大数据和智能电网，E-mail：chenj@fzu.edu.cn。

（责任编辑　王金芝）

中国知网　https://www.cnki.net