分类号：　　学校代号：11847

UDC：　　密级：　　学　　号：2112151131

佛山科学技术学院

硕士学位论文

（电子信息硕士）

基于域自适应的短期电力负荷预测应用研究

作者姓名：陈彦佑

学科专业：电子信息

导师姓名：何俊

完成时间：二〇二四年五月

中国知网　https://www.cnki.net

Foshan University

A dissertation for master's degree

Application Research of Short-term Power Load Forecasting Based on Domain Adaptation

Author: Chen Yanyou

Speciality: Electronic and Information Engineering

Supervisors: He Jun

Finished time: May,2024

中国知网 https://www.cnki.net

摘　要

面对新型电力系统的转型以及大量的工业企业投产，电网的稳定性迎来挑战。为保障电力系统的运行稳定，电力企业运营部门需要使用精准的负荷预测技术来设计方案，控制运行成本，平衡电力的供应与需求。本文主要使用迁移学习中的域自适应技术对当前短期电力负荷预测技术在面对不同地区的负荷进行预测时存在的预测精确度低和模型泛化能力差的问题开展深入研究。旨在面对不同地区的负荷数据分布差异大以及目标预测区域负荷数据样本少的问题时，进行短期电力负荷预测，提高模型泛化能力，提升预测精度。本文主要的工作如下：

（1）针对不同地区的负荷数据分布差异大的问题，本文提出一种基于域自适应权重矩阵的极端梯度提升树的电力负荷预测方法，通过计算域自适应权重矩阵以缩小不同区域的负荷数据的分布差异，提高短期电力负荷预测精度，同时也解决原本模型训练过程中的梯度消失和模型泛化能力差等问题，并通过协方差差异相似对比度损失函数以改善预测模型的泛化能力和鲁棒性。采用 Electricity Load Diagrams 2011-2014 Dataset 数据集进行实验验证，实验结果表明，本模型在所有迁移任务中比传统极端梯度提升树模型的均方根误差平均降低 0.1943。

（2）针对目标预测区域负荷数据样本少的问题，提出一种基于残差网络的 Stacking 负荷预测微调模型。该模型基于残差网络在源域用户学习相关负荷变化的时序特征，然后在变分多核主成分分析的特征重构下，将特征传入通过 Stacking 融合的模型中训练，然后将训练完成的模型迁移到目标预测区域的少量历史负荷日的数据，利用域自适应中的微调技术，使得模型能够快速适应于目标区域的短期电力预测。采用佛山采集的工商业用户的电力负荷数据以及 Electricity Load Diagrams 2011-2014 Dataset 数据集进行迁移学习实验验证。实验结果表明，本模型在所有迁移任务中比其他模型的预测精度更佳，均方根误差最低降至 0.21。

关键词：短期电力负荷预测；迁移学习；域自适应；残差网络；微调

中国知网　https://www.cnki.net

ABSTRACT

In the face of the transformation of the new power system and the production of many industrial enterprises, the stability of the power grid has ushered in a challenge. To ensure the stable operation of the power system, the operation department of the power enterprise needs to use accurate load forecasting technology to design schemes, control operating costs, and balance the supply and demand of power. This thesis mainly uses the domain adaptation technology in transfer learning to carry out in-depth research on the problems of low prediction accuracy and poor model generalization ability of current short-term power load forecasting technology in the face of load forecasting in different regions. In the face of the large difference in load data distribution in different regions and the small number of load data samples in the target prediction area, this thesis aims to carry out short-term power load forecasting, improve the generalization ability of the model, and improve the prediction accuracy. The main work of this thesis is as follows:

(1) In view of the large difference of load data distribution in different regions, this thesis proposes a power load forecasting method based on extreme gradient boosting tree with domain adaptive weight matrix. By calculating domain adaptive weight matrix, the distribution difference of load data in different regions is reduced, and the accuracy of short-term power load forecasting is improved. At the same time, the problems of gradient disappearance and poor generalization ability of the model in the original model training process are solved, and the covariance difference similar contrast loss function is used to improve the generalization ability and robustness of the prediction model. The Electricity Load Diagrams 2011-2014 Dataset was used for experimental verification. The experimental results show that the root mean square error of this model is reduced by 0.1943 on average compared with the traditional extreme gradient boosting tree model in all migration tasks.

(2) Aiming at the problem of small load data samples in the target prediction

中国知网 https://www.cnki.net

area, a Stacking load forecasting fine-tuning model based on residual network is proposed. The model learns the time series characteristics of related load changes based on residual network in the source domain, and then under the feature reconstruction of variational multi-kernel principal component analysis, the features are passed into the model through Stacking fusion for training, and then the trained model is transferred to the data of a small number of historical load days in the target prediction area, and the fine-tuning technology in domain adaptation is used. So that the model can quickly adapt to the short-term power prediction of the target area. The power Load data of industrial and commercial users collected in Foshan and Electricity Load Diagrams 2011-2014 Dataset were used for transfer learning experimental verification. Experimental results show that the proposed model has better prediction accuracy than other models in all transfer tasks, and the root mean square error is reduced to 0.21 at the lowest.

Key Words: Short-term power load forecasting; Transfer learning; Domain adaptation; Residual Network; Fine-tuning

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 短期电力负荷预测研究现状.....2
1.3 研究内容与论文结构.....5
第二章 相关理论介绍.....7
2.1 负荷预测基本理论.....7
2.1.1 负荷预测的分类.....7
2.1.2 负荷特性与误差指标.....9
2.2 迁移学习.....13
2.2.1 迁移学习定义.....13
2.2.2 域自适应.....15
2.3 预测模型介绍.....16
2.3.1 残差网络.....16
2.3.2 极端梯度提升树.....18
2.3.3 Stacking 融合算法.....19
2.4 本章小结.....20
第三章 基于 XGBoost 模型的跨域负荷预测.....21
3.1 基本思想.....21
3.2 算法设计.....22
3.2.1 域自适应权重矩阵.....22
3.2.2 协方差差异相似对比度.....22
3.3 电力负荷数据处理.....24
3.3.1 原始电力负荷数据.....24
3.3.2 电力负荷数据特征集.....25
3.4 实验验证.....26
3.4.1 实验设置.....26
3.4.2 实验结果与分析.....27
3.5 本章小结.....36
第四章 基于 Stacking 残差网络的负荷预测.....37
4.1 基本思想.....37
4.2 算法设计.....37
4.2.1 变分多核主成分分析.....37
4.2.2 Stacking 的残差网络.....39
4.3 负荷数据处理与实验设置.....41

中国知网 https://www.cnki.net

4.3.1 佛山工商业用户数据集.....41
4.3.2 实验设置.....42
4.4 实验验证与结果分析.....43
4.4.1 相同地域电力负荷数据迁移.....43
4.4.2 跨地域电力负荷数据迁移.....46
4.5 本章小结.....53
第五章 总结与展望.....54
5.1 总结.....54
5.2 展望.....55
参考文献.....56

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

随着城市人口规模的扩大和工商业的大力发展，电力市场也应当与时俱进，逐步转型。虽然不同地区发展速度不同，但是每个地区对电力的需求日益增长是必然的。电力系统能否稳定地运行取决于电网公司对每个地区的电力规划，特别是在用电高峰时段，如果某个地区负荷出现剧烈波动，没有足够的电力供应就会引发超负荷的问题。因此，精确合理的电力负荷预测能够为电力规划[1]、电网运行[2]和电网维护[3]提供有效的指导。

近年来，域自适应技术在各大研究领域展现出十分优秀的性能，为很多领域提供新的研究思路。短期电力负荷预测的研究者们也纷纷引入迁移学习的方法来改善传统电力负荷预测模型的弊端。传统的电力负荷预测方法依赖于大量的历史电力负荷数据，并且这些历史电力负荷数据还需来源于同一个用户。同时，收集大量的历史负荷数据需要花费大量的人力和物力，会加大电网企业运营压力。电网公司在对不同地区开展业务时，往往无法第一时间收集大量当地用户的历史电力负荷数据，需要通过跨地区的部门进行业务协调，调取数据。而且面对极端情况，比如因为非人为因素导致历史负荷数据缺失，从而导致模型训练数据不充分，模型训练不充分则会导致模型预测精度大打折扣。

传统电力负荷模型在预测不同地区的电力负荷数据时，模型泛化能力差。针对这个问题，迁移学习中的域自适应技术可以用来提高模型在不同地区的数据集上的泛化能力。旨在通过减少两组数据之间的分布差异，来提升模型的性能。也能够有效解决某一区域电力负荷数据有限时，通过另一区域的数据训练模型，然后通过模型微调，使得模型在数据有限的数据集中仍能保持较好的性能。这种方法极大节省电网公司的人工成本以及时间成本，并且能够合理地规划不同片区的电力资源，为实现源网荷储一体化[4]的合理布局提供新思路，有助于提高能源的合理利用率以及降低电网的运营成本[5]。

中国知网 https://www.cnki.net

1.2 短期电力负荷预测研究现状

电力负荷预测的研究还需要追溯于 1976 年，当时 Box 等人[6]提出一种无需考虑其他因素的 Box-Jenkins 法。在 20 世纪 90 年代，人工神经网络[7-9](Artificial Neural Network, ANN)在各个研究领域已经掀起一股浪潮，机器学习在负荷预测的应用也就应运而生。随着 21 世纪计算机算力的发展速度不断提高，深度学习在机器学习领域突出重围，以卷积神经网络[10-12](Convolutional Neural Network, CNN)为代表的深度学习模型，能够通过构建一种非线性的相关函数去拟合一个真实值，使得模型能够达到较强的泛化能力。

目前负荷预测的主流方法如图 1.1 所示，主要包括基于统计学的方法[13]、基于时间序列的方法[14]和基于机器学习的方法[15]。

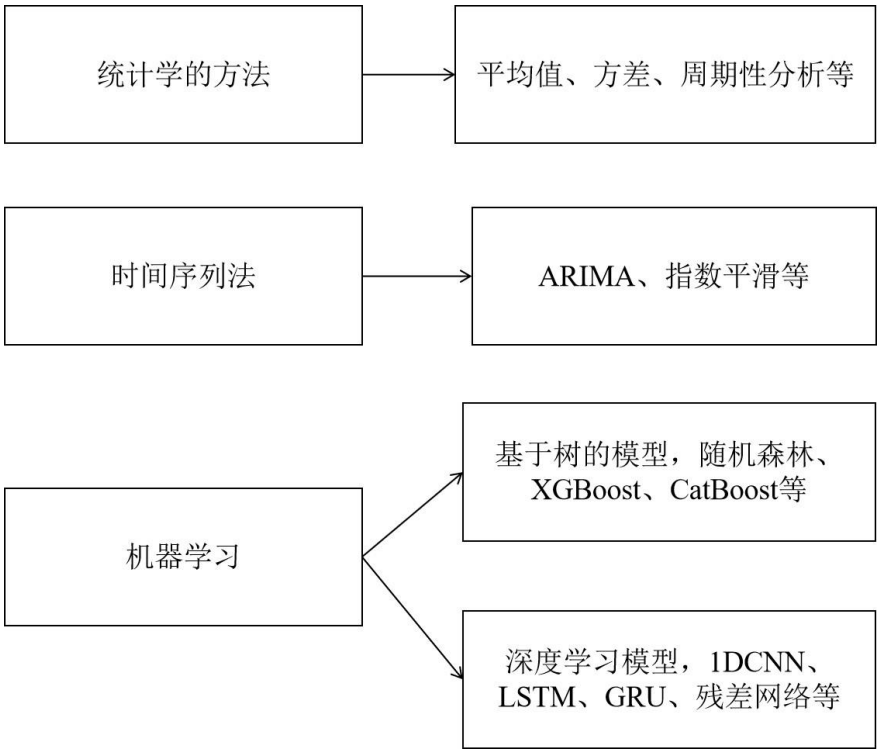


图 **1.1** 目前负荷预测的主流方法

Fig **1.1** Current mainstream methods for load forecasting

统计方法基于历史负荷数据的统计分析，例如平均值、方差、周期性分析等，比如 Box-Jenkins 法。这类方法简单直观，无需添加数据的额外特征，但往往无法捕捉数据的非线性关系和复杂环境下影响负荷值的动态变化。

时间序列方法基于时间序列模型，如自回归移动平均模型(Auto Regressive Integrated Moving Average, ARIMA)模型和指数平滑模型等。方娜等人[16]利用 ARIMA 提出一个自动预测框架，从多个组合中选取最佳的预测模型。Dudek

中国知网 https://www.cnki.net

等人[17]利用指数平滑模型技术动态提取每个单独时间序列的主要成分，以提升模型在预测中的精度。虽然这类算法通过分析电力负荷数据与其他影响因素之间的线性关系实现精准的电力负荷预测，但是仍然无法捕捉电力负荷数据与其他影响因素的非线性关系，会导致模型的泛化能力不足。

近年来，机器学习方法在负荷预测领域得到广泛应用，其中极端梯度提升树算法凭借其出色的性能和其的可解释性，备受研究者们的关注。极端梯度提升树是一种基于梯度提升决策树(Gradient Boosting Decision Tree, GBDT)的集成学习算法。这类方法通过迭代训练多个弱分类器并将它们组合成一个强分类器，能够有效地处理非线性关系和复杂特征。Deng 等人[18]使用 Bagging 集成极端梯度提升树算法，使用影响因素分析法从而提高模型因素。Yang 等人[19]使用贝叶斯超参数优化方法建立一种最优极端梯度提升树的负荷预测模型，然后通过模型微调和加权假日样本做到精准预测。Yao 等人[20]在极端梯度提升树模型的基础上集成轻量级梯度提升机(Light Gradient Boosting Machine, LightGBM)提升模型的预测精度。Zhang 等人[21]在极端梯度提升树模型的基础上集成类别型特征提升(Categorical Boosting, CatBoost)方法，提升模型在对电力负荷特征的分类并能够很好地捕捉不同特征之间的非线性关系。然而，这类基于 GDBT 算法的模型，在面对训练数据预测数据分布差异较大的情况下，性能会下降。因此，在将训练好的模型运用到另一个地区的电力负荷预测时，导致模型对电力负荷预测的精度降低[22, 23]。综上所述，基于机器学习的方法在负荷预测中取得显著的成果。这些方法利用机器学习算法从数据分布差异小的历史负荷数据中，捕捉电力负荷与其他影响因素之间的复杂关系，从而提高模型的预测精度，但在数据分布差异大的情况下，这类方法精度不尽如人意。

传统的机器学习方法在处理大规模、高维度的负荷数据时存在一定的局限性。因此，传统的预测方法可能无法满足当前需求。近年来深度学习技术，已经在这一领域显示出巨大潜力。姜建国等人[24]提出一种基于一维卷积神经网络(1D Convolutional Neural Network, 1DCNN)和长短时记忆神经网络(Long Short-Term Memory, LSTM)的模型，通过多层次的特征提取显著提高短期电力负荷预测的准确性。传统经验模态分解(Empirical Mode Decomposition, EMD)存在模态混叠以及端点效应[25]，变分模态分解(Variational Modal Decomposition,

中国知网 https://www.cnki.net

VMD)存在参数选择困难的问题。因此，杨汪洋等人[26]使用互补集合经验模态分解(Complementary Ensemble Empirical Mode Decomposition, CEEMD)技术分解原始数据，采用 VMD 对去除噪声后的数据进行二次信号特征提取，最后通过时序卷积网络(Temporal Convolutional Network, TCN)和双向长短时记忆神经网络(Bi-directional Long Short-Term Memory, Bi-LSTM)进行预测。朱伟等人[27]使用分解负荷序列的方法传入门控循环单元(Gate Recurrent Unit, GRU)网络使得模型精准度上升。朱莉等人[28]将 Informer 模型进行改进，将负荷数据进行二次分解重构。从而降低负荷预测结果的波动性。赵星宇等人[29]提出一种将 TCN 和 LSTM 相结合的预测方法，该方法依赖于负荷数据使用自适应噪声完备集合经验模态分解(Complete Ensemble Empirical Mode Decomposition with Adaptive Noise, CEEMDAN)进行预处理。但这类方法的鲁棒性较差，不能够很好地适应新的负荷数据，需要大量的原始负荷数据进行训练。

Stacking 作为一种集成学习方法，在各个领域中都能够很好地改进模型。当然，目前仍有很多在短期电力负荷预测的研究者在使用 Stacking 进行改进传统模型，Stacking 能够通过结合多个不同的基学习器进行训练，在多个基学习器之中通过融合每个基学习器学习的特征来提高集成模型的预测性能。Massaoudi 等人[30]通过 Stacking 集成三个基于 GBDT 算法，构建一种新颖的 Stacking 集成学习模型，提高模型的预测精度。Jiang 等人[31]通过 Stacking 集成径向基函数(Radial Basis Function, RBF)、随机向量函数连接(Random Vector Functional Link, RVFL)和反向传播神经网络(Back Propagation Neural Network, BPNN)模型，采用电力负荷相似日预测方法提高模型的精准度。通过以上文献不难看出，Stacking 技术不仅能够处理数据之间的非线性关系，还能有效地整合来自不同来源但数据之间分布差异小的数据。

然而，尽管深度学习模型和 Stacking 模型在短期电力负荷预测中有效，但它们通常都是在同一用户的数据中进行预测[32]。当涉及不同用户的电力负荷预测时，传统的模型并不能很好地实现高的预测精准度。不同地区的电力负荷数据分布的不一致性，可能缺乏足够的跨域数据来训练模型。针对这些问题，研究人员尝试使用迁移学习的方法解决这个问题，迁移学习的思想是训练一个模型，利用从一个训练任务中获得的知识来辅助另一个域的负荷。Li 等人[33]研究

中国知网 https://www.cnki.net

一种基于迁移学习的跨域电力负荷预测方法，该方法通过引入 AM-CIF-LSTM 模型来克服数据分布不一致的问题。Bai 等人[34]中提出一种深度学习分位数回归模型，将源域训练模型的参数进行迁移，最后对目标域训练模型进行超参数优化，从而提高目标域电力负荷数据的预测精准度。刘世昌等人[35]提出核岭回归的迁移方法，将待预测类型日相似的数据迁移到待预测类型日的数据中。

从以上的国内外对短期电力负荷预测的研究不难看出，目前基于相同用户或者是相同地区的短期电力负荷预测技术已经十分成熟。但面对跨区域或具有不同数据分布特征的负荷预测任务时，这些传统模型的性能往往会受到限制。这主要是因为不同地区的电力使用习惯、经济活动和天气条件等因素的差异可能会极大地影响电力负荷的波动，使得模型难以直接迁移和应用。研究者们正尝试研究一个模型能够精准预测不同数据分布的负荷，并且引入目前各领域都在研究的迁移学习模型，致力于在拥有目标预测用户少量的负荷数据样本下，也能够使用迁移学习技术对目标预测用户进行精准的短期电力负荷预测。

1.3 研究内容与论文结构

本研究致力于利用域自适应技术实现精准的跨区域短期电力负荷预测，为电力系统稳定运行和电力的合理规划提供保障。本文的目标是根据现有区域的历史电力负荷数据和相关特征以及预测目标区域的历史电力负荷数据和相关特征，精准预测目标区域未来一段时间内的电力负荷值。图 1.2 为本文的结构框图，本文每个章节具体内容如下：

第一章为绪论。该章节阐述短期电力负荷预测的研究背景与研究现状。主要通过分析近年来研究者们对传统负荷预测方法的改进以及在电力负荷预测的研究中运用迁移学习的方法改进传统方法，并分析各类研究模型优缺点。

第二章为相关理论介绍。该章节介绍电力系统负荷预测的基本理论，迁移学习的定义，残差网络、极度梯度提升树和 Stacking 算法。

第三章首先介绍研究背景，然后是算法设计，解释域自适应权重矩阵的设计以及定义协方差差异相似性对比度以及损失函数，最后将算法应用于 Electricity Load Diagrams 2011-2014 Dataset 的同一地区三个地点的负荷数据迁移实验，将三个地点的负荷数据互为源域和目标域，验证该算法的性能。

中国知网 https://www.cnki.net

第四章介绍一种基于 Stacking 的残差网络模型来进行短期电力负荷预测。可以在负荷数据样本量更少的情况下，通过变分多核主成分分析对数据进行特征重构。采用佛山工商业用户数据集，设置多组迁移实验，验证多个不同预测模型的精准度和泛化能力，并且在第三章的基础上，增加跨地区电力负荷数据的迁移实验，通过不同的迁移实验来验证提出模型的泛化性。

第五章对全文的所有方法进行回顾总结，分析每个模型的不足之处并且对下一阶段仍需要进行研究的工作进行阐述。

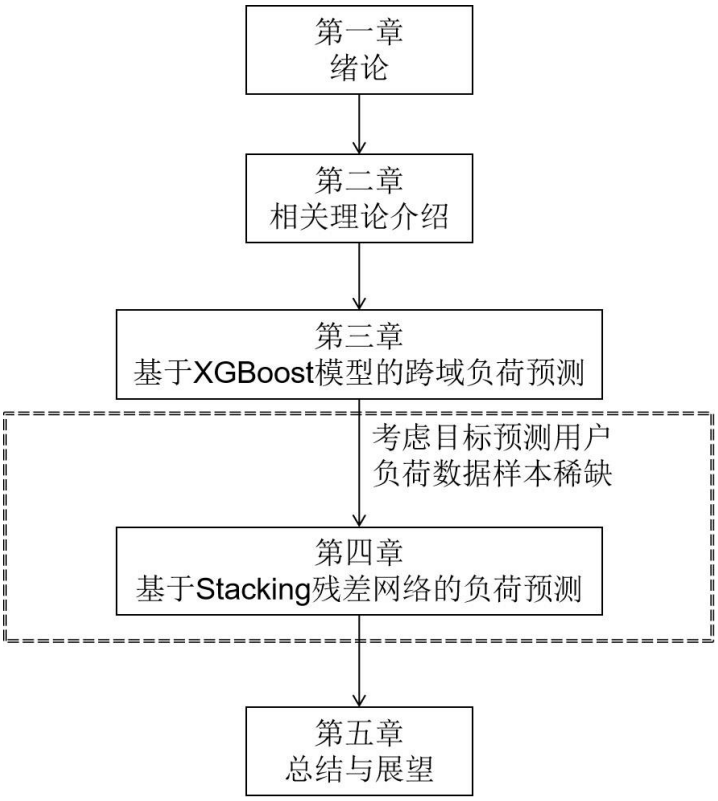


图 **1.2** 本文结构框图

Fig **1.2** Block diagram of this thesis structure

中国知网 https://www.cnki.net

第二章 相关理论介绍

2.1 负荷预测基本理论

电力系统负荷预测的分类是为了更好地适应不同时间跨度的需求，从而更有效地支持电力系统的运行、规划和市场交易。在这一小节中，将详细讨论电力系统负荷预测的分类体系、每个分类的应用场景以及相应的预测方法。

2.1.1 负荷预测的分类

负荷预测的类型如图 2.1 所示，目前负荷预测的类型主要分为三大类：短期负荷预测[36, 37]、中期负荷预测[38, 39]、长期负荷预测[40-42]。

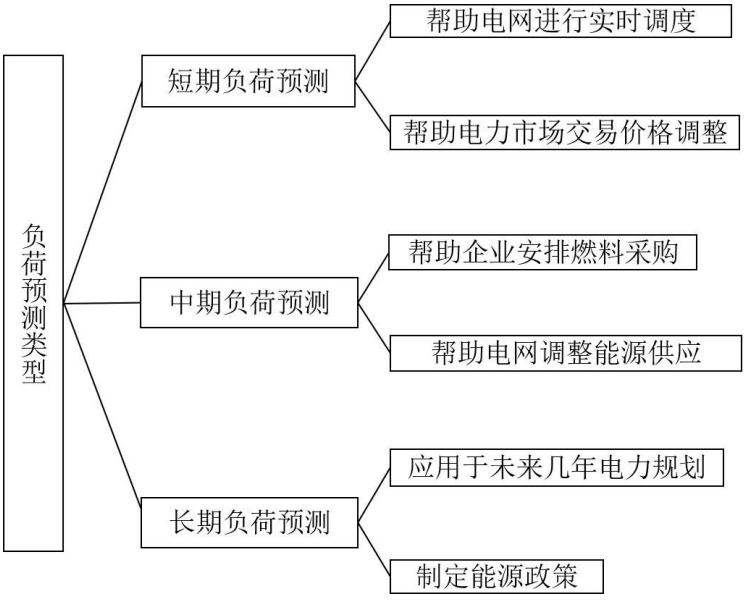


图 **2.1** 负荷预测类型及其作用

Fig **2.1** Load forecasting types and their roles

短期负荷预测是指对未来数小时内电力系统负荷进行准确预测。这个时间范围内的预测对于电力系统的实时调度和运行至关重要。在电力系统的实时运行中，对负荷进行精准预测是确保系统平稳运行的基础。实时调度需要对未来几小时内的负荷波动做出快速而准确地响应，以保障电力供需平衡。短期负荷预测对于电力市场参与者的能源交易决策至关重要。发电商、负荷侧管理者和市场监管机构需要根据负荷预测结果作出相应的能源购买、出售和调整决策，

中国知网 https://www.cnki.net

以优化市场效益。电力设备的运行和维护计划通常需要提前安排，而这些计划的制定又严重依赖于对负荷的准确预测。通过短期负荷预测，能够更好地规划设备的停机维护，最大程度地保障电力系统的可靠性。为实现短期负荷预测，通常采用的方法包括时间序列分析、神经网络模型和支持向量机等。这些方法能够充分考虑负荷的历史数据和即时信息，提高短期负荷预测的准确性。

中期负荷预测涵盖时间跨度从数小时到数天，是在电力系统中用于市场交易和中期规划的重要预测任务。电力市场的规划需要提前数天对负荷进行较为准确的预测，以便制定合理的市场政策和电价机制。中期负荷预测为市场参与者提供决策依据，促使市场更加高效地运行。电力系统中的发电企业需要提前安排燃料采购、发电设备运行等方面的计划。中期负荷预测为发电企业提供未来数天内电力需求的合理估计，有助于优化能源供应计划，提高能源利用效率。中期负荷预测也对电力系统的调度策略产生深远影响。通过提前了解电力负荷的趋势，系统调度员可以更好地安排发电计划、调整输电网络配置，以应对未来数天内可能出现的负荷波动。中期负荷预测方法包括基于统计模型的回归分析、灰色模型、基于机器学习的决策树和随机森林等。这些方法在考虑到中期时间范围内的负荷变化规律时，能够更加准确地预测电力负荷。

长期负荷预测涵盖时间跨度从数天到数年，主要用于电力系统的长期规划和发展。随着新能源的不断发展，电力系统需要制定合理的长期规划来适应未来的能源结构。长期负荷预测为新能源的引入和布局提供决策支持，有助于优化系统的可再生能源利用。长期负荷预测对于电力系统的扩建规划至关重要。通过准确预测未来数年的负荷需求，电力系统规划者可以合理安排新设备的引入和老旧设备的更新，以确保系统的可靠性和经济性。政府和电力主管部门通常需要依据未来负荷的长期趋势来制定相关的能源政策。长期负荷预测为政策制定提供重要的依据，有助于促使电力系统朝着可持续、高效的方向发展。长期负荷预测目前的主流方法包括基于趋势分析的模型、计量经济学模型，以及一些复杂的系统动力学模型。这些方法能够更全面地考虑负荷变化的长期趋势和结构性变化，提高长期负荷预测的准确性。

电力系统负荷预测的分类为不同时间跨度的需求提供解决方案，从短期、中期到长期，每个时间范围都有着独特的应用场景和挑战。各种负荷预测方法

中国知网 https://www.cnki.net

的不断发展和创新为电力系统的运行、规划和市场交易提供更为可靠的技术支持。通过深入了解每种预测方法的原理和适用范围，电力系统运营者和决策者能够更好地应对不同时间跨度的负荷波动，实现电力系统的高效、可靠运行。

2.1.2 负荷特性与误差指标

电力负荷预测模型的精度受到多种因素的影响，而这些因素决定电力负荷的特点。针对这些特点对于选择合适的预测模型分析因素与负荷之间的相关性、提高预测准确性以及有效维护电网的稳定性至关重要。本节将深入分析电力负荷的主要特性，包括非线性[43]、季节性[44]、动态性[45]和异常性[46]等。电力系统负荷预测受到多种不确定性因素的影响,这使得负荷的未来变化难以精确预测。不同的不确定性源涵盖了诸如气象因素、经济发展状况、以及突发事件等多个方面。气象因素，诸如天气急变、降雨、温度波动等，直接影响着负荷的规模和波动。经济发展状况的不确定性包括产业结构的调整、新兴产业的兴起等，这些都会对电力负荷产生重要影响。突发事件，如自然灾害、社会事件等同样是无法预测的因素。这种不确定性使得负荷预测变得更加复杂，因为模型很难捕捉到这些不确定性的变化。因此，负荷预测模型需要具备一定的鲁棒性和适应性，能够应对各种突发情况，以确保在不同情景下的准确性和稳定性。

电力系统负荷预测通常表现出明显的非线性特性。传统的线性模型在捕捉负荷变化的复杂规律上存在一定的局限性。电力负荷受到多种因素的共同作用，而这些因素之间的关系可能是非线性的，例如，温度对负荷的影响可能是非线性的。因此，为更好地适应实际情况，负荷预测模型需要具备一定的非线性建模能力。非线性特性使得模型的选择和参数调整更为复杂，需要采用一些先进的非线性建模技术[47]，如神经网络、支持向量机等。这些方法能够更灵活地捕捉复杂的负荷变化规律，提高模型的预测准确性。电力负荷在不同季节表现出明显的周期性变化。季节性变化与气象因素、节假日、生产活动等密切相关。例如，在冬季，人们常常开暖气使得用电负荷增加，而在夏季人们开冷气也会导致用电负荷则相应增加。在一些国家，节假日对负荷的影响也是明显的，例如，我国春节期间家庭用电增加，而工业负荷相对减少。季节性的存在增加电力负荷预测的难度。传统的预测方法难以很好地捕捉到这种周期性的变化，因

中国知网 https://www.cnki.net

此需要采用一些专门针对季节性的电力负荷预测模型或者引入季节性因素进行调整，以提高负荷预测的准确性。电力系统的负荷是一个动态过程，受到多方面因素的不断变化影响。市场结构的调整、新技术的引入、政策法规的变化都会对电力负荷产生影响。这种动态性使得电力负荷预测不仅需要考虑历史数据和当前状态，还需要不断更新模型，及时反映系统变化。动态性也表现在负荷的快速波动上，尤其是在短期电力负荷预测中。例如，遇到突发事件、大型工业设备的启停等都可能导致电力负荷的瞬时变化。电力系统中负荷数据通常呈现出异常性，即在不同时间点或不同环境下，数据的特性会发生变化。这对电力负荷预测提出更高的要求，需要模型能够适应数据的异常性。异常性可能来源于多个方面，包括季节性的变化、经济结构的调整、能源政策的变革等。数据异常性使得建模变得更为复杂，需要采用一些能够灵活调整的方法。传统的预测模型在处理异常数据上存在一定的局限性，因此，需要结合先进的模型和数据处理技术，更好地适应电力系统中电力负荷数据的异常性。

针对电力负荷的非线性特点，引入先进的非线性模型是提高电力预测准确性的关键之一。神经网络、支持向量机等模型能够更灵活地捕捉负荷变化的复杂规律，适应不同的非线性关系，从而提高负荷预测的精度。在负荷预测中，既可以考虑基于物理的模型，又可以结合数据驱动的模型。物理模型能够更好地理解系统的运行机理，而数据驱动模型能够更灵活地适应负荷的变化。将这两种模型结合起来，能够充分发挥各自的优势，提高负荷预测的综合性能。对于季节性的特点，可以通过引入季节性因素来改善预测效果。这可以包括温度、节假日、工业生产计划等因素。同时，在面对一些不可抗力事件时，也需要将这类因素考虑进去，以提高模型对于不确定性因素的适应能力。考虑到电力系统的动态性，引入实时数据是提高预测准确性的一种有效方法。实时数据能够反映系统当前的状态，为模型提供及时的信息，比如发电量、传输损失和天气状况。同时，可以采用自适应的模型参数，及时调整模型以适应系统的动态变化，提高模型的实时性和鲁棒性。在处理和分析电力负荷数据时，面对数据的异常性不仅是一个挑战，也是提高预测准确性和系统稳定性的重要机会。通常情况下，电力负荷受到多种因素的影响，包括气候变化、社会经济活动、人口动态等。因此，仅仅依靠历史电力负荷数据进行预测和分析，往往无法准确捕

中国知网 https://www.cnki.net

捉到这些复杂因素的变化。为了提高模型的适应性和预测的准确性，综合分析多方面的数据成为了一种必要的策略。

电力负荷的特性使得电力负荷预测任务变得极为复杂，需要充分考虑非线性、季节性、周期性、动态性以及数据异常性等因素。这些特点有助于选择合适的模型和方法，提高负荷预测的准确性和可靠性。随着科技的不断发展，对于电力系统负荷预测特点的理解将不断深化，新的预测方法和模型也将不断涌现，为电力系统的稳定运行和可持续发展提供更好的支持。

电力系统负荷预测的准确性是评估模型性能的关键指标之一。为量化模型预测与实际观测之间的差异，本文使用误差分析指标衡量模型的可靠性。这一节将深入探讨电力系统负荷预测中常用的误差分析指标，包括均方根误差[48-50](Root Mean Square Error, RMSE)和平均绝对误差[51-53](Mean Absolute Error, MAE)等。这些指标不仅能够量化模型预测的准确性，还能帮助我们更好地理解预测结果与实际观测之间的偏差，为电力系统的运行和规划提供重要参考。

RMSE 是一种广泛应用于负荷预测误差分析的指标，它计算预测值与实际观测值之间的差异的平方平均值。具体计算公式如式(2.1)：

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2} \tag{2.1}$$

其中，n表示样本数量，Y_i是实际观测值，$\hat{Y}_i$是相应的预测值。RMSE 的计算方法使得较大的误差对整体误差的贡献更为显著，因此，它更加关注对预测中大误差的敏感性。RMSE 的优点在于对预测误差的较大值更为敏感，但缺点在于平方运算可能放大异常值的影响，使得对异常值过于敏感。

MAE 是另一种广泛应用于误差分析的指标，它计算预测值与实际观测值之间的绝对差异的平均值。计算公式如式(2.2)：

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|Y_i - \hat{Y}_i| \tag{2.2}$$

MAE 对异常值不敏感，因为它是通过绝对值计算误差，而不是平方。这使得 MAE 在处理潜在的异常值或离群点时更为稳健。然而，由于没有平方项的缓冲效应，MAE 可能无法捕捉到误差的分布特性。因此 MAE 更适合对误差的整体分布情况进行评估，特别是在考虑到模型应对异常值的能力时。

决定系数[54, 55](Coefficient of determination, R-squared)是一种用于评估模型

中国知网 https://www.cnki.net

对实际观测值变异的解释能力的指标，通常用 R^2 表示。计算公式如式(2.3)：

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} \tag{2.3}$$

其中，$\bar{Y}$ 是实际观测值的平均值。

决定系数的取值范围在 0 到 1 之间，越接近 1 表示模型对观测值的变异解释能力越强。当 R^2 接近 1 时，说明模型的拟合效果良好；而当 R^2 接近 0 时，说明模型无法解释观测值的变异，拟合效果差。

平均绝对误差[56-58](Mean Absolute Percentage Error, MAPE)是另一种广泛应用于误差分析的指标，它基于 MAE 的计算，但在预测值与实际观测值之间取二者的绝对差异的平均值。计算公式如式(2.4)：

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{\hat{Y}_i - Y_i}{\hat{Y}_i}\right| \tag{2.4}$$

MAPE 对异常值不敏感，因为它是通过绝对值计算误差，而不是平方。这使得 MAPE 在处理潜在的异常值或离群点时更加稳健。然而，由于没有平方项的缓冲效应，MAPE 可能无法捕捉到误差的分布特性。

在实际应用中，通常需要综合考虑多个误差分析指标，以全面评估负荷预测模型的性能。不同的指标关注不同方面的模型表现，因此，模型比较与选择应该根据具体需求和应用场景来确定。一种常用的方法是通过交叉验证，将模型在不同时间段内的预测性能进行比较。同时，通过对不同误差指标的综合考虑，可以制定合理的权衡策略，确保选取的模型在多个方面都具有良好的性能。

误差分析指标是评估电力系统负荷预测模型性能的关键工具。不同的指标在衡量模型的不同方面性能上具有各自的优势和局限性。在实际应用中，选择合适的误差分析指标以及综合考虑多个指标的综合评估，有助于找到最适合具体应用场景的负荷预测模型。深入理解这些误差分析指标的计算原理和应用场景，将有助于提高电力系统负荷预测的准确性和稳定性。

中国知网 https://www.cnki.net

2.2 迁移学习

2.2.1 迁移学习定义

迁移学习[59](Transfer Learning, TL)是机器学习领域的一个重要研究方向，它的核心思想在于利用已有的知识来解决新的、但与已知问题相关或类似的问题。在面对新情境时，人类往往能够利用之前的经验和知识来更快地学习和适应。这种学习和适应能力在机器学习领域被视为一种高度值得追求的目标，因为它能够显著提高算法的泛化能力和应用的灵活性。在传统的机器学习方法中，模型的训练通常是针对特定的任务、在特定的数据分布下进行的。这种方法建立在一个基本假设之上：训练数据和测试数据遵循相同的分布。然而，这一假设在现实世界中往往难以成立，特别是当应用场景跨越不同领域时。例如，在股票价格预测和电力负荷预测中，尽管两者在形式上截然不同，但在数据处理和特征识别的方法论上却可能有着相似之处。因此，如何有效地利用一个领域中的知识来帮助另一个领域的学习成为一个迫切需要解决的问题，而迁移学习正是为解决这一问题而生。通过引入源域(Source Domain, SD)中的知识，迁移学习旨在增强目标域(Target Domain, TD)中的学习过程，从而突破传统机器学习方法的限制。具体而言，迁移学习的过程涉及识别源域和目标域之间的共性和差异，以及如何有效地将知识从源域迁移到目标域中。这一过程不仅需要算法能够识别两个领域中的相关性，还需要有能力调整和优化迁移的知识，使其在新的领域中尽可能发挥作用。迁移学习的动机不仅来源于其在技术层面的创新和应用价值，更深层次地，它受到人类学习机制的启发。在人类的学习过程中，通过将以往经验中获得的知识应用到新的、类似的情境中，人们能够更快地学习新技能，解决新问题。例如，一个学过钢琴的人在学习其他键盘乐器时会更加容易，因为他们能够利用对键盘布局、音乐理论等方面的已有知识。这种跨领域的学习能力展示知识迁移的潜力，模仿这种人类的学习方式，迁移学习试图在机器学习模型中实现相似的知识迁移能力。这种方法不仅可以提高学习效率，减少对大量标注数据的依赖，还能提升模型面对未知数据时的鲁棒性。在实际应用中，迁移学习已经展示出其广泛的潜力，从图像识别、自然语言处理到强化学习等多个领域，都有迁移学习的成功应用案例。

中国知网 https://www.cnki.net

实现迁移学习的技术方法多样，这些方法包括但不限于基于模型的迁移、基于实例的迁移和基于特征的迁移。这些技术手段各有其优势和特定的应用场景，共同的目标是通过有效利用已有的知识，以减少模型在新领域训练时对数据的需求，从而提高模型的泛化能力。基于模型的迁移学习方法尝试直接调整源域中的模型参数，以使其能够适应目标域。这种方法通常涉及预训练和微调两个步骤。在预训练阶段，模型在源域的大规模数据集上进行训练，学习到一般性的特征或模式。随后，在微调阶段，模型参数会根据目标域的数据进行细微调整。这种方法的关键在于找到一种有效的方式，让在源域学习到的知识能够在目标域中发挥作用，同时避免过拟合到源域的特异性。基于模型的迁移学习在深度学习中尤为常见，例如，在图像识别任务中，通过在大型图像数据集上预训练的 CNN 可以被用来加速小数据集上的学习任务。这种方法允许模型利用在大规模数据集上学到的丰富视觉特征，加快并优化小规模数据集上的学习过程。基于实例的迁移学习涉及在源域和目标域之间选择性地迁移数据样本。这种方法的核心思想是识别源域中哪些数据样本对于目标任务最为相关和有用，然后将这些数据样本直接用于目标域的学习过程。这样做的挑战在于如何衡量不同领域之间数据样本的相关性，并有效地选择有助于目标任务的样本。实现基于实例的迁移学习通常需要一些策略来评估和选择样本，如加权策略，其中对于源域中的每个样本根据其对目标任务的相关性赋予不同的权重。这要求算法能够理解两个领域的内在联系，并能够评估不同领域数据之间的相似度。基于特征的迁移学习着重于发现和利用源域和目标域之间的共享特征空间。这种方法的关键在于找到一种表示方式，使得来自不同领域的数据能够在同一特征空间内被有效表示和处理。通过这样做，即便源域和目标域的数据分布有所不同，模型也能够通过学习到的通用特征表示来提高在目标域上的性能。实现基于特征的迁移学习通常涉及特征提取和特征转换两个步骤。特征提取旨在从源域和目标域的数据中提取有意义的特征，而特征转换则关注于将这些特征映射到一个共享的特征空间中。这要求算法不仅要能够识别出两个领域之间的相似性，还要能够克服它们之间的差异。

在电力负荷预测的场景中，迁移学习尤为重要。由于电力负荷数据受到多种因素的影响，例如季节变化、气候条件、用户行为习惯等，这些因素在不同

中国知网 https://www.cnki.net

地区可能表现出不同的特征和模式。通过迁移学习，可以利用某一地区的历史负荷数据来辅助其他地区或相似场景下的负荷预测，从而提高预测的准确性和鲁棒性。此外，迁移学习在处理电力系统的非平稳性方面也显示出独特优势。电力系统的动态变化要求模型能够适应新的数据分布，而传统机器学习方法在这一点上往往力不从心。迁移学习通过从相关领域的数据中学习来弥补这一不足，使得模型更加灵活地适应电力负荷的动态变化。为实现有效的迁移学习，需要解决几个关键问题。首先，如何选择和处理源域数据，以确保其与目标任务相关性高，且有助于目标任务的学习；其次，如何设计迁移学习算法以最大化从源域到目标域的知识转移；最后，如何评估迁移学习在新任务上的效果。这些问题构成迁移学习研究的核心内容，也是本研究将深入探讨的重点。

综上所述，迁移学习作为一种强大的机器学习方法，对于短期电力负荷预测方法的研究和应用具有重要意义。通过迁移跨域的知识，能够构建更加智能、高效的预测模型，从而更好地应对电力系统的复杂性和动态性。

2.2.2 域自适应

域自适应(Domain Adaptation，DA)在电力系统的短期负荷预测中，由于电力负荷数据受多种因素的影响，如季节变化、天气条件、用户行为习惯等，使得不同时间段或不同地区的电力负荷特性可能大相径庭。因此，利用域自适应技术进行负荷预测，可以提高模型在面对不同电力系统状态时的适应性和准确性。在域自适应中，假设源域和目标域具有相似的特征空间，但它们的边缘概率分布存在差异。这意味着源域的数据和目标域的数据在特征空间中可能具有相似的分布，但在标签空间中可能存在较大的差异。

域自适应方法通常包括两个关键步骤：特征对齐(Feature Alignment)和模型微调(Model Fine-tuning)。选择源域和目标域中具有相似分布的特征，以便在迁移学习过程中保留有用的信息，同时去除那些可能会引入偏差的不相关特征。然后进行特征对齐，其旨在减少源域和目标域在特征空间上的分布差异。通过特征对齐，使用算法尝试找到一个共同的特征表示，使得同样的模型能够同时适用于源域和目标域的数据。域自适应的模型微调是通过对源域和目标域的数据进行适应，使得目标域中的数据分布更接近于源域中的数据分布，从而提高

中国知网 https://www.cnki.net

目标域的学习性能。这是因为当模型在源域上训练得到的知识能够更好地适应目标域时，模型在目标域上的表现通常会得到改善。目前的研究中常用的域自适应方法包括最大均值差异[60](Maximum Mean Discrepancy, MMD)以及领域对抗神经网络[61](Domain Adversarial Neural Network, DANN)。这些方法通过最小化源域和目标域之间的距离或最大化它们之间的差异，使得目标域中的数据分布更接近于源域中的数据分布。通过这样的处理，可以提高目标域的学习性能。

2.3 预测模型介绍

2.3.1 残差网络

残差网络[62](Residual Network, ResNet)是一种深度学习模型，它在图像识别任务中取得显著的成果。在短期电力负荷预测中，ResNet 也被广泛应用于提高预测性能。在传统的深度神经网络中，随着网络层的加深，信息在传递过程中会逐渐丢失，导致网络性能下降[63]。而 ResNet 通过引入直接连接前后层的跳跃连接，使得网络可以学习到残差函数，即目标映射与输入之间的差异。这种结构不仅有助于信息的传播，也使得网络可以通过反向传播更有效地训练。

ResNet 的基本单元是残差块(Residual Block)，它由两个卷积层和一个跳跃连接组成。跳跃连接将输入直接添加到残差块的输出中，形成残差连接。通过残差连接，网络可以学习到残差函数，从而更好地适应数据的特征。

具体地，残差学习块的功能可以表示为一个映射 $H(x)$，它通过将输入 x 传递给一个加权的非线性变换来增强特征 $H_i(x)=\sigma(W_i x+b_i)$，这个映射将会学习到输入和输出之间的残差函数 $F(x)=H(x)-x$。

为实现这种残差学习，每个残差学习块还包括一个跳过连接，它允许输入 x 直接与映射的输出相加，如式(2.5)：

$$x_{i+1}=H_i(x_i)+x_i \tag{2.5}$$

其中 x_i 和 x_{i+1} 分别代表第 i 个和 $i+1$ 个残差块的输入和输出。

将 ResNet 用于短期电力负荷预测步骤如下：

中国知网 https://www.cnki.net

步骤 1：输入层输入数据。将电力负荷数据标准化后作为输入层的输入；

步骤 2：构造残差块。残差块构造如图 2.2 所示。在构建残差块时，针对每个样本 (x_{si}, y_{si}) 的残差可以表示为式(2.6)：

$$r_i = \sigma(BN(W_{i,2} * \sigma(BN(W_{i,1} * x_{si} + b_{i,1})) + b_{i,2})) \tag{2.6}$$

其中 $W_{i,j}$ 对应的是权重，$b_{i,j}$ 对应的是偏差，用于调整 x_{si} 的特征表示，BN 是对应的批次归一化处理，减少内部协变量偏移，保持每层的输入分布相对稳定；

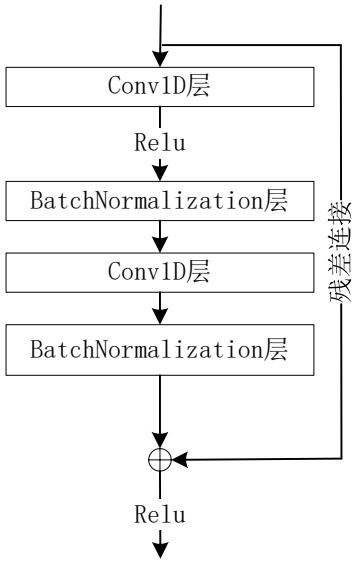


图 **2.2** 残差块构造

Fig **2.2** Residual block construction

步骤 3：残差连接。采用跳过连接将 r_i 与输入 x_{si} 直接相加，得到式(2.7)，这种方法在层间连接中添加直接的路径，减少训练过程中梯度消失的情况。

$$x_{si+1} = r_i + x_{si} \tag{2.7}$$

在短期电力负荷预测中，ResNet 可以应用于迁移学习中，通过将已经学习到的知识从源域迁移到目标域，提高目标域的学习性能。ResNet 在迁移学习中的应用可以分为两个方面：特征提取和域自适应。ResNet 可以作为特征提取器，从源域和目标域的数据中提取有用的特征。通过在源域上预训练 ResNet，可以获得具有丰富特征表示能力的模型。然后，可以将这个预训练的网络应用于目标域的数据，提取目标域中的特征。这样可以减少目标域上的训练样本数量，同时利用源域的知识来提高目标域的学习性能。ResNet 可以通过域自适应方法

中国知网 https://www.cnki.net

来减小源域和目标域之间的数据分布差异。

总的来说，ResNet 在短期电力负荷预测中的应用可以通过作为特征提取器和域自适应方法来实现。通过在源域上预训练深度 ResNet，可以获得具有丰富特征表示能力的模型，并将其应用于目标域的数据中，提取目标域的特征，可以减小源域和目标域之间的数据分布差异，提高目标域的学习性能。

2.3.2 极端梯度提升树

极端梯度提升树[64](Extreme Gradient Boosting，XGBoost)是一种高效的机器学习算法，它在许多领域都取得显著的成功。在短期电力负荷预测中，XGBoost 也被广泛应用于提高预测性能。XGBoost 是一种基于决策树的集成学习算法，它通过构建多个决策树并将它们组合起来进行预测。不同于传统的决策树算法，XGBoost 在构建每一个树模型时都会考虑到之前树模型的错误，从而在迭代过程中逐步减少预测误差。XGBoost 引入正则化项来控制模型的复杂度，防止过拟合，并通过特征子采样和列抽样等技术来降低模型方差，提高泛化能力。这种梯度提升策略每轮迭代都是在拟合前一轮模型的残差，从而不断更新模型参数。XGBoost 优化目标函数(Obj)的核心思想是最小化由损失函数和正则化项两部分构成的目标函数，如式(2.8)，损失函数评估预测误差，正则化项控制模型复杂度，避免模型产生过拟合。

$$Obj = \sum_{i=1}^{n} L(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k) \tag{2.8}$$

其中，L 是损失函数，y_i 是样本的实际值，$\hat{y}_i$ 是预测值，f_k 是第 k 棵树，K 是树的总数，Ω 是正则化项。对损失函数进行二阶泰勒展开，得到式(2.9)：

$$Obj_{Taylor}^{(t)} \approx \sum_{i=1}^{n}\left[L(y_i, \hat{y}_i^{(t-1)}) + g_i f_k(x_i;\theta_k) + \frac{1}{2} h_i f_k^2(x_i;\theta_k) \right] + \sum_{k=1}^{K} \Omega(f_k) \tag{2.9}$$

简化泰勒展开后的目标函数为式(2.10)：

$$Obj_{Taylor}^{(t)} = \sum_{i=1}^{n}\left[g_i f_k(x_i;\theta_k) + \frac{1}{2} h_i f_k^2(x_i;\theta_k) \right] + \Omega(f_k) + C \tag{2.10}$$

其中，g_i 和 h_i 分别是样本 i 的一阶和二阶导数，$f_k(x_i;\theta_k)$ 是第 k 棵树对样本 i 的预测值，θ_k 是树的结构参数，C 是常数。

中国知网 https://www.cnki.net

2.3.3 Stacking 融合算法

Stacking[65]是一种集成学习算法，通过结合多个基学习器[66]的预测结果来构建一个更为强大和精准的预测模型，近年来在机器学习领域内受到广泛的关注和研究。这种方法的核心优势在于它能够通过融合不同模型的独特视角和优势，达到单一模型难以实现的预测准确性和稳定性。Stacking 算法的实现分为两个主要的步骤：基学习器的训练和元学习器[67]的构建。Stacking 算法的第一步是训练多个基学习器。这些基学习器可以采用不同的机器学习算法，比如决策树、随机森林和神经网络等。原始的训练数据集会被划分为多个子集训练基学习器，每个基学习器在其对应的数据子集上进行训练。这种数据分割可以是随机的，也可以是基于特定策略的，旨在确保每个基学习器都能从不同角度学习数据的特性，增加模型间的多样性。通过这种方式，每个基学习器都会生成一组预测结果。这些预测结果反映每个模型对数据的理解和预测能力。尽管单个模型的预测可能存在偏差或不足，但当这些模型集成在一起时，它们的综合预测能力往往能够实现显著的提升。Stacking 算法的第二步涉及元学习器的构建。元学习器的任务是学习如何最有效地结合基学习器的预测结果。在这个过程中，基学习器的预测结果被用作元学习器的输入特征。元学习器本身可以是任何一种机器学习算法，从简单的线性回归到复杂的神经网络都可以。选择何种算法作为元学习器取决于问题本身的复杂度以及预测任务的具体要求。

元学习器的训练过程是一个优化过程，旨在找到最佳的方法来融合不同基学习器的预测结果。通过学习每个基学习器的预测强项和弱点，元学习器能够赋予更准确的基学习器更高的权重，而对于那些预测表现不佳的模型则给予较低的权重。这种权重分配机制使得 Stacking 算法能够自适应地优化组合预测，从而产生比任何单一基学习器都要强大的综合预测性能。Stacking 的关键优势在于其能够综合不同模型的优点，弥补单个模型的不足[68]。不同的基学习器可能对数据的不同方面具有不同的预测能力和偏好，通过结合这些模型的预测结果，Stacking 能够提供更全面和准确的预测。此外，由于包含多个独立模型的预测，Stacking 通常也能提供更高的模型鲁棒性，即对新数据或噪声数据的抵抗能力。Stacking 算法已经被成功应用于许多机器学习任务中，包括但不限于回归分析、分类问题、自然语言处理和图像识别等。它能够在竞赛和实际应用

中国知网 https://www.cnki.net

中实现优异的性能，尤其是在数据集复杂且任务要求高度准确性的场合。然而，Stacking 也面临着一些挑战，其中最主要的是模型的复杂性和计算成本。由于需要训练多个基学习器以及一个元学习器，Stacking 算法的训练过程可能会比单个模型的训练更为复杂和时间消耗更大。此外，选择合适的基学习器和元学习器，以及合理地设置它们的参数也是实现高效 Stacking 的关键。

总体而言，尽管存在一些挑战，Stacking 算法凭借其强大的预测能力和灵活的适应性，在机器学习领域内占有重要地位。随着算法优化技术的不断进步和计算资源的日益丰富，Stacking 及其变体将继续在众多领域中发挥重要作用，推动机器学习技术的发展和应用。

2.4 本章小结

本章深入探讨基于域自适应的短期电力负荷预测方法的关键技术和应用。介绍迁移学习的定义和动机，强调其在电力负荷预测中的重要性。迁移学习的核心在于利用已有知识来解决新的、相关的问题，特别是在不同地区或不同情境下的电力负荷预测。这一方法能够显著提高预测的准确性和鲁棒性。讨论域自适应的概念和在电力负荷预测中的应用。域自适应通过调整源域和目标域数据的分布差异，增强模型在不同环境下的适应性和准确性。

本章介绍 ResNet 的原理和在迁移学习中的应用。ResNet 通过残差学习解决深度模型训练中的关键问题，并且在特征提取和域自适应方面表现出色，从而提高短期电力负荷预测的性能。同时阐述 XGBoost 的原理，XGBoost 作为一种高效的集成学习算法，XGBoost 在处理复杂数据时表现出强大的能力。最后讨论 Stacking 融合算法的原理，这种方法能够有效地整合不同模型的优点，结合多个不同模型的预测结果来提高总体预测准确性。

综上所述，这些方法和技术的融合为短期电力负荷预测提供一种全面且有效的解决方案。通过深入研究迁移学习、域自适应、ResNet、XGBoost 和 Stacking 融合算法，本研究不仅提高预测模型的性能，而且增强模型在不同环境下的适应能力和稳定性，为电力系统的运行和调度提供有力的支持。

中国知网 https://www.cnki.net

第三章 基于 XGBoost 模型的跨域负荷预测

3.1 基本思想

传统的短期电力负荷预测方法常常受到两个前提的约束：1)需要收集大量完整的历史电力负荷数据；2)训练数据和测试数据必须来自相同的概率分布。

然而，在现实的电力系统中，同时满足这两个条件很困难。因为大部分时间电力系统处于正常状态，且如果电力系统发生故障，故障时刻的电力负荷的数据会缺失，在需要预测的时候，这部分数据是需要人为填充。此外，电力供应从正常状态到发生故障的时间相对较长，导致填充的电力系统故障时的负荷数据非常困难。为解决这个问题，迁移学习可以利用从源域学习到的知识应用于目标域，即目标域遇到电力负荷数据缺失时，可以在源域学习负荷预测知识从而填充这部分缺失数据。因此，本章提出一种基于 XGBoost 模型和域自适应权重矩的短期电力负荷预测方法。该方法首先使用 XGBoost 作为基本的预测模型，首先通过计算源域和目标域的历史电力负荷数据协方差，提取多层特征。为估计源域和目标域之间的边际分布差异，所提出的模型利用域自适应权重矩阵计算来最小化边际分布差异，从而调整 XGBoost 模型的参数，使其学习到更具鲁棒性的特征表示。最后，通过在中进行多个对比实验，验证所提方法的有效性。因此，本章所提方法的主要贡献有以下几个方面：

1)本章提出一种新的基于域自适应的短期电力负荷预测方法，有效缓解不同区域电力负荷数据分布差异的迁移问题。该方法首先通过构建 XGBoost 模型从电力负荷数据中提取特征，随后利用域自适应权重矩阵计算源域与目标域的域间权重，将权重加到目标域模型中，提升模型的性能；

2)本章构建一种可微分损失函数来计算域自适应权重矩阵，以最小化跨域学习特征的协方差差异相似性对比度。这种方法能够有效地调整模型在目标域的权重，提升模型在目标域上的预测性能。

中国知网 https://www.cnki.net

3.2 算法设计

3.2.1 域自适应权重矩阵

为解决源域和目标域之间的分布差异问题，本章采用域自适应技术来调整模型对目标域的分布差异。通过对源域和目标域数据进行特征对齐和表示变换，使得模型在目标域的表现更好，提高模型在实际应用中的泛化能力。

本章提出域自适应权重矩阵(Domain Adaptive Weight Matrix , DAWM)。在迁移学习中，通常划分有两个域，源域 S 和目标域 T，每个域有 n 个样本，每个样本有 d 个特征。可以用 X_S 和 X_T 表示两个域的特征矩阵，它们的维度都是 $n \times d$。本章的目标是找到一个 DAWM 的权重 W，其维度为 $d \times d$，它能够将源域的特征映射到目标域的特征空间，即 $X_S W \approx X_T$。

3.2.2 协方差差异相似对比度

本章提出的协方差差异相似对比度(Covariance Difference Similarity Contrast, CDSC)是一种衡量源域和目标域之间的差异性的指标，它基于源域和目标域的协方差矩阵的相似性。协方差矩阵是一个描述特征之间线性关系的矩阵，它的维度是 $d \times d$。采用 C_S 和 C_T 表示两个域的协方差矩阵，它们的计算公式分别为式(3.1)和式(3.2)：

$$C_S = \frac{1}{n-1}(X_S - \bar{X}_S)^T (X_S - \bar{X}_S) \tag{3.1}$$

$$C_T = \frac{1}{n-1}(X_T - \bar{X}_T)^T (X_T - \bar{X}_T) \tag{3.2}$$

其中，$\bar{X}_S$ 和 $\bar{X}_T$ 分别是两个域的特征均值向量，它们的维度都是 1×d。可以用不同的方法来度量两个协方差矩阵的相似性，例如 Frobenius 范数、核范数、迹范数等。本章选择用 Frobenius 范数，它的定义如式(3.3)：

$$\| A \|_F = \sqrt{\sum_{i=1}^{d} \sum_{j=1}^{d} a_{ij}^2} \tag{3.3}$$

其中，A 是一个 $d \times d$ 的矩阵，a_{ij} 是它的第 i 行 j 第列的元素。Frobenius 范数可以衡量矩阵的大小，它越小，说明矩阵越接近零矩阵。因此，可以用两个

中国知网 https://www.cnki.net

域的协方差矩阵之差的 Frobenius 范数来定义 CDSC，如式(3.4)所示：

$$\mathrm{CDSC}(X_S, X_T) = \| C_S - C_T \|_F \tag{3.4}$$

CDSC 越小，说明两个域的协方差矩阵越相似，即两个域的特征之间的线性关系越接近。最后，将损失函数定义为 CDSC 的平方，这是一个可微分损失函数，目的是优化 DAWM 的权重W，使得 CDSC 最小化。如式(3.5)所示：

$$L(w) = \mathrm{CDSC}(X_S W, X_T)^2 \tag{3.5}$$

这个损失函数是关于W的二次函数，它是可微分的，所以本章采用梯度下降法来求解它的最小值。为避免过拟合或欠拟合，需要在损失函数中加入一个 L2 范数作为正则化项，来控制W的复杂度，那么式(3.5)可以改写为式(3.6)：

$$L(w) = \mathrm{CDSC}(X_S W, X_T)^2 + \lambda \| w \|_2^2 \tag{3.6}$$

其中，λ是一个正则化系数，它可以用交叉验证法来确定。本章设计的可微分损失函数式(3.6)，用来计算域自适应权重矩阵，以最小化跨域短期电力负荷预测学习特征的协方差差异相似性对比度。

DAWM 中的每个元素具体表示源域样本与目标域样本之间的相对权重，这一权重用于在模型训练过程中调整对目标域特征表示的重视程度。具体来说，这种权重调整机制允许模型在训练过程中通过增加或减少特定样本的影响力，来更好地适应目标域的数据分布。将 DAWM 应用于 XGBoost 模型的训练过程中，可以有效地减少源域与目标域之间的分布差异。XGBoost 作为一种高效的梯度提升树模型，其主要优势在于能够处理非线性关系和复杂的数据结构。当我们通过调整目标域样本在训练过程中的权重，实际上是在优化模型对于目标域数据的拟合程度，使得模型能够更精准地捕捉到目标域的数据特性和模式。本章将基于 DAWM 优化的 XGBoost 的方法称为 DA-XGBoost。图 3.1 中展示的 DA-XGBoost 模型结构，通过引入域自适应权重矩阵作为调整因子，进一步增强模型在面对不同数据分布时的适应性和鲁棒性。这种结构不仅继承 XGBoost 高效的数据处理能力，同时通过 DAWM，使得模型在进行跨域学习时能够有效减轻源域与目标域之间的差异带来的负面影响。

中国知网 https://www.cnki.net

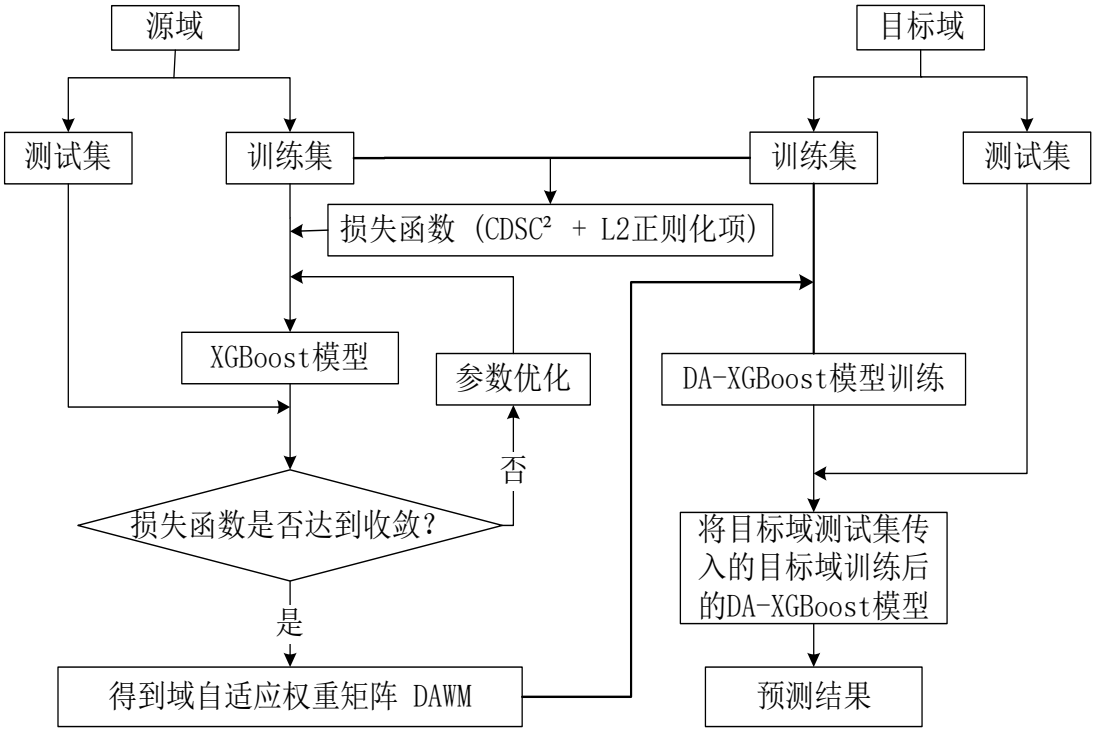


图 **3.1** DA-XGBoost 模型结构

Fig **3.1** DA-XGBoost model structure

3.3 电力负荷数据处理

3.3.1 原始电力负荷数据

本章的实验使用 Electricity Load Diagrams 2011-2014 Dataset 数据集，该数据集在 UCI 机器学习存储库中共享。该数据集涵盖从 2011 年初到 2014 年底的电力负荷数据，采样周期为 15min，数据完整，无需填充。本文选择研究区域为 MT_221，利用日最大负荷相似日[31]的原理，将 MT_221 的每月前 7 日的日最大用电负荷与数据集的其他站点的数据相比较，得出了较为相近的 MT_244 和 MT_272 的数据。图 3.2 展示本次实验的 3 个站点(MT_221，MT_244 和 MT_272)2014 年某天的历史负荷曲线，不难看出每个站点的数据分布各不相同。

中国知网 https://www.cnki.net

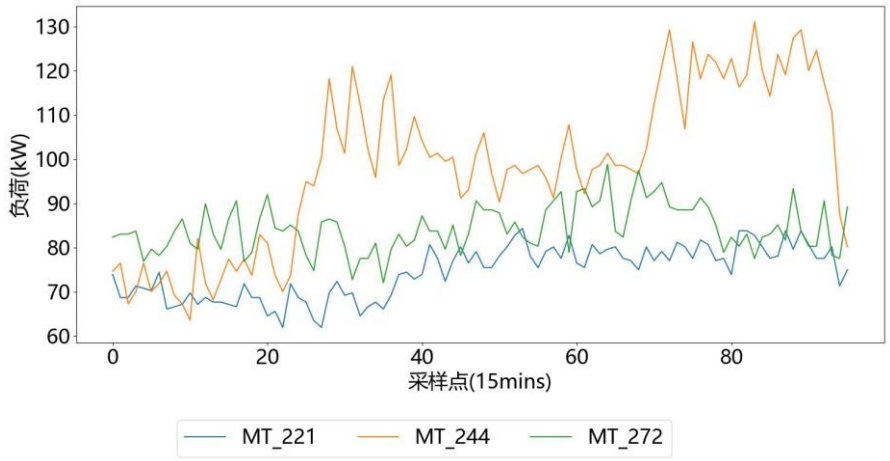


图 **3.2** 三个站点 2014 年某天历史负荷曲线

Fig **3.2** Historical load curves of the three stations on one day in 2014

3.3.2 电力负荷数据特征集

在处理时间序列数据，如电力负荷数据时，特征工程是提高预测模型性能的关键步骤。本节将详细介绍本章对数据集时间特征、季节特征、节假日特征的构建。本章标记 0，1，2 分别代表非早晚高峰、早高峰、晚高峰。设 H 为小时，则小时的分段特征可表示为式(3.7)：

$$\text{TimeSlot}(H)=\begin{cases}1 & \text{if } 7\le H<9\\ 2 & \text{if } 17\le H<19\\ 0 & \text{其他}\end{cases} \tag{3.7}$$

季节特征捕捉数据随季节变化的周期性规律。季节变化会影响电力负荷，如冬季取暖开暖气和夏季制冷开冷气的需求。本章标记 0，1，2，3 分别代表当前日期属于春季、夏季、秋季、冬季。设 M 为月份，则季节特征可表示为式(3.8)：

$$\text{Season}(M)=\begin{cases}0 & \text{if } 3\le M<6\\ 1 & \text{if } 6\le M<9\\ 2 & \text{if } 9\le M<12\\ 3 & \text{其他}\end{cases} \tag{3.8}$$

节假日对电力负荷有显著影响。例如，假日可能导致家庭电力使用增加，而工业用电减少。本章考虑到节假日因素，标记节假日为 1，非节假日为 0。设 D 为日期， H 为节假日集合，则节假日特征可表示为式(3.9)：

$$\text{Holiday}(D)=\begin{cases}1 & \text{if } D\in H\\ 0 & \text{其他}\end{cases} \tag{3.9}$$

中国知网 https://www.cnki.net

最后电力负荷数据的数据特征集的构建如表 3.1 所示。

表 3.1 电力负荷数据的数据特征集

Table 3.1 Data feature set of power load data

时间	负荷数据	小时	周几	早晚高峰	月份	年份	季节	是否是节假日
2011/1/1 0:15	81.72826653	0	5	0	1	2011	3	1
2011/1/1 0:30	87.45445081	0	5	0	1	2011	3	1
…	…	…	…	…	…	…	…	…
2011/7/1 9:30	175.3909844	9	5	1	7	2011	1	0
2011/7/1 9:45	191.0763569	9	5	1	7	2011	1	0
…	…	…	…	…	…	…	…	…
2014/12/31 23:45	58.99724011	23	3	0	12	2014	3	0
2015/1/1 0:00	57.14811408	0	4	0	1	2015	3	1

本章使用 XGBoost 对特征重要性分析，因为 XGBoost 内置的特征重要性评估功能可以帮助识别哪些特征对模型预测性能贡献最大，从而进行特征选择。然后通过 XGBoost 学习到的树模型，可以探索不同特征之间的交互关系，进而构建更复杂的组合特征。最后通过对时间特征、季节特征和节假日特征的深入分析和提取，可以显著提高电力负荷预测模型的性能。

3.4 实验验证

为检验提出的 DA-XGBoost 模型性能并验证其有效性，通过设置五组对比实验，将所提方法的分类精度与现有的五种主流的方法进行比较，包括 LSTM、基于 LSTM 改进的 GRU 方法、CatBoost、LightGBM 和 XGBoost。

3.4.1 实验设置

实验在具有 Intel I7 2.3 GHz 处理器，16gb RAM 和 64 位 Windows10 操作系统的计算设置上执行，模型基于 TensorFlow 2.5 和 Python 3.8 下的 Keras 框架。

中国知网 https://www.cnki.net

模型参数设置如下：使用 LSTM 算法的负荷预测模型神经元数量为 50 的 LSTM 层和一层全连接层，学习率设置为 0.001，训练批量设为 72；使用 GRU 算法的预测模型的神经元数量为 50 的 GRU 层和一层全连接层，学习率设置为 0.001，训练批量设为 72；使用 CatBoost 算法的负荷预测模型的 learning_rate(学习速率)设置为 0.05，最大深度设置为 10；使用 LightGBM 算法的负荷预测模型的 learning_rate(学习速率)设置为 0.05，最大深度设置为 10，num_leaves 设置为 31，feature_fraction 设置为 0.9，bagging_fraction 设置为 0.8，bagging_freq 设置为 5；本章 XGBoost 和 DA-XGBoost 的参数设置一致，如表 3.2 所示。

表 3.2 XGBoost 模型参数设置

Table 3.2 Parameter Settings of XGBoost model

参数	参数设定值	参数意义
base_score	0.5	基础分数
booster	gbtree	Booster 类型：gbtree
callbacks	None	回调
colsample_bylevel	1	逐级列下采样
colsample_bynode	1	按节点对列进行二次采样
colsample_bytree	1	按树进行列次采样
grow_policy	depth wise	增长策略：深度增长
learning_rate	0.300000012	学习速率
max_bin	256	二进制箱子的最大数量
max_cat_to_onehot	4	对独热编码的最大分类特征
max_delta_step	0	最大增量步长
max_depth	6	最大深度
min_child_weight	1	最低子代权重
n_estimators	100	估计器数量
num_parallel_tree	1	并行树的数量
predictor	auto	预测类型
reg_lambda	1	L2 正则化参数
sampling_method	uniform	抽样方法
scale_pos_weight	1	量表 Pos 权重比
subsample	1	子样品比率
tree_method	exact	树木生长法
validate_parameters	1	验证参数

3.4.2 实验结果与分析

2014 年 1 月 1 日至 1 月 7 日不同模型的预测结果每个预测采样点的时间间隔设为 15 分钟，共 96 个采样点。预测结果采用 RMSE 和 R2 系数进行评估。源域数据范围为 2013 年 12 月 1 日至 2013 年 12 月 31 日的电力负荷数据，目标

中国知网 https://www.cnki.net

域数据范围为 2013 年 12 月 18 日至 2014 年 1 月 7 日的电力负荷数据，其中目标域的测试集数据为 2014 年 1 月 1 日至 2014 年 1 月 7 日。以 MT_244 为源域 MT_221 为目标域，模型训练时的迭代次数均为 100 次，迭代 loss 曲线如图 3.3。

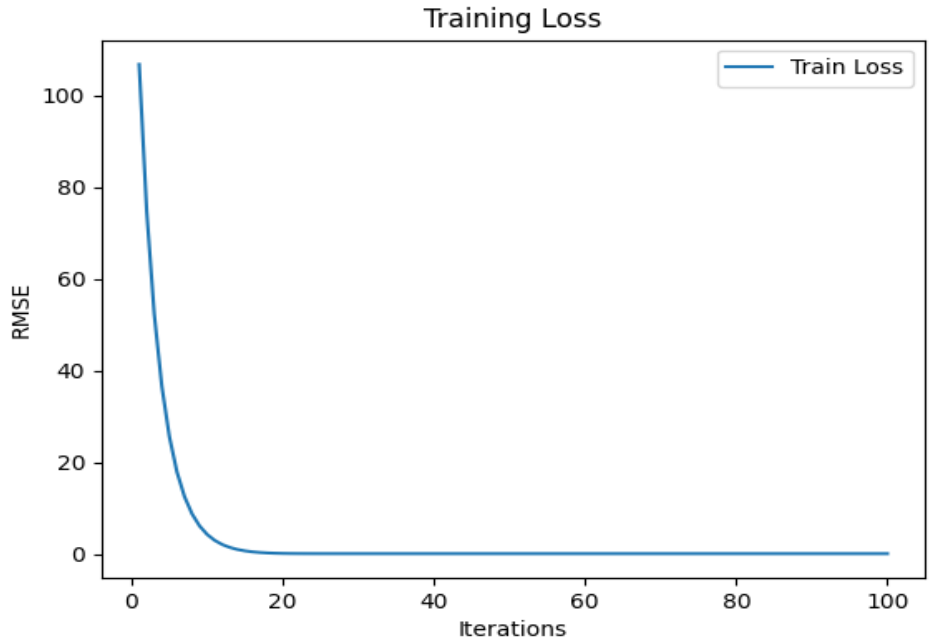


图 **3.3** 模型训练迭代 loss 曲线

Fig **3.3** loss curve of model training iteration

6 个不同模型分别对 2014 年 1 月 1 日至 2014 年 1 月 7 日不同区域的负荷值进行预测，预测结果如图 3.4 所示。首先以 MT_221 的 2013 年 12 月的 31 天电力负荷数据作为源域，以 MT_244 的 2013 年 12 月的最后十四天(2013 年 12 月 18 日至 31 日)的负荷数据作为目标域的训练集，2014 年 1 月 1 日至 2014 年 1 月 7 日作为目标域的测试集，进行第一个迁移实验，接下来保持源域数据不变，切换目标域，以 MT_272 的 2013 年 12 月的最后十四天(2013 年 12 月 18 日至 31 日)的负荷数据作为目标域的训练集，2014 年 1 月 1 日至 2014 年 1 月 7 日作为目标域的测试集，进行第二次实验，以此类推。不难看出，每一种模型完成不同的迁移预测任务的预测精度都很高，以至于从整体上观察不出有很大的预测结果与真实负荷值的差异。

中国知网 https://www.cnki.net

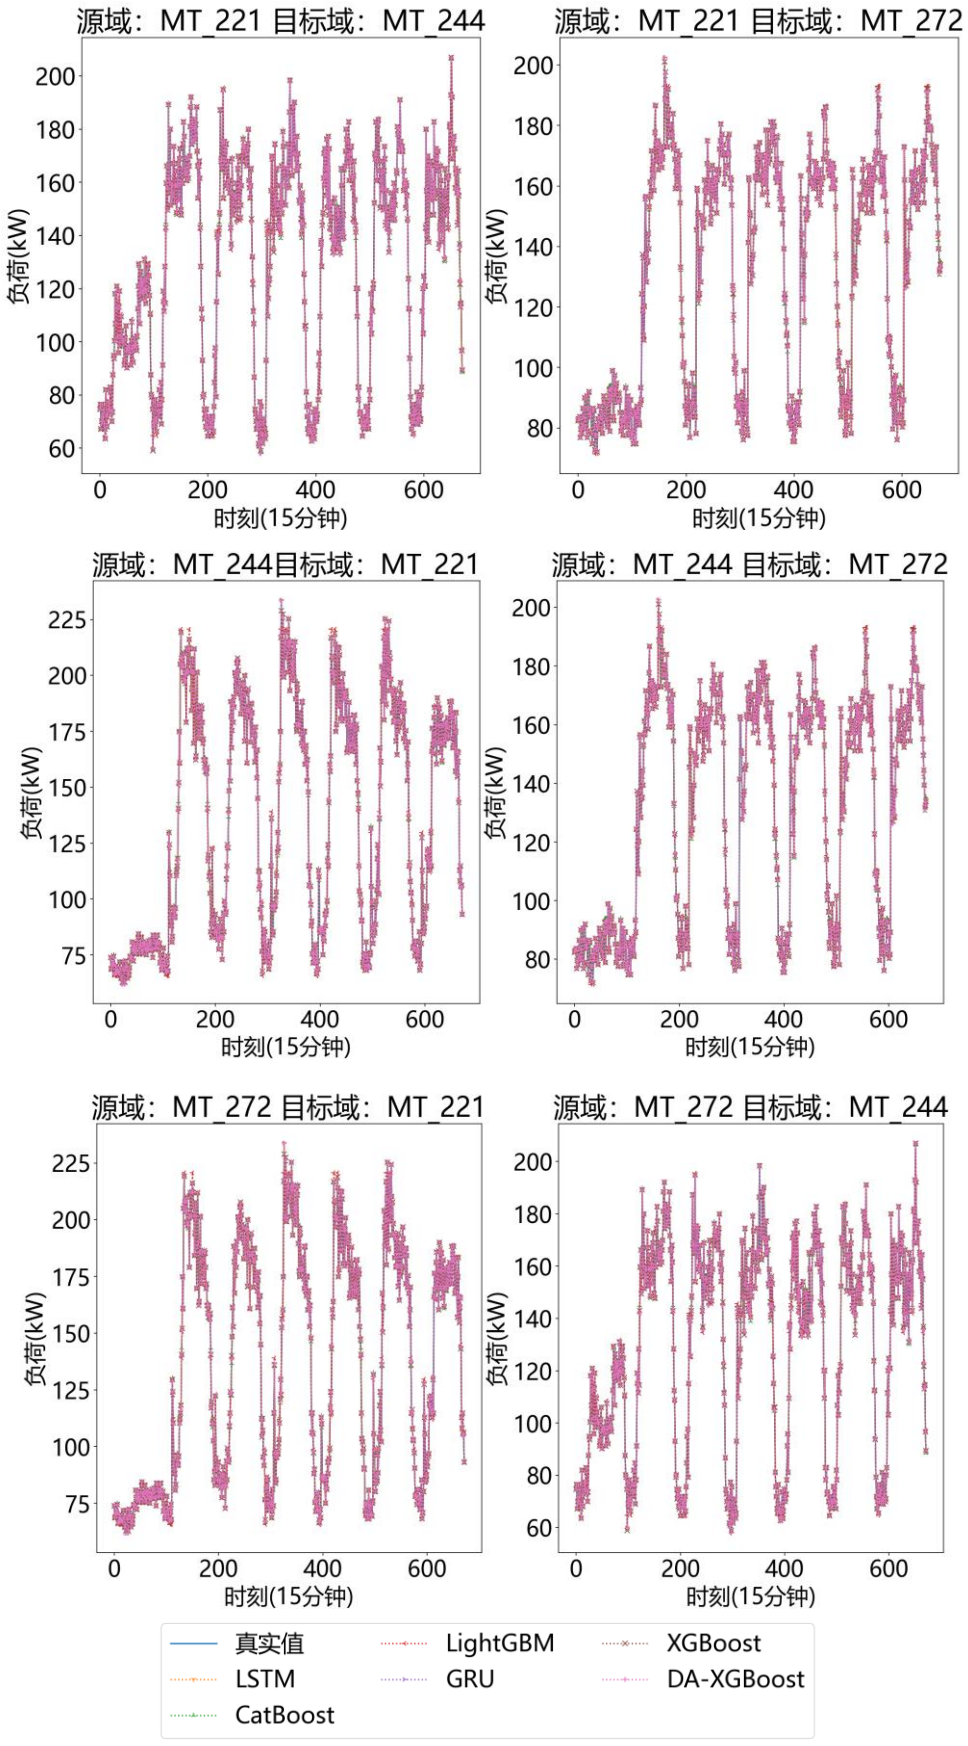


图 **3.4** 不同的迁移任务的预测结果

Fig **3.4** Prediction results for different transfer tasks

中国知网 https://www.cnki.net

由于图 3.4 中的预测值和真实负荷值的差异难以判断，为能够更加详细地看到不同模型的预测结果差异。本章在图 3.5 可视化 MT_244 为源域，MT_221 为目标域的预测结果图的部分细节。

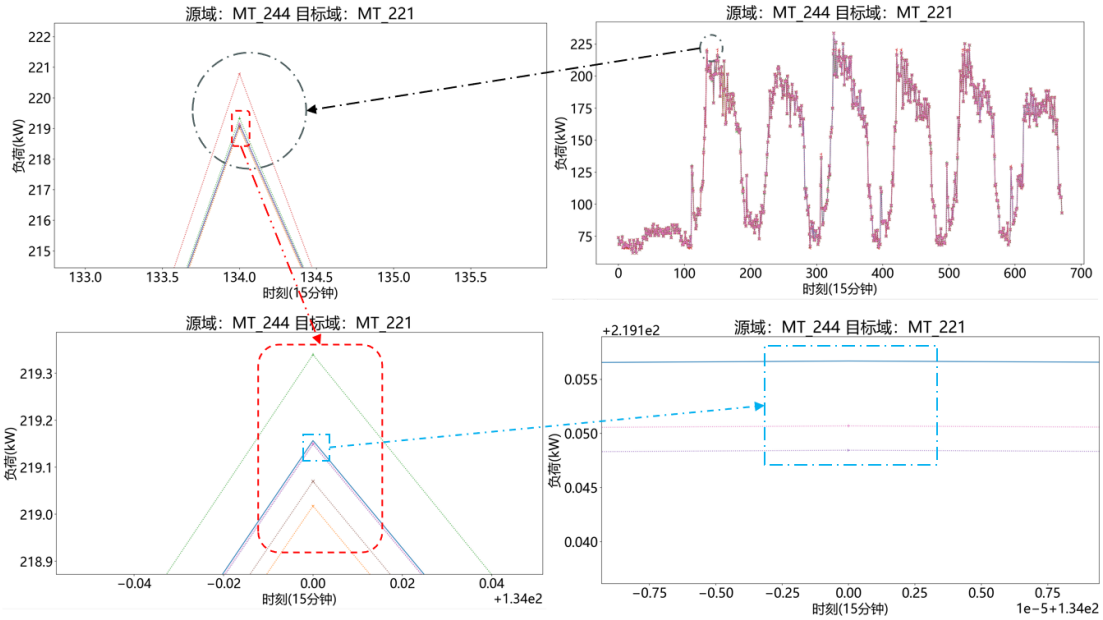


图 **3.5** 预测结果细节可视化

Fig **3.5** Detailed visualization of the prediction results

如图 3.5 所示，不难看出各个模型的预测误差从大到小依次是 LightGBM、XGBoost、CatBoost、LSTM、GRU 以及本章提出的 DA-XGBoost。能够很明显可以看出本章提出的 DA-XGBoost 在传统的 XGBoost 的基础上有很大的提升。LightGBM、XGBoost 和 CatBoost 作为传统的基于树模型的方法，通常在许多回归任务中表现得十分优异，但在这个实验中，它们的表现相对较差，不如 LSTM 和 GRU，LSTM 和 GRU 时序序列预测任务中具有良好的表现，在本次实验中也很好地展现二者的预测性能。接下来使用式(2.1)至式(2.4)这四个评价指标评价模型的性能。

以 MT_221 为源域，MT_244 为目标域的 2014 年 1 月 1 日至 2014 年 1 月 7 日各模型预测评价指标如图 3.6 所示。

中国知网 https://www.cnki.net

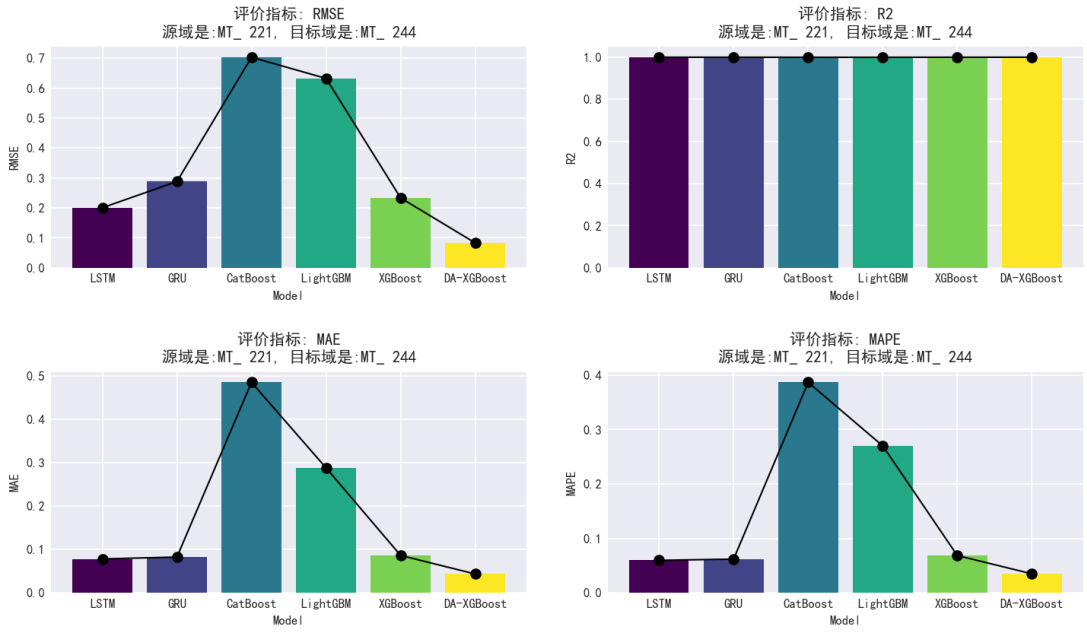


图 **3.6** 各模型从 MT_221 迁移到 MT_244 预测评价指标

Fig **3.6** Prediction evaluation metrics for each model migrating from MT_221 to MT_244

以 MT_221 为源域，MT_272 为目标域的 2014 年 1 月 1 日至 2014 年 1 月 7 日各模型预测评价指标如图 3.7 所示。

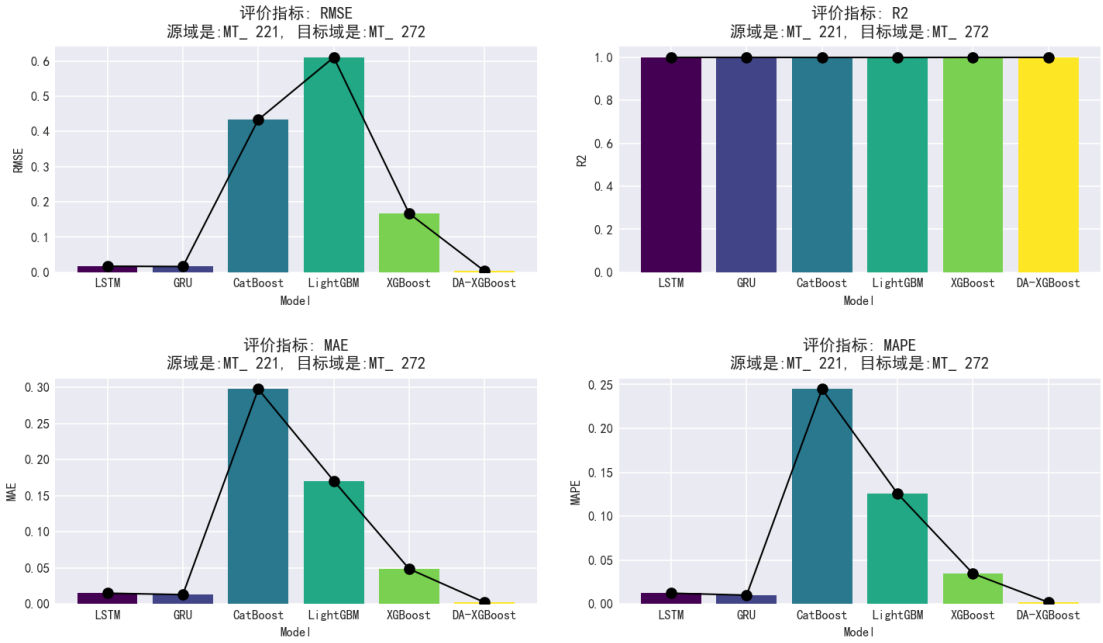


图 **3.7** 各模型从 MT_221 迁移到 MT_272 预测评价指标

Fig **3.7** Prediction evaluation metrics for each model migrating from MT_221 to MT_272

以 MT_244 为源域，MT_221 为目标域的 2014 年 1 月 1 日至 2014 年 1 月 7 日各模型预测评价指标如图 3.8 所示。

中国知网 https://www.cnki.net

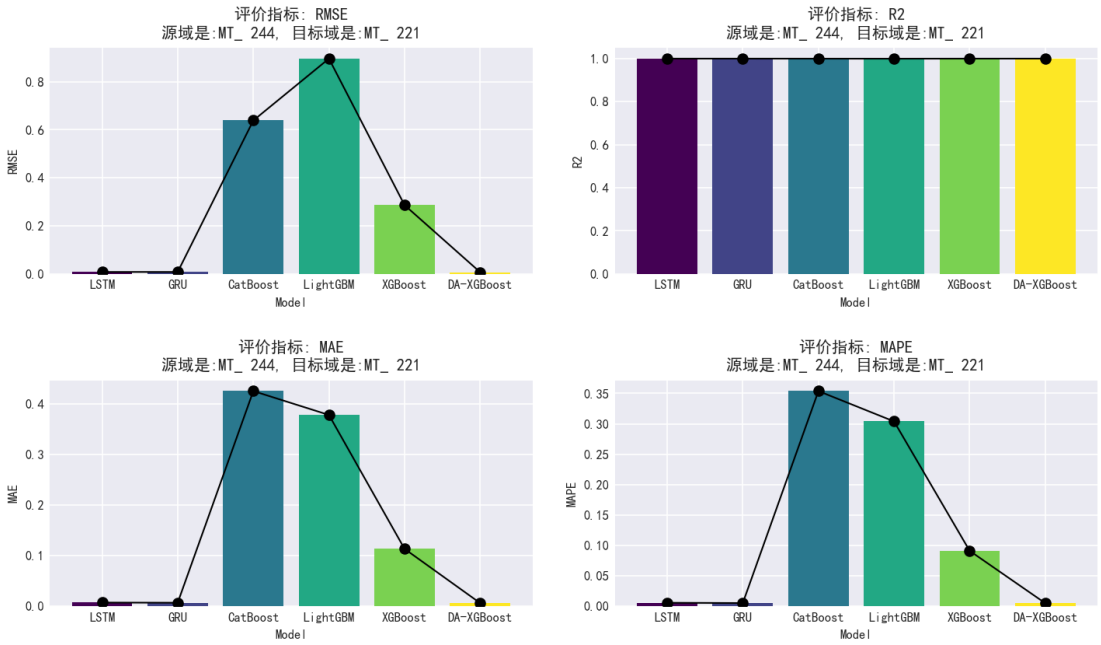


图 **3.8** 各模型从 MT_244 迁移到 MT_221 预测评价指标

Fig **3.8** The models migrated from MT_244 to MT_221 to predict the evaluation metrics

以 MT_244 为源域，MT_272 为目标域的 2014 年 1 月 1 日至 2014 年 1 月 7 日各模型预测评价指标如图 3.9 所示。

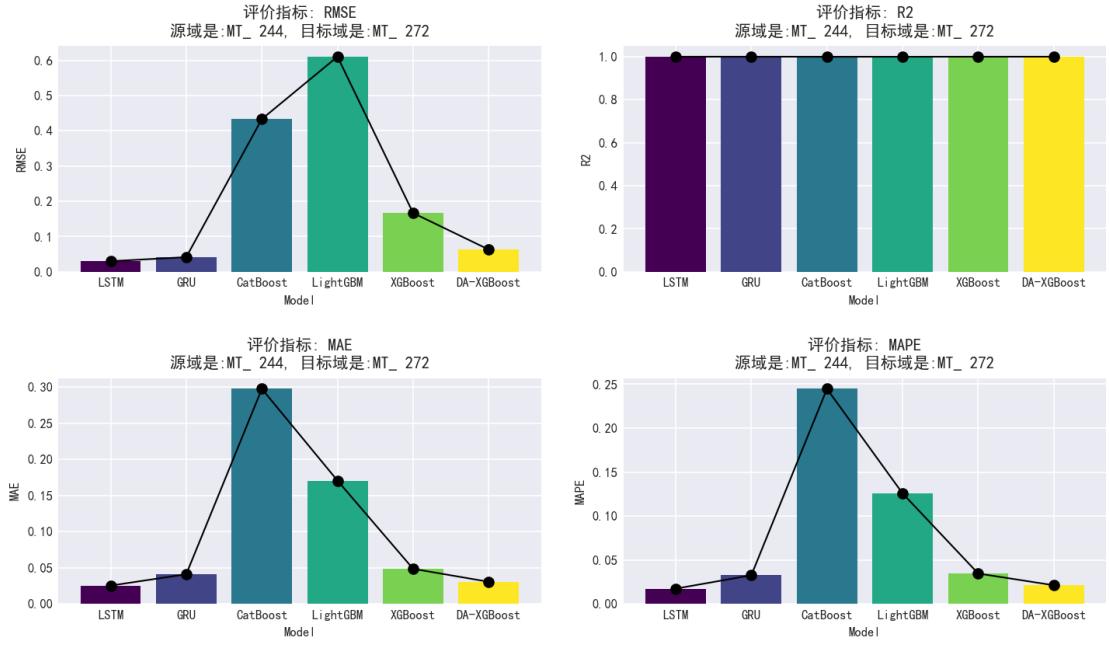


图 **3.9** 各模型从 MT_244 迁移到 MT_272 预测评价指标

Fig **3.9** The models migrate from MT_244 to MT_272 prediction evaluation metrics

以 MT_272 为源域，MT_244 为目标域的 2014 年 1 月 1 日至 2014 年 1 月 7 日各模型预测评价指标如图 3.10 所示。

中国知网 https://www.cnki.net

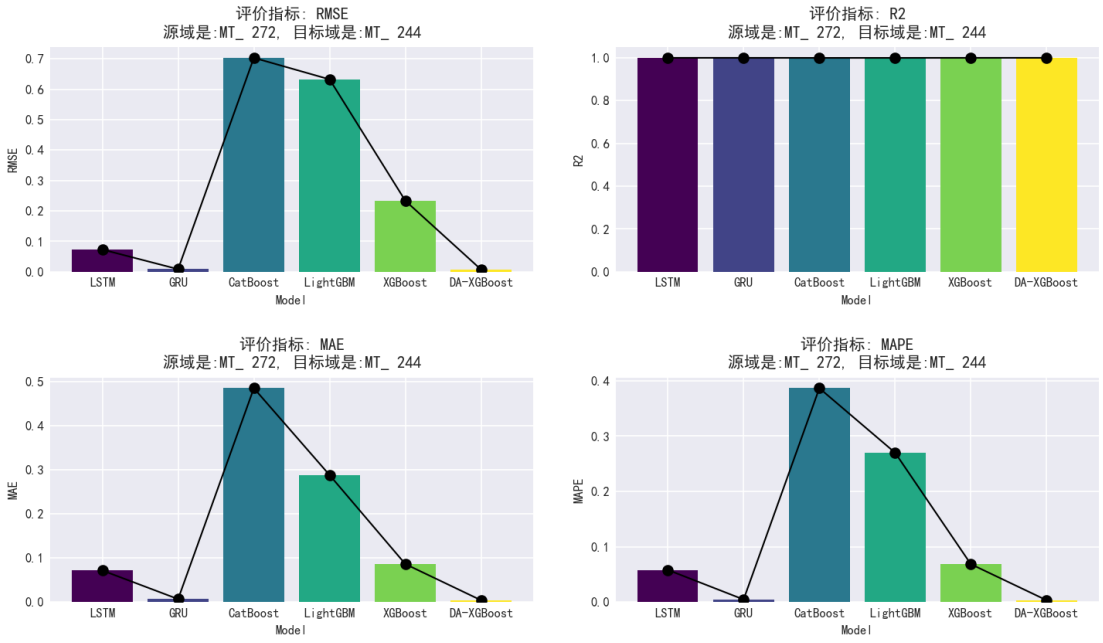


图 **3.10** 各模型从 MT_272 迁移到 MT_244 预测评价指标

Fig **3.10** Each model migrates from MT_272 to MT_244 prediction evaluation metrics

2014 年 1 月 1 日至 2014 年 1 月 7 日以 MT_272 为源域，MT_221 为目标域的模型评价如图 3.11 所示。

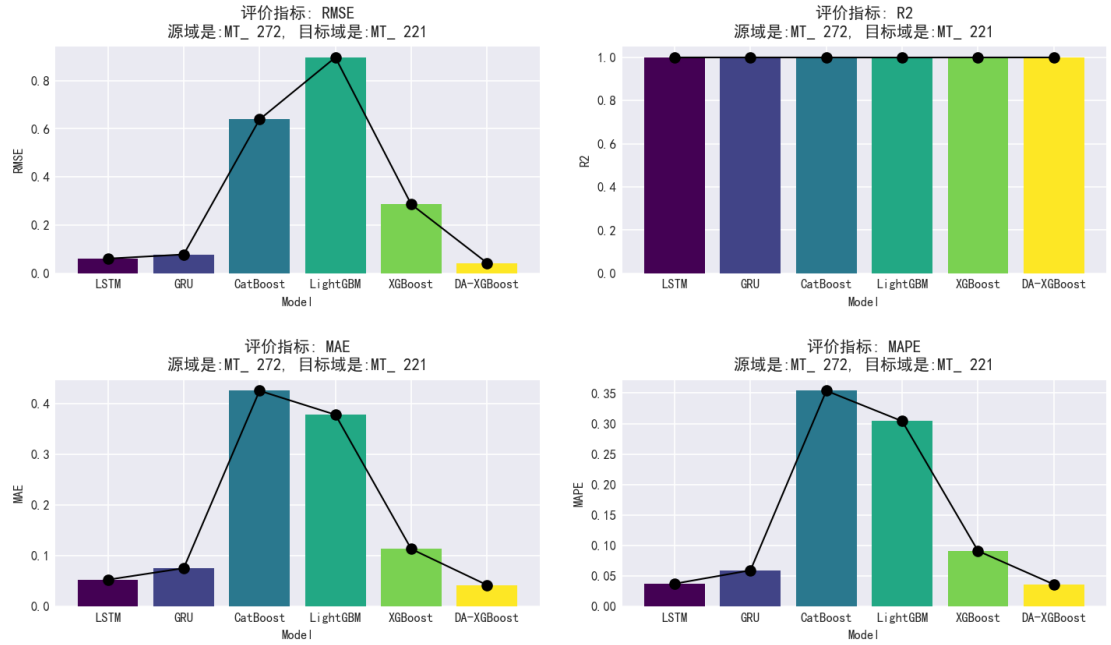


图 **3.11** 各模型从 MT_272 迁移到 MT_221 预测评价指标

Fig **3.11** Each model migrates from MT_272 to MT_221 prediction evaluation metrics

不难看出，各个模型在 R^2 上相差无几，每个模型具有较高的拟合度，说明本章节数据特征集的设计是十分有成效的。但是 DA-XGBoost 在 RMSE、MAE 和 MAPE 上都明显优于所有模型。深度学习模型 LSTM 和 GRU 相对于基于树

中国知网 https://www.cnki.net

模型的方法 LightGBM、XGBoost 和 CatBoost 拥有更低的 RMSE、MAE 和 MAPE。各个模型对 2014 年全年每月前 7 日进行预测，各个模型在不同迁移策略上的不同性能评估结果如表3.3和表3.4所示，其中A、B、C分别代表MT_221、MT_244、MT_272 三个地区，M1、M2、M3、M4、M5、M6 分别代表 LSTM、GRU、CatBoost、LightGBM、XGBoost、DA-XGBoost(本章提出的方法)。

表 3.3 各模型预测的 RMSE 和 MAE 评价指标平均值

Table 3.3 Average values of RMSE and MAE evaluation metrics predicted by each model

迁移策略	A→B	A→C	B→A	B→C	C→A	C→B	平均值
M1(RMSE)	0.2007	0.0172	0.0084	0.0302	0.0611	0.0732	0.0651
M1(MAE)	0.0785	0.0150	0.0076	0.0254	0.0531	0.0720	0.0379
M2(RMSE)	0.2882	0.0163	0.0083	0.0417	0.0784	0.0088	0.0419
M2(MAE)	0.0829	0.0131	0.0072	0.0412	0.0758	0.0071	0.0379
M3(RMSE)	0.7033	0.4332	0.6386	0.4332	0.6386	0.7033	0.5917
M3(MAE)	0.4857	0.2975	0.4253	0.2975	0.4253	0.4857	0.4029
M4(RMSE)	0.6325	0.6100	0.8959	0.6100	0.8959	0.6325	0.7128
M4(MAE)	0.2885	0.1706	0.3782	0.1706	0.3782	0.2885	0.2791
M5(RMSE)	0.2335	0.1668	0.2864	0.1668	0.2864	0.2335	0.2289
M5(MAE)	0.0865	0.0486	0.1136	0.0486	0.1136	0.0865	0.0829
M6(RMSE)	0.0833	0.0034	0.0073	0.0632	0.0431	0.0074	0.0346
M6(MAE)	0.0438	0.0023	0.0065	0.0307	0.0425	0.0044	0.0217

表 3.4 各模型预测的 R^2 和 MAPE 评价指标平均值

Table 3.4 Average values of R^2 and MAPE evaluation indicators predicted by each model

迁移策略	A→B	A→C	B→A	B→C	C→A	C→B	平均值
M1(R^2)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
M1(MAPE)	0.0599	0.0124	0.0060	0.0175	0.0376	0.0583	0.0319
M2(R^2)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
M2(MAPE)	0.0622	0.0101	0.0055	0.0327	0.0596	0.0049	0.0292
M3(R^2)	0.9997	0.9999	0.9998	0.9999	0.9998	0.9997	0.9998
M3(MAPE)	0.3866	0.2447	0.3538	0.2447	0.3538	0.3866	0.3284
M4(R^2)	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997
M4(MAPE)	0.2701	0.1258	0.3039	0.1258	0.3039	0.2701	0.2333
M5(R^2)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
M5(MAPE)	0.0687	0.0347	0.0913	0.0347	0.0913	0.0687	0.0649
M6(R^2)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
M6(MAPE)	0.0352	0.0020	0.0053	0.0213	0.0365	0.0035	0.0173

通过表3.3和表3.4可知，本章模型在不同区域的预测性能均有良好的表现，尤其是在 MT_244 迁移到 MT_211 的任务中，RMSE 达到最低值 0.0034，MAE 达到最低的 0.0023，MAPE 达到最低的 0.002，远远低于传统的 XGBoost 模型。

中国知网 https://www.cnki.net

所有模型对 2014 年全年每月前 7 日预测的平均性能评估图如图 3.12 所示。

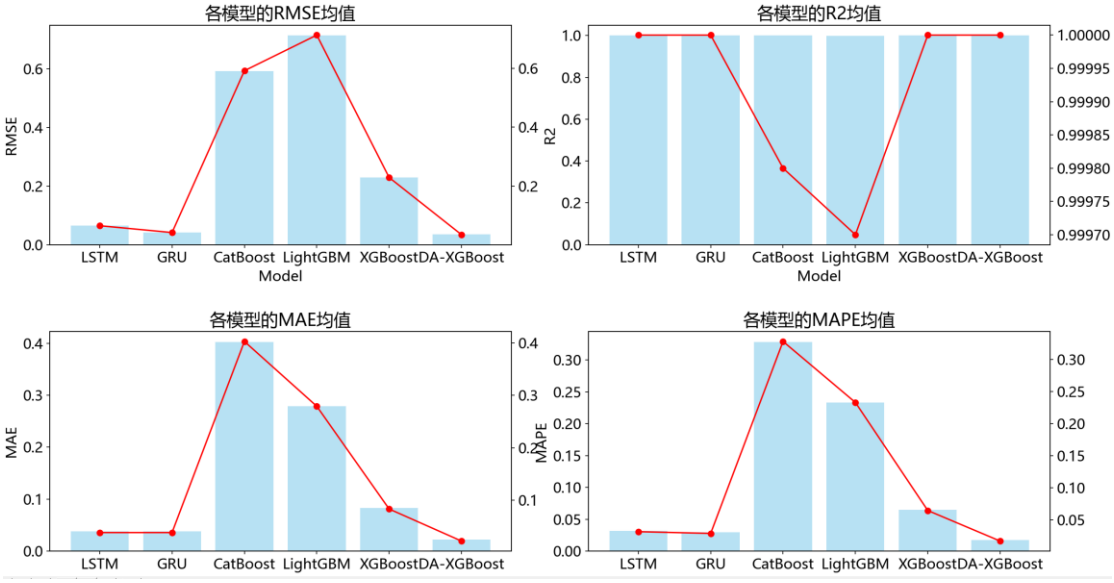


图 **3.12** 各模型的平均性能

Fig **3.12** Average performance of each model

通过图 3.12 可知，基于树的模型与深度学习模型的预测精度都较为不错，预测曲线与真实值的拟合度都十分地高。从 RMSE、MAE 和 MAPE 中的平均值不难看出，各个模型在所有迁移任务中的平均预测误差从大到小依次是 CatBoost、LightGBM、XGBoost、LSTM、GRU 以及本章提出的 DA-XGBoost。其中 LSTM 和 GRU 它们在时序序列预测任务中展现了其固有的优势。由于它们在模型架构上对时间序列数据的内在特性进行了优化，它们能够捕捉到时间序列中的长期依赖关系，有效地解决了传统模型在面对长序列时遗忘过去信息的难题，它们的灵活性和对序列时间点的敏感性使得这两种模型特别适用于预测动态变化的时间序列数据，从而在预测电力负荷的未来趋势方面显示出了更强的能力。这使得它们在预测精度和稳定性方面表现出了显著的优势。能够很明显可以看出本章提出的 DA-XGBoost 在传统的 XGBoost 的基础上有很大的提升，在预测的稳定性和可靠性方面也展现出了更好的结果。LightGBM、XGBoost 和 CatBoost 作为传统的基于树模型的方法，通常在许多回归任务中表现得十分优异，但在这个实验中，它们的表现相对较差，不如 LSTM 和 GRU。

实验结果表明：

1)DA-XGBoost 模型在短期负荷预测中表现出显著的预测精度和泛化能力。通过对数据的深入分析和特征工程，有效地捕捉短期负荷预测中的关键特征，包括历史负荷数据和节假日等因素，使得预测结果更加全面和可靠，通过

中国知网 https://www.cnki.net

对源域和目标域数据的权重进行动态调整，模型能够更好地利用目标域数据的信息，提高了预测的精确度和泛化能力，有效地弥补了源域数据与目标域数据之间的差异，使得模型在不同环境下都能够表现出良好的性能。

2)域自适应技术在解决源域和目标域分布差异方面表现出相当大的优势。DA-XGBoost 模型通过计算领域间相似度和权重矩阵，巧妙地将关注点转移到目标域数据上，最大限度地降低分布差异的影响。

3)通过与传统模型和其他方法的对比实验，验证 DA-XGBoost 在短期电力负荷预测方面的性能优越性。相对于传统的模型，本方法在源域和目标域都能够得到更好的预测结果，与实际电力负荷数据密切一致。

3.5 本章小结

本章的核心是提出一种用于短期负荷预测的领域自适应 XGBoost 模型，并通过实验验证其优越的预测精度和泛化能力。然而，尽管领域自适应 XGBoost 模型在多个方面表现出色，但在实际应用中仍面临一些挑战。首先，构建有效的源域模型需要大量的数据，这在某些情况下可能难以获得。此外，当遇到数据中存在的非线性关系特别复杂时，该模型的泛化能力有时候还不足以应对这类挑战。因此需要研究一种处理目标地区负荷数据样本少，负荷样本数据间存在非线性关系复杂的数据处理的方法，提高模型泛化力。

中国知网 https://www.cnki.net

第四章 基于 Stacking 残差网络的负荷预测

4.1 基本思想

第三章的域自适应 XGBoost 模型通过对源域和目标域之间的分布差异进行建模和调整权重，该模型显示更高的预测精度和泛化能力，显示现实世界的应用潜力。虽然域自适应权重矩阵和协方差差异相似性对比损失函数的设计提高预测的准确性，但是 XGBoost 模型在处理数据量比较小的数据时，数据的非线性关系更加复杂时，会导致模型的泛化能力不足。为克服这些局限性，第四章将介绍一种基于 Stacking 残差网络模型来进行负荷预测。在目标预测区域数据量更少的情况下，ResNet 在处理深层次非线性问题上的优势，以及 Stacking 模型通过结合多个不同预测模型来提高预测的准确性和泛化能力。

4.2 算法设计

4.2.1 变分多核主成分分析

本章提出的变分多核主成分分析(Variational Multiple Kernel Principal Component Analysis, VMKPCA)是一种结合变分推断和多核学习的降维方法。其主要目标是在处理高维数据时，能够有效地发现数据中的低维结构，同时利用多核技术融合不同的数据视图或特征表示，提高降维的性能，并且能够捕捉不同分布数据样本之间的非线性关系。

1.变分推断

设集合 $X=\{x_i\}_{i=1}^{N}$，其中 $x_i \in \mathbb{R}^D$。该方法的目标是将这些高维数据点映射到一个低维子空间 $Z=\{z_i\}_{i=1}^{N}$，其中 $z_i \in \mathbb{R}^d$，且 $d \ll D$。通过引入 M 个不同的核函数 $\{k_m\}_{m=1}^{M}$，每个核函数对应于不同的特征映射或数据视图。找到一个优化的核组合，以及一个映射到低维空间的线性变换。对于每个核 k_m，定义一个对应的权

中国知网 https://www.cnki.net

重 α_m，且 $\sum_{m=1}^{M}\alpha_m=1,\alpha_m\geq 0$。则，组合核 k 定义为式(4.1)：

$$k(x_i,x_j)=\sum_{m=1}^{M}\alpha_m k_m(x_i,x_j) \tag{4.1}$$

最后引入变分推断，首先定义模型的先验分布。假设 Z 的先验为高斯分布，即 $p[Z]=\mathcal{N}[0,I]$。接下来，需要定义似然函数 $p(X\mid Z)$ 以及变分后验分布 $q(Z\mid X)$。由于直接计算后验分布 $p(Z\mid X)$ 是困难的，引入变分分布来近似它，如式(4.2)：

$$q(Z\mid X)=\prod_{i=1}^{N}\mathcal{N}(z_i\mid\mu_i,\Sigma) \tag{4.2}$$

2.目标函数

变分推断的目标是最小化 $q(Z\mid X)$ 和 $p(Z\mid X)$ 之间的 KL(Kullback-Leibler)散度。KL 散度是衡量两个概率分布相似程度的非对称度量，表示用一个分布来近似另一个分布时的信息损失。在变分推断中，KL 散度用来衡量近似分布 $q(Z\mid X)$ 与真实后验分布 $p(Z\mid X)$ 之间的差异。$q(Z\mid X)$ 是通过变分推断方法选择的一个简化的分布，它的形式通常更易于计算。变分推断的核心目标是找到参数化的分布 $q(Z\mid X)$ 的参数，使得 KL 散度最小，这意味着 $q(Z\mid X)$ 尽可能接近 $p(Z\mid X)$。因此，本章算法的优化目标可以写为式(4.3)：

$$\mathcal{L}(q)=\mathrm{KL}(q(Z\mid X)\|\,p(Z\mid X))=\mathbb{E}_q[\log q(Z\mid X)]-\mathbb{E}_q[\log p(X,Z)] \tag{4.3}$$

其中，$\mathbb{E}_q[\cdot]$ 表示在 $q(Z\mid X)$ 下的期望。该目标函数由两部分组成：第一项是近似分布 $q(Z\mid X)$ 的熵，它量化分布内部的不确定性；第二项是近似分布与联合分布 $p(Z\mid X)$ 之间交叉熵的期望值，它考虑观测数据 X 和隐变量 Z。本章通过梯度下降法来调整每个核的权重 $\{\alpha_m\}$，以最大化整个模型的似然，本章同样采用梯度下降法更新 $q(Z\mid X)$ 的参数变分参数 μ_i 和 Σ。

本章提出的 VMKPCA 结合变分推断和多核学习的方法，寻找一种更加有效的降维方法。通过优化多核组合和变分参数，可以有效地挖掘出高维数据中的低维结构，同时处理来自不同特征空间的信息。该方法通过选择适当的核函数来实现有效的降维。本章采用 VMKPCA 方法对源域和目标域的数据进行特

中国知网 https://www.cnki.net

征重构，能够将高维数据映射到低维特征空间的同时，还能保留数据的重要结构信息。通过特征选择和特征提取操作，得到经过处理的源域和目标域的训练集和测试集，以及对应的特征权重和特征映射矩阵。

4.2.2 Stacking 的残差网络

本章构建的 Stacking 微调模型以残差网络作为基底模型来提取时间序列数据的高级特征。Stacking 的残差网络核心概念在于通过堆叠残差块来构建深层网络，以便更有效地进行特征学习。残差网络的基本构建块是残差块，其设计理念是学习输入与输出之间的残差，而不是直接尝试学习映射函数。该方法有助于缓解深层网络中的梯度消失或梯度爆炸问题，能够通过增加更多的层来提高模型精度。本章将式(2.7)的残差网络改写为式(4.4)：

$$y = F(x,\{W_i\}) + x \tag{4.4}$$

其中，x 和 y 分别是残差块的输入和残差块的输出，$\{W_i\}$ 表示残差块中卷积层的权重集，$F(x,\{W_i\})$ 表示需要学习的残差映射。本章的 F 由 2 个相同参数的卷积层组成，卷积层对输入 x 进行处理，并且最后的输出通过一个残差连接与输入 x 直接相加，从而构成残差块的输出 y 。

对于更深的残差网络，这些残差块被在一起，每个块的输出作为下一个块的输入。整个网络的输出是通过堆叠所有残差块得到。在本章的电力负荷预测任务中，残差块的输入维度和残差块的输出维度不匹配，通过映射权重矩阵 W_s 来调整维度，将式(4.4)修改为式(4.5)：

$$y = F(x,\{W_i\}) + W_s x \tag{4.5}$$

这里，W_s 是一个可学习的映射权重矩阵，用于将 x 的维度调整到和 $F(x,\{W_i\})$ 拥有相同的维度，从而可以使得残差块的输入和输出相加。图 4.1 展示本章提出的 Stacking 模型结构。

中国知网 https://www.cnki.net

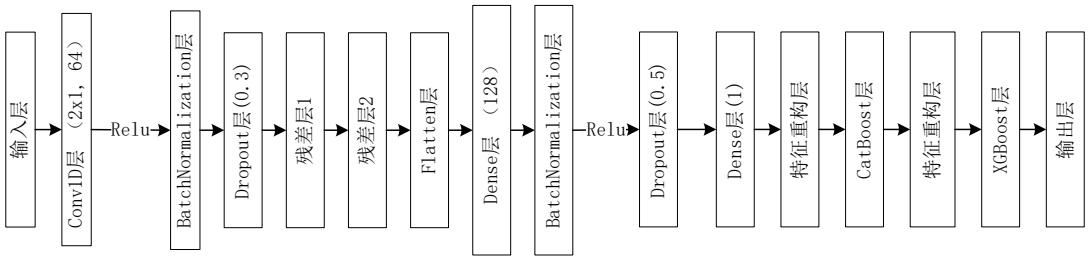


图 **4.1** 本章提出的模型结构图

Fig **4.1** Structure diagram of the proposed model

首先，利用 Stacking 的 Resnet 模型捕捉电力负荷数据特征集与时间的非线性关系，将这种关系作为特征通过 VMKPCA 降维后输入到 CatBoost，CatBoost 提取更深层次的特征后再进行 VMKPCA 进行特征降维，最后传入 XGBoost 中进行负荷预测。因为 CatBoost 能够最大程度地对特征进行分类，并且能够捕捉电力负荷数据中的非线性关系，对噪声具有较强的抗干扰性，所以本章将 CatBoost 放在模型的第二层。最后一层的 XGBoost 模型的正则化能够使得模型的泛化性更强，减少模型过拟合的风险，从而提高预测精度。

如果将 XGBoost 放在第二层，优先对模型进行正则化处理，CatBoost 放在第三层，最后再进行特征分类，然后模型进行预测，这并不会得到更好的结果，反而各个模型的优点发挥不到最佳状态，甚至会导致模型发生负迁移现象。

本章提出模型的流程图如图 4.2 所示，ResNet 作为 Stacking 模型的第一层，其主要职责是进行深层特征的抽象和提取。这些特征随后被用作 CatBoost 和 XGBoost 模型的输入，这两个模型作为第二层，各自学习不同的数据表示和模式。通过这种方式，CatBoost 和 XGBoost 可以在一个较为高级的特征空间中进行学习，这个特征空间是由 ResNet 所提供的。然后将训练好的模型传入目标域，通过目标域训练集训练后进行模型微调，最后，目标域测试集的数据传入微调后的模型，形成最终的预测输出。通过这种顺序的组合，本章提出的 Stacking 模型利用每个单独模型的优势，同时通过集成方法降低预测误差和模型的泛化误差。ResNet 的深度特征提取能力，以及 VMKPCA 的特征重构，然后把重构后的特征送入 CatBoost 和 XGBoost，最后将模型送入目标域训练集进行微调。

中国知网 https://www.cnki.net

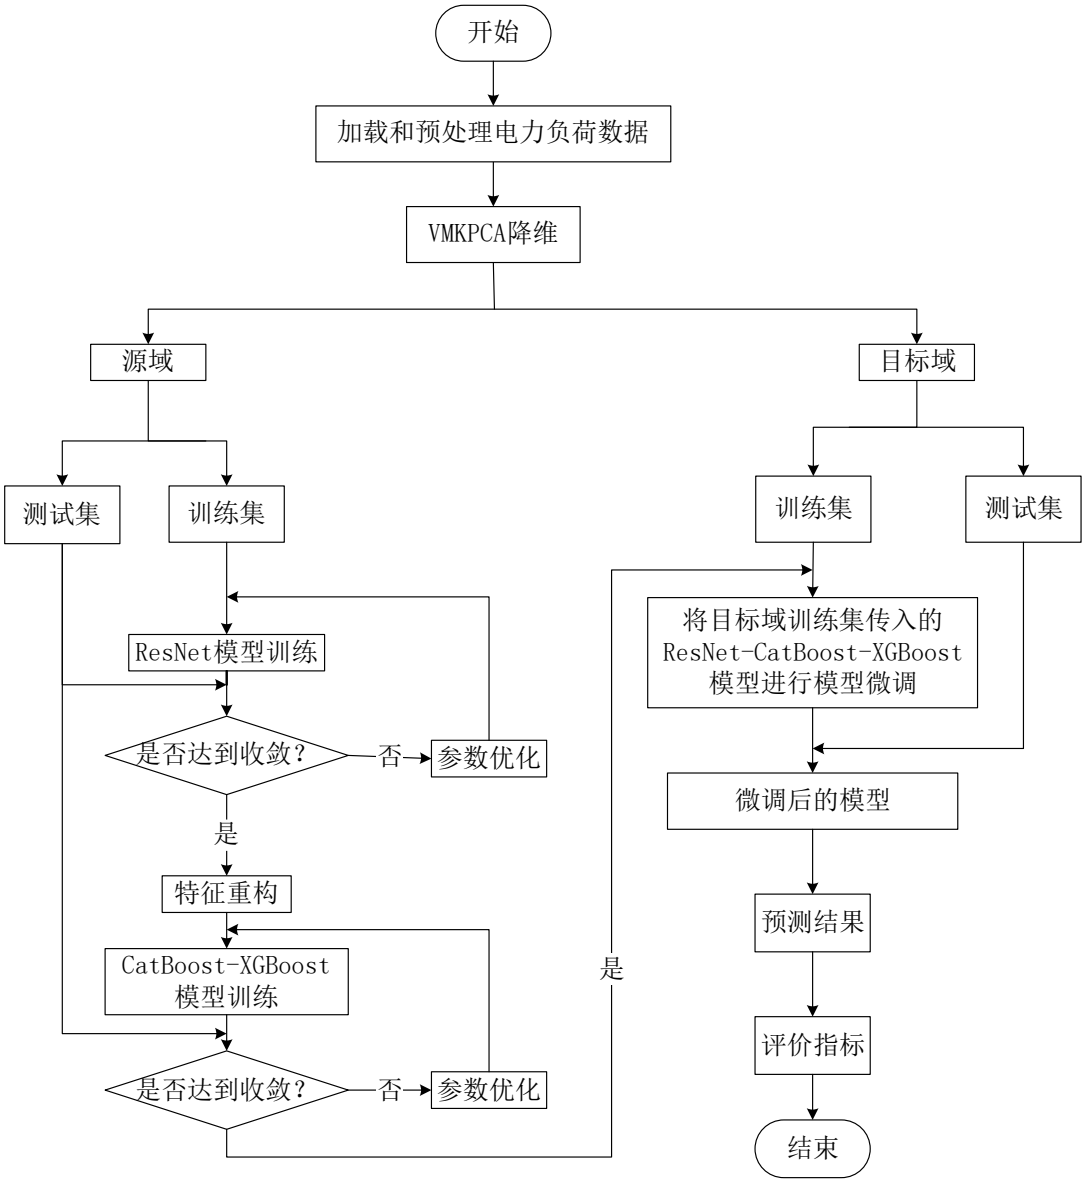


图 **4.2** 本章提出的模型流程图

Fig **4.2** Flowchart of the proposed model

4.3 负荷数据处理与实验设置

4.3.1 佛山工商业用户数据集

本实验数据采集于我国佛山顺德区的 6 个工商业用户 2021 年 12 月到 2022 年 12 月的历史负荷，历史负荷采集周期为 15 分钟。佛山工商业用户数据集的数据特征集构建参考 3.3.2 节。图 4.3 展示 6 个用户 2021 年 12 月第一周的历史负荷曲线，可以看出用户 1，用户 2，用户 3 在负荷变化规律上比较相似，这表

中国知网 https://www.cnki.net

明他们之间的能耗模式和使用习惯存在共性，从而成为了迁移学习的良好候选对象。具体来说，如果我们将这三个用户在负荷管理方面学习到的知识和模式互相迁移，不仅可以增强模型对这一类用户群体的预测准确性，还可以在相似的使用习惯和能耗模式中寻找到优化能源分配和使用的方法，可以更好地管理相似能耗用户。反之，用户 1，用户 2，用户 3 和用户 4，用户 5，用户 6 之间的相关性比较弱，说明他们的能耗模式和使用习惯有所不同，如果使用目前主流的迁移学习模型将用户 1、用户 2 和用户 3 学习到的知识直接迁移到用户 4，用户 5，用户 6 会造成负迁移现象。在进行迁移学习时，不能简单地假设所有用户的数据和模式都是相似的，而应该考虑到用户之间的个性化特征和差异。

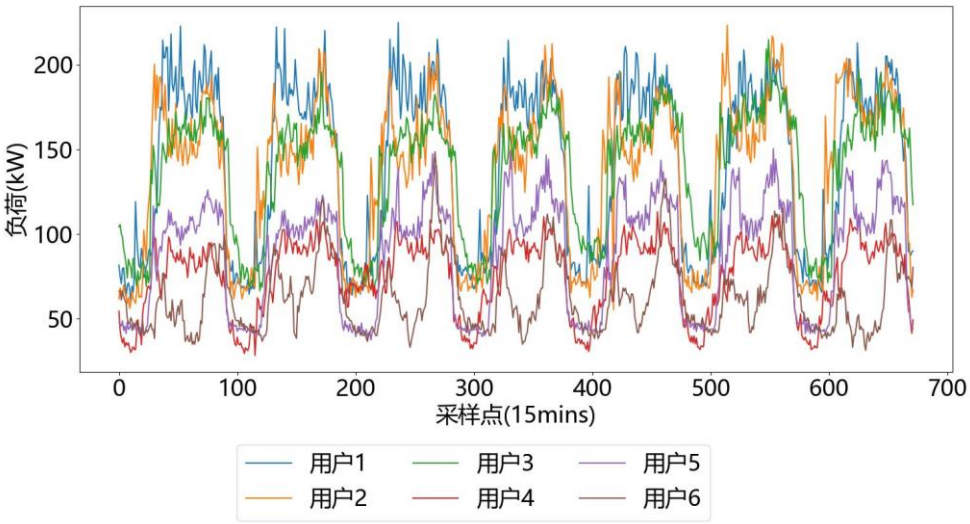


图 **4.3** 佛山数据集 2021 年 12 月第一周的历史负荷曲线

Fig **4.3** Historical load curve of Foshan dataset in the first week of December 2021

4.3.2 实验设置

实验在具有 Intel I7 2.3 GHz 处理器，16gb RAM 和 64 位 Windows10 操作系统的计算机环境上设置执行。实现预测的模型基于 TensorFlow 2.5 以及 Python 3.8 下的 Keras 框架。为验证本章所提出的 ResNet-CatBoost-XGBoost 算法在不同迁移学习策略中的效果，设置 8 种算法与本章提出的模型进行对比：XGBoost 模型、XGBoost-CatBoost 集成模型、CatBoost 模型、CatBoost-XGBoost 集成模型、ResNet 模型、ResNet-CatBoost 集成模型、ResNet-XGBoost 集成模型和 ResNet-XGBoost-CatBoost 集成模型。

本章各个模型的参数设置如下：

中国知网 https://www.cnki.net

残差层的参数如表 4.1 所示。

表 4.1 残差层参数设置

Table 4.1 Parameter Settings of the residual layer

网络层	网络参数	激活函数
输入层	/	/
卷积层 1	filters=64,kernel_size=2,padding='same'	Relu
卷积层 2	filters=64,kernel_size=2,padding='same'	Relu
全池化层	pool_size=2	/
Dropout	0.2	/

ResNet 的参数设置如表 4.2 所示。

表 4.2 ResNet 网络参数设置

Table 4.2 ResNet network parameter Settings

网络层	网络参数	激活函数
输入层	/	/
卷积层	filters=64,kernel_size=2,padding='same'	Relu
Dropout1	0.3	/
残差层 1	filters=64, kernel_size=2	Relu
残差层 2	filters=64, kernel_size=2	Relu
Flatten	/	/
Dense1	128	Relu
Dropout2	0.5	/
Dense2	1	Relu
输出层	/	Adam

其他模型的具体参数设置请参见 3.4.1 节。

4.4 实验验证与结果分析

4.4.1 相同地域电力负荷数据迁移

图 4.4 为不同模型以用户 1 作为目标域，用户 2 作为源域的 2022 年 1 月 15 日预测结果。不难看出 ResNet-XGBoost-CatBoost 集成模型发生负迁移现象，

中国知网 https://www.cnki.net

是所有结果中误差最大的，也是所有结果中集成模型最多的，可能是由于模型的集成方式未能有效地结合各个子模型的优势，或是子模型间的不兼容导致的，证明 Stacking 集成模型的顺序也是 Stacking 模型融合成功的必要条件。

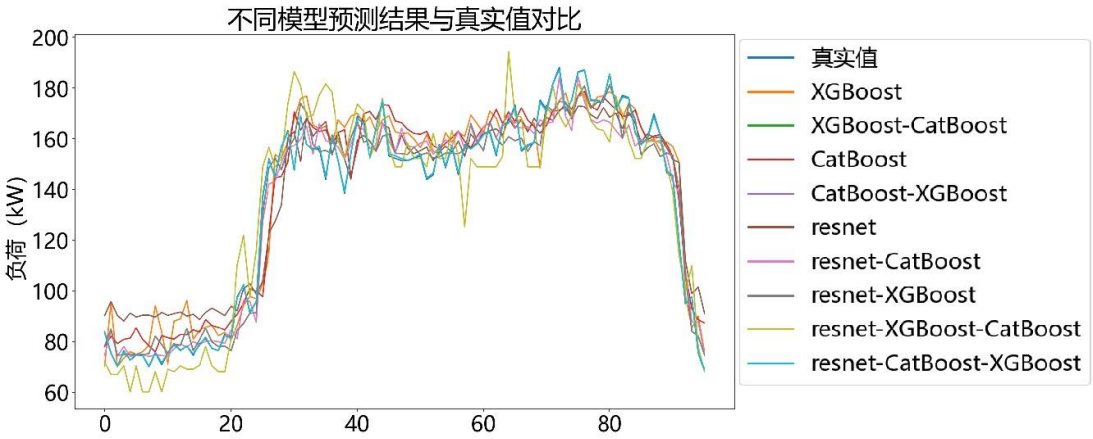


图 **4.4** 各模型在 2022 年 1 月 15 日预测结果

Figure **4.4** Prediction results of each model on January 15, 2022

为更加直观地分析不同预测模型的预测精度，本章将预测 2021 年 12 月至 2022 年 12 月，每个月第三周的 7 天来考察每一个模型的泛化性。首先以用户 2 的 2021 年 12 月第二周和第三周(2021 年 12 月 11 日至 24 日)的负荷数据作为目标域，其中 2021 年 12 月第二周的数据为目标域的训练集，2021 年 12 月第三周的数据作为目标域的测试集，以用户 1 的 2021 年 12 月的前两周(2021 年 12 月 4 日至 17 日)的负荷数据作为源域，进行第一次实验。接下来就是以用户 2 的 2022 年 1 月第二周和第三周的负荷数据作为目标域，其中 2022 年 1 月第二周的数据为目标域的训练集，2022 年 1 月第三周的数据作为目标域的测试集，以用户 1 的 2022 年 1 月的前两周的负荷数据作为源域，进行第二次实验，依此类推，研究继续按月进行，每个月的实验都遵循相同的设计原则，直至预测 2022 年 12 月第三周（12 月 17 日至 23 日）的数据。

通过这种迭代式的实验设计，可以系统地评估数据迁移方法在不同时间段内的预测能力，特别是考虑到季节性变化对能源需求的显著影响。本章使用式(2.1)和式(2.4)对不同模型的性能进行评估。表 4.3 和表 4.4 分别展示的是各模型在不同迁移策略中的性能指标，其中 A 表示 XGBoost，B 表示 CatBoost，C 表示 ResNet，本章模型为 ResNet-CatBoost-XGBoost。

表 4.3 各模型的性能指标对比

Table 4.3 Comparison of performance indicators of each model

中国知网 https://www.cnki.net

迁移策略	用户 1→用户 2		用户 2→用户 1		用户 2→用户 3	
评价指标	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE
A	16.55	10.57%	15.55	10.66%	11.60	7.42%
A-B	13.43	8.26%	13.12	8.36%	9.96	5.86%
B	12.80	8.98%	15.46	10.58%	12.78	8.44%
B-A	4.44	2.76%	5.57	3.61%	3.94	2.27%
C	16.34	10.70%	14.58	10.89%	10.81	6.91%
C-B	13.00	8.20%	11.49	6.89%	9.18	5.04%
C-A	13.43	8.26%	13.12	8.36%	9.96	5.86%
C-A-B	10.15	6.14%	10.41	5.5%	8.29	4.68%
本章模型	2.81	1.75%	2.68	1.74%	2.07	1.25%

表 4.4 各模型的性能指标对比

Table 4.4 Comparison of performance indicators of each model

迁移策略	用户 3→用户 2		用户 3→用户 1		用户 1→用户 3	
评价指标	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE
A	17.88	12.15%	14.49	10.16%	11.92	6.62%
A-B	14.21	8.37%	12.56	7.78%	9.83	5.47%
B	15.19	8.36%	11.68	8.35%	10.77	6.00%
B-A	4.42	2.79%	4.59	2.75%	3.39	2.12%
C	15.03	10.24%	12.73	9.46%	12.19	6.39%
C-B	12.14	6.90%	11.55	7.24%	11.18	6.73%
C-A	14.21	8.37%	12.56	7.78%	9.83	5.47%
C-A-B	11.00	6.15%	9.35	5.68%	8.81	5.04%
本章模型	2.78	1.77%	2.71	1.73%	2.22	1.40%

各模型性能对比分析：

XGBoost 与 XGBoost-CatBoost：在用户 1 迁移到用户 2 的预测中，XGBoost 模型从 RMSE 的 16.55 降低到 13.43，MAPE 也从 10.57%降低到 8.26%，表明集成后的 XGBoost-CatBoost 模型，在捕捉数据集细节上更为精准，使得模型能够更好地识别数据特征，预测结果也更为准确。

CatBoost 与 CatBoost-XGBoost：CatBoost 模型在用户 1 迁移到用户 2 的预

中国知网 https://www.cnki.net

测中，RMSE 为 12.8，MAPE 为 8.98%。然而，集成 XGBoost 后，RMSE 降低到 4.44，MAPE 降低到 2.76%，表明集成后的模型在预测准确性有极大的提升。

ResNet 、 ResNet-CatBoost 、 ResNet-XGBoost 、 ResNet-XGBoost-CatBoost 与 ResNet-CatBoost-XGBoost：ResNet 模型通常用于图像处理任务，本章将其应用于电力负荷的时间序列预测。在用户 1 迁移到用户 2 的预测中，其 RMSE 为 16.34，MAPE 为 10.7%。本章提出的方法 ResNet-CatBoost-XGBoost 将 RMSE 降低到 2.81，MAPE 降低到 1.75%。

所有模型面对不同的迁移任务时，本章提出的模型性能都是十分理想的。不难看出，本章提出的模型与其他模型进行对比，无论是 RMSE 还是 MAPE，在不同迁移任务中都获得最低的值。这表明本章模型在面对不同迁移任务都具有较强的泛化能力。特别是在用户 2 迁移到用户 3 的预测中，将 RMSE 降低到 2.07，MAPE 达到极低的 1.25%。由图 4.5 不难看出，每个模型在佛山工商业用户数据集的所有迁移任务平均误差比较中，本章提出的集成模型的性能始终优于其他模型。同时，本章通过对比单一模型和 Stacking 集成模型，不难发现集成后的模型在性能上始终优于单一模型，原始模型显示出更大的波动性。

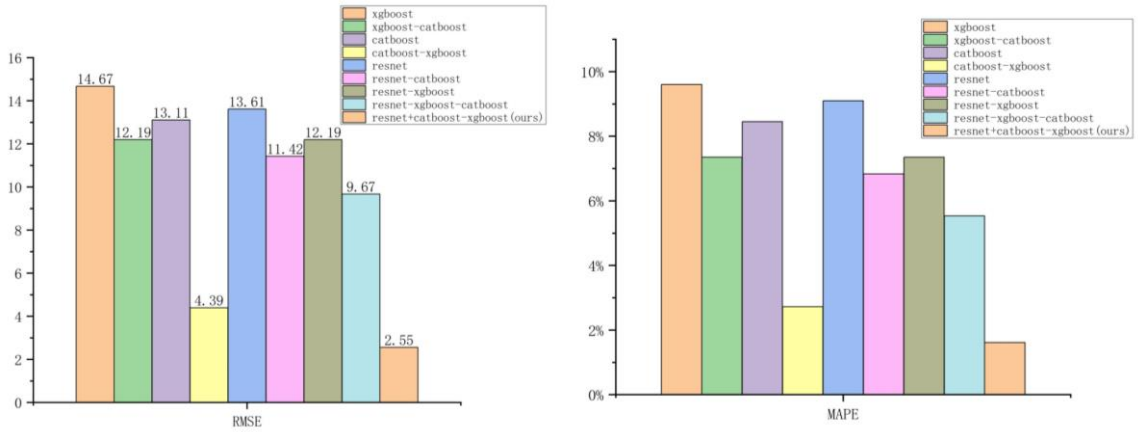


图 **4.5** 各模型的误差对比

Fig **4.5** Error comparison of each model

4.4.2 跨地域电力负荷数据迁移

本节实验中，本章尝试将提出的模型在两个不同地区不同时间的数据集之间进行短期电力负荷预测。首先将佛山工商业数据集内的其他三个用户(用户 4、用户 5、用户 6)作为目标域，利用日最大负荷的相似性[31]的预测原理，然后将三个区域每年的 12 月的前 7 日的日最大负荷分别与第三章中的电力负荷数据集

中国知网 https://www.cnki.net

的所有区域每年的 12 月的前 7 日的日最大负荷相比较，得出第三章的电力负荷数据集的 MT_005 区域的日最大负荷值与三个用户的日最大负荷值较为相近，尽管这四者的时间、空间以及用能特征不一致，但这四者的用电行为具有相关性。因此采用第三章的电力负荷数据集的 MT_005 区域 2013 年 12 月至 2014 年 12 月期间的数据作为源域，佛山工商业数据集内的其他三个用户(用户 4、用户 5、用户 6)2021 年 12 月至 2022 年 12 月的数据作为目标域。图 4.6 中不难看出，MT_005 与这三个用户的数据分布显著不同。

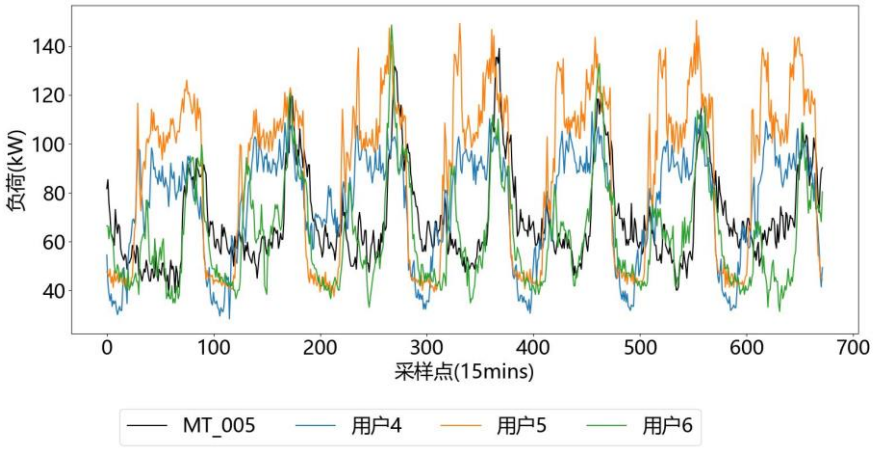


图 **4.6** 不同数据集负荷数据对比

Fig **4.6** Comparison of load data of different datasets

和本章上一个实验相同，源域数据和目标域数据将滞后 7 天的历史负荷以及使用时序多维特征变量转化后的独热值(One Hot)用来作为输入数据，进行预测时间尺度为 15 分钟的 24 小时短期电力负荷预测研究。每组实验重复 10 次，记录平均值和标准差。图 4.7 为 MT_005 作为源域，用户 4 作为目标域的 2022 年 1 月 15 日不同模型预测结果。

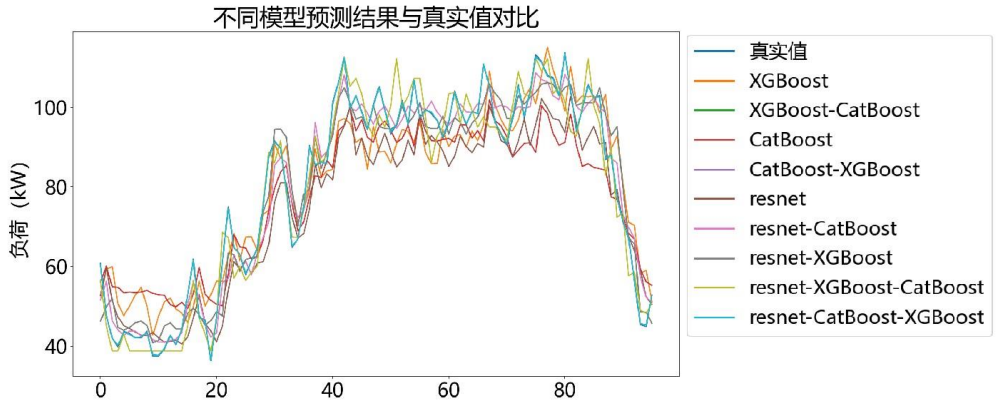


图 **4.7** 各模型在 2022 年 1 月 15 日预测结果

Fig **4.7** Forecast results for each model on January 15, 2022

中国知网 https://www.cnki.net

为更加直观地分析各类预测模型在不同月份迁移任务的预测精度，本节将预测 2021 年 12 月至 2022 年 12 月，每个月第三周的 7 天来考察模型的泛化性，使用 RMSE 和 MAPE 对每个模型的性能进行评估。

以 MT_005 为源域，用户 4 为目标域的各模型评价指标平均值如图 4.8。

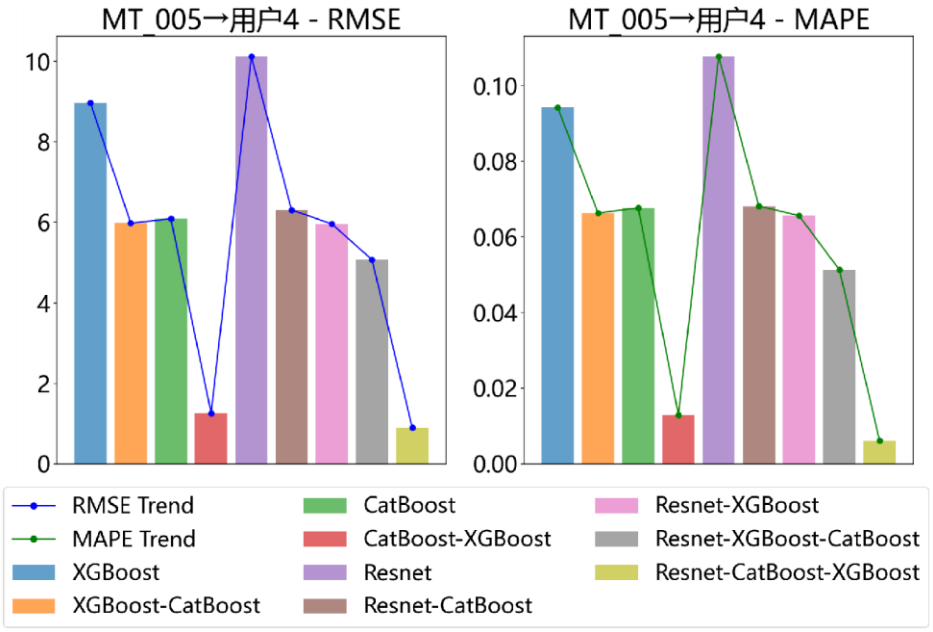


图 **4.8** 从 MT_005 迁移用户 4 的评价指标平均值

Fig **4.8** Average value of evaluation indicators from MT_005 to user 4

以 MT_005 为源域，用户 5 为目标域的各模型评价指标平均值如图 4.9。

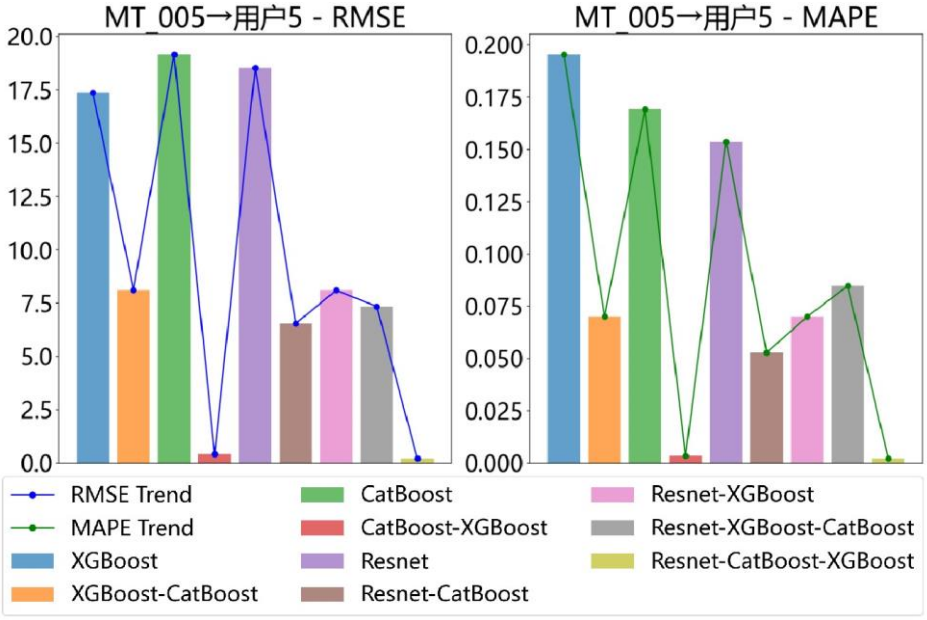


图 **4.9** 从 MT_005 迁移用户 5 的评价指标平均值

Fig **4.9** Average value of evaluation indicators of migrated from MT_005 to user 5

以 MT_005 为源域，用户 6 为目标域的各模型评价指标平均值如图 4.10。

中国知网 https://www.cnki.net

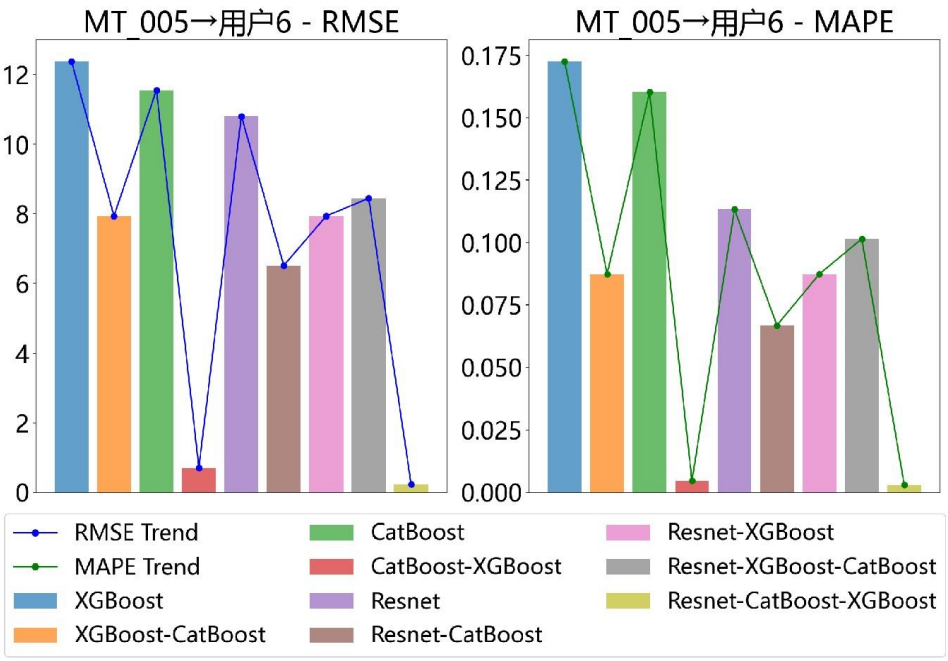


图 **4.10** 从 MT_005 迁移用户 6 的评价指标平均值

Fig **4.10** Average value of evaluation indicators migrated from MT_005 to user 6

不难看出，本章提出的方法在这三个迁移任务中的表现都十分的优异，不难看出，在大多数情况下，采用集成模型的方法能够显著提高预测准确度，相较于单一模型，集成模型展现出了更高的性能。这一结果充分证明了集成学习策略在迁移学习中的有效性和潜力。然而 Resnet-XGBoost-CatBoost 集成模型中实验发生负迁移现象，其在所有集成模型的表现中是最差的，并且也是集成模型数量最多的一个，错误的集成策略不仅无法发挥出各单一模型的最大潜力，反而可能导致整体性能的大幅度下降。由此可见，集成模型的构建并非简单的模型堆砌，其背后需要深思熟虑的策略和精确的执行。因此 Stacking 技术对模型集成的先后顺序要依据各个模型的特性，否则会达到事倍功半的效果。

为加强验证本章模型的泛化性，本节将以 MT_005 为目标域，使用其他三个用户的负荷数据来预测 MT_005 地区 2013 年 12 月至 2014 年 12 月，每个月第三周的 7 天来考察模型，使用 RMSE 和 MAPE 对每个模型的性能进行评估。以用户 4 为源域，MT_005 为目标域的各模型评价指标平均值如图 4.11。

中国知网 https://www.cnki.net

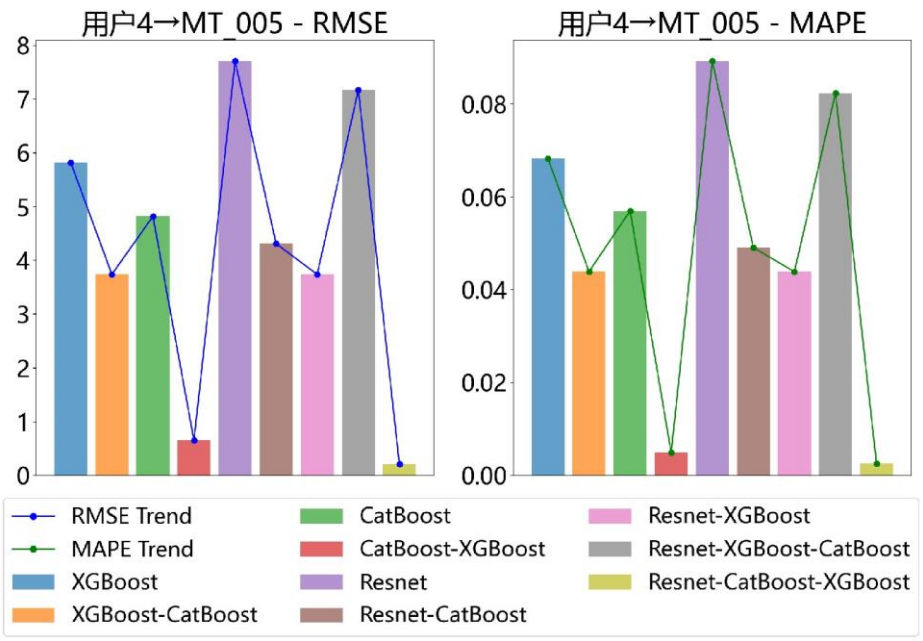


图 **4.11** 从用户 4 迁移到 MT_005 的评价指标平均值

Fig **4.11** Average value of evaluation indicators migrated from user 4 to MT_005

以用户 5 为源域，MT_005 为目标域的各模型评价指标平均值如图 4.12。

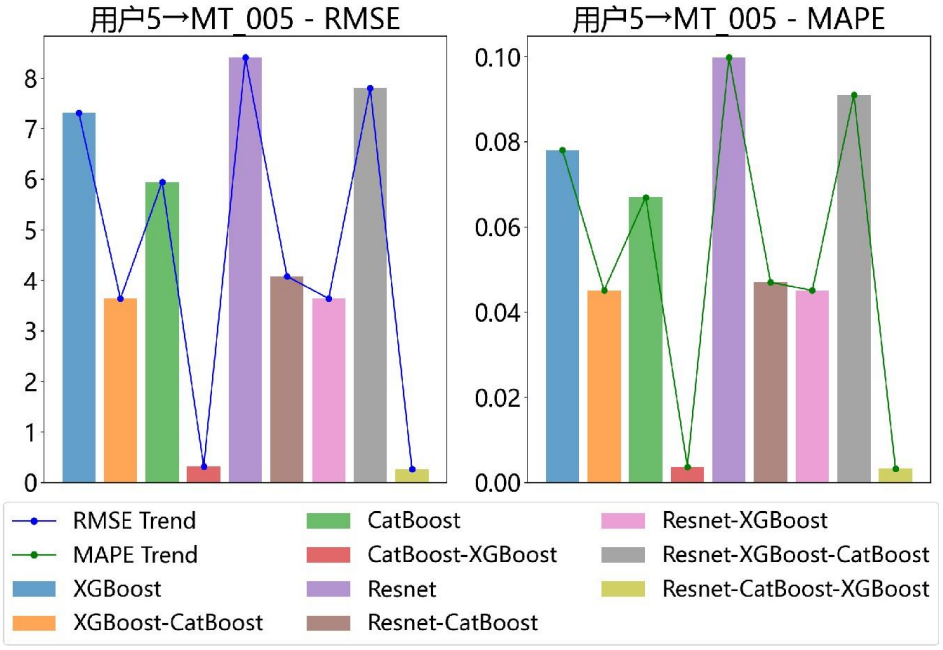


图 **4.12** 从用户 5 迁移到 MT_005 的评价指标平均值

Fig **4.12** Average value of evaluation indicators migrated from user 5 to MT_005

以用户 6 为源域，MT_005 为目标域的各模型评价指标平均值如图 4.13。

中国知网 https://www.cnki.net

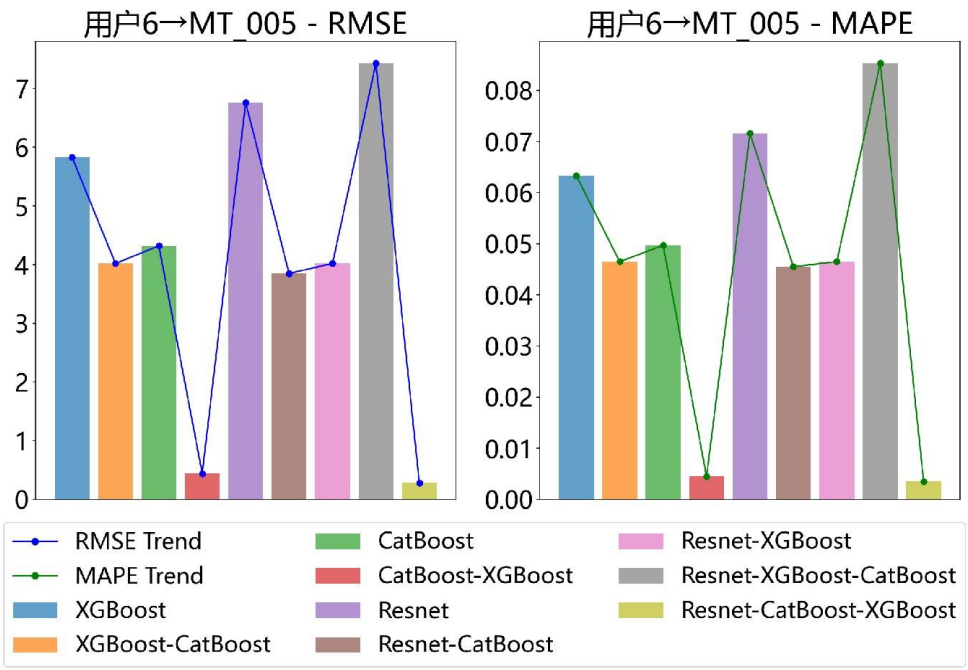


图 **4.13** 从用户 6 迁移到 MT_005 的评价指标平均值

Fig **4.13** Average value of evaluation indicators migrated from user 6 to MT_ 005

表 4.5 展示的是各个模型在 MT_005 作为源域的迁移策略性能指标值，A 表示 XGBoost 模型，B 表示 CatBoost 模型，C 表示 ResNet 模型，其中 C-B-A 模型为本章提出的 Resnet-CatBoost-XGBoost 模型。

表 4.5 MT_005 作为源域的迁移策略性能

Table 4.5 Migration policy performance of MT_005 as a source domain

迁移策略	MT_005→用户 4		MT_005→用户 5		MT_005→用户 6	
评价指标	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE
A	8.97	9.42%	17.37	19.54%	12.38	17.25%
A-B	5.98	6.63%	8.10	7.00%	7.94	8.74%
B	6.09	6.77%	19.15	16.92%	11.56	16.02%
B-A	1.26	1.29%	0.43	0.34%	0.71	0.47%
C	10.12	10.77%	18.52	15.37%	10.81	11.33%
C-B	6.308	6.82%	6.54	5.29%	6.52	6.69%
C-A	5.96	6.56%	8.10	7.00%	7.94	8.74%
C-A-B	5.07	5.13%	7.34	8.48%	8.45	10.15%
本章模型	0.90	0.62%	0.21	0.22%	0.23	0.31%

各个模型在 MT_005 作为目标域的迁移策略性能指标值如表 4.6 所示，A

中国知网 https://www.cnki.net

表示 XGBoost 模型，B 表示 CatBoost 模型，C 表示 ResNet 模型，其中 C-B-A 模型为本章提出的 Resnet-CatBoost-XGBoost 模型。

表 4.6 MT_005 作为目标域的不同迁移策略性能

Table 4.6 Performance of different migration strategies for MT_005 as a target domain

迁移策略	用户 4→MT_005		用户 5→MT_005		用户 6→MT_005	
评价指标	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE
A	5.82	6.83%	7.31	7.81%	5.83	6.33%
A-B	3.74	4.39%	3.64	4.51%	4.02	4.65%
B	4.82	5.70%	5.95	6.70%	4.32	4.97%
B-A	5.82	6.83%	7.31	7.81%	5.83	6.33%
C	7.71	8.93%	8.41	9.98%	6.76	7.16%
C-B	4.31	4.91%	4.08	4.70%	3.85	4.55%
C-A	3.74	4.39%	3.64	4.51%	4.02	4.65%
C-A-B	7.17	8.24%	7.80	9.10%	7.43	8.53%
本章模型	0.65	0.49%	0.32	0.37%	0.44	0.45%

通过表 4.5 和表 4.6 不难看出，集成模型在绝大多数的迁移任务中都表现得比单一模型好，但是集成模型的顺序不一致也会导致模型性能发生变化，甚至导致模型发生负迁移现象，本章提出的模型在所有迁移任务中均表现得十分优异，并且与其他模型相比，本章提出的模型性能波动幅度不大。

各模型在不同数据集的所有迁移任务中平均性能指标如图 4.14 所示。

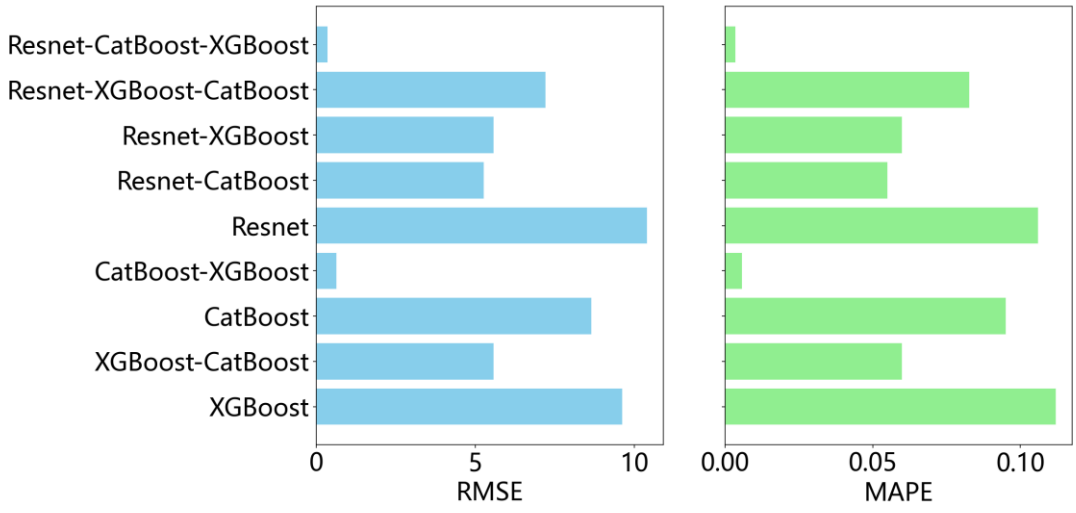


图 **4.14** 不同数据集的所有迁移任务中平均性能指标

Fig **4.14** Average performance indicators of each model across all migration tasks

中国知网 https://www.cnki.net

从图 4.14 不难看出 Resnet-XGBoost-CatBoost 集成模型在所有集成模型中的性能表现相对较差，其平均 RMSE 和 MAPE 最高。这表明在某些迁移任务中，集成模型的顺序能够决定是否取得良好的预测结果，可能存在模型集成方式不合理或者在某些任务中的数据特征捕捉能力不足的问题。相比之下，单一模型的平均 RMSE 和 MAPE 均高于集成模型，这表明集成模型在这些任务中能够弥补单一模型的缺陷，并且模型集成有利于提升预测任务准确性。

本章模型的平均性能始终比其他模型高，并且性能指标的波动幅度也比较小，得益于 VMKPCA 的特征重构以及 Stacking 模型集成，使得三个模型发挥出最大的优势，提高模型的泛化性以及预测精准度。

4.5 本章小结

本章探讨基于残差网络的 Stacking 微调模型在短期电力负荷预测中的应用。通过 Stacking 方法结合不同模型的优势和 VMKPCA 的特征重构，能够在拥有少量目标预测区域的负荷样本，也能拥有较佳的预测精度，在相同地域不同用户以及不同地域不同用户的负荷预测迁移任务都完成得比较好。总结来说，实验结果显示出 VMPCA 的特征重构能力以及集成网络架构能够在短期电力负荷预测准确性方面有效提升。因此本章研究工作能够促进在目标预测区域负荷样本稀缺的极端情况下跨区域短期电力负荷预测的应用。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 总结

目前我国正在进行新型电力系统的转型，很多地区正在进行源网荷储一体化，都离不开电力负荷预测。传统的配网系统是依靠地区负荷作为主要基准，目前电力数字化转型期间，电力行业的专家提出对用电需求要实现准确预测、灵活调配电量资源、增强配网的平衡性与韧性等方面的新需求。精准的电力负荷预测给电网的运行提供保障，同时也给电力系统规划与电力系统转型提供可靠的依据。传统的机器学习模型在对同一用户的负荷预测实现较为精准的预测，但是不同用户使用同一个模型进行预测并且其中一个用户缺少大量负荷数据的情况下，传统的机器学习模型往往表现不佳，其中原因是其泛化能力弱。

针对这一问题，本文运用域自适应技术的方法，研究负荷数据稀缺的短期电力负荷预测问题。本文主要研究工作与研究结果总结如下：

（1）传统的短期电力负荷预测方法需要大量完整的历史电力负荷数据并且训练数据和测试数据要来自相同的概率分布。因此导致传统模型泛化能力弱的问题。传统模型在单源数据训练的效果十分显著，但是将训练后的模型迁移到不同区域的负荷数据时，会导致模型预测效果不佳，模型就会出现负迁移现象。为解决这个问题，本文提出一种基于域自适应技术的域自适应权重矩阵(DAWM)以及定义协方差差异相似性对比度(CDSC)损失函数来缩小源域和目标域的分布差异，即使目标域电力负荷数据缺失，仍可以使用源域训练模型来预测目标域。本文通过使用 5 种目前主流的预测方法，使用 Electricity Load Diagrams 2011-2014 Dataset 数据集的 3 个站点负荷数据，三个站点两两互相迁移，实现对不同站点之间负荷数据的知识迁移，解决传统模型的负迁移现象，通过多个评价指标来证明本文模型的泛化能力优于其他传统模型。

（2）针对电力系统训练样本有限的情景，本文提出一种残差网络的 Stack 微调模型，在方法 1 的基础上，引入机器学习的 Stacking 方法和深度学习模型残差网络，提出变分多核主成分分析法并使用域自适应中的模型微调方法实现不同区域之间的电力负荷预测，其中通过在佛山采集的工商业用户的数据集，进行实验验证基于相同地域不同用户的迁移。为验证该方法的泛化性，又将佛山工商业

中国知网 https://www.cnki.net

的三个用户数据和第三章的数据集的一个站点数据进行跨时间以及跨地域的相互迁移，从多个评价指标验证方法的可靠性。

5.2 展望

本文提出的两个基于域自适应技术的短期电力负荷预测模型从多个评价指标检验其有效性，但仍然意识到本文存在的一些不足，仍需要进一步的研究，后续的研究工作将主要集中于以下两点：

（1）目前大多数负荷预测模型对正常天气时的短期电力负荷进行预测，精度都十分高，后续应当考虑极端情况下的负荷预测的研究。例如极端天气条件、突发事件或系统故障，可能会导致负荷数据出现异常值。目前基于域自适应技术的负荷预测模型在处理极端情况方面仍有所不足。未来的研究将在模型设计阶段引入异常值检测方法，以确保模型输入数据的质量。引入注意力机制或自适应网络层，使模型能够自动识别并适应异常数据点，加强模型对时间序列和空间分布的综合分析能力并且实现极端天气情况下两个地域相邻用户之间的迁移任务。

（2）电力公司目前采用的负荷预测模型大部分都具有可解释性。虽然基于域自适应技术的短期电力负荷预测模型在准确性和泛化能力上取得显著进展，但模型的解释性不足导致在实际应用中，电力公司对该技术的认可度低。为增强域自适应负荷预测模型的可解释性，未来的研究工作将集中在设计可解释性的方法和技术上。探索模型中间层的特征表示来解释模型的决策过程，通过分析模型对特定输入样本，可视化模型的决策依据，提高模型决策过程的透明度。

中国知网 https://www.cnki.net

参 考 文 献

[1] 刘艳, 陈玛玲. 绿色动能促“双碳”优质电力更强劲[N]. 厦门日报, 2024-01-26(A07).

[2] 莫非. 服务“双碳”目标构建新型电力系统[N]. 中国电力报, 2024-02-27(001).

[3] 张智刚, 康重庆. 碳中和目标下构建新型电力系统的挑战与展望[J]. 中国电机工程学报, 2022, 42(08): 2806-2819.

[4] 邱燕超. 以数字化信息化手段提升电力安全管理水平[N]. 中国电力报, 2023-06-19(006).

[5] 赵永平, 刘志强, 丁怡婷. 推动能源转型服务发展大局[N]. 人民日报, 2024-02-26(001).

[6] Box G E P, Jenkins G M, Reinsel G C. Time series analysis forecasting and control - Rev. ed[J]. Journal of Time, 1976, 31(2): 238-242.

[7] 梁露, 张智晟. 基于多尺度特征增强 DHTCN 的电力系统短期负荷预测研究[J]. 电力系统保护与控制, 2023, 51(10): 172-179.

[8] Kim D, Lee D, Nam H, et al. Short-Term Load Forecasting for Commercial Building Using Convolutional Neural Network (CNN) and Long Short-Term Memory (LSTM) Network with Similar Day Selection Model[J]. Journal of Electrical Engineering & Technology, 2023, 18(6): 4001-4009.

[9] Xiao X, Mo H D, Zhang Y A, et al. Meta-ANN e A dynamic artificial neural network refined by meta- learning for Short-Term Load Forecasting[J]. Energy, 2022, 246: 123418.

[10] Zhang Y L. Short-Term Power Load Forecasting Based on SAPSO-CNN-LSTM Model considering Autocorrelated Errors[J]. Mathematical Problems in Engineering, 2022, 2022: 10.

[11] 任建吉, 位慧慧, 邹卓霖, 等. 基于 CNN-BiLSTM-Attention 的超短期电力负荷预测[J]. 电力系统保护与控制, 2022, 50(08): 108-116.

[12] Hua H, Liu M P, Li Y Q, et al. An ensemble framework for short-term load forecasting based on parallel CNN and GRU with improved ResNet[J]. Electric Power Systems Research, 2023, 216: 109057.

[13] Bento P M R, Pombo J A N, Calado M R A, et al. Stacking Ensemble Methodology Using Deep Learning and ARIMA Models for Short-Term Load Forecasting[J]. Energies, 2021, 14(21): 21.

[14] Tarmanini C, Sarma N, Gezegin C, et al. Short term load forecasting based on ARIMA and ANN approaches[J]. Energy Reports, 2023, 9: 550-557.

[15] Zhang S Y, Chen R H, Cao J C, et al. A CNN and LSTM-based multi-task learning architecture for short and medium-term electricity load forecasting[J]. Electric Power Systems Research, 2023, 222: 109507.

[16] 方娜, 陈浩, 邓心, 等. 基于 VMD-ARIMA-DBN 的短期电力负荷预测[J]. 电力系统及其

中国知网 https://www.cnki.net

自动化学报, 2023, 35(6): 59-65.

[17] Dudek G, Pelka P, Smyl S. A Hybrid Residual Dilated LSTM and Exponential Smoothing Model for Midterm Electric Load Forecasting[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(7): 2879-2891.

[18] Deng X Z, Ye A S, Zhong J S, et al. Bagging-XGBoost algorithm based extreme weather identification and short-term load forecasting model[J]. Energy Reports, 2022, 8: 8661-8674.

[19] Yang Q Y, Lin Y Y, Kuang S S, et al. A novel short-term load forecasting approach for data-poor areas based on K-MIFS-XGBoost and transfer-learning[J]. Electric Power Systems Research, 2024, 229: 110151.

[20] Yao X T, Fu X L, Zong C F. Short-Term Load Forecasting Method Based on Feature Preference Strategy and LightGBM-XGboost[J]. IEEE Access, 2022, 10: 75257-75268.

[21] Zhang L J, Jánosík D. Enhanced short-term load forecasting with hybrid machine learning models: CatBoost and XGBoost approaches[J]. Expert Systems with Applications, 2024, 241: 122686.

[22] Zhang Q, Wu J J, Ma Y, et al. Short-term load forecasting method with variational mode decomposition and stacking model fusion[J]. Sustainable Energy, Grids and Networks, 2022, 30: 100622.

[23] Zhao X, Li Q S, Xue W L, et al. Research on Ultra-Short-Term Load Forecasting Based on Real-Time Electricity Price and Window-Based XGBoost Model[J]. Energies, 2022, 15(19): 7367.

[24] 姜建国, 万成德, 陈鹏, 等. 基于 1DCNN-LSTM 和迁移学习的短期电力负荷预测[J]. 吉林大学学报(信息科学版), 2023, 41(01): 124-130.

[25] Zou H B, Yang Q H, Chen J T, et al. Short-term Power Load Forecasting Based on Phase Space Reconstruction and EMD-ELM[J]. Journal of Electrical Engineering & Technology, 2023, 18(5): 3349-3359.

[26] 杨汪洋, 魏云冰, 罗程浩.基于 CVMD-TCN-BiLSTM 的短期电力负荷预测*[J/OL].电气工学报:1-10[2024-04-10].http://kns.cnki.net/kcms/detail/10.1289.TM.20230601.1229.002.html.

[27] 朱伟, 孙运全, 钱尧, 等. 基于 CEEMD-GRU 模型的短期电力负荷预测方法[J]. 电测与仪表, 2023, 60(1): 16-22.

[28] 朱莉, 韩凯萍, 朱春强. 二次分解策略组合 Informer 的短期电力负荷预测方法[J]. 国外电子测量技术, 2023, 42(6): 23-32.

[29] 赵星宇, 吴泉军, 朱威. 基于CEEMDAN和TCN-LSTM模型的短期电力负荷预测[J]. 科学技术与工程, 2023, 23(4): 1557-1564.

[30] Massaoudi M, Refaat S S, Chihi I, et al. A novel stacked generalization ensemble-based hybrid LGBM-XGB-MLP model for Short-Term Load Forecasting[J]. Energy, 2021, 214: 14.

[31] Jiang Q, Cheng Y X, Le H Z, et al. A Stacking Learning Model Based on Multiple Similar

中国知网 https://www.cnki.net

Days for Short-Term Load Forecasting[J]. Mathematics-Basel, 2022, 10(14): 20.

[32] 万成德. 基于深度学习和迁移学习的短期电力负荷预测[D]. 大庆: 东北石油大学, 2022.

[33] Li S W, Wu H B, Wang X M, et al. Short-term load forecasting based on AM-CIF-LSTM method adopting transfer learning[J]. Frontiers in Energy Research, 2023, 11: 1162040.

[34] Qinyi B, Dongbin H, Ling X. Optimized Transfer Learning Based Short-term Electrical Load Interval Prediction[J]. Journal of Physics: Conference Series, 2023, 2661(1): 012033.

[35] 刘世昌, 金敏. 多尺度分析与数据互迁移相结合的短期电力负荷预测方法[J]. 计算机科学, 2018, 45(7): 315-321.

[36] 顾吉鹏, 邵亮, 陆垂基, 等. 基于 LSTNet 模型的配电台区短期电力负荷预测研究[J]. 电气传动, 2023, 53(5): 63-70.

[37] 王峰. 基于 IPSO 算法的短期电力负荷预测模型研究[J]. 自动化仪表, 2023, 44(4): 22-26.

[38] 程红利, 黄文焘, 姜庆超, 等. 基于变分模态分解的中期电力负荷混合预测模型[J]. 应用科技, 2023, 50(6): 48-55.

[39] 钟士元, 张文锦, 罗路平, 等. 基于行业聚类电量曲线分解的中期负荷预测[J]. 电力建设, 2022, 43(2): 81-88.

[40] 邓斌, 张楠, 王江, 等. 基于 LTC-RNN 模型的中长期电力负荷预测方法[J]. 天津大学学报, 2022, 55(10): 1026-1033.

[41] 王凌谊, 王志敏, 钱纹, 等. 基于迁移学习的中长期电力负荷预测[J]. 供用电, 2022, 39(3): 69-74.

[42] 王艳松, 申晓阳, 李强, 等. 基于 PCA-GRD-LWR 模型的海上油田中长期最大电力负荷预测[J]. 中国石油大学学报（自然科学版）, 2023, 47(2): 129-135.

[43] 蔡华锋, 唐艺豪. 基于 Pyraformer 网络的短期电力负荷预测[J]. 武汉大学学报(工学版), 2023, 56(9): 1105-1113.

[44] 李丹, 孙光帆, 缪书唯, 等. 基于多维时序信息融合的短期电力负荷预测方法[J]. 中国电机工程学报, 2023, 43(S1): 94-106.

[45] 张雪, 肖秦琨. CEEMDAN 组合 DISPSO-LSTM 的短期电力负荷预测[J]. 西北工业大学学报, 2021, 41(4): 461-469.

[46] 韩雅萱, 石梦舒, 黄元生, 等. 基于机器学习的短期电力负荷预测方法比较及改进研究[J]. 科技管理研究, 2023, 43(1): 163-170.

[47] Dong X, Deng S, Wang D. A short-term power load forecasting method based on k-means and SVM[J]. Journal of Ambient Intelligence and Humanized Computing, 2022, 13(11): 5253-5267.

[48] Shi H F, Miao K, Ren X C. Short-term load forecasting based on CNN-BiLSTM with Bayesian optimization and attention mechanism[J]. Concurrency and Computation: Practice and Experience, 2023, 35(17): e6676.

[49] Ullah F U M, Ullah A, Khan N, et al. Deep Learning-Assisted Short-Term Power Load

中国知网 https://www.cnki.net

Forecasting Using Deep Convolutional LSTM and Stacked GRU[J]. Complexity, 2022, 2022: 15.

[50] Wan A P, Chang Q, AL-Bukhaiti K, et al. Short-term power load forecasting for combined heat and power using CNN-LSTM enhanced by attention mechanism[J]. Energy, 2023, 282: 128274.

[51] 杨健, 孙涛, 陈小龙, 等. 基于 VMD-EWT-IASSP-EBILSTM 的短期电力负荷预测[J]. 科学技术与工程, 2023, 23(27): 11646-11654.

[52] Anping W, Qing C, Khalil A-B, et al. Short-term power load forecasting for combined heat and power using CNN-LSTM enhanced by attention mechanism[J]. Energy, 2023, 282: 128274.

[53] Niu D X, Yu M, Sun L J, et al. Short-term multi-energy load forecasting for integrated energy systems based on CNN-BiGRU optimized by attention mechanism[J]. Applied Energy, 2022, 313: 118801.

[54] Nan W, Lihua Y, Chao L, et al. Short-term load forecasting using detrend singular spectrum fluctuation analysis[J]. Energy, 2022, 256: 124722.

[55] Zou Z Q, Wang J, Ning E, et al. Short-Term Power Load Forecasting: An Integrated Approach Utilizing Variational Mode Decomposition and TCN-BiGRU[J]. Energies, 2023, 16(18): 6625.

[56] 赵茂胜, 段嘉琪, 肖政杰. 基于 PSO-RBF 的短期电力负荷预测模型[J]. 电子设计工程, 2023, 31(14): 127-131,136.

[57] 赵齐昌. 基于 XGBoost-LSTM 组合模型的电力负荷预测研究[D]. 汉中: 陕西理工大学, 2022.

[58] Yi S Y, Liu H C, Chen T, et al. A deep LSTM-CNN based on self-attention mechanism with input data reduction for short-term load forecasting[J]. IET Generation, Transmission & Distribution, 2023, 17(7): 1538-1552.

[59] 张启阳, 陈希亮, 曹雷, 等. 深度强化学习中的知识迁移方法研究综述[J]. 计算机科学, 2023, 50(5): 201-216.

[60] 黄荷, 陈杰, 李毅靖, 等. 基于 GRU-MMD 的电力数据挖掘方法[J]. 工业加热, 2021, 50(10): 61-65.

[61] 李晶晶, 孟利超, 张可, 等. 领域自适应研究综述[J]. 计算机工程, 2021, 47(6): 1-13.

[62] 赵鹏飞. 基于深度残差网络的短期电力负荷预测研究[D]. 成都: 电子科技大学, 2022.

[63] 盛镕镕. 基于 LSTM 和 ResNet 的短期电力负荷预测研究[D]. 苏州: 苏州大学, 2022.

[64] 李翔. 基于模型融合的短期电力负荷预测[D]. 无锡: 江南大学, 2023.

[65] He Y Y, Xiao J L, An X L, et al. Short-term power load probability density forecasting based on GLRQ-Stacking ensemble learning method[J]. International Journal of Electrical Power & Energy Systems, 2022, 142: 108243.

[66] 王士彬, 何鑫, 余成波, 等. VMD-Stacking 集成学习的多特征变量短期负荷预测模型[J].

中国知网 https://www.cnki.net

兵器装备工程学报, 2024, 45(02): 218-224.

[67] 朱国森. 基于 Stacking 与 Prophet 组合模型的短期电力负荷预测[D]. 合肥: 安徽理工大学, 2021.

[68] 吕奇. 基于特征工程及 XGBoost 算法的超短期电力负荷预测[D]. 沈阳: 沈阳农业大学, 2023.

中国知网 https://www.cnki.net