分类号：TP183
密　级：公开
UDC：004
编　号：2024Y210854000350

青海大学

2021级攻读硕士学位研究生毕业论文

基于多任务学习和迁移学习的综合能源系统短期负荷预测研究

Research on multi-energy load forecasting of integrated energy systems based on multi-task learning and transfer learning

指导教师：梅生伟　教授
学生姓名：朱苏洵
学科专业名称：计算机技术
研究方向：负荷预测
学院(系、部)：计算机技术与应用学院
授予学位日期：2024 年 6 月 11 日

中国知网　https://www.cnki.net

Qinghai University Master Dissertation

Research on multi-energy load forecasting of integrated energy systems based on multi-task learning and transfer learning

Supervisor: Shengwei Mei

Candidate: Suxun Zhu

Academic Major Applied for: Computer Technology

Specific Major: Load Forecasting

College (Department): College of Computer Technology and Applications

Date of grant of degree: June 11, 2024

中国知网 https://www.cnki.net

基于多任务学习和迁移学习的综合能源系统短期负荷预测研究

中文摘要

综合能源系统作为传统电力系统向新型电力系统转型的重要物理载体，能实现多元化能源供应，提高能源利用效率。准确的负荷预测是保证综合能源系统的可靠调度和高效经济运行的前提和基础，但是，目前综合能源系统负荷预测面临着三个主要难题：负荷与多变量影响因素之间复杂相关性提取难；各类能源之间耦合关系复杂且负荷随机性强；历史负荷数据不足产生的“小样本”问题。针对这些问题，本文系统地展开了综合能源系统短期负荷预测研究，主要工作有：

（1）针对多变量输入中关键特征信息提取不全面的问题，提出了基于时间模式注意力机制和卷积网络-端到端模型的短期电力负荷预测方法。首先，基于先验知识构建多变量特征输入。然后，采用卷积网络和端到端模型提取时空特征。在此基础上，引入时间模式注意力机制分析各变量之间的隐藏联系，对时序权重进行差异化分配。

（2）针对多能耦合复杂、负荷随机性强的问题，提出了基于季节趋势分解和卷积式渐进提取多任务学习的短期多元负荷预测方法。首先，应用季节趋势分解将负荷中规律信息和不确定性信息建模为可解释的分量。接着，对多元负荷分量进行联合建模。以卷积网络提取更深层的特征信息，以长短期记忆网络学习时间依赖关系。同时，显式分离专家网络分别学习多元负荷的共性和特性表征，并采用渐进式路由机制实现特定任务参数的逐步分离

（3）针对新建设综合能源系统历史数据不足的问题，提出了基于多变量时序数据生成和迁移学习的短期小样本负荷预测方法。首先，通过多变量时间序列生成的变分自动编码器学习目标域数据的潜在空间表示，丰富和扩充目标域数据集。接着，采用最大均值差异衡量源域和目标域数据的相似性，从中选择与目标域高相关的样本训练迁移模型。最后，构建包含增强模型和迁移模型的集成预测方法。

综上，本文针对综合能源系统负荷预测面临的挑战，以相关深度学习技术为支撑，开展了短期负荷预测算法的研究，取得了良好的效果。

关键词：综合能源系统，多任务学习，迁移学习，多元负荷预测

中国知网 https://www.cnki.net

RESEARCH ON SHORT-TERM LOAD FORECASTING OF INTEGRATED ENERGY SYSTEMS BASED ON MULTI-TASK LEARNING AND TRANSFER LEARNING

Abstract

The integrated energy system is a crucial physical facilitator for the conversion of the conventional power system into a new kind of power system. It can achieve diversified energy supply and enhance the overall efficiency of using various energy sources. Accurate multi-energy load forecasting is a prerequisite and foundation to ensure reliable dispatch and economical operation of integrated energy systems. However, there are three main problems in load forecasting of the integrated energy system: the difficulty of extracting the complex correlation between the load and multi-variable influencing factors; the complex coupling relationship between energy sources and strong nonlinearity and stochasticity of the load; and the "small sample" problem caused by insufficient historical data. With these issues in mind, this paper conducts systematic study on short-term load forecasting of the integrated energy system. The primary works are:

(1) A short-term load forecasting approach based on temporal pattern attention mechanism and convolutional network-sequence-to-sequence model is suggested, aiming at the problem of incomplete extraction of key feature quantities in multi-variable input features. First, multivariate input features are constructed based on prior knowledge. Then, a convolutional network and a sequence-to-sequence model are used to extract spatiotemporal features. Based on this, a temporal pattern attention mechanism is introduced to analyze the hidden connections between variables and perform differential allocation of temporal weights. Experimental results show that models based on temporal pattern attention mechanisms have better prediction results compared to models based on traditional attention mechanisms.

中国知网 https://www.cnki.net

(2) A short-term multi-energy load forecasting approach based on seasonal-trend decomposition and convolutional progressive extraction multi-task learning is provided, aiming at the issues of complex multi-energy coupling and strong load randomness. The regular and uncertain information in the load is first modeled into interpretable components using seasonal trend decomposition. Next, the multivariate load components are jointly modeled. A convolutional network is built to extract deeper feature information, and a long- and short-term memory network is used to learn time-series dependencies. At the same time, task-sharing experts and task-specific experts are constructed to learn the commonality and characteristic representation of multiple loads, respectively, and use a progressive routing mechanism to gradually separate specific task parameters. According to the experimental findings, the suggested decomposition-joint prediction model outperforms the multi-task models already in use in terms of prediction accuracy.

(3) A short-term, small-sample load forecasting method based on multivariate time-series data generation and transfer learning is proposed to address the problem of insufficient historical data for newly constructed integrated energy systems. First, a latent spatial representation of the target domain data is learned by a variational autoencoder generated from multivariate time series to enrich and expand the target domain data set. Then, the maximum mean difference is used to measure the similarity of the source and target domain data, and samples more relevant to the target domain are selected to train the migration model. Finally, an integrated prediction method including the augmentation model and the migration model is constructed. The approach can successfully optimize the prediction accuracy of small sample load data, according to experimental results.

In summary, this paper addresses the challenges of integrated energy system load forecasting, supports relevant deep learning technology, and conducts research on short-term load forecasting algorithms, achieving good results.

Keywords: Integrated energy system, Multi-task learning, Transfer learning, Multi-energy load forecasting.

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 课题背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 单一负荷预测研究.....3
1.2.2 多元负荷预测研究.....5
1.2.3 小样本负荷预测研究.....7
1.3 研究内容及章节安排.....9
第二章 基于 TPA 机制和 CNN-Seq2seq 的单一负荷预测.....11
2.1 概述.....11
2.2 电力负荷影响因素的分析.....11
2.2.1 基于先验知识的最近负荷选取.....12
2.2.2 基于先验知识的气象特征选取.....12
2.2.3 基于先验知识的时间特征选取.....12
2.2.4 输入特征集的构造.....13
2.3 负荷预测模型的构建.....13
2.3.1 基于 CNN-Seq2seq 的时空特征提取.....13
2.3.2 基于 TPA 机制的关键信息处理.....16
2.3.3 模型整体框架.....17
2.4 算例分析.....17
2.4.1 数据来源与实验环境.....17
2.4.2 数据预处理及评价指标.....17
2.4.3 超参数设置.....18
2.4.4 预测结果分析.....19
2.5 本章小结.....21
第三章 基于 STL 和 CPLE 的多元负荷预测.....22
3.1 概述.....22
3.2 负荷特性分析.....22
3.2.1 多能耦合分析.....22
3.2.2 多能负荷分解预测.....24
3.2.3 多能负荷分量影响因素分析.....25
3.3 负荷预测模型的构建.....26
3.3.1 基于 PLE 的共享方法.....26
3.3.2 模型整体框架.....28
3.4 算例分析.....30

中国知网 https://www.cnki.net

3.4.1 数据来源与实验环境.....30
3.4.2 评价指标.....30
3.4.3 输入特征选择和数据集划分.....30
3.4.4 实验框架.....31
3.4.5 不同单任务预测模型比较.....33
3.4.6 不同多任务预测模型比较.....35
3.4.7 消融实验.....38
3.4.8 不同负荷分解方法比较.....38
3.5 本章小结.....40
第四章 基于 TimeVAE 和迁移学习的小样本负荷预测.....41
4.1 概述.....41
4.2 基于 TimeVAE 的数据增强.....41
4.3 基于 MMD 的参数迁移.....43
4.4 负荷预测的集成框架.....45
4.5 算例分析.....47
4.5.1 数据来源与实验环境.....47
4.5.2 评价指标.....47
4.5.3 输入数据处理.....47
4.5.4 参数设置.....48
4.5.5 不同迁移学习策略比较.....49
4.5.6 不同数据增强方法比较.....51
4.5.7 不同预测模型比较.....52
4.5.8 消融实验.....53
4.6 本章小结.....54
第五章 总结与展望.....55
5.1 总结.....55
5.2 展望.....56
参考文献.....57

中国知网 https://www.cnki.net

插图目录

图 1-1 研究内容及章节关系 10
图 2-1 负荷影响因素分析 12
图 2-2 CNN-Seq2seq 结构图 14
图 2-3 一维卷积原理 14
图 2-4 LSTM 结构图 15
图 2-5 TPA 结构图 16
图 2-6 整体预测流程图 17
图 2-7 模型预测结果对比 20
图 3-1 IES 与用户侧的交互结构 23
图 3-2 负荷预测曲线 24
图 3-3 不同多任务方法的框架 27
图 3-4 PLE 的具体结构 28
图 3-5 预测方法整体流程 29
图 3-6 相关性分析热图 31
图 3-7 实验框架 32
图 3-8 单任务模型的电、热、冷负荷预测曲线比较 34
图 3-9 多任务模型的电、热、冷负荷预测曲线比较 37
图 3-10 不同分解方法下的电、热、冷负荷预测曲线比较 39
图 4-1 TimeVAE 模型架构 42
图 4-2 迁移学习策略 44
图 4-3 整体框架 46
图 4-4 目标域 IES 的电、冷负荷数据 48
图 4-5 基于 MIC 的定量分析热图 48
图 4-6 不同迁移学习策略的评价指标 50
图 4-7 不同数据增强策略的评价指标 51
图 4-8 不同模型的负荷预测曲线 52
图 4-9 基于不同改进模块的预测结果 54

中国知网 https://www.cnki.net

插表目录

表 2-1 输入特征集 13
表 2-2 CNN 网络结构不同参数实验对比 18
表 2-3 超参数设置 19
表 2-4 模型预测结果比较 19
表 3-1 所提模型参数 29
表 3-2 对比模型参数 32
表 3-3 单任务预测结果的 MAPE、RMSE 和 WMA 评估指标 33
表 3-4 CPLE 模型与其他单任务模型的整体精度提升对比 35
表 3-5 多任务预测结果的 MAPE、RMSE 和 WMA 评估指标 36
表 3-6 CPLE 模型与其他多任务模型的整体精度提升对比 37
表 3-7 PLE 共享方法与其他共享方法的总体精度提升比较 37
表 3-8 CPLE 消融研究 38
表 3-9 不同负荷分解方法的 MAPE、RMSE 和 WMA 评估指标 40
表 4-1 数据增强后，不同迁移学习策略的比较 50
表 4-2 不同预测模型在目标域测试集的预测结果 52

中国知网 https://www.cnki.net

第一章 绪论

1.1 课题背景及意义

能源是人类社会发展的重要基础和动力，也是应对全球气候变化和实现可持续发展的关键因素。随着全球经济的快速增长，能源需求和消费持续上升。然而，化石能源的大量开发利用造成了严重的环境污染和温室气体排放[1,2]，使得能源危机和能源安全问题日益突出。为了应对这一挑战，各国纷纷设立符合各国国情的双碳目标，旨在加大对清洁可再生能源的开发利用，减少对化石燃料的依赖，推动能源消费方式和供给体系的变革[3]。

例如，欧盟成员国已采取了 3000 项政策和措施以应对气候变化所带来的严重影响。根据预测，欧洲各地已经实施的措施将使得 2030 年温室气体净排放总量（包括国际航空）减少 43%，而目前正在计划中的进一步措施将提高减排幅度至 48%。2021 年，美国重新加入《巴黎协定》，目标是到 2030 年将温室气体净排放量减少 50%至 52%，并启动了“全球甲烷承诺”，推动国内和国际气候行动。同时自 2021 年起，中国积极履行应对气候变化的《巴黎协定》，并推动国家自主贡献目标，认真开展有效、周密的行动，在实现碳达峰、碳中和方面取得重大进展。此外，中国已制定双碳目标的“1+N”政策框架以及控制温室气体排放中长期战略，加快全国碳市场建设，执行国家适应气候变化战略。

然而，根据国际能源署估计，2023 年全球与能源相关的二氧化碳排放比 2022 年增长了 1.1%，增加了约 4.1 亿吨，达到了 374 亿吨的新高[4]。这远非按照《巴黎协定》中规定的全球气候目标所要求的那样迅速下降。值得注意的是，由于清洁能源部署不断增加，排放量出现结构性放缓。2023 年排放量增长百分比大幅慢于全球 GDP 增长（约为 3%），延续了二氧化碳增长速度慢于全球经济活动的近期趋势。根据《2023 年油气行业发展报告》，2015 至 2023 年全球清洁能源投资快速上涨，从落后化石能源 18.94%到领先 65.71%[5]。可再生能源装机增量增长 75%至 540 吉瓦，电动汽车销量增长 35%至 1400 万辆[6]。其中，中国贡献了全球太阳能光伏、风电和电动汽车新增量的 60%，在全球清洁能源经济中占据压倒性领先地位。但由于清洁能源的增长不足以跟上不断增长的能源需求，中国与能源相关的二氧化碳排放量于 2022 年的下降转为 2023 年的上升。这一趋势表明，尽管在清洁能源领域取得了一些成就，但仍需积极推动能源绿色低碳转型，才能实现真正的碳排放减少。

中国知网 https://www.cnki.net

在能源改革过程中，综合能源系统（Integrated Energy System，IES）已被认为是适应可再生能源渗透和提高能源效率的有效方法[7]。它通过整合多种能源系统，如电力、燃气、热能和冷能等，实现了各类能源的综合利用。IES的核心优势在于其能够通过能量转换、储存和交换等方式，实现不同能源部门之间的物理耦合和最佳协调，从而提高整体能源效率并减少浪费[8,9]。

在 IES 中，负荷预测的准确性对于维持能源供需平衡至关重要[10]。准确的负荷预测能够帮助能源供应系统更好地满足实际需求，避免能源的过度供应或短缺，从而提高经济效益。例如，一个 10000 兆瓦的电厂，负荷预测误差减少 1%，每年可节省 160 万美元[11]。并且，随着可再生能源在能源系统中的比重增加，系统的不确定性和复杂性也随之增加。如光伏和风力发电，具有间歇性特点，这使得能源需求曲线变得更加不稳定。因此，在 IES 中进行准确的负荷预测变得更加重要，它有助于密切跟踪能源需求的变化，确保能源供应的稳定性。总之，IES的发展和优化需要依赖于准确的负荷预测技术，这对于提高能源效率、降低成本、减少环境影响以及适应可再生能源的渗透具有重要意义。

在此背景下，人工智能、大数据、区块链等数字化技术与电力技术的深度融合[12]，为能源电力转型释放了新价值。《“十四五”现代能源体系规划》明确提出要加快能源产业数字化发展；《新一代人工智能发展规划》明确提出以人工智能作为技术支撑，促进能源结构生态化建设；国家电网公司明确提出打造“数智化坚强电网”，深化新型电力系统构建。这些举措旨在通过融合新兴技术，推动能源领域向着清洁、高效、智能的未来迈进。因此，本文为解决 IES 负荷结构和特性带来的预测难题，以多任务学习、迁移学习等先进技术为支撑，开展 IES 短期负荷预测研究。旨在通过提高 IES 负荷预测的准确性和效率来优化能源供需平衡，提高可再生能源利用率，进而促进能源绿色低碳转型，为实现可持续发展目标提供强有力的技术支持。

1.2 国内外研究现状

负荷预测根据时间粒度可以分三类：超短期负荷预测、短期负荷预测、中长期负荷预测。分别如下：

（1）超短期负荷预测：预测单位从几分钟到几个小时。该类预测常用于流量控制，用于检测电力系统的稳定性并预测其备用容量，以防止电力调度不足的情况发生。

（2）短期负荷预测：预测单位为 1 小时至几周。该类预测常用于调整电力经济调度、分析电力供需和潮流、预测事故危机、企业运营和设备维护等。

中国知网 https://www.cnki.net

（3）中长期负荷预测：预测单位为 1 个月至 1 年至数年。这种预测通常用于估计峰值电力消耗和电力设备的维护以及电力政策研究。可用于检测发电机检修和停机时间，以及开发或建设新的发电机组，制定电力行业未来电力规划。

本文的研究目标是提高 IES 短期负荷预测的预测精度，以此来优化能源管理和规划以及实现能源高效利用。考虑综合能源系统目前存在的三大难题：负荷与多变量影响因素之间关键特征信息提取不全面；多能耦合关系复杂且负荷随机性强；历史负荷数据不足产生的“小样本”问题，从预测对象的角度出发[13]，展开对综合能源系统中的单一负荷预测、多元负荷预测以及小样本负荷预测的研究。

1.2.1 单一负荷预测研究

单一负荷预测关注于单一能源类型或单一用户的负荷预测。这种方式便于分析负荷与影响因素之间的关系，有助于更好的理解特定负荷模式和消费行为。这为后续多元负荷预测提供了理论和实践基础。

目前，现有的负荷预测方法多数集中于单一负荷的独立预测[14]，主要包括传统预测方法、机器学习预测方法和深度学习预测方法。传统的方法有卡尔曼滤波法、负荷求导法、指数平滑法、时间序列法等。例如，文献[15]将卡尔曼滤波算法应用于短期负荷预测，并利用小批量处理策略实现实时预测。文献[16]通过改进传统方法并结合分形理论和相似日理论，提出负荷求导法对历史数据进行处理，并通过实际案例验证了该方法的可行性。文献[17]研究了指数平滑模型中最佳平滑系数的确定方法，并通过增加近期数据权重、减少远期数据权重的策略，有效提高了电力系统负荷预测的准确性。文献[18]考虑到需求响应计划、插电式电动汽车充电以及分布式能源的使用，引入时间序列自回归综合移动平均和季节性自回归综合移动平均模型构建预测模型，并在德克萨斯州电力可靠性委员会提供的负荷数据上进行验证分析。上述方法结构简单，应用简便，能较为准确地描述单变量下负荷随时间的变化趋势，缺点是难以对多种负荷影响因素建模，非线性数据拟合弱。

机器学习法包括支持向量机、随机森林、粒子群优化、极限学习机等，文献[19]关注到支持向量机在负荷预测的潜力，以模拟退火算法优化支持向量机参数，提出了基于模拟退火支持向量机的预测模型，实证结果显示其预测性能优于自回归积分移动平均和广义回归神经网络模型。文献[20]通过集成多棵回归树并利用时间序列的季节性模式来处理负荷数据的非平稳性和复杂性问题。展现了随机森林方法在电力负荷预测中的高精度和强泛化能力。文献[21]通过粒子群优化算法优化所提长期负荷概率预测模型参数。文献[22]结合小波变换

中国知网 https://www.cnki.net

的集成策略和多个极限学习机构成的预测器并行运行，然后通过偏最小二乘回归进行最终预测，显著提升了预测性能。上述方法具有强大的非线性处理能力及学习能力，能够有效应对传统线性模型难以解决的复杂负荷预测问题，但此类方法在处理时间序列数据时仍存在局限性，缺少对时间变化规律捕捉和利用。此外，该类算法在面对大规模数据集时可能会遇到性能瓶颈，如计算效率低下、内存消耗大等问题，这在实际的电力系统负荷预测中可能成为限制因素，因为这些系统往往需要处理大量的历史数据以提高预测的准确性。同时，由于负荷受到多种因素的影响[23]，如天气条件、节假日、社会经济活动等，机器学习模型可能无法全面考虑所有这些影响因素，导致预测结果的偏差。

深度学习对数据的深层地挖掘能力使得它在负荷预测方向大放异彩。文献[24,25]用卷积神经网络（Convolutional Neural Networks，CNN）提取输入数据的高维特征实现负荷预测，其预测精度与机器学习方法对比更高。长短期记忆网络（Long Short-Term Memory，LSTM）是一种适合处理相互依赖特性数据的网络，文献[26]对传统前馈神经网络难以处理序列数据及循环神经网络没有长期记忆的问题，提出了基于LSTM的负荷预测模型。文献[27]用相较于LSTM参数更精简，收敛速度更快的门控循环神经网络（Gated Recurrent Neural Network，GRU）对动态时间序列建模。文献[28]建筑级别的负荷预测上将 LSTM 与基于 LSTM 的编码器解码器模型（Sequence to Sequence，Seq2Seq）对比，发现Seq2Seq表现更好。上述文献提出的预测模型由单一网络组成，虽然能很好处理时间序列数据的联系，但当数据序列较长或涉及多维特征的情况时，模型可能会因为无法全面的捕捉和利用所有的特征信息而出现信息丢失的问题[29,30]。特征信息的丢失可能会导致模型无法准确识别和反映数据中的微妙变化和关键模式，从而影响预测的准确率。此外，多维特征之间的相互作用也可能在单一网络模型中被简化或忽略，从而影响模型对复杂关系的捕捉能力。

为解决上述问题，有研究者通过组合模型的方式，学习复杂的变量变化[31,32]。组合模型能把多种模型的优势联合在一起，提高预测的准确性和泛化性。例如：在电负荷预测方面，文献[33]提出了一种基于注意力机制的编码器-解码器模型，以LSTM作为基本单元记忆时间信息；在热负荷预测方面，文献[34]针对暖通空调高能耗热的情况，将多层感知器神经网络和支持向量回归相结合建立预测模型；在冷负荷预测方面，文献[35]采用随机森林方法提取相关性高的参数作为输入变量，并通过改进的并行鲸鱼优化算法对极限学习机的网络参数进行优化。上述方法虽然在建模负荷的时间相关性方面表现良好，但忽略了多变量输入之间的高维空间关系。

综上所述，传统预测方法简单易用但难以处理多因素和非线性问题。机器

中国知网 https://www.cnki.net

学习方法能处理非线性问题但不适合大规模数据。深度学习，尤其是 LSTM 和 CNN，在负荷预测中表现出色，但可能在处理长序列或多维特征时丢失信息。为提高预测精度，有研究者采用组合模型，充分发挥不同方法的优势。目前，组合模型已成为负荷预测领域的主流方法。然而，对于负荷与其影响因素之间的时空依存关系，现有组合模型仍然存在一定的局限性。

1.2.2 多元负荷预测研究

随着能源系统变得更加复杂，涉及多种能源类型（如电力、热能、气体等），多元负荷成为了一个重要的预测对象。此类方法在考虑负荷本身特性的同时，关注了不同能源之间的相互作用和依赖性，实现了在大规模历史数据下的负荷预测，为后续样本稀缺的负荷预测提供了理论和实践基础。

与单负荷预测相比，多元负荷预测的应用场景更为复杂。新能源的接入以及能量转换装置的存在，使得 IES 内部多种能量之间不仅存在耦合关系，而且其负荷波动更加复杂多变。此外，气象因素如温度、湿度等对能源需求有着直接影响，进一步增加了能源之间耦合转化关系的复杂度[36]。特征工程与预测模型是影响 IES 多元负荷预测精度的重要因素。在特征工程方面，有不少研究将多能负荷分解后再预测。分解算法将负荷序列分解为相对比较平稳的分量序列，再对每个分量分别建立预测模型, 叠加分量预测结果来整合最终的预测值。文献[37,38]采用了经验模态分解（Empirical Mode Decomposition，EMD）将负荷分解为不同幅频特性的本征模态分量，有效削弱了负荷的非线性特征。但 EMD 会引起模式混叠，影响特征处理的可靠性。二次模态分解是避免模态混叠问题的可行方法之一[39,40]。但两次分解所产生的模态分量较多，处理分量集合大幅增加了计算负担[41]。此外，众多分量的预测值在叠加重构过程中更易导致估计误差累积，对最终结果产生不利影响。也有研究人员尝试使用抑制模态混叠的分解算法。文献[42]考虑传统 EMD 产生的模态混叠以及提升对负荷序列的时间感知能力，提出了使用集合经验模态分解对可调节负荷进行处理。文献[43,44]基于变分模态分解处理原始序列，并融合多类模型进行负荷预测。文献[45]使用增加了正负白噪声辅助的互补集成经验模态分解（Complete Ensemble Empirical Mode Decomposition，CEEMD）来减少模态混叠现象。然而，此类方法主要侧重于序列数据高频、低频分量的分解，且模态分量的可解释性较差。

在预测模型方面，依据模型数量可以分为两类。第一类是多能负荷单一预测，对冷、热、电等多类负荷分别建模、预测，各模型之间相互独立。此类方法是典型的单负荷预测方法的典型扩展[46]，难以很好的利用与预测负荷与其他负荷之间的关联信息进行辅助预测。第二类是多能负荷联合预测，此类方法通

中国知网 https://www.cnki.net

常与多任务学习框架结合，将多能负荷视为一个整体的预测目标，同时输出电、热、冷等多个负荷的预测结果。文献[47]结合温湿指数和耦合特征，通过 GRU 神经网络和注意力（Attention）机制进行特征提取和预测建模。文献[48,49]利用 LSTM 的时序记忆能力和多任务学习（Multi task learning，MTL）的共享信息学习能力，提出短期负荷联合预测方法。文献[50]提出了一种 CNN 和双向 GRU 结合的混合网络预测模型，并通过 Attention 机制进一步优化。文献[51,52]在 Transformer 的基础应用 MTL 对负荷进行预测。上述研究表明，考虑能负荷之间共有的数据特征可以提高预测的准确性。然而，传统的共享底层（Shared-Bottom）模型结构要求所有任务共享底层特征，这种强制性的特征共享无法考虑到子任务之间的相关性差异[53]。这导致在某些情况下模型会出现负迁移问题[54]，即某些任务之间的弱相关关系可能会干扰其他任务，从而影响多任务模型的整体性能，甚至可能会出现多任务模型效果小于对应的单任务模型的情况。

为此，文献[53]在 Shared-Bottom 阶段引入了多个并列的专家子网络，为每个任务分配一个门控单元，通过这种方式来动态调整和控制每个专家子网络对最终预测结果的贡献权重。多门控混合专家网络（Multi-gate Mixture-of-Experts，MMoE）模型的设计使得模型能够实现对共享信息灵活且合理的分配，提高了模型的整体性能和表达能力。尽管 MMoE 模型在多任务学习中表现出色，但仍具有一定的局限性。它的底层的专家仍然是共享的，可能存在“跷跷板[55]”现象：一个任务的性能提升伴随着另一个任务的性能降低。这表明模型可能无法捕捉任务之间更加复杂的关系，从而给部分任务带来噪音导致性能退化。此外，MMoE 中的专家子网络之间缺乏有效的区分和交互机制，这可能会限制模型的整体优化效果。例如，当模型面对一组任务，其中一部分任务间存在较强的相关性，而另一部分任务间相关性较弱时，如果模型无法区分这些不同的相关性并采取相应的处理策略，可能会导致模型无法充分学习到每个任务的独特特征，从而影响预测的准确性。

综上所述，在多元负荷预测中，研究者们面临着能量耦合和负荷波动性强带来的复杂挑战。为了提高预测精度，特征工程和预测模型的选择至关重要。特征工程中，EMD 等模态分解方法被用于处理负荷序列，不仅存在模式混叠问题，而且可解释性差。多元负荷单一预测难以有效利用负荷关联性辅助预测。至于基于多任务学习的联合预测，虽然可以通过多任务学习框架整合多能负荷关联信息，但可能存在负迁移问题。为此，有研究者提出基于门控单元控制专家权重的优化方法来合理分配共享信息。尽管如此，模型仍需进一步优化以捕捉更复杂的任务关系，提高联合预测任务效果。

中国知网 https://www.cnki.net

1.2.3 小样本负荷预测研究

在数据量有限的情况下进行负荷预测是目前研究的热点问题。小样本负荷预测方法着重于如何最大限度地利用有限的数据，以及如何有效借助其他包含丰富数据的系统。

现有的短期负荷预测方法大都是基于丰富的数据来研究的，数据不足情况下的 IES 研究相对较少。然而不管是多任务模型还是单任务模型，在没有足够数据支持的情况下，难以进行准确的负荷预测。小样本问题已成为制约新型电力系统数字化转型的重要因素之一。IES 是一种新兴的能源利用方式，其实落地进程远未达到饱和程度[56]。新建设的 IES 通常缺乏大规模的历史数据，使得模型缺乏足够的数据进行训练[57]。

迁移学习（Transfer Learning，TL）是一种人工智能领域的先进技术，通过从数据丰富的源域迁移知识来提升目标域任务的性能，尤其在目标域数据不足的情况下效果显著。这种学习机制已被应用于多个研究领域和问题，例如图像分类、文本情感分析等等。近年来，TL 的使用已扩展到负荷预测领域，特别是建筑能源预测[58]，以解决可用数据有限的问题。TL 的核心是利用在充足数据条件下获得的知识来重用在数据不足的任务上。具体来说，将数据充足的领域定义为源域，并在源域上执行的任务定义为源域任务。想要处理但数据不足的领域和任务将被定义为目标域和目标任务。TL 的方法主要分为三类：基于实例的方法，基于特征的方法和基于模型的方法。

实例迁移通常将源域中的相似的实例直接迁移到目标域中以扩充样本。例如，文献[59]提出了一种基于实例的多源迁移学习框架，用于短期电力负荷预测。通过两阶段相似度度量和增强式集成学习方法，从源域中挑选最有帮助的数据样本进行知识迁移和预测。特征迁移侧重于从源域学习有用的特征表示，并将这些特征应用到目标域上。这可能涉及特征选择、特征提取或特征变换。例如，文献[60]提出了一种基于特征相似度和时间遗忘因子融合的迁移学习预测机制，有效应用于新用户的电力负荷预测，提高了 IES 中小样本电力负荷预测的准确性。在模型迁移中，源域的知识被用来训练一个模型，然后将这个模型或其部分知识迁移到目标域。这可能包括迁移已经训练好的模型参数或者模型结构。该类迁移方法主要基于神经网络构建参数共享模型进行迁移，因此又被成为参数迁移。负荷预测领域关于 TL 的研究通常采用参数迁移的方法。例如，文献[61]提出了一种多源迁移学习引导的集成 LSTM 预测方法，通过优势比较的源域建筑匹配和基于相似度的模型集成策略，结合多个源域数据为建筑负荷预测生成高精度的基本模型。文献[62]提出了一种基于两层 TL 的短期负荷预测架构，并构建潜在参数辅助模型学习目标区和源区负荷的关系。文献[63]在建筑

中国知网 https://www.cnki.net

能源预测任务中开发了基于 TL 的先进方法，并着重探索了不同迁移策略在不同场景下的潜力。文献[64]结合两阶段传递回归模型和 TL 对电力负荷数据进行预测。文献[65,66]利用 TL 优化原模型的热负荷预测性能。文献[67]开发 CNN-GRU 组合作为源模型，提出基于最大均差的模型结构调整策略，协同 TL 实现目标域负荷预测。上述研究表明，通过迁移学习可以提高小样本负荷预测精度。但与前面的两种 TL 方法相比，参数迁移可以通过直观的重用从源域学习到的模型，避免重新提取训练数据或对复杂的数据表示进行关系推理，这使得该类方法可以更加高效且可以更好地捕获源领域的高级知识。因此，参数迁移的方法在小样本负荷预测方面得到广泛应用。但是，基于参数的 TL 方法仍然依赖于源任务和目标任务之间的相似性。如果源任务的数据与目标任务差异较大，迁移效果可能会受到影响。此外，参数迁移策略的表现与具体应用场景相关，需要深入理解任务特性才能制定一个合适的迁移策略。

除了 TL 的方法，还有一些研究尝试扩充目标域数据集，通过增加训练数据的多样性，即数据增强（Data Augmentation，DA）方法来减少模型的过拟合。文献[68]引入了混合增强方法扩展训练样本的分布。然而，这种方法可能破坏时序的结构和语义，生成不符合时序规律的数据。为提高生成样本的质量，有研究者借助生成对抗网络（Generative Adversarial Network，GAN）来生成样本。例如，文献[69]通过结合气象因素和多负荷历史数据，以及基于 LSTM 构建的生成器和判别器来进行多元负荷预测。文献[70]提出了一种结合条件 GAN、CNN 和半监督回归的混合预测模型，通过构建条件标签矩阵、应用灰色加权相关方法生成高质量相似日，显著提高了短期负荷预测的准确性。文献[71]介绍了一种利用条件时序生成对抗网络（Time-series Generative Adversarial Network，TimeGAN）的建筑空调负载场景生成方法。这种方法将无监督对抗训练与监督训练相结合，以空调负荷的动态和静态特征作为条件监督项生成样本。文献[72]结合一种可控制的 GAN 的数据驱动方法，通过嵌入可解释流形空间，用于高效可靠的可再生能源场景样本生成。文献[73]采用基于局部融合生成对抗网络的小样本图像生成器，通过上下文信息增强细节特征来生成电力缺陷数据。文献[74]将双向的 GAN 网络与 TL 相结合，构建电力负荷预测模型。上述基于 GAN 的样本生成方法虽然在生成质量较高的样本方面表现出色，但相应的代价是训练时间更长且样本多样性不足[75]。

综上所述，可以通过 TL 和 DA 方法来提升模型训练效果。然而，TL 具有数据依赖性，成功与否和两域之间的相似性有很大关联。且迁移策略的选择需要对任务特性有深入理解。而现有的增强方法虽然能扩充样本数量，但存在破坏时序结构、训练时间长和样本多样性不足等问题。因此，需要进一步研究合

中国知网 https://www.cnki.net

适的，能够契合小样本负荷数据的 TL 和 DA 方法。

1.3 研究内容及章节安排

针对国内外研究现状和存在的问题，本文分别从单一负荷预测、多元负荷预测、小样本预测循序渐进开展工作。拟解决问题及对应的研究内容如图 1-1 所示，每个章节具体内容如下：

第一章，绪论。阐述本文相关研究背景及意义，从单一负荷、多元负荷、小样本负荷三个方面介绍了负荷预测研究现状，并对此进行分析总结。最后展示了本文具体的研究内容及结构安排。

第二章，基于时间模式注意力机制和卷积网络-序列到序列模型的短期电力负荷预测方法。首先基于先验知识分析电力负荷影响因素，构建输入特征集。然后结合卷积神经网络对负荷与其影响因素之间空间耦合关系的捕捉能力，以及序列到序列模型对负荷数据之间时间依赖关系的建模能力，充分挖掘多维输入变量的时空特征。与此同时，考虑序列到序列模型在处理长序列时可能出现的信息丢失，以及普通的注意力机制只关注时间维度信息的限制，采用时间模式注意力机制来增强模型在时间维度和空间维度上的关键信息处理能力。最后结合真实数据设置算例分析，对比卷积层数确定超参数，对比其他预测模型表明所提预测方法的有效性。

第三章，基于季节趋势分解和卷积式渐进分层提取多任务模型的短期多元负荷预测方法。根据综合能源系统的负荷特性分析，采用季节趋势分解算法将原始多元负荷分别分解为趋势分量、周期分量和残差分量，分隔出负荷内部叠加的时序规律。然后利用最大互信息系数分析每类负荷分量与气象因素之间的相关性，结合相关性高的影响因素形成输入特征集。接着，利用卷积网络挖掘高维空间的耦合信息，长短期记忆网络学习负荷数据的时间规律。与此同时，构建任务共享、任务特定两类专家模块和渐进式分离机制逐步提取和分离多元负荷之间的共享知识和特定知识。最后，设置算例分析，将所提模型与单任务模型、多任务模型以及不同的负荷分解算法进行比较，验证所建立卷积式渐进分层提取联合预测模型的准确性和优越性。此外，还进行了消融实验，验证所提方法每个模块的必要性。

第四章，基于多变量时间序列生成的变分自动编码器和迁移学习的短期小样本负荷预测方法。首先，利用时间变分自动编码器对目标域的多变量输入进行扩充，并通过最大均值差异来约束人工生成数据和目标域数据的分布，目的是提升数据多样性的同时保证数据质量。接着，利用最大均值差异判断源域和

中国知网 https://www.cnki.net

目标域负荷数据的相似性，选取相似度较高的数据训练迁移知识模型。然后，将增强模块和迁移模块结合，利用增强后的目标域数据对迁移模型进行微调，提升对目标任务的适应能力。最后，通过算例仿真，分别验证了所提迁移学习策略和数据增强方法的优势以及所提集成模型的可行性。第五章，总结与展望。对全文研究内容的总结以及对未来工作的展望。

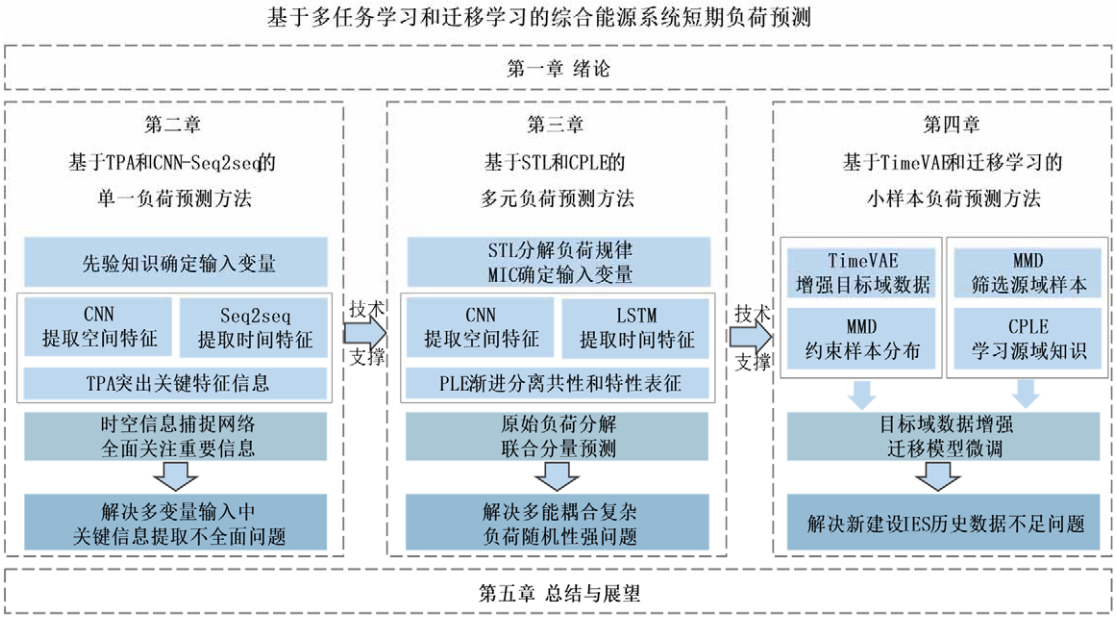


图 1-1 研究内容及章节关系

中国知网 https://www.cnki.net

第二章　基于 TPA 机制和 CNN-Seq2seq 的单一负荷预测

2.1 概述

负荷的变化是由多种影响因素共同决定的，如天气、时间、经济情况等，但未必预测模型中包含的因素越多越好。此外，负荷变化蕴含相关影响因素的演化信息，存在难以直接在低维空间直接观测到的隐藏的时空规律。为了突出对当前任务的关键信息，常使用注意力机制对预测结果优化。然而，典型的注意力机制仅对时间步加权，存在对时间步内的所有特征等权重对待的局限性，忽略了重要特征变量的影响。

因此，针对第一个挑战：负荷往往受多方面因素的影响，且多维特征变量之间复杂关系难以提取全面的问题，本章以单一负荷为预测对象，提出基于时间模式注意力机制（Temporal Pattern Attention，TPA）的 CNN-Seq2seq 短期电力负荷预测方法。具体方法为：（1）结合专家知识分析负荷影响因素，确定输入特征变量。（2）搭建综合考虑时空信息的预测模型。使用 CNN 网络捕捉日期特征、天气特征以及历史负荷特征之间的空间耦合关系，采用基于 LSTM 网络的 Seq2seq 模型学习时间变化规律相关的信息。由于 Seq2seq 将整个输入序列用一个固定维度的向量表示，可能会导致细节信息的丢失，因此引入 TPA 机制优化 Seq2seq 参数。相比于传统注意力机制，TPA 在提取周期性时间信息的同时，还能够对不同时间步内的参数进行差异化权重分配，这使得预测模型能够更全面的关注与预测结果相关的重要信息。（3）算例分析。多轮实验优化模型超参数，分析所提方法的有效性以及 TPA 相对于普通注意力机制的优越性。主要结构如下：2.1 节进行了本章内容概述，2.2 节分析了负荷影响因素，2.3 节描述了所提模型细节，2.4 节报告了实验结果，2.5 节给出了结论。

2.2 电力负荷影响因素的分析

神经网络是个黑箱，它能够自动提取高维特征信息，也经常会拟合到非重要特征，导致模型因为这些不好的特征局部坍塌。在神经网络模型的合适位置引入恰当的先验知识可以显著提高相关任务的效果。因此，本章节将先验知识与神经网络建模相结合，以此来加快模型收敛速度并提升模型精度。

基于先验知识方法将短期电力负荷预测的主要影响因素分为三种：最近负

中国知网　https://www.cnki.net

荷，气象因素，时间因素。如图 2-1 所示。

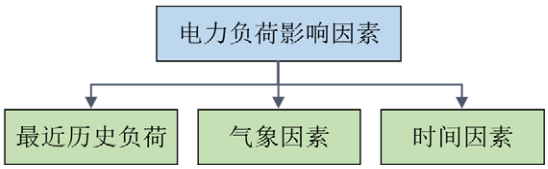


图 2-1 负荷影响因素分析

通过对这些影响因素的统一考虑，将用电负荷公式用式（1）表示：

$$Y_{pred} = L(n, w, s, r) \tag{1}$$

式中，Y_{pred}为负荷预测值，n为真实负荷趋势值，w为天气波动引起的负荷变化，s为日期改变引起的负荷变化，r为噪声，通常忽略此变量的影响。由上式可知，$L(n, w, s, r)$的预测精度越高，预测负荷与真实负荷的相似度越高。

2.2.1 基于先验知识的最近负荷选取

用电负荷是一组时间序列数据，具有一定的规律性和周期性。因此模型可以通过学习历史负荷的波动规律预测近期的负荷变化。对于待预测时刻来说最近的历史负荷包含着丰富的先验信息。此外，序列长度的选择也会影响模型的预测效果。如果选取的最近负荷序列过短会导致预测模型学习不到完整的规律性信息，过长则会导致模型难以选择重点信息。因此，综合考虑使用待测时的前 24 时的用电负荷作为输入参数对$L(n, w, s, r)$进行建模。

2.2.2 基于先验知识的气象特征选取

负荷预测易受到气象因素的影响，用合理的方法考虑气象因素的影响是提高预测精度的关键之一。气象因素主要包括温度、湿度、天气类型等。气象因素本质是通过影响用户活动来对用电负荷产生造成影响。例如，高温和低温都会使负荷增加，其原因在于温度直接影响人体舒适度，进而影响用户对空调或电暖气的使用频率迅速增加，导致用电负荷快速增长。根据文献调研结果，使用包含温度、相对湿度、风向、风速、气压、降水量、露点在内的 7 种气象类型作为模型的气象特征。

2.2.3 基于先验知识的时间特征选取

时间因素是影响短期负荷预测的重要因素。用电负荷反映了人们生产、生活规律，而生产和生活波动与时间变化密不可分。时间因素对负荷的影响主要体现在 1 天 24 小时的变化，一周的变化，月内日期的变化，月份的变化、四季的变化，是否为节假日等。以校园用电负荷为例，其日负荷曲线与校园内用户日常生活节奏一致；周负荷也具有规律，即工作日负荷曲线相似，双休日或节

中国知网 https://www.cnki.net

假日负荷比工作日低；夏季和冬季相比于其他季节用电负荷较高。因此，构建包含时、日、周、月、季节、是否为节假日在内的 6 个时间特征作为$L(n,w,s,r)$的输入。

2.2.4 输入特征集的构造

综上所述，构造包含最近历史负荷、气象因素、时间因素在内，序列长度为 24，特征维度为 14 的向量作为模型的输入特征。如表 2-1 所示，$i\in[1,24]$。

表 2-1 输入特征集

影响因素	特征类型	特征描述
最近负荷	y_{t-i}	$t-i$时刻负荷值
气象因素	温度	$t-i$时刻气温
	相对湿度	$t-i$时刻相对湿度
	风向	$t-i$时刻风向
	风速	$t-i$时刻风速
	气压	$t-i$时刻气压
	降水量	$t-i$时刻降水量
	露点	$t-i$时刻露点温度
时间因素	时	$t-i$时刻
	日	$t-i$时刻的日份，1-31 表示 1 号~31 号
	周	$t-i$时刻的周，0-6 表示周一到周日
	月	$t-i$时刻的月份，1-12 表示 1 月到 12 月
	季节	$t-i$时刻的季节，1-4 表示春夏秋冬
	节假日	$t-i$时刻的日份是否为节假日，是为 1，否为 0

2.3 负荷预测模型的构建

2.3.1 基于 CNN-Seq2seq 的时空特征提取

CNN-Seq2seq 混合网络由两部分组成，CNN 网络用于挖掘空间特征，Seq2seq 网络用于学习时序特征。CNN-Seq2seq 处理输入数据的具体流程如图 2-2，首先，将预处理后的多维特征序列输入 CNN；其次，通过卷积核在特征图上滑动卷积的方式提取含有空间信息的特征；最后，利用 Seq2seq 获得包含双向时序特征的隐状态向量以及当前时刻的隐藏状态作为 TPA 的输入。

中国知网　https://www.cnki.net

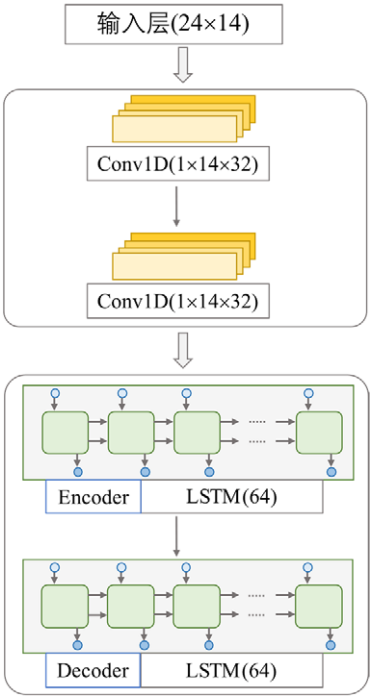


图 2-2 CNN-Seq2seq 结构图

下面介绍 CNN 和 Seq2seq 的基本结构。CNN 凭借强大的特征提取能力在负荷数据的特征提取中得到了广泛应用。它的核心是借助多个卷积核来提取局部特征，并对每个卷积核中的权重参数进行共享来综合不同局部感受野，获得全局特征。图 2-3 展示了一维 CNN（1DCNN）的卷积原理。

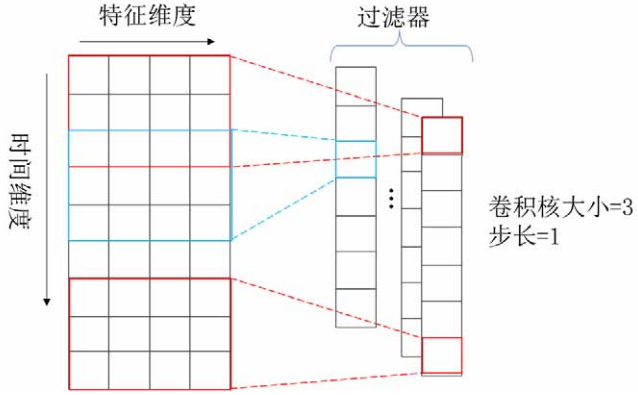


图 2-3 一维卷积原理

Seq2seq 是一种处理输入输出数据为可变长度的序列到序列模型。由编码器（Encoder）和解码器（Decoder）构成，其组成单元可以是各种神经网络。为了更好的学习多能负荷数据的时序特征，以 LSTM 作为 Seq2seq 的基本单元来分析 CNN 提取的特征向量。LSTM 是一种基于循环神经网络改进的网络模型[80]，在时序数据的建模和预测方面具有优异的表现。它通过引入门机制控制特征的

中国知网 https://www.cnki.net

流通和损失，增强了对长时间序列的处理能力，使其不但能够对短期依赖良好建模，还克服了 RNN 存在的梯度消失/爆炸问题。LSTM 的基本原理如图 2-4 所示，数学描述如式（2）~（7）所示。

LSTM 通过引入门控单元来控制信息的流动，从而有效地捕捉序列中的长程依赖关系。它具有三个关键的门控结构：遗忘门、输入门和输出门，以及一个细胞状态来存储和传递信息。遗忘门决定了上一个细胞状态的保留程度，设x_t是时间步t的输入向量，则遗忘门f_t可以表示为：

$$f_t = (W_f \cdot [h_{t-1}, x_t] + b_f) \tag{2}$$

其中，h_{t-1}是时间步$t-1$的输出，W和b是对应的参数矩阵和偏置向量。

输入门i_t控制着新的输入信息$\tilde{C}_t$对当前细胞状态C_t的影响程度，具体计算公式为：

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t \tag{3}$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \tag{4}$$

$$\tilde{C}_t = tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \tag{5}$$

其中，σ表示激活函数$Sigmoid$，$tanh$表示激活函数$tanh$。$\tilde{C}_t$是通过候选细胞状态计算得到的，表示新的候选细胞状态。

当前时间步的输出h_t可由输出门o_t和当前细胞状态C_t得到：

$$h_t = o_t \times tanh(C_t) \tag{6}$$

$$o_t = \sigma(W_O \cdot [h_{t-1}, x_t] + b_o) \tag{7}$$

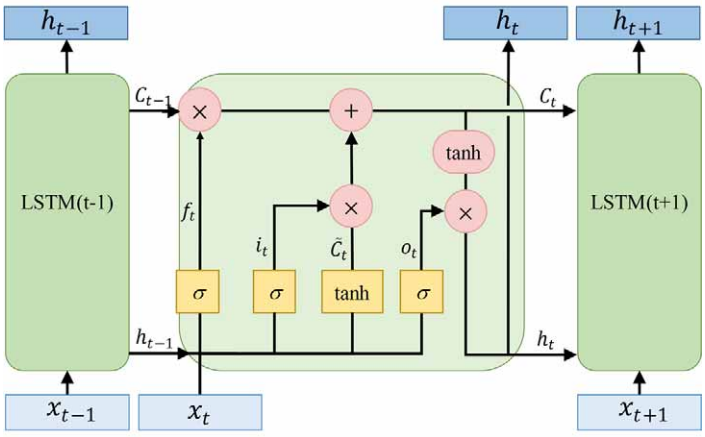


图 2-4 LSTM 结构图

CNN-Seq2seq 网络综合了 CNN 和 Seq2seq 的优点，充分挖掘时空特征。此外，本章节负荷预测模型中输入变量是多维的，为了进一步提高模型预测效果，引入注意力机制给予重要特征更高关注。

中国知网 https://www.cnki.net

2.3.2 基于 TPA 机制的关键信息处理

TPA 机制是一种能够提取时间模式并关注不同时间序列的不同时间步长的注意力机制。典型的注意力机制是对相关的时间步进行加权，而 TPA 不仅能提取序列的时间信息还能考虑到不同变量对预测结果的影响。因此，采用 TPA 机制对 CNN 提取的定长时序模式分配不同的权重来优化 Seq2seq 的输出进而提高模型性能。TPA 结构如图 2-5 所示。

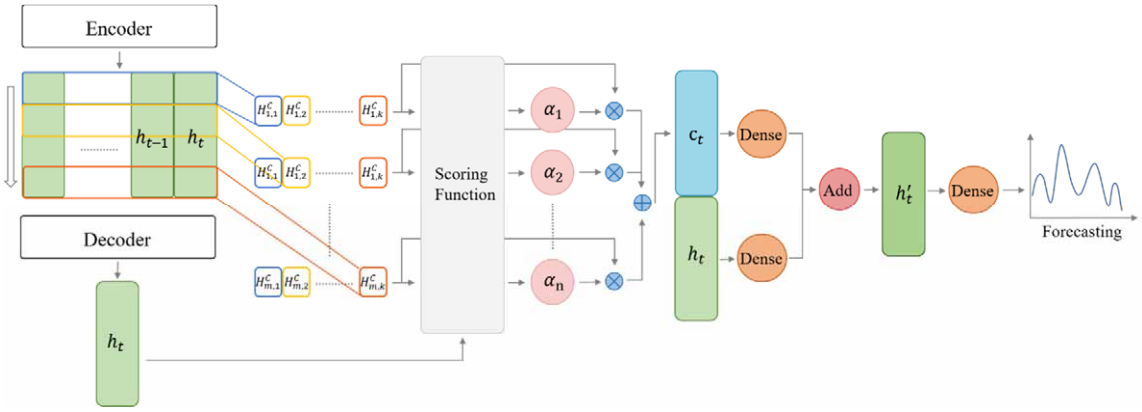


图 2-5 TPA 结构图

首先对原始时序数据用 CNN-Seq2seq 进行特征提取，获得编码器所有时刻隐藏状态h_{t-w}~h_t。定义隐状态矩阵 $H=\{h_{t-w},h_{t-w-1},\dots,h_t\}$。对于隐藏状态矩阵 H 的每行，使用 k 个 CNN 过滤器提取特征，产生维度为$m*k$的 HC 矩阵。对于解码器 t 时刻的隐藏状态h_t，将其与 HC 矩阵的每行作用，从而对每行产生一个权重a_i，将每行进行加权求和得到c_t。最后，c_t和h_t经过线性变换得到最终隐藏层输出，再通过一个全连接层获得预测输出y_{pred}。数学描述如（8）~（13）所示。

$$HC_{i,j}^{c}=\sum_{i=1}^{w}H_{i,(t-w-1+l)}\times C_{j,(T-w+l)} \tag{8}$$

$$f\left(H_i^C,h_t\right)=\left(H_i^C\right)^T W_a h_t \tag{9}$$

$$\alpha_i=sigmoid\left(f\left(H_i^C,h_t\right)\right) \tag{10}$$

$$c_t=\sum_{i=1}^{n}\alpha_i H_i^C \tag{11}$$

$$h_t'=W_h h_t+W_c c_t \tag{12}$$

$$y_{t-1+\Delta}=W_{h'}h_t' \tag{13}$$

其中，H 为 Seq2seq 编码层隐藏状态矩阵，w 为时间序列长度，C_j表示第 j 个长度为 T 的滤波器；×表示卷积运算，HC_i是HC的行向量，W_a为$k\times m$的权重矩阵，α_i为注意力权重，n 表示输入变量 x 的特征数，$y_{t-1+\Delta}$表示最终预测值，

中国知网　https://www.cnki.net

△表示不同预测任务的预测时间尺度，$W_{h'}$、W_h和W_c为对应变量的不同权重矩阵。

2.3.3 模型整体框架

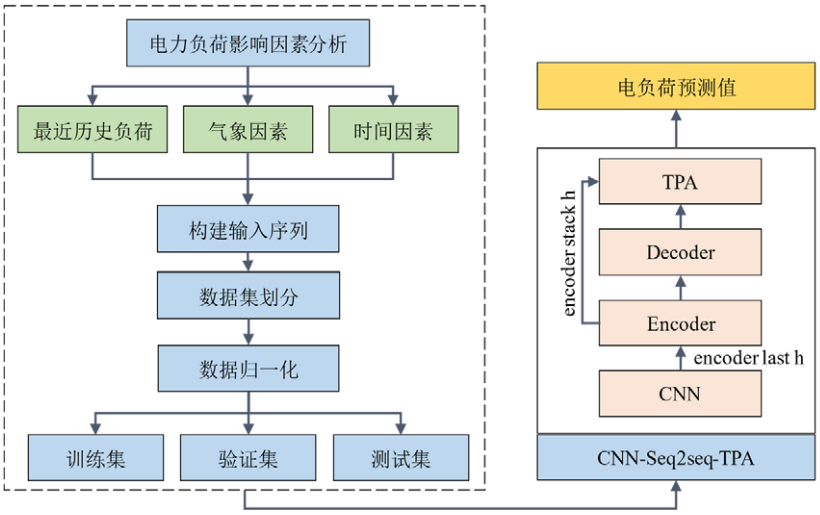


图 2-6 整体预测流程图

本章提出的 CNN-Seq2seq-TPA 混合网络模型如图 2-6 所示，该模型主要由三部分组成，CNN 部分包括两个一维卷积层，Seq2seq 部分的编码层和解码层均为单层 LSTM 网络，注意力部分是 TPA 机制。CNN 负责提取原始时序数据的空间特征；Seq2seq 负责对对 CNN 提取的特征矩阵挖掘时间的规律；TPA 机制负责关注关键特征信息，优化模型输出。

2.4 算例分析

2.4.1 数据来源与实验环境

本章节使用基于 TensorFlow 的 Keras 神经网络库搭建并训练 CNN-Seq2seq-TPA 模型来验证预测模型的可靠性和精确性。其中，对于绘图的处理采用 matplotlib 库，硬件环境的配置为两块 Xeon4215R CPU 和两块 NVIDIA RTX 3090 GPU。算例使用的数据集为美国德克萨斯大学达拉斯分校（UTD）的 2014 年 1 月 1 日到 2015 年 12 月 31 日负荷、气象及日期数据[76]，以小时为单位，共 17521 组数据。

2.4.2 数据预处理及评价指标

因数据集各项特征取值范围不同且数值差异较大，为了提高数据的表达能

中国知网 https://www.cnki.net

力以及加快网络训练速度，对数据进行归一化。其式如下：

$$x^* = \frac{x - x_{min}}{x_{max} - x_{min}} \tag{14}$$

式中，x^*为映射后的特征值，取值范围为[0,1]，x为该列特征原始值，x_{max}为该列特征最大值，x_{min}为该列特征最小值。

将归一化后的数据集按照 2.2 小节构建输入特征集，并将其划分为训练集、验证集和测试集，占比分别为 80%，10%，10%。

UTD 数据集中负荷数据不存在值为 0 的情况，因此，采用平均绝对百分比误差（Mean Absolute Percentage Error，MAPE）和均方根误差（Root Mean Squared Error，RMSE）作为评价指标，MAPE 表示预测结果与真实结果的平均偏移量，RMSE 描述样本的离散程度。误差指标的数值越小则模型预测精度越高，稳定性越好。具体计算公式分别如下所示：

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_{act}(i) - y_{pred}(i)}{y_{act}(i)}\right| \times 100\% \tag{15}$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}(y_{act}(i) - y_{pred}(i))^2}{y_{act}(i)}} \tag{16}$$

式中，$y_{act}(i)$为时刻i的负荷真实值，$y_{pred}(i)$为时刻i的负荷预测值，n为训练或测试集样本个数。

2.4.3 超参数设置

超参数的调优可使预测值更贴近真实值，采用控制变量法对不同数量的卷积层构建的负荷预测模型进行对比。表 2-2 是不同卷积层数模型实验结果。由实验结果可知 CNN 网络层数为 2 时误差最小，适当的增加 CNN 模型深度可以提高模型预测精度，但当卷积层到一定数量后再增加会导致模型预测误差增大。

表 2-2 CNN 网络结构不同参数实验对比

CNN 网络层数	RMSE(kW)	MAPE(%)
1	105.65	2.60
2	93.73	1.48
3	95.36	1.84
4	99.62	1.93

经过上述实验，确定了 CNN 的网络层数，对其余超参数不断调优对比，最终确定 CNN-Seq2seq-TPA 的参数如表 2-3 所示。

中国知网　https://www.cnki.net

表 2-3 超参数设置

参数描述	超参数	数值/类型
CNN 网络参数	Filter	32
	Kernel size	1
	Padding	causal
	Stride	1
Seq2seq（LSTM）网络参数	Hidden unit	64
	Regularization	L1(0.001)
	Dropout	0.1
	Loss function	MAE
优化参数	Epoch	200
	Optimizer	Adam
	Learning rate	0.001
	Batch size	512

2.4.4 预测结果分析

为验证 CNN-Seq2seq-TPA 的预测精度，将所提模型与 GRU、LSTM、XGBoost、Seq2seq、CNN-Seq2seq、CNN-Seq2seq-LA 模型进行对比。GRU 和 LSTM 模型分别由一层的 GRU 和 LSTM 网络构成，其中隐藏单元数量均为 64。XGBoost 模型的最大深度为 6，学习率为 0.9。Seq2seq 模型与所提模型的 Seq2seq 基本单元和具体参数相同，同理 CNN-Seq2seq 和基于普通注意力机制（Luong Attention）的 CNN-Seq2seq-LA 模型。上述模型优化参数均相同。表 2-4 是不同模型在测试集上预测精度的对比。

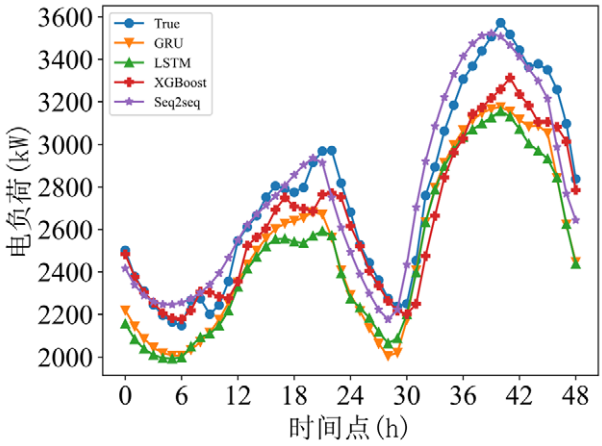
表 2-4 模型预测结果比较

模型	RMSE(kW)	MAPE(%)
GRU	278.18	9.35
LSTM	275.23	8.89
XGBoost	212.35	5.61
Seq2seq	178.71	4.11
CNN-Seq2seq	111.85	2.21
CNN-Seq2seq-LA	106.07	1.81
CNN-Seq2seq-TPA	92.35	1.78

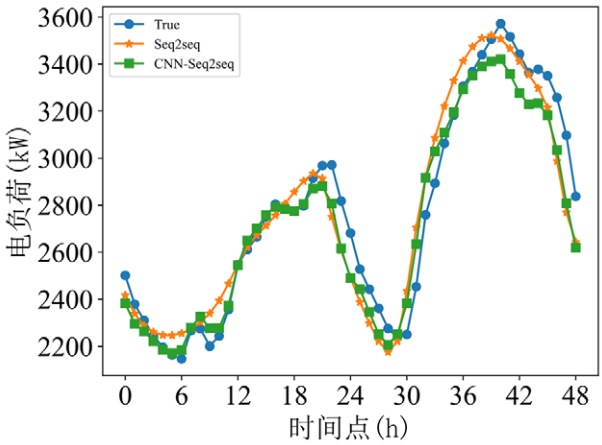
图 2-7 是 2015 年 9 月 27 日 0 点到 2015 年 9 月 28 日 24 点的实际负荷值与不同模型负荷预测结果的曲线对比。结合表 2-4 和图 2-7，可以看出所提模型精度最高，预测曲线最为贴合真实曲线。CNN-Seq2seq-TPA 和 CNN-Seq2seq-LA 与 CNN-Seq2seq 相比 RMSE 分别下降了 19.50kW，5.78kW，MAPE 分别下降了 0.43%，0.40%。CNN-Seq2seq-TPA 与 CNN-Seq2seq-LA 相比，CNN-Seq2seq-TPA 的 RMSE，MAPE 分别下降了 13.72kW，0.03%。图 2-7（c）显示加入注意力机制的模型要比不加入的模型在负荷波动较剧烈的区域的预测精度更佳，TPA 机制要比 LA 机制表现更好。结合表 2-4 和图 2-7（b）可以得出，CNN 网络的存在能改善预测曲线的平滑性，提高预测精度。在图 2-7（a）中，明显可

中国知网 https://www.cnki.net

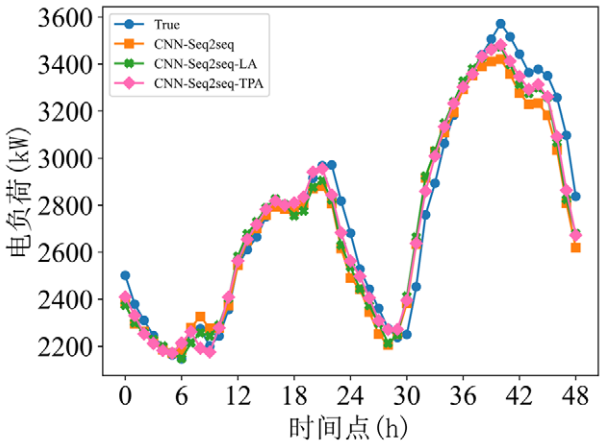
以看出 Seq2seq 模型的效果最好，XGBoost 次之，LSTM、GRU 模型效果较差。虽然 Seq2seq 相比其他三个模型的预测结果更接近真实值，但在电力负荷波动较大的地方预测效果都比较差。综上，所提预测模型相比于对比模型，充分利用了 CNN、Seq2seq、TPA 的优势，在效果上表现最佳。



（a）



（b）



（c）

图 2-7 模型预测结果对比

中国知网 https://www.cnki.net

2.5 本章小结

本章考虑负荷影响因素众多以及多维特征之间存在复杂关系的情况，提出了一种基于 TPA 的 CNN-Seq2seq 混合网络的短期电力负荷预测模型。该模型利用先验知识筛选特征信息，CNN-Seq2Seq 网络提取时空特征，TPA 机制进一步提高负荷预测精度。本章主要结论具体如下：

（1）CNN 与 Seq2seq 网络的结合，能充分发挥 CNN 网络对特征间耦合关系提取的优势以及 Seq2seq 对时序信息的学习能力。CNN-Seq2seq 相比于 GRU、LSTM、Seq2seq 模型 MAPE 分别降低了 7.14%、6.68%、1.9%，RMSE 分别降低了 166.33kW、163.38kW、66.86kW。算例结果表明了 CNN-Seq2seq 对预测结果的有效提升。

（2）TPA 的引入对多维时序数据关键信息的处理更为全面。CNN-Seq2seq-TPA 相比于 CNN-Seq2seq、CNN-Seq2seq-LA 模型 MAPE 分别降低了 0.43%、0.03%，RMSE 分别降低了 19.5kW、13.72kW。算例结果表明了注意力机制能进一步提高预测精度，而 TPA 机制比传统的注意力机制关注更多重要信息。

本章提出的单一负荷预测模型为后续多元负荷预测提供了可行性技术支撑，为在更复杂的应用场景下的短期负荷预测研究奠定了基础。

中国知网　https://www.cnki.net

第三章 基于 STL 和 CPLE 的多元负荷预测

3.1 概述

IES 的出现使各类能源之间的联系更为紧密，但同时也引入了一系列新的问题。由于各种能源之间存在着物理特性的差异，以及耦合利用所带来的影响效应，使得负荷表现出更大的波动性和随机性。第二章中提出的基于混合网络的负荷预测方法，表明了 CNN、LSTM 等神经网络强大的负荷建模能力。

因此，在上一章的技术基础上，针对第二个挑战：复杂的多能耦合关系以及负荷波动性和随机性更强的问题，提出一种基于季节趋势分解和卷积式渐进分层提取共享方法（Seasonal Trend decomposition using loess-Convolutional Progressive Layered Extraction，STL-CPLE）的多任务模型，用于同时预测电、冷、热负荷。具体方法为：（1）确定输入特征。根据 IES 负荷非平稳性和非线性特点，采用 STL 算法将冷、热、电负荷分别分解为趋势分量、周期分量和随机分量。提高负荷序列的可解释性的同时避免了不确定性信息对其他分量预测的影响。然后，考虑覆盖负荷和影响因素之间线性和非线性关系，对负荷和气象特征进行 MIC 相关性分析，为每类负荷分量构建对应的输入特征。（2）对多元负荷分量建立预测模型。以 1DCNN 作为特征提取单元，LSTM 作为时间建模单元，协同 PLE 多任务模型优化预测性能和效率。其中，PLE 通过设置任务共享专家和任务特定专家显式分离专家网络，并采用渐进式路由策略建模不同专家之间的交互，逐步分离负荷独享信息。（3）算例分析。通过两组实验来验证 STL-CPLE 模型的有效性。在负荷预测模型方面，与不同单任务模型和多任务模型进行对比，并对 CPLE 进行了消融实验。在负荷分解方法方面，与不同分解方法进行对比。上述实验结果表明所提方法的准确性以及预测模型和分解方法的优越性。本章主要结构如下：3.1 节进行了本章内容概述，3.2 节分析了负荷特性，3.3 节描述了所提模型细节，3.4 节报告了实验结果，3.5 节给出了结论。

3.2 负荷特性分析

3.2.1 多能耦合分析

本章以亚利桑那州立大学坦佩校区的 IES 为研究对象，探讨 IES 中不同负

中国知网 https://www.cnki.net

荷之间的耦合关系。校园有 288 栋建筑，50246 名学生，73190 块太阳能光伏板。IES 基本组件之间的能量流如图 3-1 所示。该 IES 的供电包括外部电网和屋顶光伏电源。以冷热电联产机组、锅炉、燃气锅炉及制冷机等设备作为能量转换装置。该系统由电、冷、热子系统组成，通过集成多种能源的转化和存储设备耦合多种能量，以满足不同能源需求。能源服务商扮演着协调者的角色，负责规划 IES 内部各类能源的转化、存储、分配、消费等环节。用户侧利用智能终端设备收集多样化的用能需求，并反馈给系统端进行能量转换。能源服务商将需求进行汇总分析后，借助准确的多元负荷预测，制定能源转换和分配决策方案。

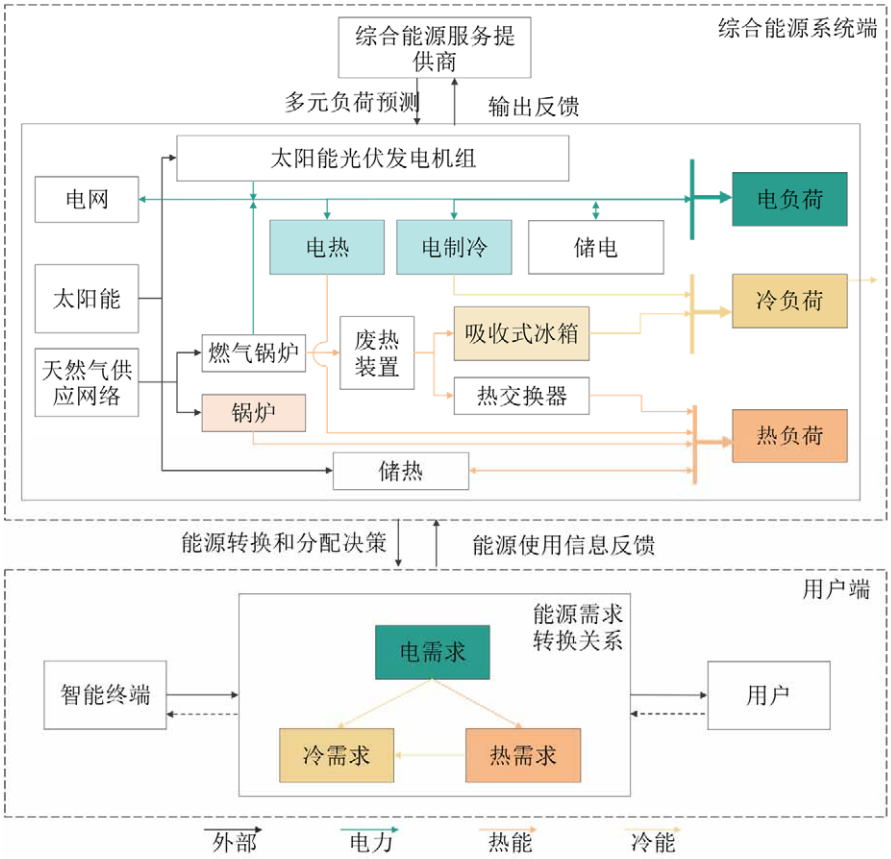
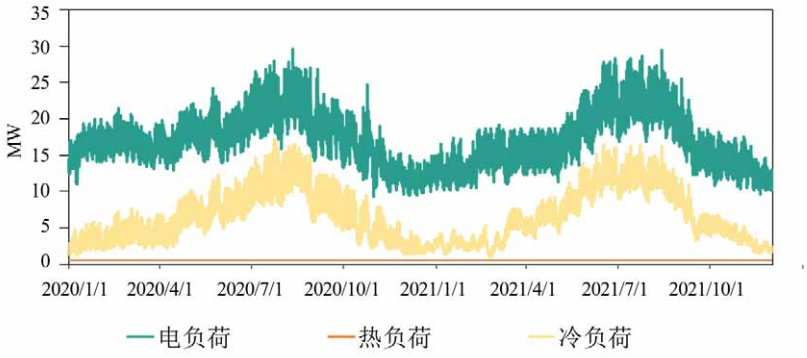


图 3-1 IES 与用户侧的交互结构

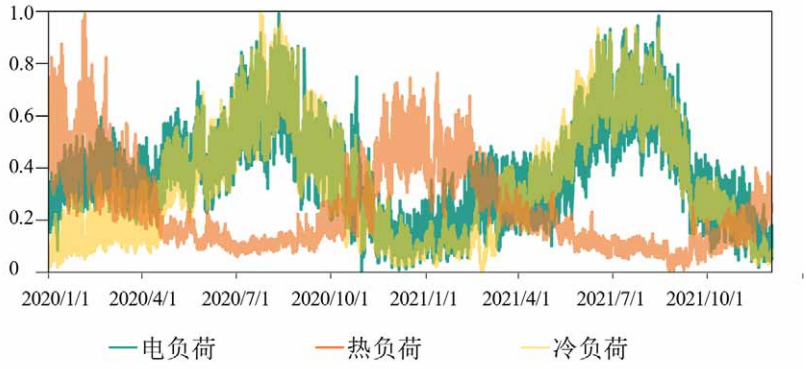
根据 IES 的结构可知负荷消耗是由多个能量子系统支持的，且子系统之间存在能量转换[77]。再加上多样化的用户需求，使得多能负荷的随机性增加。为进一步分析负荷之间的关系，展示坦佩校区 2020-2021 年的电、热、冷负荷变化。在图 3-2（a）中，电负荷与冷负荷呈正相关关系，且频率波动大致相同。无量纲化后可以明显看出热需求与电、冷需求呈负相关。这表明用能需求之间存在依存关系，一种负荷的变化趋势隐藏了其他负荷的规律信息。相较于电负荷和冷负荷，热负荷的需求非常低。原因是坦佩属于热带沙漠气候，日照时间长，降雨少，是美国年平均气温最高的城市之一。此外，不同负荷在不同季节具有

中国知网 https://www.cnki.net

不同变化趋势和波动幅度，冬季的热负荷变化尤为剧烈。负荷整体呈现出非平稳性和较大波动性。



（a）原始负荷



（b）无量纲负荷

图 3-2 负荷预测曲线

3.2.2 多能负荷分解预测

从图 3-2 可以看出，负荷表现出非平稳性。不同负荷在不同季节有不同的变化趋势和波动，其中冬季供热负荷变化尤为剧烈。此外，子系统之间的能量转换和多样化的用户需求增加了多能源负荷的随机性和波动性。但模型的适用性有限，直接对信息复杂的 IES 负荷建模容易出现预测误差。STL 分解算法可以分离负荷中包含的多重规律[78]，每个分解项都具有明确的物理意义[79]，有助于预测模型更好的理解序列的内在规律和特点。

STL 是一种基于局部加权回归的分解算法，基本思想是将原始时间序列分解为三个分量：趋势T_t、季节/周期S_t、残差R_t。其中，趋势项代表了变化的趋势和走向；季节项反映了不同时间尺度下的周期性变化；残差项是原始序列减去趋势项和季节项之后剩余的部分，表示序列中的随机因素。STL 的分解可以表示为：

$$Y_t = T_t + S_t + R_t \tag{17}$$

中国知网 https://www.cnki.net

STL 的计算流程分为内循环和外循环，内循环通过局部加权回归平滑等操作分解出趋势项和季节项，外循环则基于残差结果调节鲁棒权重，减少异常值对下一次内循环的影响。设$T_t^{(k)}$和$S_t^{(k)}$为第k次迭代的结果，m_p为周期窗口，即一个周期样本数。那么第$k+1$次内循环的迭代过程如下：

（1）去趋势。计算$Y_t - T_t^{(k)}$以去除趋势。

（2）平滑周期子序列。对（1）中得到的序列进行划分，将划分后的子序列进行 Loess 后重新组合，得到临时周期序列$C_t^{(k+1)}$。

（3）低通滤波。对$C_t^{(k+1)}$应用低通滤波器，先按照顺序做长度m_p、m_p、3 的滑动平均处理，再进行一次 Loess 平滑，得到低通量$L_t^{(k+1)}$1。

（4）计算季节分量。第$k+1$次迭代的季节分量为$S_t^{(k+1)} = C_t^{(k+1)} - L_t^{(k+1)}$。其中，用$C_t^{(k+1)}$减去$L_t^{(k+1)}$是为了防止低频功率进入季节分量。

（5）计算趋势分量。计算$Y_t - S_t^{(k+1)}$以去除季节分量，然后使用 Loess 对这个差异序列进行平滑，得到第$k+1$次迭代的趋势分量$T_t^{(k+1)}$。

外循环的主要任务是求出内循环进行 LOESS 时所用到的鲁棒性权重 ρ_t，根据残差分量的大小分配给每个时间点。利用内循环中得到的季节和趋势分量来计算残差分量 R_t，R_t 越大，对应 ρ_t 越小，ρ_t 体现的是 R_t 的极端程度。其计算公式为：

$$h = 6\text{median}(|R_t|) \tag{18}$$

$$B(u) = \begin{cases} 0, u \geq 1 \\ (1-u^2), 0 \leq u < 1 \end{cases} \tag{19}$$

$$\rho_t = B\left(\frac{|R_t|}{h}\right) \tag{20}$$

其中，median( )为中位数函数。B(u)为双平方权重函数。

STL 属于加法模型，适合时间尺度相对一致的序列。然而，许多时间序列数据呈现出随趋势变化的周期模式，在这种情况下乘法模型更适合。STL 的乘法形式可以通过对数函数来实现，如式（21）所示。从图 3-2 可以看出，显然应该使用基于乘法的 STL 形式来执行负载分解。

$$\log Y_t = \log T_t + \log S_t + \log R_t \tag{21}$$

结合 STL 乘法形式和计算过程分别对电负荷、热负荷与冷负荷序列进行分解，即可得到三类负荷的趋势分量集合、季节分量集合与残差分量集合。下文所提不同负荷分量均为多能负荷的不同分量集合。

3.2.3 多能负荷分量影响因素分析

考虑过滤掉无关特征减少计算负担，以及为负荷分解预测提供更精细化的数据支持，对负荷分量和气象特征进行 MIC 相关性分析。MIC 是一种基于互信

中国知网 https://www.cnki.net

息的检测不同变量之间相关性的度量方法，能够均衡覆盖各种线性、非线性关系。该方法普适性高且计算复杂度低，在深度学习中常用于特征选取。运用 MIC 的基本思路是：用二维散点图表示两个变量间的关系，对散点图进行网格化估算变量的概率密度分布，最后归一化得到 MIC 值。MIC 的取值范围为[0,1]，值越大关联程度越深。具体计算过程如式（22）、（23）所示。

$$MIC(x,y) = \max_{a*b<B(n)} \frac{I(x,y)}{\log_2 \min(a,b)} \tag{22}$$

$$I(x,y) = \sum p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)} \tag{23}$$

式中，n 为样本数量，a，b 分别代表在二维坐标系中变量 x，y 方向上的网格数目，B(n)是关于样本大小的函数，通常设置为$n^{0.6}$。$I(x,y)$表示变量 x，y 之间的互信息，$p(x)$、$p(y)$分别为 x，y 的概率密度分布，$p(x,y)$为 x、y 联合概率密度分布。

基于上述公式计算多元负荷分量与气象环境之间的 MIC 值，从中选择相关性强的特征进行保留。同时，考虑到时间序列特性，构造小时特征和节假日特征。小时特征对应编码值 0-23，工作日特征设置为 1 表示工作日，0 表示非工作日。

3.3 负荷预测模型的构建

在 STL-CPLE 中，采用 CNN 进行整体特征提取，LSTM 对时间依赖性进行建模。采用 PLE 多任务方法，建立两类专家网络，一种类型侧重于学习负载之间的耦合关系，而另一种类型则侧重于捕获特定于负载的信息，并应用渐进式路由策略来分离不同负载预测任务的特定参数。CNN 和 LSTM 的基本原理见第二章 2.2.1 小节。

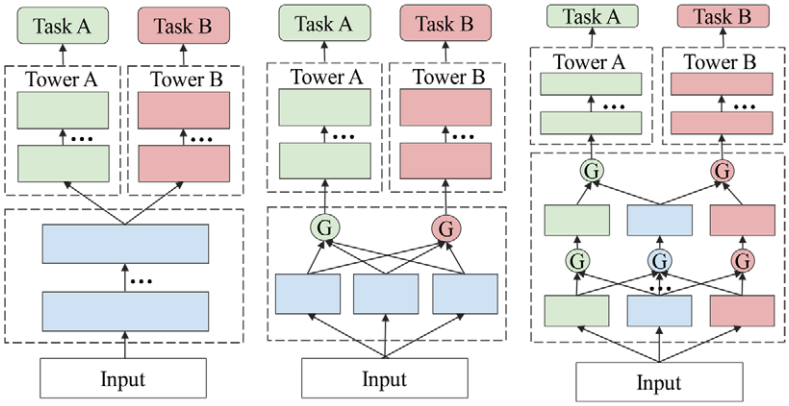
3.3.1 基于 PLE 的共享方法

目前，应用于多能负荷联合预测领域的多任务模型大多数是传统硬参数共享的，即在所有任务中使用同一个的隐藏层，对特定任务保留不同的输出层。该共享方式过于简单，没有考虑到不同负荷之间耦合程度的差异，易受到子任务间弱相关性带来的有害干扰。并且，负荷之间的复杂关联容易导致跷跷板现象，难以在所有任务中实现相对于相应单任务模型的显着改进。因此，为了减少远程相关任务的影响及提高共享学习效率，采用 PLE 多任务策略。

PLE 在 MMoE 的基础上进行了改进，明确地将专家划分为任务共享专家和任务特定专家。共享专家专注于学习共享模式，特定任务专家则致力于学习特

中国知网 https://www.cnki.net

定任务的模式，这种划分有助于避免不同任务之间的参数冲突和负向迁移，实现定制分享。在信息交互方面，与 MMoE 模型中全连接路由不同，PLE 设计了一种更灵活高效的渐进式分离路由。在 MMoE 中，专家之间没有差异和交互，所有任务使用相同的专家输出。而 PLE 通过渐进式分离路由将底层所有专家作为特征提取器，提取高阶共享知识，并在更高层逐渐分离特定任务参数。具体而言，PLE 为每类任务定制门控单元，从共享专家和该任务的独享专家中选择所需信息。定制门控网络消除了子任务层与其他任务独享专家之间的联系，使得特定任务专家专注于自身知识学习。共享专家对应的门控单元则从所有专家网络中抽取信息。这表明共享专家受所有任务的影响，而特定任务专家的参数只受自己的任务影响。图 3-3 展示了三种模型的结构对比。



（a）硬参数共享 （b）MMoE （c）PLE

图 3-3 不同多任务方法的框架

PLE 由专家模块、门控单元和塔网络组成。专家模块、门控单元和塔式网络。专家模块和门控单元位于底部，可以形成多层特征提取网络。同样，塔式网络也由放置在模型顶部的多层网络组成。专家模块有两种模式：共享模式和特定任务模式。每个专家模块包含多个称为专家的子网络，以帮助学习特征。在 PLE 中，门控单元选择性地融合不同的专家模块。如图 3-4 所示，每个专家模块都有一个门单元，由带有 SoftMax 激活函数的单层全连接网络组成。输入作为选择器，计算所选向量的加权和，即门控网络的输出。令输入向量为x，底层网络层数为N，则每层网络输出的计算公式可以表示为：

$$g^{k,j}(x) = w^{k,j}(x)S^{k,j}(x) \tag{24}$$

$$w^{k,j}(x) = \text{Softmax}\left(w_g^k\left(g^{k,j-1}(x)\right)\right) \tag{25}$$

其中，$g^{k,j}(x)$为第k个子任务在第 j 层网络的输出，即门控单元的输出。$w^{k,j}(x)$是任务 k 在第 j 层的权重参数，通过线性矩阵w_g^k和 Softmax 函数计算得出，其输入是 j-1 层网络输出$g^{k,j-1}(x)$。

中国知网 https://www.cnki.net

$S^{k,j}(x)$是任务 k 在第 j 层的选择矩阵，由共享模块E_s和任务 k 的独享模块E_k组成，具体公式见（26）。

$$S^{k,j}(x) = [E^T_{(k,1),j}, E^T_{(k,2),j}, \dots, E^T_{(k,m_k),j}, E^T_{(s,1),j}, E^T_{(s,2),j}, \dots, E^T_{(s,m_s),j}]^T \tag{26}$$

式中，m_s和m_k分别表示共享专家数目和任务k的独享专家数目。特别注意，共享模块的选择矩阵由该层的所有专家组成。

塔式网络位于模型最顶部，负责吸收从共享专家和任务特定专家提取到的知识并输出任务结果，由多层神经网络构成。式（27）中$y^{k,N}(x)$为任务k的预测结果，t^k为任务k的塔式网络。

$$y^k(x) = t^k\left(g^{k,N}(x)\right) \tag{27}$$

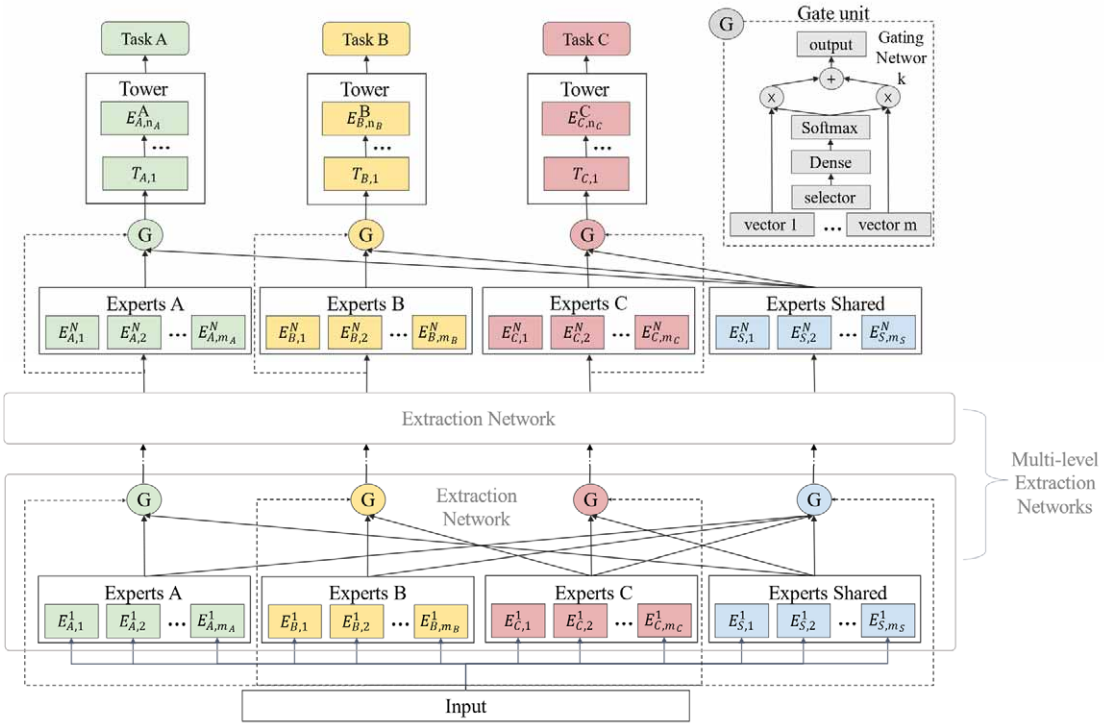


图 3-4 PLE 的具体结构

3.3.2 模型整体框架

鉴于上述方法，在 PLE 的基础上，本章提出了一种称为 CPLE 的协作负荷预测模型。如图 3-5 所示，利用 1DCNN 而不是 FC 作为特征提取单元从输入序列中提取信息。与基于 FC 的 PLE 相比，使用具有强大信息提取能力的卷积网络可以更好地从多个能源负荷和气象因素中提取隐藏的空间耦合信息。同时，由于 LSTM 在预测时间序列方面的出色性能，使用 LSTM 构建塔式网络来学习多能量数据的时间关系。该预测方法主要包括两个阶段：

（1）负荷分解与分析：首先清洗原始数据中缺失或异常的值[81,82]。使用

中国知网 https://www.cnki.net

STL 对清洗后电、冷、热负荷进行分解，获得对应的趋势、季节和剩余分量。接着计算分量与气象因素间的 MIC 值来筛选强相关气象特征。以不同负荷的相同类型分量为模型的输入变量，结合时间特征，分别构建每类分量的输入特征集。

（2）分量建模与预测：对（1）阶段获得的输入特征集进行归一化，然后为每类分量分别建立 CPLE 预测模型，将获得的季节、趋势和残差分量预测结果重组以获得的电、冷、热负荷预测值。其中，所提模型的最佳参数通过网格搜索[83]来确定，如表 3-1 所示。

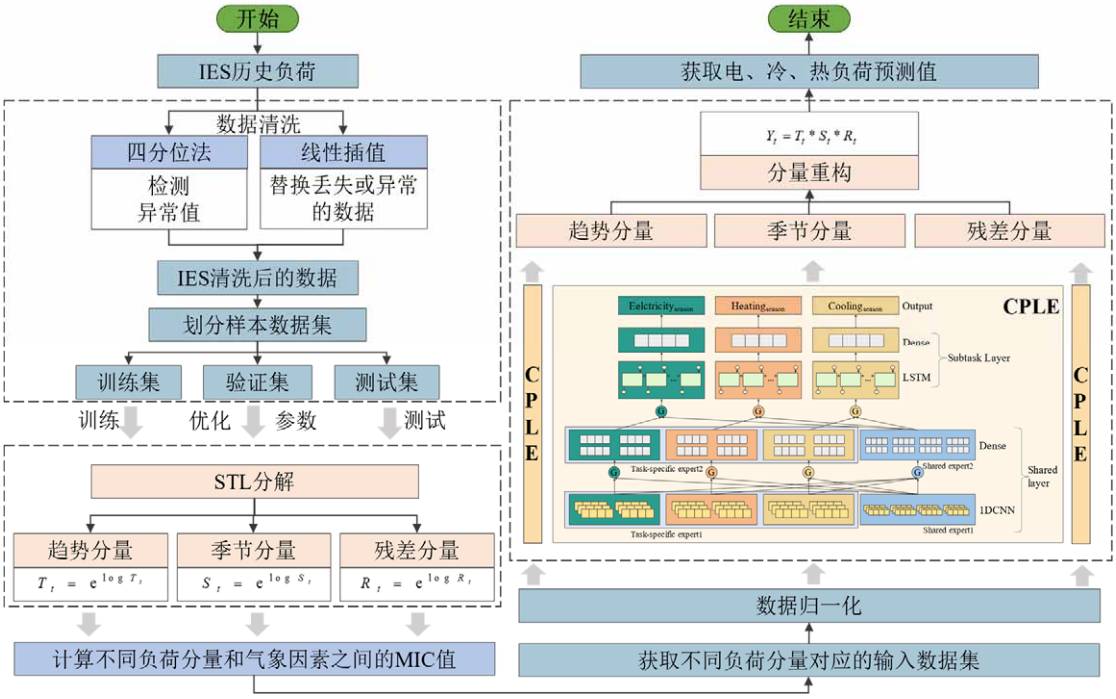


图 3-5 预测方法整体流程

表 3-1 所提模型参数

参数类型	参数名称	网络类型	数量	数值
架构参数	Shared expert1	1DCNN	4	16
	Task-specific expert1	1DCNN	2/2/2	16
	Kernel size			3
	Shared expert2	Dense	8	8
	Task-specific exper2t	Dense	4/4/4	8
	Subtask layer	LSTM	1/1/1	16
		Dense	1/1/1	1
优化参数	Loss function		MAE	
	Epoch		300	
	Optimizer		Adam	
	Batch size		64	
	Time step		12	

中国知网 https://www.cnki.net

3.4 算例分析

3.4.1 数据来源与实验环境

数据来自美国亚利桑那州立大学 CAMPUS METABOLISM 项目[84]，包含了坦佩校区2020和2021年的电、热、冷负荷，采样率1h/次，共16800个采样点。由于 IES 负荷数据单位不一致，式（28）[85]将不同类型的负荷单位统一转换为 MW。

$$1\mathrm{MW} = 284\mathrm{Ton} = 3.4\mathrm{mmBtu/h} \tag{28}$$

相应的气象数据是从全球天气精确预报网络爬取的，具体来自距离坦佩校区最近的气象站（凤凰城天港国际机场站）[86]。气象数据包括温度、露点、湿度、风速、阵风、气压、降水。该软件平台使用 TensorFlow 和 Keras 框架实现。硬件配置包括两个 Xeon 4215R CPU 和两个 NVIDIA RTX 3090 GPU。此外，为了确保平等地考虑每个变量的影响，确定数据集后进行归一化操作。

3.4.2 评价指标

为了全面评估所提预测模型效果，采用 RMSE、MAPE 和权重平均精度（Weighted Mean Accuracy，WMA）为评价指标。

考虑 IES 自身结构以及各负荷的重要程度，设置 WMA 指标中电、冷、热负荷的权重值分别为 0.4、0.4、0.2[87]。相关公式见（29）、（30）。

$$MA = 1 - MAPE \tag{29}$$

$$WMA = \alpha_{elec} MA_{elec} + \alpha_{cool} MA_{cool} + \alpha_{heat} MA_{heat} \tag{30}$$

3.4.3 输入特征选择和数据集划分

考虑到负荷的季节差异，将数据按照春、夏、秋、冬四季进行划分。对每个季节的数据，按照 8：1：1 的比例划分为训练集、验证集和测试集后，结合构成整体的训练集、验证集与测试集[88]。

根据动态分解和预测的思路，对原始负荷数据进行 STL 分解[79]。三类负荷分别被分解为趋势、季节及残差项。负荷中的规律和随机成分被分离，一方面清晰呈现了负荷的趋势和周期变化模式，另一方面避免了噪声对趋势和季节分量预测的干扰。STL 分解预测法直观易懂并暴露出更多的信息，从不同的方面把握数据的变化特征，减少了随机波动对负荷预测的影响。

为了模型更加简洁高效，采用 MIC 方法分析多元负荷与气象因素的相关性，筛选出对目标变量影响力强的特征。将 MIC 值大于 0.3 的视为强相关关系，小

中国知网 https://www.cnki.net

于 0.1 的视为弱相关关系[89]。由 MIC 热力图 3-6 可知，多元负荷之间存在强相关性。负荷与温度和露点温度存在强相关性，与湿度、压力存在中等程度相关性。与风速、风向、降雨量的相关性几乎为零，故在后续的分析中直接剔除了这三种气象因素。

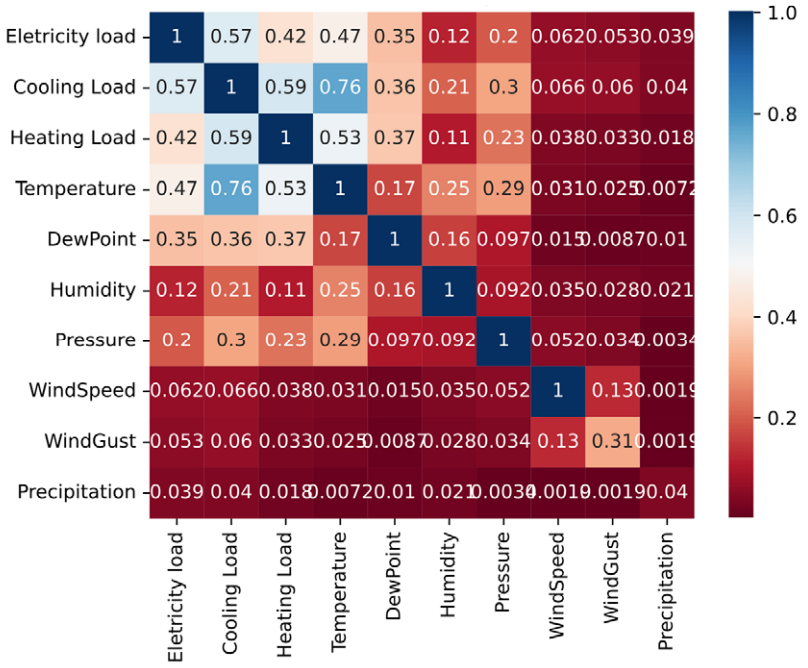


图 3-6 相关性分析热图

原始负荷分解后会将负荷原本的变化规律分解到不同分量中，这些分量代表了负荷的不同特性。分量所受影响的因素可能会因其所代表的负荷类型或特征而不同。同时，季节的差异性也会导致影响因素的改变。因此需要针对不同季节下的不同负荷分量，选择合适的输入特征进行预测。通过计算不同季节下负荷分量与天气数据之间的 MIC 值可知，气象因素对负荷的趋势分量集合影响较强，对季节和残差分量集合影响较小。在夏季，多元负荷趋势项与露点温度、湿度有较强相关性，MIC 均值大于 0.3。在冬季，与温度和露点温度关联程度深，MIC 均值大于 0.3。根据相关性分析结果，为不同季节下的三种负荷分量分别构建输入特征。

3.4.4 实验框架

本章主要通过两组实验来验证 STL-CPLE 模型的有效性。在负荷预测模型方面，将 LSTM、CNN-LSTM、TCN、基于 LSTM 的 DA-Seq2Seq 四种单任务模型作为对比，其中 CNN-LSTM 是 CPLE 对应的单任务模型。将 CNN-BiGRU-Attention、Transformer、LSTNet-Skip、MMoE 四种多任务模型作为对比。并对

中国知网 https://www.cnki.net

CPLE 进行了消融实验。在负荷分解方法方面，以 CPLE 作为底座模型，将不分解、EMD 分解、CEEMD 与基于加法形式的 STL 分解方法作为对比。实验所用模型参数如表 3-2 所示。

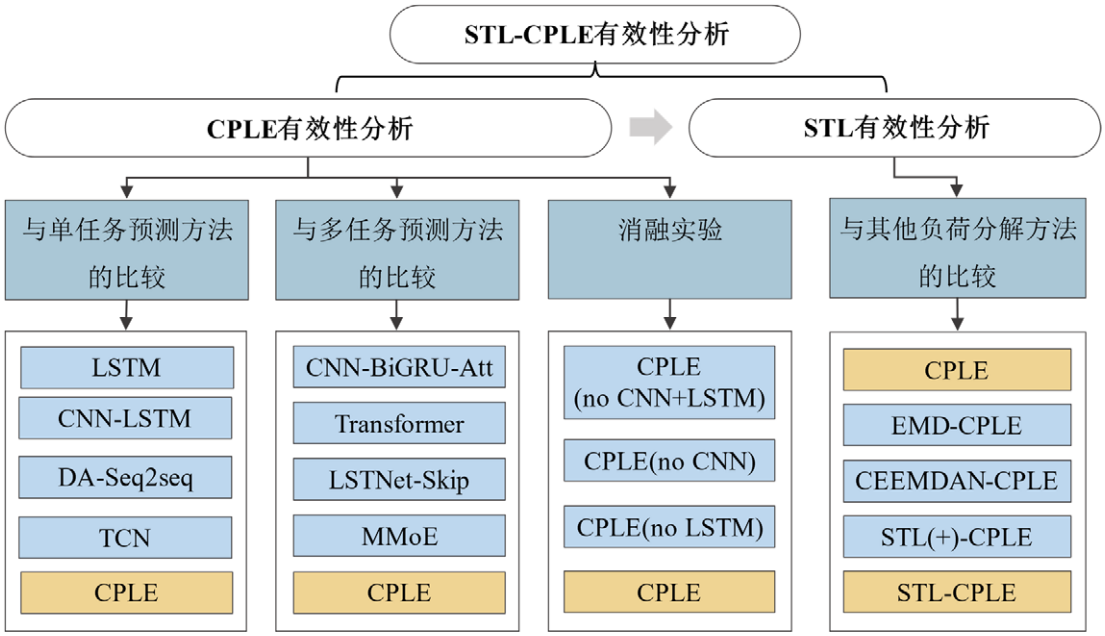


图 3-7 实验框架

表 3-2 对比模型参数

模型类型	模型名称	参数	值
单任务模型	LSTM	LSTM 隐藏单元的数量	16
	CNN-LSTM	CNN 隐藏单元数量	16
		卷积核大小	3
		Dense 隐藏单元的数量	8
		LSTM 隐藏单元的数量	16
	TCN[40]	TCN 隐藏单元的数量	32
		卷积核大小	4
		膨胀系数	[1,2,4]
		辍学率	0.2
	DA-Seq2Seq (LSTM)	编码器隐藏单元数	128
		解码器隐藏单元数	128
		注意力层数	2
		注意力隐藏单元的数量	[时间步长、特征数]

中国知网 https://www.cnki.net

续表

模型类型	模型名称	参数	值
多任务模型	CNN-BiGRU-Attention[50]	CNN 隐藏单元数量	[4,8]
		卷积核大小	[3,3]
		BiGRU 隐藏单元的数量	10
		注意力层数	3
		注意力隐藏单元的数量	64
	Transformer[51]	Transformer 模块数量	2
		注意力头数	4
		注意力头大小	16
		Dense 隐藏单元的数量	16
	LSTNet-Skip[87]	CNN 隐藏单元数量	100
		RNN 隐藏单元的数量	100
		Skip-RNN 层的跳跃长度	4
		卷积核大小	6
		辍学率	0.2
	MMoE[53]	专家数量	4/4/4/4
		专家隐藏单元数量	32/32/32/32
		子任务层（LSTM）隐藏单元的数量	[16,8]/ [16,8]/ [16,8]
		辍学率	0.3

3.4.5 不同单任务预测模型比较

为验证所提模型在多能负荷预测中的优越性，首先与单任务模式的 LSTM、CNN-LSTM、DA-Seq2Seq、TCN 模型进行比较。模型详细预测结果见表 3-3。所提模型与其他模型的整体性能比较见表 3-4。 图 3-8 展示了夏季、冬季的测试集中连续 48h 的预测对比。从图中可以看出，所提模型的预测曲线更贴合真实负荷曲线。与单一负荷预测方法相比 MAPE 和 RMSE 更小，在冷负荷预测方面提升更为显著。所提模型与对应的单任务模型 CNN-LSTM 相比，CPLE 电热冷负荷的 MAPE 分别降低了 17.81%、40.16%、15.64%。与单任务模型中预测效果最好的是 DA-Seq2seq 相比，三类负荷的 MAPE 仍然降低了 21.44%、35.59%、9.38%。即使加入了其他负荷作为辅助特征，单任务方法仍然难以有效利用 IES 负荷之间的相关性和互补性。

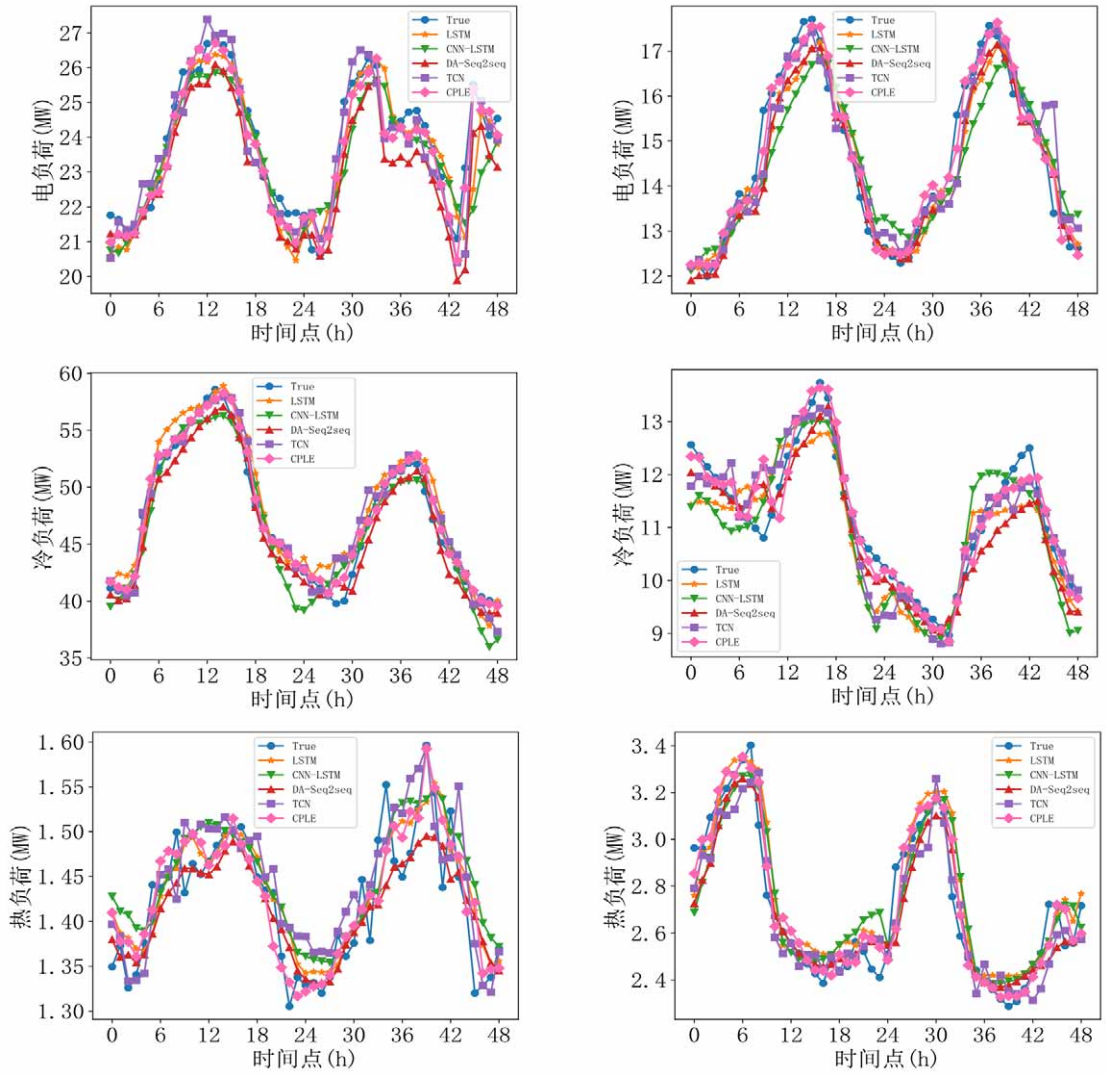
表 3-3 单任务预测结果的 MAPE、RMSE 和 WMA 评估指标

季节	模型	RMSE(MW)			MAPE(%)			WMA(%)
		电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
春季	LSTM	0.97	0.89	0.07	4.37	2.99	3.11	96.43
	CNN-LSTM	0.89	0.90	0.06	3.25	3.07	2.62	96.94
	TCN	0.92	0.93	0.07	4.23	2.95	3.08	96.51
	DA-Seq2seq	0.72	1.06	0.06	2.82	3.71	2.64	96.86
	CPLE	0.75	0.75	0.05	2.96	2.14	2.43	97.47

中国知网 https://www.cnki.net

续表

季节	模型	RMSE(MW)			MAPE(%)			WMA(%)
		电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
夏季	LSTM	1.22	1.61	0.05	3.80	2.98	2.97	96.69
	CNN-LSTM	1.01	1.81	0.04	2.92	3.43	2.55	96.95
	TCN	0.85	1.40	0.05	2.61	2.50	3.02	97.35
	DA-Seq2seq	1.20	1.15	0.04	3.97	2.11	2.56	97.05
	CPLE	0.70	1.00	0.04	2.16	1.71	2.55	97.94
秋季	LSTM	0.99	1.64	0.09	4.80	8.27	4.60	93.85
	CNN-LSTM	0.85	0.82	0.08	3.68	3.83	3.95	96.20
	TCN	0.82	1.26	0.08	3.87	5.75	3.83	95.39
	DA-Seq2seq	0.81	0.86	0.06	3.84	4.49	2.84	96.10
	CPLE	0.75	0.51	0.06	3.27	2.47	2.97	97.11
冬季	LSTM	0.75	0.68	0.12	3.72	4.95	3.26	95.88
	CNN-LSTM	0.60	0.61	0.11	2.78	4.48	2.99	96.50
	TCN	0.62	0.57	0.11	2.86	3.88	2.99	96.71
	DA-Seq2seq	0.57	0.48	0.11	2.59	3.46	3.25	96.93
	CPLE	0.47	0.38	0.08	1.99	2.53	2.28	97.74



（a）夏季　　（b）冬季

图 3-8 单任务模型的电、热、冷负荷预测曲线比较

中国知网 https://www.cnki.net

表 3-4 CPLE 模型与其他单任务模型的整体精度提升对比

模型	RMSE(%)			MAPE(%)			WMA(%)
	电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
CPLE vs LSTM	31.78%	45.19%	25.58%	37.79%	53.83%	26.67%	1.93%
CPLE vs CNN-LSTM	20.33%	36.09%	16.88%	17.81%	40.16%	15.64%	0.95%
CPLE vs TCN	14.49%	31.20%	42.30%	21.00%	40.81%	39.30%	1.27%
CPLE vs DA-Seq2seq	19.03%	25.65%	10.80%	21.44%	35.59%	9.38%	0.85%

3.4.6 不同多任务预测模型比较

接下来与其他多任务预测模型进行比较，包括 CNN-BiGRU-Attention，Transformer，LSTNet-Skip，MMoE。前三者基于传统硬共享方法；MMoE 基于多门控混合专家的共享方法；CPLE 基于渐进式分层提取的共享方法。对比模型的参数见表 3-2。基于春夏秋冬四个测试集的模型预测误差见表 3-5。CPLE 与其他模型的整体性能比较见表 3-6。为了更直观地分析预测性能，图 3-9 展示了夏冬两季测试集中连续 48h 的预测曲线。下面是对预测结果的详细分析。

从预测结果来看，CPLE 的精度最高，MMoE 的精度次之。接着是 CNN-BiGRU-Attention，最后是 LSTNet-Skip、Transformer。相较于其他模型，CPLE 显著提高了 HL、CL 预测精度。这表明所提模型充分利用冷热负荷之间的互补性，为 HL、CL 预测提供了丰富的辅助信息，有效改善了冬季冷负荷和夏季热负荷的预测效果。基于传统硬共享的模型效果最差，是因为该架构不能考虑到多能负荷之间耦合程度的差异，完全共享底层参数。这可能会导致关联性相对较弱的任务给共享参数带来噪声，产生负面影响。LSTNet-Skip、Transformer 这两个模型效果低于 CNN-BiGRU-Attention，可能是因为受到滑动窗口的限制，它们更适合处理长时间序列预测。

与传统硬共享方法中效果最好的 CNN-BiGRU-Attention 相比，MMoE 的 MAPE 指标平均降低了 0.12%，RMSE 平均降低了 9.21%，WMA 提升了 0.21%。表明 MMoE 改善了存在较大误差的预测点。如图 3-9 中所示，MMoE 明显减小了在峰谷值的预测误差，特别是夏季热负荷和冬季冷负荷。验证了多专家与多门控的集成方式可以使共享网络更全面学习负荷的变化规律，优化任务信息分配。从四季测试结果来看，春季 MMoE 的 WMA 低于 CNN-BiGRU-Attention，虽然 CL 的预测效果好，但热和冷负荷的精度被牺牲，导致多任务预测的整体性能退化。这验证了 MMoE 共享方式的局限性。在 MMoE 中，所有专家被所有任务共享，只依赖于门控网络可能难以对负荷之间更复杂的关系建模，使得一些任务提升会牺牲另一部分任务的性能。

CPLE 与 CNN-BiGRU-Attention 相比，不管是整体评估还是四季分别评估，都具有更好的性能表现。与 MMoE 相比，整体电热冷评估好于 MMoE，四季测

中国知网 https://www.cnki.net

评时 WMA 指标优于 MMoE，MAPE 和 RMSE 大多数时候处于领先。表明了所提共享模型的先进性。虽然 CPLE 的效果要优于这两个模型，但可能是网络结构或参数等其他因素的影响。因此，为了验证所提模型“定制专家和门控+渐进式分离路由”的共享方法要优于传统硬共享方法以及 MMoE 的“无差别专家和门控+全连接路由”的共享方法，设置仅多任务学习方法不同，重建 CNN-LSTM 以及 MMoE 进行比较。重建的 CNN-LSTM 记为 CNN-LSTM*，MMoE 记为 MMoE*。表 3-7 是 PLE 与其他共享方法的性能对比，结合表 3-4 来分析三种共享方法的性能。在三种共享方法中，PLE 方法效果最好，传统方法效果最差。CNN-LSTM*的预测精度甚至低于对应单任务方法，出现严重的负迁移问题。MMoE*的效果要比原始的 MMoE 更接近 CPLE，但还是存在一定差距。CPLE 的整体测试集所有评价指标均优于 MMoE*，四季测试集其 WMA 同样优于 MMoE*，但 MAPE 和 RMSE 仍然没有全面领先 MMoE*。表明 PLE 方法虽可以缓解跷跷板现象，但不能避免，但从整体评价来讲 PLE 性能最优，提高了共享学习效率。

表 3-5 多任务预测结果的 MAPE、RMSE 和 WMA 评估指标

季节	模型	RMSE(MW)			MAPE(%)			WMA(%)
		电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
春季	CNN-BiGRU-Att	0.81	0.73	0.07	3.30	2.13	3.17	97.19
	Transformer	0.81	0.60	0.07	3.16	1.79	2.95	97.43
	LSTNet-Skip	0.87	0.68	0.06	3.95	2.15	2.57	97.05
	MMoE	0.84	0.66	0.08	3.36	2.03	3.52	97.14
	CPLE	0.76	0.75	0.06	2.96	2.15	2.43	97.47
夏季	CNN-BiGRU-Att	0.95	1.44	0.05	2.92	2.63	2.77	97.23
	Transformer	0.71	1.21	0.05	2.22	2.23	2.89	97.64
	LSTNet-Skip	0.75	1.18	0.05	2.30	2.11	2.62	97.71
	MMoE	0.67	1.08	0.04	2.07	1.94	2.38	97.92
	CPLE	0.71	1.01	0.05	2.16	1.72	2.55	97.94
秋季	CNN-BiGRU-Att	0.82	0.56	0.09	4.05	2.74	3.88	96.51
	Transformer	0.79	0.54	0.09	3.94	2.59	4.14	96.56
	LSTNet-Skip	0.78	1.10	0.07	3.61	5.58	3.23	95.68
	MMoE	0.72	0.60	0.07	3.04	2.89	3.32	96.96
	CPLE	0.75	0.51	0.07	3.27	2.47	2.97	97.11
冬季	CNN-BiGRU-Att	0.58	0.63	0.15	2.63	4.64	4.28	96.23
	Transformer	0.60	0.86	0.11	2.63	6.06	3.03	95.92
	LSTNet-Skip	0.51	0.39	0.09	2.34	2.69	2.40	97.51
	MMoE	0.49	0.40	0.09	2.14	2.90	2.53	97.48
	CPLE	0.47	0.39	0.09	1.99	2.53	2.28	97.74

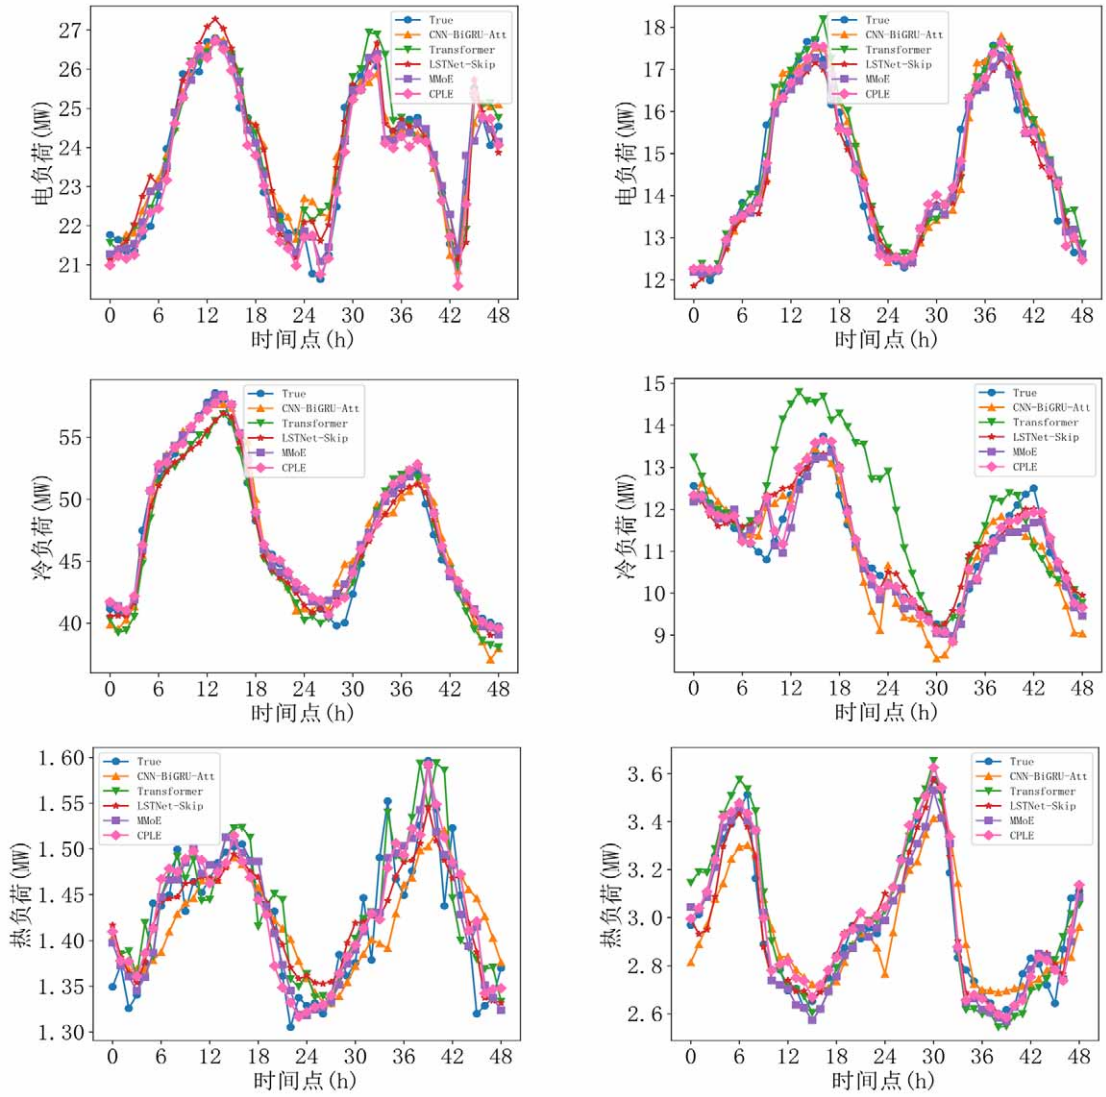
中国知网 https://www.cnki.net

表 3-6 CPLE 模型与其他多任务模型的整体精度提升对比

模型	RMSE(%)			MAPE(%)			WMA(%)
	电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
CPLE vs CNN-BiGRU-Att	12.74%	13.18%	17.68%	16.01%	8.09%	17.32%	0.40%
CPLE vs Transformer	7.38%	17.37%	19.40%	13.09%	29.99%	21.43%	0.70%
CPLE vs LSTNet-Skip	7.57%	20.77%	5.54%	14.82%	29.22%	5.51%	0.59%
CPLE vs MMoE	1.36%	3.21%	12.03%	2.15%	9.08%	13.05%	0.19%

表 3-7 PLE 共享方法与其他共享方法的总体精度提升比较

模型	RMSE(%)			MAPE(%)			WMA(%)
	电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
CPLE vs CNN-LSTM*	13.39%	31.22%	47.72%	15.49%	40.64%	46.56%	1.29%
CPLE vs MMoE*	2.72%	4.91%	0.39%	0.59%	7.37%	0.42%	0.09%



（a）夏季 （b）冬季

图 3-9 多任务模型的电、热、冷负荷预测曲线比较

中国知网 https://www.cnki.net

3.4.7 消融实验

前面进行了与其他预测模型的横向对比。为进一步验证 CPLE 模型每个组件的必要性，设置消融实验进行分析。通过减少组件来评估每个组件对模型性能的贡献。首先，分别去除 CNN 模块和 LSTM 模块，以同样参数的 Dense 代替，检验 CNN 对特征的抽取能力，以及 LSTM 对时序数据的建模能力。然后，将 CNN 模块和 LSTM 模块同时替换，只使用 PLE 多任务学习方法。一共包含三个场景：（1）仅删除 CNN 模块（-C）。（2）仅移除 LSTM 模块（-L）。（3）同时去除 LSTM 和 CNN（-（C+L））。结果总结于表 3-8。

分别移除 CNN 模块和 LSTM 模块后，该模型的性能下降，但比同时移除 CNN 模块和 LSTM 模块的模型效果要好。这表明所提方法对共享层和子任务层的改进都是有效的，并且两者结合可以进一步提高预测准确性。分析此情况出现的原因：与普通全连接网络相比，使用一维卷积网络作为特征提取层可以更好地挖掘多能之间隐藏的相关性，并为下一模块提供保留时序特性的耦合特征信息。而 LSTM 独特的循环神经网络结构使其能够学习到较长的时间片特征，从而捕捉更全面的时间信息。仅使用 CNN 缺乏对长期时间依赖关系进行建模的能力，而仅使用 LSTM 则不能很好地提取空间耦合特征，这两种方法都存在局限性。因此所提模型结合 CNN 和 LSTM 网络的特点，采用基于先验分离的 PLE 多任务学习框架，在充分提取不同类型负荷之间潜藏的时空关系的同时处理好任务冲突，有效地增强了模型表达能力。

表 3-8 CPLE 消融研究

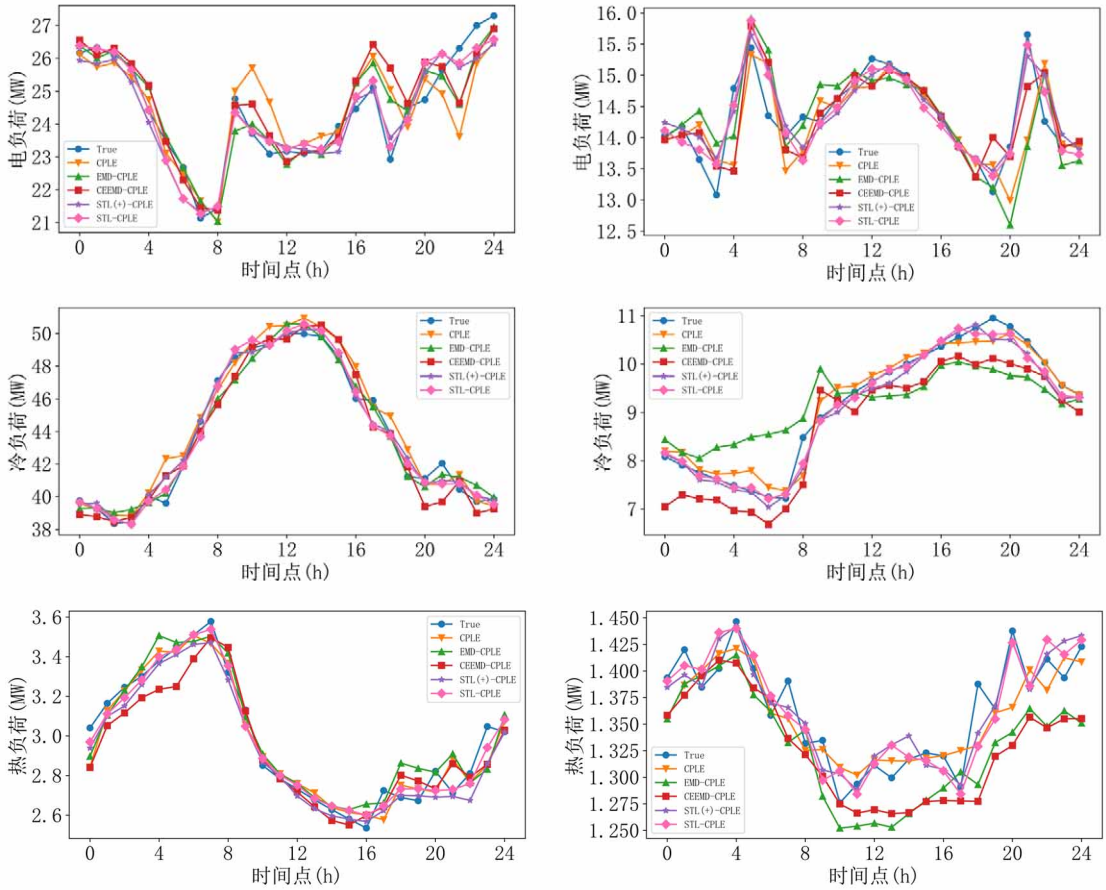
模型	RMSE(MW)			MAPE(%)			WMA(%)
	电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
CPLE	0.67	0.66	0.06	2.60	2.22	2.56	97.56
-C	0.70	0.65	0.07	2.66	2.27	2.78	97.47
-L	0.71	0.66	0.07	2.66	2.31	2.79	97.45
-(C+L)	0.72	0.70	0.07	2.74	2.44	2.88	97.35

3.4.8 不同负荷分解方法比较

为评估所提出的基于乘法形式的 STL 方法的分解效果，基于 CPLE 模型，以不分解，EMD 分解，CEEMD 分解，基于加法形式的 STL 分解作为对比。基于乘法形式的 STL 方法记为 STL，基于加法形式的 STL 分解记为 STL(+)。设置 STL 的周期窗口与输入特征的时间步长一致。STL(+)的参数同 STL。EEMD 的迭代次数为 1000，白噪声标准差为 0.2，CEEMD 迭代次数为 100，白噪声标准差与 EEMD 相同。此外，为优化 EMD 和 CEEMD 获得的 IMF 特征，根据样本熵和过零率将其分频处理。表 3-9 展示了不同分解方法的整体评估指标值。图 3-10 是夏季和冬季典型日的负荷预测结果。

中国知网 https://www.cnki.net

分解方法的表现排名为：STL>STL(+)>CEEMD>不分解>EMD。结果表明 STL 的分解不影响 CPLE 模型的预测能力。不仅证明了所提分解方法的适用性，还证实了所提模型的泛化性。EMD 效果最差，甚至低于不分解。CEEMD 和不分解效果接近。如图 3-10 所示，在负荷波动剧烈处，EMD 和 CEEMD 不能很好的拟合。这是由于 EMD 存在模态混叠，即使通过分频优化，负荷特征也可能无法良好提取。不进行负荷分解虽避免了 EMD 的这一问题，但难以拟合原始负荷信号的强随机性与波动性特征。相比于不分解，CEEMD 的预测性能更好。但 CEEMD 的整体指标低于 STL 大约 1 个百分点。这可能因为 IMF 中残留了一些白噪声，从而影响了后续的负荷预测。实验结果表明，STL 将不确定信息分离出来再预测，一方面有助于捕捉随机性波动，另一方面避免了对规律信息的干扰，可以更好的对负荷的趋势、周期特征建模。STL 精度要高于 STL(+)，验证了乘法分解比加法分解适合处理负荷周期不断发生变化的情况。



（a）夏季 （b）冬季

图 3-10 不同分解方法下的电、热、冷负荷预测曲线比较

中国知网 https://www.cnki.net

表 3-9 不同负荷分解方法的 MAPE、RMSE 和 WMA 评估指标

模型	RMSE(MW)			MAPE(%)			WMA(%)
	电负荷	冷负荷	热负荷	电负荷	冷负荷	热负荷	
CPLE	0.67	0.66	0.06	2.60	2.22	2.56	97.56
EMD-CPLE	0.61	0.67	0.06	2.37	2.97	2.55	97.35
CEEMD-CPLE	0.60	0.68	0.06	2.38	2.41	2.51	97.58
STL (+)-CPLE	0.40	0.39	0.04	1.70	1.30	1.70	98.46
STL-CPLE	0.38	0.41	0.04	1.60	1.38	1.64	98.48

3.5 本章小结

以解耦负荷和提高联合学习性能为目标，本章提出了一种名为 STL-CPLE 的短期联合负荷预测方法。以美国亚利桑那州立大学坦佩校区 IES 为对象进行了验证和分析。主要结论如下：

（1）STL 分解方法将负荷包含的不同特征分离，明确物理含义的同时降低了负荷的复杂度，有利于后续的建模和预测。电、热、冷负荷预测 MAPE 指标分别为 1.60%，1.37%，1.63%，WMA 为 98.48%，较其他分解方法误差更低，准确性更高。

（2）PLE 共享方法优化了负荷之间耦合关系的建模，有效缓解了多任务学习方法中负迁移、跷跷板现象。与对应单任务相比，三类负荷的 MAPE 平均降低了 24.54%，WMA 提高了 0.95%。与对应传统共享方法相比，MAPE 平均降低了 34.32%，WMA 提高了 1.29%。

（3）CPLE 基于 PLE 策略，引入 CNN、LSTM 网络进一步改进，充分发挥了混合网络的优势。与单任务中的最先进的方法相比，MAPE 平均降低了 22.14%，WMA 提高了 0.85%。与多任务中的最先进的方法相比，MAPE 平均降低了 8.05%，WMA 提高了 0.19%。

中国知网 https://www.cnki.net

第四章　基于 TimeVAE 和迁移学习的小样本负荷预测

4.1 概述

第三章研究了具有充足的历史负荷数据条件下 IES 多元负荷预测方法。然而，实际应用中，新建设的 IES 的数量可能远大于拥有完整历史数据的系统。这意味着许多新系统没有足够的历史数据。但不管是多元负荷预测模型还是单一负荷模型，在没有足够样本的情况下都难以进行准确的负荷预测。

因此，本章针对第三个挑战：新建 IES 用于负荷预测的训练样本稀缺，从而导致包含未来信息量有限的问题，提出基于 TimeVAE 和迁移学习的小样本负荷预测方法。具体方法为：（1）构建数据增强模块。利用 TimeVAE 学习数据的分布和特征，增强目标域数据的代表性和多样性。采用 MMD 衡量样本相似性，确保人工样本集与真实样本集具有相同的分布。（2）构建迁移学习模块。根据迁移学习的思想，以第三章提出的 CPLE 模型为底层模型，转移在源域中学习到的模型参数和经验，快速适应目标域数据。这里采用 MMD 来过滤源域数据，选择相似度较高的样本进行训练，以减少负迁移的影响。（3）搭建基于数据增强和迁移学习的小样本负荷预测模型。（4）算例分析。进行了三组对比实验，分别验证 TimeVAE、迁移学习的可行性以及所提模型的先进性。此外，进行消融实验表明每个模块的必要性。本章主要结构如下：4.1 节进行了本章内容概述，4.2 和 4.3 节分别分析了数据增强策略和迁移策略，4.4 节描述了所提预测框架细节，4.5 节报告了实验结果，4.6 节给出了结论。

4.2 基于 TimeVAE 的数据增强

对于新建 IES 或 IES 新接入用户，历史负荷数据往往非常有限。在这种情况下，使用现有的预测模型可能会因为预测所需信息量不足，从而导致预测准确性显著下降甚至失效。因此，可以考虑采用人工数据生成的方法来扩充数据集信息量。然而，负荷序列中复杂的时间依赖性使得合成数据生成具有挑战性。此外，目前常用的基于 GAN 的数据生成模型存在模式崩溃[90]、耗时、训练数据不足等局限性。

TimeVAE 是一种可以在数据量很小的情况下最大限度地生成真实的时序数据样本的方法[91]。相比于 GAN，TimeVAE 能够准确表征原始数据的时间属性并

中国知网　https://www.cnki.net

且有效减少训练开销，其模型结构如图 4-1 所示。从图中可以看出，输入数据X首先通过一系列卷积层+ReLU 激活函数提取时间序列的特征，接着对卷积层的输出进行 flatten，送入全连接层。全连接层的输出是潜在变量的分布参数，通常包括均值μ和标准差σ。然后，使用重参数化技巧从多变量高斯分布中采样潜在变量z。解码器接收采样的潜在变量z经过一个全连接层后被重塑回三维数组的形状，再通过一系列转置卷积层+ReLU 激活函数重建原始数据，最后利用全连接层生成与原始输入数据X形状相同的输出。假设给定一个输入数据集X，由一些连续或离散变量x的N个样本组成。TimeVAE 具体工作原理如下。

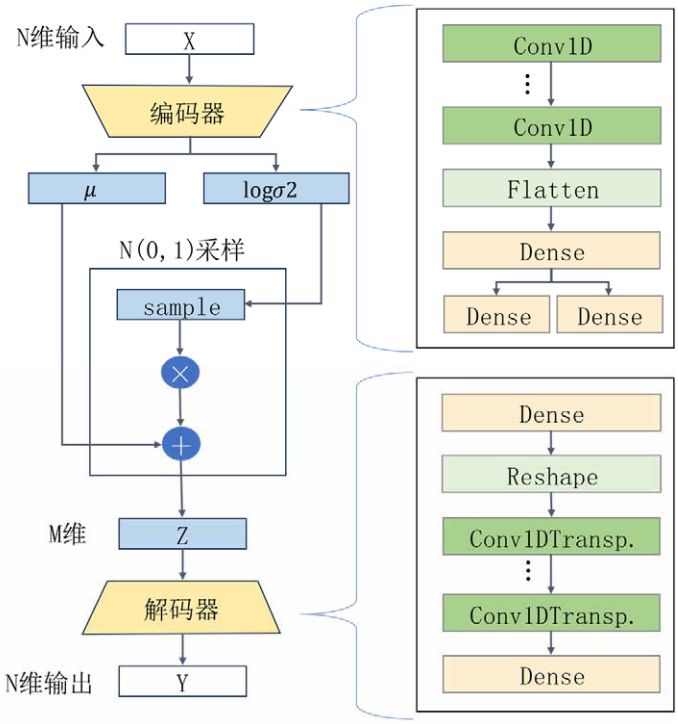


图 4-1 TimeVAE 模型架构

（1）编码器：

编码器的输出是输入数据x映射到潜在空间中的潜在变量z的概率分布。这个分布通常是高斯分布，由编码器网络输出的均值向量μ和方差向量σ^2参数化。假设z是从均值为 0，方差为 1 的标准正态分布中采样得到的噪声。则编码器网络输出的μ和σ^2可以表示为：

$$(\mu, \log \sigma^2) = \text{Encoder}(x) \tag{31}$$

（2）潜在变量采样：

为了能够在训练过程中对潜在变量进行采样，需要使用重参数化技巧。先从标准正态分布中采样噪声ϵ，然后利用编码器得到均值μ和标准差σ进行线性变换，计算得到潜在变量z。

中国知网 https://www.cnki.net

$$z = \mu + \epsilon \cdot \sigma \tag{32}$$

其中，ϵ是从标准正态分布中采样。z的采样过程是可微的，这使得 VAE 可以通过反向传播进行训练。

（3）解码器：

解码器将潜在变量z映射回原始数据空间，重构出与输入数据x类似的数据样本$\hat{x}$的概率分布。解码器网络的输出表示重构数据的条件分布，则解码器网络输出的条件分布参数θ可以表示为：

$$p_\theta(x \mid z) = \text{Decoder}(z) \tag{33}$$

（4）损失函数和训练：

TimeVAE 使用证据下界（Evidence Lower Bound，ELBO）损失函数进行训练，通过调整网络参数 θ和 ϕ 来最小化损失。该函数由两部分组成：重构误差（负对数似然）和 KL 散度（正则化项）。ELBO 损失函数的公式表示为：

$$\text{ELBO}(\theta, \phi) = -\text{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] + \text{DKL}(q_\phi(z \mid x)||p_\theta(z)) \tag{34}$$

其中，第一项是重构误差，表示观测数据x的对数似然在后验分布$q_\phi(z|x)$下的期望。第二项是是 KL 散度，表示后验分布$q_\phi(z|x)$与先验分布$p_\theta(z)$之间的 KL 散度，用于衡量两个分布之间的差异。

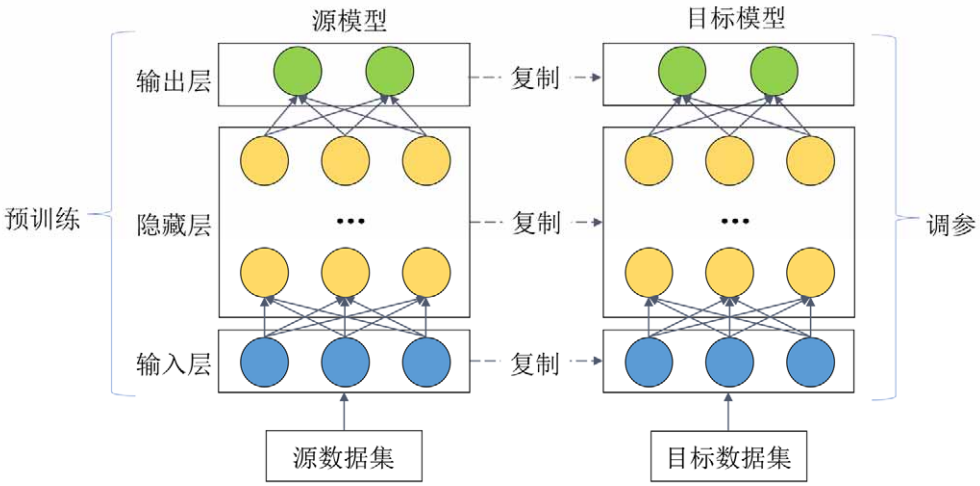
4.3 基于 MMD 的参数迁移

迁移学习可以通过从具有相似负荷消费模式的其他 IES 或用户转移样本或知识来补充目标域任务所需信息量。迁移学习定理为：给定一些源域和任务的数据集$(Dom_{s_i}, Tsk_{s_i})|i = 1, 2, \ldots, n^s$以及一些目标域的数据集和任务$(Dom_{T_i}, Tsk_{T_i})|i = 1, 2, \ldots, n^T$，迁移学习的目标是将源域知识运用到目标域，以提高学习到的决策函数$f^T{}_j(j = 1, 2, \ldots, n^T)$的预测性能。

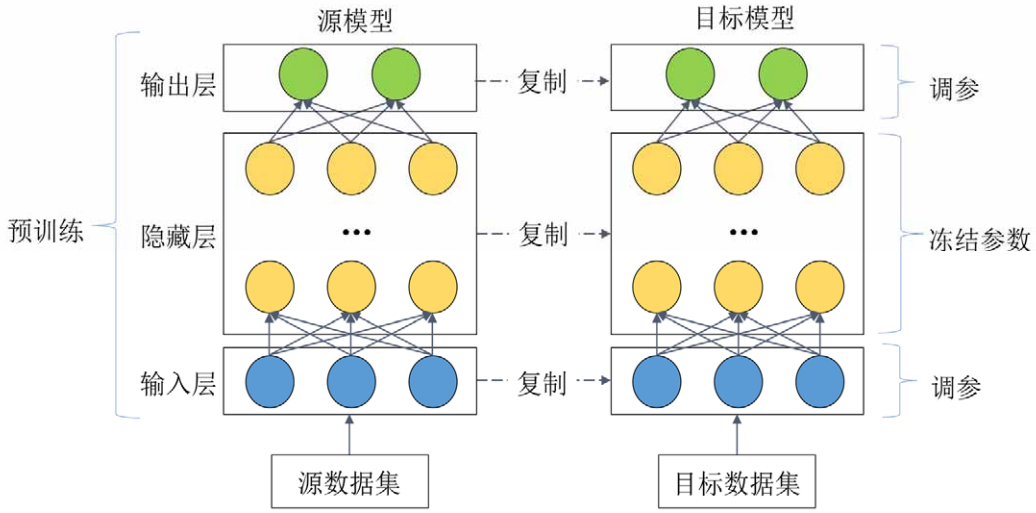
图 4-2 展示了迁移学习两种策略：全模型微调和冻结训练[74]。在全模型微调过程中，以源域数据训练得到的源模型作为初始状态，然后在目标域数据上继续训练对所有参数进行优化。这种策略可以很好的拟合目标域数据，但需要较多的计算资源和时间。此外，如果目标域数据质量较低可能会导致后继学习对先前学习产生消极影响。因此，全模型微调适合源域和目标域之间的差异较大，或者目标域数据较多且质量较高的情况。相比之下，冻结训练中源模型的大部分权重保持不变，仅更新顶层参数权重（通常是输出层）以适应目标任务。这种策略能够继承源模型的有用特征，减少资源消耗及过拟合风险，但也可能因源域和目标域之间的差异较大而产生负迁移现象。在本章中，考虑到目标域

中国知网　https://www.cnki.net

是新建的 IES，其样本数据量较少，且源域为具有丰富历史负荷数据的同类型 IES。选择冻结训练模式进行迁移学习。



（a）全参数微调



（b）冻结训练

图 4-2 迁移学习策略

为进一步减少负面迁移，使用最大均值差异算法来衡量源域 IES 数据和目标 IES 数据之间的相似性。最大均值差异（Maximum Mean Discrepancy，MMD）是一种用于衡量两个概率分布之间差异的方法[92]，通过比较两个分布在特征空间中的均值和协方差来评估它们之间的距离。具体地，如果源域和目标域的分布越相似，则它们在特征空间中的均值和协方差之间的距离越小，MMD 值就越接近于 0；反之，如果它们之间的分布差异较大，则 MMD 值会较大。

MMD 的计算可以通过核函数来实现，通常采用高斯核函数。其计算公式如下：

中国知网 https://www.cnki.net

$$\mathrm{MMD}^2 = \frac{1}{n(n-1)}\sum_{i=1}^{n}\sum_{j=1}^{n}k(x_i,x_j) - \frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m}k(x_i,y_j) + \frac{1}{m(m+1)}\sum_{i=1}^{m}\sum_{j=1}^{m}k(y_i,y_j) \tag{35}$$

其中，n和m分别表示源域和目标域的样本数，x_i和y_j分别表示源域和目标域的样本，$k(\cdot,\cdot)$是核函数。

4.4 负荷预测的集成框架

本章节提出了一个基于 TimeVAE 和迁移学习的集成学习框架，分别执行数据增强和知识转移。在迁移学习模块中，基于源域输入集优化模型参数，进行参数的迁移和微调。在数据增强模块中，通过 TimeVAE 生成负荷数据增强目标域数据集实现模型再训练、参数微调和多元负荷预测。具体流程如图 4-3 所示。每个模块的详细计算过程如下。

（1）数据增强模块：

首先，根据滑动窗口构建原始目标域的真实输入数据集$S^{RAW} = \{S_{N_1-a}^{RAW}, S_{N_1-a+1}^{RAW}, \dots, S_{N_1}^{RAW}\}$以及基于 TimeVAE 的人工数据集$S^{TVAE} = \{S_{N_2-a}^{TVAE}, S_{N_2-a+1}^{TVAE}, \dots, S_{N_2}^{TVAE}\}$。$N_1$、$N_2$分别为真实输入集、人工输入集的样本数量，$a$为滑动窗口长度。则 t 时刻对应的原始样本为：

$$S_t^{RAW} = [\mathrm{X}_{t-a}\mathrm{X}_{t-a-1}, \dots, \mathrm{X}_{t-1}] \tag{36}$$

$$\mathrm{X}_{t-1} = [f_{t-1}^1, f_{t-1}^2, \dots, f_{t-1}^m] \tag{37}$$

其中，X_{t-1}为$t-1$时刻的特征序列，m表示特征数量。

然后，使用 TimeVAE 对 t 时刻输入特征进行增强，生成的数据表示为：

$$S_t^{TVAE} = [\hat{\mathrm{X}}_{t-a}, \hat{\mathrm{X}}_{t-a-1}, \dots, \hat{\mathrm{X}}_{t-1}] \tag{38}$$

为了确保由 TimeVAE 生成的人工样本与真实样本数据具有相同的分布，使用 MMD 来衡量人工数据集和真实数据集之间的相似性。当两个数据集的相关系数低于某一阈值时判断生成失败，重新进行生成。最终目标域输入集表示为：

$$S^{target} = \{S^{RAW}, S^{TVAE}\} \tag{39}$$

（2）知识迁移模块：

首先，使用S^{target}来训练目标预测模型M^T。该模型继承了源模型M^S包含的丰富知识，即相似 IES 的负荷变化模式。考虑多任务联合预测可以优化小样本负荷的预测性能，源模型采用前一章节提出的短期负荷联合预测模型

中国知网 https://www.cnki.net

CPLE。根据实验中表现，采用底层共享网络固定，顶层塔式网络微调的迁移策略。其训练框架包括以下两个步骤：

首先，采用 MMD 筛选得到与目标数据S^{target}相似的源数据S^{sourse}。使用S^{sourse}训练负荷预测模型M^S最小化损失值函数，如公式（40）所示：

$$\min_{\theta^T} \| M^S(\theta^S, S_{in}^{sourse}) S_{out}^{sourse} \|^2 \tag{40}$$

其中，M^S是通过源数据构建的模型，θ^S是M^S的参数，S_{in}^{sourse}是预测负荷对应的输入序列，S_{out}^{sourse}是预测负荷的真实值。

然后，使用包括原始数据和人工数据的目标数据来训练目标预测模型M^T，其共享层从M^S继承并在训练期间固定，如公式（41）所示：

$$\min_{\theta^T} \| M^T(\theta^T, S_{in}^{target} | \theta^{S^*}) S_{out}^{target} \|^2 \tag{41}$$

其中，θ^T是M^T的参数，S_{in}^{target}是目标域预测模型的输入，S_{out}^{target}是预测负荷的真实值，θ^{S^*}表示M^S模型共享层的优化参数。

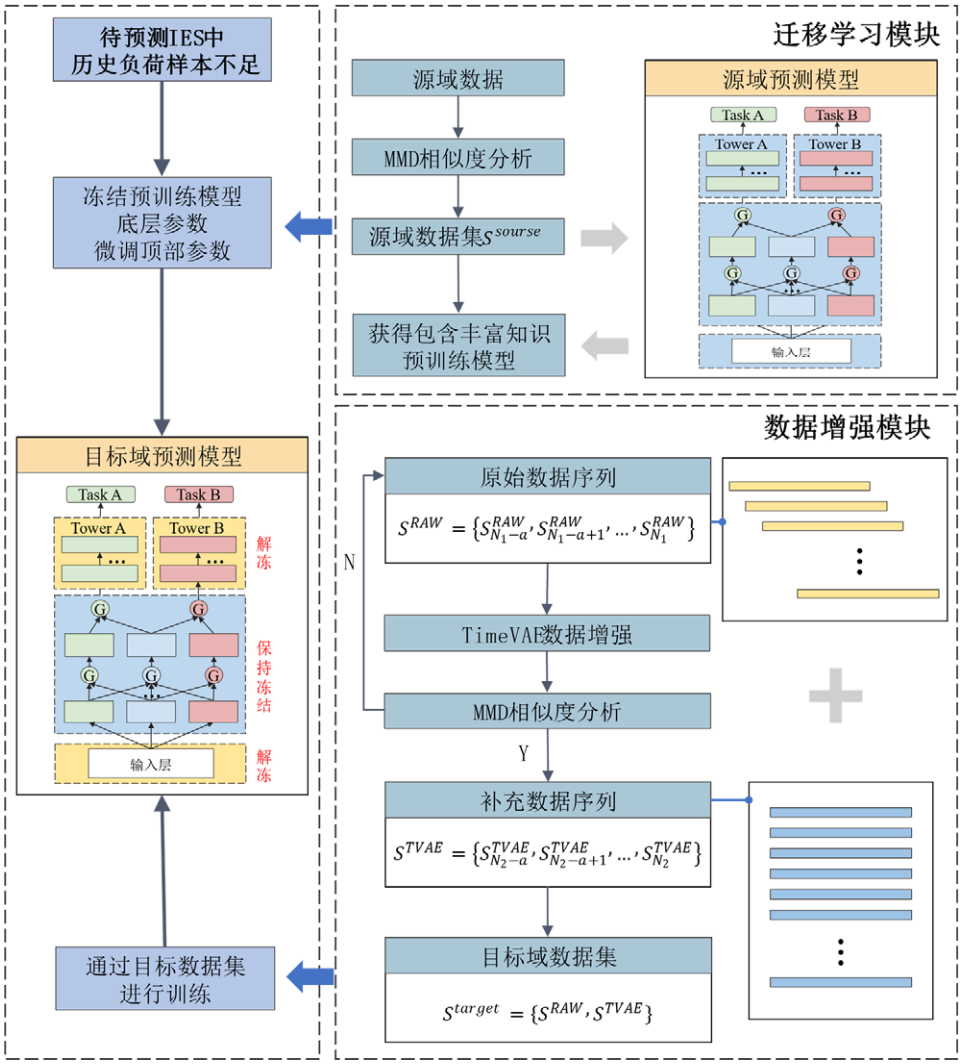


图 4-3 整体框架

中国知网 https://www.cnki.net

4.5 算例分析

4.5.1 数据来源与实验环境

本节实验数据为美国亚利桑那州立大学 IES 记录的 2020 年 1 月至 2021 年 2 月的负荷数据（电、冷）[84]，以及相关天气数据（温度、露点、湿度、气压）。气象数据来源于天气网站。亚利桑那州立大学共有四个校区，以坦佩校区的IES为目标域，西校区、理工校区、凤凰城市中心校区的 IES 为源域。负荷采样间隔均为 1 小时。使用源域三个校区 2020 年 1 月至 12 月的负荷作为源域数据。因源域的 IES 只包含电、冷负荷数据，所以只针对电、冷负荷任务进行训练。本节的重点是验证 TimeVAE 数据增强模块和迁移学习模块对预测精度的提升，因此目标域不需要大量的数据集。以坦佩校区 2021 年 1 至 2 月的负荷作为目标域数据，训练集和测试集的比例为 1：1。软件平台采用 Tensorflow 和 Keras 框架实现。硬件配置包括两个 Xeon 4215R CPU 和两个 NVIDIA RTX 3090 GPU。

4.5.2 评价指标

本章采 RMSE、MAPE、MAE、R2 指标来量化所提方法的性能。平均绝对误差（Mean Absolute Error，MAE）是预测值与实际值之间的绝对误差的平均值。MAE 越小表明预测模型的性能越好，且 MAE 对偏差较大的样本更敏感。公式见（42）：

$$MAE = \frac{1}{n}\sum_{i=1}^{N}\left|y_{act}(i) - y_{pred}(i)\right| \tag{42}$$

其中，$y_{act}(i)$是第i个样本的实际值，$y_{pred}(i)$是对应的预测值，n是表示输入集大小。

R 方（R-Squared，$R2$）：$R2$是衡量模型对观测数据的拟合程度的统计量。$R2 \in [0,1]$，越接近 1 表示模型拟合得越好。公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^{N}\left(y_{act}(i) - y_{pred}(i)\right)^2}{\sum_{i=1}^{N}(\bar{y}_{act}(i) - y_{act}(i))^2} \tag{43}$$

其中，$\bar{y}_{act}(i)$是实际值的平均值。

4.5.3 输入数据处理

首先对源域数据和目标域数据进行预处理，处理方法同第四章。以 MW 作为各负荷的计量单位，电、冷负荷单位换算公式为：$1\text{MW} = 284\text{Ton}$。预处理后的目标域 IES 负荷数据如图 4-4 所示。

中国知网　https://www.cnki.net

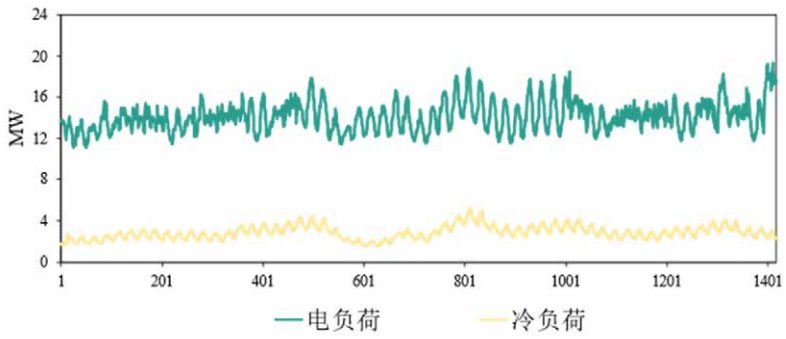


图 4-4 目标域 IES 的电、冷负荷数据

IES 的数据分析和处理可以直接影响多能负荷预测的结果。基于目标域，使用 MIC 对变量之间的相关性进行量化。图 4-4 直观地描述了两个变量之间的相关程度。MIC 值越大，相关程度越高。选取 MIC 大于 0.3 的变量作为输入特征。确定变量可以减少输入数据的冗余以及提高数据质量，为提高预测精度奠定基础。同样，基于源域 IES 数据，利用 MIC 过滤模型训练的输入变量。

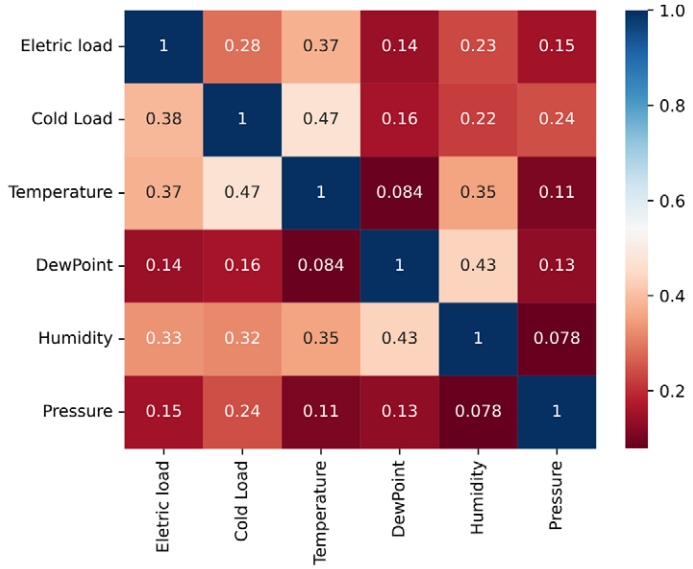


图 4-5 基于 MIC 的定量分析热图

接下来使用 MMD 度量源域和目标域之间数据分布的相似性来选择源域数据集。如果 MMD 太大，说明该源域 IES 与目标域之间的差异较大，可能会导致负迁移。根据 MMD 结果，选择中心校区 2020 年 1 月至 12 月为源域数据集，并按照 9：1 的比例划分为训练集和测试集。最后，对数据进行归一化得到目标域和源域的输入数据集。

4.5.4 参数设置

本节通过集成三个模型来进行小样本条件下的短期多能负荷预测，这三个

中国知网 https://www.cnki.net

模型分别是人工数据生成模型 TimeVAE、负载预测模型 CPLE 和迁移学习模型。该模型称为 DA-CPLE-TL。通过网格搜索[83]对这些模型的结构和参数进行优化，具体参数如下：

（1）TimeVAE 模型：TimeVAE 模型由编码器，解码器两部分组成，如图 4-1 所示。编码器有三个一维卷积层，卷积核大小分别为 3，3，3，卷积步长大小分别为 2，2，2，滤波器数量分别为 50，100，200。每个卷积层的激活函数均为 ReLU。卷积层后接一个 flatten 操作和一个全连接层，全连接层的维度大小为 8。解码器包括三个转置卷积，卷积核大小分别为 3，3，3，卷积步长大小分别为 2，2，2，滤波器数量分别为 100，50，特征数量。每个卷积层的激活函数同样为 ReLU。卷积层后接一个 flatten 操作、一个全连接层以及一个 reshape 操作，全连接层的维度大小为序列长度*特征数量。Reshape 将全连接层的输出重塑为（序列长度，特征数量）。TimeVAE 的两个损失的比例为：5（重构损失）：1（KL 散度损失），并使用 Adam 优化器来编译 TimeVAE。与此同时，为进一步优化 TimeVAE 重建结果，设置早停策略和学习率衰减回调。早停策略的设置为：如果损失在连续 10 个 epoch 内没有改善（阈值=0.1），则停止训练。学习率衰减回调的设置为：如果损失在连续 5 个 epoch 内没有改善（初始学习率=0.001），它会将学习率减小为原来的 0.1 倍。最大 epoch 为 300。

（2）预测模型：以 CPLE 模型进行负荷联合预测。一共有两个负荷预测任务：电负荷、冷负荷。CPLE 分为共享层和子任务层。共享层有两层，第一层专家网络由一维卷积构成。其中，共享专家模块包括 8 个专家子网，任务特定专家模块均包括 4 个专家子网。所有卷积网络的设置相同：滤波器数量为 16，卷积核大小为 3，卷积步长为 1，激活函数为 ReLU。第二层专家网络由全连接构成，共享专家模块包括 16 个专家子网，任务特定专家模块均包括 8 个专家子网。全连接网络维度均为 8。子任务层由一个 LSTM 和一个全连接构成，LSTM 神经元数量为 16，全连接神经元数量为 1。

（3）迁移学习模型：对 CPLE 共享层的结构和权值进行了迁移，对电、冷负荷的子任务层进行微调。源域 IES 和目标域 IES 负荷预测模型的结构相同。

为了验证 TimeVAE 和迁移学习的有效性以及所提模型的准确性，进行了以下几组对比实验。

4.5.5 不同迁移学习策略比较

为了研究所提迁移学习方法的性能，以 CPLE 模型为基线，设置四种算法进行对比：

算法 1：不进行预训练，直接对目标域数据进行预测。

中国知网　https://www.cnki.net

算法 2：在源域的数据集训练后，对源模型所有参数进行微调。

算法3：在源域的数据集训练后，仅冻结源模型共享层参数，对其余参数进行微调。

算法4：在源域的数据集训练后，冻结除输出层之外的所有参数，仅对输出层进行微调。



图 4-6 不同迁移学习策略的评价指标

实验结果如图 4-6 所示。从结果中可以看出，算法 3（所提迁移学习方法）的迁移参数方式在绝大多数指标中占优，综合评价相对最高。算法 2 的效果低于算法3，原因是所有参数都被微调使得网络忘记与源域数据相关的信息。此外，也可能是因为目标域数据量有限，导致模型难以学习到足够信息以适应目标域的数据分布。算法 4 中，出现较为严重的负迁移，这可能是因为保留过多的训练度，使得参数不平衡从而导致负迁移。为进一步展示所提迁移方法的可行性，在人工数据集（所提增强方法）+目标域数据集的基础上进行算法验证。结果如表 4-1 所示。上述结果表明，仅将包含耦合关系的共享层参数冻结既可以保留较多训练度又可以满足较小目标域数据的需求，从而实现更有效的跨域知识利用。

表 4-1 数据增强后，不同迁移学习策略的比较

算法类型	MAE(MW)		MAPE(%)		RMSE(MW)		R2	
	电	冷	电	冷	电	冷	电	冷
算法 1	0.38	0.32	2.58	2.85	0.56	0.47	0.88	0.95
算法 2	0.43	0.30	2.87	2.69	0.63	0.50	0.85	0.94
算法 3	0.36	0.28	2.39	2.54	0.56	0.43	0.88	0.96
算法 4	0.41	0.45	2.75	4.12	0.60	0.59	0.86	0.92

中国知网 https://www.cnki.net

4.5.6 不同数据增强方法比较

同样以 CPLE 为基线模型，将所提增强方法与其他数据增强方法进行对比，具体设置如下：

算法 5：不进行数据增强，仅使用目标域数据训练。

算法 6：使用 TimeGAN 对目标域数据进行增强。该模型基于 ydata-synthetic 库实现。其中，学习率为 0.001，epoch 为 200。其余参数采用默认值。

算法 7：使用 VAE 对目标域数据进行增强。VAE 模型由全连接网络组成。其中，编码器维度为[500,250,50]，解码器维度为[50,250,500]。潜在变量 z 的维度为 10，学习率为 0.001，epoch 为 300。

算法 8：使用 TimeVAE 对目标域数据进行增强。具体参数见 4.5.4 节。

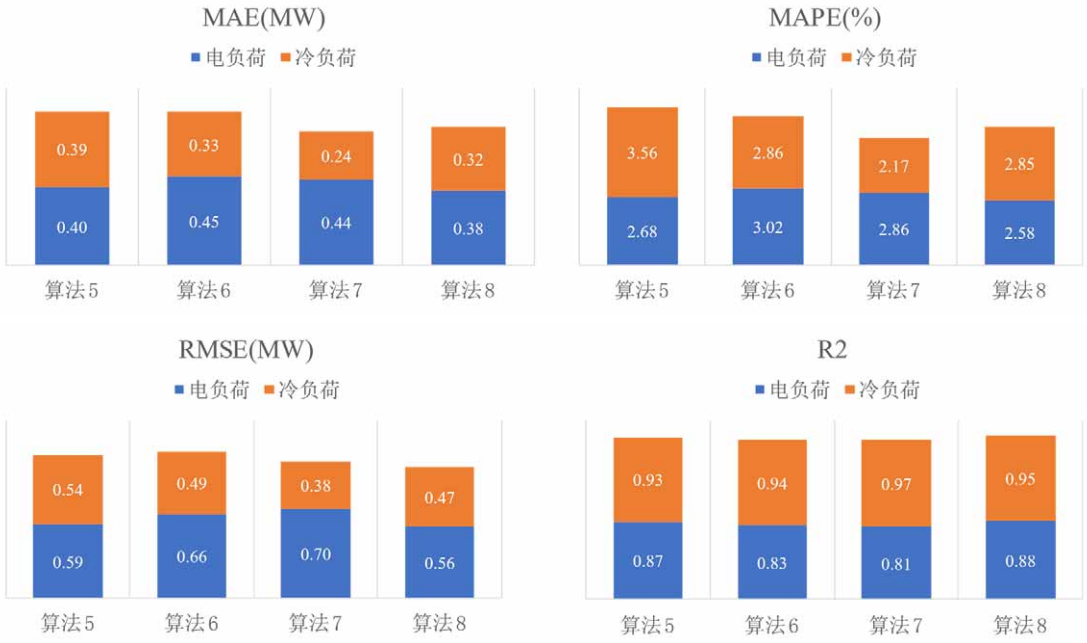


图 4-7 不同数据增强策略的评价指标

从图 4-7 中的结果可以观察到，算法 8（所提出的数据增强方法）表现最佳，其各项指标均处于领先地位。其次是算法 7，算法 5 和算法 6 的效果最差。结果表明基于 VAE 的数据增强方法（算法 7、8）要优于基于 GAN 的数据增强方法（算法 6）和不进行增强的方法（算法 5）。具体来说，算法 5 表现较差的原因可能是预测模型仅依赖于目标域有限的原始数据，无法充分捕捉数据分布中的重要特征。而算法 6 可能受限于 GAN 生成模型需要足够的数据来训练的特性。当目标域数据量较小时，TimeGAN 无法有效地学习到数据分布。相较于算法 7，算法 8 在数据增强方面表现更加优异的原因在于它结合了 CNN 和 VAE 架构来学习时间序列数据的概率分布。这种结合使得模型能够更加准确地建模时序数据的时间成分，从而更好地生成具有目标域数据特点的合成数据。

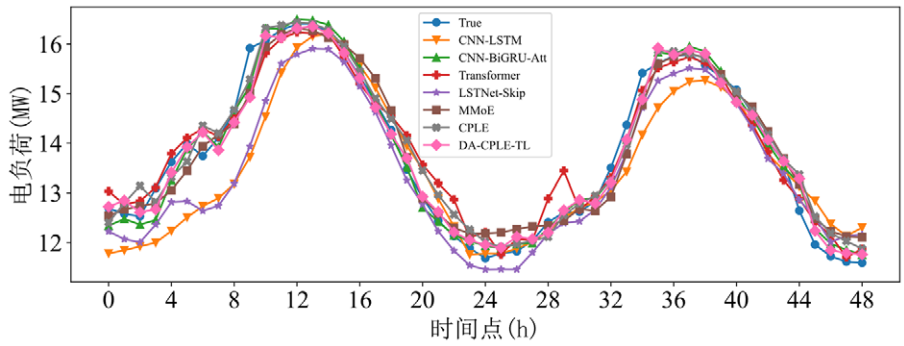
中国知网 https://www.cnki.net

4.5.7 不同预测模型比较

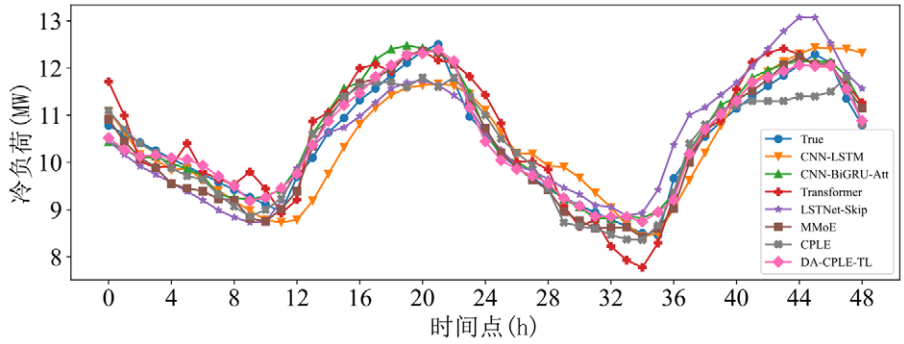
本章所提模型基于 TL 和 DA，通过模型训练、参数传递、参数微调、数据增强等优化模型性能。为了验证方案的可行性，将该模型与 CNN-LSTM、Transformer、LSTNet-Skip、CNN-BiGRU-Att、MMoE、CPLE 模型进行对比。其中，CNN-LSTM 是 CPLE 对应的单任务模型。上述对比模型的参数见表 3-2。对比模型的输入为目标域的原始训练集。

表 4-2 不同预测模型在目标域测试集的预测结果

模型	MAE(MW)		MAPE(%)		RMSE(MW)		R2	
	电	冷	电	冷	电	冷	电	冷
CNN-LSTM	0.60	0.54	3.93	4.87	0.88	0.67	0.70	0.90
Transformer	0.48	0.78	3.21	7.15	0.71	1.06	0.81	0.74
LSTNet-Skip	0.40	0.39	2.64	3.59	0.65	0.57	0.84	0.93
CNN-BiGRU-Att	0.44	0.41	2.90	3.73	0.83	0.63	0.74	0.91
MMoE	0.46	0.40	3.04	3.50	0.66	0.63	0.83	0.91
CPLE	0.40	0.39	2.68	3.56	0.60	0.55	0.86	0.93
DA-CPLE-TL	0.36	0.28	2.39	2.54	0.56	0.43	0.88	0.96



（a）电负荷



（b）冷负荷

图 4-8 不同模型的负荷预测曲线

从表 4-2 和图 4-8 中结果可知，所提方案在电、冷负荷预测中更具竞争力，各项指标均优于对比模型，预测曲线最接近真实值。下面是对结果的详细分析。

与 CNN-LSTM 相比，DA-CPLE-TL 模型在电负荷和冷负荷预测上的表现都

中国知网 https://www.cnki.net

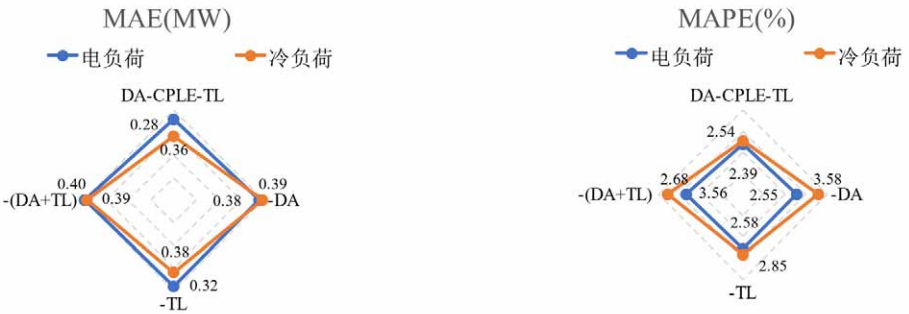
有显著提升。电负荷的 MAE、MAPE、RMSE 分别降低了 39.77%、39.24%、36.17%，R2 提高了 26.11%。冷负荷的相应指标分别降低了 47.70%、47.83%、35.97%，R2 提高了 6.93%。而 CPLE 模型在电负荷和冷负荷预测上也表现出不俗的性能，其 MAE 分别降低了 33.72%、29.10%，MAPE 分别降低了 31.77%、26.89%，RMSE 分别降低了 32.54%、17.46%，R2 分别提高了 23.24%、3.58%。这说明即使在小样本情况下，CPLE 仍然能够保持出色的性能，验证了 CPLE 作为基座模型的有效性。

相比于对比模型中预测性能最好的 CPLE，DA-CPLE-TL 电、冷负荷的 MAE 分别降低了 9.11%，26.23%，MAPE 分别降低了 10.95%，28.65%，RMSE 分别降低了 5.38%，22.42%，R2 分别提高了 2.33%，3.24%。冷负荷预测得到明显的改善。电负荷的改善相对较小，这可能是因为相较于冷负荷，电负荷的变化更加剧烈、更加复杂，即使通过迁移学习和数据增强得到了一定的改善，但仍然无法达到冷负荷提升的高度。

与多任务模型相比，基于单任务模型的 CNN-LSTM 的预测曲线与真实曲线偏离较大，这可能是因为在样本量较少时，单任务模型无法有效地利用共享层来提取任务之间的关联关系，从而影响了预测性能。此外，CNN-LSTM 在冷负荷预测方面的精度明显高于电负荷，这是由于冷负荷的变化更为规律，相对容易建模。相比之下，电负荷受到更多因素的影响，使得其变化更加不规律，预测难度也因此增加。

4.5.8 消融实验

为验证所提模型每个模块的必要性，逐渐排除组件来观察模型性能是如何下降的。-DA 表示所提模型仅去除数据增强模块，-TL 表示所提模型仅去除迁移学习模块，-(DA+TL)表示同时去除数据增强和迁移学习模块。图 4-9 展示了每个模型评价指标。



中国知网　https://www.cnki.net

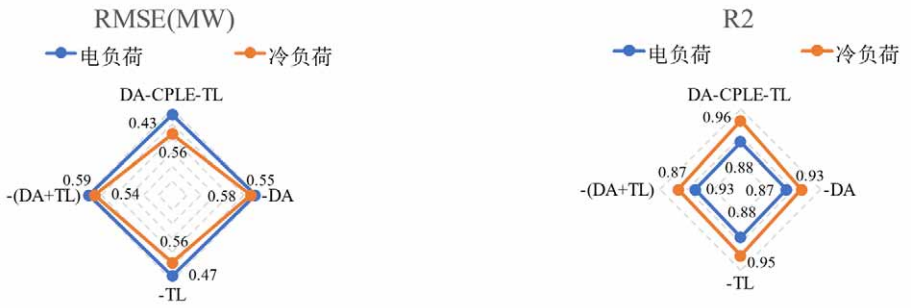


图 4-9 基于不同改进模块的预测结果

当仅去除 TimeVAE 生成的人工样本时，相比于所提模型，电负荷的 MAE、MAPE、RMSE 分别提高了 5.28%、6.62%、2.60%，R2 降低了 0.80%。冷负荷的 MAE、MAPE、RMSE 分别提高了 27.92%、29.09%、22.14%，R2 降低了 2.90%。在去除人工样本的基础上继续去除源领域知识迁移，相比于所提模型，电负荷的 MAE、MAPE、RMSE 分别提高了 9.11%、10.94%、3.76%，R2 降低了 1.15%。冷负荷的 MAE、MAPE、RMSE 分别提高了 26.23%、28.65%、20.99%，R2 降低了 2.68%。上述结果表明，人工样本生成和知识迁移都有助于模型性能的提升，而两者的结合能进一步提升模型的效果。

4.6 本章小结

考虑对新建 IES 进行负荷预测所需信息量不足，提出了一种结合 TimeVAE 和 TL 的集成预测框架，以提高小样本数据下短期预测精度。以美国亚利桑那州立大学坦佩校区 IES 为目标域，其他三个校区 IES 为源域进行了验证分析。主要结论如下：

（1）TimeVAE 数据增强方法能够准确表征原始数据的时间属性，生成的人工数据可以有效补偿数据多样性。与 TimeGAN 相比，MAPE 平均降低了 16.23%、RMSE 平均降低了 13.73%。与不增强相比，MAPE 平均降低了 11.77%、RMSE 平均降低了 8.42%。

（2）基于 MMD 的参数迁移方法可以利用来自其他具有丰富数据的相似 IES 的知识来提高模型预测性能。与不进行迁移相比，所提迁移方法的 MAPE 平均降低了 13.28%，MAE 平均降低了 10.91%。

（3）数据增强和知识迁移的集成策略可以进一步提高小样本负荷的预测精度。实验结果表明，与其他模型相比，采用 TimeVAE 数据合成和 CPLE 迁移参数的模型预测精度最高。与原始预测相比，所提集成预测方法的 MAPE 平均降低了 19.79%、RMSE 平均降低了 12.38%。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 总结

本文旨在优化负荷调控及提高能源效率，以促进新型电力系统的建设。针对 IES 负荷预测中多维特征序列关键信息难以全面捕捉，负荷结构多元化和负荷特性复杂化，以及新建 IES 训练样本不足的挑战，开展了基于多任务学习和迁移学习的短期负荷预测研究。主要工作如下：

（1）提出了一种基于 TPA 机制的 CNN-Seq2seq 短期电力负荷预测方法。该方法考虑减少数据冗余，构建了基于历史负荷、日期、气象先验知识的多变量特征数据集。考虑多维特征中复杂时空信息以及关键特征变量难以全面捕捉，建立了基于 CNN-Seq2seq 的时空特征提取模型。同时，引入了 TPA 捕捉时间模式并对时间步内的特征进行差异化权重分配，更全面的关注了关键信息。实验结果表明，与普通注意力机制相比，TPA 的 RMSE 降低了 12.9%，MAPE 降低了 1.65%。

（2）提出了一种基于 STL 和 CPLE 多任务学习的短期多元负荷预测方法。该方法考虑负荷本身具有的趋势、周期耦合特性，采用基于 STL 的时序分解算法以及 MIC 相关性分析，为多元负荷的每类分量分别构建了输入特征集。考虑多元负荷之间的共性和特性表征，引入多类专家网络和门控网络，构建了基于 PLE 多任务学习的渐进分离任务信息方法。考虑多元负荷之间、负荷与辅助特征之间的复杂时空耦合信息，将 CNN、LSTM 与 PLE 共享方法融合，建立 CPLE 预测模型进一步优化了时空特征提取。实验结果表明，与传统多任务方法相比，所提方法的电热冷负荷的 MAPE 平均降低了 34.32%，RMSE 平均降低了 30.77MW，WMA 平均提高了 1.29%。

（3）提出了一种基于 TimeVAE 和迁移学习的短期小样本负荷预测方法。考虑数据多样性和代表性有限，建立了基于 TimeVAE 的多变量输入数据生成模型。考虑扩充的数据量有限以及存在具有丰富样本的相似 IES，构建了采用冻结训练策略的参数迁移模型。同时，考虑负向迁移，采用了 MMD 约束源域和目标域数据分布。最后综合数据增强模型和迁移学习模型的优势，构建了用于小样本负荷预测的集成模型。实验结果表明，与原始模型相比，所提方法的 MAPE 平均降低了 19.79%、RMSE 平均降低了 12.38%。

中国知网 https://www.cnki.net

5.2 展望

新能源的大规模并网，使得新型电力系统负荷表现出更加复杂的新特性。在综合能源系统应用场景下，本文基于数据驱动和深度学习技术，重点研究了多任务学习和迁移学习在短期负荷预测方面的应用，并取得了一定成果。但仍存在改进空间，未来考虑从以下几个方面继续探索：

（1）本文所提出的预测方法仅针对短期负荷预测，对于中长期负荷预测的研究还不够深入。未来可以探索结合更多时间尺度的负荷数据，发展更为全面的负荷预测模型。例如，可以考虑将季节性因素、人口增长率以及宏观经济指标等长期影响因素纳入模型，以提高中长期预测的准确性。

（2）本文主要关注了单步负荷预测问题，即预测下一个时间点的负荷值。虽然单步预测在许多应用场景中已经足够，但在实际的能源系统运营和管理中，多步预测（即预测未来多个时间点的负荷）同样重要。多步预测能够帮助能源运营商更好地规划资源分配、优化调度策略，并提高系统的经济性和可靠性。因此，未来的研究可以着重发展多步负荷预测模型。

（3）随着能源系统的不断发展和新技术的应用，如分布式能源资源、需求响应等，未来的电力系统将更加复杂和动态。因此，如何将这些新元素融入负荷预测模型，提高模型的适应性和鲁棒性，将是未来研究的重要方向。同时，考虑到能源系统的可持续性，如何通过负荷预测优化能源消耗，实现能源系统的绿色低碳转型，也是值得深入探讨的问题。

中国知网 https://www.cnki.net

参考文献

[1] 张笑演,王橹裕,黄蕾,等.考虑扩展碳排放流和碳交易议价模型的园区综合能源优化调度[J].电力系统自动化,2023,47(9):34-46.

[2] 章坚民,王雨宽,薛禹胜,等.自然灾害-电力系统-碳排放变化的贝叶斯网络建模与估计[J].电力系统自动化,2023,47(7):1-11.

[3] Zhou D, Ding H, Wang Q, et al. Literature review on renewable energy development and China's roadmap[J]. Frontiers of Engineering Management, 2021, 8(2): 212-222.

[4] International Energy Agency. CO2 Emissions in 2023. https://www.iea.org/reports/co2-emissions-in-2023; 2023 [accessed 2 March 2024].

[5] 中国石油集团经济技术研究院.2023 年油气行业发展报告. http://etri.cnpc.com.cn/etri/2021/home.shtml; [2024 年 3 月 2 日访问].

[6] International Energy Agency. . CO2 Emissions in 2023. https://www.iea.org/reports/co2-emissions-in-2023/emissions-grew-in-2023-but-clean-energy-is-limiting-the-growth; 2023 [accessed 2 March 2024].

[7] 雷杨,赵纪峰,丁石川,等.考虑双重不确定性的区域综合能源系统多阶段滚动随机规划[J].电力系统自动化,2023,47(20):53-63.

[8] Wu J, Yan J, Jia H, et al. Integrated energy systems[J]. Applied Energy, 2016, 167: 155-157.

[9] 章禹,郭创新,尹建兵等.区域综合能源系统电-气多元储能的优化配置研究[J].浙江电力,2023,42(06):60-69.

[10] 司方远,张宁,韩英华等.面向多元灵活资源聚合的区域综合能源系统主动调节能力评估与优化：关键问题与研究架构[J/OL].中国电机工程学报:1-23[2024-03-18].

[11] Hong T, Pinson P, Wang Y, et al. Energy forecasting: A review and outlook[J]. IEEE Open Access Journal of Power and Energy, 2020, 7: 376-388.

[12] 冯斌,胡轶婕,黄刚,等.基于深度强化学习的新型电力系统调度优化方法综述[J].电力系统自动化,2023,47(17):187-199.

[13] 孔祥玉,马玉莹,艾芊,等.新型电力系统多元用户的用电特征建模与用电负荷预测综述[J].电力系统自动化,2023,47(13):2-17.

[14] 滕贤亮,谈超,昌力,等.高比例新能源电力系统有功功率与频率控制研究综述及展望[J].电力系统自动化,2023,47(15):12-35.

[15] Sharma S, Majumdar A, Elvira V, et al. Blind Kalman filtering for short-term load forecasting[J]. IEEE Transactions on Power Systems, 2020, 35(6): 4916-4919.

[16] 赵成旺,顾幸生,严军.负荷求导法在超短期负荷预测中的应用[J].电力系统及其自动化学报,2006,(05):5-9.

[17] Ji P, Xiong D, Wang P, et al. A study on exponential smoothing model for load forecasting[C]//2012 Asia-Pacific Power and Energy Engineering Conference. IEEE, 2012: 1-4.

[18] Nguyen H, Hansen C K. Short-term electricity load forecasting with Time Series Analysis[C]//2017 IEEE International Conference on Prognostics and Health Management (ICPHM). IEEE, 2017: 214-221.

中国知网 https://www.cnki.net

[19] Pai P F, Hong W C. Support vector machines with simulated annealing algorithms in electricity load forecasting[J]. Energy Conversion and Management, 2005, 46(17): 2669-2688.

[20] Dudek G. Short-term load forecasting using random forests[C]//Intelligent Systems' 2014: Proceedings of the 7th IEEE International Conference Intelligent Systems IS'2014, September 24-26, 2014, Warsaw, Poland, Volume 2: Tools, Architectures, Systems, Applications. Springer International Publishing, 2015: 821-828.

[21] 李益民,董海鹰,丁坤等.考虑长期负荷概率预测的储能多阶段优化配置[J].综合智慧能源,2024,46(02):19-27.

[22] Li S, Wang P, Goel L. Short-term load forecasting by wavelet transform and evolutionary extreme learning machine[J]. Electric Power Systems Research, 2015, 122: 96-103.

[23] 章姝俊,陆海清,陈佳玺等.基于多因素相关性分析的气温敏感负荷预测[J].浙江电力,2023,42(09):27-35.

[24] 李鹏,何帅,韩鹏飞,郑苗苗,黄敏,孙健.基于长短期记忆的实时电价条件下智能电网短期负荷预测[J].电网技术,2018,42(12):4045-4052.

[25] 虞殷树,陈东海,朱耿等.基于改进关联分析的行业短期电力负荷预测[J].浙江电力,2023,42(11):29-38.

[26] 高明,郝妍.基于 BiLSTM 网络与误差修正的超短期负荷预测[J].综合智慧能源,2023,45(01):31-40.

[27] 陈海文,王守相,王绍敏,王丹.基于门控循环单元网络与模型融合的负荷聚合体预测方法[J].电力系统自动化,2019,43(01):65-72.

[28] Marino D L, Amarasinghe K, Manic M. Building energy load forecasting using deep neural networks[C]//IECON 2016-42nd annual conference of the IEEE industrial electronics society. IEEE, 2016: 7046-7051.

[29] 朱耿,王波,贺旭等.基于关键特征优化的电力系统短期负荷预测方法[J].浙江电力,2023,42(08):46-53.

[30] 沈建良,来骏,张翼等.基于 ACMD 和 BiGRU-Attention 的负荷预测模型研究[J].浙江电力,2023,42(06):70-77.

[31] Bashir T, Haoyong C, Tahir M F, et al. Short term electricity load forecasting using hybrid prophet-LSTM model optimized by BPNN[J]. Energy Reports, 2022, 8: 1678-1686.

[32] Tang X, Chen H, Xiang W, et al. Short-term load forecasting using channel and temporal attention based temporal convolutional network[J]. Electric Power Systems Research, 2022, 205: 107761.

[33] Mathew J, Behera R K. EMD-Att-LSTM: a data-driven strategy combined with deep learning for short-term load forecasting[J]. Journal of Modern Power Systems and Clean Energy, 2021, 10(5): 1229-1240.

[34] Ding Y, Zhang Q, Yuan T, et al. Model input selection for building heating load prediction: A case study for an office building in Tianjin[J]. Energy and Buildings, 2018, 159: 254-270.

[35] Gao Z, Yu J, Zhao A, et al. A hybrid method of cooling load forecasting for large commercial building based on extreme learning machine[J]. Energy, 2022, 238: 122073.

[36] 金立,张力,任炬光等.针对气象敏感型综合能源负荷的收敛交叉映射因果关系分析[J].综合智慧能源,2023,45(01):23-30.

[37] ESEYE A T，LEHTONEN M．Short-term forecasting of heat demand of buildings for

中国知网 https://www.cnki.net

efficient and optimal energy management based on integrated machine learning models[J]．IEEE Transactions on industrial informatics，2020，16(12)：7743-7755．
[38] 刘亚珲,赵倩.基于聚类经验模态分解的 CNN-LSTM 超短期电力负荷预测[J].电网技术,2021,45(11):4444-4451.
[39] 陈锦鹏,胡志坚,陈纬楠等.二次模态分解组合 DBiLSTM-MLR 的综合能源系统负荷预测[J].电力系统自动化,2021,45(13):85-94.
[40] 李文武,张鹏宇,石强等.基于聚合混合模态分解和时序卷积神经网络的综合能源系统负荷修正预测[J].电网技术,2022,46(09):3345-3357.
[41] 石卓见,冉启武,徐福聪.基于聚合二次模态分解及 Informer 的短期负荷预测[J/OL].电网技术,1-15[2024-01-28].
[42] 李彬,胡纯瑾,王婧.基于 EEMD-BiLSTM 的可调节负荷预测方法[J].综合智慧能源,2022,44(09):33-39.
[43] 杨坚,赵洁,汤义勤等.基于序列分解的母线负荷降噪预测方法[J].浙江电力,2023,42(12):81-87.
[44] Liu L, Hu X, Chen J, et al. Embedded Scenario Clustering for Wind and Photovoltaic Power, and Load Based on Multi-Head Self-Attention[J]. Protection and Control of Modern Power Systems, 2024, 9(1): 122-132.
[45] 陆潍潍,殷林飞.基于 CEEMD 与 GWO-LSTM 的精细非侵入性负荷监测[J].综合智慧能源,2023,45(11):36-44.
[46] Li K, Mu Y, Yang F, et al. A novel short-term multi-energy load forecasting method for integrated energy system based on feature separation-fusion technology and improved CNN[J]. Applied Energy, 2023, 351: 121823.
[47] 金立,张力,唐杨等.考虑温湿指数与耦合特征的综合能源负荷短期预测[J].综合智慧能源,2023,45(07):70-77.
[48] Wu K, Gu J, Meng L, et al. An explainable framework for load forecasting of a regional integrated energy system based on coupled features and multi-task learning[J]. Protection and Control of Modern Power Systems, 2022, 7(2): 1-14.
[49] 吕忠麟,顾洁,孟璐.基于耦合特征与多任务学习的综合能源系统短期负荷预测[J].电力系统自动化,2022,46(11):58-66.
[50] Niu D, Yu M, Sun L, et al. Short-term multi-energy load forecasting for integrated energy systems based on CNN-BiGRU optimized by attention mechanism[J]. Applied Energy, 2022, 313: 118801.
[51] 李云松,张智晟.考虑综合需求响应的 Trans-GNN 综合能源系统多元负荷短期预测[J/OL].电工技术学报,1-11[2024-03-18].
[52] 李云松,张智晟.基于 GRU-TGTransformer 的综合能源系统多元负荷短期预测[J].电力系统保护与控制,2023,51(15):33-41.
[53] 吴晨,姚菁,薛贵元等.基于 MMoE 多任务学习和长短时记忆网络的综合能源系统负荷预测[J].电力自动化设备,2022,42(07):33-39.
[54] Yang, Z., Xu, Q., Cao, X., & Huang, Q. (2020). Task-feature collaborative learning with application to personalized attribute prediction. IEEE transactions on pattern analysis and machine intelligence, 43(11), 4094-4110.
[55] Tang H, Liu J, Zhao M, et al. Progressive layered extraction (ple): A novel multi-task learning

中国知网 https://www.cnki.net

(mtl) model for personalized recommendations[C]//Proceedings of the 14th ACM Conference on Recommender Systems. 2020: 269-278.

[56] 李家熙,王丹,贾宏杰,等.面向可再生能源接入的综合能源系统熵态机理和分析方法[J].电力系统自动化,2023,47(9):47-58.

[57] Zhu Jizhong, Dong Hanjiang, Li Shenglin, Chen Ziyu, Luo Tengyan. Review of datadriven load forecasting for integrated energy system. Proceedings of the CSEE 2021;41(23):7905–24.

[58] Yuan Y, Chen Z, Wang Z, et al. Attention mechanism-based transfer learning model for day-ahead energy demand forecasting of shopping mall buildings[J]. Energy, 2023, 270: 126878.

[59] Qian F, Ruan Y, Lu H, et al. Enhancing source domain availability through data and feature transfer learning for building power load forecasting[C]//Building Simulation. Beijing: Tsinghua University Press, 2024: 1-14.

[60] 孙晓燕,李家钊,曾博等.基于特征迁移学习的综合能源系统小样本日前电力负荷预测[J].控制理论与应用,2021,38(01):63-72.

[61] Peng C, Tao Y, Chen Z, et al. Multi-source transfer learning guided ensemble LSTM for building multi-load forecasting[J]. Expert Systems with Applications, 2022, 202: 117194.

[62] L. Cai, J. Gu, Z. Jin, Two-layer transfer-learning-based architecture for short-term load forecasting, IEEE Trans. Ind. Informat. 16 (3) (Mar. 2020) 1722–1732.

[63] Fan C, Sun Y, Xiao F, et al. Statistical investigations of transfer learning-based methodology for short-term building energy predictions[J]. Applied Energy, 2020, 262: 114499.

[64] Xu X, Meng Z. A hybrid transfer learning model for short-term electric load forecasting[J]. Electrical engineering, 2020, 102: 1371-1381.

[65] Lu Yakai, Tian Zhe, Zhou Ruoyu, Liu Wenjing. A general transfer learning-based framework for thermal load prediction in regional energy system. Energy 2021; 217:119322.

[66] Wang Chendong, Yuan Jianjuan, Huang Ke, Zhang Ji, Zheng Lihong, Zhou Zhihua, Zhang Yufeng. Research on thermal load prediction of district heating station based on transfer learning. Energy 2022; Part E, 239:122309.

[67] Li C, Li G, Wang K, et al. A multi-energy load forecasting method based on parallel architecture CNN-GRU and transfer learning for data deficient integrated energy systems[J]. Energy, 2022, 259: 124967.

[68] Lu Y, Wang G, Huang S. A short-term load forecasting model based on mixup and transfer learning[J]. Electric Power Systems Research, 2022, 207: 107837.

[69] Su J, Chen F, Qiu Z, et al. Multi-load short-term prediction of an integrated energy system based on GAN-LSTM[C]//Journal of Physics: Conference Series. IOP Publishing, 2023, 2564(1): 012062.

[70] Bu X, Wu Q, Zhou B, et al. Hybrid short-term load forecasting using CGAN with CNN and semi-supervised regression[J]. Applied Energy, 2023, 338: 120920.

[71] 曾爽,丁屹峰,李香龙等.基于条件时序生成对抗网络的楼宇空调负荷场景生成方法[J].电网技术,2022,46(07):2448-2456.

[72] Dong W, Chen X, Yang Q. Data-driven scenario generation of renewable energy production based on controllable generative adversarial networks with interpretability[J]. Applied Energy, 2022, 308: 118387.

中国知网 https://www.cnki.net

[73] 何宇浩,宋云海,何森等.面向电力缺陷场景的小样本图像生成方法[J].浙江电力,2024,43(01):126-132.
[74] Zhou D, Ma S, Hao J, et al. An electricity load forecasting model for Integrated Energy System based on BiGAN and transfer learning[J]. Energy Reports, 2020, 6: 3446-3461.
[75] 梁俊杰,韦舰晶,蒋正锋.生成对抗网络 GAN 综述[J].计算机科学与探索,2020,14(01):1-17.
[76] Jie Zhang, Cong Feng, June 4, 2019, "Short-term load forecasting data with hierarchical advanced metering infrastructure and weather features", IEEE Dataport.
[77] Siddiqui O, Dincer I. Design and analysis of a novel solar-wind based integrated energy system utilizing ammonia for energy storage[J]. Energ Conver Manage 2019;195:866–84.
[78] Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition. J. Off. Stat, 6(1), 3-73.
[79] 张昆明,蔡珊珊,章天晗等.考虑多维时域特征的行业中长期负荷预测方法[J].电力系统自动化,2023,47(20):104-114.
[80] Graves, A., & Graves, A. (2012). Long short-term memory. Supervised sequence labelling with recurrent neural networks, 37-45.
[81] Vardhan, B. S., Khedkar, M., Srivastava, I., Thakre, P., & Bokde, N. D. (2023). A Comparative Analysis of Hyperparameter Tuned Stochastic Short Term Load Forecasting for Power System Operator. Energies, 16(3), 1243.
[82] Kiruthiga, D., & Manikandan, V. (2022). Intraday time series load forecasting using bayesian deep learning method—a new approach. Electrical Engineering, 104(3), 1697-1709.
[83] Liashchynskyi, P., & Liashchynskyi, P. (2019). Grid search, random search, genetic algorithm: a big comparison for NAS. arXiv preprint arXiv:1912.06059.
[84] Arizona State University. Load data. (Jan. 2020 - Nov. 2021). Available: http://cm.asu.edu/.
[85] Wang, C., Wang, Y., Zheng, T., Dai, Z., & Zhang, K. (2022). Comprehensive Energy System Multi-Load Prediction Based on ResNet-LSTM Network and Attention Mechanism. Journal of Building Engineering, 07, 1789-1799.
[86] Phoenix, AZ Weather Conditions. (Jan. 2020 - Nov. 2021). Available: https://www.wunderground.com/weather/us/az/phoenix.
[87] Lu, B., Huo, Z., & Yu, M. (2023). Short-term Multi-load Forecasting of Integrated Energy Systems Based on LSTNet-Skip. Proceedings of the CSEE, 6, 2273-2283.
[88] 孙伟,朱世睿,杨建平等.基于图卷积网络的微电网拓扑辨识[J].电力系统自动化,2022,46(05):71-81.
[89] Cui, S., & Wang, X. (2022). Multivariate load forecasting in integrated energy system based on maximal information coefficient and multi-objective Stacking ensemble learning. Electric Power Automation Equipment, 42(5), 32-39+81.
[90] Akash Srivastava, Lazar Valkov, Chris Russell, Michael U Gutmann, and Charles Sutton. Veegan: Reducing mode collapse in gans using implicit variational learning. In Proceedings of the 31st International Conference on Neural Information Processing Systems, pp. 3310–3320, 2017.
[91] Desai A, Freeman C, Wang Z, et al. TimeVAE: A variational auto-encoder for multivariate time series generation[J]. arXiv preprint arXiv:2111.08095, 2021.
[92] Li K, Wei B, Tang Q, et al. A data-efficient building electricity load forecasting method based on maximum mean discrepancy and improved TrAdaBoost algorithm[J]. Energies, 2022,

中国知网 https://www.cnki.net

15(23): 8780.

中国知网 https://www.cnki.net