单位代码 11799
学　　号 2019658003

重慶工商大學

硕士学位论文

基于数据分布相似性的企业电量迁移预测研究

论文作者：肖威
所在学院：管理科学与工程学院
学科专业：管理科学与工程
研究方向：管理科学
指导教师：白云副教授
提交论文日期：2022 年 5 月 16 日
论文答辩日期：2022 年 5 月 19 日

中国•重庆

2022 年 5 月

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

目　录

摘 要.....I

ABSTRACT.....III

第 1 章 绪论.....1

1.1 研究背景与意义.....1

1.1.1 研究背景.....1

1.1.2 研究意义.....2

1.2 国内外研究现状.....2

1.2.1 电量预测研究现状.....2

1.2.2 迁移学习研究现状.....4

1.2.3 迁移学习在电量预测中的研究现状.....5

1.3 本文的研究内容及创新点.....5

1.3.1 本文研究内容.....5

1.3.2 本文创新点.....5

1.4 本文的结构安排.....6

第 2 章 基础理论介绍.....8

2.1 迁移学习概述.....8

2.1.1 基本概念和定义.....8

2.1.2 迁移学习类型.....10

2.1.3 负迁移.....11

2.2 领域间相似性的度量.....13

2.2.1 相似性度量概述.....13

2.2.2 常见相似性度量方法.....13

2.2.3 相似性度量在迁移学习中的适用性.....16

2.3 机器学习预测模型.....16

2.3.1 BP 神经网络.....16

2.3.2 支持向量机.....18

2.3.3 ELM 神经网络.....19

2.3.4 LSTM 神经网络.....21

中国知网 https://www.cnki.net

2.3.5 模型对比.....24
2.4 本章小结.....24
第 3 章 基于数据分布相似性的迁移预测.....25
3.1 数据收集.....25
3.2 实验环境搭建.....28
3.3 评价指标.....28
3.4 相同用电规模企业预测建模.....29
3.4.1 预测模型参数设计.....29
3.4.2 结果与分析.....30
3.5 基于迁移学习的企业电量预测建模.....36
3.5.1 基于数据分布相似性的迁移 LSTM 模型.....37
3.5.2 基于改进 MMD 的迁移 LSTM 模型.....44
3.6 本章小结.....47
第 4 章 不同迁移因素的影响研究.....48
4.1 样本数量对迁移预测的影响.....48
4.2 惩罚因子对迁移预测的影响.....55
4.3 季节性 MMD 对迁移预测的影响.....58
4.4 本章小结.....64
第 5 章 不同用电规模企业迁移预测初探.....65
5.1 方法设计.....65
5.2 不同用电规模企业的电量预测分析.....66
5.2.1 实验设计.....66
5.2.2 结果与分析.....67
5.3 本章小结.....72
第 6 章 总结与展望.....73
6.1 全文总结.....73
6.2 未来展望.....74
参考文献.....75
致谢.....80
在学期间发表论文和主持与参与的项目.....81

中国知网 https://www.cnki.net

基于数据分布相似性的企业电量迁移预测研究

摘 要

电量预测是电力系统发电规划的重要组成部分，是合理安排购电、发电、输配电的必要前提，是电力经济运行的依据。准确的电力供应预测不仅可以提高供电企业的运营效率和水平，而且对生产企业的项目投资和管理具有重要意义。由于企业的行业、规模等因素差异，导致电量预测中仍存在电量样本数据不足、预测模型泛化性低等问题。本文基于企业电量数据分布的相似性，通过迁移学习，采用机器学习算法实现对不同用电规模企业电量的精准预测。本文主要研究内容如下：

第一，基于数据分布相似性的迁移预测。根据用电规模划分企业类型，搭建长短期记忆网络（Long-Short Term Memory，LSTM）、误差反向传播(Back-propagation，BP)、支持向量机（support vector machines，SVM）、极限学习机（Extreme Learning Machine，ELM）四种机器学习模型对三种规模的企业日用电量进行了预测分析。实证结果表明，LSTM 模型对相同规模之间的企业电量预测均有着更好的性能。同时为了解决目标域企业样本不足的问题，通过迁移学习，采用 KL 散度（Kullback-Leibler divergence）、JS 散度（Jensen-Shannon）、最大均值差异（Maximum Mean Discrepancy，MMD）三种相似性度量改进 LSTM 模型的损失函数，证明了基于 MMD 的迁移 LSTM 模型运用到企业电量预测的可行性。不需要对目标企业再次重新建模，在保证模型预测精度的基础上，节省大量时间、人力成本。最后通过添加惩罚因子λ，改进模型损失函数，提出了一种基于改进 MMD 的迁移 LSTM 模型，进一步提高了模型的预测精度，确定了惩罚因子对模型预测性能的影响。

第二，不同迁移因素的影响研究。分别研究了样本数量、惩罚因子λ和季节性 MMD 对迁移 LSTM 模型的影响：（1）在训练集样本比例较少的情况下，迁移学习确实有助于提升 LSTM 在样本比例不足时的对相同规模企业电量的预测性能。（2）惩罚因子λ的改变对基于全年 MMD 的迁移 LSTM 模型的预测性能有较大影响，当惩罚因子λ∈[30，35]，基于全年 MMD 的迁移 LSTM 模型预测性能最好。（3）针对不同 MMD 距离的迁移策略，基于全年 MMD 的迁移 LSTM 模型明

中国知网 https://www.cnki.net

显好于基于季节 MMD 的迁移 LSTM 模型的预测效果，对于不同规模企业更加稳定。

第三，不同用电规模企业迁移预测初探。以上的研究都是在相同用电规模企业下研究，进一步探究模型对不同规模企业电量预测效果，通对源域企业电量数据进行标准化改进，缩小不同规模企业间的电量数据分布差异，使得基于改进 MMD 的迁移 LSTM 模型实现了不同规模的企业间电量的有效预测，在保证较高的预测精度的情况下，不仅能够解决城市电网规划中电量数据收集不足的问题，还节省了重建模型的训练时间。

总的来说，本文的研究针对基于数据分布相似性的迁移学习在企业电量预测中的应用，实现了从相同用电规模和不同用电规模的企业电量精准预测，为电网的日常运行、规划管理等多项工作提供参考依据，提高电力企业的经济效益，为维护我国的能源安全提供有力保障。

关键词：电力系统；数据分布相似性；迁移预测；企业电量；机器学习模型

中国知网 https://www.cnki.net

RESEARCH ON ENTERPRISE ELECTRICITY MIGRATION PREDICTION BASED ON DATA DISTRIBUTION SIMILARITY

ABSTRACT

Electricity forecasting is an important part of power generation planning in the power system. Accurate power supply forecast can not only improve the operation efficiency and level of power supply enterprises, but also has important significance for project investment and management of production enterprises. Due to differences in factors such as industries and scales of enterprises, there are still problems such as insufficient power sample data and low generalization of prediction models in power forecasting. Based on the similarity of enterprise power data distribution, this paper uses machine learning algorithm to achieve accurate prediction of power consumption of enterprises with different power consumption scales through transfer learning. The main research contents of this paper are as follows:

First, migration prediction based on similarity of data distribution. According to the scale of electricity consumption, the types of enterprises are divided, and four machine learning models of long and short term memory network, error back propagation, error back propagation and extreme learning machine are built to predict and analyze the daily electricity consumption of enterprises of three scales. The empirical results show that the LSTM model has better performance for the power prediction of enterprises of the same scale. At the same time, in order to solve the problem of insufficient enterprise samples in the target domain, through transfer learning, three similarity measures of KL divergence, JS divergence and maximum mean discrepancy are used to improve the loss function of the LSTM model, and the application of the transfer LSTM model based on MMD distance is proved. to the feasibility of enterprise electricity forecasting. There is no need to re-model the target enterprise again, and a lot of time and labor costs can be saved on the basis of maintaining the prediction accuracy of the model. Finally, by adding a penalty factor λ and improving the model loss function, a transfer LSTM

中国知网 https://www.cnki.net

model based on an improved MMD is proposed, which further improves the prediction accuracy of the model and determines the impact of the penalty factor on the model prediction performance.

Second, study the influence of different migration factors. The effects of the number of samples, penalty factor λ and seasonal MMD on the transfer LSTM model were studied separately: (1) In the case of a small proportion of training set samples, transfer learning does help to improve the LSTM in the case of insufficient sample proportion. Predictive performance of electricity in large-scale enterprises. (2) The change of the penalty factor λ has a great influence on the prediction performance of the mig ration LSTM model based on the annual MMD. When the penalty factor $\lambda \in [30, 35]$, the prediction performance of the migration LSTM model based on the annual MMD is the best. (3) For the migration strategies of different MMD distances, the prediction effect of the migration LSTM model based on the annual MMD is significantly better than the prediction effect of the migration LSTM model based on the seasonal MMD, and it is more stable for enterprises of different scales.

Third, a preliminary study on the migration prediction of enterprises with different electricity consumption scales. The above researches are all conducted under the same scale of electricity consumption. To further explore the effect of the model on the power forecasting of enterprises of different scales, standardize and improve the power data of enterprises in the source domain to reduce the difference in the distribution of power data between enterprises of different scales. The migration LSTM model of MMD realizes the effective prediction of electricity among enterprises of different scales. Under the condition of ensuring high prediction accuracy, it can not only solve the problem of insufficient electricity data collection in urban power grid planning, but also save the reconstruction model training time.

In general, the research in this paper aims at the application of transfer learning based on data distribution similarity in enterprise electricity forecasting, and realizes accurate electricity forecasting from enterprises with the same electricity consumption scale and different electricity consumption scales. Management and other tasks provide a reference basis, improve the economic benefits of power companies, and provide a strong guarantee for maintaining my country's energy security.

中国知网 https://www.cnki.net

Keywords: Power system; Data distribution similarity; Migration prediction; Enterprise electricity; Machine learning

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景与意义

1.1.1 研究背景

电力工业是把一次能源转化为二次能源，以电力为动力的能源产业，电能既能广泛地应用在各行各业又是其他能源不可替代的。随着国民经济发展和人民生活水平提高，我国对电力的依赖程度不断提高。电量预测是电力系统发电计划的重要组成部分，是合理安排电力购电、发电、输电的必要前提，是电力系统经济运行的基础[1]。近年来，随着智能电网建设步伐加快及电力市场改革不断深化，我国电力行业也进入了发展新阶段。2021 年，全国全社会用电量 8.31 万亿千瓦时，同比增长 10.3%，用电量快速增长主要受国内经济持续恢复发展、上年同期低基数、外贸出口快速增长等因素拉动。其中全社会用电量两年平均增长 7.1%，各季度两年平均增速分别为 7.0%、8.2%、7.1%和 6.4%，总体保持平稳较快增长[2]。“十四五”电力规划工作启动会议[3]中提出，电力发展“十四五”规划要以提高电力安全保障能力为重点，以推进电力供给侧结构性改革为抓手，以提高电力系统整体效率为目标，以促进电力的绿色转型升级为目标。目前，电量预测已成为现代化电力系统运行管理的重要研究领域[4]。

通过对全社会用电量的分析和预测，电力企业了解全社会用电量，主要是通过对历史数据的分析和对电力客户用电量的分析。而电力作为一种特殊商品，其价值在于能够满足人们日常生活需要以及国家经济建设所需，所以电力企业必须重视电量的分析与预测工作。但是在实际开展这项工作的时候存在很多问题。如果电力企业对生产企业的电力供应缺乏分析和预测，或者在数据分析中出现错误等，将影响电力企业的发展决策[5]。因此，对电量进行合理、准确的预测是电力企业可靠发展的关键，不仅可以提高供电企业的运营效率和运营水平，而且对生产企业进行项目投资和生产经营管理具有重要意义。

但是，目前在电量预测中仍然存在一些问题。

（1）由于不同的用电企业(如商业、制造业、重工业等)具有不同的用电特性，生产企业的电量数据是一个复杂的数据集，从行业到区域，具有多层次、高维度、高信息含量、低价值密度的特点[6]，且当各行业处于不同经济社会发展阶段时其用电发展特性会出现波动变化，随着经济发展新常态和产业结构转型的加

中国知网 https://www.cnki.net

快，这种波动会进一步加剧。因此，传统的将整个用电行业作为一个整体的传统预测模型存在一定的缺陷，忽视了用电行业的内在特性而做出预测误差。如何减小不同规模企业之间的电量数据差异，提高电量预测模型的泛化性，缩短重建模型的训练时间，是当前迫切需要解决的问题。

（2）在电网规划前，对城市进行详细的调查研究，在此基础上，以往的城市电力规划数据变得非常重要，成为调查研究的基础。传统的方法是通过人工记录来获取一些原始资料，然后再将这些原始资料整理成表格或图表等形式。这些原始资料具有时效性强、内容丰富等优点。然而，由于这些数据是实时更新的，因此过去的数据收集工作不足，往往使调查难以进行。从目前的实际情况看，我国电网规划建设和改造时没有很好的数据组织工具[7]，传统的电量预测方法基于企业自身的已有数据进行预测，电量数据过少导致无法对未来时刻进行准确预测。因此，能否利用大量的、相关的企业电量数据，能否挖掘与目标企业电量数据的相似性，通过迁移学习，提高电量预测的精度，也是本文研究的重点。

基于以上问题，本文提出了一种基于数据分布相似性的迁移学习方法，可应用于生产企业的电量预测。

1.1.2 研究意义

科学意义。目前所见的电量预测的研究成果大多是基于企业自身大量的电量数据进行预测，在城市电网规划的情况下无法实现准确预测。本文提出的基于数据分布相似性的迁移学习的电量预测方法，能够提升对新鲜样本的适应能力，解决数据收集不足的问题，为城市电网规划的决策方法提供理论参考和指导，也为迁移学习的应用范围进行扩充。

现实意义。电量预测是企业生产运营管理和电网管理的重要组成部分，是确保电力企业安全平稳运行的基本手段之一。本文的研究为电力企业的决策方法提供理论参考和指导，并为电网的日常运行、规划管理等多项工作提供参考依据，提高了电力企业的经济效益，为维护我国的能源安全提供有力保障。

1.2 国内外研究现状

1.2.1 电量预测研究现状

目前电量预测研究经历了几十年的发展，国内外电量预测研究取得了丰富的积累和突破，开发出了许多有效的电量预测方法。然而，由于电力市场环境的复

中国知网 https://www.cnki.net

杂性及随机性，导致电量预测精度受到一定程度的影响。本文对电力市场运作模式下的电量预测问题进行分析与探讨；提出提高电能预测准确性的措施建议。

第一种方法是许多电力行业专业人士从长期的工作经验和对电力行业数据的广泛观察中总结出的未来电量趋势的方法，这种方法通常被称为经典方法，其中电力弹性系数法和单耗法具有代表性[8,9]。经典方法通常需要长时间的训练，才能得出更准确的结论。由于需要大量人工经验，该方法只能根据几个典型的电量特征来推断未来电力的大致趋势，很难保证对现代电力系统进行准确、实时性的预测。因此，一些新的算法应运而生，如支持向量机、人工神经网络（Artificial Neural Network，ANN）等。由于其计算简单方便且易于实现，成为了最常用的方法之一。后来，随着统计学方法的发展，大量基于统计学的预测方法和经典方法相结合的预测方法被应用于电力预测研究，这些方法被称为传统方法，其中回归分析预测方法[10]、灰色模型预测法[11]、时间序列预测方法[12]以及趋势外推预测方法[13]等，被认为是传统方法的代表方法。国内外学者在传统方法的基础上进行研究，又衍生出大批预测方法。例如，王捷[14]等人提出建立蚁群灰色神经网络组合预测模型来预测长期的经济。王德文、孙志伟[15]结合云计算技术，提出了基于随机森林算法的电力用户侧大数据分析处理平台和并行负荷预测方法算法。

传统方法在经典方法的基础上取得了许多突破，大大提高了精确性和实用性，但由于电力使用的复杂性和诸多影响因素，传统方法不能很好地预测电力情况。近年来，随着机器学习方法和深度学习方法的发展及其在各行各业的应用，包括电量预测在内都取得了突破性进展。

早在上 20 世纪 90 年代，人工神经网络就被引入到电量预测领域，利用 ANN 强大的非线性表达能力来预测更复杂的电力情况[16]。但是，由于神经网络存在收敛速度慢、容易陷入局部极小值等问题，使得其应用效果不理想。因此，如何有效解决上述问题成为当前该领域关注的热点。

机器学习方面，回归分析法中的多元线性回归模型也常被使用。此外，越来越多的学者倾向于对线性模型进一步的改进，得到 SVM 模型，与多元线性回归相比，SVM 模型在结合核核函数可以防止过拟合和增强非线性表达能力，因此 SVM 可以适应更多的电量消耗预测，这已被许多学者广泛研究[17]。在深度学习中，大多数深度学习算法都是 ANN 的扩展，深度学习类算法具有更深的隐藏层，典型的深度学习算法有深度神经网络(Deep Neural Network，DNN)，卷积神经网络(Convolutional Neural Networks，CNN)，循环神经网络(Recurrent Neural

中国知网 https://www.cnki.net

Network，RNN)等。更深的隐藏层可以表达更复杂的非线性关系，从而获得最准确的预测精度，是电力预测领域中研究最广泛的方法之一。其中，由于 RNN 本身的网络结构，它是最适合处理时间序列信号的。LSTM 是对 RNN 的一种改进，它能防止由于 RNN 的深度而产生的梯度消失，能更好地处理时间序列信号，并广泛应用于电量预测研究[18]。

1.2.2 迁移学习研究现状

迁移学习是指从环境中学习的知识有助于改善在新环境中的学习。在迁移学习中，目标任务的性能随着资源任务提供的信息而提高，迁移学习放松了传统机器学习中的假设，即数据分布相同，来自相同特征空间，在源领域具有大的标定数据，在目标领域具有小的可伸缩数据，在源领域和目标领域之间具有一些通用的特征。如果源领域和目标领域的任务相同，这种迁移学习模式称为归纳迁移学习[19]。总体上来说，目前将迁移学习应用在电量时间序列数据的研究成果还比较少，大多数的应用场景都是图像分类[20]、文本情感分类[21]、人类活动分类[22]、软件缺陷分类[23]和多语言文本分类[24]。

近年来，随着机器学习应用场景的不断涌现，迁移学习是一种利用现有知识解决不同领域相关问题的新型机器学习方法，可以解决目标领域标注样本不足的问题[25]。通过模型权重共用的方法，迁移学习可以有效地解决训练数据不足造成模型准确度低的问题。大多数早期的迁移学习算法都是基于这样的假设：通过匹配来自不同领域的特征分布可以实现自适应。这些方法的目的是通过最大限度地减少源域中的域差异和类别损失来获取域不变特征，2015 年出现了大量的迁移学习算法，例如 DAN[26]、DDC[27]和 Deep-CORAL[28]，其中最具代表性的应该是 DDC 和 Deep-CORAL。DDC 使 AlexNet 预训练模型加上微调，利用 MMD 距离最小化源域与目标域分布之间的距离，从而使基于源域的标签分类器可以直接用于目标域的测试。姜海燕[29]等提出了一种基于最大均值差异的多标记迁移学习算法，并将其作为子空间特征均值差异最小化的评价指标，使源域和目标域的特征多标记图像分类实验尽可能相似。针对大数据时代小样本数据预测精度较低的问题，任俊等[30]提出一种基于堆栈降噪自编码（SDA）与支持向量回归机（SVR）的混合模型，该方法采用源域大样本数据对堆栈降噪自编码和支持向量回归机混合模型进行迁移预训练，再利用目标域小样本数据微调混合模型，在多种数据集上的实验结果证明了该方法的有效性。顾涛勇等[31]提出了一种自适应权重插值拟

中国知网 https://www.cnki.net

合迁移学习算法，可以用于预测机载设备在不同工作环境发生故障的概率。该方法采用基于机器学习技术的加权函数对训练集进行优化处理，从而提高了模型的泛化能力，可以避免数据贫化的预测风险。苏运等[32]提出了一种基于低秩表示的多站点多任务负荷预测方法，该方法可以在学习过程中提取出不同位置的负荷预测模型共享的低维表示，从而挖掘多个任务之间的关联，同时区分不同任务间的差异。王天力[33]通过在 BP 神经网络的基础上融合人工蜂群算法，验证了基于 BP 神经网络模型的人工蜂群算法的可行性，并将该模型应用于短期电力负荷预测。

1.2.3 迁移学习在电量预测中的研究现状

目前电量预测领域中迁移学习的研究成果较少，而基于迁移学习的电量预测在一定程度上可以提高电量数据利用率和网络的性能。刘世昌[34]提出了多尺度分析与数据互迁移相结合的短期电力负荷预测方法，利用基于实例的迁移学习方法，将类似于其他几种类型的日常预测数据转移到需要预测的日常数据集。盛昌[35]提出了一种基于节假日的加权迁移学习方法，利用不同来源的假日负荷数据权重反映目标城市与源城市的相关性，反映不同负荷数据信息的本质特征，从而建立更准确的预测模型。

1.3 本文的研究内容及创新点

1.3.1 本文研究内容

由于不同用电规模企业间的电量数据相似性较低，传统企业电量预测模型的泛化程度低，城市电网规划中数据更新迭代快以及目前电量预测领域中迁移学习的研究成果较少等问题，本文提出了一种基于数据分布相似性的迁移学习方法应用于企业电量预测中，通过相似性分析，将最大均值差异 MMD 作为判断源域企业和目标域企业电量数据的相似性度量，测算相同用电规模企业之间日用电量的 MMD 距离，通过迁移学习，建立了基于改进 MMD 的迁移 LSTM 神经网络模型，建立普适性模型后，探究不同比例的样本数量、惩罚因子以及季节性 MMD 对迁移预测精度的影响。进一步探究了不同用电规模企业的电量迁移预测效果。通过实证分析证明了本文模型的可行性，有效解决了由于数据更新过快导致模型准确度低等问题，为电力系统的安全运行提供有力保障。

1.3.2 本文创新点

本文的主要创新点：

中国知网 https://www.cnki.net

（1）方法创新。电量的精准预测往往需要大量的目标企业电量数据作支撑，本研究采用一种基于数据分布相似性的迁移学习方法，能在保证预测准确率不明显下降的前提下大大减少了算法对企业自身电量数据的依赖，从而能够提升预测模型的泛化性，节省模型的重新建模时间，帮助电力企业有效进行日常规划管理工作。

（2）应用创新。目前迁移学习应用到电量预测领域尤其是企业日用电量数据的实证分析的相关研究相对来说较少，主要是集中在电力负荷预测上。迁移学习在大数据背景下的研究仍然在不断发展，应用在预测领域的研究很少，在电量预测方面的研究更是微乎其微，未来还有很大的发展空间。本文将迁移学习应用到企业电量预测领域，系统构建基于迁移学习的电量预测的模型，定性与定量的分析了企业用电的特征与规律，为企业电量的精确预测和管理提出理论支持。

1.4 本文的结构安排

根据本文研究思路及其现有基础，本文的研究流程如图 1.1 所示。

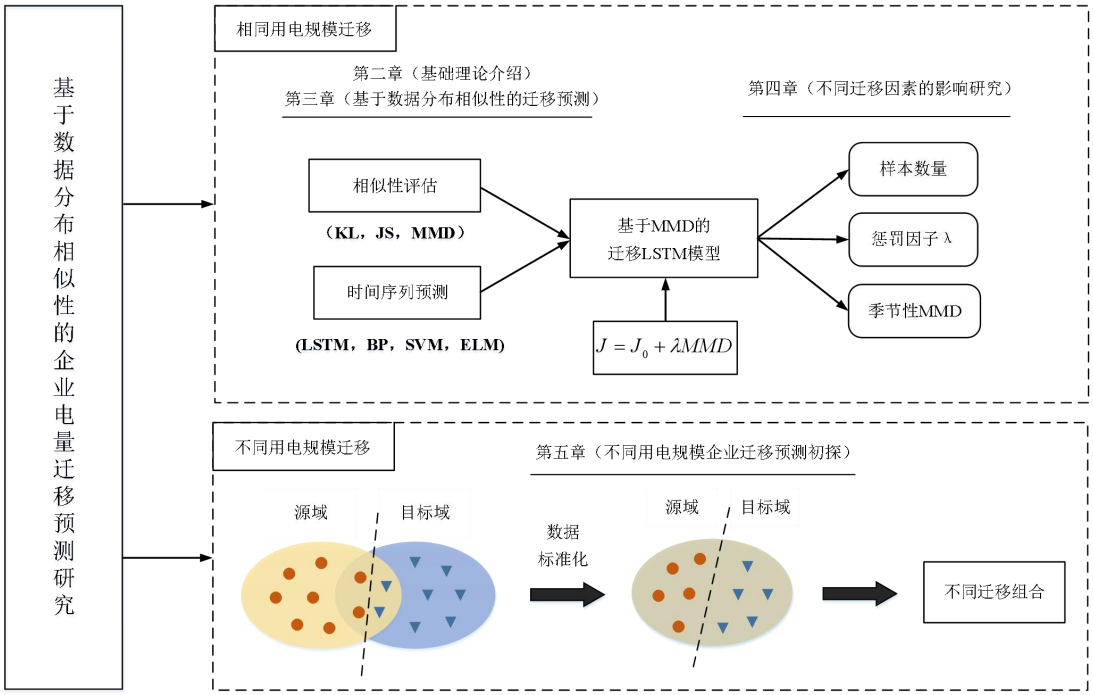


图 1.1 研究流程图

具体地，本论文共分为六个章节，各个章节的研究内容关系如下所示：

第一章，绪论。基于企业电量预测与迁移学习的研究背景和意义，综述了国内外电量预测与迁移学习领域的研究现状，并对其存在的不足进行了分析，引出本文的研究内容。最后，对文章的主要内容进行了简要概括。

第二章，基础理论介绍。分三个方面主要介绍了迁移学习相关的概念和理

中国知网 https://www.cnki.net

论、常见的相似性度量方法以及介绍了相关神经网络模型的原理结构，作为整个论文的理论基础。本文主要的核心思想是利用预测模型和迁移学习在保证预测可靠精度的情况下实现迁移预测，提高电网运行的安全性和可靠性。

第三章，基于数据分布相似性的迁移预测。通过对比常见 LSTM、BP、SVM、ELM 模型对三种相同规模的企业日用电量的预测性能，从整体上把握各个模型在企业电量预测中的性能和效果，最终选取 LSTM 模型作为电量预测模型。然后采用 KL 散度、JS 散度、MMD 距离三种不同的相似性度量改进 LSTM 模型的损失函数，发现基于 MMD 距离的迁移 LSTM 模型在三种规模企业预测中能达到较高的精度，预测结果相对稳定。最后加入惩罚因子λ改进模型的损失函数，提出一种基于改进 MMD 的迁移 LSTM 模型，与直接利用目标域建模的 LSTM 模型进行实验对比分析，讨论迁移 LSTM 模型对相同规模企业的电量预测效果。

第四章，不同迁移因素的影响研究。从不同迁移因素入手，探究不同比例的样本数量、惩罚因子λ和季节性 MMD 对迁移预测精度的影响。

第五章，不同用电规模企业迁移预测初探。以上章节均是研究相同规模企业的电量预测，本章进一步拓展研究到不同规模的企业，通过对输入源域企业电量数据的标准化改进，缩小不同规模企业间的电量数据差异，探究本文提出的基于改进 MMD 的迁移 LSTM 模型在不同规模企业迁移预测时的效果。

第六章，总结与展望。第一部分对文中研究的主要内容进行总结概述，第二部分对未来工作提出展望。

中国知网 https://www.cnki.net

第 2 章 基础理论介绍

本章主要是为接下来的几章提供理论基础和知识铺垫，分别介绍了介绍迁移学习的相关理论、领域间相似性的度量以及对几种常见机器学习模型进行了阐述。

2.1 迁移学习概述

传统机器学习和数据挖掘的方法通常基于训练数据和测试数据来自同一领域的假设，即训练数据和测试数据具有相同的输入特征空间，满足相同的数据分布要求。然而，在许多实际情况下，与测试数据分布相同的有标签的训练样本可能很少，而且对样本进行标签是费力和费时的。如果模型直接针对少数已知样本进行训练，可能会出现拟合问题，并对模型的性能产生负面影响。在许多情况下，虽然难以取得与测试数据相同领域的标签样本，但不同领域的已知样本数目可能非常多。例如，在图像识别方面，已知 A 类物品对象的照片很少，而 A 类和 B 类对象的照片虽然不同，但有相似之处。传统的机器学习方法需要找出大量 B 类对象并贴上标签，以节省资源。因此，为解决这一问题，提出了迁移学习，通过训练与目标域相关的源领域的样本来帮助构建最终模型[36]。

迁移学习的主要思想与我们熟悉的“一取三就”和类比归纳类似，通过利用现有的相关经验知识来帮助学习新知识，可以将来自不同来源但相关源领域知识作为辅助信息，帮助目标领域提高学习任务的训练效果。本文对迁移学习进行了全面深入的阐述，从其基本概念、模型建立方法以及在实际应用中的优势等方面进行了分析与探讨。此外，还表明迁移学习可用于解决缺乏带标注数据匮乏的问题，并使训练集和测试集能够以不同的方式分布。本节将详细介绍迁移学习的形式化定义、分类和其他理论基础知识。

2.1.1 基本概念和定义

为此，我们需要用数学语言形式化正式定义迁移学习。因此，本文提出了一个基于领域知识的迁移学习方法。该方法是针对当前迁移学习中存在的一些问题而产生的一种新的方法。它可以解决传统迁移学习所不能解决的问题。在给出迁移学习的形式化定义之前，我们首先描述和解释两个重要的基本概念：领域和任务。

领域是迁移学习的学习主体，一个领域包含两个组成部分：实例的特征空间

中国知网 https://www.cnki.net

X 和实例所服从的边缘概率分布 $P(x)$，其中 $x \in \mathrm{X}$ 。通常用符号 D 表示一个领域，并记为 $\mathrm{D} = \{\mathrm{X}, P(x)\}$。根据领域的组成要素不同，两个领域的特征空间或边际概率分布也不同。在迁移学习中，我们把辅助信息所在的领域称为源领域（Source domain），记作 D_s，把要解决的问题所在的领域称为目标领域（Target domain），记作 D_T，迁移学习将源领域中的知识迁移到目标领域。任务（Task）是迁移学习的学习目标,通常用符号 T 表示。给定一个领域 $\mathrm{D} = \{\mathrm{X}, P(x)\}$，一个任务也由两个要素构成：标注空间 Y 和标注所对应的目标预测函数 $f(\cdot)$。因此，可以将任务记为 $\mathrm{T} = \{\mathrm{Y}, f(\cdot)\}$。从概率或统计学的角度解释，可以将预测函数 $f(x)$ 视为条件概率分布 $P(y|x)$，即 $f(x) = P(y|x)$,其中 $x \in \mathrm{X}$，$y \in \mathrm{Y}$ 。此后，将在变量符号中通过加下标 S 和 T 来分别表示源领域和目标领域中的变量，例如，将源领域和目标领域的标注空间分别表示为 Y_S 和 Y_T [37]。

一般情况，源领域数据及其学习任务可以分别表示为式（2.1）和式（2.2）的形式:

$$D_S = \left\{\left(x_i^S, y_i^S\right)\right\}_{i=1}^{n_S} \tag{2.1}$$

$$\mathrm{T}_s = \left\{\mathrm{Y}_s, f_s(\cdot)\right\} \tag{2.2}$$

其中，$x_i^s \in \mathrm{X}_s$ 为源领域数据集中的第 i 个实例的特征向量，$y_i^s \in \mathrm{Y}_s$ 为实例 x_i^s 所对应的标注，$n_s = |D_s|$ 为源领域数据集实例数目。

类似地，目标领域数据及其学习任务可以分别表示为式（2.3）和式（2.6）：

$$D_T = D_T^l \bigcup D_T^u \tag{2.3}$$

其中，D_T^l 为目标领域带标注数据集，D_T^u 为目标领域无标注数据集，二者的表达式分别见（2.4）和（2.5）：

$$D_T^l = \left\{\left(x_j^T, y_j^T\right)\right\}_{j=1}^{n_T'} \tag{2.4}$$

$$D_T^u = \left\{x_j^T\right\}_{j=n_T'+1}^{n_T'+n_T^u} \tag{2.5}$$

其中，$x_j^T \in \mathrm{X}_T$ 为目标领域数据集中的实例，$y_j^T \in \mathrm{Y}_T$ 为实例 x_j^T 所对应的标注。$n_T = n_T^l + n_T^u$ 为目标领域数据集 D_T 中实例的数目，一般都有 $0 \le n_T \ll n_S$，即目标领域中带标注的数据数远小于源领域中带标注的数据。

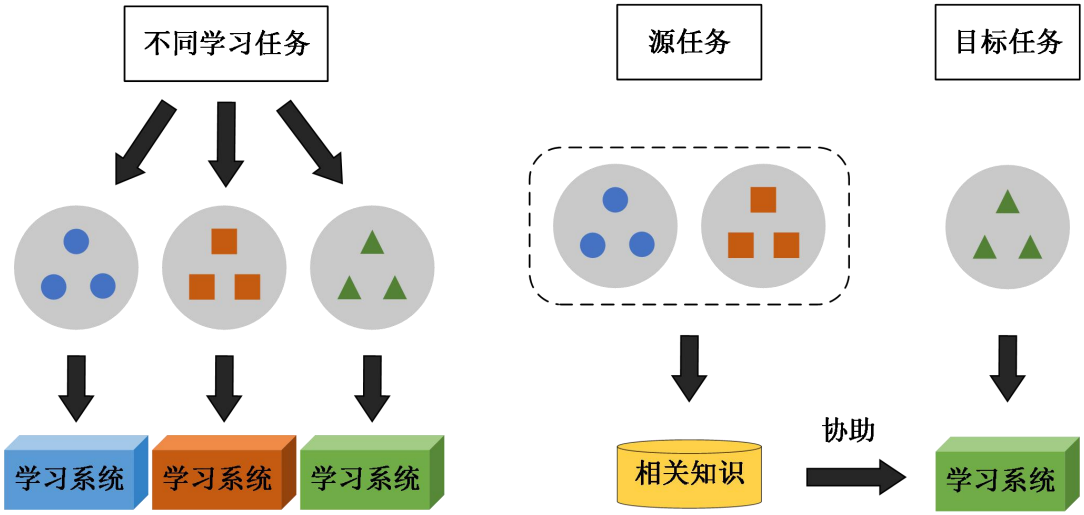
$$\mathrm{T}_T = \left\{\mathrm{Y}_T, f_T(\cdot)\right\} \tag{2.6}$$

本文引用文献[38]中对迁移学习的形式化定义，具体见定义 2.1。定义 2.1 迁移学习[39]：对于一个目标领域 D_T 和其对应的学习任务 T_T，假设存在源领域 D_s 和其对应的学习任务 T_s，其中 $\mathrm{D}_s \neq \mathrm{D}_T$ 或者 $\mathrm{T}_s \neq \mathrm{T}_T$。迁移学习旨在通过将源领域 D_s 和

中国知网 https://www.cnki.net

源任务 T_s 中的有用知识迁移到目标领域 D_T，提升目标任务 T_T 中的目标预测函数 $f_T(\cdot)$ 的训练效果。在通过将源领域 D_s 和源任务 T_s 中的有用知识迁移到目标领域 D_T，提升目标任务 T_T 中的目标预测函数 $f_T(\cdot)$ 的训练效果。

迁移学习的学习过程示意图如图 2.1 所示。相比于传统机器学习，迁移学习放松了独立和分布假设的基本条件，并将知识从不同但相关的源领域转移到目标领域，从而有助于解决传统机器学习中缺乏带标注数据的问题，以培训高度泛化的目标预测函数。然而，由于目标领域的不完备性，使得迁移学习的应用受到一定限制。因此，为了进一步提高迁移学习算法的分类精度，需要对迁移学习过程进行改进。迁移学习中的一个重要问题是如何尽可能地发现和利用与目标任务相似的源的任务，以避免负迁移，同时提高正迁移。



（a）传统机器学习过程　　（b）迁移学习过程

图 2.1 传统机器学习和迁移学习过程示意图

2.1.2 迁移学习类型

对于迁移学习问题，可根据特性差异进行详细分类。在每项研究中，研究人员通常选择特定类型的迁移学习类型进行研究。而对于不同性质的迁移学习来说，其分类是不相同的。所以，需要从多个角度出发，将迁移学习的类别加以区分和分析，以更好地实现相关工作开展。

根据源域和目标领域中数据特征空间的异同，迁移学习可分为同构迁移学习与同构迁移学习。当目标域和源域的特征空间相同时，这种迁移学习问题称为同态迁移学习。异构迁移学习的关键在于建立异构特征空间之间的关系，但由于目标领域和源域数据位于不同的特征空间中，因此目标领域和源域特征空间之间可

中国知网 https://www.cnki.net

能并不直接相关。在异构迁移学习中，我们必须依靠特定领域的先验知识来构造一个映射来关联这两个特征空间，而该映射的构造通常非常复杂和困难。在异构迁移学习中，先验知识常被用来将异构特征空间转化为同构特征空间然后再转化同构迁移学习。本文研究的迁移学习研究属于同构迁移学习。

依据根据目前流行的机器学习分类方法，可以将机器学习分为有监督、半监督监督式和无监督机器学习三大类。根据是否标记源域和目标域样本将迁移学习分为三类[40]：在目标领域有少量标注样本的归纳法迁移学习、在源领域有标签样本的直接迁移学习和在源领域和目标领域没有标签样本的无监督迁移学习。此外，根据对迁移的了解将迁移学习分为四类[41]：基于案例的迁移方法、基于特征的迁移方法、基于关系的迁移方法和基于模型的迁移方法，如图 2.2 所示。实例迁移是指学习任务，其中源域中的某些数据可以通过调整权重在目标域中重用。基于特征迁移是指源域和目标域之间可以共享学习到的特征表达，这些新的特征表达可以用来提高目标域的性能。模型迁移方法假设源域和目标域可以共享某些参数的先验分布或模型超参数。本文采用的是基于特征的迁移学习针对企业电量进行迁移预测。

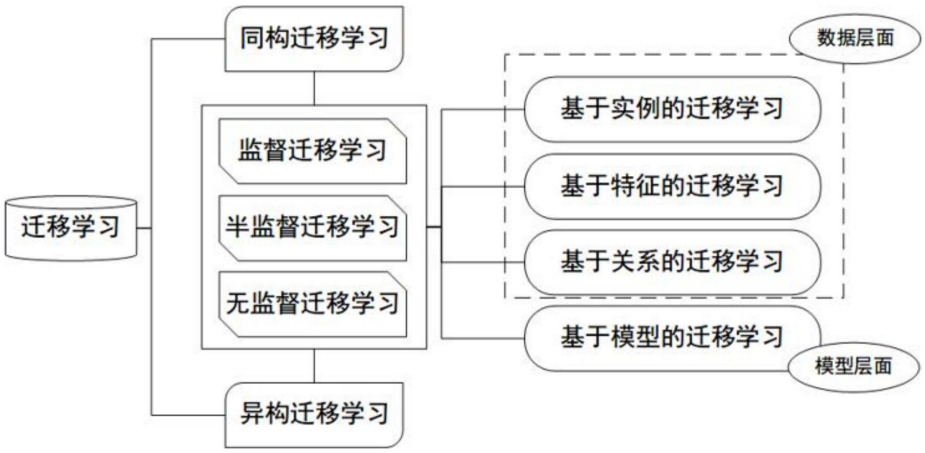


图 2.2 迁移学习分类

2.1.3 负迁移

迁移学习并不总是有效的，迁移学习的有效性的前提需要满足以下三个基本假设：(1)源域和目标域的学习任务相关或相似，源域和目标域应该有相同的类别；(2)源域和目标域的分布不能太大差异，即领域样本之间不能有太多差异；(3)需要建立一个既适用于源域又适用于目标域的网络模型。这三个基本假定都有一定的局限性，而且它们也不是完全成立的。在实际应用中还存在着很多其他的条

中国知网 https://www.cnki.net

件限制因素。比如源-目标空间距离过大以及训练量有限等。如果没有这些必要的前提，迁移学习就可能导致负迁移(Negative Transfer，NT)，如图 2.3 所示。

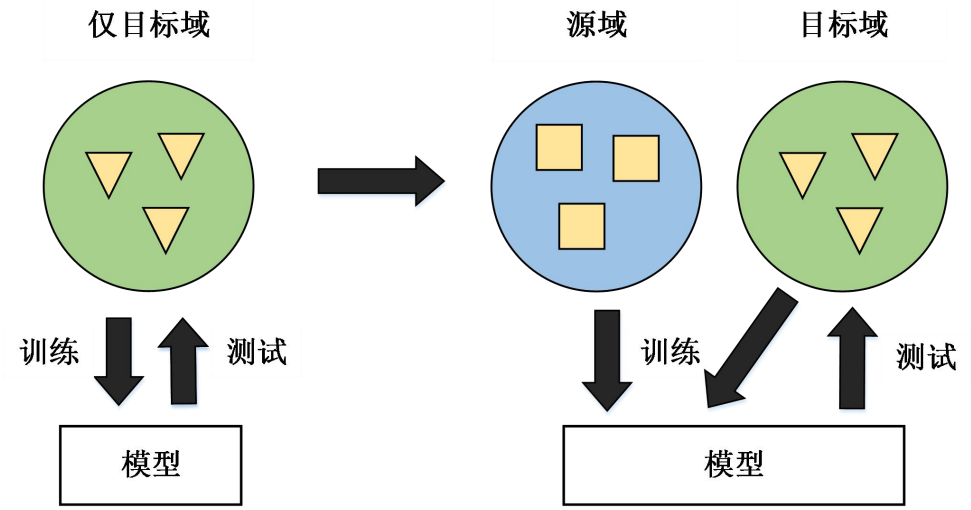


图 2.3 负迁移示意图

对于迁移学习而言，负迁移是一个不可避免的问题。迁移学习需要考虑三个基本问题：迁移什么、怎么迁移、何时迁移。大多数迁移学习研究只考虑前两个问题，但为了避免负迁移现象，应同时考虑所有三个问题。

2005 年，Rosenstein 等人[42]首次对负迁移进行了研究，近年来，负迁移的研究受到了广泛关注，研究根据四个因素分为四个研究方向，分别是源域数据质量、目标域数据质量、领域分布差异和集成算法。（1）源域数据质量：在迁移学习中，源域中的数据量往往远远大于目标域，因此源数据质量对于迁移学习性能的效果至关重要。为了避免负迁移，该研究方向的算法[43]主要是研究和探索领域之间的相似信息，避免不相关的信息，这些信息包括源域样本、特征或者样本标签等信息；（2）目标域数据质量：迁移学习到模型最终应用于目标域，目标域数据在确定迁移对象时至关重要。尽管改善目标域数据质量的迁移学习算法[44]较少，但是提高目标域数据质量对于迁移学习性能是非常重要的；（3）领域分布差异：领域分布差异是导致负迁移现象的根本原因，目前大多数算法[45]都是用来测量和减小域分布差异的，研究方向是通过对抗训练[46]和特征优化[47]来消除域之间的分布；（4）集成算法：目前许多集成算法，如安全迁移[48]、强化迁移[49]等算法提出了一些避免负迁移的理论保证。

本文主要基于源域与目标域数据之间的分布差异因素考虑解决负迁移的问题，主要思想就是尽可能领域分布差异，提高目标域的识别精度。通常认为，数据分布差异越大，负迁移现象就会越严重。为了解决数据分布不一致的问题，一

中国知网 https://www.cnki.net

方面可以通过测量域之间的相似性来选择数据分布差异小的源域，另一方面可以从源域和目标域中提取一次数据，以减少数据之间的差异，并相应地移动数据。

2.2 领域间相似性的度量

目前，大多数的迁移学习研究都假定源区和目标领域是不同的但相互关联的，源领域和目标领域有很高的相似性，因此源领域有足够的迁移知识供目标领域学习，而不是被源领域的干扰信息所削弱。

由于源领域是固定的，且目标领域的迁移性能在很大程度上依赖于源领域，因此当选择的源领域与目标领域的相似性较小时，可能会出现负迁移。领域间的相似程度对迁移的有效性非常重要，如果能找到一个合适的度量领域之间相似程度的度量标准，并帮助基于相似程度选择与目标领域高度相似的源领域进行迁移学习，则可以提高迁移效率并避免负迁移。因此，在本节中，我们将概述跨领域的相似性度量，并介绍机器学习中常用的一些相似性度量方法，以进一步探讨和分析其在迁移学习中的适用性。

2.2.1 相似性度量概述

机器学习的其他领域经常涉及到与相似性度量有关的问题。常用的度量方法可分为两类：一种是距离度量[50]（Distance measure），通过直接计算两个给定实例之间的距离或两个概率分布的差异来估计两个给定实例之间的相似性，距离越小相似度越高，距离越大相似度越低。常见的距离度量包括闵可夫斯基距离、马氏距离、Hellinger 距离和非度量距离 KL 散度等。另外一种是相似度度量[51]（Similarity measure），经常用于将数据与一些特征差异进行比较，其值域一般为[0，1]。与距离度量相反，相似度量值越大，被比较对象的相似度越高，而相似度越小，相似度越低。常见的相似度度量有余弦相似度、皮尔逊相关系数和最大均值差异等。

2.2.2 常见相似性度量方法

目前，已经有很多相似性度量方法[52]，本文将对常见的相似性度量方法进行总结，根据不同类型的相似度度量，从距离度量和相似度度量两个方面对机器学习中的常见相似性度量方法进行介绍和分析。

距离度量可以分为基于实例的距离度量和基于概率分布的距离度量。常见的基于实例的距离度量有闵可夫斯基距离及其特殊形式哈欧氏距离和马氏距离等，

中国知网 https://www.cnki.net

详细介绍如下。

（1）闵可夫斯基距离（Minkowski distance）[53]

假设给定两个实例 $x_i=\left(x_{i1},x_{i2},\ldots,x_{in}\right)$ 和 $x_j=\left(x_{j1},x_{j2},\ldots,x_{jm}\right)$，闵可夫斯基距离的定义为

$$d_{\mathrm{mk}}\left(x_i,x_j\right)\triangleq\left\|x_i-x_j\right\|_p=\sqrt[p]{\sum_{k=1}^{m}\left|x_{ik}-x_{jk}\right|^p} \tag{2.7}$$

其中，$\|\cdot\|$ 表示范数，$p\geq 1$ 表示阶数，通常取 p=1,2 或 ∞。

当 $p=2$ 时，其等价于欧式距离(Euclidean distance)，也就是两点在欧式空间中的真实距离，计算公式如式(2.8)所示。

$$d_{\mathrm{cd}}\left(x_i,x_j\right)=\left\|x_i-x_j\right\|_2=\sqrt{\sum_{k=1}^{m}\left|x_{ik}-x_{jk}\right|^2} \tag{2.8}$$

（2）马氏距离（Mahalanobis distance）[54]

马氏距离与量纲无关，其运用 Cholesky 变换消除实例不同特征间的相关性以及量纲不同的性质，排除了变量之间的相关性对结果的干扰。定义见式（2.9）。

$$d_{\mathrm{ma}}\left(x_i,x_j\right)\triangleq\sqrt{\left(x_i-x_j\right)S^{-1}\left(x_i-x_j\right)} \tag{2.9}$$

其中，S 为实例（向量）x_i 和 x_j 之间的协方差对称矩阵。若协方差矩阵是单位矩阵，即实例中各特征独立同分布，则二者之间的马氏距离等于它们之间的欧式距离。

常见的基于概率分布的距离度量有 KL 散度、Hellinger 距离、巴氏距离和最大均值差异 MMD 等。本文仅考虑离散概率分布，具体介绍如下。

(1) KL 散度[55]

KL 散度在信息论中又称为相对熵，同时也是 f 散度的一个特例。KL 散度是可以用于衡量两个概率分布差异的一种度量，假设有两个分布 P_T 和 P_S,KL 散度的定义见式（2.10）。

$$D_{KL}\left(P_S\|P_T\right)\triangleq\sum_{i=1}^{n}P_S\left(\mathbf{x}_i\right)\log\frac{P_S\left(\mathbf{x}_i\right)}{P_T\left(\mathbf{x}_i\right)} \tag{2.10}$$

KL 散度的取值范围为$[0,+\infty)$，KL 散度就越小，说明分布 P_T 和分布 P_S 的差异就越小，当且仅当两个分布相同时取 0。KL 散度不满足距离公理中的对称性法则，即 $D_{KL}\left(P_S\|P_T\right)\neq D_{KL}\left(P_T\|P_S\right)$，同时也不满足三角不等式法则，因此它不是真正的距离度量，属于一种非度量距离。但是它具有非负性，并且能体现出相似性的概念，被作为统计学中的广义距离，称为散度。KL 散度在机器学习中经常

中国知网 https://www.cnki.net

被作为损失函数、在回归中验证拟合分布和真实分布间的概率密度相似度、自然语言处理问题中用于比较文档相似度、推荐系统中比较用户相似度等。

(2) JS 散度[56]

JS 散度度量了两个概率分布的相似度，基于 KL 散度的变体，其定义表达式见式（2.11）。

$$D_{JS}=\frac{1}{2}KL\left(P_S\|\frac{P_S+P_T}{2}\right)+\frac{1}{2}KL\left(P_T\|\frac{P_S+P_T}{2}\right) \tag{2.11}$$

JS 散度解决了 KL 散度非对称的问题。一般地，JS 散度是对称的，其取值是 0 到 1 之间。

(3) Hellinger 距离（Hellinger distance）[57]

Hellinger 距离是一种衡量两个分布间差异的度量，其定义表达式见式（2.12）。

$$D_{\text{Hclli}}\left(P_s,P_T\right)\triangleq\sqrt{\frac{1}{2}\sum_{i=1}^{n}\left(\sqrt{P_S\left(\mathbf{x}_i\right)}-\sqrt{P_T\left(\mathbf{x}_i\right)}\right)^2} \tag{2.12}$$

Hellinger 距离也属于 f 散度的一种特殊形式，但是 Hellinger 距离满足距离度量公理，由公式可以得出，Hellinger 距离是非负对称距离，取值范围为[0,1]，当且仅当 $P_s=P_T$ 时 $D_{\text{Hclli}}=0$，同时也满足三角不等式。

（4）巴氏距离（Bhattacharyya distance）[58]

巴氏距离的定义见式（2.13）。

$$D_{\text{Bhat}}\left(P_S,P_T\right)=-\ln\left(\sum_{i=1}^{n}\sqrt{P_S\left(x_i\right)P_T\left(x_i\right)}\right) \tag{2.13}$$

巴氏距离的取值范围为$[0,+\infty)$，不满足三角不等式，不是严格意义上的距离度量，常被用于特征选择。

（5）最大均值差异[59]

最大均值差异可以度量在再生核希尔伯特空间（Reproducing kernel hilbert space，RKHS）中两个分布 P_s 和 P_T 之间的差异。其主要思想是将原始特征空间映射到 RKHS 空间 H 后，通过计算映射后的样本总体的均值差，来衡量分布间的差异，均值差越小，表明两个分布的差异越小。给定两个分别服从分布 P_s 和 P_T 的数据集中的全体实例构成的矩阵 $\mathbf{X}^{(s)}$ 和 $\mathbf{X}^{(t)}$，当 $n_s,n_t\to\infty$ 时 $\mathbf{X}^{(s)}$ 和 $\mathbf{X}^{(t)}$ 在 RKHS 中的最大均值差异的表示见式（2.14）：

中国知网 https://www.cnki.net

$$MMD=\left\|\frac{1}{n_{\mathrm{s}}}\sum_{i=1}^{n_{\mathrm{s}}}\phi\left(\mathbf{x}_i^{(s)}\right)-\frac{1}{n_{\mathrm{t}}}\sum_{j=1}^{n_{\mathrm{t}}}\phi\left(\mathbf{x}_j^{(\mathrm{t})}\right)\right\|_{\mathrm{H}} \tag{2.14}$$

MMD 的取值范围为$[0,+\infty)$，两个分布之间的差异越小，MMD 的值越接近于 0，反之增大。MMD 是非参数化度量，能度量出两个分布间的差异。在进行度量前不需要先估计出样本的数据分布，且利用核技巧简化计算，计算简单。在迁移学习研究领域，MMD 常被作为损失函数或正则项加入到学习器的目标优化函数中。MMD 度量就是使用源域数据集与目标域数据集的总体均值之差来表示源域与目标域之间的分布差异。

2.2.3 相似性度量在迁移学习中的适用性

此前，已有一些相似性度量方法被应用于迁移学习领域，主要是将度量学习（metric learning）与迁移学习相结合，形成了迁移度量学习的分支——迁移度量学习（transfer metric learning）。在迁移度量学习中，将度量作为目标优化函数，在已有的源领域和目标领域有监督或无监督先验知识的基础上构造约束结构优化问题。在迁移度量学习中，我们将度量作为目标优化函数，基于源领域和目标领域中存在的有监督或无监督的先验知识，构造了一些约束优化问题，该优化问题的求解是一种适合于目标任务的度量。

本文假设源领域仍未定义，希望通过某种相似性度量方法来度量其他域与目标域之间的相似性来选择合适的源域。因为如果选择的源领域和目标领域之间的相似性很低，即使将原始特征空间映射到一个新的空间，两个域的分布也很难相似或相同。但是，现有的相似性度量方法及其在迁移学习中的应用可以作为参考，以探讨它是否可以应用于本文的研究场景。

在本章 2.1.1 节的基本概念与定义的介绍中，描述了“领域”的定义，并了解到一个域包含两个要素：特征空间与边缘概率分布。本研究假设源领域与目标领域具有相同的特征空间，即同构迁移学习，因此当测量两个域之间的相似性时，比较对象落在了两个域之间的边缘概率分布差异上。为了测量这两个区域之间的相似程度，需要找到一种合适的度量方法来估计这两个分布之间的差异。

2.3 机器学习预测模型

2.3.1 BP 神经网络

BP 神经网络算法是 20 世纪 80 年代提出的一种最常用、最有效的神经网络算

中国知网 https://www.cnki.net

法[60]。BP 神经网络具有很强的自适应能力和容错功能。该网络由两个输入层、一个隐藏层和三个输出层组成，其中每个层均包含着若干神经元。它可以根据需要随时改变网络结构。它采用最快速下降的方法进行学习，使逆向反馈不断提高网络的权值和阈值。它可以存储大量的输入输出和输出之间的关系，并且通过学习将输出值和期望值之间的误差降到最低来不断调整[61]。它是一种广泛应用于函数逼近、模型识别、数据压缩和时间序列预测的神经网络模式。

BP 网络实质上是一种输出模式的映射模型，由输入层、中间层和输出层组成。只有一个输入层和一个输出层，至少有一个隐藏层数，其中使用最广泛的是三层 BP 网络结构。该模型各层都包含着一到多个节点，网络层间呈现全连接的状态，任意一层（输入层除外）的各神经单元与前一层所有神经单元分别连接，但同层的神经元节点间不相互联系，即各节点之间不存在反馈作用，如图 2.4 所示。

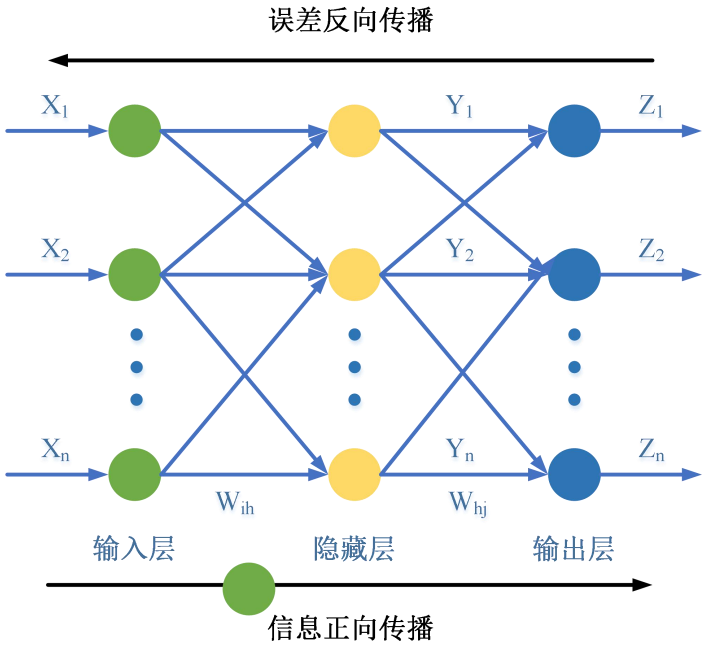


图 2.4 BP 神经网络结构示意图

BP 神经网络拓扑结构的拓扑结构中，只有一个输入层和一个输出层，通过求解这个问题来确定节点的数目。BP 神经网络结构设计的关键是确定隐藏层数和隐藏层节点数。根据 Kolmogorov 定理，隐藏层可以是单层，只要隐藏层中有足够的节点，三层 BP 神经网络就可以在闭集上任意精度地逼近任意非线性连续函数。然而，目前还没有明确的理论来指导隐藏层节点数的确定，在实际工作中，我们主要依靠经验法和试凑法来判断[62]。

中国知网 https://www.cnki.net

2.3.2 支持向量机

支持向量机统计理论为机器学习方法机器学习的方法提出的 Cortes 和 Vapnik[63]。它为解决非线性和高维模式识别问题提供了极好的思路，其中心思想是最大限度地利用空间[64]。支持向量机可以很好地处理小样本、多类数据以及不完全数据等情况。其主要优点有两个方面：（1）泛化能力强；（2）计算简单且易于实现。SVM 的目的是构造一个最优的超平面，它可以在以下约束条件下对所有样本进行精确的分类。其基本函数如下式所示：

$$f(\boldsymbol{x})=\boldsymbol{\omega}\cdot\oint(\mathbf{x})+b \tag{2.15}$$

其中 $f(x)$是一个非线性映射函数，并且ω和 b 是需要确定的向量参数。在数据集$\{(x_1, y_1),(x_2, y_2)$，…,$(x_n, y_n)\}$ ($x_i\in R^n$，$y_i\in R^n$)中 x_i为输入，y_i是输出，并且 R^n表示 n 维欧氏空间。可训练函数 $f(x)$逼近实际值 y。支持向量机的目标函数可以表示为：

$$\min_{\omega,b}\frac{1}{2}||\boldsymbol{\omega}||^2+C\sum_{\mathrm{i}=1}^{\mathrm{n}}\int(f(\mathbf{x_i})-y_i) \tag{2.16}$$

其中，$\int$是成本函数，C 是惩罚因子，n 表示数据的数量。SVM 的不敏感函数如下：

$$\int=\begin{cases}|f(\mathbf{x_i})-y_i|-\varepsilon, & |f(\mathbf{x_i})-y_i|\geq\varepsilon\\ 0, & \text{otherwise}\end{cases} \tag{2.17}$$

其中ε表示不灵敏损耗参数。SVM 方法将预测值 $f(x)$与实际值 y 之间的最大偏差ε置于两者之间，当两者之间的绝对差值大于ε时，开始计算成本值。两个宽度的边距 2ε将在 $f(x)$的中心下方建造[65]。右边界点是“支持向量”的确定模型。如果训练样本停留在空白处，则可以假定结果是正确的。

由于柔性边界，松弛变量ξ_i和ξ_i^*被引入，因此方程可以被改写为：

$$\begin{aligned}&\min_{\omega,b,\xi_i,\xi_i^*}\frac{1}{2}||\boldsymbol{\omega}||^2+C\sum_{\mathrm{i}=1}^{\mathrm{n}}(\xi_i+\xi_i^*)\\ &\text{s.t.}\quad\begin{cases}y_i-f(\mathbf{x_i})\leq\varepsilon+\xi_i\\ f(\mathbf{x_i})-y_i\leq\varepsilon+\xi_i^*\\ \xi_i\geq0,\xi_i^*\geq0,\mathrm{i}=1,2,...\mathrm{n}\end{cases}\end{aligned} \tag{2.18}$$

式中，ξ_i和ξ_i^*分别表示误差上限和误差下限。通过引入拉格朗日乘子$\boldsymbol{\alpha}\geq0$，$\boldsymbol{\delta}\geq0$。拉格朗日函数为：

中国知网 https://www.cnki.net

$$\begin{aligned} \mathrm{L} = & \min_{\omega,b,\xi_i,\xi_i^*}(\boldsymbol{\omega},b,\boldsymbol{\xi},\boldsymbol{\alpha},\boldsymbol{\delta})\frac{1}{2}\|\boldsymbol{\omega}\|^2 + C\sum_{\mathrm{i}=1}^{\mathrm{n}}(\xi_i+\xi_i^*) \\ & + \sum_{\mathrm{i}=1}^{\mathrm{n}}\alpha_i(\mathrm{y_i} - f(\mathbf{x_i}) - \varepsilon - \xi_i) + \sum_{\mathrm{i}=1}^{\mathrm{n}}\alpha_i^*(f(\mathbf{x_i}) - \mathrm{y_i} - \varepsilon - \xi_i) \\ & - \sum_{\mathrm{i}=1}^{\mathrm{n}}\delta_{\mathrm{i}}\xi_i - \sum_{\mathrm{i}=1}^{\mathrm{n}}\delta_{\mathrm{i}}^*\xi_i^* \end{aligned} \tag{2.19}$$

其中（2.18）式的对偶函数可以写成：

$$\begin{aligned} & \max_{\alpha,\alpha^*}\sum_{\mathrm{i}=1}^{\mathrm{n}}y_i(\alpha_i^*-\alpha_i) - \varepsilon(\alpha_i^*+\alpha_i) - \frac{1}{2}\sum_{\mathrm{i}-1}^{\mathrm{n}}\sum_{\mathrm{j}=1}^{\mathrm{n}}(\alpha_i^*-\alpha_i)(\alpha_j^*-\alpha_j)K(\mathbf{x_i},\mathbf{x_j}) \\ & \mathrm{s.t} \qquad \begin{cases} \sum_{\mathrm{i}=1}^{\mathrm{n}}(\alpha_i^*-\alpha_i) = 0 \\ 0 \le \alpha_i, \alpha_i^* \le C, \mathrm{i} = 1,2,...\mathrm{n} \end{cases} \end{aligned} \tag{2.20}$$

在方程（2.20）中，函数 $K(x_i,y_j)$是核函数。核函数可以将低维空间的非线性问题转化为高维空间的规划线性问题。近似函数为：

$$\boldsymbol{f}(\mathrm{x}) = \sum_{\mathrm{i}=1}^{\mathrm{n}}(\alpha_i - \alpha_i^*)K(\mathbf{x_i},\mathbf{x}) + b \tag{2.21}$$

2.3.3 ELM 神经网络

极限学习机是一种单隐层前馈神经网络，由于其学习速度快、调节参数低、预测精度高而受到众多学者的青睐[66]。通过大量的研究和应用，ELM 对高度非线性、非平稳性和时变数据具有良好的学习和学习拟合能力。同时，ELM 还具有很强的泛化能力，可以很方便地对复杂系统进行建模。它将神经网络理论运用到机器视觉领域中去，通过神经元之间的相互连接形成一个网络模型。目前，ELM 已广泛应用于故障分类及回归预测中。它最大的特点是比传统的学习算法更快[67]，只需要调整隐层节点的个数。

对于一个 ELM 神经网络，假设有 N 个任意的样本 (X_i,t_i)，其中，$X_i=[x_{i1},\ x_{i2},\cdots,x_{in}]^{\mathrm{T}} \in R^n$，$t_i=[t_{i1},t_{i2},\cdots,t_{im}]^{\mathrm{T}} \in R^m$，一个有 L 个隐层节点的神经网络可以表示为：

$$\sum^{L}\beta_i h(W_i \cdot X_j + b_i) = O_j,\quad (j = 1\cdots N) \tag{2.22}$$

式中 $h(x)$ 为激活函数，$W_i=[\omega_{i1},\omega_{i2},\ldots,\omega_{in}]^{\mathrm{T}}$ 为输入权重，β_i 为输出权重，b_i 为第 i 个隐层单元的偏置，$W_i \cdot X_j$ 表示 W_i 和 X_j 的内积，O_j 表示系统的输出。

中国知网 https://www.cnki.net

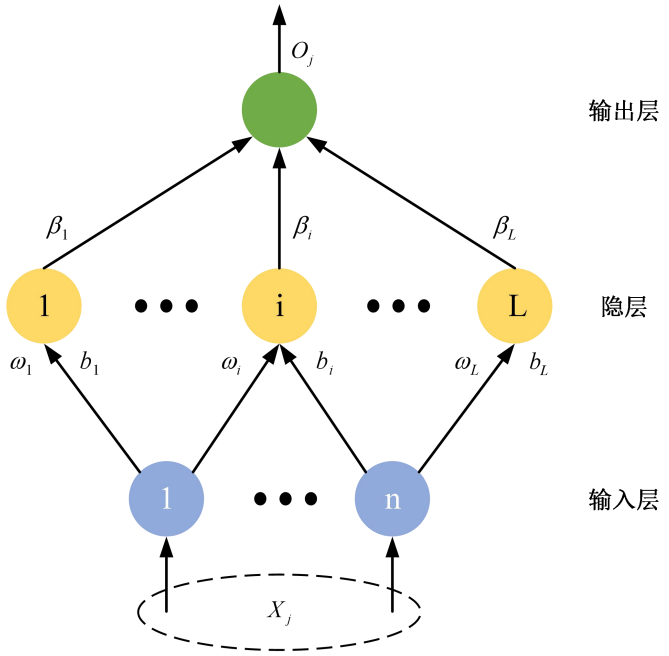


图 2.5 ELM 网络结构图

极限学习机的目标是最小化网络输出错误，可以表示为：

$$\sum_{j}^{N}\left\|O_j - t_j\right\| = 0 \tag{2.23}$$

即存在 β_i，W_i，b_i 使得

$$\sum_{i}^{L}\beta_i h\left(W_i \cdot X_j + b_i\right) = t_j, \quad (j = 1\cdots N) \tag{2.24}$$

可以矩阵表示为：

$$H\beta = T \tag{2.25}$$

式中：$H = \begin{bmatrix} h\left(\omega_1 \cdot x_1 + b_1\right) & \cdots & h\left(\omega_L \cdot x_1 + b_L\right) \\ \vdots & \cdots & \vdots \\ h\left(\omega_1 \cdot x_N + b_1\right) & \cdots & h\left(\omega_L \cdot x_N + b_L\right) \end{bmatrix}_{N\times L}$

其中 H 是隐层节点的输出，β 为输出权重，T 为期望输出。

部分基于梯度下降学习的传统算法在训练网络的过程中需要调整所有参数，而在 ELM 算法中，只要输入权重 W_i 和隐层偏置 b_i 随机确定，通过网络训练，就可以确定隐层的输出矩阵，进而可以确定输出权重 β 。这样，ELM 神经网络的训练过程实际上就是一个求解线性系统（$H\beta = T$）的过程。于是得出：

$$\hat{\beta} = H^{+}T \tag{2.26}$$

式中 H^{+}是矩阵 H 的 Moore-Penrose 广义逆矩阵。

计算得到 β 后，ELM 就完成了网络训练。由式（2.26）可知，ELM 的训练过程实际上是一个线性回归求解过程。

中国知网 https://www.cnki.net

2.3.4 LSTM 神经网络

循环神经网络是用来处理序列数据的，其独特的循环结构具有记忆历史信息的功能，使其在处理先验和前验序列数据时具有独特的优势[68]。在传统神经网络模型中，输入层、隐藏层与输出层之间的连接是完全的，但各层之间的节点之间是无连接的。由于每个隐层都只包含两个神经元，因此它只能以单个模式工作。这就导致它无法很好地进行自学习、自适应性以及容错能力等特性的实现。循环神经网络模型假设一个序列的电流输出不仅与当前输入有关，而且与时序的前一个输出有关，这种思想表现在隐藏层之间的节点连接的神经网络结构中，隐藏层输入依赖于输入层的输出和前一个隐藏层的输出，从而基本形成了历史信息的存储结构。经典的 RNN 结构模型及其模式展开如图 2.6 所示：

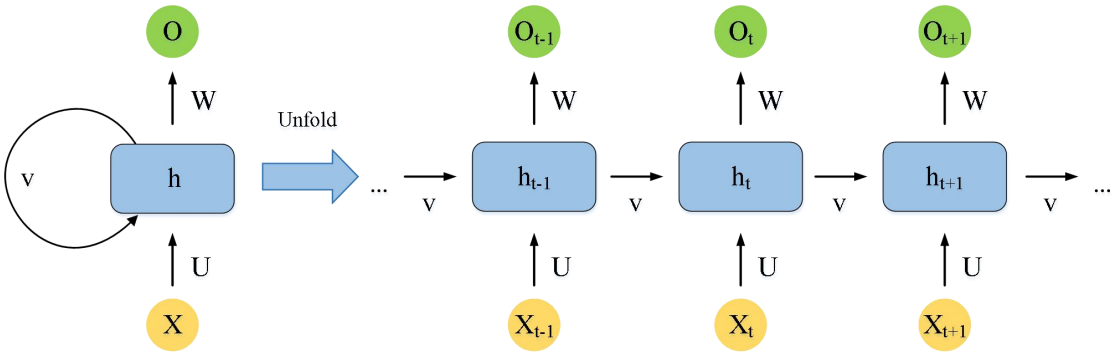


图 2.6 RNN 结构示意图

在图中 x_t 是 t 时刻的输入向量。S_t 是 t 时刻的隐状态，由上一时刻的隐状态和当前输入得到，计算公式见公式（2.26）：

$$S_t = f\left(Ux_t + WS_{t-1}\right) \tag{2.27}$$

一般来说在计算 S_0 时，需要用到 S_{-1}，但是其并不存在，在实现中一般置为 0。O_t 表示 t 时刻的输出向量，计算公式见公式（2.28）：

$$O_t = g\left(S_t V\right) \tag{2.28}$$

U 代表从输入层到隐藏层的权值矩阵，通过这个参数将初始输入抽象成隐藏层的输入。W 代表隐藏层之间的权值矩阵，代表记忆控制。V 是从隐藏层到输出层的权值矩阵，通过这个参数将隐藏层的输出抽象成最终的网络输出。该过程满足了深度学习算法的核心思想：逐级抽象、提取特征、回归。在这一思路下，本文提出了基于循环神经网络模型的遥感影像分类方法。值得注意的是，传统神经网络隐藏层之间的参数是独立的，而循环神经网络隐藏层之间的参数是共享的，

中国知网 https://www.cnki.net

如（V、W、T），g 和 f 分别代表 tanh 、sigmoid 等激活函数。循环神经网络的参数迭代优化采用反向时间传播算法（BPTT），求出误差函数 E 对神经元 j 输入的偏导数，从而借用随机梯度下降算法来更新神经元权重。

利用 RNN 神经网络对 LSTM 神经元网络进行了改进[69]。它利用了数据本身所具有的时序特性以及空间关系，并将这些特征结合到一起形成新的网络。这种方法被广泛应用于生物信息学、信号处理等领域。RNN 中的特殊结构允许从序列中提取和存储上下文信息，以便在随后的计算中引用，从而对这种历史记忆信息做出更准确的推断。然而，传统的 RNN 在实际的时间序列建模中存在一个严重的问题，即梯度消失和梯度爆炸给 RNN 模型的有效训练带来了很大的困难。

为了解决由于信息之间的依赖关系时间跨度过长造成的梯度消失或梯度爆炸问题。LSTM 神经网络引入了输入门，输出门，以及隐藏层之间的遗忘门，能更好地协调历史记忆单元中的信息分配，比 RNN 更具协调记忆的能力，其突出的特点是可以学习时间序列的长期依赖信息[70]。

LSTM 的网络结构与普通前馈神经网络的结构类似，也由输入层、隐藏层和输出层这三层结构构建，但是具有更复杂的结构，如图 2.7 所示。LSTM 网络模型中，隐藏层增加了一个状态 c，称为细胞状态(Cell State)，用于保存长期状态。

细胞状态实现长期状态的保存是通过遗忘门(Forget Gate)、输入门(Input Gate)、输出门(Output Gate)这三种特殊结构实现的，三个门限结构相当于三个阀门，可以通过对隐藏层输入输出的递归调整实现信息的长期保存。

LSTM 的基本单元包括三个控制门和一个记忆细胞单元 cell。三个控制门分别是遗忘门、输入门、输出门。假设 h_{t-1} 代表上一时刻的输出，X_t 代表当前 t 时刻的输入向量，W_i、W_o、W_c、W_f 分别为输入门、输出门、cell 和遗忘门在作用当前输入向量的权值矩阵，U_i、U_o、U_c、U_f 分别带包作用在上一输出序列上的权值矩阵，b_f、b_i、b_c、b_o 为相应的偏置向量。LSTM 进行状态更新和输出信息的过程如下：首先输入门根据输入和上一时刻输出进行状态的更新，遗忘门控制保留有用历史信息的比例，Cell 单元根据当前输入、上一时刻输出、历史记忆信息 C_{t-1} 对 cell 状态进行更新，最后在输出门的控制之下，输出当前时刻的信息 h_t，计算过程见公式(2.29)至(2.34)：

$$i_t = \sigma\left(W_i * x_t + U_i * h_{t-1} + b_i\right) \tag{2.29}$$

$$f_t = \sigma\left(W_f * x_t + U_f * h_{t-1} + b_f\right) \tag{2.30}$$

$$\tilde{C}_t = \tanh\left(W_C * x_t + U_C * h_{t-1} + b_c\right) \tag{2.31}$$

中国知网 https://www.cnki.net

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \tag{2.32}$$

$$o_t = \sigma\left(W_o * x_t + U_o * h_{t-1} + b_o\right) \tag{2.33}$$

$$h_t = o_t * \tanh\left(C_t\right) \tag{2.34}$$

其中 i_t、f_t、C_t、o_t 分别为输入门、输出门、cell 和输出门在 t 时刻的状态，σ 和 tanh 分别为 sigmoid、tanh 激活函数。在处理内存更新的过程中，LSTM 神经网络将历史内存添加到新的信息中。如果遗忘门状态不是为 0，以前进入 cell 单元的历史内存将永远存在。在“记忆”功能结构设计方面的先进性，使得 LSTM 模型相比传统 RNN 拥有更强的信息选择能力和时间序列的学习能力。

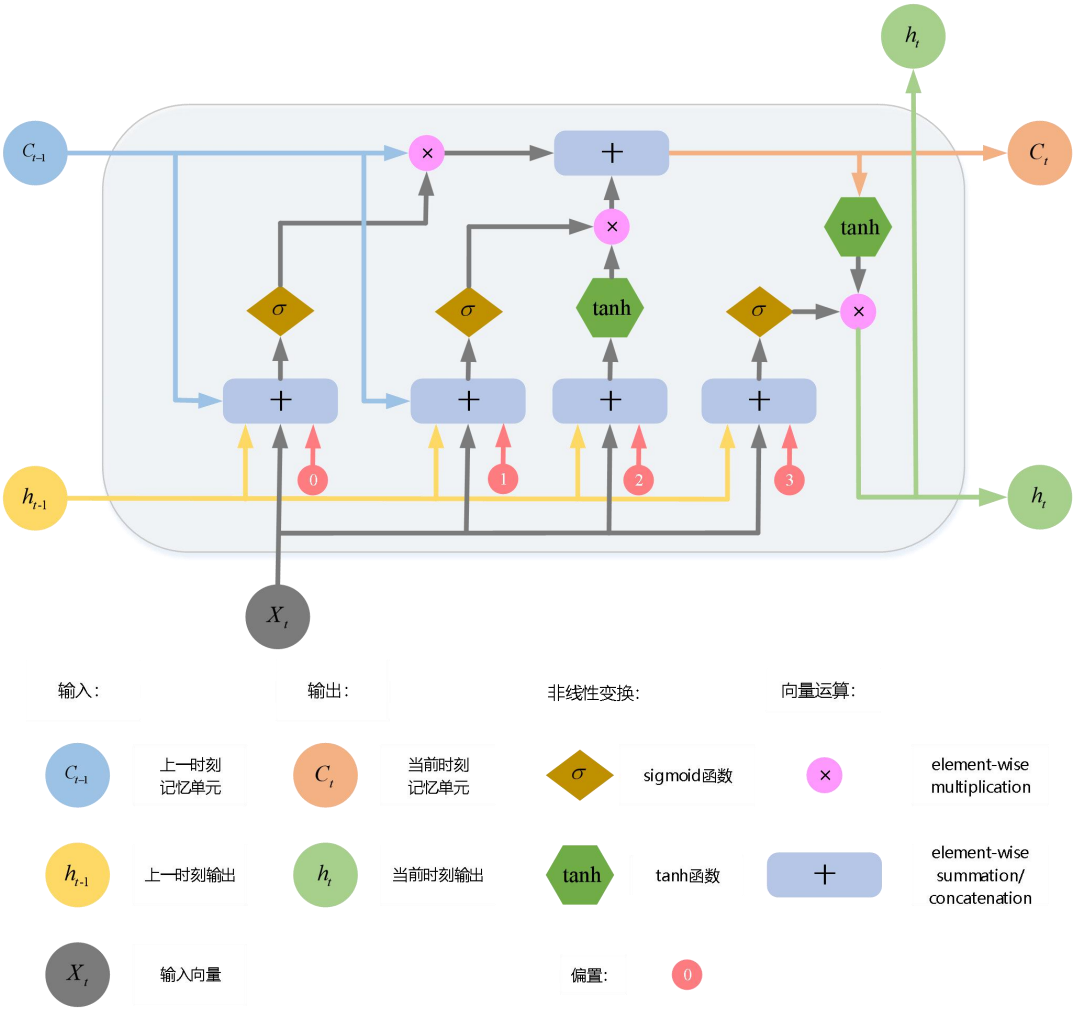


图 2.7 LSTM 结构示意图

中国知网 https://www.cnki.net

2.3.5 模型对比

各预测模型优缺点对比如表 2.1 所示。

表 2. 1 各预测模型优缺点对比

预测模型	优点	缺点
BP	BP 神经网络能学习和存贮大量的输入-输出模式映射关系，其突出优点就是具有很强的非线性映射能力和柔性的网络结构。	BP 算法学习过程收敛速度慢，网络训练失败的可能性较大。
SVM	可以利用核函数学习高维空间的非线性映射，泛化错误率低，具有良好的学习能力，能够解决小样本情况下的机器学习问题。	SVM 算法对大规模训练样本难以实施，参数选择依赖于经验，对核函数选择敏感。
ELM	具有符合训练速度快、结果精确度高等优点。	适用于结构简单的问题学习速率慢，效果提升不明显。
LSTM	具有长期记忆功能，主要其采用门机制学习时间依赖关系，能够一定程度上解决梯度爆炸，梯度消失问题。	该模型在很大程度上取决于逐步的预测，参数较多，需要大量数据才能对其进行正确训练。

2.4 本章小结

本章主要对课题研究中涉及的理论基础知识进行概述。具体分为三个小节进行阐述。

首先第一节对迁移学习相关的概念和理论进行了介绍，包括迁移学习的定义和类型，并说明了本文迁移学习研究的具体类型，以及不可避免的负迁移问题。

然后在第二节对机器学习中常见的领域间相似性度量方法进行了介绍，把相似性度量方法归纳为距离度量和相似度度量两类，进一步，分析已有相似性度量相关理论在本文迁移学习研究场景中的适用性，发现与其他常见相似性度量方法相比，最大均值差异 MMD 可以度量分布间的差异，且为非参数化方法，计算简单，符合本文研究目标，可以将其用于领域间相似性度量，为后续相似性度量方法的应用与改进的必要性做理论铺垫。

最后第三节介绍了主流的机器学习预测模型 BP、SVM、ELM 和 LSTM 四种模型的原理和结构，对模型的优缺点进行了对比分析，作为本文实验分析的模型基础。

中国知网 https://www.cnki.net

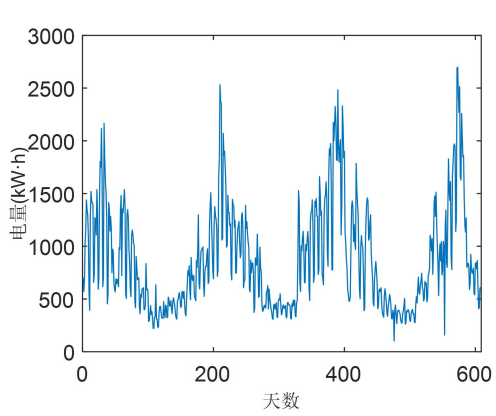
第 3 章 基于数据分布相似性的迁移预测

本章大致包括了如下两个方面的内容：第一部分是 LSTM、BP、SVM、ELM 四种机器学习模型分别对三种用电规模企业进行电量预测，以便于在整体对照上掌握 LSTM 模型在企业电量预测中的性能与效益。第二部分主要为了解决目标域企业样本不足的问题，分析源域和目标域企业领域间的相似性，采用 KL 散度、JS 散度、MMD 距离三种相似性指度量，分别改进 LSTM 模型的损失函数，确定最优的相似性度量，最后通过添加惩罚因子λ，提出了一种基于改进 MMD 的迁移 LSTM 模型。

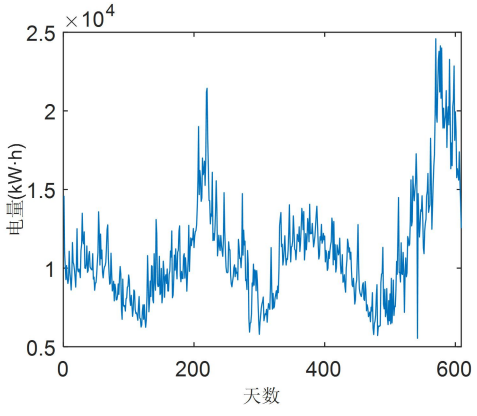
3.1 数据收集

本文数据来自中国江苏省扬中市高新区 1000 多家企业的历史电量数据（https://tianchi.aliyun.com/competition/entrance/231602/information?from=oldUrl），时间选取从 2015 年 1 月 1 日至 2016 年 8 月 31 日共 609 份日用电量记录。将其按平均日用电量的大小把企业分为三大规模：小型用电企业、中型用电企业、大型用电企业。其中当平均日用电量＜5000kW·h 时，划分为小型用电企业；当 5000kW·h≤平均日用电量 50000kW·h 时，划分为中型用电企业；平均日用电量≥50000kW·h 时，划分为大型用电企业。

从每种规模中各选 2 家企业作为实验样本数据，其中一家作为源域企业，其余作为目标域企业，一共选取 6 家企业作为本文实验的数据支撑，如图 3.1 和 3.2 所示。本文所选企业的电量数据较为完整，均采集于真实电力系统运行，具有代表性，符合大多数企业生产用电量规律。

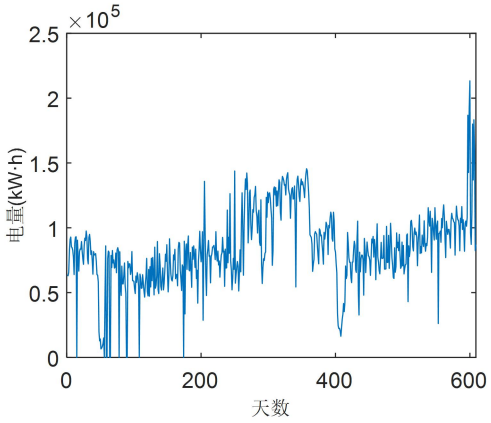


（a）小型企业



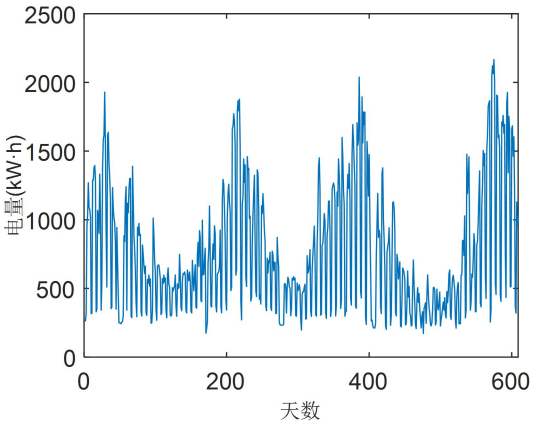
（b）中型企业

中国知网 https://www.cnki.net

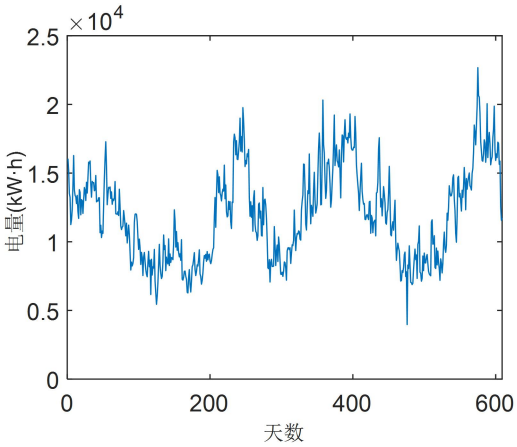


（c）大型企业

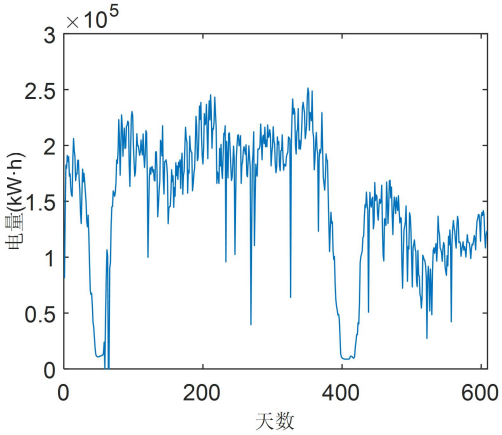
图 3.1 源域企业电量数据



（a）小型企业



（b）中型企业



（c）大型企业

图 3.2 目标域企业电量数据

根据气象研究中经常使用的季节划分方法，以 3 到 5 月为春季，以 6 到 8 月为夏季，以 9 到 11 月为秋季，以 12 月到 2 月为冬季。从图 3.1 至图 3.2 中企业电

中国知网 https://www.cnki.net

量趋势发现，用电量按时间序列既有波动趋势,又存在季节周期性变动。三种不同规模的企业电量数据均存在较为相似的波动规律，其中小型企业电量季节性变动规律最为明显，呈现出夏冬两季高、春秋两季低的特点，这也是企业电量数据的总体变化规律。但由于所划分的三种企业的电量数量级差异较大，平均日用电量越小，更能直观的反映出日用电量变化规律。

表 3.1 各企业样本数据统计学指标

	用电规模	均值	偏度	峰度	ADF 检验
源域	小型企业	879.06	1.06	3.70	-3.60
	中型企业	10986.23	1.38	2.34	-1.73
	大型企业	84152.03	0.06	4.60	-3.10
目标域	小型企业	758.97	0.88	2.82	-5.41
	中型企业	12019.75	0.32	2.34	-1.44
	大型企业	14871.86	-0.77	2.87	-1.78

表 3.1 展示了 6 家企业样本数据的各项统计学指标。由偏度和峰度可以看出，总体数据分布明显不符合正态分布。根据 ADF 检验，5%的显著临界值是-1.94，源域的中型企业的 ADF 检验结果为-1.73 大于 5%的显著临界值，目标域的中型和大型企业的 ADF 检验结果为-1.44 和-1.78 均大于 5%的显著临界值，表明这 3 家企业样本序列是非平稳序列。其中两家大型企业个别样本电量值为 0，表示该企业在此时间段处于停产休息状态，其余四家企业的样本数据均未出现明显异常值，为了确保数据的真实性和实验的科学性，没有对两家大型企业的样本为 0 的值进行替换处理。

为了简化模型的计算，提高数据建模的准确性，本文首先将数据进行 z-score 标准化处理（Zero-mena normalization）。该方法以原始数据的均值和标准差为基础进行数据的标准化，利用标准化后的数据进行数据分析，将数据中不同的变量转换到相同的尺度。对于机器学习算法来说，数据标准化不仅加快了参数优化求解的整个过程，而且削弱了取值大小对建模的影响，同时保留了数据中的信息。通常将其归一化到一个较小的特定区间，如式(3.1)所示：

$$z = \frac{X_i - \mu}{\sigma} \tag{3.1}$$

其中 X_i 是某个数据点，μ 是所有点 X_i 的平均值，σ 是所有点 X_i 的标准差。

中国知网 https://www.cnki.net

3.2 实验环境搭建

Matlab 是一个高级技术计算语言和交互式环境。它具有大量可用于管理应用的数学运算函数，并具有对非线性动态系统进行数值分析、矩阵运算、建模和仿真的能力，为实现用户所需的功能提供了完整的应用。Matlab 中使用的算法具有强大的应用工具箱，并且经过了优化和容错处理，因此使用 Matlab 编程工作不仅在计算问题时方便用户界面，而且使其自然化语言更接近所需的数学表达，从而更加简单和清晰。Matlab 的另一大特点是数据可视化功能方便，便于用图形表示向量和矩阵，并对生成的图形进行标记，这对许多研究科研工作者是十分友好。本文选择将 Matlab 用于数据处理和特征提取，同时运用于图形处理。

在综合考虑实验室条件等各种因素后，本文给出了实验环境的部分硬件和软硬件设置，如表 3.2 所示。

表 3. 2 硬件和软件开发环境

硬件	配置或安装信息
处理器	Intel(R) Core(TM) i5-8265U CPU @1.60GHZ
内存	8.0 GB RAM
操作系统	Windows 10 专业版 64-bit
编辑环境	Matlab R2019b 版

3.3 评价指标

为了客观地反映模型对不同规模企业电量的预测性能，选取了三种不同的指标进行模型预测性能的评价。包括均方根误差(Root Mean Square Error，RMSE)，平均绝对百分比误差(Mean Absolute Percentage Error，MAPE)和精确度(R-Sqaured，R^2)。这三种指标的计算方式见公式(3-2)至公式(3-4)：

$$RMSE=\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i-\hat{y}_i\right)^2} \tag{3.2}$$

$$MAPE=\frac{1}{n}\sum_{i=1}^{n}\frac{\left|y_i-\hat{y}_i\right|}{\left|y_i\right|} \tag{3.3}$$

$$R^2=1-\frac{\sum_{i}\left(\hat{y}_i-y_i\right)^2}{\sum_{i}\left(\bar{y}_i-y_i\right)^2} \tag{3.4}$$

其中，n 是样本个数，y_i 和 $\hat{y}_i$ 分别是第 i 个样本的预测值和真实值。

RMSE 反映两个值的平方误差，对较大误差敏感，容易放大误差。MAPE 是

中国知网 https://www.cnki.net

误差和真实值之间的比例，是一个相对误差函数。对于小误差，在企业用电较小的区间段可能产生较大的影响；对于大误差，在企业用电较大的区间段可能产生较小的影响。最后利用 R^2 对回归模型系数进行拟合优度，拟合值越高，精度越高。总的来说，这三个指标从不同的角度反映了模型的性能。

3.4 相同用电规模企业预测建模

3.4.1 预测模型参数设计

LSTM 模型解决了 RNN 梯度消失和长期记忆功能缺陷的问题，使循环神经网络能够真正有效地建立长距离时序预测建模。目前 LSTM 模型已成功地应用于自然语言处理相关的建模、音频和视频分析研究等多个时间序列数据处理分析领域，能够准确和有效地预测时间序列。本次研究的流程如图 3.3 所示。

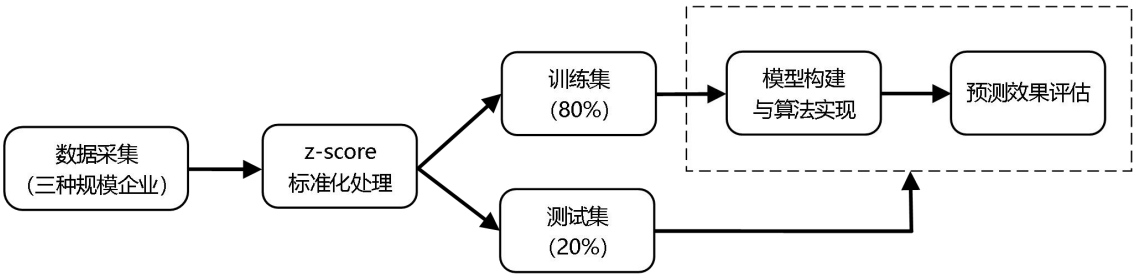


图 3. 3 电量预测流程图

LSTM 神经网络的参数设置主要由输入序列长度、节点数、学习率、优化器和初始化方式组成。本文所使用的 LSTM 神经网络共分四个层次，包含 1 层输入层，1 层隐藏层，1 层全连接输出层和 1 层回归输出层。设置记忆单元个数为 120～170，迭代次数设置为 150～250，选取 sigmod 函数来控制遗忘门、输入门、和输出门，以 tanh 函数作为激活函数。LSTM 网络一次进行一个时间步长的预测，在每个时间步，网络使用该时间步的值进行预测，并且只计算前一个时间步的网络状态，并且网络在每个预测之间更新它的状态。为了提高预测精度，采用了动态调整学习速率的方法，并通过对参数的在线优化使网络具有更好的性能。在 LSTM 神经网络中引入 dropout，以减少模型的过拟合，dropout 比率为 0.3。采用深度学习方法的 Adam 优化算法，根据企业用电规模的不同，设定学习率在 0.01-0.1 之间。通常，神经网络的训练需要大量的训练数据，本文将数据集的前 80%样本即 1 到 486 天作为训练集，剩余 20%即 487 到 609 天作为测试集，采用平均绝对误差（mean absolute error，MAE）作为模型的损失函数。根据经验对三种用电规模企业进行相应的参数设定，如表 3.3 所示。

中国知网 https://www.cnki.net

表 3.3 LSTM 建模参数设置

用电规模	参数设置
小型企业	隐藏层节点=150，初始学习率=0.1，迭代次数=150
中型企业	隐藏层节点=120，初始学习率=0.01，迭代次数=250
大型企业	隐藏层节点=100，初始学习率=0.01，迭代次数=250

同时选取其它三种典型的机器学习预测算法进行对比：

（1）BP 神经网络：目前应用最广泛的神经网络模型之一，在网络理论和性能上都已比较成熟。BP 神经网络具有较强的非线性映射能力和灵活的网络结构，网络结构学习和存储大量的输入-输出模式映射关系。但在训练过程中，主要是通过不断调整网络权值以最大限度地适应当前的训练样本，需要手动设置大量的网络训练参数。核心是将网络输出和期望输出之间的误差归结于权值和阈值的“错误”，并通过反向传播将误差“分摊”于各个神经元的权值和阀值。本文所使用的 BP 神经网络，采用动量梯度下降算法训练，其层数为 8 层，隐藏层节点数为 128，激活函数采用 tanh 和 purelin。

（2）SVM 模型：支持向量机是通过最优化方法解决机器学习中的分类和回归问题的工具，常用于求解小样本、非线性和高维模式，具有成熟的理论基础和实际应用范例。优点是泛化错误率低，学习能力强，能够解决小样本情况下的机器学习问题。采用网格遍历法对 SVM 模型进行反复调试和交叉验证，确定了支持 SVM 模型参数的最优组合，包含径向基（Radial Basis Function，RBF）核函数、惩罚系数 C=1 和 epsilon=0.01。

（3）ELM 模型：ELM 是一种新的快速学习算法，对于单隐层神经网络，ELM 可以对输入权重和偏置权值进行随机初始化，并得到相应的输出权重。ELM 分为三层结构，即输入层、隐藏层和输出层。ELM 中的输入层与隐藏层之间的连接权重和隐藏层节点阈值是随机生成的，优点是在训练过程中不需要人工调整，只需要求解输出权重矩阵，不需要重复迭代地调整输入权值和隐藏层偏置，从而计算量和时间复杂度都会小很多，训练速度也能更快。本文的 ELM 模型选用 Radial Basis 激活函数，隐藏层节点数为 5，使用交叉验证训练模型找出较优的神经元连接权值和偏置。

3.4.2 结果与分析

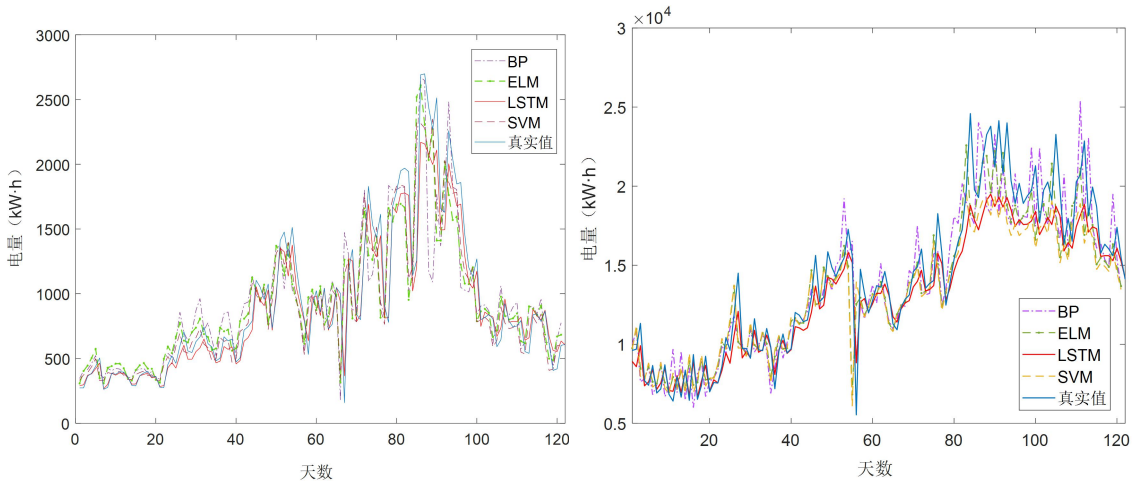
根据本章第 3.2、3.5.1 节内容确定好这四种模型的结构和参数后，着眼于企

中国知网 https://www.cnki.net

业日用电的连续变化，对源域三家企业电量数据分别进行 LSTM、BP、SVM、ELM 建模，对三种相同的规模跨度上的企业电量数据分别进行预测。对比四种模型的电量预测效果，得到的预测曲线如图 3.4 所示。图 3.5 至图 3.7 分别展示了每种用电规模下的电量预测拟合图。

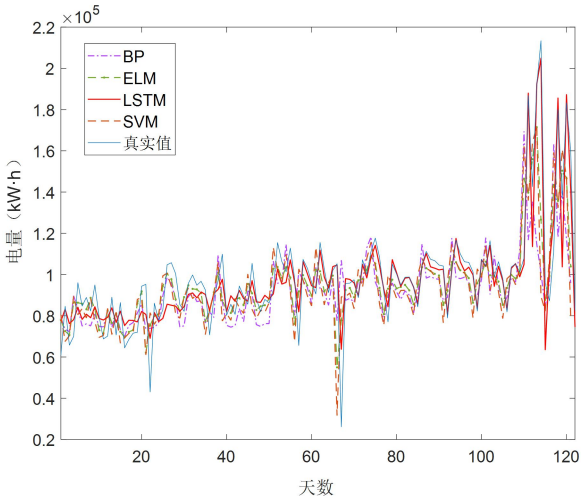
从图 3.4 可以看出，测试集中小型企业日用电在 1 到 60 天和 100 到 120 天时间段波动较小，在 60 到 100 天时间段波动幅度逐渐增大，电量峰值出现在 90 天左右。中型企业与小型企业电量整体趋势相近，但日用电量波动幅度更大。大型企业的日用电量在 1 到 110 天整体波动较小，在 110 天到 120 天存在较大波动。

在相同规模企业的电量预测结果中，对于日用电量总体偏低的小型企业，4 种模型对电量预测趋势近似拟合于实际样本的测试集趋势，在电量峰值处 LSTM 模型与真实值出现一定误差，其余时间段 LSTM 模型拟合程度最高，BP 模型在整个测试集均存在过拟合现象。对于中型企业，整体来看 LSTM 模型效果最好，但在 80 到 120 天电量波动较大对 LSTM 模型有一定误差。对于日用电量总体最高的大型企业，随着样本数据数量级的增大，LSTM 相较于其余三种模型表现出优良的稳定性与精确性，预测整体趋势与真实值保持一致。总的来说，LSTM 模型在各种规模企业的电量预测上均取得了较好的效果。



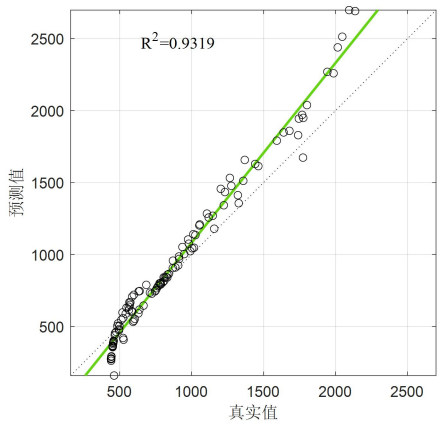
（a）小型企业　　（b）中型企业

中国知网　https://www.cnki.net

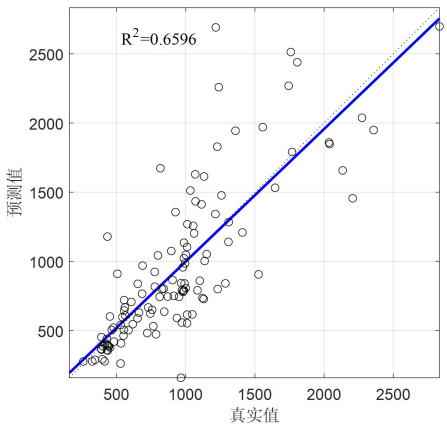


（c）大型企业

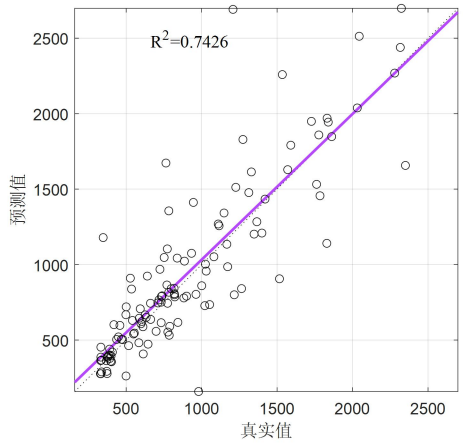
图 3.4 不同模型下的电量预测效果



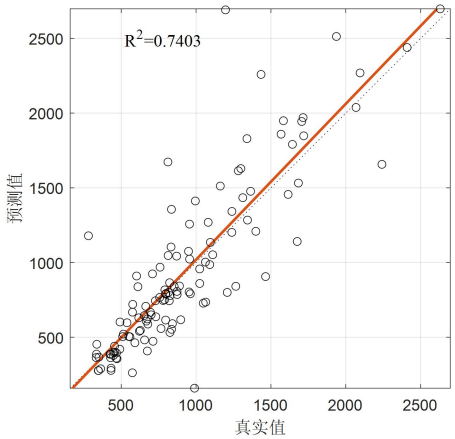
（a）LSTM



（b）BP



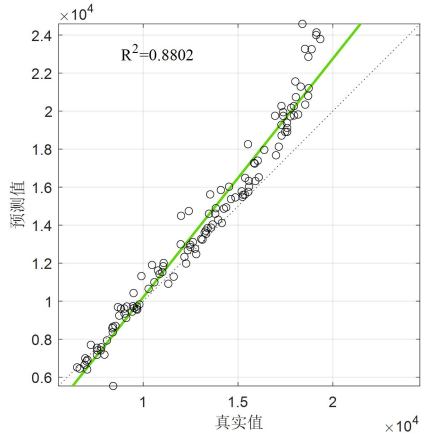
（c）SVM



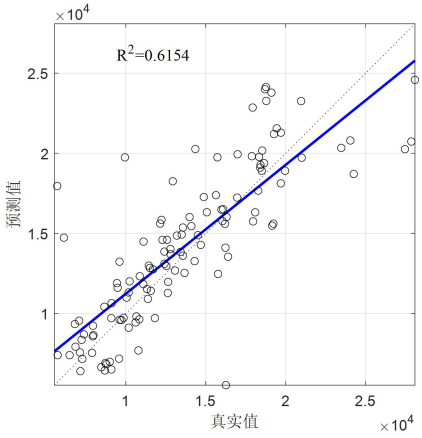
（d）ELM

图 3.5 小型用电企业中不同模型预测拟合曲线图

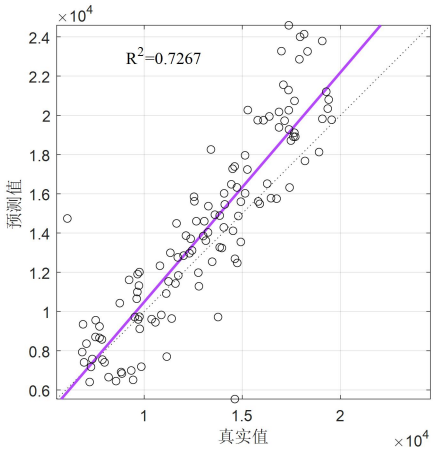
中国知网 https://www.cnki.net



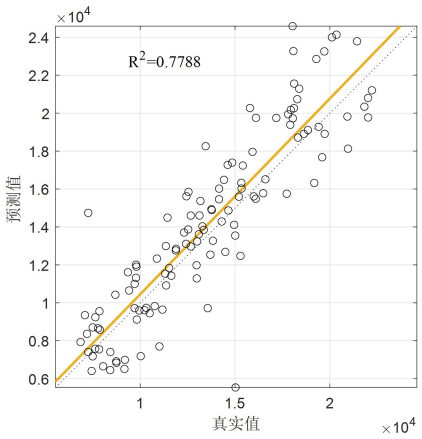
（a）LSTM



（b）BP

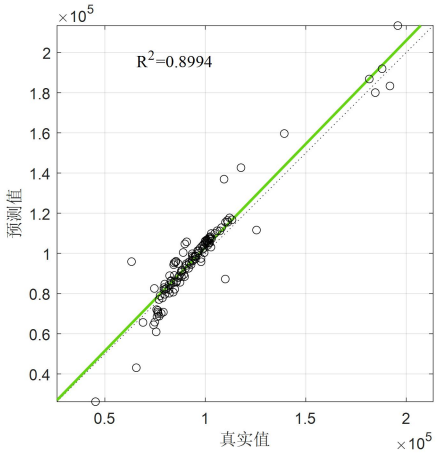


（c）SVM

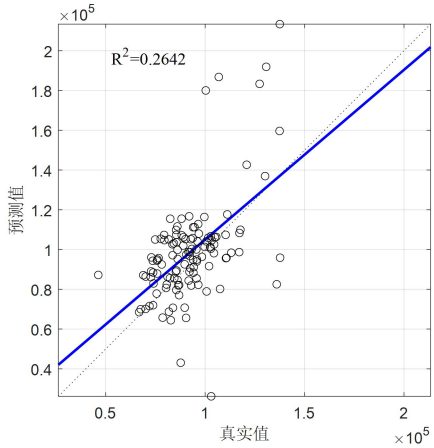


（d）ELM

图 3.6 中型用电企业中不同模型预测拟合曲线图

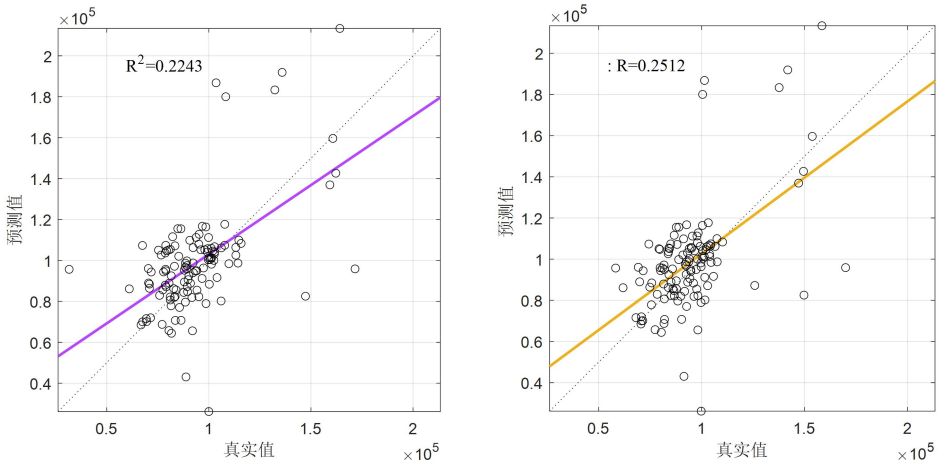


（a）LSTM



（b）BP

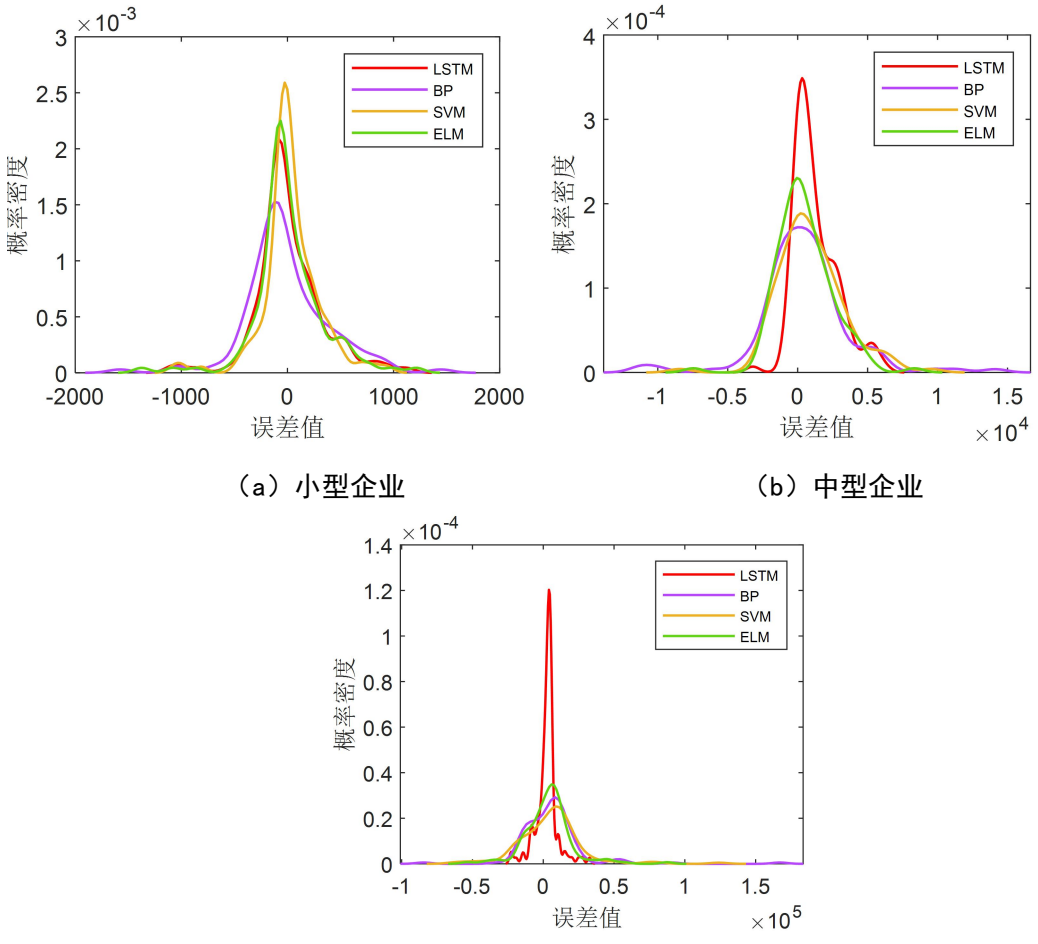
中国知网 https://www.cnki.net



（c）SVM　　（d）ELM

图 3.7 大型用电企业中不同模型预测拟合曲线图

不同预测模型下的预测误差，其分布特征存在较大差异性，下面对三种用电规模企业下的预测误差结果分别进行拟合，可得到更精细的误差特征。对比四种预测模型下的误差分布，结果如图 3.8 所示。



（a）小型企业　　（b）中型企业

（c）大型企业

图 3.8 不同模型下的企业电量预测误差分布

中国知网　https://www.cnki.net

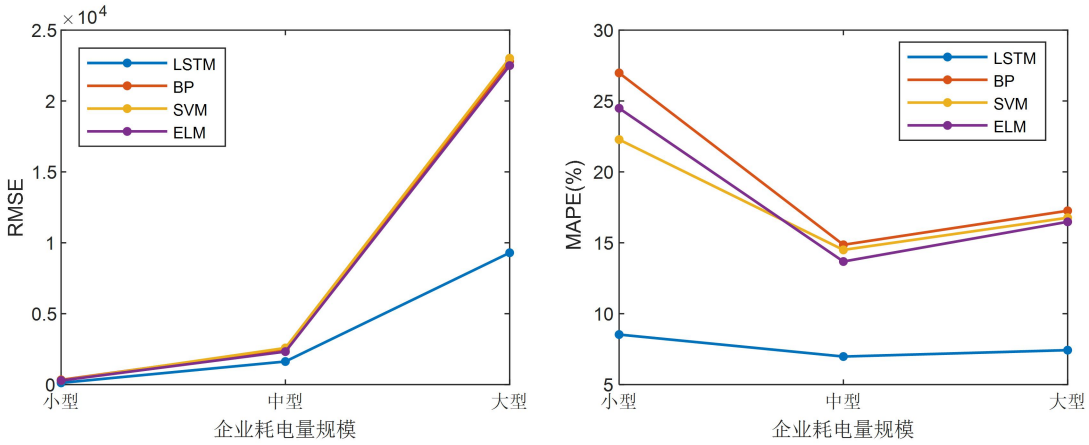
由图 3.6 可看出，三种不同规模企业下的误差分布存在较大差异。对于小型企业，误差值主要集中在[-1000,1000]区段，四种模型的误差数据较集中于 0 附近呈对称分布，误差分布差异较小，其中 SVM 在 0 附近的概率密度最高，其次分别是 ELM、LSTM、BP 模型。对于中型企业，误差值主要集中在[-5000,5000]区段，其中 LSTM 模型的横轴范围最小，在 0 附近峰值最高，此时 LSTM 模型的整体预测误差最小。对于大型企业，误差值主要集中在[-20000,20000]区段，LSTM 模型在 0 附近峰值远高于其余三种模型，此时 LSTM 模型的预测效果远最优。表明随着企业用电规模的增大，LSTM 模型具有稳定的可靠预测精度。

各指标实验结果如表 3.4 所示。从定量数值分析可知，LSTM 模型对三种不同规模企业的各种预测误差指标均优于 BP、SVM、ELM 模型。对于小型企业，LSTM 的 R^2 达到 0.9319，是 BP 模型的 1.4 倍，是 SVM、ELM 模型的 1.3 倍，说明对于用电规模较小的企业，LSTM 模型预测可以得到较优的结果。对于中型企业，LSTM 的预测精确度最高，R^2 达到 0.8802，虽然不及小型企业的预测精度，但仍旧表现出较好的预测结果。对于大型企业，LSTM 的 R^2 到 0.8994，远远高于其余三种预测模型，表现出对各种规模企业的电量预测的高稳定性。通过以上分析，说明了 LSTM 神经网络模型在预测相同用电规模企业电量方面的优势。

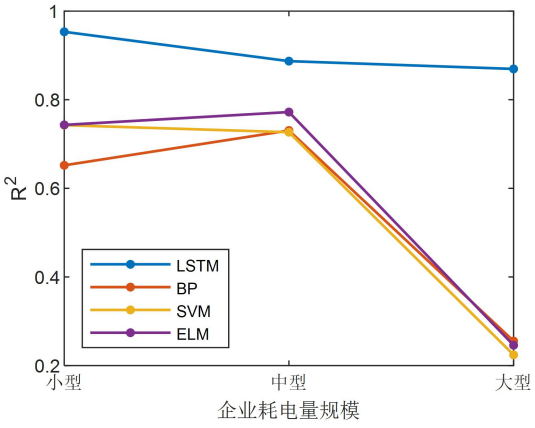
表 3. 4 不同模型的电量预测性能表

用电规模	误差指标	RMSE	MAPE(%)	R^2
小型	LSTM	148.68	14.25	0.9319
	BP	330.57	27.59	0.6596
	SVM	288.02	22.28	0.7426
	ELM	288.86	24.46	0.7403
中型	LSTM	1678.53	6.96	0.8802
	BP	3017.54	15.95	0.6154
	SVM	2584.00	14.50	0.7267
	ELM	2290.41	13.65	0.7788
大型	LSTM	8166.09	6.60	0.8994
	BP	22596.24	16.92	0. 2642
	SVM	23015.81	16.77	0.2243
	ELM	22432.91	16.52	0.2511

中国知网 https://www.cnki.net



（a）RMSE　　（b）MAPE



（c）R^2

图 3.9 不同模型对企业电量的预测性能对比图

为了更加直观的反映 LSTM 模型在预测企业电量中的优良性能，图 3.9 展示了不同预测模型对企业日用电量的评价指标对比，相比其他三种模型，LSTM 模型的在企业电量预测上的 RMSE 和 MAPE 更小，R^2 明显更大。同时随着企业日用电量的增大，BP、SVM、ELM 模型的预测性能逐渐变差，而 LSTM 模型的预测效果相对平稳。

3.5 基于迁移学习的企业电量预测建模

随着智能电网建设的发展，电力系统记录数据的规模和范围不断扩大，但大数据利用率并不高。在企业电量预测过程中，有效利用历史数据、企业电量数据和工作模型参数，可以提高电量预测的效率和绩效。传统的电力企业电量预测主要依靠人工进行，这就造成了大量时间资源的浪费以及预测结果不准确的现象。因此如何高效地对海量历史数据进行处理成为了当前亟待解决的难题之一。在建立企业电量预测模型时，会遇到数据丢失、缺乏新的电网数据、异常故障样本少

中国知网 https://www.cnki.net

等数据采集问题。如果能够利用现有的数据集，为不同的目标企业建立一个通用的模型，将提高网络训练的效率和准确性。迁移学习是机器学习、人工智能等学科交叉发展起来的一种新技术，是解决这一问题的主流机器学习方法，它将知识从以前的任务转移到新的任务上，以便在新的任务中获得更好的学习效果。

但是，很多迁移学习应用并没有考虑数据集之间的相似性。例如，在一个给定样本集中，源数据库中包含许多不同类型的数据表示。这些来源各异的数据表示通常是相互独立的，它们具有相同或相似的结构，这种情况下往往存在正迁移。如果源域数据与目标域数据之间的相关性较小，则可能出现负迁移，即迁移学习具有负迁移效应，这使得我们无法通过一个简单地把两个来源进行比较来获得一致结果。因此在实际情况中，有必要考虑源域与目标域之间的分布距离。

本章第 3.5 节实验结果表明，LSTM 模型由于其独特的记忆和网络结构，在企业电量预测中具有良好的性能，本文将以 LSTM 模型作为企业电量模型进行接下来的研究。如何将数据分布相似性与 LSTM 模型结合，调整网络模型，避免负迁移是本文研究的重点。

3.5.1 基于数据分布相似性的迁移 LSTM 模型

迁移学习是指利用源域的数据或知识来促进目标域的学习，如何对不同类型数据进行有效划分成为了当前研究的热点之一。其中，基于特征相似度的相似性度量方法因其具有较高的准确率而得到广泛关注。

为了解决目标域企业样本不足的问题，同时在保持模型预测精度的基础上，节省模型训练时间。针对基于 LSTM 模型的电力数据网络，参数化度量方法是度量分布间差异的有效指标或方法，在度量前通常需要对分布密度进行估计。然而数据的分布估计需要大量的数据，且估计过程复杂，时间复杂度高，这就大大增加了机器学习模型算法的复杂性。迁移学习场景中的数据通常很稀少，从一个小样本中估计的数据分布泛化性能往往很差。目前 KL 散度和 JS 散度在机器学习中经常被作为损失函数，用于验证拟合分布与真实分布的概率密度相似度，比较自然语言处理问题中的文档相似度，比较推荐系统中的用户相似度等。非参数化度量方法 MMD 不仅可以度量分布间的差异，而且可以便捷地计算分布密度估计。

本文为了验证不同相似性度量指标对企业电量预测的性能影响，将 KL 散度、JS 散度和 MMD 距离作为相似性度量指标，提出一种普适性迁移学习模型来实现相同规模企业的电量迁移预测，最后通过实验比较了上述三种相似度量指标

中国知网 https://www.cnki.net

对电量迁移预测性能的影响。其主要流程图如图 3.10 所示。方法步骤如下：

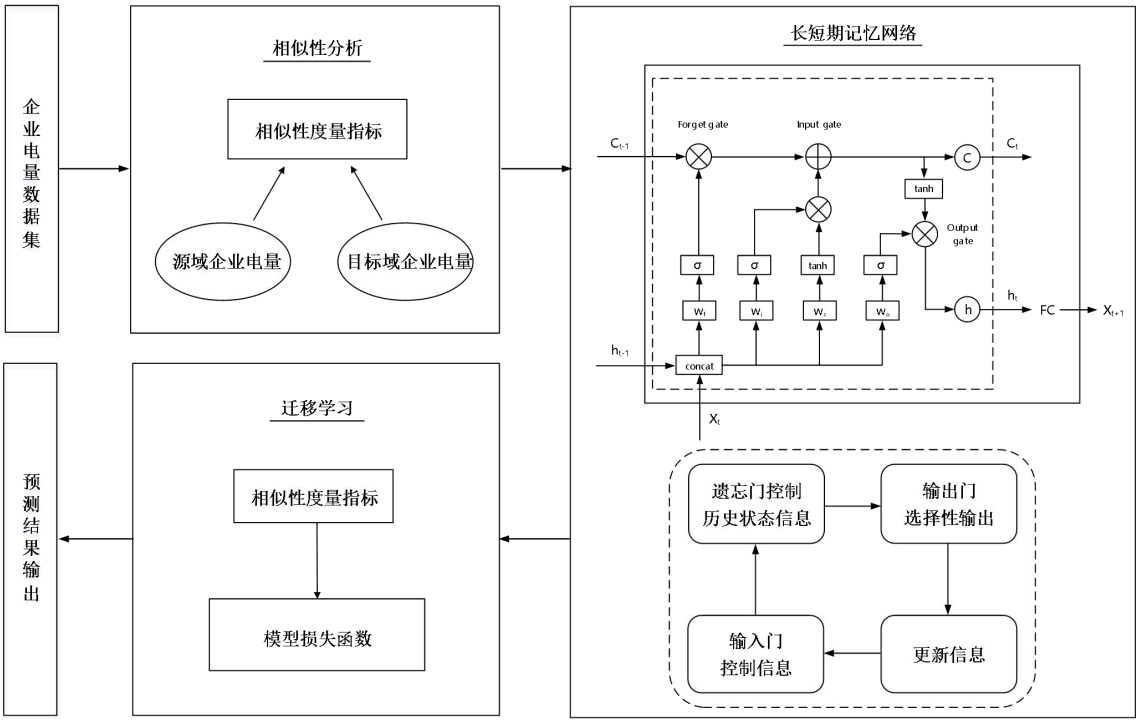


图 3.10 基于迁移 LSTM 模型的电量预测流程图

通过引入三种相似性度量指标，作为判断源域企业和目标域企业电量数据的相似度度量，从而减小训练样本与测试样本在子空间中的分布差异，进行源域和目标域的相似性分析，所述目标域企业为预测用电量的企业。在原始 LSTM 模型损失函数的基础上，加入源域和目标域之间的相似性度量，利用三种度量指标对源领域和目标领域的数据分布差异进行分析，得到分布距离，对模型进行优化，得到的迁移模型损失函数为：

$$J_1 = J_0 + KL = \frac{1}{m}\sum_{i=1}^{m}\left|\left(z_t - y_i\right)\right| + KL \tag{3.5}$$

$$J_2 = J_0 + JS = \frac{1}{m}\sum_{i=1}^{m}\left|\left(z_t - y_i\right)\right| + JS \tag{3.6}$$

$$J_3 = J_0 + MMD = \frac{1}{m}\sum_{i=1}^{m}\left|\left(z_t - y_i\right)\right| + MMD \tag{3.7}$$

J_1、J_2、J_3 分别为加入 KL 散度、JS 散度、MMD 距离的损失函数，m 为训练集样本大小；J_0 为 MAE 函数；y_i 为模型实际输出；z_t 为模型预测值。

中国知网 https://www.cnki.net

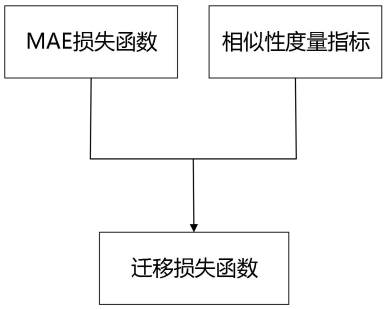


图 3.11 迁移损失函数示意图

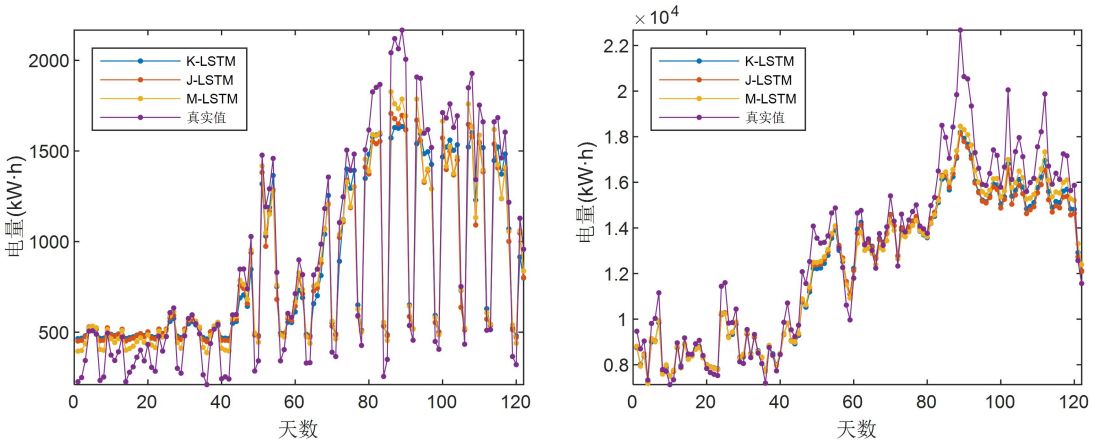
表 3.5 相同规模企业的相似性度量指标

企业	KL	JS	MMD
小型企业	0.0642	0.0153	0.0776
中型企业	0.024	0.0062	0.0608
大型企业	0.1497	0.0335	0.0595

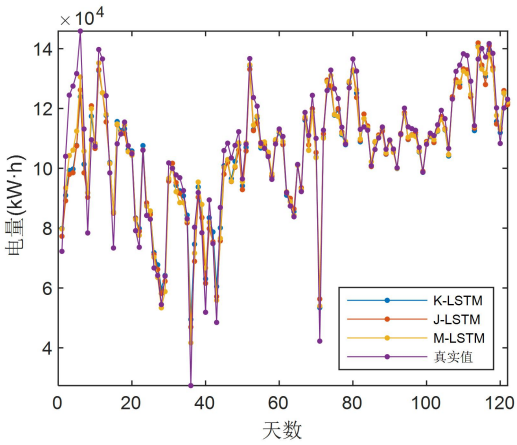
按照本章第 3.2 节所描述的对源域和目标域企业电量数据进行相应的预处理，将源域企业的前 80%样本作为训练集，目标域企业后 20%样本作为测试集。然后利用本章第 3.5 节已有源域企业训练的 LSTM 模型，作为原始模型。分别求出三种企业用电规模下，源域和目标域企业电量数据样本之间的 KL 散度、JS 散度、MMD 距离的值，按式(3.5)至(3.7)改进 LSTM 模型损失函数，实现迁移预测，具体如图 3.11 所示。计算三种规模源域和目标域企业全部样本的每种相似性度量指标，如表 3.5 所示。

记 K-LSTM 为 KL 散度的迁移 LSTM 模型，J-LSTM 为 JS 散度的迁移 LSTM 模型，M-LSTM 为 MMD 距离的迁移 LSTM 模型。三种相似性度量的迁移 LSTM 模型的参数与本章第 3.5 节保持一致。图 3.12 展示了三种不同用电规模企业的预测情况，图 3.13 至图 3.15 展示了每种用电规模下的电量预测拟合图，可以看出基于 MMD 距离的迁移 LSTM 模型的预测结果更加接近真实电量，从而表明 MMD 距离比其余两种度量更能反映企业日用电量数据之间的相似性。

中国知网 https://www.cnki.net

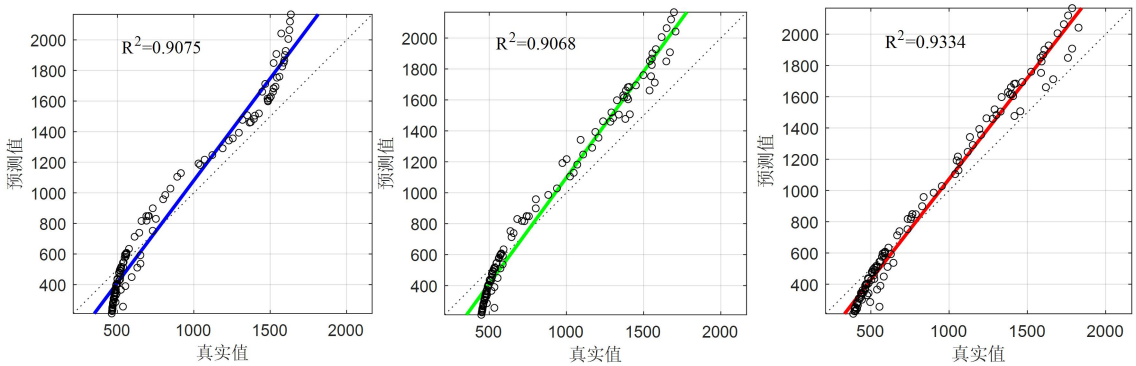


（a）小型企业　　（b）中型企业



（c）大型企业

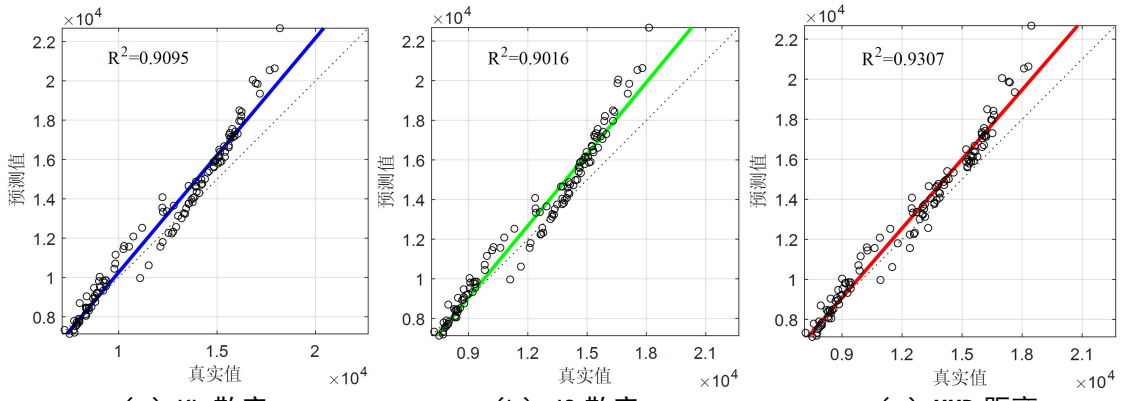
图 3.12 不同相似性度量的迁移模型电量预测图



（a）KL 散度　　（b）JS 散度　　（c）MMD 距离

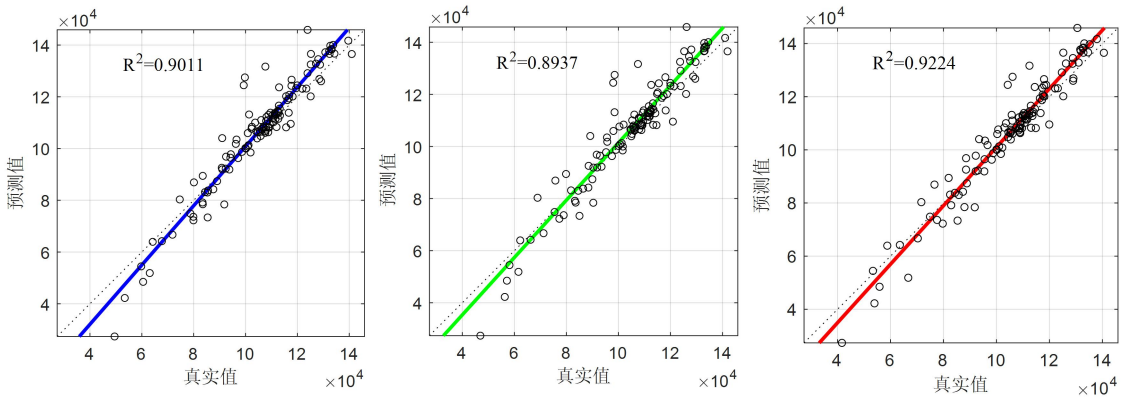
图 3.13 小型企业迁移电量预测拟合曲线图

中国知网 https://www.cnki.net



（a）KL 散度　　（b）JS 散度　　（c）MMD 距离

图 3.14 中型企业迁移电量预测拟合曲线图



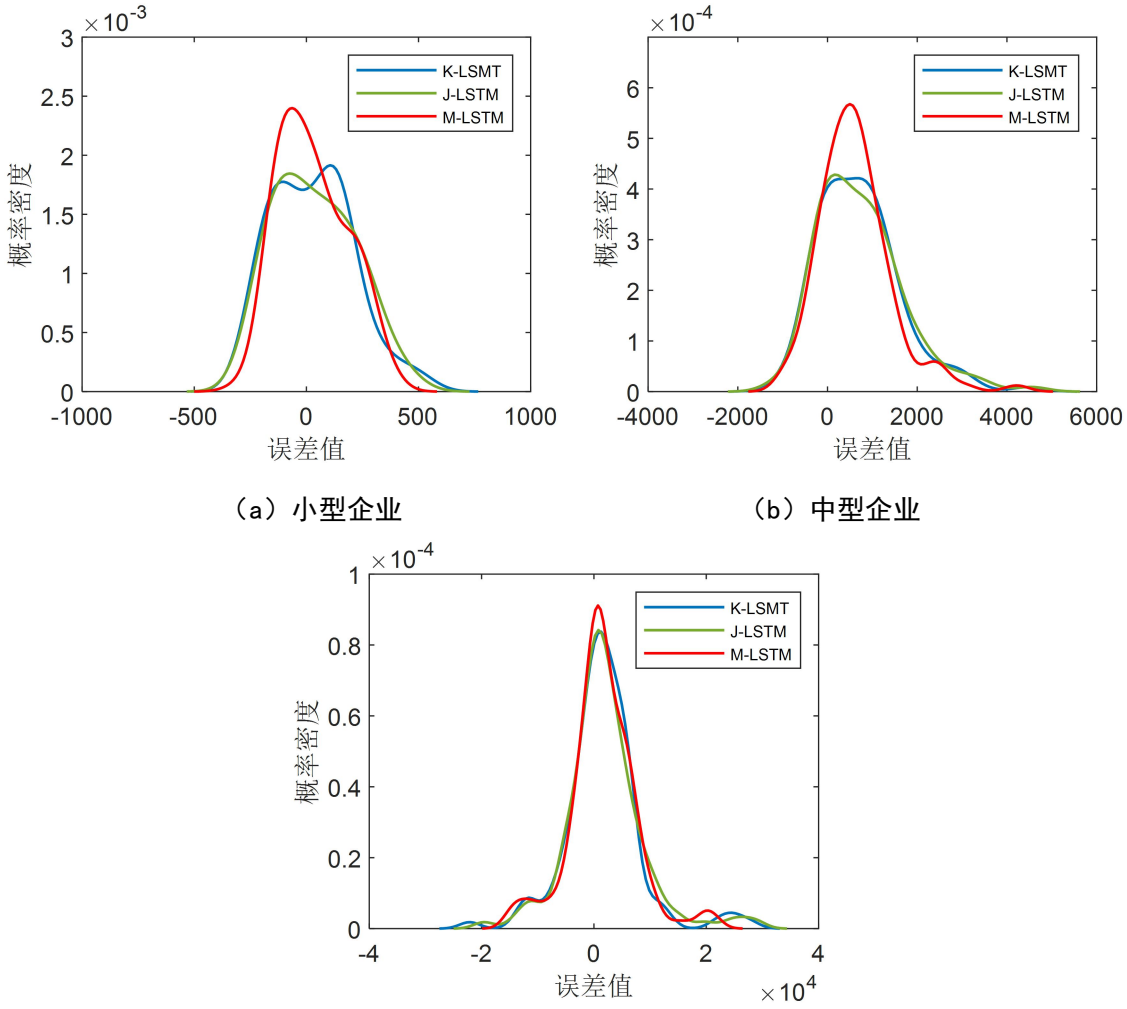
（a）KL 散度　　（b）JS 散度　　（c）MMD 距离

图 3.15 大型企业迁移电量预测拟合曲线图

同时对三种用电规模企业下的预测误差结果进行拟合，比较三种相似性方法下的预测误差分布，如图 3.16 所示。

从图 3.16 可看出，对于小型企业，误差值主要集中在[-500,500]区段，M-LSTM 模型的误差数据较集中于 0 附近呈对称分布，峰值最高，误差分布差异最小。对于中型企业，误差值主要集中在[-2000,2000]区段，其中 M-LSTM 模型在 0 附近峰值最高，此时 M-LSTM 模型整体预测误差最小。对于大型企业，误差值主要集中在[-10000,10000]区段，三种相似性度量下的预测误差分布较为接近，M-LSTM 模型的峰值最高，拟合精度最好。

中国知网　https://www.cnki.net



（a）小型企业　　（b）中型企业

（c）大型企业

图 3.16 不同相似性下的企业电量预测误差分布

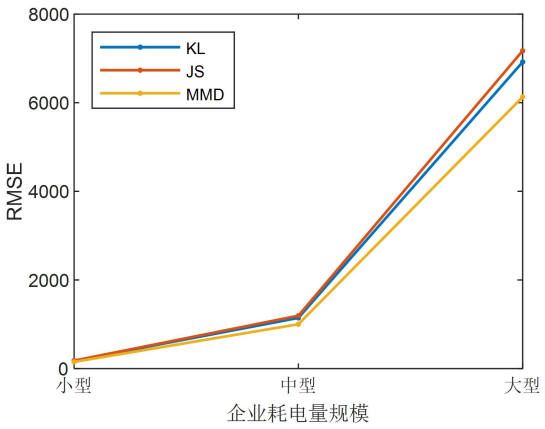
为了避免偶然误差，对每个数据集进行了 10 次重复试验，所得平均值用作相应的结果。表 3.6 和图 3.17 展示了相同规模企业三种相似性度量的迁移 LSTM 模型的预测误差情况。以 R^2 为例，对于小型用电规模的企业，通过 MMD 距离迁移的模型达到了 0.9334，相较于 KL 散度和 JS 散度分别高出 0.0259 和 0.0266，MMD 预测精度最高；对于中型用电规模的企业，采用 MMD 距离的模型达到 0.9307，效果明显优于 KL 散度和 JS 散度的 0.9095 和 0.9016，此时 MMD 的预测效果最好。对于大型用电规模的企业，MMD 距离作为相似性度量的模型达到 0.9224，效果明显优于 KL 散度和 JS 散度的 0.9011 和 0.8937，同样基于 MMD 的迁移 LSTM 模型预测效果最好。

总体结果显示基于 MMD 距离的迁移 LSTM 模型在预测企业电量中的精度最高，体现了 MMD 距离在相同规模企业日用电量预测上的优势。

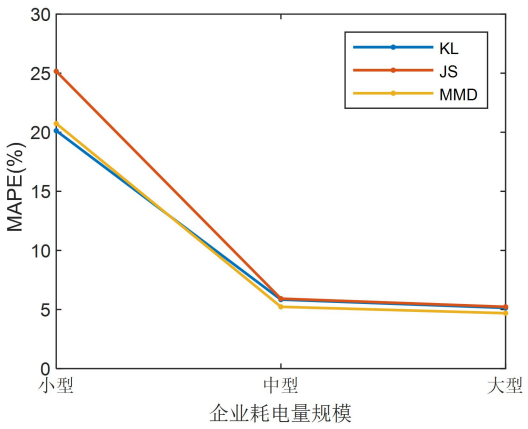
中国知网 https://www.cnki.net

表 3.6 不同相似性度量下迁移预测误差对比

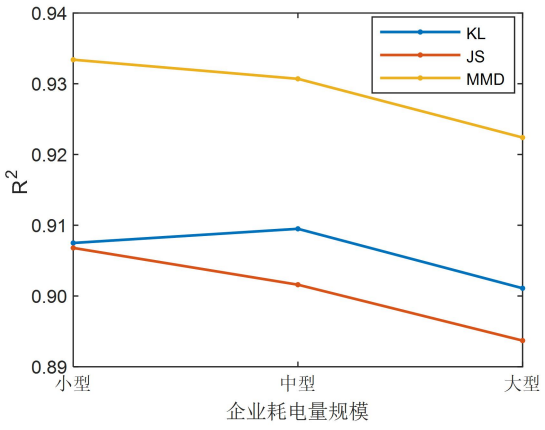
企业	预测模型	RMSE	MAPE(%)	R^2
小型企业	K-LSTM	179.22	20.13	0.9075
	J-LSTM	179.88	25.16	0.9068
	M-LSTM	152.06	20.74	0.9334
中型企业	K-LSTM	1144.59	5.84	0.9095
	J-LSTM	1193.45	5.92	0.9016
	M-LSTM	1001.60	5.23	0.9307
大型企业	K-LSTM	6919.20	5.14	0.9011
	J-LSTM	7172.64	5.23	0.8937
	M-LSTM	6129.19	4.69	0.9224



（a）RMSE



（b）MAPE



（c）R^2

图 3.17 不同相似性度量下迁移模型预测误差对比图

中国知网 https://www.cnki.net

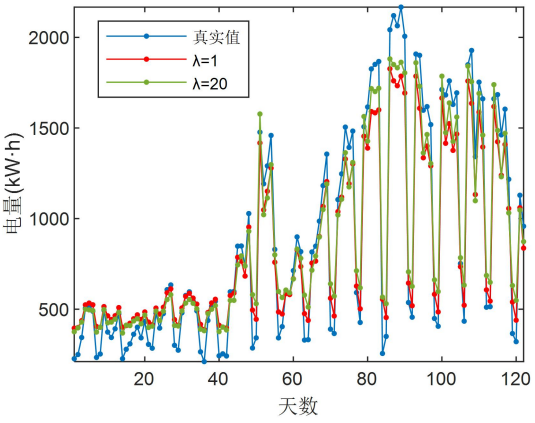
3.5.2 基于改进 MMD 的迁移 LSTM 模型

传统的相似度计算方法大多都没有考虑到特征间存在冗余信息，因此其性能会受到较大影响。着眼于城市电网规划，结合实际电量数据实时更新，当模型训练的数据量较小或者特征过多时，预测结果未必有效，模型的通用性不够，即需要提高泛化能力。根据文献[29]中提出的一种基于最大均值差异的多标记迁移学习算法，对基于 MMD 距离的模型损失函数进行改进，本文提出了一种基于改进 MMD 的迁移 LSTM 模型的电量数据网络建模与预测方法。主要是针对本章第 3.6.1 节中传统 MMD 损失函数存在的不足，在此基础上添加惩罚因子λ，改进模型的损失函数。新的损失函数 J 如式 3.8 所示：

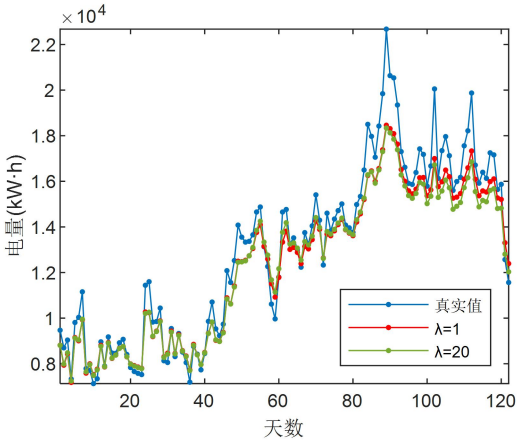
$$J = J_0 + \lambda MMD = \frac{1}{m}\sum_{i=1}^{m}\left|\left(z_t - y_i\right)\right| + \lambda MMD \tag{3.8}$$

其中λ是惩罚因子，权衡 MMD 距离与 MAE 函数的比重，控制全连接层中源领域与目标领域的分布差异。

本节通过我们所选取的 6 家企业电量数据，数据处理方法同本章第 3.6.1 节，然后利用本章第 3.6.1 节训练好的基于 MMD 距离的迁移 LSTM 模型探究参数λ的对模型预测性能的影响。根据文献[29]的经验选取惩罚因子λ=20，得到三种规模企业在参数λ=20 与λ=1 时电量预测图如图 3.18 所示，各种评价指标情况见表 3.7。

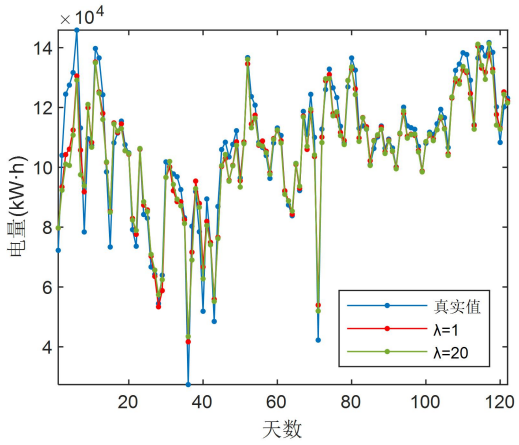


（a）小型用电企业



（b）中型用电企业

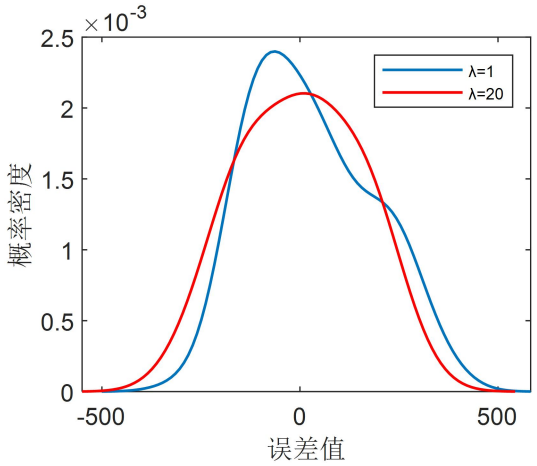
中国知网 https://www.cnki.net



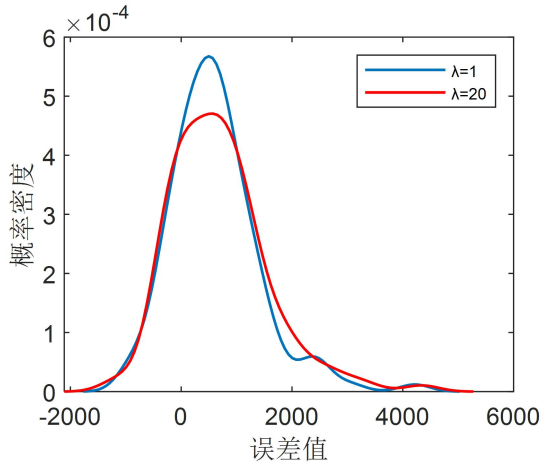
（c）大型用电企业

图 3.18 不同惩罚因子下的迁移电量预测图

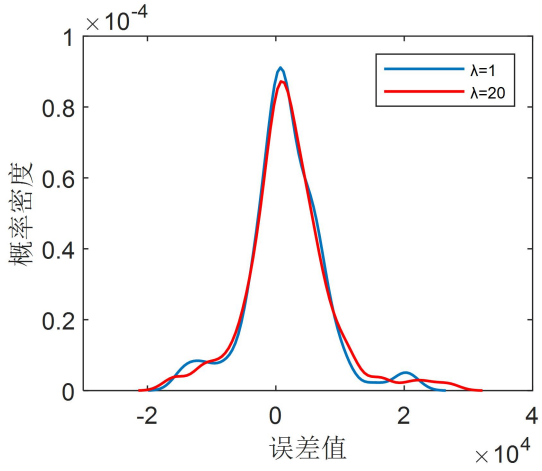
以下对三种用电规模企业下的预测误差结果进行拟合，对比两种惩罚因子的预测误差分布，结果如图 3.19 所示。



（a）小型企业



（b）中型企业

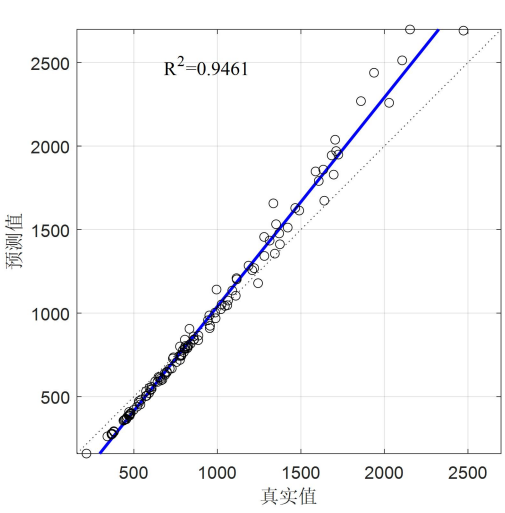


（c）大型企业

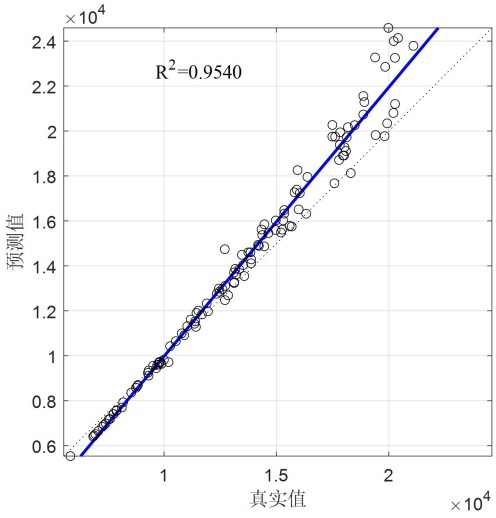
图 3.19 不同惩罚因子下的迁移电量预测误差分布

中国知网 https://www.cnki.net

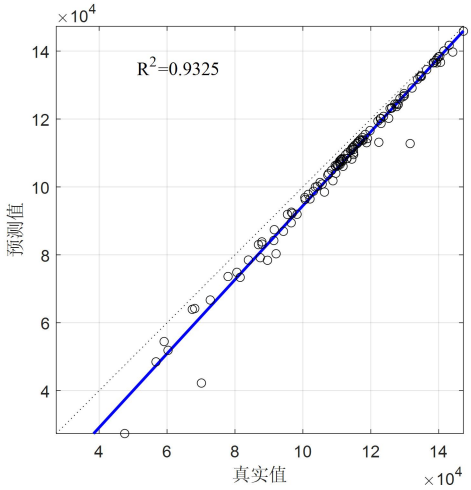
从图 3.19 可得到，对于小型企业，误差值主要集中在[-500,500]区段，惩罚因子λ=20 的误差数据较集中于 0 附近呈对称分布，λ=1 的峰值较高但位于横轴负半轴，此时惩罚因子λ=20 误差分布差异最小。对于中型企业和大型企业，两种惩罚因子下的误差分布曲线较为接近，误差峰值均位于 0 值右边，惩罚因子λ=20 的峰值较低，表明此时预测误差更小，预测效果更优。



（a）小型用电企业



（b）中型用电企业



（c）大型用电企业

图 3. 20 惩罚因子λ=20 时迁移电量预测拟合曲线图

结合图 3.20 和表 3.7 三种规模企业的迁移预测误差表可知，当惩罚因子λ=20 时的三种预测误差指标 RMSE、MAPE、R^2 都明显小于λ=1 时的预测结果。图 3.13(c)、图 3.14(c)、图 3.15(c)和图 3.20 分别是参数λ=20 与λ=1 时三种规模企业的电量拟合曲线图，结合图中对比，可以看出惩罚因子λ=20 时预测拟合度更高。综合以上分析可得，基于 MMD 距离的迁移 LSTM 模型对企业电量的预测效果受惩

中国知网 https://www.cnki.net

罚因子λ的影响，本文将在第四章对惩罚因子λ的影响做进一步探究。

表 3.7 不同惩罚因子的迁移预测指标对比

企业	惩罚因子	RMSE	MAPE(%)	R^2
小型企业	λ=1	152.06	20.74	0.9334
	λ=20	136.84	15.2	0.9461
中型企业	λ=1	1001.60	5.23	0.9307
	λ=20	773.65	4.25	0.9540
大型企业	λ=1	6129.19	4.69	0.9224
	λ=20	5440.50	3.97	0.9325

3.6 本章小结

本章在第二章方法理论的基础上，为体现电量发展的内在特性，采用分企业用电规模的方式进行电量预测。对于日用电量数量级不同的各种企业，搭建了基于 LSTM、BP、SVM、ELM 四种模型对每种规模的企业日用电量进行了预测分析。实证结果表明，LSTM 模型对三种规模的企业电量预测均有着更好的性能。

同时为了解决目标域企业样本不足的问题，通过基于数据分布相似性的迁移学习方法，采用 KL 散度、JS 散度、MMD 距离三种相似性度量改进 LSTM 模型的损失函数，发现基于 MMD 距离的迁移 LSTM 模型在三种规模企业预测中能达到较稳定的高精确度，证明了基于 MMD 距离的迁移 LSTM 模型的运用到企业电量预测的可行性。该方法的优点是仅采用源域 LSTM 网络进行建模，针对多家企业对象上的不同，通过相似性分析评估源域和目标域企业的数据相似度，用最大均值差异 MMD 作为相似度指标，进而可以在源域企业已经训练好的模型的损失函数上，直接加入 MMD 距离，不需要对目标企业再次重新建模，节省了重新建模调参时间。在保持模型预测精度的基础上，节省大量时间、人力成本。最后通过添加惩罚因子λ，改进模型损失函数，提出了一种基于改进 MMD 的迁移 LSTM 模型，进一步提高了模型的预测精度，确定了惩罚因子对模型预测性能的影响。

中国知网 https://www.cnki.net

第 4 章 不同迁移因素的影响研究

第三章提出了一种基于改进 MMD 的迁移 LSTM 模型，在一定程度上解决了样本量不足情况下企业电量的预测，为了进一步提高该模型对不同规模的企业电量预测的可靠性。本章在此基础上，从影响迁移学习的因素入手，探究了三种不同的迁移因素对模型预测性能的影响：第一种是训练样本的数量，通过减少训练样本，分析不同的训练样本数量对迁移预测的影响；第二种惩罚因子λ的大小，改变损失函数中影响 MMD 距离的权重因子，进一步分析其对迁移预测的影响；第三种是季节性 MMD，分析了全年和季节 MMD 距离对数据相似性的影响。

4.1 样本数量对迁移预测的影响

一般来说，随着训练样本的数据量上升，对模型预测能力的要求增加而过拟合的风险降低，神经网络的优势会逐步体现。在训练样本极少的情况下（几百个、几十个甚至几个样本），现有的机器学习和深度学习模型普遍无法取得良好的样本外表现，用小样本训练的模型很容易陷入对小样本的过拟合以及对目标任务的欠拟合，使模型的整体表现较差。

由于某些地区的企业日用电量样本量很少，而样本标注工作会耗费大量时间和人力，本节在第三章提出的基于改进 MMD 的迁移 LSTM 模型的基础上，将源域样本量按照比例进行划分，通过实证分析在训练样本逐渐减少时，迁移 LSTM 模型能否保持良好的预测效果，以及在样本比例达到何种程度时，预测模型的效果开始明显下降。

采用第三章 3.2 节的数据集，前 80%样本即 1 到 486 天作为训练集，剩余 20%即 487 到 609 天作为测试集。将训练集从 100%到 20%以每 10%的样本量递减进行迁移建模，同时用直接对目标域建模的 LSTM 模型进行对比实验，实证研究在不同样本比例下迁移 LSTM 模型和 LSTM 直接预测模型对汇率的预测效果。根据第三章 3.6.2 节的研究分析，选取迁移 LSTM 模型中取惩罚因子λ=1。在神经网络模型的建模方面，本章采用与第三章相同的 LSTM 神经网络结构和参数。

当惩罚因子λ=1 时，不同样本比例下三种相同规模企业的电量预测性能表如表 4.1 至表 4.3 所示：

中国知网 https://www.cnki.net

表 4.1 不同样本比例下小型企业的预测性能表（λ=1）

	LSTM 模型			迁移 LSTM 模型		
训练集样本比例	RMSE	MAPE (%)	R^2	T-RMSE	T-MAPE (%)	T-R^2
100%	123.23	18.72	0.9562	152.06	20.74	0.9334
90%	285.35	31.55	0.7655	170.45	25.26	0.9163
80%	316.41	32.61	0.7116	279.85	34.03	0.7745
70%	399.73	40.47	0.5398	239.17	25.13	0.8352
60%	243.38	34.47	0.8294	238.65	30.36	0.8359
50%	262.23	30.53	0.8019	270.70	29.04	0.7889
40%	238.37	22.55	0.8363	361.89	40.43	0.6228
30%	301.19	39.24	0.7387	371.40	26.20	0.6027
20%	307.89	37.67	0.7270	377.71	50.88	0.5891

表 4.2 不同样本比例下中型企业的预测性能表（λ=1）

	LSTM 模型			迁移 LSTM 模型		
训练集样本比例	RMSE	MAPE (%)	R^2	T-RMSE	T-MAPE (%)	T-R^2
100%	622.67	3.47	0.9732	1001.60	5.23	0.9307
90%	1658.14	7.49	0.8831	1282.01	6.57	0.9301
80%	1660.76	7.50	0.8826	1293.12	6.29	0.9289
70%	2067.76	8.69	0.8181	1251.06	6.28	0.9334
60%	2129.22	9.26	0.8072	1271.66	6.58	0.9312
50%	2272.76	10.29	0.7802	1474.47	7.71	0.9075
40%	5418.91	26.95	-0.2534	2140.69	9.86	0.8051
30%	4710.50	21.03	0.0562	2028.79	9.30	0.8249
20%	6146.28	29.54	-0.6164	3137.47	12.20	0.5813

中国知网 https://www.cnki.net

表 4.3 不同样本比例下大型企业的预测性能表（λ=1）

	LSTM 模型			迁移 LSTM 模型		
训练集样本比例	RMSE	MAPE (%)	R^2	T-RMSE	T-MAPE (%)	T-R^2
100%	5099.84	4.31	0.9463	6129.19	4.69	0.9224
90%	7830.21	6.34	0.8733	10704.81	7.09	0.7633
80%	11534.57	9.98	0.7252	9055.87	7.98	0.8306
70%	16966.40	12.94	0.4055	7877.60	6.90	0.8718
60%	15362.37	11.49	0.5126	21431.95	17.68	0.0553
50%	19152.04	16.94	0.2425	40518.08	33.00	-0.2394
40%	15485.53	14.27	0.5047	26992.99	22.12	-0.0503
30%	30144.95	26.14	-0.8812	51737.45	43.61	-0.4523
20%	27477.52	22.08	-0.5663	28741.82	24.08	-0.7036

当惩罚因子λ=20 时，不同样本比例下三种相同规模企业的电量预测性能表如表 4.4 至表 4.6 所示：

表 4.4 不同样本比例下小型企业的预测性能表（λ=20）

	LSTM 模型			迁移 LSTM 模型		
训练集样本比例	RMSE	MAPE (%)	R^2	T-RMSE	T-MAPE (%)	T-R^2
100%	123.23	18.72	0.9562	136.18	15.2	0.9461
90%	285.35	31.55	0.7655	170.35	20.76	0.9202
80%	316.41	32.61	0.7116	259.84	26.01	0.8487
70%	399.73	40.47	0.5398	277.14	28.58	0.8284
60%	243.38	34.47	0.8294	269.7	32.36	0.7943
50%	262.23	30.53	0.8019	260.34	31.04	0.8189
40%	238.37	22.55	0.8363	298.53	39.64	0.6728
30%	301.19	39.24	0.7387	323.42	41.26	0.6427
20%	307.89	37.67	0.7270	365.25	48.12	0.6191

中国知网 https://www.cnki.net

表 4.5 不同样本比例下中型企业的预测性能表（λ=20）

	LSTM 模型			迁移 LSTM 模型		
训练集样本比例	RMSE	MAPE (%)	R^2	T-RMSE	T-MAPE (%)	T-R^2
100%	622.67	3.47	0.9732	773.65	4.25	0.954
90%	1658.14	7.49	0.8831	1044.31	4.92	0.9413
80%	1660.76	7.50	0.8826	1242.12	5.14	0.9329
70%	2067.76	8.69	0.8181	1328.53	5.64	0.9244
60%	2129.22	9.26	0.8072	1235.11	5.04	0.9342
50%	2272.76	10.29	0.7802	1351.52	6.63	0.9142
40%	5418.91	26.95	-0.2534	1736.34	7.94	0.8551
30%	4710.50	21.03	0.0562	1951.68	8.22	0.8049
20%	6146.28	29.54	-0.6164	2364.31	10.53	0.7113

表 4.6 不同样本比例下大型企业的预测性能表（λ=20）

	LSTM 模型			迁移 LSTM 模型		
训练集样本比例	RMSE	MAPE (%)	R^2	T-RMSE	T-MAPE (%)	T-R^2
100%	5099.84	4.31	0.9463	5440.50	3.97	0.9325
90%	7830.21	6.34	0.8733	7934.85	6.26	0.8845
80%	11534.57	9.98	0.7252	8532.75	7.75	0.8123
70%	16966.40	12.94	0.4055	12536.64	9.35	0.6676
60%	15362.37	11.49	0.5126	14262.7	11.49	0.5475
50%	19152.04	16.94	0.2425	16342.45	12.75	0.4378
40%	15485.53	14.27	0.5047	15452.26	11.42	0.4886
30%	30144.95	26.14	-0.8812	27124.64	28.65	-0.6323
20%	27477.52	22.08	-0.5663	25278.32	20.53	-0.4361

表 4.1 至表 4.6 中各指标形式及含义如表 4.7 性能指标对照表所示。

表 4.7 性能指标对照表

LSTM 模型预测误差指标			迁移 LSTM 模型预测误差指标		
RMSE	MAPE	R^2	T-RMSE	T-MAPE	T-R^2

中国知网 https://www.cnki.net

通过观察基于 MMD 距离的迁移 LSTM 模型与 LSTM 原始模型在三种规模下的各项预测误差可以看出，随着训练集样本比例从 100%逐渐减小，两种模型的预测效果均在逐渐变差。

对于小型用电规模企业，由于日用电量普遍偏小，两种模型的预测精度均较高，以 R^2 为例，在样本比例为 100%，λ=1 和λ=20 时，迁移 LSTM 模型的 R^2 的为 0.9334 和 0.9461，相比于原始 LSTM 模型的 R^2 低了 0.0228 和 0.0101。在样本比例从 90%递减到 60%时，迁移 LSTM 模型比原始 LSTM 模型的 R^2 高。表明此时迁移 LSTM 模型的预测效果好于原始 LSTM 模型。但当样本比例减少到 50%以下时，模型的预测效果均较差，此时无法实现企业电量的准确预测。

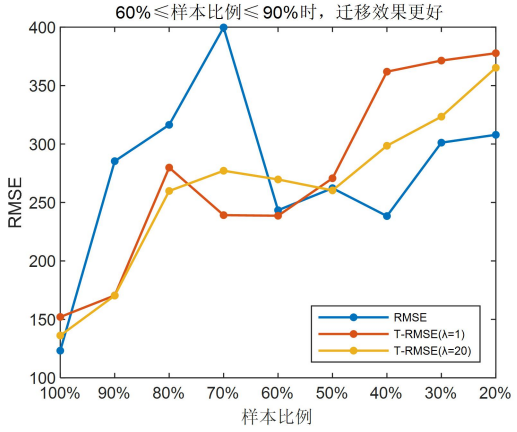
对于中型用电规模企业，两种模型的预测精度也普遍偏高，以 R^2 为例，在样本比例为 100%，λ=1 和λ=20 时，迁移 LSTM 模型相比于原始 LSTM 模型的 R^2 低了 0.0425 和 0.0192。在样本比例从 90%递减到 20%时，迁移 LSTM 模型均比原始 LSTM 模型的 R^2 要高，其中在样本比例从 90%递减到 50%时，迁移 LSTM 模型的 R^2 均保持在 0.9 以上，表明此时迁移 LSTM 模型的预测效果好于原始 LSTM 模型。当样本比例减少到 50%以下时，原始 LSTM 模型基本无法进行预测，迁移 LSTM 模型预测效果较差。

对于大型用电规模企业，两种模型的预测精度没有对以上两种规模企业的高，以 R^2 为例，在样本比例为 100%，λ=1 和λ=20 时，迁移 LSTM 模型相比于原始 LSTM 模型的 R^2 分别低了 0.0239 和 0.0138。在样本比例为 80%和 70%时，迁移 LSTM 模型均比原始 LSTM 模型的 R^2 更高，当样本比例为 70%时 R^2 差值高达 0.4663，在此情况下迁移 LSTM 模型的预测效果远优于原始 LSTM 模型。当样本比例减少到 60%以下时，大型规模企业的电量波动幅度较大，此时两种模型均无法有效用于电量预测。

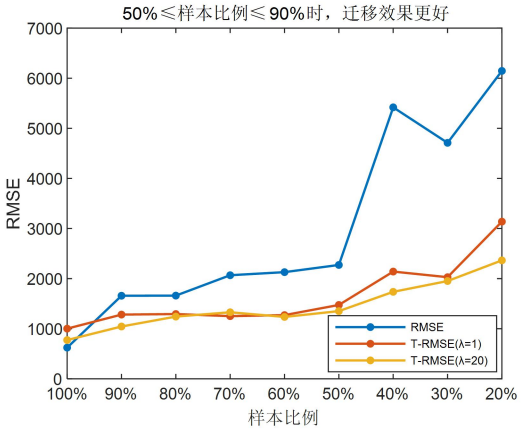
为了能够更直观的反映出迁移 LSTM 模型与 LSTM 模型在不同样本比例下对同等规模企业电量预测的差异，图 4.1 至图 4.3 分别展示了不同样本比例下三种规模企业预测指标 RMSE、MAPE、R^2 对比图，可以看出随着样本比例的逐渐减小，两种模型的预测效果确实有所减弱，在样本比例大于 90%时，基于 MMD 距离的迁移 LSTM 模型的预测误差大于 LSTM 直接预测的误差，随着样本比例的进一步减小，LSTM 直接预测模型的预测精度显著减小，而迁移 LSTM 模型则保持相对平稳。在样本比例为 80%和 70%时，迁移 LSTM 模型的预测误差均小于 LSTM 直接预测的误差，这一点在三种规模的企业上均有所体现。在样本比例低

中国知网 https://www.cnki.net

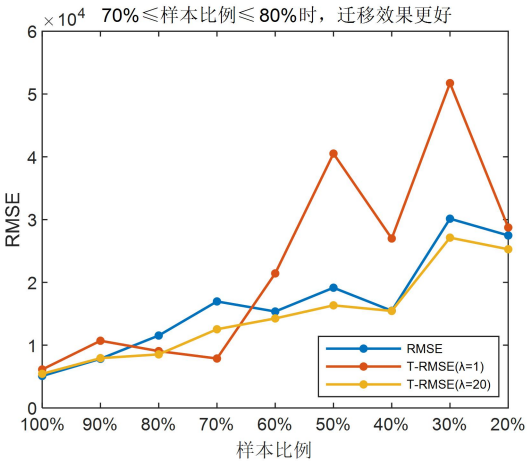
于 50%时，两种模型对三种规模企业的预测效果均较差，此时无法实现企业电量的准确预测。



（a）小型企业

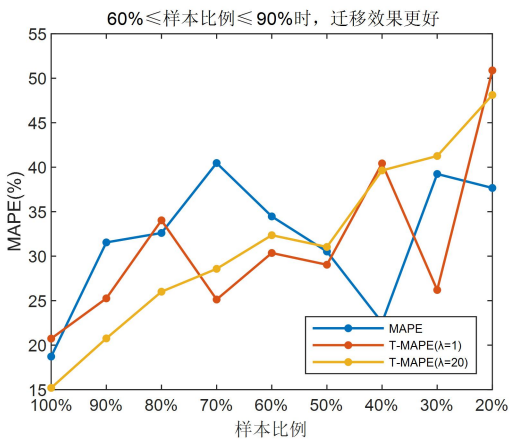


（b）中型企业

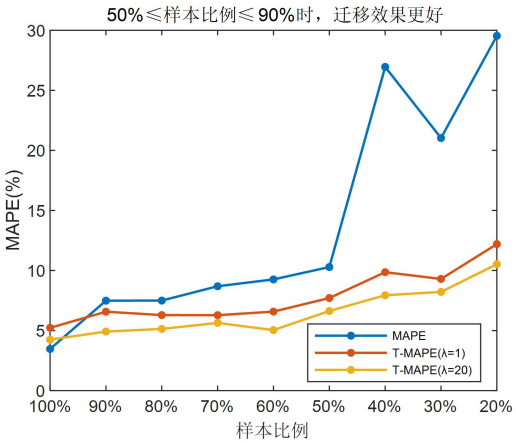


（c）大型企业

图 4.1 不同样本比例下三种规模企业预测 RMSE 对比图

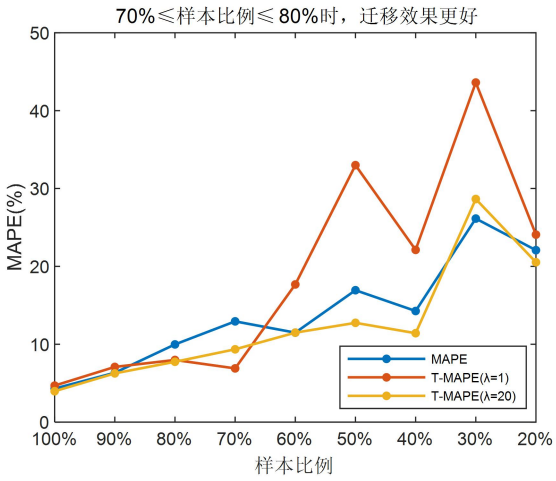


（a）小型企业



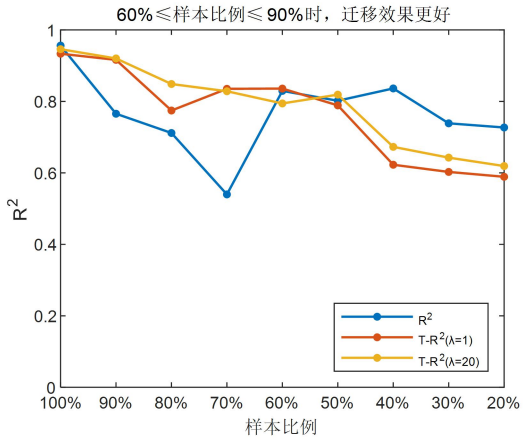
（b）中型企业

中国知网 https://www.cnki.net

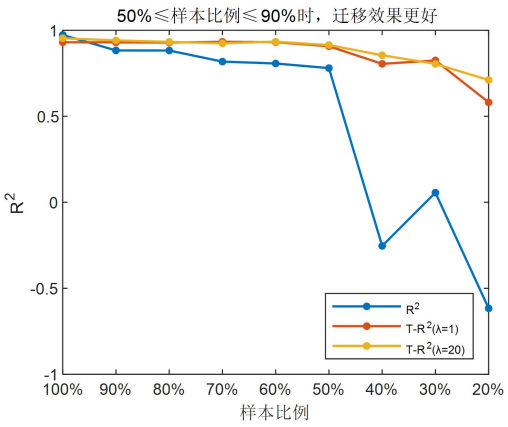


（c）大型企业

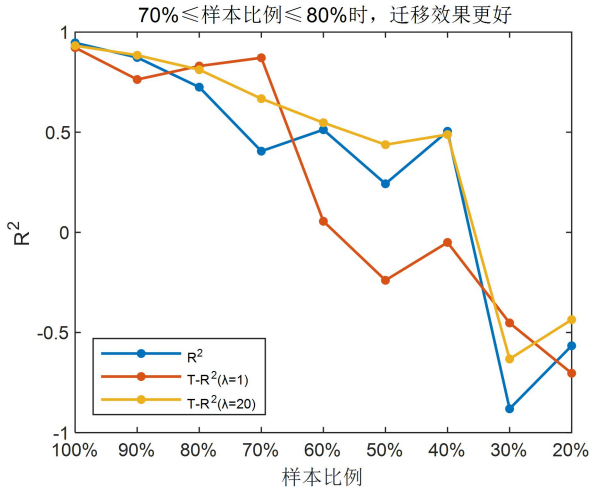
图 4.2 不同样本比例下三种规模企业预测 MAPE 对比图



（a）小型企业



（b）中型企业



（c）大型企业

图 4.3 不同样本比例下三种规模企业预测 R^2 对比图

中国知网 https://www.cnki.net

综合以上分析，针对不同用电规模的企业：（1）对于小型用电企业，样本比例在 60%到 90%之间时，基于 MMD 距离的迁移 LSTM 模型预测效果更好；（2）对于中型用电企业，样本比例在 50%到 90%之间时，迁移 LSTM 模型预测效果较好；（3）对于大型用电企业，样本比例在 70%到 80%之间时，迁移 LSTM 模型预测效果更优。因此能够得出结论，在训练集样本比例较少的环境下，迁移学习确实有助于提升 LSTM 在样本比例不足时的对企业电量的预测性能，并且可以减少样本的采集工作和解决样本集不足的问题。

4.2 惩罚因子对迁移预测的影响

迁移预测效果的影响，可以加入权重衰减（weight decay）来修改训练标准。惩罚因子λ用于权衡 MMD 距离与原始函数的比重，起到防止模型过拟合和提高模型泛化性的作用。

本节在第三章 3.6.2 节的基础上，进一步研究基于 MMD 距离的迁移 LSTM 模型中权重因子λ对相同规模企业电量预测的影响。本章第 4.1 节实证结果表明，在训练集样本逐渐减少的情况下，迁移学习能够提升 LSTM 在样本比例不足时的对企业电量的预测性能，但在样本数量最多时，迁移 LSTM 的预测效果最好，因此在本节中采用第三章 3.2 节的数据集，以训练集全部样本时作为训练集，即前 80%数据作为训练集，剩余 20%作为测试集，利用测试数据衡量不同惩罚因子λ下迁移模型的预测误差。同时基于本章第 4.2 节，采用全年 MMD 距离作为相似性度量。为了讨论权重因子λ对迁移 LSTM 模型预测效果的影响，本次实验令λ的取值以 5 为步长逐步增加到 50，并单独添加λ=1 的情况。

表 4.8 至表 4.10 展示了小型、中型、大型三种用电规模企业的预测性能的指标对比，通过观察基于全年 MMD 的迁移 LSTM 模型与 LSTM 直接预测模型在三种规模下的各项预测误差可以看出，随着权重因子从 1 到 50 不断增大，RMSE 和 MAPE 总体呈现先减小后增大的趋势，R^2 始终呈现出现增大后减小的趋势，表明该迁移 LSTM 模型的预测效果先增大后减小，存在一个峰值。以 R^2 为例：对于小型用电企业，当λ为 35 时，R^2 取得最大值为 0.9740；对于中型用电企业，当λ为 30 时，R^2 取得最大值为 0.9672；对于大型用电企业，当λ为 30 时，R^2 取得最大值为 0.9325，表明惩罚因子的改变对基于全年 MMD 的迁移 LSTM 模型的预测性能有较大影响。

中国知网 https://www.cnki.net

表 4.8 不同惩罚因子下小型企业的预测性能表

λ	T-RMSE	T-MAPE(%)	T-R^2
1	152.06	20.74	0.9334
5	163.45	20.37	0.9230
10	152.21	14.90	0.9332
15	140.51	19.71	0.9431
20	136.84	15.20	0.9461
25	129.29	17.82	0.9518
30	110.39	16.87	0.9649
35	95.06	13.17	0.9740
40	129.29	18.34	0.9562
45	163.59	18.32	0.9229
50	174.32	21.17	0.9124

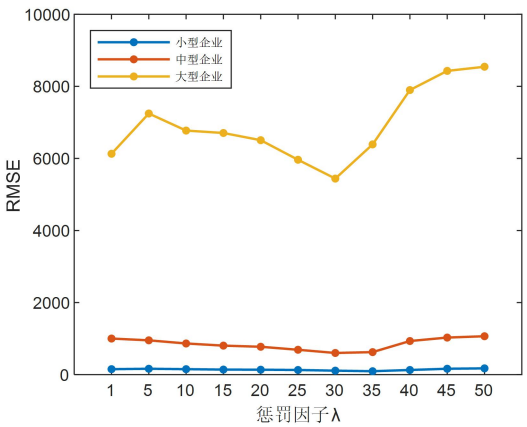
表 4.9 不同惩罚因子下中型企业的预测性能表

λ	T-RMSE	T-MAPE(%)	T-R^2
1	1001.60	5.23	0.9307
5	952.37	4.89	0.9377
10	864.74	4.73	0.9441
15	805.34	4.63	0.9455
20	773.65	4.25	0.9540
25	690.42	3.98	0.9589
30	601.45	3.49	0.9672
35	625.21	3.91	0.9601
40	932.90	4.54	0.9432
45	1028.71	5.29	0.9269
50	1065.78	5.47	0.9215

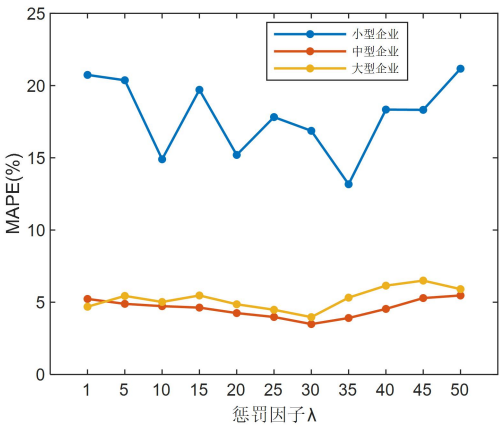
中国知网 https://www.cnki.net

表 4.10 不同惩罚因子下大型企业的预测性能表

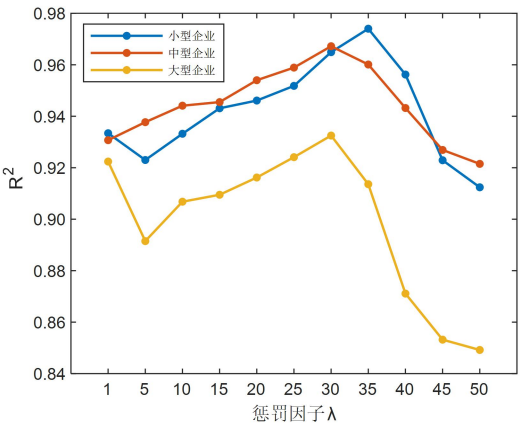
λ	T-RMSE	T-MAPE(%)	T-R^2
1	6129.19	4.69	0.9224
5	7246.63	5.44	0.8915
10	6772.90	5.02	0.9068
15	6706.13	5.47	0.9095
20	6506.13	4.86	0.9162
25	5963.12	4.48	0.9241
30	5440.50	3.97	0.9325
35	6389.32	5.32	0.9136
40	7897.53	6.15	0.8711
45	8429.16	6.50	0.8532
50	8544.30	5.91	0.8492



（a）RMSE



（b）MAPE



（c）R^2

图 4.4 不同惩罚因子下三种规模企业预测性能对比图

中国知网 https://www.cnki.net

图 4.4 反映出迁移 LSTM 模型与 LSTM 模型在不同权重因子下对企业电量预测的差异，可以看出惩罚因子λ取值的变化对所有评价指标均有不同程度的影响，具体表现如下：

（1）当λ＜30 时，随着λ的增大，RMSE 和 MAPE 的值部分出现起伏波动，但总体趋势是逐渐减小，R^2一直增加，此时 MMD 距离未能完全发挥作用；

（2）当λ＞35 时，随着λ的增大，总体趋势是 RMSE 和 MAPE 不断增加，R^2不断减少，预测误差逐渐增大。

综合以上分析，对于企业日用电量数据，当惩罚因子λ∈[30，35]，基于全年 MMD 的迁移 LSTM 模型预测性能最佳。

4.3 季节性 MMD 对迁移预测的影响

由于电量受季节周期性影响较大，为了验证基于全年的 MMD 距离和基于季节划分的 MMD 距离对模型预测精度的影响，分别考虑不同季节下源域企业和目标域企业的电量数据相似度，以不同季节进行对应迁移。分别求得三种规模下，源域和目标域企业的对应季节 MMD 的距离。如果目标域中部分数据未满一个季度时，根据其所属的季节单独计算源域和目标域企业的 MMD 距离，最后将模型损失函数根据季节性进行分段训练，具体如图 4.5 所示。

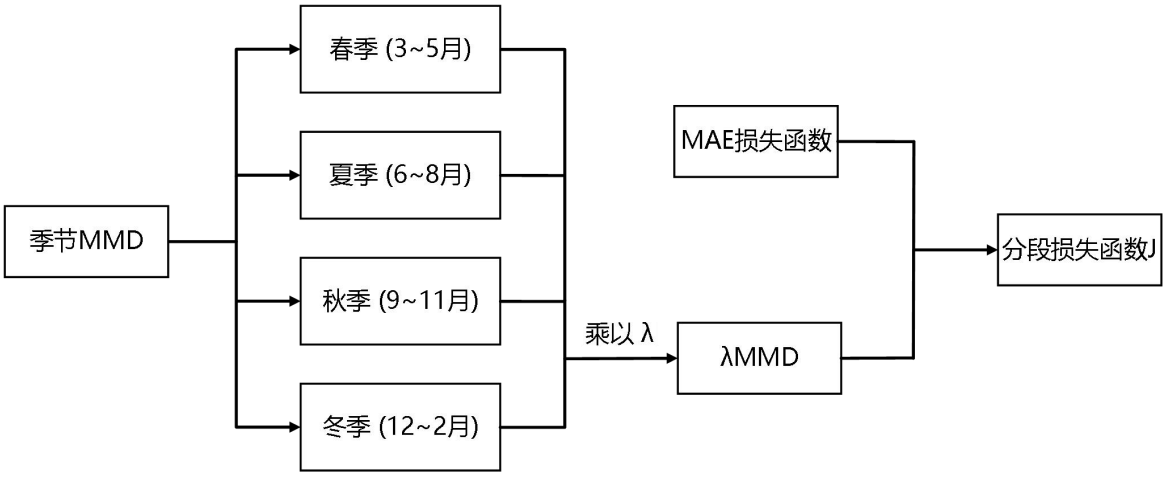


图 4.5 改进损失函数示意图

表 4.11 计算了三种规模源域和目标域企业的季节 MMD 距离，可以看出小型企业的季节 MMD 距离在春季和秋季明显偏高，得出源域和目标域企业的电量数据在这两个季节相似度较高。随着企业规模的增大，电量数据的数量逐步上升，源域和目标域企业的电量数据的相似度逐渐降低。图 4.6 直观的反映了不同规模企业 MMD 距离随季节的起伏变化，其中小型企业的波动幅度最大，大型企业波动最小。

中国知网 https://www.cnki.net

表 4. 11 相同规模企业的季节 MMD 距离

企业	春季	夏季	秋季	冬季	年平均值
小型企业	0.2105	0.1491	0.2012	0.1567	0.1794
中型企业	0.1561	0.1542	0.1504	0.1600	0.1552
大型企业	0.1548	0.1483	0.1492	0.1500	0.1506

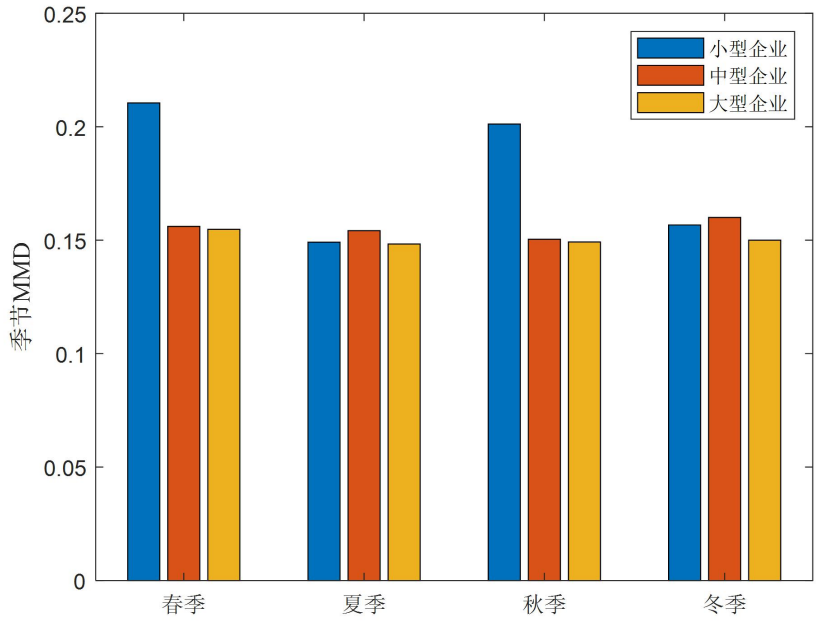
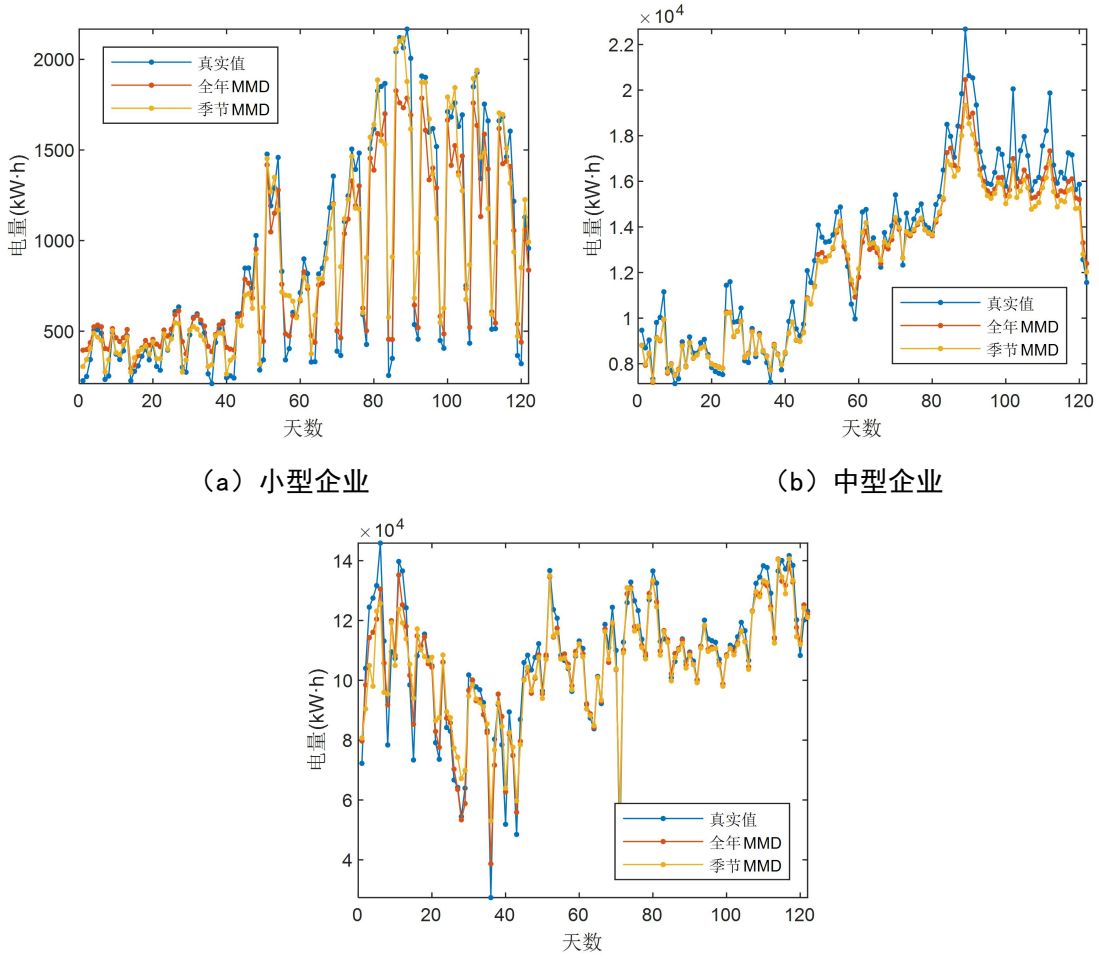


图 4. 6 三种规模企业的季节 MMD 距离示意图

基于 MMD 距离的迁移 LSTM 网络建模，将源域企业的前 80%样本作为训练集，目标域企业后 20%作为测试集进行迁移预测。将对应季节的 MMD 距离乘以惩罚因子λ，根据本章 4.3 节选取λ=30，按式（3.8）改进模型损失函数。并以相同比例划分训练集和测试集，与全年 MMD 距离进行对比，得到的三种规模企业电量预测图，如图 4.6 所示。

中国知网 https://www.cnki.net



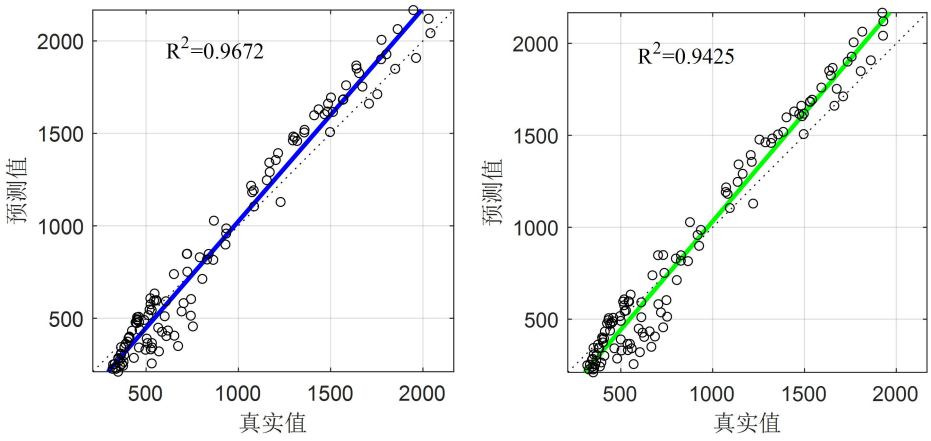
（a）小型企业　　（b）中型企业

（c）大型企业

图 4.7 不同 MMD 迁移策略的企业电量预测图

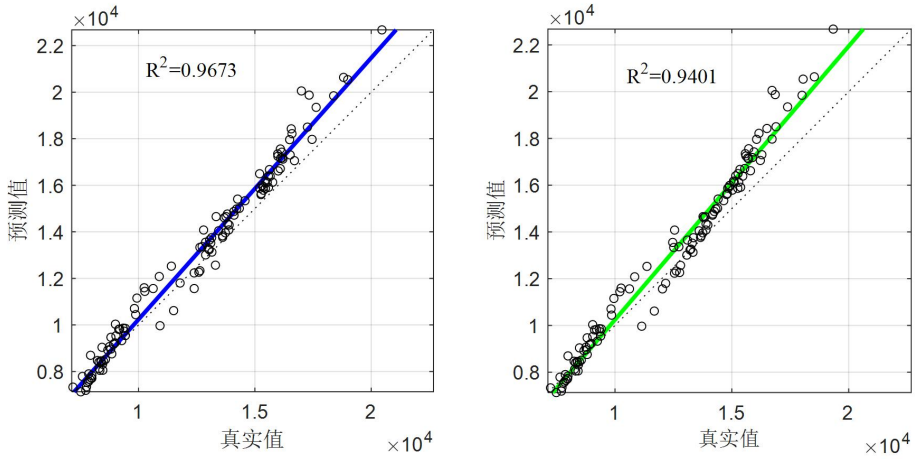
从图 4.7 中基于全年 MMD 和季节 MMD 的迁移 LSTM 模型在三种用电规模企业中的预测效果，以及对比图 4.8 至图 4.10 中两种迁移方式下的拟合曲线图可知，相比于季节 MMD，全年 MMD 与真实值的拟合程度更高，同时模型预测性能更加稳定。

中国知网 https://www.cnki.net



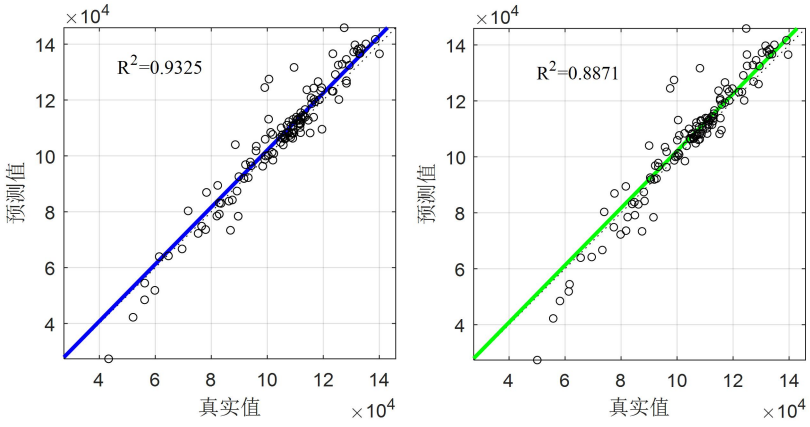
（a）全年 MMD　　（b）季节 MMD

图 4.8 不同 MMD 迁移策略的小型企业电量预测拟合图



（a）全年 MMD　　（b）季节 MMD

图 4.9 不同 MMD 迁移策略的中型企业电量预测拟合图

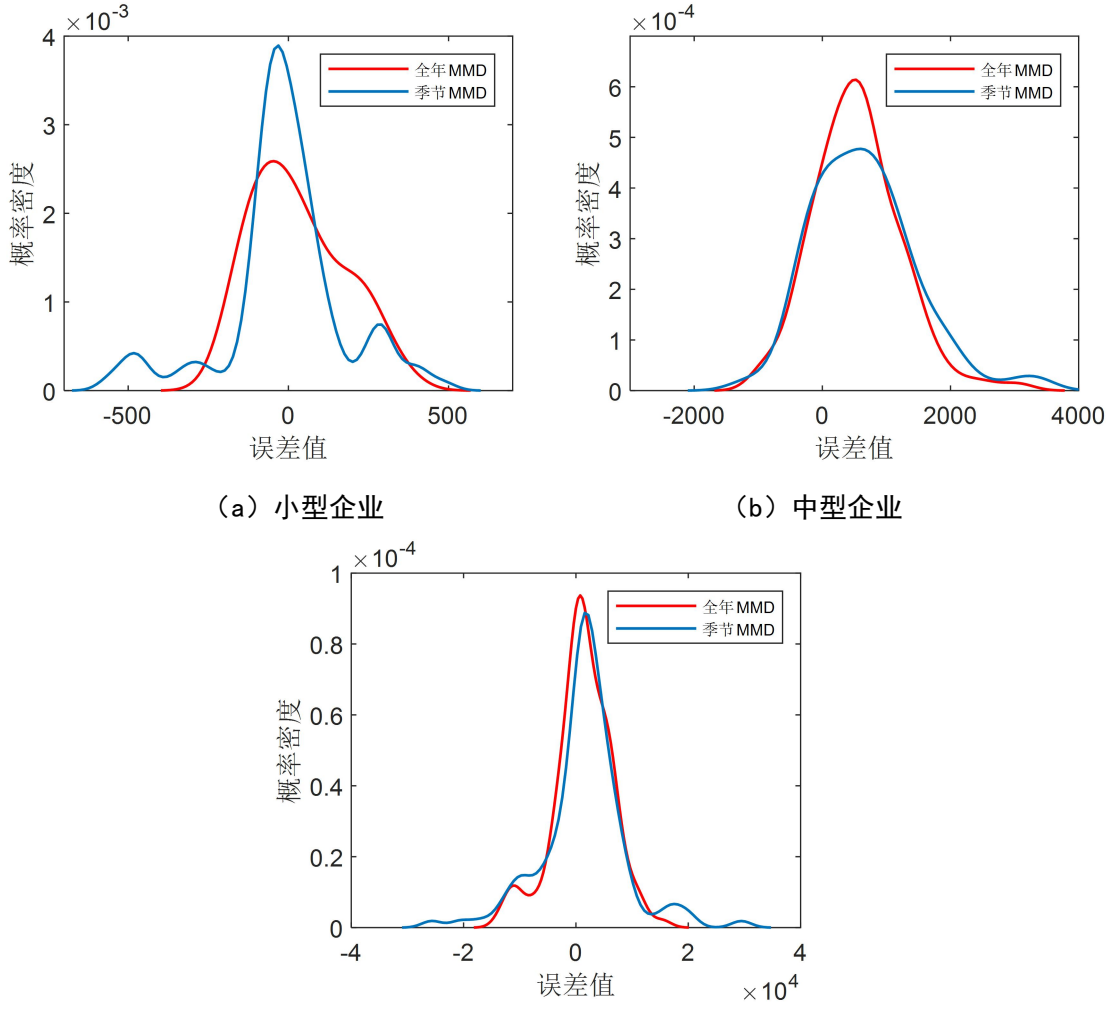


（a）全年 MMD　　（b）季节 MMD

图 4.10 不同 MMD 迁移策略的大型企业电量预测拟合图

中国知网　https://www.cnki.net

同时对三种用电规模企业下的预测误差结果进行拟合，比较全年 MMD 和季节 MMD 的预测误差分布，如图 4.11 所示。



（a）小型企业　　（b）中型企业

（c）大型企业

图 4.11 不同 MMD 迁移策略的企业电量预测误差分布

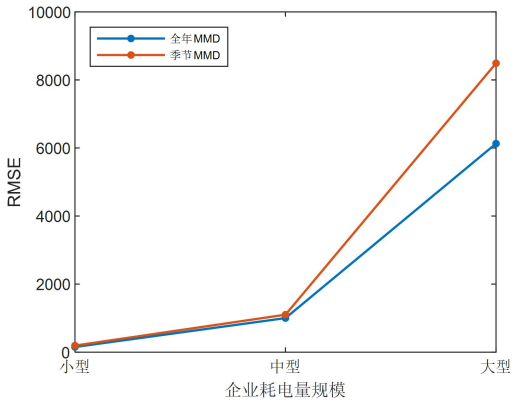
从图 4.11 可以看出，对于小型企业，全年 MMD 的误差值主要集中在[-200,500]区段，而季节 MMD 的误差值主要分布[-700,500]区段，同时季节 MMD 的预测数据在 0 附近的峰值较高，表明全年 MMD 的误差分布范围更集中，季节 MMD 的小误差较少。对于中型企业和大型企业，全年 MMD 和季节 MMD 的误差分布曲线较为接近，但全年 MMD 的横轴误差范围较小，且在 0 附近峰值较高，表明全年 MMD 的预测误差更小。

中国知网 https://www.cnki.net

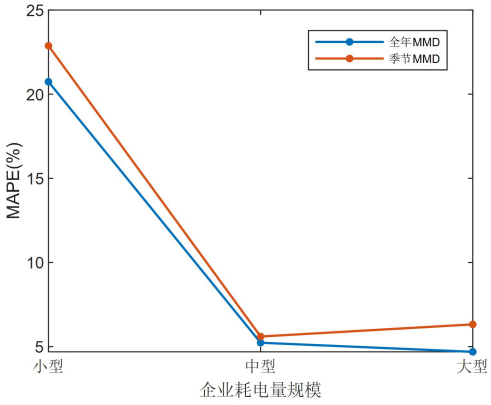
表 4.12 不同 MMD 迁移策略的迁移预测指标对比

企业	MMD	RMSE	MAPE(%)	R^2
小型企业	全年	110.39	16.87	0.9649
	季节	145.64	19.96	0.9425
中型企业	全年	601.45	3.49	0.9672
	季节	932.75	4.70	0.9401
大型企业	全年	5440.50	3.97	0.9325
	季节	7432.53	5.68	0.8871

为了客观评价两者的预测效果，表 4.12 和图 4.12 反映了目标域测试集上三种误差指标的变化情况。以 R^2 为例，对于小型用电规模的企业，通过全年 MMD 迁移的 LSTM 模型达到了 0.9649，相较于季节 MMD 超过 0.0224；对于中型用电规模的企业，全年 MMD 迁移的 LSTM 模型比季节 MMD 高出 0.0271。对于大型用电规模的企业，全年 MMD 作为相似性度量的 R^2 达到 0.9325，效果明显优于季节 MMD 的 0.8871。综合以上分析，得出采用全年 MMD 比季节 MMD 的迁移 LSTM 模型在预测企业电量中的精度更高，体现了全年 MMD 距离在相同规模企业日用电量预测上的优势。

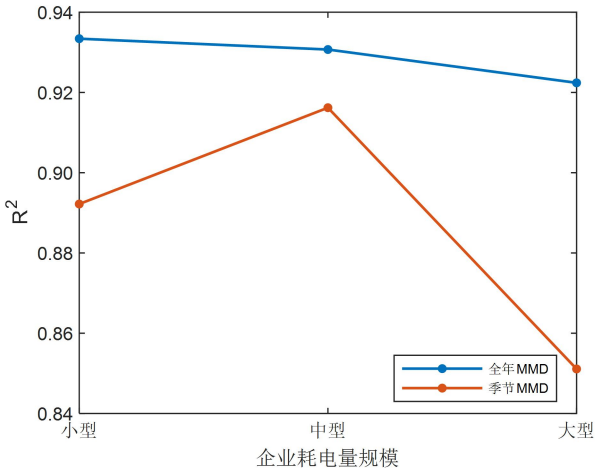


（a）小型企业



（b）中型企业

中国知网 https://www.cnki.net



（c）大型企业

图 4.12 不同 MMD 迁移策略的企业电量预测性能对比图

4.4 本章小结

在本章中，利用第三章提出的基于 MMD 距离的迁移 LSTM 模型，通过实证分析了样本数量、季节 MMD 和权重因子三种迁移因素对该模型预测性能的影响，研究结果表明：

（1）在训练集样本比例较少的情况下，迁移学习确实有助于提升 LSTM 在样本比例不足时的对相同规模企业电量的预测性能。

（2）惩罚因子λ的改变对基于全年 MMD 的迁移 LSTM 模型的预测性能有较大影响，当惩罚因子λ∈[30，35]，基于全年 MMD 的迁移 LSTM 模型预测性能最好。

（3）针对不同 MMD 距离的迁移策略，基于全年 MMD 的迁移 LSTM 模型明显好于基于季节 MMD 的迁移 LSTM 模型的预测效果，对于不同规模企业更加稳定。

中国知网 https://www.cnki.net

第 5 章 不同用电规模企业迁移预测初探

本文第三章 3.6.2 节通过建立基于改进 MMD 的迁移 LSTM 模型，将 MMD 距离作为源域和目标域的相似度指标，拉近了源域和目标域的距离，使得电量迁移预测能够有效实现。但仍存在一个关键的前提，首先源域和目标域企业需要在相同用电规模企业之间才能进行迁移预测。但很多情况下如若所选源领域与目标领域的相似性很低，即便将原始特征空间映射到新的空间，二者的分布也很难相近或相同。能否根据本文的相似性度量方法，进一步缩小不同用电规模企业间的电量数据差异，实现不同规模企业之间的电量预测，是本章的主要研究问题。

5.1 方法设计

在进行不同用电规模企业的电量预测时，所选择的源域和目标域的企业规模虽然不同，但是我们希望两者之间的相似性较高，即两个领域间的数据分布差异较小，因为这样的源域具有更多的有效迁移知识用于目标域任务的学习。通过第三章 3.5 节和第四章的研究，在相同规模企业的电量预测中，基于全年 MMD 距离的迁移 LSTM 模型能够有效学习到目标域企业的电量变动趋势，而不同规模企业电量数据的主要差异在于数量级不同。根据电量数据的变化规律，提出一种数据标准化解决方法，如图 5.1 所示：

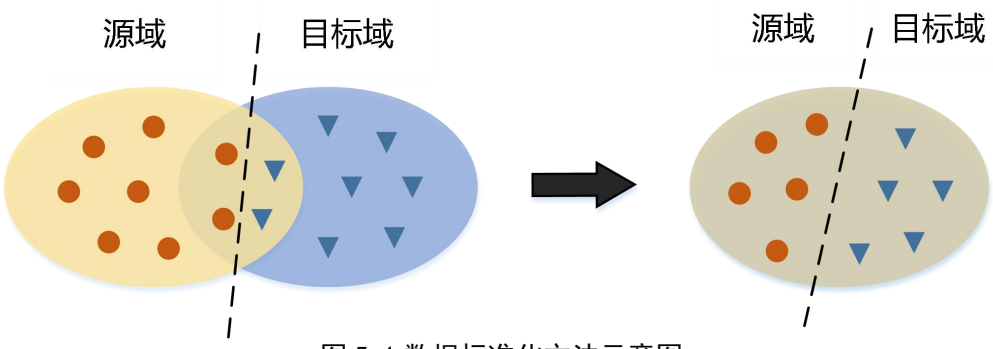


图 5. 1 数据标准化方法示意图

当源域和目标域企业用电规模不同时，假设源域企业规模为 A，目标域企业规模为 B，先分别求出已有源域和目标域企业电量样本数据的平均值分别为 A_0 和 B_0（$A_0 \neq B_0$），则

（1）若 $A_0 > B_0$ 时，记作

$$k = \frac{A_0}{B_0} \tag{5.1}$$

（2） 若 $A_0 < B_0$ 时，记作

中国知网 https://www.cnki.net

$$k=\frac{B_0}{A_0} \tag{5.2}$$

根据两种情况对源域数据进一步处理：

（1） 若 $A_0>B_0$ 时，则

$$D_A'=\frac{D_A}{k} \tag{5.3}$$

（2） 若 $A_0<B_0$ 时，则

$$D_A'=kD_A \tag{5.4}$$

式中 D_A 是初始源域数据集，D_A' 是标准化后的源域数据集。

将 D_A' 作为训练集，D_B 是目标域的数据集作为测试集，分段求出 D_A' 与 D_B 的全年 MMD 值，利用第三章 3.5 节提出的基于改进 MMD 的迁移 LSTM 模型进行预测。这种做法的目的是通过数据标准化方法，使源域样本数据的数量级同目标域保持一致，从而转变为实现相同规模的电量预测。

5.2 不同用电规模企业的电量预测分析

5.2.1 实验设计

本节采用第三章 3.2 节的数据集，为了探究基于改进 MMD 的迁移 LSTM 模型对所有不同用电规模企业之间的预测性能，本节一共进行 6 组实验，如图 5.2 所示。

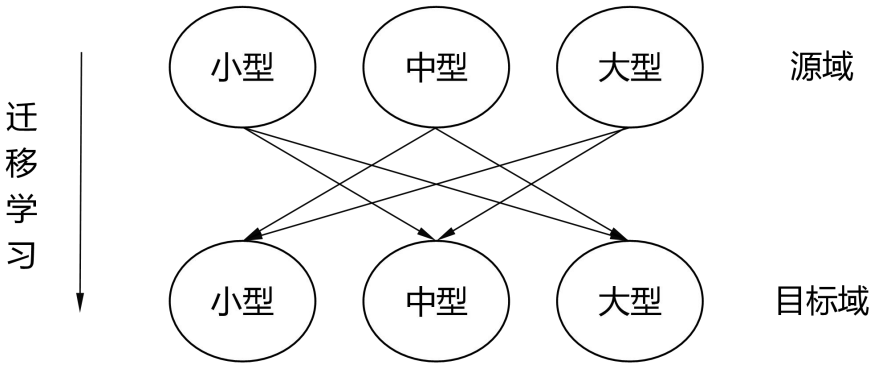


图 5.2 不同用电规模企业电量迁移示意图

根据不同规模的源域企业，首先求得源域和目标域在内的 6 家企业电量数据的平均值，通过样本数据的平均值进一步求出 k 值，如表 5.1 所示。根据本章 5.2 节所述方法进行数据处理，求出相应的全年 MMD 值，利用第三章 3.5 节提出的基于改进 MMD 的迁移 LSTM 模型进行预测，采用与第三章相同的 LSTM 神经网络结构和参数，其中表 5.1 中的参数设定以目标域企业规模为准。将得到 D_A' 的前 80%样本作为训练集，D_B 的最后 20%作为测试集，取惩罚因子λ=30。

中国知网 https://www.cnki.net

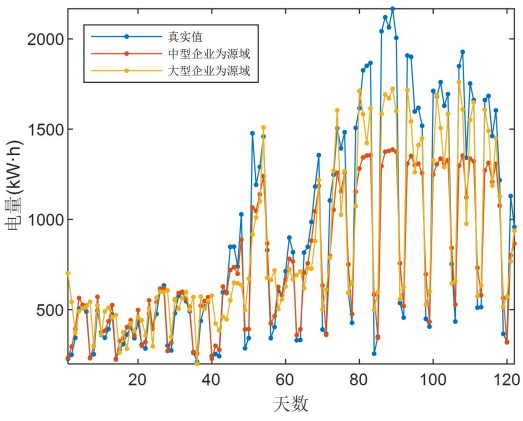
以小型用电企业迁移到中型用电企业为例，先分别求出源域和目标域企业电量样本数据的平均值分别为 A_0 和 B_0 分别是 879.06 和 12019.75，得到 $A_0<B_0$，根据式（5.2）进一步求出 k 值为 13.67，将源域数据集 D_A 乘以 k 值得到 D_A'，求出 D_A' 与目标域数据集 D_B 的全年 MMD 距离，最后将 D_A' 作为训练集输入中型规模的基于改进 MMD 的迁移 LSTM 模型进行预测。

表 5.1 不同规模企业电量迁移 k 值

源域	目标域	k 值
小型企业	中型企业	13.67
	大型企业	169.18
中型企业	小型企业	14.48
	大型企业	13.54
大型企业	小型企业	110.88
	中型企业	7.00

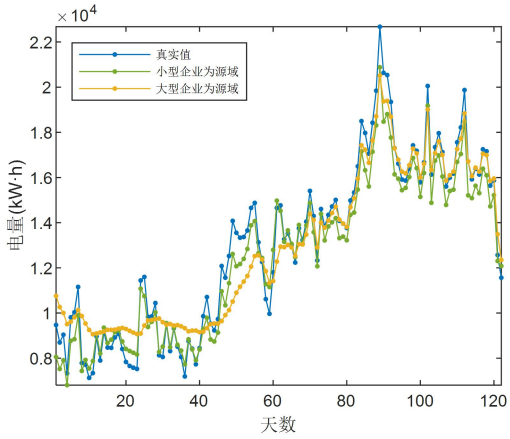
5.2.2 结果与分析

在对源域企业电量数据进行标准化改进后，不同规模企业的迁移 LSTM 模型预测效果图如图 5.3 所示。图 5.4 是各种不同规模企业电量迁移结果的拟合曲线图。从图 5.3 和图 5.4 中可以看出，与真实值相比，当目标域为小型企业时的拟合度最低，当目标域为大型企业时的拟合度最高。随着目标域企业规模的增大，基于改进 MMD 的迁移 LSTM 模型的预测精度越来越高。利用本章的方法模型，在源域和目标域数量级差别过大时，依然能够有效学习到目标域的特征，提高了基于改进 MMD 的迁移 LSTM 模型在企业电量预测上的泛化能力。

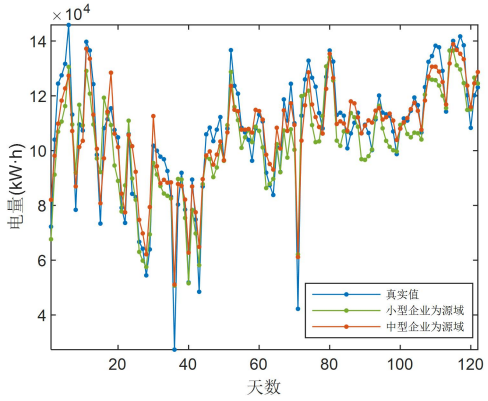


（a）

中国知网 https://www.cnki.net

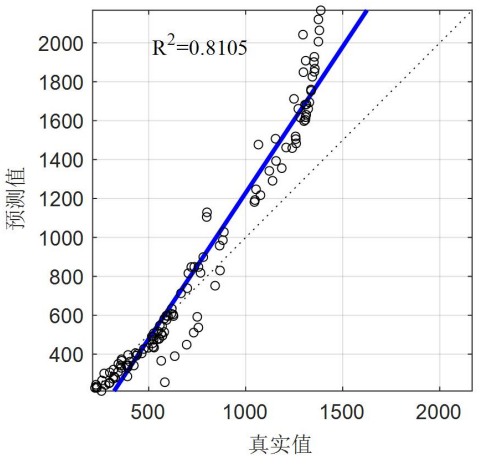


（b）

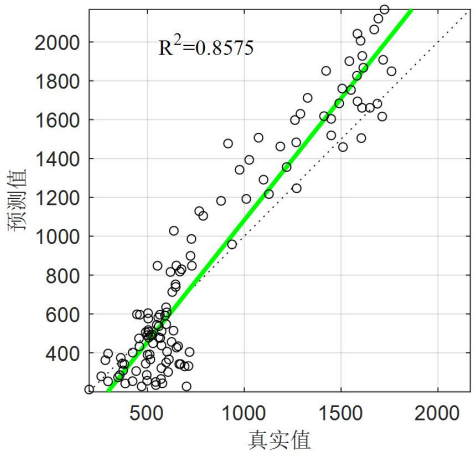


（c）

图 5.3 不同规模企业电量迁移预测效果对比图：（a）小型企业为目标域；（b）中型企业为目标域；（c）大型企业为目标域

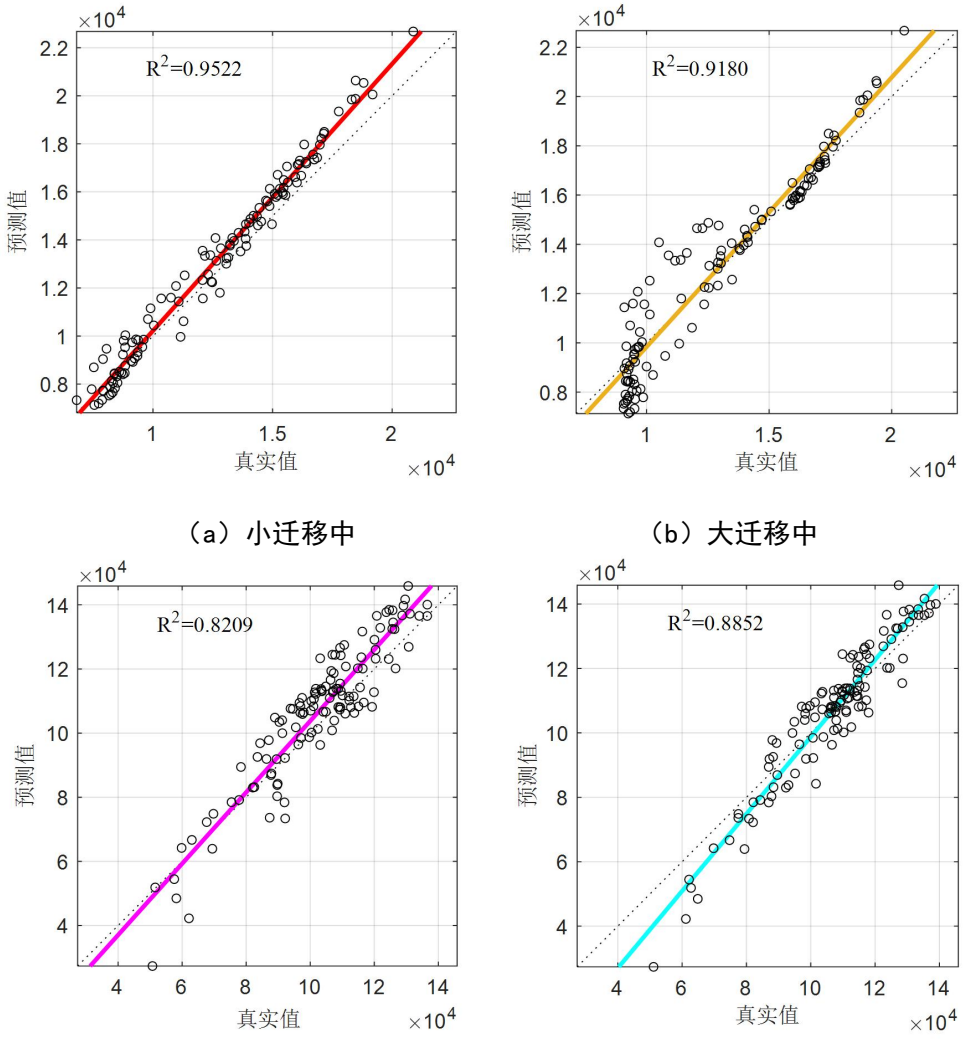


（a）中迁移小



（b）大迁移小

中国知网 https://www.cnki.net

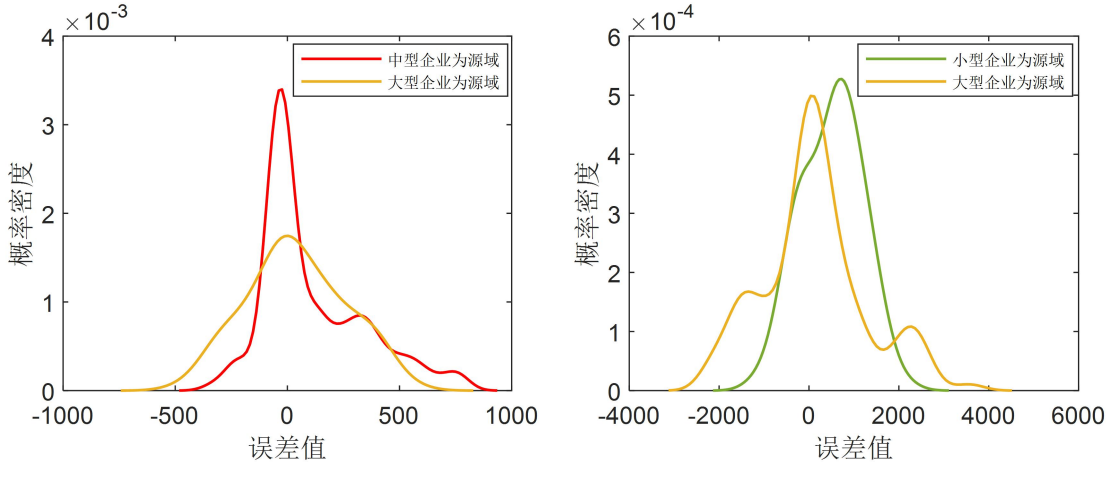


（a）小迁移中　　（b）大迁移中

（a）小迁移大　　（b）中迁移大

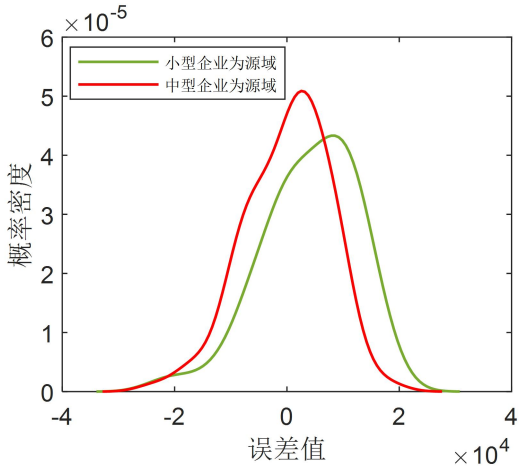
图 5.4 不同规模企业电量迁移预测拟合图

对三种用电规模企业下的预测误差结果进行拟合，比较不同规模企业电量迁移组合下的预测误差分布，如图 5.5 所示。



（a）　　（b）

中国知网 https://www.cnki.net



（c）

图 5.5 不同规模企业电量迁移预测误差分布：（a）小型企业为目标域；（b）中型企业为目标域；（c）大型企业为目标域

表 5.2 不同规模企业电量迁移预测指标对比

序号	企业规模迁移	RMSE	MAPE(%)	R^2
1	中型→小型	256.49	17.08	0.8105
2	大型→小型	222.47	29.87	0.8575
3	小型→中型	831.15	5.27	0.9522
4	大型→中型	1153.06	7.73	0.9081
5	小型→大型	9312.55	7.92	0.8209
6	中型→大型	7454.98	6.80	0.8852

从图 5.5 可以看出，不同规模企业电量迁移预测误差分布差异较大：

（1）在目标域为小型用电企业时，以中型用电企业为源域的误差值主要集中在[-200,500]区段，同时误差数据在 0 附近的峰值较高，而以大型用电企业为源域的误差值主要分布[-500,500]区段，此时以中型用电企业为源域迁移预测精度较高。

（2）在目标域为中型用电企业时，以小型用电企业为源域的误差值主要集中在[-2000,2000]区段，而以大型用电企业为源域的误差值主要分布[-4000,4000]区段，误差峰值较为接近，以大型用电企业为源域的峰值更靠近原点，总体而言，此时以小型用电企业为源域迁移预测精度较高。

（3）在目标域为大型用电企业时，以小型用电企业为源域和以中型企业为源域的误差值范围较为重合，主要分布[-30000,20000]区段，以中型用电企业为源

中国知网 https://www.cnki.net

域的峰值更靠近原点，且峰值较高，此时以中型用电企业为源域迁移预测精度较高。

表 5.2 定量展示了不同规模企业在迁移 LSTM 模型中各项预测指标的情况，可以发现：

（1） 在目标域为中型用电企业时，利用小型用电企业和大型用电企业的源域数据迁移效果最好，R^2 分别达到了 0.9522 和 0.9081，均在 0.9 以上。而当目标域为小型用电企业时，利用中型用电企业和大型用电企业的源域数据迁移效果最差，R^2 分别只达到了 0.8105 和 0.8575；当目标域为大型用电企业时，利用小型用电企业和中型用电企业的源域数据迁移效果最差，R^2 分别也只达到了 0.8209 和 0.8852，此时迁移 LSTM 模型预测性能较差。表明当目标域企业用电规模为中型时此模型预测效果最好。

（2） 由小型用电企业迁移到中型和大型用电企业的预测精度远好于由中型和大型用电企业迁移到小型用电企业的预测精度，即当源域企业规模小于目标域企业规模时，预测效果相比源域企业规模大于目标域企业规模时更好，因此在其他条件不变时，优先选择小型用电企业作为源域预测更加准确。

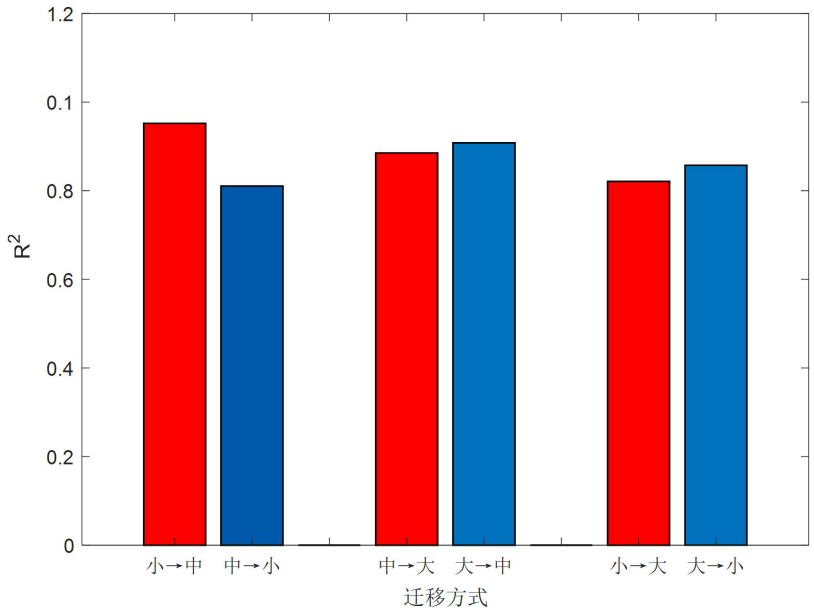


图 5.6 不同规模企业电量迁移预测 R^2 对比图

图 5.6 直观的展示了不同用电规模企业组合之间迁移的预测效果对比图。从图 5.6 可以看出，相邻两种规模企业之间的迁移效果比相差两种规模的迁移效果更好，同时反映出电量数据的数量级差别越小，数据的相似性越高，迁移预测的

中国知网 https://www.cnki.net

结果越好。

5.3 本章小结

本章通过对源域企业电量数据进行标准化改进，缩小不同规模企业间的电量数据差异，使得基于改进 MMD 的迁移 LSTM 模型实现了不同用电规模企业间的电量精准预测，得出以下结论：（1）优先选取小规模企业作为源域的迁移预测精度越高；（2）两种规模企业之间的差距越小，迁移预测效果越好。此方法在保证较高的预测精度的情况下，不仅能够解决某些地区企业日用电量样本不足的问题，还节省了重建模型训练时间。

中国知网 https://www.cnki.net

第 6 章 总结与展望

6.1 全文总结

电力预测是电力系统发电计划的重要组成部分，是对购电、发电、输电和电能分配等合理安排的必要前提，是电力系统经济运行的基础，企业生产管理的重要组成部分，是一种辅助和改善企业经济、环境等决策过程的有利工具。

本文提出了一种基于数据分布相似性的迁移学习方法，将最大均值差异 MMD 距离作为判断源域企业和目标域企业电量数据的相似性度量，通过相似性分析测算同等规模企业之间日用电量数据的 MMD 距离，运用迁移学习，建立了基于季节 MMD 的迁移 LSTM 神经网络模型，建立普适性模型后，针对不同任务，对统一模型进行相应调整训练，能提高网络训练效率和数据利用率。并在此基础上对输入源域企业电量数据加以改进，实现了不同用电规模企业的电量预测研究，能在保证预测准确率不明显下降的前提下大大减少了算法对企业自身电量数据的依赖，从而能够提升预测模型的泛化性，节省模型的重新建模时间，帮助电力企业有效进行日常规划管理工作。目前迁移学习应用到电量预测领域尤其是企业日用电量数据的实证分析的相关研究相对来说较少，本文将迁移学习应用到企业电量预测领域，分析企业用电的特征与规律，为企业电量的精确预测和管理提出理论支持。遵循由机理-模型-算法-实验的研究过程来进行故障诊断的实例分析和验证总结，本文开展的研究工作及成果总结如下所示：

（1）为体现电量发展的内在特性，以企业用电规模为划分依据进行电量预测。对于三种不同规模企业，搭建了基于 LSTM、BP、SVM、ELM 四种机器学习模型的电量预测模型进行预测分析。实证结果表明，LSTM 模型对相同用电规模的企业电量预测均有着更好的性能。同时为了解决目标域企业样本不足的问题，通过迁移学习，采用 KL 散度、JS 散度、MMD 距离三种相似性度量改进 LSTM 模型的损失函数，发现基于 MMD 距离的迁移 LSTM 模型在三种规模企业预测中能达到较稳定的高预测精度，证明了基于 MMD 距离的迁移 LSTM 模型的运用到企业电量预测的可行性。该方法的优点是仅采用源域 LSTM 网络进行建模，不需要对目标企业再次重新建模，节省了重新建模调参时间。最后通过添加惩罚因子λ，改进模型损失函数，提出了一种基于改进 MMD 的迁移 LSTM 模型，进一步提高了模型的预测精度，确定了惩罚因子对模型预测性能的影响。

（2）分别研究了样本数量、季节性 MMD 和惩罚因子λ对迁移 LSTM 模型的

中国知网 https://www.cnki.net

影响，实证结果表明：

1．在训练集样本比例较少的情况下，迁移学习确实有助于提升 LSTM 在样本比例不足时的对相同规模企业电量的预测性能。

2．惩罚因子λ的改变对基于全年 MMD 的迁移 LSTM 模型的预测性能有较大影响，当惩罚因子λ∈[30，35]，基于全年 MMD 的迁移 LSTM 模型预测性能最好。

3．针对不同 MMD 距离的迁移策略，基于全年 MMD 的迁移 LSTM 模型明显好于基于季节 MMD 的迁移 LSTM 模型的预测效果，对于不同规模企业更加稳定。

（3）进一步探究模型对不同规模企业电量预测效果，通对源域企业电量数据进行标准化改进，缩小不同规模企业间的电量数据差异，使得基于改进 MMD 的迁移 LSTM 模型实现了不同用电规模企业间的电量精准预测，得出优先选取小规模企业作为源域的迁移预测精度越高，两种规模企业之间的差距越小，迁移预测效果越好。此方法在保证较高的预测精度的情况下，不仅能够解决某些地区企业日用电量样本不足的问题，还节省了重建模型训练时间。

6.2 未来展望

本文面向企业电量预测，对数据处理、模型构建、迁移因素等进行了有限的研究，为电力企业的决策方法提供理论参考和指导，并针对电网的日常运行、规划管理等多项工作提供参考依据，取得了阶段性的研究进展。不过要实现更精确的企业电量预测还需进行更加深入的研究工作。

由于实验设备和条件限制，本文每种用电规模企业的电量数据样本只有一年半的数据，数据样本量总体偏少，预测结果与生产企业的真实电量存在一定的差距，为了使结果看起来更有说服力和优势，在今后的研究中应选取样本量大的数据，完善模型的构造及验证。

本文将生产企业按照不同用电规模标准为依据进行划分，只能间接表明企业的行业不同，模型仍具有一定的局限性。如果直接根据行业标准为依据进行企业划分，根据不同行业的企业分布搜集样本数据，选取更具有代表性的电量数据来进行迁移预测，进一步提高模型的普适性，是下一阶段的研究重点。

中国知网 https://www.cnki.net

参考文献

[1] 蒲天骄, 谈元鹏, 彭国政, 等. 电力领域知识图谱的构建与应用[J]. 电网技术, 2021, 45(06): 2080-2091.

[2] 郝英杰. 2021-2022 年度全国电力供需形势分析预测报告[R]. 中国电力企业联合会, 2022, http://www.chinasmartgrid.com.cn/news/20220128/641112.shtml

[3] “十四五”电力规划工作启动[J]. 中国能源, 2020, 42(02): 4.

[4] 李政, 陈思源, 董文娟, 等. 碳约束条件下电力行业低碳转型路径研究[J]. 中国电机工程学报, 2021, 41(12): 3987-4001.

[5] 王淞瑶, 张智晟. 基于量子加权 GRU 神经网络的电力系统短期负荷预测[J]. 电力系统及其自动化学报, 2022, 34(01): 1-7.

[6] 蒋建东, 孙书凯, 董存, 等. 风电中长期电量预测研究现状[J]. 高电压技术, 2022, 48(02): 409-419.

[7] 李达, 尹金柱. 浅谈电力市场环境下电网规划中存在的问题及解决措施[J]. 城市建设理论研究:电子版, 2014, 000(036): 9524-9525.

[8] 王磊. 基于用户设备容量的网供负荷预测方法研究[D]. 华北电力大学, 2015.

[9] 单葆国, 李江涛, 谭显东, 等. 经济转型时期电力弹性系数应用[J]. 中国电力, 2017, 50(12): 1-4.

[10] 薛斌, 程超, 欧世其, 等. 考虑舒适温度区间和突变量的月售电量预测线性回归模型[J]. 电力系统保护与控制, 2017, 45(01):15-20.

[11] 蒋浩然, 刘小聪, 李扬. 基于多变量灰色预测模型的省级电力公司中长期电量预测[J]. 电力需求侧管理, 2019,21(01): 37-41.

[12] 刘莉, 王彦博, 庞新富, 等. 基于 STL 模型的月售电量综合预测方法[J]. 控制工程, 2020, 27(11): 1930-1936.

[13] 孙书凯, 董存, 王铮, 等. 考虑不同风能特征的风电中长期电量预测方法[J]. 高电压技术, 2021, 47(04): 1224-1233.

[14] 王捷, 吴国忠, 李艳昌. 蚁群灰色神经网络组合模型在电力负荷预测中的应用[J]. 电力系统保护与控制,2009,(02):48-52.

[15] 王德文, 孙志伟. 电力用户侧大数据分析与并行负荷预测[J]. 中国电机工程学报,2015,(03):527-537.

[16] Chen H, Canizares C A, Singh A, et al. ANN-based short-term load forecasting in electricity

中国知网 https://www.cnki.net

markets[C]. Winter Meeting of the IEEE-Power-Engineering-Society, 2001: 411-415.

[17] Mohamed A, El-Hawary M E, Ieee. Mid-Term electricity price forecasting using SVM[C]. IEEE Canadian Conference on Electrical and Computer Engineering (CCECE), 2016.

[18] Torres J F, Martinez-Alvarez F, Troncoso A. A deep LSTM network for the Spanish electricity consumption forecasting[J]. Neural Computing & Applications.

[19] Jia C, Kong Y, Ding Z, et al． Latent tensor transfer learning for RGB-Daction recognition[J]. Proceedings of the ACM International Conference on Multimedia. New York, NJ, USA:ACM, 2016-96．

[20] Mei S H, Liu X, Zhang G, et al. Sensor-specific transfer learning for hyperspectral image processing[C]. 10th International Workshop on the Analysis of Multitemporal Remote Sensing Images (MultiTemp), 2019.

[21] 李垒昂, 马鸿超, 周清雷. 基于迁移学习的讽刺检测[J]. 计算机应用研究, 2021, 38(12): 3646-3650.

[22] Kim Y, Park J, Moon T. Classification of micro-doppler signatures of human aquatic activity through simulation and measurement using transferred learning[C]. Conference on Radar Sensor Technology XXI, 2017.

[23] Zhang Y W, Jin D H, Xing Y, et al. Automated defect identification via path analysis-based features with transfer learning[J]. Journal of Systems and Software, 2020, 166.

[24] 赵世琛, 王文剑. 一种面向文本分类的特征迁移方法[J]. 数据采集与处理, 2017, 32(03): 516-522.

[25] 赵凯琳, 靳小龙, 王元卓. 小样本学习研究综述[J]. 软件学报, 2021, 32(02): 349-369.

[26] Rosli N A, Abdullah S, Zamani A N, et al. Comparison multi transfer learning models for deep fake image recognizer[C]. 3rd International Cyber Resilience Conference (CRC), 2021: 38-43.

[27] Feng L, Wu B H, et al. Hyperspectral imaging combined with deep transfer learning for rice disease detection[J]. Frontiers in Plant Science, 2021, 12.

[28] Li R R, Li S M, et al. Deep domain adaptation with adversarial idea and coral alignment for transfer fault diagnosis of rolling bearing[J]. Measurement Science and Technology, 2021, 32(9).

[29] 姜海燕, 刘昊天, 舒欣, 等. 基于最大均值差异的多标记迁移学习算法[J]. 信息与控制, 2016, 45(04): 463-470+478.

[30] 任俊, 胡晓峰, 李宁. 基于 SDA 与 SVR 混合模型的迁移学习预测算法[J]. 计算机科学, 2018,

中国知网 https://www.cnki.net

45(01): 280-284+312.

[31] 顾涛勇, 郭建胜, 李正欣, 等. 基于插值-拟合-迁移学习算法的机载设备故障概率预测[J]. 系统工程与电子技术, 2 018, 40(01): 114-118.

[32] 苏运, 卜凡鹏, 郭乃网, 等. 基于低秩表示的多任务短期电力负荷预测的研究[J]. 现代电力, 2019, 36(03): 58-65.

[33] 王天力. 人工蜂群算法+BP 神经网络模型在短期电力负荷预测中的应用研究[J]. 机电信息, 2022(03): 6-9.

[34] 刘世昌, 金敏. 多尺度分析与数据互迁移相结合的短期电力负荷预测方法[J]. 计算机科学, 2018, 45(07): 315-321.

[35] 盛昌. 基于节假日加权迁移学习的短期电力负荷预测[D]. 湖南大学, 2016.

[36] Taylor M E, Stone P. Transfer learning for reinforcement learning domains: A Survey[J]. Journal of Machine Learning Research, 2009, 10: 1633-1685.

[37] 孙俏, 凌卫新. 基于域间相似度序数的迁移学习源领域的选择[J]. 科学技术与工程, 2020, 20(20): 8245-8251.

[38] Tan B, Song Y Q, Zhong E H, et al. Transitive transfer learning[C]. 21st ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD), 2015: 1155-1164.

[39] Kocer B, Arslan A. Genetic transfer learning[J]. Expert Systems with Applications, 2010, 37(10): 6997-7002.

[40] Ammatmanee C, Gan L. Transfer learning for hostel image classification[J]. Data Technologies and Applications, 2022, 56(1): 44-59.

[41] Yang J H, Li S J, et al. An iterative transfer learning based classification framework[C]. International Joint Conference on Neural Networks (IJCNN), 2018.

[42] M. T. Rosenstein, Z. Marx, L. P. Kaelbling, et al. To transfer or not to transfer[J].in Proc. NIPS 2005 Workshop on Transfer Learning, 2005 , 898(3), pp. 1–4.

[43] Wang Z R, Dai Z H, Poczos B, et al. Characterizing and avoiding negative transfer[C]. 32nd IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 11285-11294.

[44] Bleiweiss A. LSTM neural networks for transfer learning in online moderation of abuse context[C]// 11th International Conference on Agents and Artificial Intelligence. 2019.

[45] 张玉红, 余道远, 胡学钢. 领域自适应任务中的动态参数调整方法[J]. 模式识别与人工智能 , 2021, 34(10): 924-931.

中国知网 https://www.cnki.net

[46] 陈思宏, 沈浩靖, 王冉, 等. 预测不确定性与对抗鲁棒性的关系研究[J]. 软件学报, 2022, 33(02): 524-538.

[47] 王伟, 代红, 赵斯祺. 基于特征优化和 BP 神经网络的入侵检测方法[J]. 计算机工程与设计, 2021, 42(10): 2755-2761.

[48] 温廷新, 王贵通, 孔祥博, 等. 基于迁移学习与残差网络的矿工不安全行为识别[J]. 中国安全科学学报, 2020, 30(03): 41-46.

[49] 胥鹏, 王蓓蓓, 包宇庆, 等. 基于网络拓扑资源的配电网在线电压控制方法及其迁移强化学习求解[J]. 中国电机工程学报, 2020, 40(22): 7317-7328.

[50] Xu Z S. Fuzzy ordered distance measures[J]. Fuzzy optimization and decision making, 2012, 11(1): 73-97.

[51] Cross V, Mokrenko V, Crockett K, et al. Using fuzzy set similarity in sentence similarity measures[C]. IEEE International Conference on Fuzzy Systems (FUZZ-IEEE), 2020.

[52] 程前, 李建良. 基于改进动态时间规整的相似性度量及轨迹聚类[J]. 电子测量技术, 2021, 44(23): 1-5.

[53] Groenen P J F, Mathar R, Heiser W J. The majorization approach to multidimensional-scaling for Minkowski distances[J]. Journal of Classification, 1995, 12(1): 3-19.

[54] De Maesschalck R, Jouan-Rimbaud D, Massart D L. The Mahalanobis distance[J]. Chemometrics and Intelligent Laboratory Systems, 2000, 50(1): 1-18.

[55] Seo G, Yoo J, Choi J, et al. KL-divergence-based region proposal network for object detection [C]. IEEE International Conference on Image Processing (ICIP), 2020: 2001-2005.

[56] Xiao F Y, Ding W P. Divergence measure of Pythagorean fuzzy sets and its application in medical diagnosis[J]. Applied Soft Computing, 2019, 79: 254-267.

[57] Liero M, Mielke A, Savare G. Optimal Entropy-Transport problems and a new Hellinger-Kantorovich distance between positive measures[J]. Inventiones Mathematicae, 2018, 211(3): 969-1117.

[58] Khan M A, Hanif M, Khan Z a H, et al. Association of Jensen's inequality for s-convex function with Csiszar divergence[J]. Journal of Inequalities and Applications, 2019.

[59] Gretton A, Borgwardt K M, Rasch M J, et al. A kernel two-sample test[J]. Journal of Machine Learning Research, 2012, 13: 723-773.

[60] 王卓恺. 基于 BP 神经网络的商业银行零售客户信用评价研究[D]. 湖南大学, 2015.

[61] 丁红卫, 王文果, 万良, 等. 基于 BP 神经网络的电网物资需求预测研究[J]. 计算机技术与发

中国知网 https://www.cnki.net

展, 2019, (06): 1-7.

[62] 罗戎蕾, 刘绍华, 苏晨. 基于遗传算法的 BP 神经网络服装销售预测方法[J]. 北京邮电大学学报, 2014, 37(4):39-43.

[63] C Cortes, V Vapnik. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.

[64] 刘伟, 韩彦华, 王荆, 等. 基于粒子群算法优化支持向量机的变压器绕组变形分类方法[J]. 高压电器, 2020, 56(3): 72-78.

[65] T Zhang. Statistical behavior and consistency of classification methods based on convex risk minimization[J]. Annals of Statistics, 2004, 56-85.

[66] 徐睿, 梁循, 齐金山, 等. 极限学习机前沿进展与趋势[J]. 计算机学报, 2019, 42(07): 1640-1670.

[67] 丁阳征, 贾建芳. 改进 PSO 优化 ELM 预测锂离子电池剩余寿命[J]. 电子测量与仪器学报, 2019, 33(02): 72-79.

[68] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6): 1229-1251.

[69] 王鑫, 吴际, 刘超, 等. 基于 LSTM 循环神经网络的故障时间序列预测[J]. 北京航空航天大学学报, 2018, 44(04): 772-784.

[70] S Hochreiter, J Schmidhuber. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

中国知网 https://www.cnki.net

致谢

同样的夜晚，同样的坐在电脑前看着论文，但如今却不是同一个心情，随着时间的流逝，毕业已然来临。经历研究生的三年生活，我收获了很多，成长了很多。自己有很多地方做的不够好，没有真正做到让自己满意，但我希望我能不留遗憾。我想借此机会，表达所有在我研究生生涯中帮助我、鼓励我、支持我的人，谢谢你们陪我一起走过这美好的岁月。

首先，我最感谢的就是教导我三年的硕士生导师白云副教授，三年前我作为一个跨专业考研的学生，很多基础知识没有学习过。白老师在很多问题上都给我做了耐心细致的讲解，现在我还能清晰回忆起每次老师耐心指导的画面，他在百忙之中对我论文的写作给予了耐心细致、不厌其烦的指导，催我奋进。不仅是科研上的工作还是论文的选题都给了很大的动力，在我迷茫与颓废时给我指明了方向。 白老师热爱科研，对待学术态度严谨，平易近人，在为人治学方面是我学习的楷模，是我一生学习的榜样。

还要感谢我们实验室的大家，帮我克服困难，顺利完成学业。感谢三年一起奋斗过来的师门同胞和同班同学们，以及身边一直支持我的人，每当我学习艰难而叹息的时候，是他们给了我无微不至的关怀，感激之情溢于言表。

对我学业最为支持的我的父母，研究生三年使我成熟了很多，感谢他们能给我提供良好的学习环境，给予我健康的体魄，这都是我毕生受益的财富，祝你们永远健康平安。

最后，感谢对我的论文提出宝贵意见的老师和专家们，在百忙之中对我的论文进行审阅，向你们致以真诚的谢意。

中国知网 https://www.cnki.net

在学期间发表论文和主持与参与的项目

一、发表论文与专利：

[1] **肖威**. 基于 LSTM 网络的企业用电量预测分析. 集成电路应用, 2022, 39(05): 90-91. (国家级期刊)

[2] 一种企业用电量预测方法, 申请号：CN2021115909604. 5 排 2, 实质审查.

[3] 一种突发水质污染环境下的贝叶斯迁移学习方法, 申请号：CN2020104724578. 5 排 3, 实质审查.

[4] 一种汽车用具有异形边角打磨功能的车顶盖生产设备, 申请号：CN202011038333.5. 3 排 2, 实质审查.

[5] 一种智能超市用具有防疫消毒功能的空气循环设备, 申请号：CN202010925446.0. 3 排 2, 实质审查.

[6] 一种铁路轨道故障诊断用具有导轨变形检测装置, 申请号：CN202010889872.3. 3 排 3, 实质审查.

[7] 一种视觉检测用具有升降调节结构的图像收录装置, 申请号：CN202010764627.X. 3 排 3, 实质审查.

[8] 一种铁轨线路轨枕及道床健康维护用异物检测装置, 申请号：CN202010695413.1. 3 排 3, 实质审查.

[9] 一种故障诊断用具有报警结构的多功能诊断装置, 申请号：CN201910969716.5. 5 排 4, 实质审查.

二、主持与参与的项目：

[1] 国家级一般项目：多源数据驱动的流域水质预测预警与防控策略研究（项目编号：17YJC630003）2017/8-2020/12，参与， 7 排 7，结题。

[2] 市级一般项目：基于深度学习的生成对抗算法在工业机器人故障诊断的应用（项目编号：1952089）2019/11-2021/12，参与，4 排 3，结题。

中国知网 https://www.cnki.net