文章编号：1007−2322（2026）03−0422−11　　文献标志码：A　　中图分类号：TM714

基于时间卷积网络与迁移学习的短期负荷预测

罗同桐，唐志远，唐義坤，刘俊勇

（四川大学 电气工程学院, 四川省 成都市 610065）

Short-term Load Forecasting Based on Temporal Convolutional Network and Transfer Learning

LUO Tongtong，TANG Zhiyuan，TANG Yikun，LIU Junyong

（College of Electrical Engineering, Sichuan University, Chengdu 610065, Sichuan Province, China）

摘要：短期负荷预测对于优化能源供需平衡、提高电力系统运行效率至关重要。部分地区由于缺乏相关负荷历史数据集，难以使用传统的机器学习预测方法。针对数据稀缺情况下的短期负荷预测问题，提出一种基于时间卷积网络（temporal convolutional network, TCN）与迁移学习的混合预测模型。首先，为了准确度量源域的可迁移性，提出一种综合考虑数据间距离与特征分布差异的源域选择方法。该方法通过结合马氏距离与最大均值差异，筛选出与目标域具有高度相似性的源域。其次，利用雪消融优化器（snow ablation optimizer, SAO）对 TCN 模型的超参数进行优化，建立 SAO-TCN 迁移模型，以提高整体的预测效果。最后，使用实际数据集对所提混合模型进行性能评估和有效性验证。实验结果表明，相较于传统机器学习方法，所提混合模型能够增加源域选择的范围与准确性，它将均方根误差至少降低 15%。

关键词：负荷预测；迁移学习；源域选择；时间卷积网络；雪消融优化器

Abstract：Short-term load forecasting is crucial for optimizing energy supply and demand balance, which improves the efficiency of power system operation. In regions where historical load data are scarce, traditional machine learning prediction methods face great challenges. To address the short-term load forecasting issue in the context of sparse data, we propose a hybrid prediction model based on temporal convolutional network (TCN) and transfer learning. Firstly, a source domain selection method combining Mahalanobis distance and maximum mean discrepancy is introduced to measure the transferability of the source domain. This method aims to identify a source domain that is highly similar to the target domain in terms of data distribution and feature differences. Secondly, the snow ablation optimizer (SAO) is utilized to optimize the hyperparameters of the TCN model, thereby establishing an SAO-TCN transfer model to enhance overall prediction performance. Finally, the proposed hybrid model is evaluated and validated using real-world datasets. Experimental results demonstrate that in comparison to traditional machine learning methods, the hybrid model is capable of expanding the range of source domain selection and enhancing its accuracy as well, and it reduces the root mean square error by at least 15%.

Keywords： load forecasting；transfer learning；source domain selection；temporal convolutional network (TCN)；snow ablation optimizer

DOI：10.19725/j.cnki.1007-2322.2024.0072

0　引言

短期负荷预测（short-term load forecasting，STLF）是电力系统运行中至关重要的一环，它可以帮助电力企业合理规划和安排发电计划和供电方案，以满足用户需求，同时最大限度地降低碳排放量[1-2]。准确的 STLF 不仅能够提高电力系统的可靠性和稳定性，还能够优化电力系统运行，降低电力生产成本，从而为电力行业的可持续发展提供有力支撑[3-5]。

目前，STLF 可以分为传统方法和机器学习方法两大类[6-7]。传统预测方法包括多元线性回归法[8]、季节自回归差[9]以及自回归求和移动平均[10]等，这些方法虽然结构简单，但难以处理特征因素之间的复杂非线性关系[11-12]。近年来，为了提高 STLF 的精度和准确性，机器学习方法开始被

基金项目：四川省科技计划项目（2023YFSY0033）。
Science and Technology Planning Project of Sichuan Province (2023YFSY0033).

中国知网　https://www.cnki.net

广泛应用。机器学习方法通过构建复杂的数学模型和算法，从大量的数据中自动学习并发现负荷数据中的隐藏模式和关联关系。与传统预测方法相比，机器学习方法如支持向量机[13]、决策树[14]、长短期记忆网络（long short-term memory，LSTM）[15]、卷积神经网络(convolutional neural network，CNN)[16]和门控循环单元神经网络（gated recurrent unit，GRU）[17]等，展现出了强大的非线性关系和特征因素处理能力。然而，以上机器学习方法在处理长期依赖关系和捕捉时间序列中的局部模式时存在一定的局限性。时间卷积网络（temporal convolutional network, TCN）[18]因具有更好的长期依赖性和序列建模能力，为处理 STLF 问题提供了一种新的方法。由于 TCN 中的各个残差块包含许多可调整的参数，这些参数能够直接影响模型性能。利用优化算法通过引导 TCN 参数的优化，可以使模型在训练过程中能够灵活地适应不同的数据特征。

然而，在实际的预测任务中，由于数据缺乏、获取困难或无法访问等问题，很难获得足够的有效数据，这可能导致上述负荷预测模型出现过拟合现象，从而影响预测精度。迁移学习（transfer learning, TL）的出现有效地解决了这类小样本预测问题。TL 主要利用从源域获取的知识来预测目标域的负荷功率，在面对目标域数据不足的问题时，可以有效提高模型的预测性能[19]。近年来，许多 TL 方法已被成功应用于 STLF 领域。文献 [20] 通过计算皮尔逊相关系数，选择了与目标城市或地区相似的数据，用这些数据构建了一种基于 TL 的新型月度电力负荷预测方案。文献 [21] 提出一种改进的分层级 TL 策略，结合多尺度 CNN-BiLSTM-Attention 模型，用于短期电力负荷预测。按基础模型结构划分层级，根据源域数据的拟合优度值，实施分层 TL 训练，保留每层最优的训练权重，降低预测误差。文献 [22] 提出了一种结合 Wasserstein 距离和最大信息系数的转移域选择算法，用于确定训练的迁移域，有效提高负荷预测精度。文献 [23] 在预测模型中构建深度迁移学习策略，以保证其在各种场景下的适应性，其中使用最大均值差异（maximum mean discrepancy, MMD）来衡量负载特性与外部环境的渐变偏差。文献 [24] 提出了一种基于 TL 的自适应神经网络框架，用于非平稳建筑能耗预测，分别对不同时期的数据进行学习，以获得最小的整体损失。文献 [25] 提出了一种基于 TL 概念和时间融合转换器（temporal fusion transformer, TFT）架构相结合的方法，可以将知识从基于社区建筑物历史数据的一般预训练模型转移到新用户，减少了每个新建筑物对大量数据的需求。然而，以上 TL 方法在进行源域选择时都未能充分考虑数据间距离和特征分布的差异性，难以避免负迁移的产生。

为解决上述可迁移性度量和 STLF 精度问题，本文结合马氏距离（Mahalanobis distance, MD）[26]和 MMD 作为迁移学习源域选择方法（MD-MMD），并利用雪消融优化器（snow ablation optimizer, SAO）[27]优化 TCN 预测模型，提出基于 SAO-TCN 的迁移学习负荷预测模型，即 MD-MMD-SAO-TCN-TL 混合模型。具体而言，通过 MD-MMD 分析数据间的线性和非线性关系、协方差结构和特征分布的差异，度量迁移学习源域和目标域的相似性，从而选择出适合迁移的源域数据集；然后，利用 SAO 算法对 TCN 预测模型的超参数进行优化，以提高 TCN 模型准确性与泛化能力；最后，将训练好的 SAO-TCN 源域模型迁移至目标域进行短期负荷预测。实验结果表明，该混合模型能够显著提升预测精度，并有效避免负迁移。

1　MD-MMD-SAO-TCN-TL 混合模型框架

本文提出的 MD-MMD-SAO-TCN-TL 混合模型框架如图 1 所示。整体可分为两个阶段：有效源域选择阶段和 TL 负荷预测阶段。

在选择源域阶段，构建一个对源域和目标域进行相似性分析的方法，即 MD-MMD 方法。首先，对源域和目标域的输入矩阵进行预处理，计算各源域相对于各目标域的 MD 和 MMD 值，并对其进行归一化后取均值，得到 MD-MMD 值，利用 MD-MMD 值量化可迁移性。在 TL 负荷预测阶段，选择具有较好的长期依赖性和序列建模能力的 TCN 模型，利用 SAO 算法优化 TCN 模型参数，以提升 STLF 精度。

中国知网　https://www.cnki.net

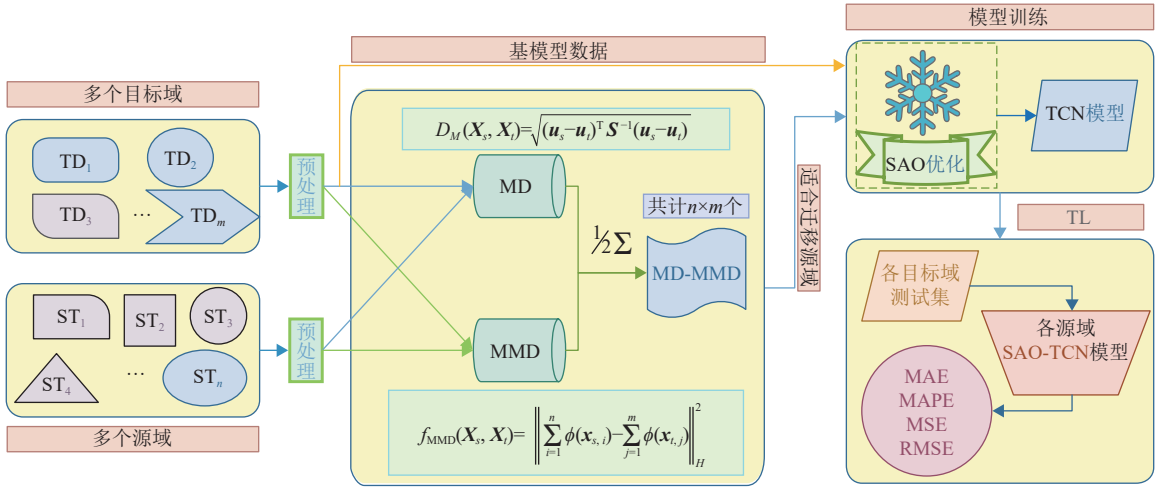


图 1 MD-MMD-SAO-TCN-TL 混合模型框架

Fig. 1 Framework of MD-MMD-SAO-TCN-TL hybrid model

2 MD-MMD-SAO-TCN-TL 混合模型原理

提高 TL 成功率的关键在于，准确评估源域和目标域之间的相似性。目前的相似性判断方法缺乏对概率分布和特征分布差异性的综合考虑，因此难以避免负迁移的产生。基于此，本文提出一种利用 MD 和 MMD 综合考虑数据间距离和特征分布差异性的相似性判断方法，即 MD-MMD 方法，并利用 SAO 算法对 TCN 模型进行优化，有效提升了 TL 性能以及 STLF 的准确性。

MD-MMD 方法通过 3 个主要步骤来度量相似性，即归一化 MD、MMD 和综合得分计算。

2.1 MD-MMD 方法

2.1.1 MD 方法

MD 是一种用于度量数据样本之间距离的方法，它考虑了数据的协方差矩阵和均值之间的关系，能够更准确地描述样本之间的距离，帮助评估 TL 中源域与目标域之间的相似性。

具体来说，对于两个样本向量$\boldsymbol{X}_s=\{\boldsymbol{x}_{s,1},\boldsymbol{x}_{s,2},\cdots,\boldsymbol{x}_{s,n}\}$和$\boldsymbol{X}_t=\{\boldsymbol{x}_{t,1},\boldsymbol{x}_{t,2},\cdots,\boldsymbol{x}_{t,m}\}$，两者之间的 MD 计算公式如下：

$$D_M(\boldsymbol{X}_s,\boldsymbol{X}_t)=\sqrt{(\boldsymbol{u}_s-\boldsymbol{u}_t)^{\mathrm{T}}\boldsymbol{S}^{-1}(\boldsymbol{u}_s-\boldsymbol{u}_t)} \tag{1}$$

式中：$\boldsymbol{u}_s$和$\boldsymbol{u}_t$是集合$\boldsymbol{X}_s$和$\boldsymbol{X}_t$的均值向量；$\boldsymbol{S}$表示联合协方差矩阵。

2.1.2 MMD 方法

MD 在处理非线性数据分布时可能表现不佳，因此引入 MMD 来综合度量可迁移性。MMD 是一种用于衡量两个概率分布之间差异的方法，能够有效地处理非线性的数据分布特征，具有较好的鲁棒性和泛化能力[28]。

对于两组数据集源域$\boldsymbol{X}_s=\{\boldsymbol{x}_{s,1},\boldsymbol{x}_{s,2},\cdots,\boldsymbol{x}_{s,n}\}$和目标域$\boldsymbol{X}_t=\{\boldsymbol{x}_{t,1},\boldsymbol{x}_{t,2},\cdots,\boldsymbol{x}_{t,m}\}$，设其概率分布为$P_s(x)$和$P_t(x)$，MMD 可表示如下：

$$f_{\mathrm{MMD}}(\boldsymbol{X}_s,\boldsymbol{X}_t)=\left\|\sum_{i=1}^{n}\phi(\boldsymbol{x}_{s,i})-\sum_{j=1}^{m}\phi(\boldsymbol{x}_{t,j})\right\|_H^2 \tag{2}$$

式中：H表示再生核希尔伯特空间（reproducing kernel Hilbert space，RKHS）；$\phi(\cdot)$表示$X\to H$的映射。

以高斯核函数实现两个领域之间的映射，表示如下：

$$k(x_{s,i},x_{t,j})=\mathrm{e}^{-\|x_{s,i}-x_{t,j}\|^2/2\sigma^2} \tag{3}$$

式中σ为核函数的径向带宽。

在 TL 中，MMD 经常被用来衡量源领域和目标领域之间的分布差异。MMD 的值越小，表示两个领域的分布越相似，越有利于 TL。因此，通过最小化 MMD，可以使得源领域和目标领域在特征空间中更加接近，有助于提高模型在目标领域上的泛化性能。

2.1.3 MD-MMD 方法综合得分计算

在 TL 中，选择合适的源域数据对于模型的泛化能力和性能至关重要。MD 作为一种考虑数据协方差矩阵和均值关系的度量方法，在描述数据间关系时具有一定的优势，尤其适用于捕捉特征空间内的相关性和方向性信息。然而，MD 在处理非线性数据分布和领域间复杂分布差异时存

中国知网 https://www.cnki.net

在局限性。

MMD 作为一种基于核方法的非参数统计量，能够有效处理非线性数据分布特征，提高模型对领域间分布差异的适应能力。通过结合 MD 和 MMD，可以综合考虑数据集的协方差结构和非线性特征，使得 TL 过程更准确、全面，从而提升模型在目标领域上的泛化性能和有效性。

结合 MMD 与 MD 的优势，可以更全面地评估不同数据分布之间的差异性和相似性，从而更有效地选择适合的源域数据进行 TL。为了对这两个指标进行综合度量，定义一个综合得分 $S_{\text{MD-MMD}}$：

$$S_{\text{MD-MMD}} = \frac{S'_{\text{MD}} + S'_{\text{MMD}}}{2} \tag{4}$$

式中 S'_{MD}、S'_{MMD} 分别为 MD 值（S_{MD}）和 MMD 值（S_{MMD}）归一化后的结果。$S_{\text{MD-MMD}}$ 值越小，则源域与目标域相似性越强，越有利于 TL。

2.2　TCN 模型

时间卷积网络（TCN）是由 Bai 等提出的一种前沿的神经网络架构，相较于传统的循环神经网络，其独特之处在于利用一系列一维卷积层来识别和理解时间序列中的长程依赖关系，同时具备更短的训练时间和更高的并行化能力[29]。

TCN 结构主要包括因果卷积、扩张卷积和残差连接[30]。

1）因果卷积。

TCN 引入了因果卷积，确保每个时间步的预测仅依赖于过去的时间步，从而提高了模型的稳定性。对于给定时间序列 $X = \{x_1, x_2, \cdots x_{t-1}, x_t\}$，TCN 输出相同长度的预测结果 $Y = \{y_1, y_2, \cdots y_{t-1}, y_t\}$。其中，预测值 y_t 只取决于当前时刻之前的输入值，与未来时刻的输入值无关。因果卷积结果如图 2 所示。

2）扩张卷积。

为了从历史序列中提取长期有效的特征信息，需要构建一个非常深度的网络模型。为了解决这个问题，TCN 引入了扩展卷积，在保证获得足够的历史有效信息的同时，显著降低了网络的深度和复杂度。采用扩张卷积可通过更少的网络层数获得输出，可避免普通卷积由于层数过多而带来梯度消失、训练复杂等问题。扩张卷积结构如图 3 所示。

3）残差连接。

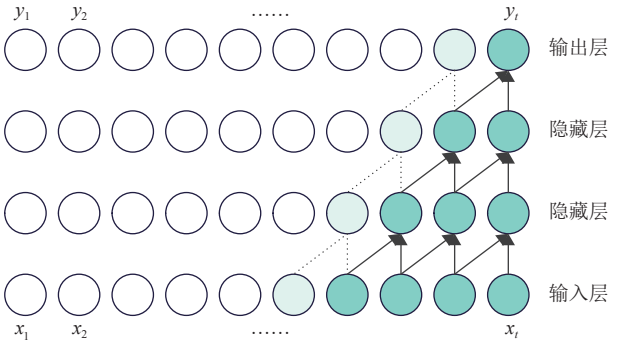


图 2　因果卷积结构

Fig. 2　Causal convolution structure

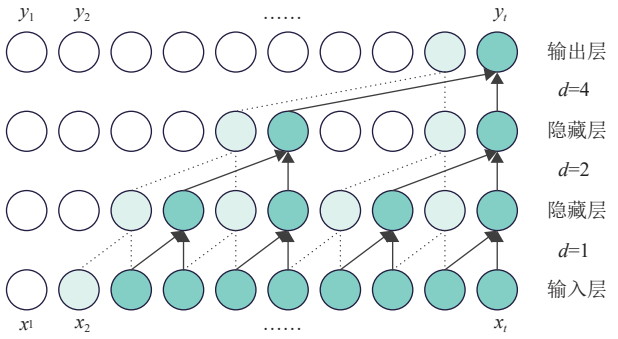


图 3　扩张卷积结构

Fig. 3　Dilated convolution structure

在训练深度网络时，残差连接可以跨层传递信息，从而提高网络的训练速度，避免梯度消失的问题[31]。TCN 的残差连接模型还包括两层卷积和非线性恒等映射。此外，残差连接模块还引入线性整流函数（ReLU）作为激活函数，引入权重归一化实现正则化，并且引入空间损失对每次训练的全通道进行归一化[32]。残差模块结构如图 4 所示。

2.3　SAO 算法

优化 TCN 模型的参数可以显著提高其在负荷预测中的准确性和稳定性，从而提升预测效果，并降低误差。雪消融优化器（SAO）是 Ling 等[27]受到自然界中雪的升华和融化行为启发而开发的一种用于数值优化和工程设计的算法。SAO 算法通过模拟积雪的升华和融化行为，实现解空间中开发和探索的权衡，避免早熟收敛。SAO 算法主要包括初始化阶段、探索阶段、开发阶段以及双种群机制。

2.3.1　初始化阶段

在 SAO 中，迭代过程从随机产生的种群开始。如式（5）所示，整个群体通常被建模为一个包

中国知网　https://www.cnki.net

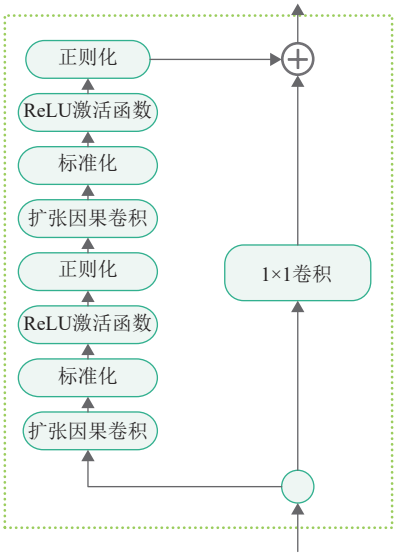


图 4 残差模块结构

Fig. 4 Residual connections structure

含N行和D列的矩阵，其中N表示群体的规模，D表示解空间的维数。

$$\boldsymbol{Z}=\boldsymbol{L}+\theta\times(\boldsymbol{U}-\boldsymbol{L})=\begin{bmatrix} z_{1,1} & z_{1,2} & \cdots & z_{1,D} \\ z_{2,1} & z_{2,2} & \cdots & z_{2,D} \\ \vdots & \vdots & \vdots & \vdots \\ z_{N,1} & z_{N,2} & \cdots & z_{N,D} \end{bmatrix}_{N\times D} \tag{5}$$

式中：$\boldsymbol{L}$、$\boldsymbol{U}$分别表示解空间的下界和上界；θ表示[0,1]区间内的一个随机数。

2.3.2 探索阶段

当雪或由雪转化的液态水转化为蒸汽时，由于不规则的运动，搜索代理呈现出高度分散的特征。在这项研究中，布朗运动被用来模拟这种情况。对于标准布朗运动，步长是基于均值为 0、方差为 1 的正态分布的概率密度函数获得的。相关的表达式如下：

$$f_{BM}(x;0,1)=\frac{1}{\sqrt{2\pi}}\times\exp\left(-\frac{x^2}{2}\right) \tag{6}$$

布朗运动能够探索搜索空间中的一些潜在区域。因此，它可以很好地反映蒸汽在搜索空间中扩散的情况。勘探过程中的位置计算公式如下：

$$\begin{aligned} Z_i(t+1)=B_i(t)\otimes\{\theta_1\times[G(t)-Z_i(t)]+\\ (1-\theta_1)\times\left[\bar{Z}(t)-Z_i(t)\right]\}+E(t) \end{aligned} \tag{7}$$

式中：$Z_i(t)$为第t次迭代中的第i个个体；$B_i(t)$是基于高斯分布的随机数向量，用于表示布朗运动；θ_1为[0,1]区间中的一个随机数；$G(t)$为当前最优解，而$E(t)$为从群体的若干精英中选出的随机个体；$\bar{Z}(t)$为整个群体的质心位置。$E(t)$和$\bar{Z}(t)$具体表达式如下：

$$\bar{Z}(t)=\frac{1}{N}\sum_{i=1}^{N}Z_i(t) \tag{8}$$

$$E(t)\in[G(t),Z_{\text{second}}(t),Z_{\text{third}}(t),Z_{\text{c}}(t)] \tag{9}$$

式中：$Z_{\text{second}}(t)$、$Z_{\text{third}}(t)$分别表示当前种群中的次优个体和第三优个体；$Z_{\text{c}}(t)$表示适应度值排名前 50% 的个体的质心位置，将适应度值排名在前 50% 的个体命名为领导者。即在每次迭代过程中，$E(t)$从当前最优解、次优个体、第三优个体和领导者质心位置组成的集合中随机选择。

2.3.3 开发阶段

当雪通过融化行为转化为液态水时，鼓励搜索代理围绕当前最佳解决方案开发高质量的解决方案，而不是在解决方案空间中以高度分散的特征进行扩展。基于当前最佳搜索代理和群体质心位置的知识，个体更有可能开发出有前途的区域。在 SAO 中，利用如下方程计算融雪速率：

$$\begin{cases} M=\left(0.35+0.25\times\dfrac{\mathrm{e}^{\frac{t}{t_{\max}}}-1}{e-1}\right)\times T(t) \\ T(t)=\mathrm{e}^{\frac{t}{t_{\max}}} \end{cases} \tag{10}$$

式中：$T(t)$表示t时刻气温；e为常数；$t_{\max}$表示终止标准。

然后，在 SAO 的开发阶段，给出位置更新方程：

$$\begin{aligned} Z_i(t+1)=M\times G(t)+B_i(t)\otimes\{\theta_2\times\\ [G(t)-Z_i(t)]+(1-\theta_2)\times\left[\bar{Z}(t)-Z_i(t)\right]\} \end{aligned} \tag{11}$$

式中：M为融雪率；θ_2为从[−1, 1]中选取的随机数。

2.3.4 双种群机制

一些从雪中转化的液态水也可以转化为蒸汽，用于勘探作业。也就是说，随着时间的推移，个体进行具有高度分散特征的不规则运动的可能性增加。然后，算法逐渐有了探索解空间的趋势，在 SAO 算法的研究中，引入二元种群机制是为了反映这种情况，以有效平衡开发与探索过程。如附录 A 所示，在迭代的早期阶段，将整个种群随机划分为两个大小相等的子种群，称之为双种群机制。

综上所述，SAO 算法的完整位置更新方程如

中国知网 https://www.cnki.net

下所示：

$$Z_i(t+1)=\begin{cases}E(t)+B_i(t)\otimes(\theta_1\times(G(t)-Z_i(t))+\\ \quad(1-\theta_1)\times(\bar{Z}(t)-Z_i(t))),i\in\gamma_{\text{index}a}\\ M\times G(t)+B_i(t)\otimes(\theta_2\times(G(t)-Z_i(t))+\\ \quad(1-\theta_2)\times(\bar{Z}(t)-Z_i(t))),i\in\gamma_{\text{index}b}\end{cases}\tag{12}$$

式中$\gamma_{\text{index}a}$、$\gamma_{\text{index}b}$分别表示负责探索的子种群P_a和被分配执行开发的子种群P_b中个体在整个位置矩阵中对应的行编号集合。附录 B 总结了 SAO 算法的整个过程。

2.4　SAO-TCN 算法

TCN 中的各个残差块包含许多可调整的参数，这些参数的选择直接影响模型性能。利用 SAO 算法优化 TCN 模型，旨在提升时序预测问题的准确性。SAO 通过引导参数的优化，使得模型在训练过程中能够更加灵活地适应不同的数据特征。这种引导机制有助于避免陷入局部最优解，提高了模型的鲁棒性。

该模型的核心结构由多个残差块组成，每个残差块由一维卷积层、层归一化、空间丢弃层和激活函数构成。这些残差块在 SAO 算法的引导下进行构建，以自适应地调整网络参数，并最大程度地提高预测性能。SAO 算法为网络提供了全局搜索和参数调整的机制，以适应不同数据模式和任务需求。

3　算例分析

3.1　算例设计及评价指标

3.1.1　算例设计

本文采用来自于中国东南部某城市的 9 个典型用户的负荷数据集，用户包括科研机构、农村、轻重工业、商业、写字楼、住宅等，数据时间范围是从 2017 年 11 月 1 日至 2018 年 10 月 31 日，数据的采样间隔为 15min。随机选取其中 6 户用户用电数据作为源域，记作$\{S_{D1},S_{D2},S_{D3},S_{D4},S_{D5},S_{D6}\}$，源域时间范围为 2018 年 6 月 1 日至 8 月 31 日共计 92 天，每个用户具有 8832 个历史时刻的负荷数据值，并按时间顺序划分为训练集和测试集，比例为 0.7:0.3；选取余下 3 个用户用电数据作为目标域，记作$\{T_{D1},T_{D2},T_{D3}\}$，目标域时间范围为 2018 年 8 月 22 日至 8 月 31 日共计 10 天，每个用户具有 960 个历史时刻的负荷数据值，为模拟小样本数据集，目标域按 0.3∶0.7 比例按时间顺序划分为训练集和测试集。

图 5(a)、(b)、(c) 分别代表目标域T_{D1}、T_{D2}、T_{D3}的负荷曲线，3 条负荷曲线都具有一定的波动性，其中T_{D1}负荷曲线的规律性较T_{D2}、T_{D3}更强。采用滑动窗口方法对数据进行处理，选取窗大小为N，利用$X-N$至X时刻的实测负荷数值预测未来$X+1$时刻的负荷数值，本文取$N=24$，即输入数据维度为 24。本文通过函数识别并删除了包含缺失值的行，以确保实验数据的完整性和可靠性。为了消除不同特征之间的量纲差异，对数据进行如下归一化处理：

$$x'=\frac{x-x_{\min}}{x_{\max}-x_{\min}}\tag{13}$$

式中：x、x'分别为归一化前后的负荷数值；$x_{\max}$、$x_{\min}$分别为负荷的最大值和最小值。

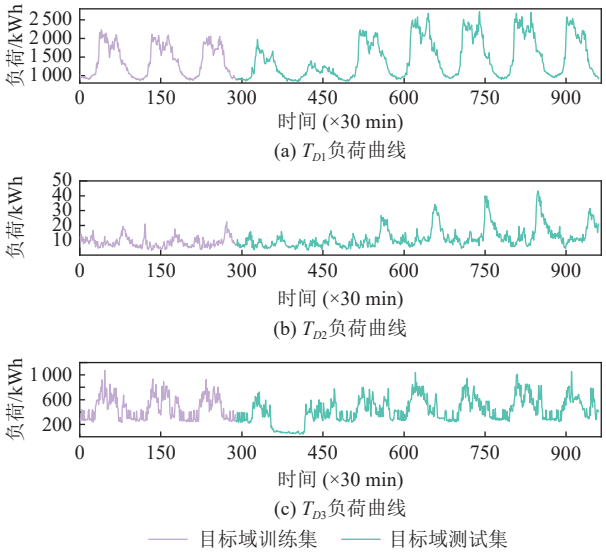


图 5　目标域负荷曲线

Fig. 5　Load curve in target domain

3.1.2　评价指标

评估回归任务性能常使用平均绝对误差（mean absolute error，MAE）、均方误差（mean-square error，MSE）、均方根误差（root mean square error，RMSE）以及平均绝对百分比误差（mean absolute percentage error，MAPE）等指标。模型预测精度随着这些指标数值的减小而提高。本文采用 MAE、MAPE、MSE 和 RMSE 这 4 个指标来度量预测模型的表现，相关公式如下：

中国知网　https://www.cnki.net

$$e_{\mathrm{MAE}}=\frac{1}{n}\sum_{i=1}^{n}|y_i-\tilde{y}_i| \tag{14}$$

$$e_{\mathrm{MAPE}}=\frac{1}{n}\sum_{i=1}^{n}\frac{|y_i-\tilde{y}_i|}{y_i}\times 100\% \tag{15}$$

$$e_{\mathrm{MSE}}=\frac{1}{n}\sum_{i=1}^{n}|y_i-\tilde{y}_i|^2 \tag{16}$$

$$e_{\mathrm{RMSE}}=\sqrt{\frac{1}{n}\sum_{i=1}^{n}|y_i-\tilde{y}_i|^2} \tag{17}$$

式中：n为样本数量；y_i为i时刻的真实值；$\tilde{y}_i$为i时刻的预测值。

3.2 负荷预测模型参数配置

3.2.1 SAO-TCN 模型参数

本文采用 SAO 算法对 TCN 模型的参数进行优化，SAO 通过迭代搜索学习率、卷积核大小和卷积核数量的参数空间，寻求最佳超参数组合，以优化 TCN 网络的超参数。TCN 模型的搜索参数及范围如表 1 所示，表中的寻优参数分别对应学习率、卷积核大小和卷积核数量，优化器设置为 adam。

表 1 SAO-TCN 模型参数及其范围

Table 1 SAO-TCN model parameters and their corresponding ranges

参数	取值
搜索个体的数量	4
最大迭代次数	50
寻优参数下限	[0.008, 2, 14]
寻优参数上限	[0.02, 6, 18]
最大训练次数	500

3.2.2 对照模型参数设置

为了验证模型的有效性，选择 TCN、LSTM、GRU 和 CNN 模型进行对比，各模型的参数设置如表 2 所示。为消除实验偏差，表 2 中所有模型优化器均设置为 adam，学习率均为 0.01，最大训练次数均为 500。

3.3 预测结果

3.3.1 基模型预测结果

为了验证 TL 是否取得正向效果，在进行 TL 之前，仅使用目标域的数据集训练一些常用的人工智能模型进行预测，这些模型被设定为基模型。

图 6(a)、(b) 分别为基模型 SAO 算法种群适应度随进化代数的变化情况和 RMSE 随训练次数的变化曲线。从图 6 可以看出，T_{D1}、T_{D2}、T_{D3}随着进化代数和训练次数的增加，损失函数值和 RMSE 都逐渐下降最后趋于稳定。其中，随着进化迭代次数的增加，T_{D3}的损失函数值最先趋于稳定，T_{D1}达到稳定时的损失函数值最小。而随着训练次数的增加，T_{D1}的 RMSE 下降最快，T_{D2}和T_{D3}的 RMSE 下降速度相近。

表 2 对照模型参数设置

Table 2 Parameter settings of the comparative model

模型	参数设置
all	优化器设置为adam，学习率为0.01，最大训练次数为500
TCN	卷积核大小为3，卷积核个数为16
LSTM	隐藏层神经元数量为256
GRU	隐藏层神经元数量为64
CNN	两个卷积层都使用3个大小为16的卷积核，采用因果填充

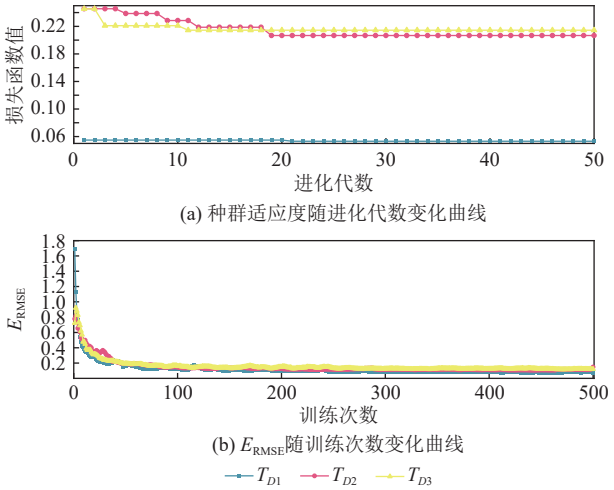


图 6 基模型 SAO 算法适应度曲线

Fig. 6 SAO algorithm fitness curve of the base model

图 7(a)、(b)、(c) 分别代表T_{D1}、T_{D2}、T_{D3}的基模型预测负荷曲线。结合图 7 和表 3 可以发现，即使在训练集样本很小的情况下，本文提出的 SAO-TCN 模型与 TCN、LSTM、GRU 和 CNN 模型相比仍具有更好的性能。其中，由于T_{D1}的负荷规律性较强，直接进行小样本预测即可得到较为理想的结果，而T_{D2}和T_{D3}负荷的波动性较强，当训练数据不足时，本文建立的模型预测性能较差，需要 TL 提高其预测精度。

从表 3 还可以看出，与次优模型 TCN 相比，在 3 个目标域T_{D1}、T_{D2}、T_{D3}中所提 SAO-TCN 模型的 4 个指标即 MAE、MAPE、MSE 和 RMSE 分别平均下降了 17%、12%、25% 以及 14%。

中国知网 https://www.cnki.net

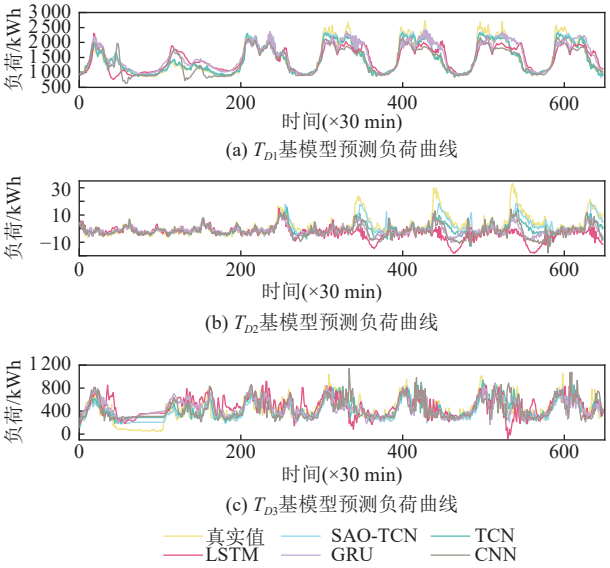


图 7　基模型预测负荷曲线

Fig. 7　Load curve of the predicted results of the base model

3.3.2　MD-MMD 方法选择源域

为了选择出有效源域进行 TL，分别使用各目标域和源域的训练集计算各源域综合得分 MD-MMD，结果如表 4 所示。

$S_{\text{MD-MMD}}$越低，对应的源域与目标域相似性越高，越适宜 TL。从表 4 可见，由所提 MD-MMD 方法得到的得分对应各目标域从低到高依次是：

$$\begin{cases} T_{D1}: S_{D1}, S_{D3}, S_{D5}, S_{D4}, S_{D2}, S_{D6} \\ T_{D2}: S_{D6}, S_{D2}, S_{D3}, S_{D1}, S_{D5}, S_{D4} \\ T_{D3}: S_{D6}, S_{D3}, S_{D2}, S_{D1}, S_{D5}, S_{D4} \end{cases} \tag{18}$$

图 8 是各源域对应目标域归一化后的S_{MD}、S_{MMD}以及$S_{\text{MD-MMD}}$。从图 8 可以看出，3 种方法得出的对应TD_1的最佳迁移源域分别是$\{S_{D5}, S_{D6}, S_{D6}\}$，对应$TD_2$最佳迁移源域分别是$\{S_{D3}, S_{D2}, S_{D6}\}$，对应$TD_3$最佳迁移源域分别是$\{S_{D1}, S_{D6}, S_{D6}\}$。而 3 种方法对应的相似性较弱的迁移源域基本一致，仅排序略有差异，对应T_{D1}, T_{D2}, T_{D3}较差迁移源域分别是$\{S_{D2}, S_{D6}\}$, $\{S_{D4}, S_{D5}\}$, $\{S_{D4}, S_{D5}\}$。

3.3.3　TL 预测结果

表 5 是基于 SAO-TCN 模型各源域对应 3 个目标域的 TL 结果，从表 5 可以看出，对应目标域T_{D1}, T_{D2}, T_{D3}的最佳迁移源域分别是$\{S_{D3}, S_{D6}, S_{D6}\}$，就判断最佳迁移源域而言，MD、MMD 和

表 3　基模型预测结果

Table 3　Prediction results of the base model

目标域	基模型	SAO-TCN	TCN	LSTM	GRU	CNN
TD_1	MAE	**78.59**	89.91	236.93	188.92	175.61
	MAPE/%	**5.31%**	6.08%	16.01%	12.77%	11.87%
	MSE	**14521.14**	17512.34	94282.86	62030.03	59347.95
	RMSE	**120.50**	132.33	307.06	249.06	243.61
TD_2	MAE	**2.50**	3.57	6.64	4.72	4.93
	MAPE/%	**20.67%**	29.60%	55.01%	39.08%	40.84%
	MSE	**15.46**	28.80	102.73	49.42	52.76
	RMSE	**3.93**	5.37	10.14	7.03	7.26
TD_3	MAE	**92.35**	101.26	143.24	121.56	131.72
	MAPE/%	**21.45%**	23.52%	33.26%	58.94%	30.59%
	MSE	**13949.98**	16194.23	33620.68	24553.61	29164.69
	RMSE	**118.11**	127.26	183.36	156.69	170.78

注：最佳性能加黑表示。

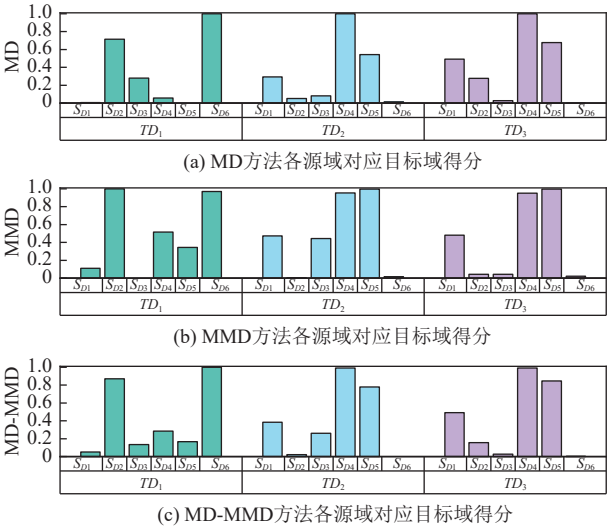
表 4　各源域对应 3 个目标域的$S_{\text{MD-MMD}}$

Table 4　$S_{\text{MD-MMD}}$ values of the three target domains corresponding to each source domain

$S_{\text{MD-MMD}}$	SD_1	SD_2	SD_3	SD_4	SD_5	SD_6
TD_1	**0.0570**	0.8571	0.1392	0.2853	0.1718	0.9846
TD_2	0.3832	0.0292	0.2626	0.9765	0.7692	**0.0084**
TD_3	0.4874	0.1598	0.0352	0.9756	0.8357	**0.0113**

注：最佳性能加黑表示。

中国知网　https://www.cnki.net



(a) MD方法各源域对应目标域得分

(b) MMD方法各源域对应目标域得分

(c) MD-MMD方法各源域对应目标域得分

图 8 3 种方式各源域对应目标域得分

Fig. 8 Score of each source domain corresponding to the target domain in the three ways

表 5 SAO-TCN 经 TL 预测结果

Table 5 Predicted results of SAO-TCN by TL

目标域	源域	MAE	MAPE	MSE	RMSE
T_{D1}	S_{D1}	77.84	5.26%	14021.27	118.41
	S_{D2}	85.66	5.79%	14913.26	122.12
	S_{D3}	**72.56**	**4.90%**	**12678.21**	**112.60**
	S_{D4}	86.38	5.84%	14935.10	122.21
	S_{D5}	73.80	4.99%	13585.30	116.56
	S_{D6}	81.22	5.49%	17725.58	133.14
TD_2	S_{D1}	2.12	17.58%	8.05	2.84
	S_{D2}	2.07	17.13%	7.69	2.77
	S_{D3}	1.99	16.46%	7.51	2.74
	S_{D4}	2.58	21.34%	11.82	3.44
	S_{D5}	2.08	17.25%	7.77	2.79
	S_{D6}	**1.97**	**16.34%**	**7.22**	**2.69**
T_{D3}	S_{D1}	79.49	18.46%	11246.54	106.05
	S_{D2}	79.82	18.54%	11148.55	105.59
	S_{D3}	76.02	17.65%	10669.36	103.29
	S_{D4}	95.52	22.18%	16106.66	126.91
	S_{D5}	80.79	18.76%	12213.07	110.51
	S_{D6}	**73.13**	**16.98%**	**10252.84**	**101.26**

注：最佳性能加粗表示。

MD-MMD 三种方法都预测正确两个，为进一步探究三种方法预测的准确性，将基模型预测结果也加入进行对比。

综合表 3、表 4 和表 5，以$S_{\text{MD-MMD}}$最低为最为佳迁移源域，对应目标域T_{D1},T_{D2},T_{D3}分别是$\{T_{D1},T_{D6},T_{D6}\}$相较于传统不进行迁移学习的机器学习方法，其预测结果可平均降低 14% 的均方根误差。

图 9 是 MD、MMD 和 MD-MMD 三种方法对应 3 个目标域的 6 个源域得分图排序，其中绿色表示正向迁移，颜色越深则表示迁移效果越好；红色代表负向迁移，颜色越深则表示迁移效果越差。从图 9 可以看出，3 种方法对各源域和各目标域相似性判断情况，对于T_{D1}，MD 的相似性判断效果较差，MMD 和 MD-MMD 两种方法相似性判断效果较为接近且都比较准确；对于T_{D2}，MMD 的相似性判断效果较差，MD 和 MD-MMD 两种方法相似性判断效果较为接近且都比较准确；对于T_{D3}，MMD 的相似性判断效果略差，MD 和 MD-MMD 两种方法相似性判断效果较为接近且都比较准确。综上所述，通过实验证明，MD-MMD 方法成功地融合了 MD 和 MMD 的优点，能更准确地判断源域和目标域之间相似性，提升 TL 负荷预测效果。

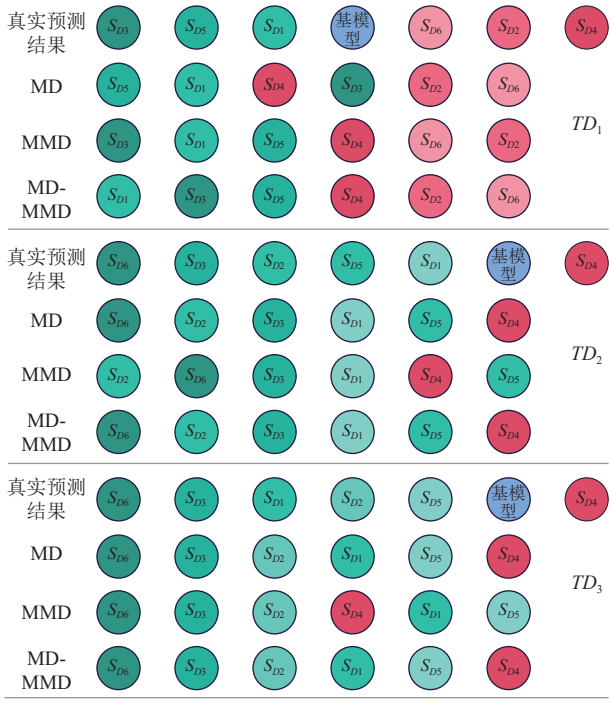


图 9 3 种方式源域与目标域相似性得分

Fig. 9 Similarity scores of source domains and target domains in three ways

4 结论

本文针对数据稀缺情况下的 STLF 问题，提

中国知网 https://www.cnki.net

出一种 MD-MMD-SAO-TCN-TL 的混合模型。利用实际数据集对所提混合预测模型的有效性和优越性进行验证，得到如下结论：

1）利用 SAO 对 TCN 模型的超参数进行优化，能够有效提高 TCN 模型的准确性与泛化能力，在 3 个目标域单独预测中，相较于 TCN 模型，SAO-TCN 模型预测结果可降低至少 10% 的均方根误差。

2）在迁移学习前，构建一种基于 MD-MMD 的源域选择方法，能够筛选出与目标域高度相似的源域，与单一源域选择方法（MD、MMD）相比，能综合考虑数据间距离和特征分布差异性，增加了源域选择的范围与准确性。

3）所提混合模型通过源域筛选和模型迁移的方法，有效解决了数据稀缺情况下的 STLF 问题，相较于传统不进行迁移学习的机器学习方法，其预测结果可平均降低 14% 的均方根误差。

（本刊附录请见网络版，印刷版略）

参考文献

[1] 李晖, 刘栋, 姚丹阳. 面向碳达峰碳中和目标的我国电力系统发展研判 [J]. 中国电机工程学报, 2021, 41(18): 6245−6259.
LI Hui, LIU Dong, YAO Danyang. Analysis and reflection on the development of power system towards the goal of carbon emission peak and carbon neutrality[J]. Proceedings of the CSEE, 2021, 41(18): 6245−6259(in Chinese).

[2] 韩肖清, 李廷钧, 张东霞, 等. 双碳目标下的新型电力系统规划新问题及关键技术 [J]. 高电压技术, 2021, 47(9): 3036−3046.
HAN Xiaoqing, LI Tingjun, ZHANG Dongxia, *et al*. New issues and key technologies of new power system planning under double carbon goals[J]. High Voltage Engineering, 2021, 47(9): 3036−3046(in Chinese).

[3] 韩富佳, 王晓辉, 乔骥, 等. 基于人工智能技术的新型电力系统负荷预测研究综述 [J]. 中国电机工程学报, 2023, 43(22): 8569−8592.
HAN Fujia, WANG Xiaohui, QIAO Ji, *et al*. Review on artificial intelligence based load forecasting research for the new-type power system[J]. Proceedings of the CSEE, 2023, 43(22): 8569−8592(in Chinese).

[4] MA Shaohui. A hybrid deep meta-ensemble networks with application in electric utility industry load forecasting[J]. Information Sciences, 2021, 544: 183−196.

[5] ABDEL-BASSET M, HAWASH H, SALLAM K, *et al*. STLF-Net: Two-stream deep network for short-term load forecasting in residential buildings[J]. Journal of King Saud University - Computer and Information Sciences, 2022, 34(7): 4296−4311.

[6] YE R, DAI Q. A relationship-aligned transfer learning algorithm for time series forecasting[J]. Information Sciences, 2022, 593: 17−34.

[7] LIU J, WANG S, WEI N, *et al*. Natural gas consumption forecasting: A discussion on forecasting history and future challenges[J]. Journal of Natural Gas Science and Engineering, 2021, 90: 103930.

[8] 邓带雨, 李坚, 张真源, 等. 基于 EEMD-GRU-MLR 的短期电力负荷预测 [J]. 电网技术, 2020, 44(2): 593−602.
DENG Daiyu, LI Jian, ZHANG Zhenyuan, *et al*. Short-term electric load forecasting based on EEMD-GRU-MLR[J]. Power System Technology, 2020, 44(2): 593−602(in Chinese).

[9] 徐晶, 迟福建, 葛磊蛟, 等. 基于 SARIMA-GRNN-SVM 的短期商业电力负荷组合预测方法 [J]. 电力系统及其自动化学报, 2020, 32(2): 85−91.
XU Jing, CHI Fujian, GE Leijiao, *et al*. Short-term combined commercial load forecasting method based on SARIMA-GRNN-SVMM[J]. Proceedings of the CSU-EPSA, 2020, 32(2): 85−91(in Chinese).

[10] 麦鸿坤, 肖坚红, 吴熙辰, 等. 基于 R 语言的负荷预测 ARIMA 模型并行化研究 [J]. 电网技术, 2015, 39(11): 3216−3220.
MAI Hongkun, XIAO Jianhong, WU Xichen, *et al*. Research on ARIMA model parallelization in load prediction based on R language[J]. Power System Technology, 2015, 39(11): 3216−3220(in Chinese).

[11] MANANDHAR P, RAFIQ H, RODRIGUEZ-UBINAS E. Current status, challenges, and prospects of data-driven urban energy modeling: A review of machine learning methods[J]. Energy Reports, 2023, 9: 2757−2776.

[12] 黄飞虎, 赵红磊, 弋沛玉, 等. 一种改进 Transformer 的电力负荷预测方法 [J]. 现代电力, 2023, 40(1): 50−58.
HUANG Feihu, ZHAO Honglei, YI Peiyu, *et al*. An improved power load forecasting method based on transformer[J]. Modern Electric Power, 2023, 40(1): 50−58(in Chinese).

[13] 赵佩, 代业明. 基于实时电价和加权灰色关联投影的 SVM 电力负荷预测 [J]. 电网技术, 2020, 44(4): 1325−1332.
ZHAO Pei, Dai Yeming. Power load forecasting of SVM based on real-time price and weighted grey relational projection algorithm[J]. Power System Technology, 2020, 44(4): 1325−1332(in Chinese).

[14] 唐贤伦, 陈洪旭, 熊德意, 等. 基于极端梯度提升和时间卷积网络的短期电力负荷预测 [J]. 高电压技术, 2022,

中国知网　https://www.cnki.net

48(8): 3059−3067.
TANG Xianlun, CHEN Hongxu, XIONG Deyi, *et al*. Short-term power load forecasting based on extreme gradient boosting and temporal convolutional network[J]. High Voltage Engineering, 2022, 48(8): 3059−3067(in Chinese).

[15] 张林, 赖向平, 仲书勇, 等. 基于正交小波和长短期记忆神经网络的用电负荷预测方法 [J]. 现代电力, 2022, 39(1): 72−79.
ZHANG Lin, LAI Xiangping, ZHONG Shuyong, *et al*. Electricity load forecasting method based on orthogonal wavelet and long short-term memory neural networks[J]. Modern Electric Power, 2022, 39(1): 72−79(in Chinese).

[16] WAN A, CHANG Q, AL-BUKHAITI K, *et al*. Short-term power load forecasting for combined heat and power using CNN-LSTM enhanced by attention mechanism[J]. Energy, 2023, 282: 128274.

[17] HUA G, SUN Y, LI W. Hybrid load prediction model of 5G base station based on time series decomposition and GRU network with parameter optimization[J]. IET Generation, Transmission & Distribution, 2024, 18(8): 1548-1558.

[18] BAI S, KOLTER J Z, KOLTUN V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[A]. arXiv, 2018.

[19] LU J, BEHBOOD V, HAO P, *et al*. Transfer learning using computational intelligence: a survey[J]. Knowledge-Based Systems, 2015, 80: 14−23.

[20] JUNG S M, PARK S, JUNG S W, *et al*. Monthly electric load forecasting using transfer learning for smart cities[J]. Sustainability, 2020, 12(16): 6364.

[21] 欧阳福莲, 王俊, 周杭霞. 基于改进迁移学习和多尺度 CNN-BiLSTM-Attention 的短期电力负荷预测方法 [J]. 电力系统保护与控制, 2023, 51(2): 132−140.
OUYANG Fulian, WANG Jun, ZHOU Hangxia. Short-term power load forecasting method based on improved hierarchical transfer learning and multi-scale CNN-BiLSTM-Attention[J]. Power System Protection and Control, 2023, 51(2): 132−140(in Chinese).

[22] WEI N, YIN C, YIN L, *et al*. Short-term load forecasting based on WM algorithm and transfer learning model[J]. Applied Energy, 2024, 353: 122087.

[23] WANG K, YU H, SONG G, *et al*. Adaptive forecasting of diverse electrical and heating loads in community integrated energy system based on deep transfer learning[J]. Frontiers in Energy Research, 2022, 10: 1008216.

[24] ZHOU Y, LI X, LIU Y, *et al*. Transfer learning-based adaptive recursive neural network for short-term non-stationary building heating load prediction[J]. Journal of Building Engineering, 2023, 76: 107271.

[25] LÓPEZ SANTOS M, DÍAZ GARCÍA S, GARCÍA-SANTIAGO X, *et al*. Deep learning and transfer learning techniques applied to short-term load forecasting of data-poor buildings in local energy communities[J]. Energy and Buildings, 2023, 292: 113164.

[26] DE MAESSCHALCK R, JOUAN-RIMBAUD D, MASSART D L. The Mahalanobis distance[J]. Chemometrics and Intelligent Laboratory Systems, 2000, 50(1): 1−18.

[27] DENG L, LIU S. Snow ablation optimizer: A novel metaheuristic technique for numerical optimization and engineering design[J]. Expert Systems With Applications, 2023, 225: 120069.

[28] 姜海燕, 刘昊天, 舒欣, 等. 基于最大均值差异的多标记迁移学习算法 [J]. 信息与控制, 2016, 45(4): 463−470.
JIANG Haiyan, LIU Haotian, SHU Xin, *et al*. Multi-label transfer learning via maximum mean discrepancy[J]. Information and Control, 2016, 45(4): 463−470(in Chinese).

[29] XUE H, GUI X, WANG G, *et al*. Prediction of gas drainage changes from nitrogen replacement: a study of a TCN deep learning model with integrated attention mechanism[J]. Fuel, 2024, 357: 129797.

[30] LU R, BAI R, LI R, *et al*. A novel sequence-to-sequence-based deep learning model for multistep load forecasting[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024: 1-15.

[31] GENG G, HE Y, ZHANG J, *et al*. Short-term power load forecasting based on PSO-optimized VMD-TCN-attention mechanism[J]. Energies, 2023, 16(12): 4616.

[32] ZHANG B, WANG S, DENG L, *et al*. Ship motion attitude prediction model based on IWOA-TCN-Attention[J]. Ocean Engineering, 2023, 272: 113911.

收稿日期：2024−03−26

作者简介：

罗同桐 (2000)，女，硕士研究生，研究方向为人工智能和负荷预测，E-mail：luotongtong@stu.scu.edu.cn；

唐志远 (1992)，男，博士，副研究员，通信作者，研究方向为电力系统控制及规划运行、分布式控制及优化，E-mail：tangzhiyuan@scu.edu.cn；

唐義坤 (1997)，男，硕士研究生，研究方向为机器学习和负荷预测，E-mail：tangyikun@stu.scu.edu.cn；

刘俊勇 (1963)，男，博士，教授，研究方向为电力市场、智能配电网、电力系统大数据技术、电动汽车，E-mail：liujy@scu.edu.cn。

中国知网 https://www.cnki.net