分类号：TM715　　单位代码：10220

密　　级：



东北石油大学

NORTHEAST PETROLEUM UNIVERSITY

专业学位研究生学位论文

学位类别：工程硕士（电气工程）

论文题目：基于深度学习和迁移学习的短期电力负荷预测

学生姓名：万成德

校内导师：姜建国　教授

校外导师：李天舒　高级工程师

论文类型：应用研究

研究方向：电力系统及其自动化

学习方式：■全日制　□非全日制

入学时间：2019 年 9 月　　论文完成时间：2022 年 4 月

中国知网　https://www.cnki.net

Short-term load forecasting based on deep learning and transfer learning

by Wan Chengde

Supervisor: Professor Jiang Jianguo

Pluralistic Supervisor: Senior Engineer Li Tianshu



A Thesis Submitted to the Northeast Petroleum University

In partial fulfillment of the requirement

For the Professional Master of Engineering *Electrical Engineering*

Full-time

April, 2022

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

基于深度学习和迁移学习的短期电力负荷预测

摘　要

电力负荷预测是电力系统高效、稳定运行的重要基石，同时也是现代电力管理系统的重要组成部分。精准的电力负荷预测不仅可以增强电力系统运行的安全性与稳定性，同时还能减少电力系统运行成本。然而，在对某些区域进行负荷预测时，由于不可控因素的影响，电力负荷历史数据出现数据缺失或存储不足的现象，导致经典深度学习预测方法无法实现高精度的短期负荷预测。因此，本文借助迁移的思想，提出一种基于迁移电力负荷数据或预测模型参数的预测方法，解决历史数据匮乏时短期负荷预测精度低的问题。

在实验数据充足的区域，建立 1DCNN-LSTM 短期负荷预测网络，充分挖掘气候信息、日期信息与电力负荷之间的关系，利用 1DCNN 网络能有效处理一维数据和在特征提取上的优势以及 LSTM 网络在长时序中能有效避免梯度爆炸和梯度消失的优势，建立短期负荷预测网络。以美国某区域电力负荷数据作为实验对象，展开实验，实验结果表明，所提出的 1DCNN-LSTM 短期负荷预测网络精度较高，实验结果符合预期设想。

针对目的域电力负荷历史数据缺失或本身存储数量较少的情况，提出一种基于迁移相似域电力负荷历史数据的预测方法。在选定目的域的前提上，依据关联度选择合适的源域；为补充目的域数据，选择从源域迁移电力负荷数据，同时为了达到最好的预测效果，分别迁移不同数据量对目的域进行补充；以美国某九州的电力负荷历史数据为实验对象，对目的域分别迁移源域三、六、九个月电力负荷数据。实验结果表明，迁移电力负荷数据可以实现目的域数据少时对短期电力负荷预测的需求，且迁移数据量为六个月时预测精度最高。

区别于迁移源域电力负荷数据，选择迁移源域训练完毕的预测模型参数，建立目的域的预测模型。与电力负荷数据迁移相同，迁移模型参数首先需要在目的域确定的情况下，依据关联度选择合适的源域，然后将源域训练完毕的模型参数迁移至目的域模型，为取得最好的预测效果，对其预测网络进行冻结和微调，最后以美国某区域电力负荷数据为实验对象，采用迁移甄选后的相似度最高的区域负荷预测模型参数的方法进行负荷预测实验，实验结果表明，该方法能有效解决目的域数据少时短期电力负荷预测困难的问题，预测精度能有效接近于源域模型预测精度甚至优于源域预测精度。

关键词：负荷预测，深度学习，迁移学习，一维卷积神经网络，长短期记忆网络

中国知网 https://www.cnki.net

Short-term Power Load Forecasting Based on Deep Learning and Transfer Learning

ABSTRACT

Power load forecasting is an important cornerstone of efficient and stable operation of power system, and also an important part of modern power management system. Accurate power load forecasting can not only enhance the safety and stability of power system operation, but also reduce the cost of power system operation. However, in some areas of load forecasting, due to the influence of uncontrollable factors, the historical data of power load is missing or insufficiently stored, resulting in the classical deep learning prediction method can not achieve high-precision short-term load forecasting. Therefore, based on the idea of transfer, this paper proposes a prediction method based on the transfer of power load data or prediction model parameters to solve the problem of low accuracy of short-term load forecasting when historical data is scarce.

In the region with sufficient experimental data, 1DCNN-LSTM short-term load forecasting network is established to fully tap the relationship between climate information, date information and power load. 1DCNN network can effectively deal with one-dimensional data and its advantages in feature extraction, and LSTM network can effectively avoid gradient explosion and gradient disappearance in long time series, so as to establish short-term load forecasting network. The experimental results show that the proposed 1DCNN-LSTM short-term load forecasting network has high accuracy, and the experimental results meet the expected expectations.

Aiming at the situation that the historical data of power load in the target domain is missing or the number of its own storage is small, a prediction method based on the historical data of power load in the migration similar domain is proposed. On the premise of selecting the target domain, the appropriate source domain is selected according to the correlation degree ; in order to supplement the target domain data, the power load data are migrated from the source domain, and in order to achieve the best prediction effect, different data volumes are migrated to supplement the target domain. Taking the power load historical data of a nine-state in the United States as the experimental object, the three-month, six-month and nine-month power load data of the source domain are migrated respectively. The experimental results show that the migration of power load data can achieve the demand for short-term power load forecasting when the target domain data are few, and the prediction accuracy is the highest when the migration data amount is six months.

中国知网 https://www.cnki.net

Different from the power load data in the migration source domain, the prediction model parameters are selected to establish the prediction model in the destination domain. Similar to the transfer of power load data, the transfer model parameters need to select the appropriate source domain according to the correlation degree when the target domain is determined, and then the model parameters trained in the source domain are transferred to the target domain model. In order to obtain the best prediction effect, the prediction network is frozen and fine-tuned. Finally, taking a regional power load data in the United States as the experimental object, the load forecasting experiment is carried out by using the method of transfer and selection of the regional load forecasting model parameters with the highest similarity. The experimental results show that the method can effectively solve the problem of short-term power load forecasting with less target domain data, and the prediction accuracy can be effectively close to the source domain model prediction accuracy or even better than the source domain prediction accuracy.

Keywords: load forecasting, deep learning, transfer learning, one-dinebsional conv olutional neural networks, long and short-term memory networks

中国知网 https://www.cnki.net

目 录

学位论文独创性声明.....I
学位论文使用授权声明.....I
摘 要.....I
ABSTRACT.....III
目 录.....V
第一章 绪 论.....1
1.1 研究背景与研究意义.....1
1.2 国内外研究现状.....3
1.2.1 基于人工智能的负荷预测方法.....3
1.2.2 基于迁移学习的负荷预测.....4
1.3 本论文的主要研究工作.....6
1.3.1 主要研究内容及方法.....6
1.3.2 论文结构.....6
第二章 电力负荷预测基本理论.....8
2.1 引言.....8
2.2 电力负荷预测的基本分类.....8
2.3 电力负荷的特性.....9
2.4 影响电力负荷的因素.....10
2.5 负荷预测的原理.....11
2.6 负荷预测的误差分析.....12
2.7 负荷预测的基本步骤.....13
2.8 本章小结.....14
第三章 数据预处理.....15
3.1 引言.....15
3.2 原始数据.....15
3.3 数据处理.....15
3.3.1 缺失数据的补充.....15
3.3.2 异常数据的识别和修正.....16
3.3.3 数据量化.....16
3.4 本章小结.....17
第四章 基于一维卷积-长短期记忆网络的短期电力负荷预测.....18

中国知网 https://www.cnki.net

4.1 引言 18
4.2 卷积神经 18
4.2.1 卷积神经网络基本概念 18
4.2.2 卷积神经网络特点 18
4.2.3 卷积神经网络结构 20
4.2.4 一维卷积神经网络 21
4.3 长短期记忆网络基本理论 21
4.4 模型预测 24
4.5 本章小结 29
第五章 基于深度学习和迁移学习的短期电力负荷预测 31
5.1 引言 31
5.1.1 迁移学习的基本概念 31
5.1.2 迁移学习的目的 32
5.1.3 迁移学习的基本分类 32
5.1.4 迁移学习的方法 33
5.1.5 负迁移 34
5.2 基于电力负荷数据迁移的短期电力负荷预测 35
5.3 基于网络参数迁移的短期电力负荷预测 38
5.4 本章小结 43
总结与展望 45
参考文献 47
作者简介、发表文章及研究成果目录 51
致 谢 52

中国知网 https://www.cnki.net

第一章 绪 论

1.1 研究背景与研究意义

电力行业是保障人们正常生活的基础性行业，同时也把握着国家命脉。如今，经济蓬勃发展，社会对电力的需求也在逐年增加，能源危机也在逐步逼近。如何保障能源的可靠性、安全性、稳定性、高效性也成为各种发展战略的关键所在，为此应当在供给侧保障能源的可靠性；在用户侧保障能源的高效利用。为了达成这一目标，需要制定科学、合理的运营计划和调度计划，由于电力负荷本身的性质，无法长时间大量储存，需要现发现用，所以精确的负荷预测是制定计划的前提条件。

在当下电网架构体系中，如果想要做到真正的经济高效，那么就不可能避开负荷预测这个话题，只有对电力负荷需求进行精准的预测，才能从源头上降低电力系统的运营成本，达到经济高效[1]。早在 20 世纪 80 年代，就有研究者认为：英国的日均负荷预测误差，只要增加百分之一即代表英国每年的电力成本将增加千亿英镑以上[2]。这一规律后来也应用于中国，举个简单的例子，首先假定中国中西部的一个省级电网，每日的人均用电负荷总量约在 4500MW 左右，如果能有效提升其日负荷预测精度，当该电网满负载发电时，预测精度每提升 1%，就可以有效减少 45MW 的旋转备用容量，在经济上，将直接带来 2000 万元/年的经济效益[3]；而当该电网不是满功率发电时，同样可以采取相应对策，诸如减少非计划限电，增加售电量[4]等。此外，在电力系统规划调度、电力市场交易、电网安全预警等领域，电力负荷预测也扮演着重要角色。高精度的电力负荷预测能极大程度上降低电力系统中由于负荷匮乏所导致发生安全事故的发生，每次电力负荷匮乏所引起的事故都会对人们的日常生活、工业生产等造成巨大影响，由此显现电力负荷预测在电力生产中的重要程度。

电能的需求量随着工业化的飞速增长而上升，人们正常生活离不开电能，工业发展和国民经济的增长都离不开电能[5]，为此，电力系统需要给予用户提供安全、可靠的电能，并且需要保障用户在不同时刻、不同场景下的各种用电需求。但是，现实生活中，电力短缺现象在某些地区发生频率升高，以至于为了保证基本用电，不得已采取限电的方法来维系，这也大大的影响了当地居民的日常生活和当地企业的发展，因此对高精度电力负荷预测的需求也越来越迫切[6]。电力系统负荷预测既能为电网规划提供科学依据，又能保证电网的安全和经济运行。在这一基础上，电力负荷预测切合社会可持续发展的价值观，立足于能源的最大化利用，从根本上实现资源的最大化利用。总的来说，人们对电力负荷的需求伴随着人们生活质量的提升也会逐步增大，对负荷需求进行高精度的预测的重要性也就愈发凸显。

目前正在运行的电网常规上有发电、输电、变电、配电、用电等五个主要组成部分，但随着供电范围增加、供电的规模变大、运行设施数量增加、运营持续时间变长，其运

中国知网 https://www.cnki.net

营的复杂程度也会越高[7]。而在电网长期的运营过程中，伴随着运营规模、参与设备数量的增加，将形成大量潜藏着丰富信息的历史数据。从这些数据中，研究人员能够更深入发现所蕴含的信息，进而通过这种信息来实现更精确的负荷预测。不过，由于电力负荷本身受到气候、日期等复杂因素的影响，所以，怎样发掘有用的信息依然是一道亟待解决的难题。

电能不同于其他市场上的商品，它具有极大的特殊性：存储难度和存储成本极高。也正是由于这一特性，导致人们不会花费巨大的成本去存储电能，所以对于电能，最优的情况就是发多少，用多少。当然这一做法略显被动，用多少，发多少则成为电力部门所期许的。当电力部门能准确做到对负荷的精准预估，就可以精确把控该区域发电工作，从而减少资源浪费，节约电能生产成本，由此不难发现，高精度的负荷预测在电力工作中的重要性。

目前电力负荷数据的采集仍然是依赖于电表这一设备，传统的老式电表需要人工抄表，而随着智能电表（Smart Meters，SM）的出现，进一步减少了人工抄表时可能出现的误差，使得采集的数据更为准确，而伴随着智能云端等一系列产品加入电网运营当中，数据采集、存储也更为精确、便捷。

尽管采集设备已经经历过各种升级换代，但考虑现实因素，已知的电力负荷数据可能由于各种原因，发生数据缺失的现象。而智能预测方法则需要完备的历史数据，这一现象的出现使得智能预测法将无法顺利的完成预测工作。如何解决这一问题，需要学者继续研究以提出新且有效的解决方法。

进行电力负荷短期预测有诸多意义，主要有以下几点：

1. 进行准确的电力负荷预测，不仅可以协助电力部门制定最为科学、合理的发电机组启停计划，还可以在很大程度上可以降低当地发电厂的成本，并对发电机组的维修工作提出指导意见。

2. 火力发电会对环境产生不可避免的污染，即使现在在发电过程中采用各种方式来尽可能地减少污染，但仍有部分污染无法避免。进行电力负荷预测可以合理规划、调整发电计划，来减少火电厂造成的污染，符合能源可持续发展的战略目的。

3. 对于某地区的电力负荷预测的结果，经电力相关部门分析后，对当地的各项工作均有指导性意义。

4. 由于负荷会随机发生变化以及电能发、输、配、用环节中各种设备的突发性故障，使能源供需端情况不断变化，供需情况的转变在供给端直观的表现就是发电所需的成本改变，而在用户端的表现则是用电所需的每一度电所需要的费用不再是一个固定值。针对这一情况，电力市场推出了分时电价的政策：用电高峰期的单价电的价格高于低谷期的单价电的价格，希望用户能合理安排他们的用电时间，能在低谷期多用电，高峰期少用电。而为了实现这一期盼，需要电力部门能提前预测出当天用电的高峰期和低谷期，

中国知网 https://www.cnki.net

为用户合理安排其用电时间提供基本条件[8]。

5. 电价是电力市场的核心内容，也是用户对电力销售最直观的了解。为了合理、科学的制定电价，无可避免的需要了解该时段电力生产所需要的成本以及该时段用户侧所消耗的电能，只有提前预测出该时段用户所需电量，才可以利益最大化地制定实时电价。

1.2 国内外研究现状

世界经济早在上个世纪六十年代就进入高速发展的阶段，其中部分发达国家对电力地需求也越来越高，人们开始思索如何高效、经济地发电，这个时候人们迫切的需要高精度的电力负荷预测[9]。随着人们对这一领域的逐步探索，在短期电力负荷领域中，依次出现了三种较为典型的预测方法，分别是初期的经典预测法，中期的传统预测法，以及现阶段仍在不断研究的智能预测法，这三种方法也代表了人们在短期电力负荷预测这个领域中研究发展的三个阶段。

在电力负荷预测初期阶段，人们借助于早期天气预测的经验，大多采用图表和个人经验对负荷进行预测[10]。其中，查表法就是一个典型的代表，使用者依据抄录下来的电力负荷历史数据以及气象信息，制表绘图，从而对电力负荷进行短期预测。经典预测法所使用的手段大多还是以基础数学工具为主，被人们所熟知的有：回归分析法、趋势外推法、时间序列法等。其中回归分析法主要对历史数据进行分析，发现其中暗藏的关系，建立自变量和因变量之间的数学联系[11]，从而将联系具体化。数学联系分为线性和非线性回归，由于自变量可能不唯一，又分为一元回归和多元回归。在数学方程确定后，用分析得来的数据预测未来某时刻的电力负荷。回归分析法的计算原理简洁、清晰且构造简洁，因此计算的速度快，不过由于该方法所建立的模式泛化能力较差，因此无法在复杂情形下对电力负荷做出准确预测。

在现阶段，随着人们在人工智能领域的不断深入，将人工智能用于负荷预测也成了许多学者研究的课题，诸如将无迹卡尔曼、小波网络、神经网络与负荷预测结合在一起，自此，短期负荷预测也进入了新篇章。而在实际分析过程中，人们发现现实情况复杂多变，无法简单地用单一的方法进行预测，于是将多种方法有机结合变成了新的突破口，试图合理地发挥每种方法的优势，以求得到一种高精度的负荷预测方法。由于本文采用将深度学习和迁移学习相结合进行短期负荷预测的方法，下面简要概述这类方法的研究现状。

1.2.1 基于人工智能的负荷预测方法

为了提高电力系统的安全性、可靠性、经济性，维持电力系统的高效运行，提高短期电力负荷预测精度成为许多研究人员的首选方法[12]。随着时代的进步，电力负荷的影响因素也越来越复杂，负荷与影响因素之间不再呈简单的线性相关，在时间上，单纯的使用时间序列对电力负荷进行预测也显得十分吃力，随后为了应对复杂多变的各类影响

中国知网 https://www.cnki.net

因素，学者们开始着眼于将人工智能应用于负荷预测领域，近些年来，随着计算机技术的突飞猛增，利用人工智能处理挖掘数据也愈发成熟，在机器学习中，以时间为序列，使用卷积神经网络（Convolutional Neural Network，CNN），构建短期负荷预测模型，成为学者们研究的典型，在许多行业的预测问题中也取得了较高的预测精度[13]。在目前研究阶段，支持向量机（Support Vector Machine，SVM）和神经网络等已经较为成熟，能较好的处理电力负荷预测中的非线性问题[14]。但是，当电力负荷数据集中的数据量过大时，使用支持向量机方法的预测效果将不在理想，而此时使用卷积神经网络则可以很好应对大规模数据中的非线性问题，因此，在处理庞大数据集进行短期符合预测时，卷积神经网络成为众多学者的优先选择[15]。

文献[16,17]利用卷积神经网络提取负荷数据特征，从而进行电力负荷预测，该方法在处理非线性序列电力负荷数据时效果较好。当数据集中的负荷数据陡度较大，有明显的不稳定性时，使用单一的 CNN 模型进行预测将无法取得良好的效果。文献[18]提出一种新的神经网络，即长短期记忆神经网络（Long Short-Term Memory，LSTM），使用该网络可以有效提取电力负荷数据时序特征。文献[19]通过建立融合了卷积神经与长短期记忆网络的预测模型，该模型能有效利用卷积神经网络进行特征提取以及长短期记忆网络的时序特性，最后解决了在长短期记忆网络中当输入时序过长所导致预测精度下降的问题。文献[20]研究在城市中，不同类型的电力负荷如何进行有效预测。文献[21]将 CNN，LSTM，CNN-LSTM 进行对比，实验结果表明 CNN-LSTM 模型在训练速度和拟合效果均优于其他两种网络。

长短期记忆网络在处理时间序列时有着良好的效果，但是当输入时间序列过长时，会出现信息丢失的情况，从而对预测精度造成影响。本文针对长短期记忆神经网络存在的问题，使用卷积神经网络对负荷特征进行提取和对时间进行压缩，从而保证在使用长短期记忆网络时信息的完整度，在很大程度上解决了单纯使用 LSTM 网络进行负荷预测时，会由于输入序列过长所导致的丢失序列信息的问题。

然而，上述预测方法仅适用于具有完备电力负荷数据集的情况下，也就是有着充足的电力负荷历史数据和相关信息。但是，在实际研究过程中，往往会出现各种问题，最终导致电力负荷数据出现缺失。正如大家所熟知的，电力负荷数据的完整度与最终负荷预测结果的精度息息相关，历史数据的缺失将对负荷预测的精准度造成极大的影响，甚至当数据缺失严重时，以上方法都无法顺利进行预测。针对这一问题，需要进一步展开研究，提出有效的解决方法。

1.2.2 基于迁移学习的负荷预测

迁移学习（Transfer learning）的核心思想是利用以前解决问题时所学会的“知识”来解决一个与之前问题相似问题，具体实施方法是将某一领域（即源域）的“知识”转

中国知网 https://www.cnki.net

移到其他领域（即目标域）[22]，从而对目标域解决问题提供帮助。

由于迁移学习能较好的处理小数据场景，因此，在图像分类、自然语言识别、AI 人机交互以及分类问题上被人们广泛使用[23-28]。但是，将迁移学习与人工智能负荷预测相结合的案例相对较少，可供学习的研究成果也相对匮乏，而且这类方法依然存在不少问题亟待解决，如源域与目标域的匹配性问题，当源域和目标域匹配性较差时，可能会出现负迁移现象。

针对预测所需数据不足所导致的各类问题，研究人员给出一种解决思路：利用迁移学习来对缺失数据进行弥补，从根本上改变数据不足的问题，使得预测工作可以正常进行。具体而言，通过从各类数据完备的源域中获取对目标域解决问题有利的知识，来实现目标域中问题的针对性解决。目前，基于迁移学习的预测方法已经被诸多学者所实现。文献[29]中 Hu 等人针对新建风电场历史负荷数据严重不足这一现实情况，采用深度学习和迁移学习相结合的方法构建预测模型并成功解决了短期风速预测问题；文献[30]则针对时间分辨率增大后伴随的数据稀疏性问题，采用迁移学习对问题进行了针对性解决；文献[31]中 Tariq 等人在进行地铁站 PM2.5 浓度实验时，遇到了部分地铁站数据采集困难这一问题，最终采用迁移学习的方法，迁移从其他地铁站（数据易采集）学习到的相关“知识”帮助解决数据采集困难的地铁站的预测问题。文献[32]中，由于美国和意大利新型冠状病毒爆发时间点早于欧美其他国家，所以可以通过迁移基于美国和意大利两国的新型冠状病毒感染数据所建立的病例预测模型参数，从而建立了德国、法国、巴西等国家的新型冠状病毒新增病例以及死亡病例预测模型；文献[33]中 Nguyen 等人通过对迁移模型的超参数调整并保留最优模型，成功预测了对离子通道中糖基化位点；文献[34]中 Deng 等人将强化学习和迁移学习相结合，对某建筑物居住人群行为进行分析，并成功建立了可伸缩性良好的行为预测模型。

以上研究成果均表明迁移学习在数据缺乏场景下的预测问题中能发挥巨大的作用。但是，使用迁移学习来解决电力负荷数据匮乏的问题，可供研究的案例仍然相对较少。蔡秋娜等人针对在短期负荷预测中，节假日负荷的相关数据通常较少且负荷规律和平时的差异较大，导致负荷预测精度较低，提出了一种基于参数迁移的节假日短期负荷预测方法，结合深度学习和迁移学习提升节假日负荷预测的精度[35]。通常在一个区域，没有新用户出现时，该区域的负荷相对稳定，而新用户出现在该区域时，其历史负荷数据往往极少，关于这一情形，孙晓燕等人提出将数据充足区域所训练的电力负荷预测模型参数进行迁移[36]，建立新的预测模型，从而有效解决这类数据缺少时的预测问题。

在上述迁移案例中，基本都是由于数据不足或是数据稀疏原因导致预测工作无法正常进行，也有试图借助迁移学习来提高预测精度。这些迁移都需要建立在一个大的前提之下：源域和目标域存在“联系”或是“相似性”，否则将会出现负迁移现象，使得预测精度不升反降。

中国知网 https://www.cnki.net

1.3 本论文的主要研究工作

1.3.1 主要研究内容及方法

通过对现有研究成果进行分析，不难发现，在现阶段将深度学习和迁移学习结合并用于短期负荷预测的成果相对较少，对研究成果进行分析总结后发现以下问题：

1. 对于源域，通常具有充足的数据集，在源域进行负荷预测，其预测精度与迁移后的目标域的预测精度成正相关。对于基于深度学习和迁移学习的短期负荷预测，首先应当考虑在源域中如何进行高精度的预测。

2. 对于确定目的域，并试图使用迁移学习来帮助解决目的域所遇到的问题时，大多忽略了有关于源域与目的域之间匹配的过程，而一个合适的源域能最大程度上发挥迁移学习的效果，源域和目标域的匹配程度，与训练模型最后的预测精确度成正相关。当源域和目标域的相似度低于一定值时，对于源域的迁移将产生负迁移现象。因此，在使用迁移学习时，首先应当考虑源域和目标域之间的相似性、匹配性是否符合任务要求。

基于以上两点，针对目标域数据偏少的情况，研究基于深度学习和迁移学习的短期电力负荷预测，内容如下：

1. 在源域，仅进行在源域范围内的短期电力负荷预测。首先，将源域历史数据集进行整理，保证源域数据中无异常数据、缺失数据；接着，在源域范围内，采用 1DCNN、LSTM、RNN、1DCNN-LSTM、1DCNN-RNN 等神经网络进行预测；最后，对比多种神经网络的预测精确度，选出预测精度最高的预测模型作为备用迁移模型。本部分主要的目的是证明在短期电力负荷预测 1DCNN-LSTM 网络预测精度优于其他的神经网络。

2. 针对目标区域内历史数据过少，难以进行电力负荷预测的问题，提出一种迁移源域电力负荷数据所引导的 1DCNN-LSTM 短期电力负荷预测的方法。首先，在源域中，从源域所覆盖的区域中，选出与目标域匹配度最高的区域，并将其作为研究的对象。为了选取匹配度最高的区域，引入欧式距离作为评价函数。迁移源域负荷数据到目标域，构造基于电力负荷数据迁移的短期电力负荷预测模型，验证其预测精度。区别于迁移电力负荷数据所引导的方法，提出一种迁移源域预测模型参数所引导的 1DCNN-LSTM 短期电力负荷预测的方法。首先进行实验目的域和源域的筛选确定工作，然后在保证源域和目标域相似度较高的基础上，迁移源域的预测模型，并用已知目标域电力负荷数据对其进行微调，最后给出基于负荷预测模型参数迁移的负荷预测模型，验证其预测精度。

1.3.2 论文结构

本文章节安排如下：

第一章，绪论。简要介绍本文的研究背景和研究意义，阐明国内外关于负荷预测的

中国知网 https://www.cnki.net

研究现状，其中包括人工智能负荷预测以及迁移学习负荷预测，最后介绍本文的主要章节安排。

第二章，主要介绍电力负荷预测的基础概念，包括负荷预测、电力负荷特性、电力负荷影响因素、预测网络评价函数等基础性工作。

第三章，主要介绍本文使用数据集的预处理工作，影响参数的量化。

第四章，介绍一种基于 1DCNN-LSTM 网络的短期电力负荷预测。主要包括一维卷积网络原理、长短期记忆网络原理以及对基于 1DCNN-LSTM 网络的短期电力负荷预测的预测结果进行准确度分析。

第五章，介绍一种将 1DCNN-LSTM 预测网络和迁移学习相结合的短期电力负荷预测算法。包括迁移电力负荷数据和迁移预测模型参数两种方法。对于迁移电力负荷数据，首先，对该方法是否可行进行初步分析；其次，选择源域与迁移数据；最后，依靠真实数据，分析该方法是否符合实验预测所想。对于迁移预测模型参数，首先，对该方法是否可行进行初步分析；其次，选择源域与迁移预测模型参数；最后，通过真实的数据，分析该方法是否符合实验预测所想。

中国知网 https://www.cnki.net

第二章 电力负荷预测基本理论

2.1 引言

电力负荷预测，从名称上就可以简单分析得出其研究主体为电力负荷，研究目的是预测，准确的讲是对电力负荷需求在一个确定的时间段内进行预测。电力负荷通常是指用电设备消耗的电能，对于用户而言，电力负荷相当于在某一时刻连接到用户插座的所有电气设备消耗的电能；预测，则是指通过对事件进行系统分析与研究，从而利用科学合理的方式发现事件的发展规律，并对其未来发展趋势进行预先估计与判断。

电力负荷预测，在现阶段是指充分分析所处电网系统运行的各项参数和自然环境下的各种因素以及在现实生活中社会因素的共同影响下，用一种特定的、系统的方法处理历史负荷数据，进而对未来一定时间内的负荷做出合理的预估，最后对预估的数据进行精度检验。对于电力相关部门，提高负荷预测技术水平具有重要的现实意义，既能使电力系统运行模式得到优化，又能使电网运行方案得到优化，同时还能减少发电费用。对用电居民也有直观体现，发电成本降低，直接导致电价降低。总的来说，对电网进行准确的负荷预测，对提高电网的经济效益和社会效益具有重要意义[37]。对于售电公司来说，高精度的负荷预测能有效对发电量做出正确判断，便于电力公司制定中长期发展战略。因此，电力负荷预测对电力系统向现代化管理转变以及售电公司向现货市场过渡具有重要意义[38]。

2.2 电力负荷预测的基本分类

按照电力负荷预测内容，一般将其分为两类：一类是系统负荷预测，另一类是母线负荷预测。系统负荷预测是指在一定时间内，对电力需求进行预测，而母线预测则是通过对系统负荷预测来推算某一时间内的电力需求，并进行相应的分配。根据预测的时间长度，可以将电力负荷预测分为超短期负荷预测、短期负荷预测、中期负荷预测和长期负荷预测四种[39]：

1. 超短期负荷预测，指预测未来极短时间内的电力负荷需求。这个时间一般指几分钟或几个小时，由于预测的时间短，所以对预测模型要求极高，不仅要求模型预测速度快，还要求模型能对突发紧急状态做出紧急处理预案，更进一步对有些模型要求能实现实时监控电力设备运行状态。

2. 短期负荷预测，从时间维度上来看是指对时间长度为一天到一周左右的负荷进行预测，主要目的是给日调度计划和周调度计划做参考，同时，短期负荷预测也是负荷预测领域中最为常见的负荷预测。短期电力负荷预测预测时间短、目的性强、可利用性高，对电力系统的经济运行和稳定运行有着重要意义。所以近些年来，在能量管理系统中，短期负荷预测已经是一个专项研究内容。

3. 中期负荷预测，是指对今后数个星期乃至数个月的电力负荷需求进行预测。由于预测的时间维度较长，通常被作为制定检修计划和燃料采购计划重要依据。

中国知网 https://www.cnki.net

4. 长期负荷预测，人们通常将比中期负荷预测所预测时间更长的负荷预测称为长期负荷预测，是一种对今后几年或是更长时间的电力需求预测。由于预测时间长，通常是作为电力相关部门制定电网扩建计划和国家制定电力行业发展计划的参考。

2.3 电力负荷的特性

在对电力负荷预测这一领域进行研究探索时，学者们发现，在未来某个时刻的电力负荷值是未知的，只能通过一系列手段不断预估一个数值来靠近它。学者们为了对该需求有更好的研究，分析和研究负荷变化的规律以及负荷的影响因素，期望能对未来某个时刻的负荷需求有一个高精度的预测[40]。但是，在分析负荷预测的影响因素时，由于环境因素（暴雨、干旱、火灾等无法预知地事故）这一类人类无法控制的因素以及在现实生活中，人为用电习惯这些无法控制的因素的存在，使得电力负荷预测工作难度升高。到目前为止，人们也只能通过对负荷的分析归纳出普遍性现象，比如城市电力需求逐年增长，并且电力需求在不同季节、星期都有着不同的变化规律，其变化规律又受到所在地区其他因素的影响。然而，许多学者在进行负荷预测工作时，常常忽略了上述因素对预测工作的影响。

从整体上看，电力负荷预测具有周期性、波形性和随机特征，而周期性又包含日周期性、周周期性和季节性周期性。对电力负荷的各种特性进行分析，能帮助我们建立更优的预测模型，从而得到高精度的预测结果。

1. 日周期性

图 2-1 是美国康涅狄格州一段时间内三天的电力负荷曲线图，纵坐标表示电力负荷，单位为 MKVA，横坐标表示连续的时间轴，采样时间间隔为一小时。由图可知，电力负荷的日周期性是十分明显的，而且在不同日期的相同时段内的电力负荷数值较为接近。

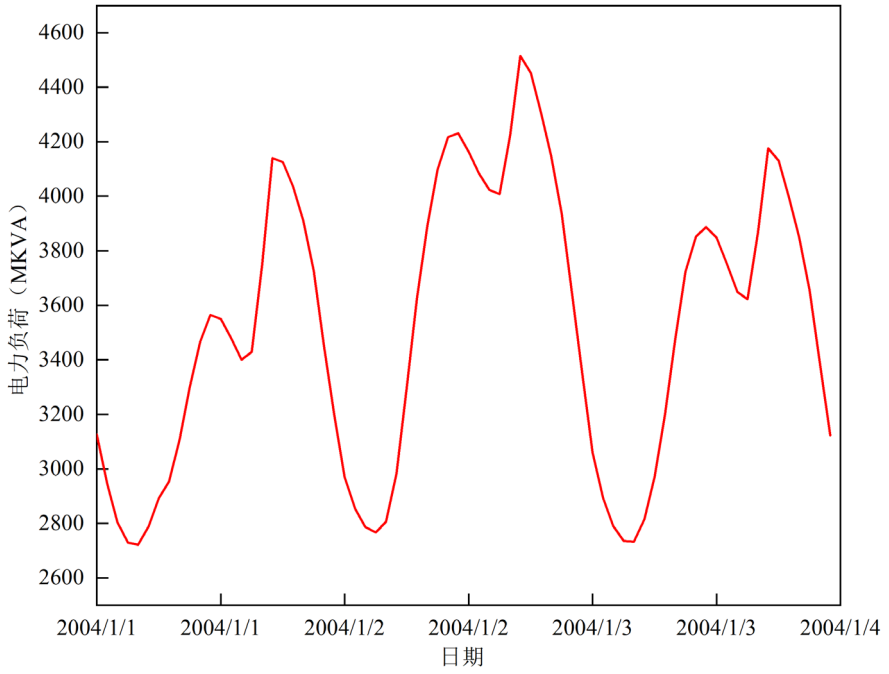


图 2-1 电力负荷的日周期性

中国知网 https://www.cnki.net

2. 周周期性

周周期性一般说的是电力负荷曲线在某一短时间内，其每一周的曲线有相似的特性。图 2-2 是美国康涅狄格州某时间段内连续四周的负荷曲线，通过对图像进行观察分析，不难发现，每周的负荷曲线波动趋势大致相同，仅在最大值和最小值上差异较大，负荷电力负荷日常变化呈现规律性。

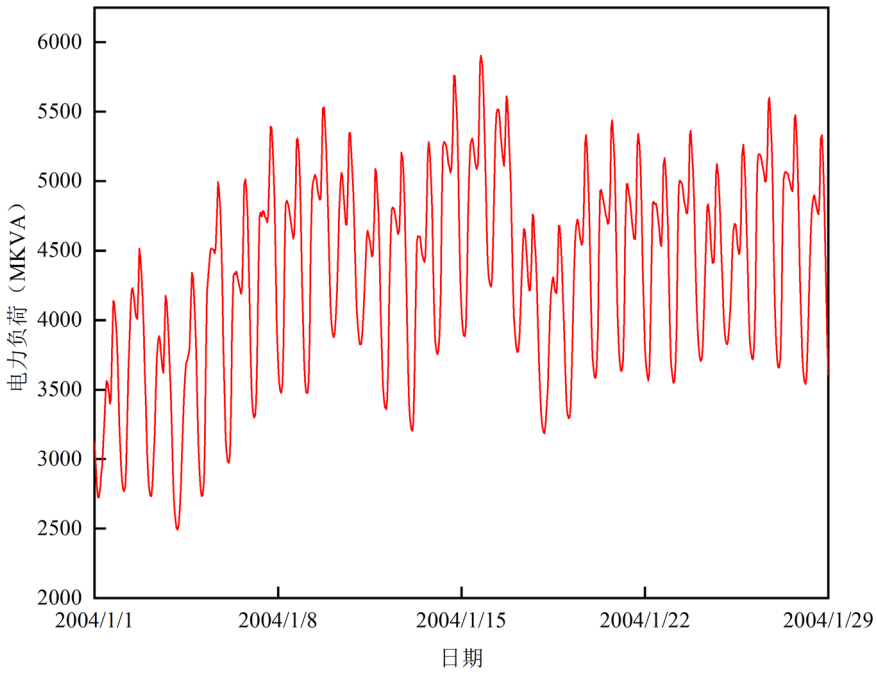


图 2-2 电力负荷的周周期性

3. 随机特性

电力负荷除了在周期上有明显的日周期性和周周期性，同时也有着强烈的随机特性。它的随机是由于一些无法控制、无法预测的因素所导致的。因此在对预测模型进行耦合训练时，通常不考虑随机突发事件的发生，即假定无重大突发事件。

2.4 影响电力负荷的因素

考虑现实生活中用电习惯以及现实生活中一些常见的场景，分析其对电力负荷的影响。一般而言，影响电力负荷需求的主要原因有四种：日常生活习惯的影响、气候的影响、季节的影响和人们在节假日用电习惯不同的影响。本文简单地对影响电力负荷需求的各种因素进行了简单的剖析。

1. 生活习惯

在日常生活中，人们通常日出而作，日落而息。这一生活习惯，会使得电力负荷曲线有着明显的特征：中午和晚上休息的之前电力负荷高，晚间休息的时候电力负荷低，通常在早上 10 点和晚上 8 点左右达到高峰，在半夜达到低谷。

2. 气温

气温对负荷的影响是非线性的。通过对人们日常用电习惯的观察与统计，可以得出一般性规律：气温越低，电力负荷需求越大，当气温升高至 0 度以上，电力负荷需求则

中国知网 https://www.cnki.net

会随着气温的升高而降低，但当气温逐步升高至 30 度左右时，电力负荷需求则会随着气温的升高而增加。这一变化规律也大体上符合电力负荷在季节因素的影响下的变化趋势。

3. 季节性因素

不同的季节对电力负荷会造成不同的影响，一年四季：春夏秋冬，其负荷波形会呈现不同的特性。在夏季和冬季有明显规律，在夏天，人们的用电需求会随着温度的升高而增加，而在冬天则恰恰相反，用电需求随着温度的降低而增加[41]。

4. 工作日和非工作日

非工作日，各个企业等生产会暂停，人们的生活习惯在休息日也会有所不同，因此休息日的电力负荷也会随之变化，总的来说，电力负荷在休息日比较小，在工作日比较大。

2.5 负荷预测的原理

电力负荷预测，从本质上分析，是在电力负荷历史数据的基础上，引入各项影响因素并选择合适的预测模型，从而分析电力负荷变化的规律，最后对未来负荷需求做出预测。为了获得高精度的负荷预测结果，应当从预测工作的基本方法和原理着手，并用最基本的方法和原理作为我们预测工作的指导。电力负荷预测基于以下原理：

1. 可知性原理

从可知性这一基本概念出发，引申出预测工作中的可知性原理：对某一事物进行分析、研究和预测需要建立在一定的条件下，即该事物的发展模式、发展条件、发展趋势等都能被人们客观感受和认知。只有这样，我们才可以通过分析预测对象的历史数据来进行简单的预测[42]。

2. 可能性原理

人们常说世界上不存在两片一模一样的树叶，这便是可能性所导致的。事物在发展过程中，其发展趋势受外界因素的影响，不同的因素在不同的时刻会给事物的发展带来不一样的影响。在实际预测过程中，应当设置多种方案，来针对由于多方面影响因素作用下导致事物不同的发展方向。

3. 连续性原理

在预测工作中，有这么一个前提，对于待预测的目标，它处于一个连续统一的过程中，它正在发展而且也将不断的发展下去。从客观上讲，它将带着在发展过程中出现的特征继续发展，而这些特征可以用来对未来进行预测。同样的，人们的用电规律不是凭空出现的，是客观存在的并且会一直存在下去，这也为电力负荷预测提供了理论基础。

4. 可控性原理

可控性原理表明，自然事物的发展是可控的。这一观点是针对于事物未来的发展，而不是现在正在发生的事情。例如，你无法让现在正在下的雨停止，但是你可以通过人工降雨来让未来某个时刻下雨。同样的，在负荷预测领域当中，预测本身就是希望能通

中国知网 https://www.cnki.net

过各种各样的方法，将预测到的未来的信息反馈到现在，从而利用反馈的信息指导人们工作，针对性制定相关计划，保障未来事物的顺利发展。

5. 相似性原理

现实生活中，由于事物的发展受到各种因素的影响，因此每个事物都展现着不同的发展规律和特点，但是事物的发展并不是杂乱无章，随性而为的，它们仍遵循着一些普遍性规律。实际应用当中，正是由于事物间存在普遍的规律，学者们才可以借助于对客观规律的研究和分析，归纳相关的普遍规律，并由此引申出相关的理论，然后学者将理论付诸于实际行动当中，探索和改造世界。电力负荷预测也是如此，学者通过观察现阶段电力负荷发展，了解电力负荷发展的规律以及展现的特点，对规律和特点进行总结，最后提出系统性理论。将理论用于实际预测工作当中，有效洞悉电力负荷未来发展趋势和发展模式，由此可进行准确的电力负荷预测。这就是相似性原理在电力负荷预测领域中的应用。

6. 系统性原理

一个系统通常由内部、外部两个系统构成，其中内部系统包含了复杂的内部结构，同时它又与外部相联系，从而形成外部系统。在负荷预测领域中，将被预测的目标视为一个系统，而预测就是针对该系统进行全面的研究与分析。

2.6 负荷预测的误差分析

电力负荷预测误差通常是在电力负荷预测过程中，由于电力负荷历史数据本身存在的问题以及电力负荷预测模型本身的缺陷，导致最终负荷预测结果与实际值之间存在数值上的差异。电力负荷预测误差分析对电力负荷预测模型建立评估系统具有重要意义，可以更加直观帮助研究人员对模型的优劣势进行客观分析。导致预测产生的原因有以下几种：

1. 数学模型误差

数学模型的优劣直接影响到预测的结果，其重要性不言而喻，每种数学模型都有其适用场合，例如人工智能方法适用于复杂电力系统；回归分析法适用于简单电力系统。而在实际电力系统中，无论选择哪种模型，都会存在一定差异。

2. 预测方法误差

在电力负荷预测领域中，由于预测内容的不同，需要根据每种预测的特性，采用最为恰当的预测方法：在中长期负荷预测中，由于负荷数据比较少，使用神经网络会出现过拟合问题，最终会导致预测结果出现较大偏差。在这种情况下，应使用回归分析法，回归分析法对数据量要求不高，因此能有效地进行中长期负荷预测。由于每个方法的侧重点都不一样，适用范围也不一样，所以在同一情况下，应针对性选择合适的预测方法，以便取得最优的预测效果。

3. 历史数据误差

电力负荷预测需要预测地区电力负荷历史数据以及外界相关影响因素数据，比如气

中国知网 https://www.cnki.net

象数据和日期数据，这些数据都是由相关设备采集且采集数据较多，因此在传输、存储上可能出现数据丢失等情况，因此会造成相应的误差。

4. 随机性误差

电力负荷的增减趋势不仅呈现出一般性规律，同时，其变化也受突发因素影响，且影响因素种类繁多，各种突发影响会相应的产生各类误差。

本文采用以下几个误差指标来计算评估论文所涉及的电力负荷预测模型性能的优劣，计算公式如下：

（1） 平均绝对百分比误差：

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{\hat{y}_i - y_i}{y_i}\right| \tag{2.1}$$

（2） 平均绝对误差

$$MAE = \frac{\sum_{i=1}^{n}|\hat{y}_i - y_i|}{n} \tag{2.2}$$

（3） 均方根误差

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2} \tag{2.3}$$

上述公式（2.1）、（2.2）、（2.3）中，$\hat{y}_i$和y_i分别表示预测时刻i的预测值和真实值，n表示样本总数。

2.7 负荷预测的基本步骤

使用神经网络进行电力负荷预测通常按照以下步骤依次进行：

1. 首先应当确定预测目标。按照电力负荷预测中以时间长短为依据的划分，预测目标通常分为超短期负荷预测、短期负荷预测、中长期负荷预测、长期负荷预测[43]。

2. 搜集电力负荷数据及相关历史资料。资料包括预测目标所在地区的气象数据，预测起止时间内的日期信息等。

3. 资料分析处理。主要是分析资料中的负荷变化特点，对其变化趋势、增减情况形成初步了解，便于后期预测模型的选取。

4. 选取合适的模型进行预测，对预测结果进行评估。

具体流程图如图 2.3 所示。

中国知网 https://www.cnki.net

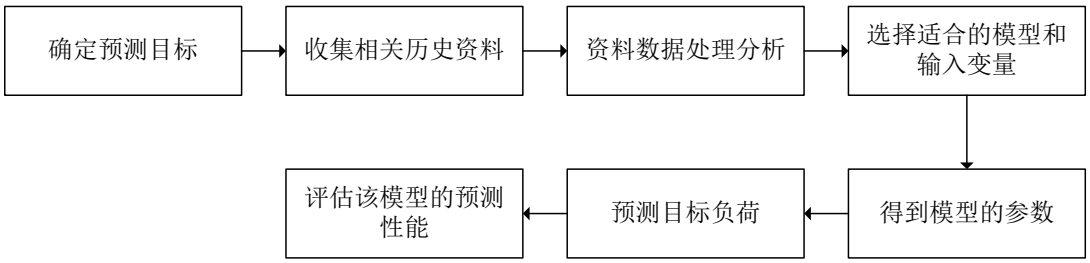


图 2.3 负荷预测基本流程图

2.8 本章小结

本章首先对电力负荷预测的基本知识进行了概述，主要包括分类标准、基本特性、影响因素、基本原理，然后对电力负荷预测结果的误差进行了系统分析，最后给出了电力负荷预测的基本步骤以及本论文使用的评估预测模型优略的评价指标，为后续工作奠定基础。

中国知网 https://www.cnki.net

第三章 数据预处理

3.1 引言

电力负荷原始数据是对该地区供、需电的原始呈现，电力负荷原始数据集在形成的过程中，数据集中包含的无论是历史电力负荷数据，还是相关气候数据都不可避免存在一定问题[44]。为了在短期电力负荷预测中取得良好的精度，需要对原始数据集进行预处理，包括依据电力负荷影响因素进行数据初步筛选、原始信息量化、缺失数据识别、异常数据排查等。

3.2 原始数据

本文使用的数据集由美国某州 2004 年 1 月 1 日至 2004 年 12 月 31 日（一年）的电力负荷数据、气象数据以及日期数据组成，数据时间间隔为 1*h*（60*min*），共 8783×9 条数据，每一条数据涵盖了多类信息，包括最高温度、最低温度、平均温度等。取前 5 条数据，具体如表 3-1：

表 3-1 原始数据集

日期	最高温度	最低温度	平均温度	季节	月份	小时数	星期	天数	是否周末	电力负荷
2004/1/1/0.00	33	26	29.5	春	1	1	四	1	否	3126
2004/1/1/1.00	34	26	30	春	1	2	四	1	否	2945
2004/1/1/2.00	40	26	33	春	1	3	四	1	否	2804
2004/1/1/3.00	38	23	30.5	春	1	4	四	1	否	2729
2004/1/1/4.00	37	21	29	春	1	5	四	1	否	2722

如上表所示，表中每一行主要内容包括温度信息、日期信息、电力负荷，其中温度信息主要包括：最高温度、最低温度、平均温度，日期信息由季节、月份、小时数、星期、对应天数、周末等组成，各类数据共 11 种类别，其中温度的单位为摄氏度（℃），电力负荷单位为 MKVA。

3.3 数据处理

对数据进行初步整理，发现本文所使用的数据集中有坏数据。通常学者将无法真正反应电力负荷需求的数据称为坏数据，而对于常见的坏数据通常可被分为以下两类：数据缺失、数据异常。在预测实验中，数据集中存在坏数据将会影响研究人员的判断，进而影响建立高精准度的预测模型，为此必须在建模前加以修正[45-46]。

3.3.1 缺失数据的补充

电力负荷数据在采集过程中由于电表发生故障或者采集者操作失误抑或是采集完成后数据保存不善等多种原因都有可能导致某时刻负荷数据以及相关数据标签信息的

中国知网 https://www.cnki.net

丢失，数据缺失会对电力负荷预测精度造成一定程度的影响，为减小影响，需要对缺失数据进行合理的补充。

对于单个时间点的电力负荷数据缺失进行如下处理：由于该地区电力负荷值与上一时刻该地区的电力负荷值和下一时刻该地区的电力负荷值之间存在一定关系。同时，引入前一天该时刻该地区的电力负荷值与后一天该时刻该地区的电力负荷值作为参考，对该点负荷进行如下补充：

$$M(x,t) = a_1 M(x-1,t) + a_2 M(x+1,t) + a_3 M(x,t+1) + a_4 M(x,t-1) \quad (3.1)$$

式中，$M(x,y)$为第 x 天 t 时刻点的负荷值（t 的单位为小时数 h），a_i 为权重系数，可根据实际情况调整。

3.3.2 异常数据的识别和修正

1. 水平处理方法

本文采用的电力负荷数据采集时间间隔为 1h（60min），在这种情况下，电力负荷数据通常不会发生剧烈的变化，即负荷曲线一般是平滑的、连续的。基于这一理论，对异常数据进行筛选和修正。以某时刻的电力负荷为例，首先通过对数据的初步分析，设定一个合适的阈值；然后将该时刻电力负荷值与上一时刻以及下一时刻的电力负荷数值差和设定阈值进行比对，如果数值差大于阈值，说明该时刻的电力负荷数据异常，应对其进行修正；最后，对异常数据进行水平修正，修正后的值为该点前后两个时刻的负荷数据的平均值。

2. 垂直处理方法

通常情况下，人们的日常生活都展现出强烈的规律性，而且在日常生活中，排除突发重大事件或者气候上发生极端天气的情况下，相同日类型的相邻时间点的电力负荷数据之间应当呈现出一定的相似性。在这一基础上，建立如下假设：

将某时刻电力负荷数值与相同日类型或相邻时间点的电力负荷数值进行对比，若对比后，发现两者之间出现较大数值差（大于既定阈值），则认为该点的电力负荷数据可能为异常数据。

此时，应对该点的电力负荷数据采用如下方法进行修正：

$$M(x,t) = \begin{cases} x(t) + \Delta(t) & M(x,y) > x(t) \\ x(t) + \Delta(t) & M(x,y) < x(t) \end{cases} \quad (3.2)$$

式中，$\Delta(t)$为数据处理前设定的阈值，$M(x,t)$为第x天t时刻点的负荷值，$x(t)$为相同日类型因素相邻日期负荷的平均值。

3.3.3 数据量化

由上一章对负荷影响因素的分析可知，对电力负荷产生较大影响的因素包括气候因素、日期因素等。为此本文构建了包含气候因素、日期因素等因素在内的一维特征向量作为预测模型的输入，具体如表格 3-2 所示[47]。

中国知网 https://www.cnki.net

表 3-2 预测特征集

影响因素	特征类型	特征描述
日期因素	季节	1-4 代表春夏秋冬
	月	1-12 代表 1 月至 12 月
	小时数	1-24 代表每一天的小时数
	星期	1-7 代表周一至周日
	一年中的天数	1-365 代表该年中的天数
	是否周末	1 代表周末 0 代表工作日
气候因素	最高温度	当日温度的最高值，℃
	最低温度	当日温度的最低值，℃
	平均温度	当日温度的平均值，℃

将原始数据数字化以后，由于每个物理量的含义不同、量纲不同，数字化后所呈现出来的数值差异可能会很大。如果不对参数进行二次处理，直接将其作为输入，可能会出现计算速度慢、收敛性差、迭代时间长等问题，将直接对负荷预测精度造成影响[48]。

针对温度、星期这两大类影响因素，对其进行基于辅助信息的内在关系和经验的量化规则，对辅助信息进行处理，如表格 3-3 和表格 3-4 所示。

表 3-3 日期信息量化标准

星期	星期一	星期二	星期三	星期四	星期五	星期六	星期天
基础描述	1	2	3	4	5	6	7
指数	0	0.02	0.04	0.06	0.08	0.8	1

表 3-4 温度信息量化标准

温度（T/℃）	T≤0	0＜T≤10	10＜T≤20	20＜T≤30	30＜T≤40	T＞40
指数	0	0.2	0.4	0.6	0.8	1

3.4 本章小结

本章主要介绍了电力负荷原始数据所包含的信息以及数据预处理的相关内容，包括缺失数据补充、异常数据排查与修正、数据量化等，这些都为后续建立短期电力负荷预测模型打好基础。

中国知网 https://www.cnki.net

第四章 基于一维卷积-长短期记忆网络的短期电力负荷预测

4.1 引言

在短期电力负荷预测中，考虑到常规方法不能精准地提取特征和无法保障长时间序列中信息的完整性，本文将 1DCNN 和 LSTM 相结合，提出一种基于一维卷积和长短期记忆的预测方法。利用 1DCNN 在特征提取上的优势和在时间卷积减少计算时间的优势，并将这些优势与 LSTM 的顺序敏感性相结合，充分提取电力负荷、时间日期、温度等参数的历史特征，通过所学习到的特征对短期内的电力负荷进行预测。

4.2 卷积神经

4.2.1 卷积神经网络基本概念

卷积神经网络（CNN）是深度学习（Deep Learning）的代表算法之一，该网络结构表现为深度结构，而且该网络同时也是前馈神经网络[49]。对卷积神经网络进行分析可发现，该网络可以通过卷积与池化等手段得到平移旋转不变性，这一特性通常被学者认为是具有表征学习能力（Representation Learning）的特点，也正因卷积神经网络具有这一学习能力，也可被称作“平移不变人工神经网络”（Shift-Invariant Artificial Neural Networks，SIANN）[50]。

4.2.2 卷积神经网络特点

卷积神经网络的结构近似于多层感知器，针对预测精度低的问题能够通过多层感知器解决，但训练的参数过大，导致预测速度慢。卷积神经网络在这一基础上进行了改进，采用稀疏连接的方式链接相邻的两层神经元，同一神经元共享信息，并对样本进行池化运算。通过这些操作，使数据在学习过程中不仅可以充分的将原有特征转化为抽样特征，还可以提高网络的稀疏性与预测效率，CNN 网络的特点如下：

1. 稀疏连接

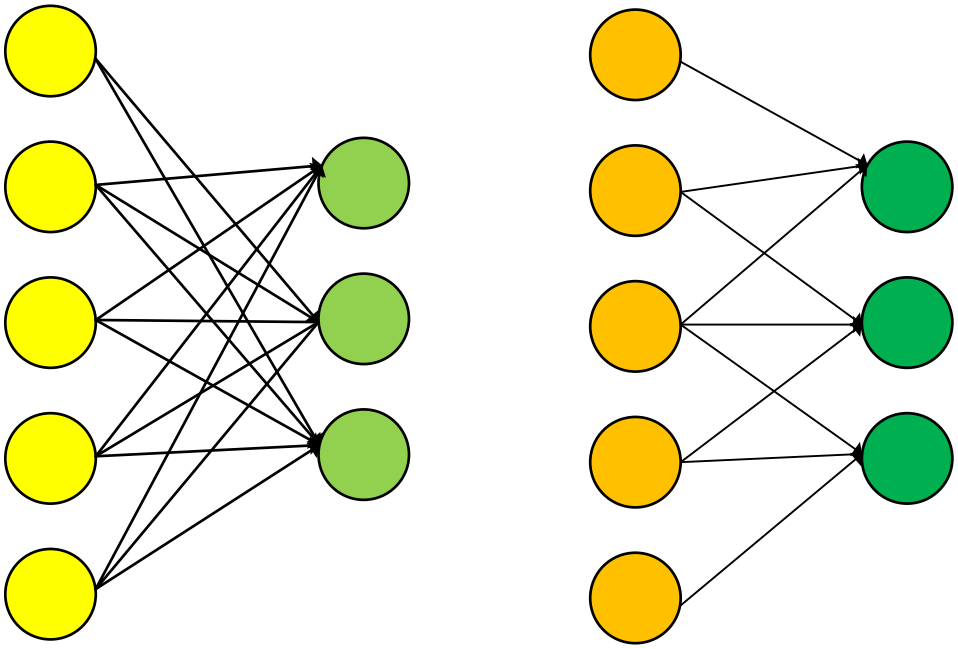
传统的神经网络通常采用完全连接的方式来进行稀疏的连接，也就是说，在前一层，隐藏层的神经元和每一层的神经元之间存在这关联，从图 4-1（a）就可看出这一特点。神经网络中，用于描述这种连接的强弱通常有几种形式表示，当输入的神经元数量增多时，一些网络参数可能会成倍增加，造成网络的参数过多，同时，网络的复杂性也相应变大。为了防止这种现象出现，卷积神经网络在输入数上通过一些微小维度卷积核的滑动，使该层中的神经元仅与上一层部分相近的神经元连接，大幅度减少网络参数，简化网络，降低过拟和的风险，如图 4-1（b）所示。

2. 参数共享

在传统的神经网络中，神经元间存在着完全的连通性，并且每个神经元具有各自特定的参数，这些参数在传播过程中只使用一次，不同神经元之间没有参数共享。而卷积神经网络中每个卷积核都有各自独特的参数，具有参数共享的特点[51]，在卷积运算中直

中国知网 https://www.cnki.net

接训练一个固定的，不同神经元重复使用这个参数合集，不需要单独对某个参数进行训练，如图 4-2 所示，相同的连接线代表共享的权重参数。



（a）全连接　　（b）稀疏连接

图 4-1 全连接方式与稀疏连接方式

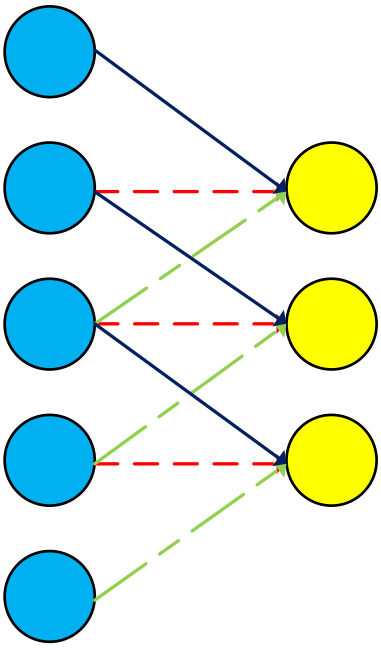


图 4-2 权值共享示意图

3. 空间池化

池化操作一般在卷积操作之后，是对特征二次提取的过程。卷积层通过多个卷积核学习数据中的多样化特征，如果不加以干预则会大大增加网络的复杂程度，导致网络过

中国知网 https://www.cnki.net

拟合。在池化层中，经由卷积层提取的特征向量被划分为不同的区域，为了避免过拟合现象出现，通过提取区域最大值或平均值等方法，减少参数在空间中传输，达到减小网络的复杂程度的目的。

4.2.3 卷积神经网络结构

CNN 网络主要通过池化层和卷积层中的池化和卷积来实现多特征提取[52]。在卷积神经网络中，卷积层具有很强的学习能力。在卷积神经网络中，每个卷积层一般包含多个卷积核与特征平面，利用这些卷积核共享每个特征平面的参数，包括权重和阈值。在实现参数共享的同时，也降低了网络中自由参数的传输，从而避免过拟合现象出现。输入数据上进行卷积核的滚动，便可提取相应的数据特征，多个卷积核就能够学习数据的多样化特征，保证信息能够被充分利用。

池化层可以分为平均池化和最大值池化。池化层在卷积层之后，其输出为相应池化区域内的最大值或平均值，然后经全连接层输出。CNN 网络结构如图 4-3 所示。

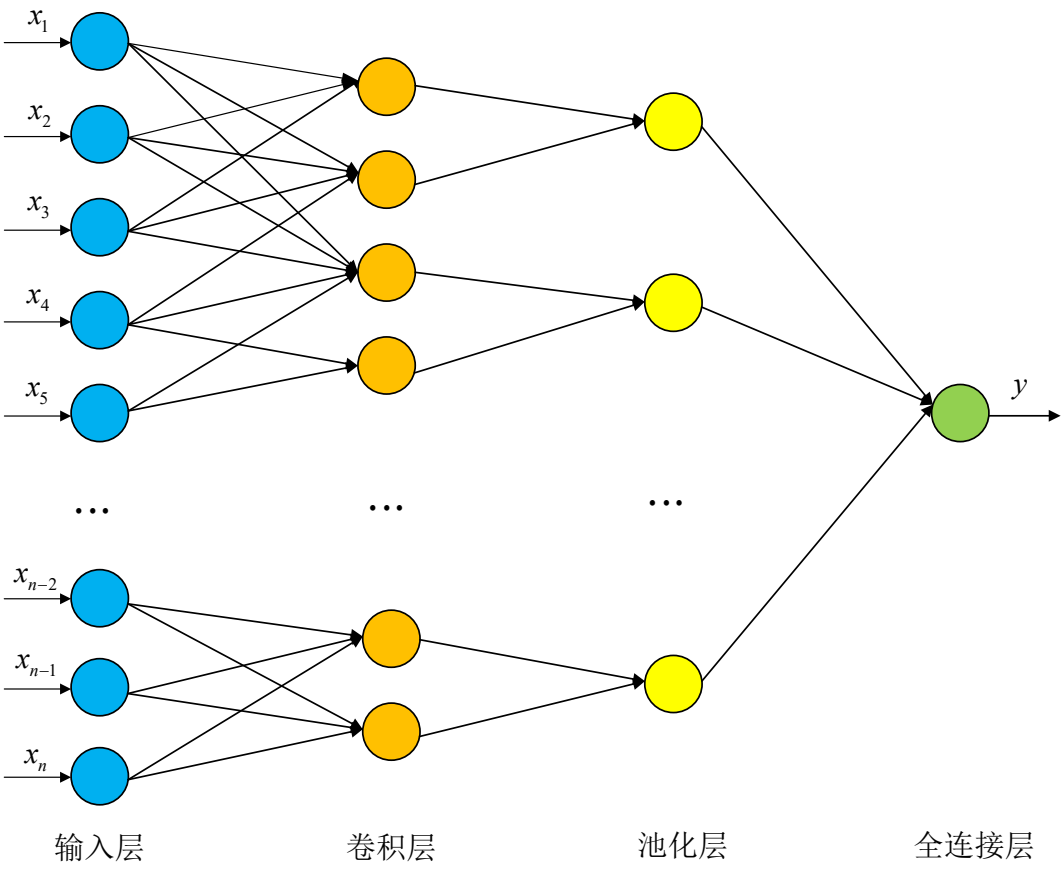


图 4-3 CNN 网络结构图

在电力负荷预测领域中，将负荷影响因素（气候、日期等）作为输入变量，如图 4.3 中，$x_i(i \in (1,n)$为输入变量，输入层函数为线性恒等函数。卷积层的输入为输入层的输出，卷积层通过多个卷积核进行特征映射，并在数据上重复滑动最后输出多组数据，同一卷积核具有相同的权值ω与阈值b，将所得多组数据通过非线性激活函数运算后，传递

中国知网 https://www.cnki.net

给池化层。池化层根据设定好池化宽度对范围内的数据进行池化操作，即用平均值或最大值代替该宽度内的特征来达到降维的目的，最后使用全连接层输出结果。

4.2.4 一维卷积神经网络

处理一维数据时需要相应使用一维卷神经网络[53]。一维卷积（1DCNN）也是由输入层、隐藏层和输出层组成，隐藏层包括一维卷积层和一维池化层。一维卷积与池化运算如图 4-4 所示。

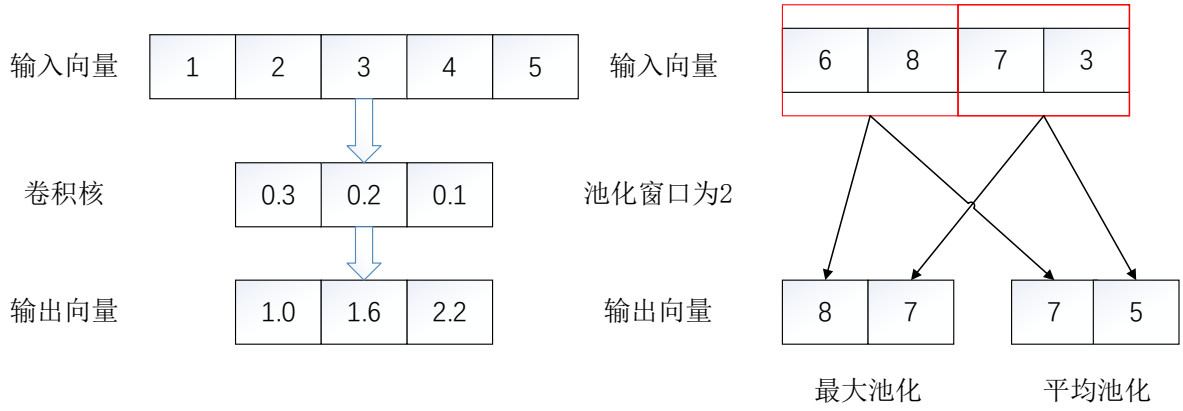


图 4-4 一维卷积与池化运算

当输入信号为$x_i(i \in (1,n)$时，卷积层的计算公式如式（4.3）所示，最大池化运算如式（4.4）所示：

$$x_i^l = f\left(\sum_{j=i}^{k} x_j^{l-1}\omega_j^l + b_j^l\right), i = 1,2,\dots,n-r+1; k = i+r-1 \tag{4.3}$$

$$p_i^l(j) = \max_{(j-1)w+1 \le t \le jw}\{q_i^{l-1}(t)\} \tag{4.4}$$

式中，f 是激活函数运算；x_i^l是第 l 层第 i 个节点的输出；x_j^{l-1}是第 l-1 层 j 第个节点输出；r 为卷积核步长；j 的取值范围为 i 至 k 表示稀疏链接；ω_j^l为x_j^{l-1}对应的权值；b_j^l为x_j^{l-1}对应的偏置；$q_i^{l-1}(t)$为第 l-1 个特征矩阵。

4.3 长短期记忆网络基本理论

LSTM（Long Short Term）网络是由 Hochreiter & Schmidhuber(1997)提出的一种递归神经网络[54]。人类在思考问题的时候并不是每时每刻都从零开始，简单来说，当你在阅读某篇文章的时候，你会基于先前所得到的信息来推断当时词汇的含义，人类的思想具有持久性，而传统的神经网络学习方式并与人类思想并不相同，不会保留在上一个任务中学习到的相关参数[55]。

在传统的神经网络中，输入和输出的各项参数都是独立的，但在时序问题中[56]，前一时刻与后一时刻的信息关系密切，因而不能进行时序模型化。针对以上问题，国内外

中国知网 https://www.cnki.net

的研究人员提出了 RNN 网络，RNN 也就是所谓的循环神经网络，它能保持数据持久，然而，这种方法存在着梯度爆炸和梯度消失等风险，这也导致这一方法无法很好的解决长时间跨度的非线性问题，为了解决这一问题，LSTM 出现于人们的视野当中。

LSTM 由输入门、遗忘门、输出门组成，并由这些门来实现信息的保护和控制，如图 4-5 所示为 LSTM 的基本构成。其中，h_{t-1}表示 LSTM 在上一时刻的输出，x_t表示输入，h_t表示当前单元输出，c_t和c_{t-1}表示存储单元当前状态和上一时刻的状态。

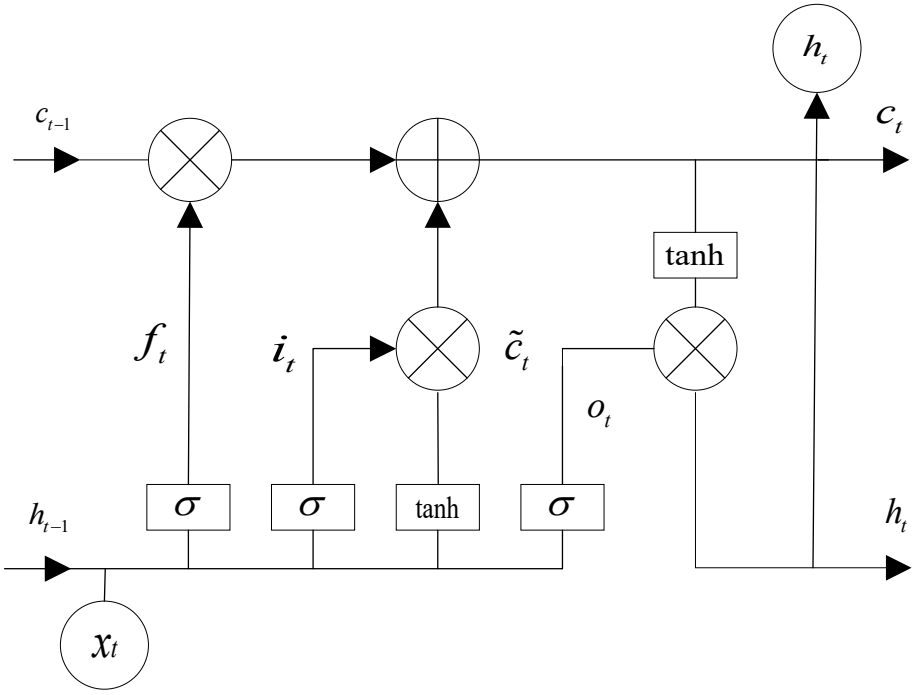


图 4-5 LSTM 结构

在 LSTM 网络中，第一步是选择丢掉什么信息，通过遗忘门f_t（图 4-6）完成，该门读取h_{t-1}和x_t，输出一个在 0 到 1 之间的数字给c_{t-1}中的数字。其中，1 表示“完全保留”，0 表示“完全舍弃”。其值如公式(4.7)所示，式中w_f是权重矩阵，b_f是偏置，σ是 sigmoid 函数。

$$sigmoid(x) = \frac{1}{1+e^{-x}} \tag{4.5}$$

$$\tanh(x) = \frac{e^{z}-e^{-z}}{e^{z}+e^{-z}} \tag{4.6}$$

$$f_t = \sigma\left(w_f * [h_{t-1}, x_t] + b_f\right) \tag{4.7}$$

中国知网 https://www.cnki.net

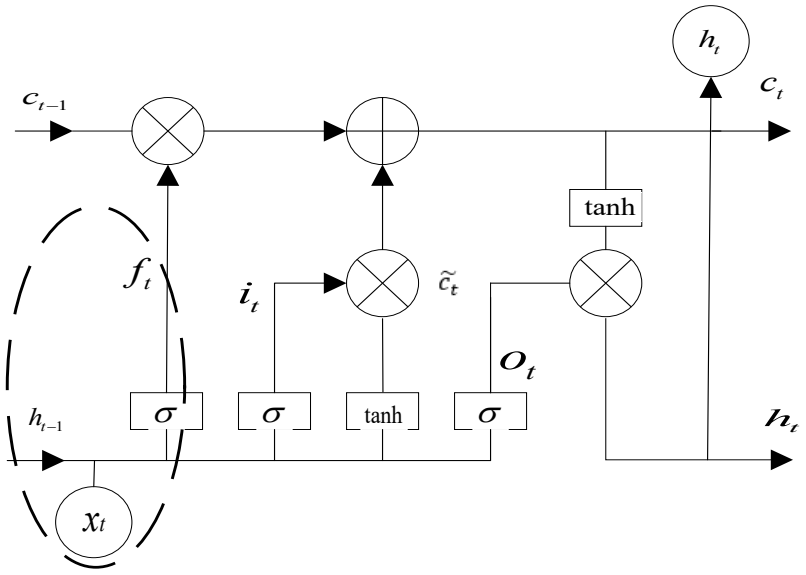


图 4-6 遗忘门

第二步决定保留什么样的新信息。包含两个过程：第一，sigmoid 层，又称输入门（图 4-7）决定更新什么值；第二，tanh 层建立一个新的候选值：$\tilde{c}_t$，会被加入到状态中，进而依据这两个信息来更新状态。其值如公式(4.8)所示，式中，w_i是权重矩阵，b_i是偏置，同时，新状态信息可由公式(4.9)得到。式中，w_c是权重矩阵，b_c是偏置。最后，由公式(4.10)可得当前状态c_t：

$$i_t = \sigma(w_i * [h_{t-1}, x_t] + b_i) \tag{4.8}$$

$$\tilde{c}_t = tanh(w_c * [h_{t-1}, x_t] + b_c) \tag{4.9}$$

$$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t \tag{4.10}$$

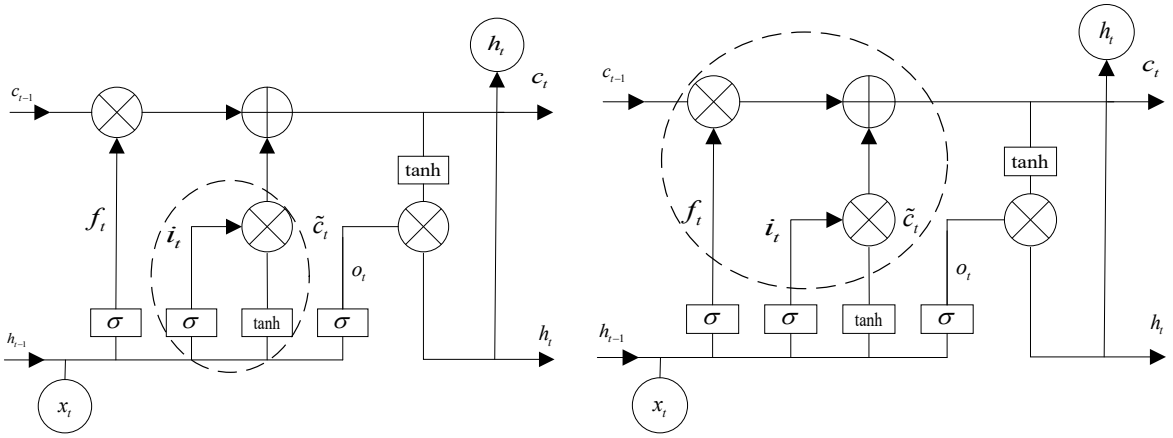


图 4-7 输入门

最终，需要确定输出值，输出值由输出门o_t（图 4-8）控制，其值如公式(4.11)所示，式中，w_o是权重矩阵，b_o是偏置。

$$o_t = \sigma(w_o * [h_{t-1}, x_t] + b_o) \tag{4.11}$$

$$h_t = o_t * \tanh(c_t) \tag{4.12}$$

中国知网 https://www.cnki.net

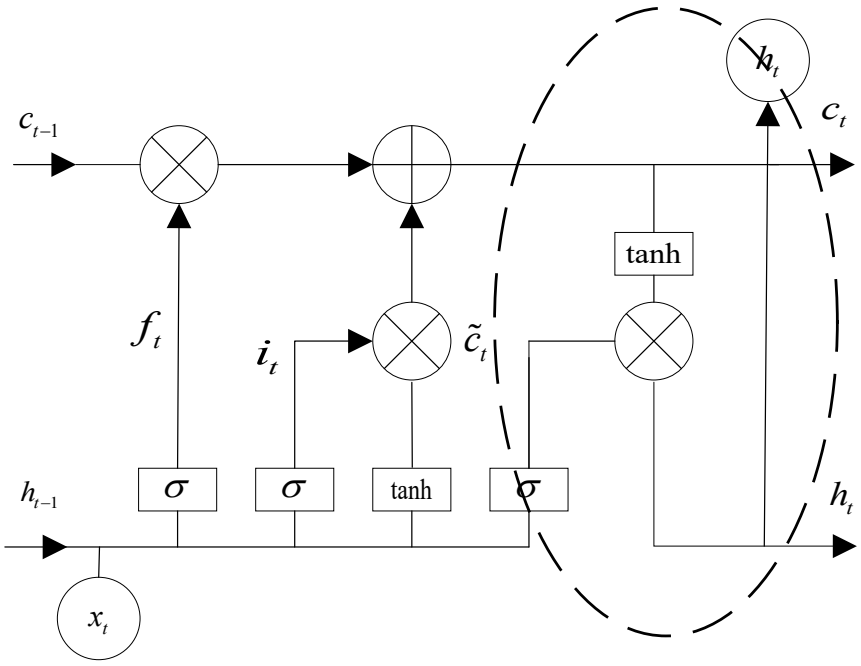


图 4-8 输出门

借助于输入门、遗忘门、输出门和存储单元，LSTM 具有长时间序列信息读取、复位和更新的功能，同时，可以通过调节 LSTM 网络内部共享权重矩阵来调节其输出的大小。

有了以上基础知识之后，将数据带入 1DCNN-LSTM 神经网络模型当中进行预测分析，使用 Python 调用深度学习库 Keras 进行建模，底层依赖 Tensorflow 框架。

4.4 模型预测

首先按照 8：2 的比例划分训练集与测试集，如图 4-9 所示为输入特征图，按时间序列排序。其中t为该坐标轴以时间为尺度；T为间隔一小时的某一具体时刻；$T+n$为T时刻往后n个$1h$间隔的时刻。

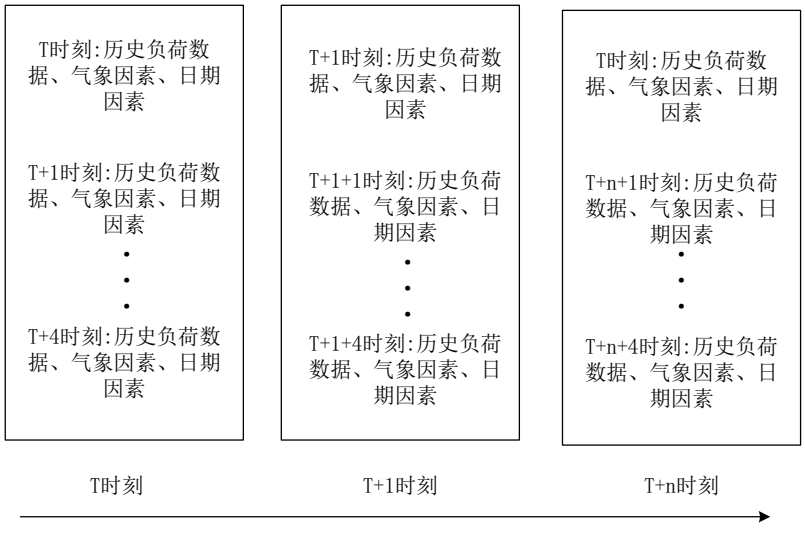


图 4-9 网络模型输入结构

中国知网 https://www.cnki.net

本次使用的 1DCNN-LSTM 网络模型如图 4-9 所示，主要分为两部分：1DCNN 与 LSTM，1DCNN 分别处理每个作为输入的时间序列样本，1DCNN 的架构与 CNN 相同，它将 Conv1D 层与 MaxPooling1D 层进行堆叠，最后连接 Flatten 层。在 LSTM 网络中，通过循环堆叠，增加网络容量，模型的预测效果被进一步提升，增加网络层数或神经元个数，并将 Dropout 引入至 LSTM 中，在迭代过程中，会随机丢失掉部分神经元，以避免过拟合现象的发生[57]。相应参数设置如表 4-1 所示：

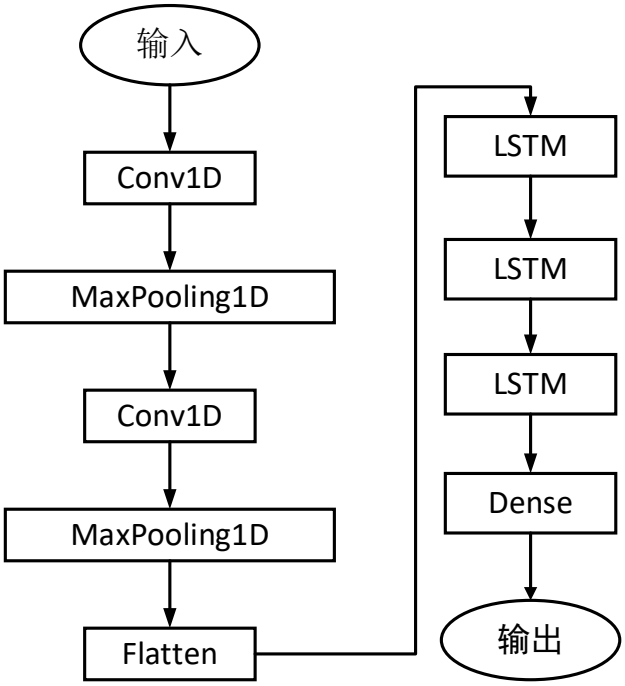


图 4-10 1DCNN-LSTM 网络模型

在选择网络激活函数时，综合考虑了 Sigmoid、ReLU、tanh 三种激活函数，其公式如下所示（Sigmoid、tanh 函数如公式 4.5、4.6 所示），图像绘图如图 4-11 所示。

$$ReLU(x) = \max(0, x) \tag{4.13}$$

ReLU 激活函数的导数如公式 4.11 所示：

$$\frac{d}{d_x} ReLU(x) = \begin{cases} 1, (x > 0) \\ 0, (x \leq 0) \end{cases} \tag{4.14}$$

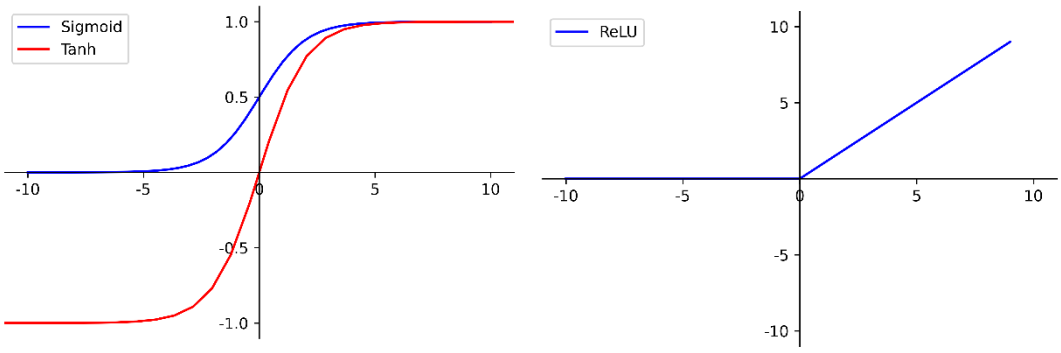


图 4-11 激活函数曲线图

中国知网 https://www.cnki.net

Sigmoid 函数一端逼近于 0，一端逼近于 1，且两端都趋于饱和。当神经网络的权值为 0 至 1 间的随机值时，随着层数的增加梯度值将会逐步变小。如果网络层数较多，那么梯度在经过多次传播后将会接近于 0，即出现梯度消失的现象；当初始化网络初值为（1，+∞）区间的值，则会出现梯度爆炸的情况。与此同时，tanh 虽然解决了 Sigmoid 函数不是 0 中心输出问题，但仍存在梯度消失的问题[58]。

ReLU 函数的输入值小于 0 的部分将会被设置为 0，因此神经网络具有稀疏性。对于深度学习算法，一个明确的目标时从数据变量中分解关键因素。由于原始数据通常被高密度的特征所包裹，如果可以解决特征之间复杂关系并将其转化为稀疏特征，那么这些特征将具有鲁棒性，并且可以有效避免在长时间维度上随着迭代次数增多而出现梯度消失和梯度爆炸。

在模型训练过程中，需要大量的时间和计算机资源进行训练，为了节省资源。使用 Adam 算法作为本文的优化算法。Adam 能够自适应学习率，它可以根据训练数据迭代更新神经网络权值，随机梯度下降可以保持一个单一的学习率，用于所有的权重更新训练[59]，并且学习率在训练过程中不会改变。因此传统的随机梯度下降算法可以被其替代[60]。

Adam 具体过程如下[61]：

1. 输入训练样本数据集 X，全局学习率ε，矩估计衰减率ρ_1，矩估计衰减率β_1，矩估计衰减率β_2，稳定常数 δ
2. 参数初始化
3. 计算时间步长 t 的梯度g_t

$$g_t = \nabla_\theta J(\theta_{t-1}) \tag{4.15}$$

4. 计算梯度的指数移动平均值

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t \tag{4.16}$$

5. 计算梯度平方的平均移动指数

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) {g_t}^2 \tag{4.17}$$

6. 通过使用偏差对m_t进行修正

$$\widehat{m_t} = \frac{m_t}{(1-\beta_2^t)} \tag{4.18}$$

7. 对v_t进行修正

$$\widehat{v_t} = \frac{m_t}{(1-\beta_1^t)} \tag{4.19}$$

8. 更新参数

$$\theta_t = \theta_{t-1} - \alpha \times \frac{\widehat{m_t}}{\sqrt{\widehat{v_t}} + \varepsilon} \tag{4.20}$$

具体参数设置如表 4-1 所示：

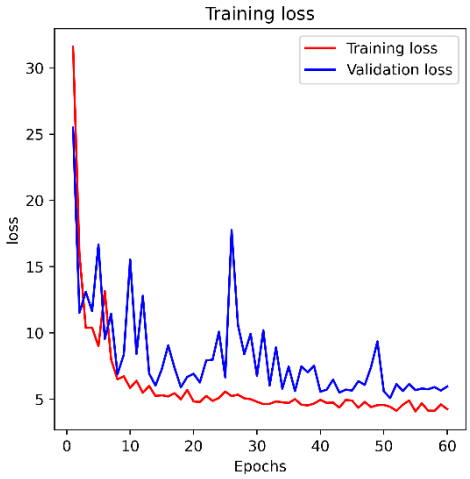
中国知网 https://www.cnki.net

表 4-1 1DCNN-LSTM 网络各参数设置

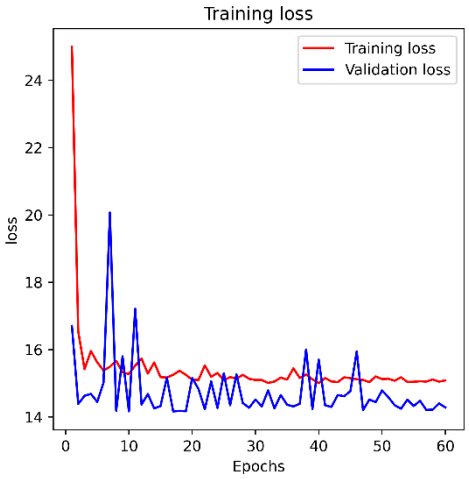
超参数	值
Num_epochs	60
Batch_size	64
ε	0.01
Convld	32
Convld_1	64
Convld_2	128
Convld_3	64
Convld_4	64
LSTM	32
LSTM_1	64
LSTM_2	128
Input_featuers	24
Output_class	24

训练次数为 60，最大迭代次数为 64，学习率 0.01，第一层 Conv1D 卷积核数目为 32、64、128，第二层 ConvlD 卷积核数目依次为 64、64，LSTM 网络部分共设置 3 层 LSTM 网络层，各层神经元数目依次为 32、64、128，输入 24（特征为 9），输出 24（特征为 1）。

使用 Keras 进行 1DCNN-LSTM 神经网络模型的拟合预测，为验证 1DCNN-LSTM 神经网络模型在短期负荷预测中的优越性，将 1DCNN-LSTM 网络模型与 1DCNN、RNN、LSTM、1DCNN-RNN 这几类预测模型进对于，迭代次数均为 60 次，迭代 loss 曲线如下图所示：

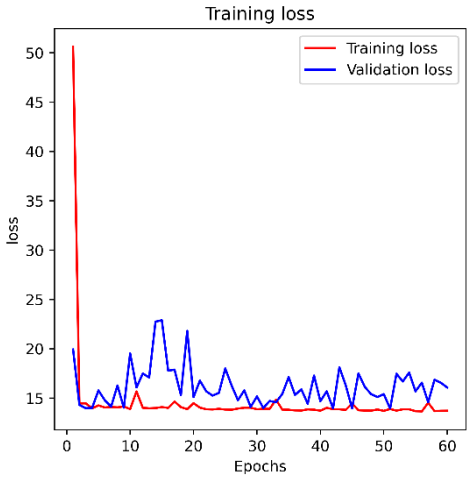


1DCNN-LSTM loss 图

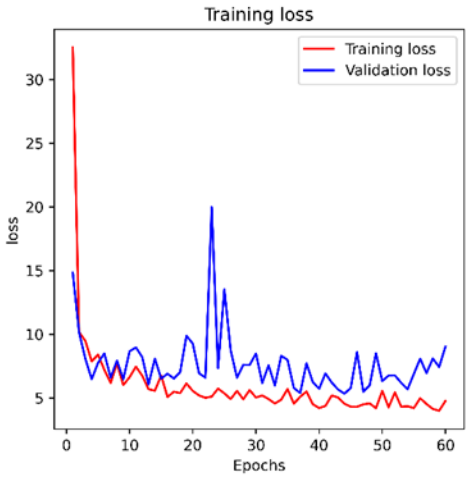


1DCNN loss 图

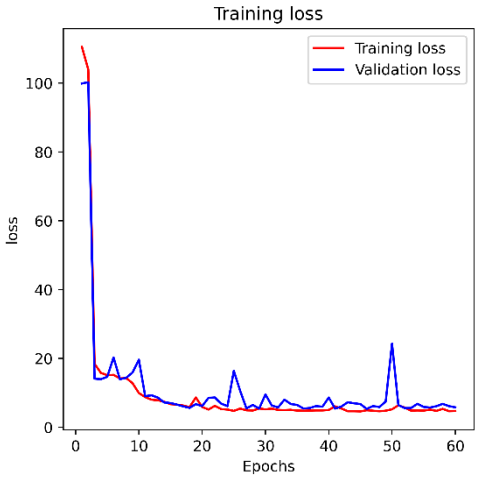
中国知网 https://www.cnki.net



LSTM loss 图



1DCNN-RNN loss 图



RNN loss 图

图 4-12 各类模型预测 loss 图

各种模型在经过 60 次迭代之后，模型 loss 函数基本趋于稳定，由图 4-12 不难发现，RNN 网络和 1DCNN-LSTM 的拟合情况优于其他网络，随后对各类模型展开预测实验，预测结果如图 4-13 所示：

中国知网 https://www.cnki.net

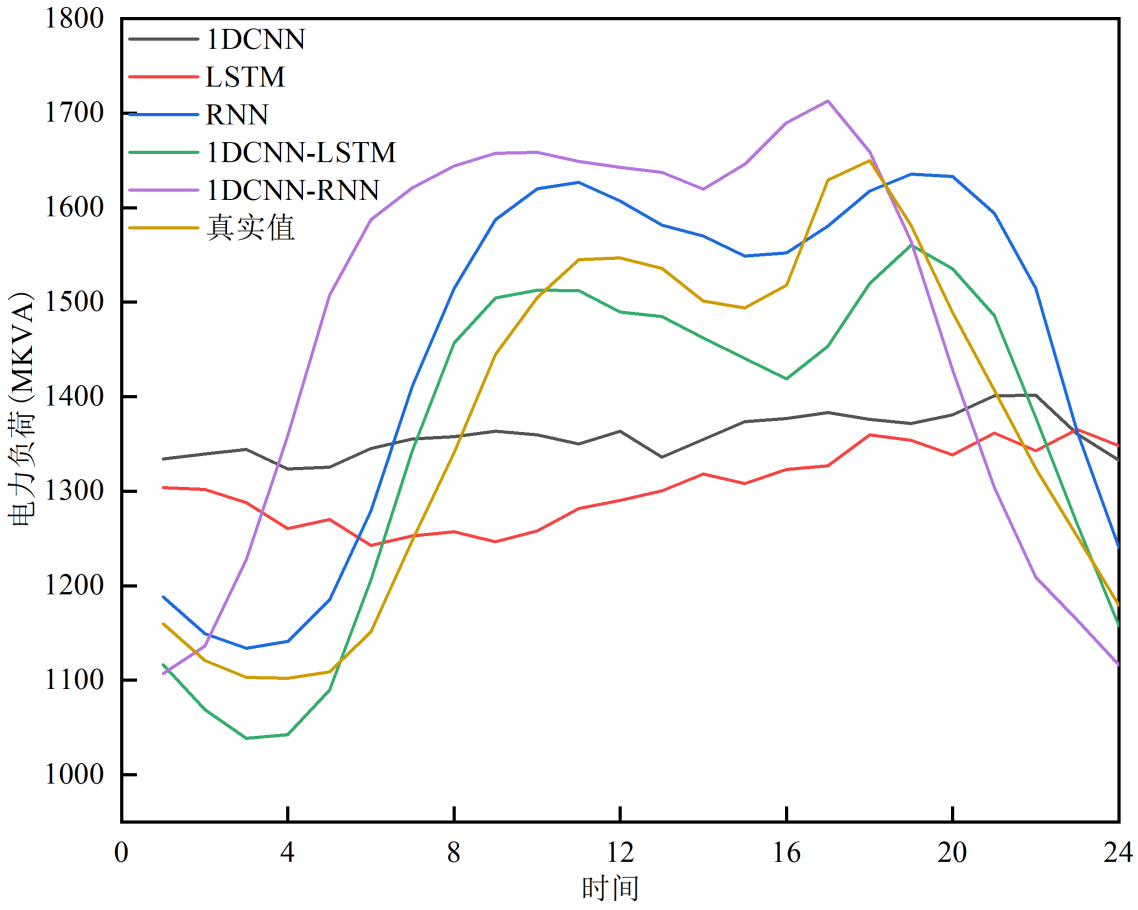


图 4-13 预测结果对比图

图像曲线为测试集最后一天 0 点至 24 点的电力负荷曲线。为了更加直观的分析各类预测模型的预测精度，分别计算各类预测模型的预测评估指标，结果如表 4-2 所示。

表 4-2 预测评估指标

预测模型 / 评估指标	1DCNN	LSTM	RNN	1DCNN-LSTM	1DCNN-RNN
MAPE	11.78%	12.24%	6.47%	4.35%	11.65%
MAE	157.73	170.41	87.48	60.21	150.33
RMSE	171.93	187.58	102.57	71.56	191.087
预测精度	88.22%	87.76%	93.53%	95.65%	88.35%

由上表可知，预测效果最优的模型为 1DCNN-LSTM，其 MAPE 为 4.35%，MAE 为 60.21，RMSE 为 71.56，负荷预测精度为 95.65%，各项参数指标均为最优。分析其原因：1DCNN-LSTM 神经网络预测模型，结合了一维卷积神经网络在特征提取上的优势和 LSTM 神经网络的长时记忆功能，能有效防止梯度消失和梯度爆炸。在本次实验中，1DCNN-LSTM 网络拟合情况良好，表明模型在拟合训练中表现稳定，也进一步佐证了该模型在本次实验中的优越性。

4.5 本章小结

中国知网 https://www.cnki.net

本章考虑历史负荷数据、时间、温度等参数对短期电力负荷预测的影响，提出1DCNN-LSTM 短期电力负荷预测方法，实验表明，1DCNN-LSTM 模型预测精度符合初步期望，可为短期电力负荷预测提供可靠信息，并为下一章，将迁移学习与该网络融合提供基础。

中国知网 https://www.cnki.net

第五章 基于深度学习和迁移学习的短期电力负荷预测

5.1 引言

常规的机器学习，特别是监督的学习一般基于两个基本的前提条件：第一，在数据之间的分配时一致的；第二，有很多标签资料。然而，在预测实验中，由于多种原因，例如数据间的分布存在差异、数据的不充分等问题都会使机器学习的效果不如人意。如何克服这一问题，进而在这样的条件下依旧可以保障模型的精度成为众多学者研究的热点。基于这一问题，学者逐步发现迁移学习，试图从相似的领域和任务中发现共同点，寻求解决方案。

维基百科中关于“迁移学习”的概念如下：“迁移学习”是一种新的机器学习方式，能够利用现有的知识解决各种与之有关的问题[62]。具体而言，是一种在两个具有一定相似性或者关联性的领域中，利用数据、任务、模型等作为媒介，将一个领域的“知识”用来解决另一个相关领域的问题。当源域和目的域之间存在符合实验要求的关联性时，源域的各类数据、提取出的数据特征、源域预训练完毕的预测模型都可以作为迁移的对象，进而帮助目的域解决问题。迁移学习可以让机器学习的过程发生改变，它不仅可以降低对样本的需求，而且可以提高模型训练效率。

在负荷预测领域，使用深度学习或机器学习进行负荷预测需要建立在一个完备、数据量充足的情况下，第四章已经描述了如何在数据完整的情况下，使用 1DCNN-LSTM 网络进行短期负荷预测，本章将在其基础上，针对目的域历史数据不足这一特殊场景，引入迁移学习，进行短期负荷预测。

5.1.1 迁移学习的基本概念

迁移学习是指在新的领域中，从有关领域中迁移相关知识的方法。我们可以从真实生活中获的一些“迁移”的例子。假设有两个想学弹钢琴的人，其中一个人没有学习过任何音乐的经验，而另外一个人从事音乐教学，有着广泛的音乐知识。拥有广泛音乐知识的人可以把他的音乐知识“迁移”到钢琴学习上，从而可以更高效地学习钢琴[63]。

领域（Domain）和任务（Task）是迁移学习中两个重要概念。之前学习过任务为“源任务”，对应的领域为“源域”；准备学习的任务为“目标任务”，对应领域为“目标域。下面给出相关概念的基本解释：

领域（Domain）：领域D由一个二元组$\{X, P(X)\}$组成，一般用$D = \{X, P(X)\}$表示。它包含两个部分：特征空间$X = \{x|x_i \in X, x = 1,2,\cdots,n\}$和边缘分布$P(x)$。

任务（Task）：对于某个给定的领域 D，任务 T 也是由一个二元组$\{Y, f(\cdot)\}$组成，可以表示为$T = \{Y, f(\cdot)\}$。其中，Y为标签空间，$f(\cdot)$是领域D的目标预测领域。$f(\cdot)$没有给出，可以从已有训练数据$\{x_i, y_i\}, x_i \in X, y_i \in Y$学习得到，$f(\cdot)$有时被表示为条件概率分布$f(x) = Q\big((y|x)\big)$。

中国知网 https://www.cnki.net

迁移学习（Transfer Learning）已知源域D_S和源任务T_S，目标域D_T和目标任务T_T，迁移学习旨在使用源域D_S和T_S中的知识去解决或是提升、改进对于目标域的预测函数$f(\cdot)$的学习，其中$D_s \neq D_t$，$T_s \neq T_t$。其基本示例如图 5-1 所示：

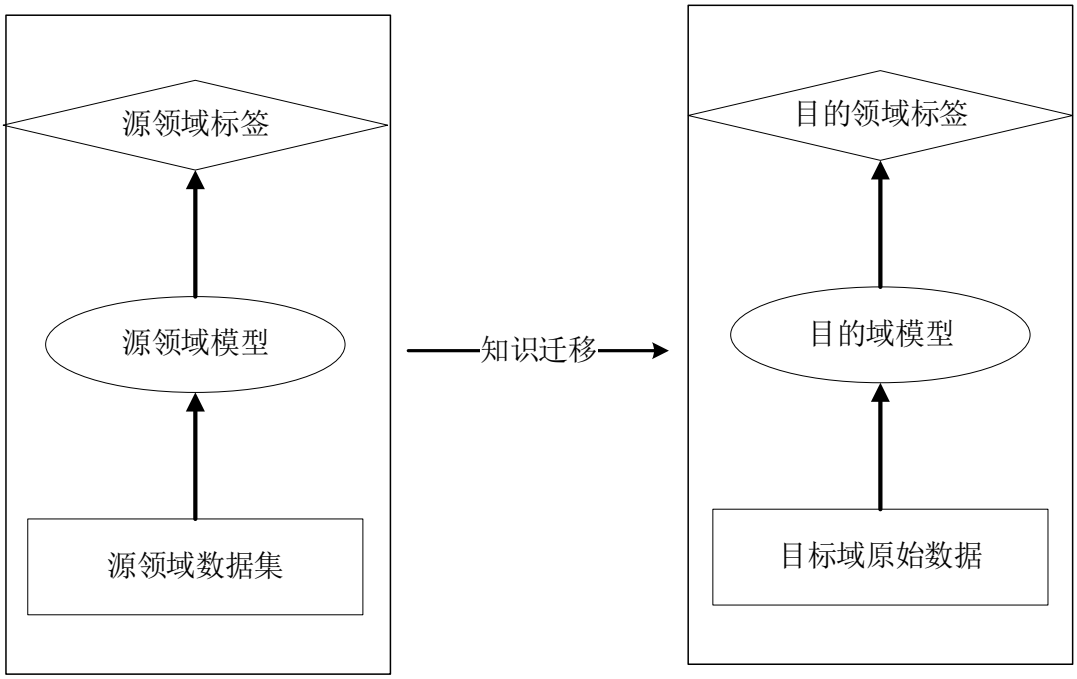


图 5-1 迁移学习基本示例

5.1.2 迁移学习的目的

迁移学习的目的可以分别从主观上考虑和从客观上考虑。从主观上讲，迁移学习是希望从源域获取一定的知识，进而为目的域服务。从客观上讲，现实的研究中，由于各种各样的因素，会出现数据不足或缺失的问题，为了克服这么一个问题，顺利地完成预期任务，我们希望得到迁移知识的帮助。

一般来讲，迁移学习的有效性可以从以下三个方面进行判断：

1. 目标任务是否因迁移学习的介入才得以顺利完成或迁移学习是否在任务中发挥了关键性作用。

2. 在进行迁移学习后，对于目标任务而言，其任务完成所需时间是否减少。

3. 在迁移学习的作用下，目标任务的完成状况是否得到改善，可从任务完成度进行权衡。

上述三个标准均可用于简单的判断迁移学习是否有效[64]。如果采用迁移学习之后的结果并没有达到以上要求，甚至出现了学习率降低和学习效果变差，那么可以初步判定此次迁移是负迁移。因此，在迁移学习中，寻找合适的源域以及采取适当的方法，既能有效防止负迁移现象的出现，又可以有效提升正向迁移的效果。

5.1.3 迁移学习的基本分类

迁移学习关注的重点用一句来概括就是“什么时候对什么内容采取什么样的方式进

中国知网 https://www.cnki.net

行迁移”。其中，“什么内容”是指有哪些可以迁移的知识在源域和源任务当中。通常，这种知识可以被分为两类，一类是共有的，即源域和目的域中共有的；另一类是特有的，是指在特定领域所拥有的。接下来要处理的问题是“采取何种方式迁移”，“采取何种方式”与迁移的相关技术有关。最后的问题是“什么时候进行迁移”，这一问题的关键在于迁移的时间，如果迁移时间不合适，不但对问题产生优化作用，还可能造成一定的负面效果。

对迁移学习进行基本分类，有以下分类参考：源域和目标域数据之间是否具有相同的数据标签，源任务和目标任务是否归属于同一类型的任务等，通过以上参考，可以将迁移学习划分为以下三类：归纳式迁移学习、直推式迁移学习、无监督迁移学习[65]。下表给出三种迁移学习下“域”和“任务”之间的关系以及相对应的学习场景。

表 5.1 迁移学习基本分类

迁移学习类别	归纳式迁移学习	直推式迁移学习	无监督迁移学习
源域与目标域关系	相同/不同	不同但相关	不同但相关
源任务与目标任务关系	不同但相关	相同	不同但相关
源域标签	有标签/无标签	有标签	无标签
目标域标签	有标签/有标签	无标签	无标签
学习场景	归回、分类	回归、分类	聚类、降维

1. 归纳式迁移学习：归纳式迁移学习中，源任务和目标任务可能相似，也可能存在差异，但二者之间存在一定的关联性，即$D_s \neq D_t$或$D_s = D_t$，$T_s \neq T_t$。归纳式迁移学习是一种被广泛使用的学习方式，它与多任务学习相似，但二者之间也存在一定差异，即：归纳式迁移学习是通过将源域内的知识迁移到目的域来实现，而多任务学习则是在不同领域实现不同的任务[66]。当源域不存在标签信息，而目标域存在时，归纳式迁移学习与自我学习相似，不同之处是归纳式学习的源域没有标签信息数据。

2. 直推式迁移学习：直推式迁移学习使用的场景要求较高，通常是当源域和目标域的任务要求一致时，采用该方法，并且在该类学习方式中，源域和目标域之间虽然存在关联性，但两者有本质上的差别：源域数据有标签，而目标域数据无标签，即$D_s \neq D_t$，$T_s = T_t$。这一方法通常用于分类问题和回归分析任务。

3. 无监督迁移学习：在这种模式下，源域和目标域属于不同类型的域，但两者之间仍具有一定相关性，这一区别同样适用于源任务和目标任务，即$D_s \neq D_t$，$T_s \neq T_t$。无监督迁移学习还具有很特殊的点：源域和目标域数据都没有标签。这一方法主要用于聚类、降维等无监督学习任务。

5.1.4 迁移学习的方法

迁移学习所研究的问题可以用“对什么东西进行迁移学习”来描述，或者简单来讲就是“迁移什么”，这里指的是不同的领域或者不同任务之间哪部分“知识”可以进行迁

中国知网 https://www.cnki.net

移。在迁移学习中，有着样本迁移、参数迁移、分级迁移和特性表达迁移等多种迁移方式。下面对几类常见的迁移学习方法及方法特征进行简要介绍：

1. 样本迁移：将数据样本选择性迁移，并用于解决目的域的问题，这种方法被学者称为样本迁移，这也是最为直接也是最为便捷的迁移学习方式之一[67]。当采用样本迁移的时候，往往不会对数据样本的内在信息进行解读，首先观察样本的标签信息，对标签中所蕴涵的信息进行理解，如果标签信息反馈的信息是有效的、可利用的，将直接迁移该样本，并在目标任务中使用该类样本解决问题。这一方法在某些特定场景下表现效果突出，其中典型场景为：源任务的训练样本以及分类标签充足，而目标任务训练样本数不足，同时源任务与目标任务之间存在一定关联性，当这三者同时被满足时，就可以通过样本迁移来完成目标任务[68]。

2. 参数迁移：这种迁移方式属于归纳型迁移学习，其关键在于将有关信息以参数的形式传输到目标任务中[69]。

3. 分级迁移：实际工作中，各种工作都有其特殊性，其困难程度也不尽相同，将一个工作依据其难易程度划分为若干个工作，并针对性进行工作安排，可以极大程度上提升整个任务的效率。将这一理念用于迁移学习当中，将复杂的目标任务分解为若干个简单的源任务，来帮助解决目标任务所遇到的问题。

4. 特征表述迁移：这种迁移方式更侧重细节的迁移，比如样本与样本之间的映射关系，目标与目标之间表示方法的传递等。其主要的中心思想与之前的一些迁移方式有所不同。

5.1.5 负迁移

在迁移学习中，目标任务与源任务的相似程度对迁移学习的效果有很大的影响。当源域与目标域或源任务与目标任务之间相似度高，在这一基础上进行的迁移通常是有效的。而当源域与目标域或源任务与目标任务之间相似度低，在这基础上进行的迁移学习通常无法发挥其预测的效果，甚至对目标任务起反作用，降低学习效率和学习效果，通常将这类起反作用的迁移称为负迁移。

目标任务与源任务的相似度直接决定了迁移是否有效。若目标任务和源任务之间具有高度的相似性，通常可认为此次迁移时有效的，进而可以对目标任务提供优化以及提升学习效率等，相反，当两者之间的相似度比较低时，就很难实现有效的迁移，不仅无法提高目的域学习效率，还会产生负迁移。

负迁移现象的出现，极大程度对迁移实验产生了不良影响，为尽可能将不良影响减小至最小范围，针对实验中使用源域及源任务中包含的信息，制定以下规则：

1. 在其他各条件允许的情况下，仅在迁移任务开始时，对源域和源任务相关信息进行迁移利用。

2. 在迁移任务中，有选择性的迁移源域和源任务信息，进而促进目的任务顺利完成。

中国知网 https://www.cnki.net

在实验环境中，有效的迁移学习被学者认定应当具备识别源域和目的域以及源任务和目的任务之间相似度的能力。从而在产生正迁移的同时避免负迁移。然而，当我们也可以为避免负迁移现象出现，采取相应的措施，例如选择地利用源域信息，而这将导致在避免负迁移现象产生的同时也降低了迁移学习所带来的正优化效果。然而，若不加以适当的措施，可能会造成负迁移，将直接导致目标任务无法完成。所以，必须在二者之间进行折中，根据具体的情形，采用相应合理的措施。下面将介绍一些常规方法来避免负迁移现象出现：

1. 规避负面信息：这种方式主要是通过对源任务中会对目标任务产生负面影响的信息进行分析，以尽量减少负面信息对目标任务的不良作用。该方法的目的就是为了最低限度的保障目标任务在完成时不会因为不良信息的所带来的影响而退步。在一些极端的情形下，目标任务会选择性忽略源任务，进而使得迁移学习与常规机器学习一样，即没有优化也没有负优化。

2. 选择最优源任务：假设初始源任务不止一个，那么这也代表有更大该概率选出一个与目标任务相似度极高的源任务。为实现这一目标，需要在大量的源任务之间寻找。这种方式的优点是：由于已经有了多种不同的源任务，因此可以假设，一定可以寻找一个更接近于目的任务的源任务。这样，就可以不用为所选择的源任务中包含的丰富信息采取任何防护措施，而是可以充分地利用源任务以及源任务中包含的信息，这样既能有效防止预测实验中出现负迁移现象，又没有降低预期中采用迁移所带来的优化效果。将所有的源任务按与目标任务的相似程度排列，这是一种便于筛选出最为合适的源任务的途径，此时，相似度最高的源任务称为迁移的最优对象。

3. 任务相似性建模：在选择最优源任务的基础上，考虑利用多个源任务进行迁移，为此需要以相似度为参考因素，对拟迁移的多个源任务进行权重分析。这一方式虽然可以极大程度上提升目标任务完成效果，但相应带来的是，迁移模型的复杂性、最终优化结果的不确定性以及多源任务之间的匹配性问题。

5.2 基于电力负荷数据迁移的短期电力负荷预测

数据样本迁移，属于分类中的样本迁移。即在众多电力负荷数据中，选择合适的数据进行迁移。这一类迁移需要提前考虑源域与目标域之间的相关性：数据类型、数据标签等。假设源域和目标域之间的数据几乎不相关，那么将大概率导致负迁移的现象，即迁移学习带来了负面的学习效果。本文采用的负荷数据时间标签一致、特征标签类型一致、属于同一类型数据，所以可以采用数据样本迁移。

源域的选取结果与最终构建的预测模型精度息息相关，能否选择出最优源域直接关系到最后实验结果，如果源域选择出现问题，将有可能导致负迁移现象出现。因此，合理的选取源域是迁移学习首先要解决的问题。

历史数据不足严重影响到卷积神经-长短记忆网络的精度。当试图用迁移学习来解决数据不足所导致的精度下降的时候，会有诸多选择性。例如，现有美国九州电路负荷

中国知网 https://www.cnki.net

数据，其中一个州（ME）电力负荷数据量较少，无法采用 1DCNN-LSTM 网络对其进行短期负荷预测，与此同时，其他八个州电力负荷数据完备。九个州分别为：内布拉斯加州（NE）、康涅狄格州（CT）、麻萨诸塞州（MASS）、缅因州（ME）、新罕布什尔州（NH）、罗得岛州（RI）、得克萨斯州（TX）、佛蒙特州（VT）、南达科他州（SD）。

针对这一问题，拟采用电力负荷参数迁移这一手段，基本框架如图 5-2 所示。

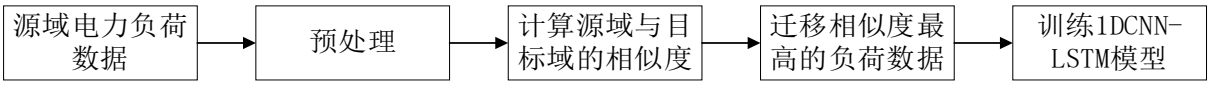


图 5-2 迁移电力负荷数据的负荷预测方法框架

选择合适的电力负荷数据进行迁移为最为关键的一步。由于本章节采用的数据集为同一类型数据集，时间标签一致，所以采用欧几里得距离（公式 5.1）作为衡量。九个州一周电力负荷曲线如图 5-3 所示：

$$d(x,y)=\sqrt{\left(\sum(x_i-y_i)^2\right)} \tag{5.1}$$

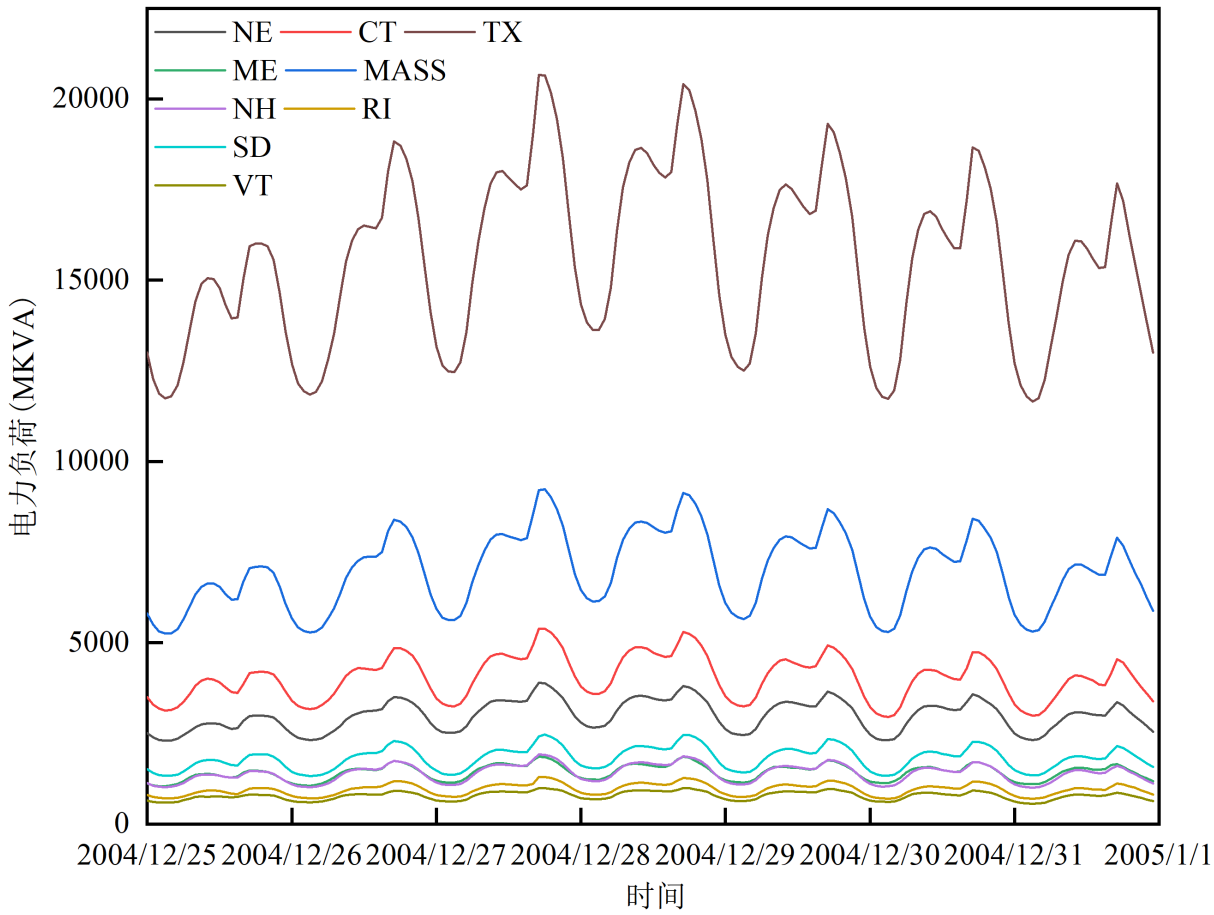


图 5-3 电力负荷曲线

经计算可得以 ME 基准的欧几里得距离之和，如表 5-1 所示，欧几里得距离是表示每个时间点上，两个区域的电力负荷差的绝对值，所以欧几里得距离之和越小，即两个区域的负荷点对应的差值越小，两个区域的相似度越高。从表中不难发现，在以 ME 为

中国知网 https://www.cnki.net

基准的情况下，NH 与 ME 之间的欧几里得距离最小，故而本章将以 ME 为目的域，NH 为源域开展基于负荷数据迁移的电力负荷预测实验。

表 5-2 以 ME 为基准欧几里得距离

地区	CT	MA	NE	NH	RI	SD	TX	VT
欧几里得距离	383055	809858	227704	4827	67775	57598	2063036	92560

在确定迁移域后，针对目的域数据量少的这一情况，选择从 NH 中迁移数据对 ME 进行数据补充，此时迁移数据的多少会对预测精度有显著影响。以下将分别迁移 NH 三个月、六个月、九个月的电力负荷数据对其进行补充后进行短期电力负荷预测。预测结果如图 5-4 所示，预测结果评价参数如表 5-3 所示。

在预测实验中，通过迁移源域相关电力负荷参数，对目的域进行了补充，而在预测网络中，有训练集与测试集的划分，为保证结果对比是基于目的域数据进行的，应选择导出其测试集最后一组预测数据。

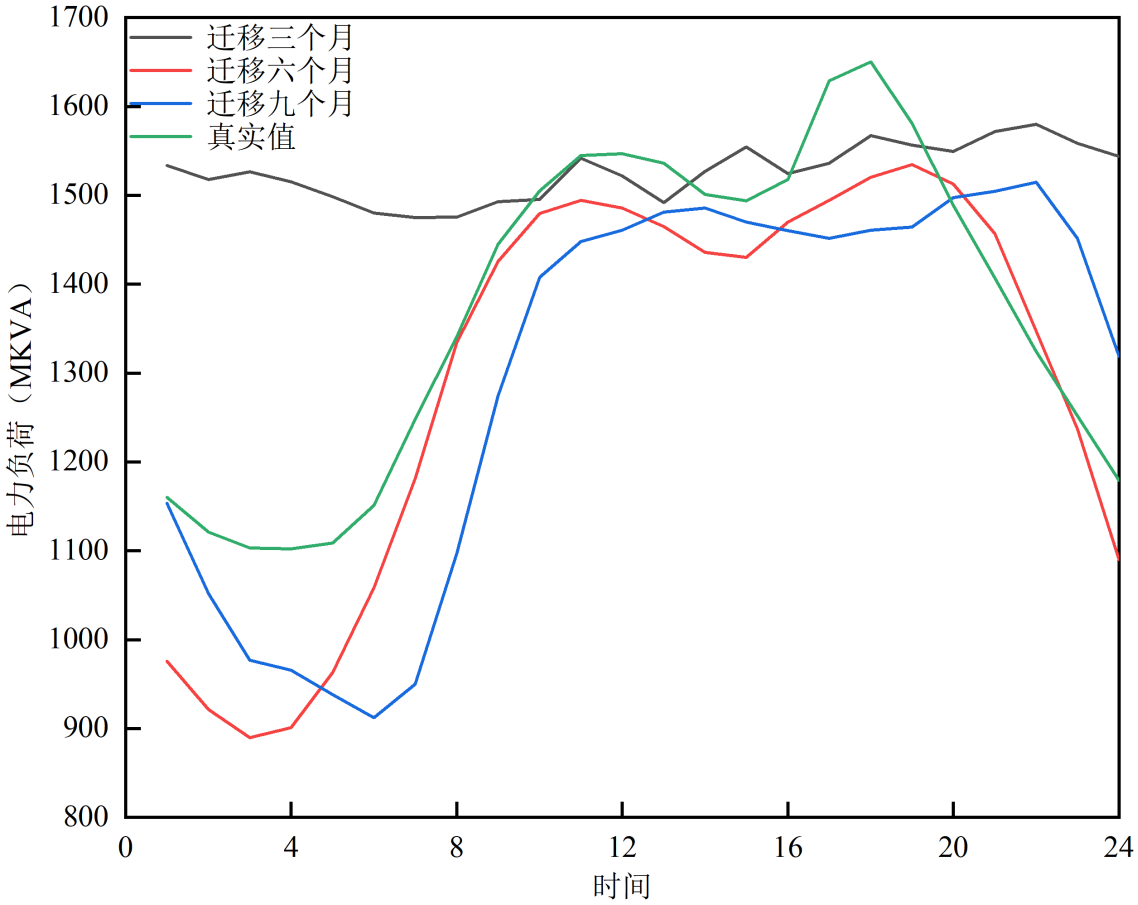


图 5-4 迁移预测结果

中国知网 https://www.cnki.net

表 5-3 数据迁移结果评价

类型	迁移三个月	迁移六个月	迁移九个月
MAPE	14.7%	6.65%	9.51%
MAE	117	84	125.53
RMSE	235	105.31	147.58

由表可直观分析得出，当迁移源域 6 个月电力负荷数据时，1DCNN-LSTM 网络预测效果最优，预测精度可达 93.35%，而当迁移源域 3 个月电力负荷数据时，预测结果则相应较差。

通过电力数据迁移，能有效解决目的域电力负荷少时无法利用深度学习这类方法进行短期负荷预测，但由于没有融合目的域自身的电力负荷的特征，导致其预测精度会在一定程度上低于完备数据集下所进行的负荷预测。从结果上分析，该方法能有效促进短期电力负荷预测任务的完成，属于有效迁移。

5.3 基于网络参数迁移的短期电力负荷预测

本章节采用网络参数迁移进行短期电力负荷预测。在 5.2 中，在确定目的域的前提下，通过欧几里得距离计算，筛选出最佳源域，并通过电力负荷数据迁移的方法顺利完成短期电力负荷预测。本节选择采用迁移预测网络参数的方法进行短期电力负荷预测。具体流程如图 5-5 所示，首先通过初期数据对比，依据源域与目的域之间的相关性，选择出关联性最高的目的域与源域；然后，在源域，完成数据充足情况下的短期负荷预测模型的训练，将该模型的参数全部迁移到目的域预测模型作为初始参数；接着，固定目的域模型的前 1 层参数，利用目的域样本数据微调其余参数，最终完成预测模型训练。

中国知网 https://www.cnki.net

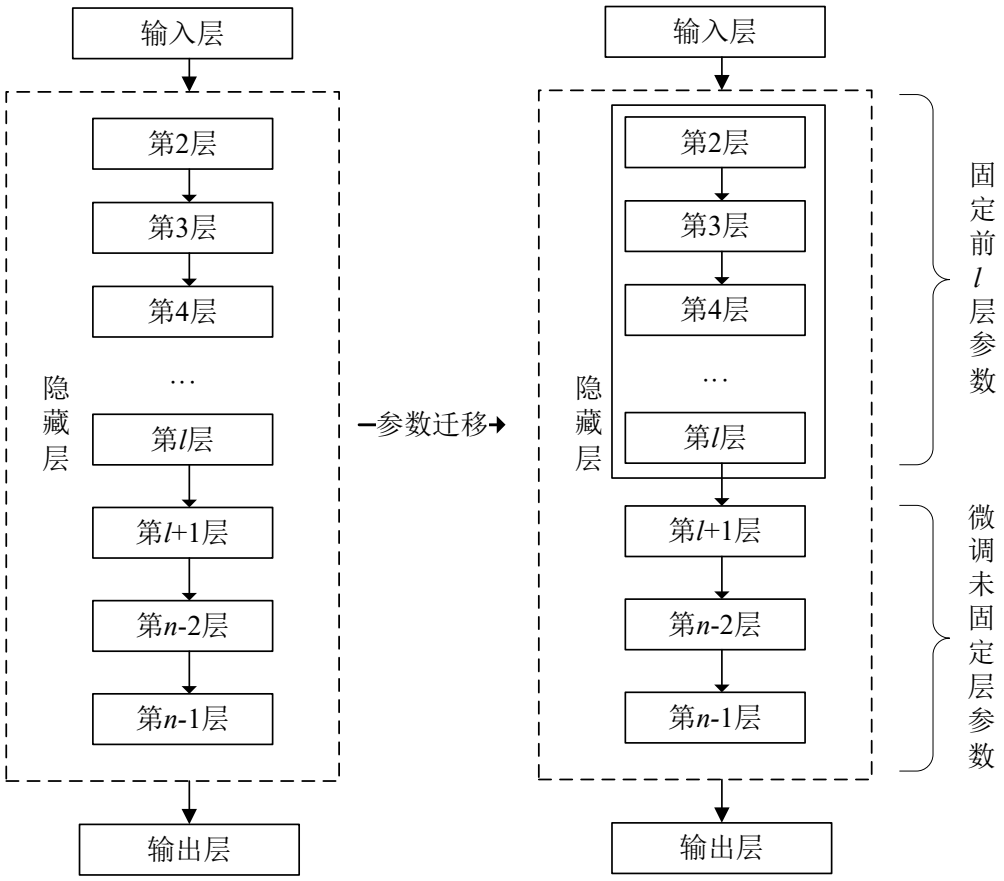


图 5-5 网络参数迁移流程图

本文以 ME 为目的域，NH 为源域，使用目的域时间长度为一周的电力负荷数据与源域时间长度为一年的电力负荷数据来进行仿真。源域预测模型为 1DCNN-LSTM 网络，其参数如表 4-1 所示。

本章对比如下负荷预测方法，如图 5-6 所示。

P1：建立 1DCNN-LSTM 预测网络，将 ME 数据集最后一天作为输入，输出即为预测结果。

P2：迁移源域建立的 1DCNN-LSTM 预测模型，不冻结参数层，利用目的域前 6 天的电力负荷数据对预测模型进行微调。

P3：同 P2，冻结至倒数第二层参数。

P4：同 P2，冻结至倒数第三层参数。

P5：同 P3，冻结至倒数第四层参数。

中国知网 https://www.cnki.net

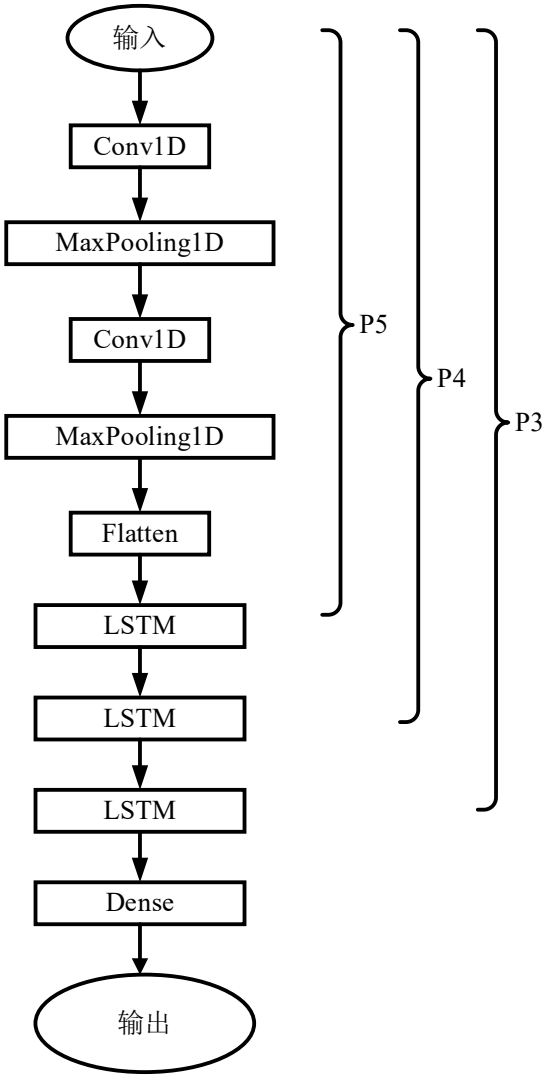


图 5-6 迁移网络结构图

源域建立的 1DCNN-LSTM 预测模型，其网络构架如表 5-4 所示：

图 5-4 模型层次图

Layer（type）	Output Shape	Param#
Conv1d（Conv1D）	(None,24,32)	320
Conv1d（Conv1D）	(None,18,64)	14400
Conv1d（Conv1D）	(None,14,128)	41088
Max_pooling1d（MaxPooling1D）	(None,7,128)	0
Conv1d（Conv1D）	(None,5,64)	24640

中国知网 https://www.cnki.net

Conv1d（Conv1D）	(None,4,64)	8256
Max_pooling1d_1（MaxPooling1D）	(None,2,64)	0
Lstm（LSTM）	(None,2,32)	12416
Lstm_1（LSTM）	(None,2,64)	24832
Lstm_2（LSTM）	(None,128)	98816
Dense（Dense）	(None,24)	3096

对于微调模型部分，对初始学习率采用试样法，调用 Adam 优化以及 RMSprop 优化，Adam 优化具体流程在上一章节已经介绍，现对 RMSprop 优化算法进行简单介绍。RMSprop 优化算法在 AdaGrad 算法的基础上，引入了衰减系数来控制历史信息的获取多少，从而对损失函数在更新中存在摆幅过大的现象进行优化处理，并且可以进一步加快函数的收敛速度[70]。

RMSprop 具体如下：

1. 输入训练样本数据集 X（样本数为 m），全局学习率ε，矩估计衰减率 ρ
2. 参数初始化
3. 计算时间步长 t 的梯度g_t

$$g_t = \frac{1}{m}\nabla_\theta \sum_i L(f(x^i,\theta),y^i) \tag{5.2}$$

4. 计算累计平方梯度

$$\gamma = \rho\gamma + (1-\rho)g^2 \tag{5.3}$$

5. 计算参数更新

$$\Delta\theta = -\frac{\varepsilon}{\sqrt{\delta+\gamma}}g_t \tag{5.4}$$

分别将学习率设置为 RMSProp lr=0.01，RMSProp lr=0.001，RMSProp lr=0.0001，Adam lr=0.01，Adam lr=0.001，Adam lr=0.0001。对其损失函数 loss 进行比对。对比结果如表 5-5 所示：

表 5-5 学习率对比图

类别	学习率	Loss
RMSprop	0.01	4.308
	0.001	7.977
	0.0001	7.227
Adam	0.01	8.500
	0.001	8.347

中国知网 https://www.cnki.net

	0.0001	8.413

该项对比是建立在冻结网络至网络的最后一层即 lstm_2，后调整学习率得到的损失函数对比。由表可知，当选择使用 RMSprop 优化算法，设置学习率为 0.01 时，其损失函数最小。

P1-P5 预测结果如图 5-7 所示：

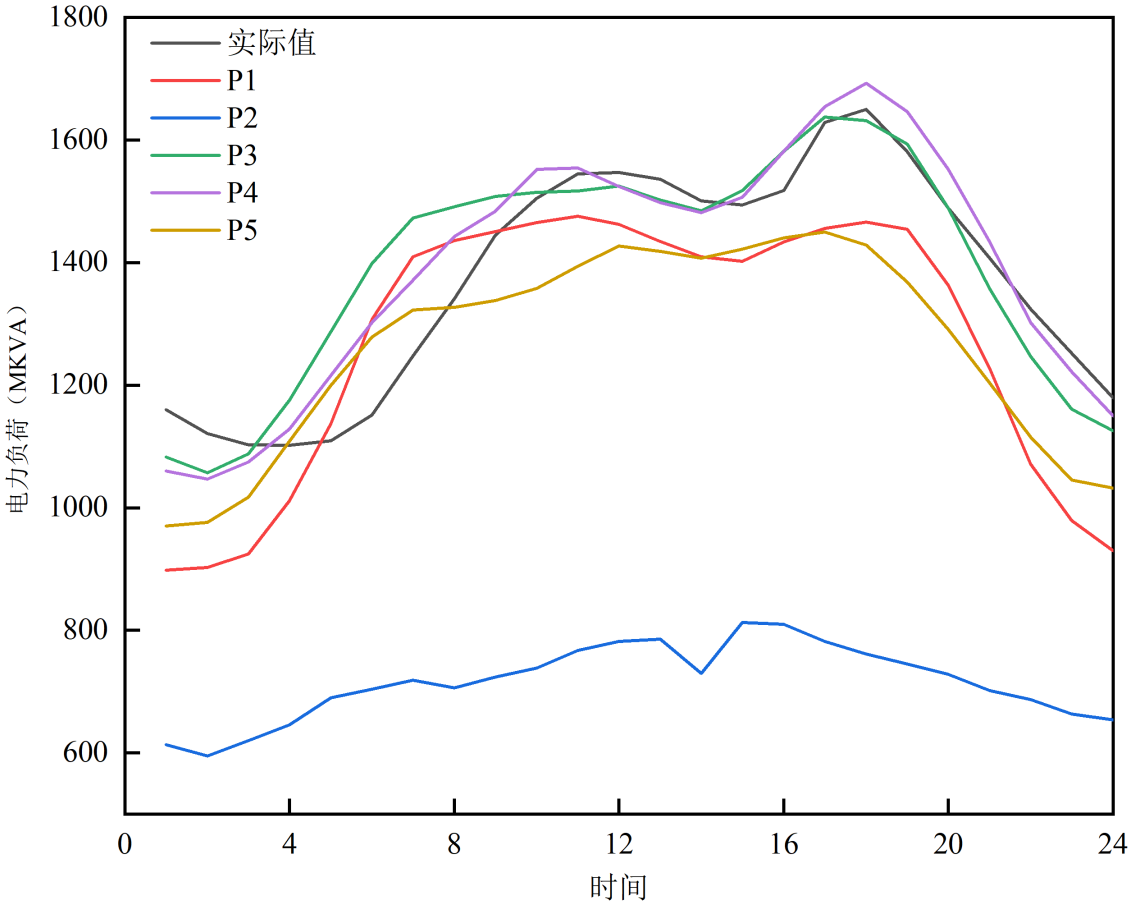


图 5-7 迁移模型预测结果

对 5 个模型预测结果进行评估，评估结果如表 5-6 所示：

表 5-6 评估参数对比图

类别	MAPE%	MAE	RMSE	精度
P1	10.53	138.36	157.12	89.47%
P2	47.43	657.15	671.03	53.57%
P3	5.34	66.72	94.29	94.66%
P4	4.09	52.86	64.83	95.91%
P5	9.70	133.18	146.23	90.3%

将各项参数转换为柱状图，直观显示如图 5-8 所示。

中国知网 https://www.cnki.net

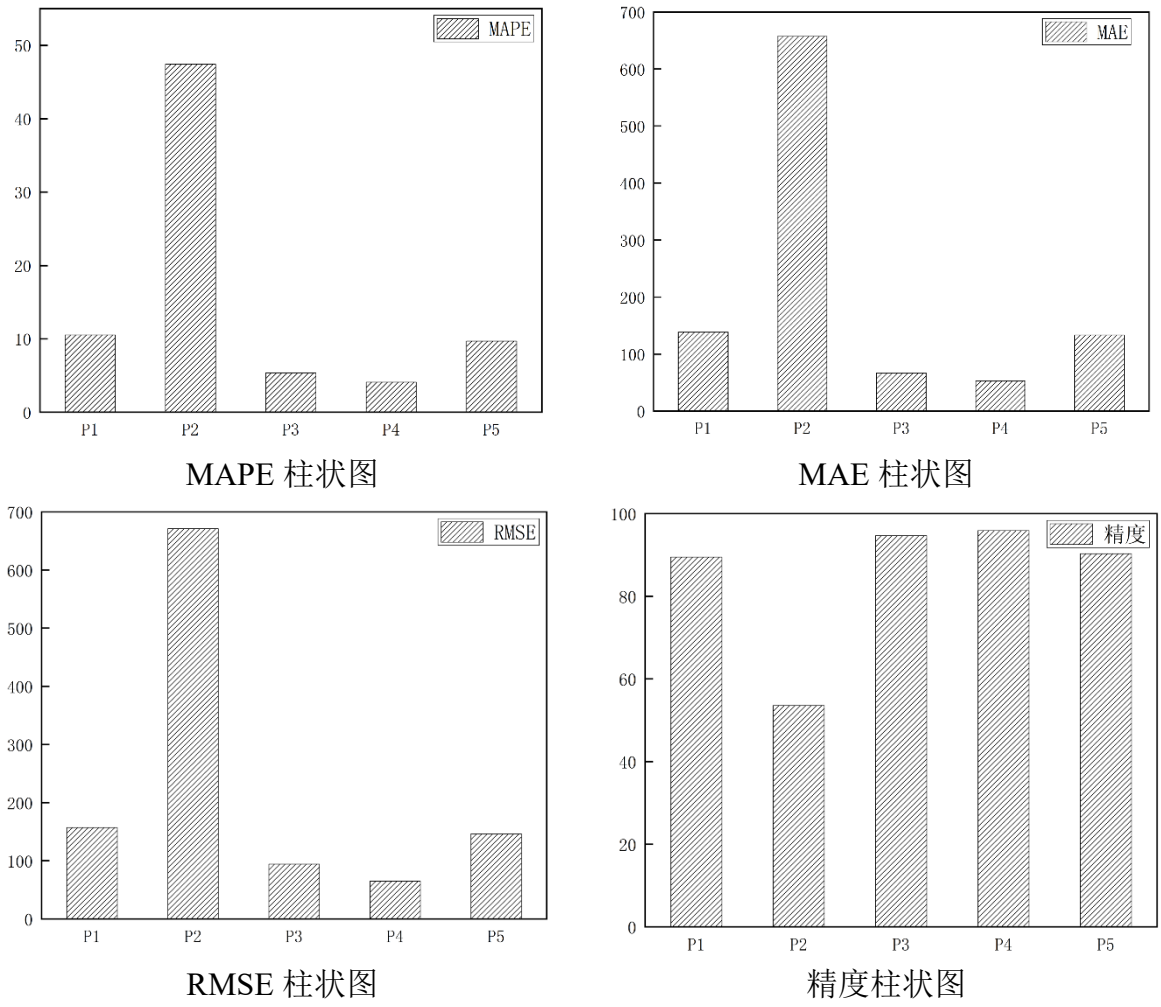


图 5-8 评估参数柱状图

通过预测曲线图和表格评估参数数据对比可以发现，在 P1-P5 模型中，P4 模型的预测精度最高（P4 为冻结至倒数第三层），其精度为 95.91%。P1 模型没有提取到目的域的负荷特征，预测精度极大程度上取决于源域模型的预测精度和源域与目的域之间的相似性；P2 模型，则采用目的域 6 天的数据（6×24 条数据），并对该数据作数据扩充，提取数据特征，但由于没有固定源域迁移的预测模型，会导致模型参数被影响，预测精度极大程度被破坏；P3-P5 是对堆叠的三层 LSTM 模型分别进行微调，根据实验结果可知，当仅对最后两次 LSTM 层进行微调时[71]，其预测精度最高。

综上所述，得益于源域电力负荷预测模型所提供的模型参数以及最后两层 LSTM 模型对目的域电力负荷特征的学习，融合了目的域的电力负荷特征之后，新的预测模型其预测效果甚至高于原基础模型，该结果也证明本章所提出的基于 1DCNN-LSTM 和模型参数迁移的预测方法能有效解决目的域数据少时电力负荷预测问题，其模型精度和稳定性都符合实验需求。

5.4 本章小结

本章主要是针对目的域数据量少的时进行的短期电力负荷预测。其主要思路为（1）

中国知网 https://www.cnki.net

迁移电力负荷数据，弥补目的域电力负荷数据的不足，进而采用 1DCNN-LSTM 网络进行短期电力负荷预测，达到对目的域进行短期负荷预测；（2）迁移预测模型参数，利用源域丰富的电力负荷数据，进行短期负荷预测模型的训练，并将其迁移至源域，最后利用目的域基本数据对模型进行微调，实现对目的域电力负荷的预测。经实验证明，两种方法均可实现目的域电力负荷数据少时，对短期电力负荷预测的需求，其精度分别达到了 93.35%和 95.91%，符合电力负荷短期预测的精度要求。

中国知网 https://www.cnki.net

总结与展望

电力负荷预测可以为电力系统安全运行以及系统规划等提供重要信息，因此它也是电力系统规划重要的一环。面对电力系统运行压力逐年增加，建设新型智能电网已经迫在眉睫。在新型智能电网的构建中，精准、高效的电力负荷预测是新型智能电力系统实现安全节能减耗、电能调度系统化管理以及电网运行安全实时监控的基础。

在电力负荷预测实验当中，由于多方原因，会出现预测实验所需电力负荷历史数据及其他相关资料出现缺失，当数据缺失严重时，极大程度的影响预测精度。因此，本文希望通过“迁移”这一思想来解决这一问题，来达到数据缺失时仍可以保持一个高精度的负荷预测。研究主要分为以下三个方面：

1. 以深度学习为切入点，实现在数据量充足的情况下，进行短期电力负荷预测。为提取电力负荷数据所隐藏的各种特征，使用一维卷积神经网络作为特征提取网络，提取完毕后采用长短期记忆网络作为预测的主体，同时对基础电力负荷数据也进行了数据扩充，以求达到更好的预测效果。算例分析表明，本文提出的基于 1DCNN-LSTM 网络的短期负荷预测精度能达到 95.64%，符合最初对电力负荷预测的精度要求。

2. 为了解决当目的域电力负荷缺失时，短期电力负荷预测精度受到极大程度的影响这一问题，本文引入了“迁移”的思想，将深度学习和迁移学习相结合，提出数据样本迁移模型和模型参数迁移模型。其中，数据样本迁移模型实验中，分别迁移三、六、九个月的电力负荷数据用来扩充目的域数据，最终实验表明，迁移 6 个月时的预测精度最高，为 93.35%。

3. 区别于迁移电力负荷相似数据，选择迁移预测模型参数。在预测模型参数实验中，分别冻结预测模型各层网络，并采用目的域基础数据对预测模型进行微调，最终算例分析表明，冻结至倒数第三层网络时，预测精度最高 95.91%。

综上所述，本文提出的方法适用于在拥有着充足电力负荷数据的源域和少量电力负荷数据的目的域所进行针对目的域的短期负荷预测，预测精度良好，负荷实际电力负荷预测所需。

目前，国内电网正处于转型期间，从传统电网转向新型智能电网，负荷预测在这一过程中，能提供巨大帮助。随着国内外研究人员对负荷预测领域的不断深入以及数学模型理论的不断发展电力系统短期负荷预测必将会出现更多新方法，这些新的方法势必在模型稳定性、模型适应性以及模型精度等方面有着巨大提升。

本文所涵盖的工作主要包括以下内容：电力负荷历史数据筛选与处理、建立基于 1DCNN-LSTM 短期负荷预测模型以及将迁移学习应用于负荷预测。在这个过程中，还有以下几个方面可以进一步深入研究。首先，本文采用的电力负荷数据中，考虑了日期因素、历史负荷因素、温度因素，并没有考虑其它气象信息、预测负荷地区的经济发展情况、传统节日等多种因素，这些因素同样也会对该地区的电力需求造成不同程度的影响，为此，在负荷预测过程中，需要对这类影响因素进行分析。其次，电力负荷需求本

中国知网 https://www.cnki.net

身带着明显的地域性标签，不同的地区，同一影响因素会造成不同的影响，这也表明，同一种电力负荷预测方法在不同地区的预测效果可能会有所差别，每种方法都有其适用地区，更多的预测方法应当被研究。目前对于短期电力负荷预测，有许许多多预测效果良好的预测模型，每种预测模型都有其优劣，因此在实际应用过程中，在不同的地区，如何从原始电力负荷数据中，挖掘信息并进行分析，最终选择出最优的预测方法成为诸多学者研究探讨的问题之一。再者，在迁移电力负荷数据时，应当充分考虑源域与目的域之间的地理关系，在相似度检验时，应当采用更加精密的算法，来确定目的域和源域。最后，随着计算机技术的发展，将大数据与负荷预测结合在一起成为现在研究的一个热点方向，如何对数据进行挖掘，如何对数据间的关系网络进行构建，如何利用大数据提升预测模型稳定性与预测精度都属于该方向的典型内容。

总之，短期负荷预测是一个牵一发而动全身的项目，无论是初期数据特征分析，还是中期预测模型构建都与最后的预测结果息息相关，如何进一步完善预测流程，建立科学、合理、高精度的短期负荷预测模型仍需要更加深入的研究。

中国知网 https://www.cnki.net

参考文献

[1] 张勇, 陶一凡, 巩敦卫. 迁移学习引导的变源域长短时记忆网络建筑负荷预测[J]. 控制与决策, 2021, 36(10):2328-2338.

[2] 陶一凡. 融合迁移学习和长短记忆网络的建筑负荷预测研究[D]. 中国矿业大学, 2021.

[3] 曾攀. 基于大数据和日日拓扑网络的短期电力负荷预测方法[D]. 湖南大学, 2016.

[4] 周末, 金敏. 多算法多模型与在线第二次学习结合的短期电力负荷预测方法[J]. 计算机应用, 2017, 37(11):3317-3322.

[5] 史哲. 含柔性直流装置的中压交流系统方向判据研究[D]. 天津大学, 2018.

[6] 盛昌. 基于节假日加权迁移学习的短期电力负荷预测[D]. 湖南大学, 2016.

[7] 胡冬霞, 黄勇. 基于集成学习的电力数据特征提取方法研究[J]. 智库时代, 2020, (24):261-261+267.

[8] 周末. 多算法多模型与在线第二次学习结合的短期负荷预测方法[D]. 湖南大学, 2017.

[9] 代林. 基于神经网络的电力负荷预测方法研究及实现[D]. 电子科技大学, 2012.

[10] 程宇也. 基于人工神经网络的短期电力负荷预测研究[D]. 浙江大学, 2017.

[11] 余泽远. 不确定性环境下电力系统风险评估及应急能力评价研究[D]. 华南理工大学, 2020.

[12] Khwaja A S, Zhang X, Anpalagan A, et al. Boosted neural networks for improved short-term electric load forecasting[J]. Electric Power Systems Research, 2017, 143:431-437.

[13] 邱金鹏, 牛东晓. 基于小波-时间序列组合模型的风电功率预测[J]. 电力建设, 2016, 37(01):125-130.

[14] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. Computer Science, 2014.

[15] Cho K, Merrienboer B V, Bahdanau D, et al. On the properties of neural machine translation: encoder-decoder approaches[J]. Computer Science, 2014.

[16] 常峰铭. 基于深度学习的智能电网短期电力负荷预测研究[D]. 湘潭大学, 2019.

[17] 杨蕊. 神经网络技术在短期电力负荷预测中的应用研究[D]. 重庆大学, 2018.

[18] 栗然, 孙帆, 丁星, 等.考虑多能时空耦合的用户级综合能源系统超短期负荷预测方法[J]. 电网技术, 2020, 44(11): 4121-4134.

[19] 刘月峰, 杨宇慧. 基于 CNN-LSTM 的短期电力负荷预测研究[J]. 科技创新与应用, 2020(01): 84-85.

[20] 刘婉兵, 李妍, 杜明秋, 等. 城市负荷空间分布的聚类群簇分析[J]. 电力系统自动化, 2019, 43(05): 59-65+82.

中国知网 https://www.cnki.net

[21] 李俊卿, 陈雅婷. LSTM-CNN 网络在同步电机励磁绕组匝间短路故障预警中的应用[J]. 华北电力大学学报(自然科学版), 2020, 47(04):61-70.

[22] 张勇, 杨康, 郝国生, 等. 基于相似历史信息迁移学习的进化优化框架[J]. 自动化学报, 2021, 47(03):652-665.

[23] Murre J M J. Transfer of learning in backpropagation and in related neural network models[J]. Connectionist Models of Memory and Language (PLE: Memory), 2014: 73.

[24] Pratt L Y. Discriminability-based transfer between neural networks[C]. Advances in Neural Information Processing Systems, 1992.

[25] Mihakova L, Huynh T N, Mooney R J. Mapping and revising markov logic networks for transfer learning[C]. National Conference on Artificial Intelligence, 2007.

[26] Mihakova L, Mooney R. Transfer learning with markov logic networks[C]. Proceedings of the ICML-06 Workshop on Structural Knowledge Transfer for Machine Learning, 2006.

[27] Gupta R, Ratinov L A. Text categorization with knowledge transfer from heterogeneous data sources[C] Proceedings of the Twenty-Third AAAI Conference on Artificial Intelligence.2008: 842-847.

[28] Xiao Ling, Gui-Rong Xue, Wenyuan Dai. Can chinese web pages be classified with english data Source?[C]. Proceedings of the 17th international conference on World Wide Web. 2008: 969-978.

[29] Hu Q H, Zhang R J, Zhou Y C. Transfer learning for short-term wind speed prediction with deep neural networks[J]. Renewable Energy, 2016, 85:83-95.

[30] Ma J, Cheng J C P, Lin C Q, et al. Improving air quality prediction accuracy at larger temporal resolutions using deep learning and transfer learning techniques[J]. Atmospheric Environment, 2019, 214:116885.

[31] Tariq S, Loy-Benitez J, Nam K, et al. Transfer learning driven sequential forecasting and ventilation control of PM2.5 associated health risk levels in underground public facilities[J]. Journal of Hazardous Materials, 2020, 406: 124753.

[32] Gautam Y. Transfer Learning for COVID-19 cases and deaths forecast using LSTM network[J]. ISA transactions, 2021.

[33] Nguyen T, Le N, Tran T A, et al. Incorporating a transfer learning technique with amino acid embeddings to efficiently predict N-linked glycosylation sites in ion channels[J]. Computers in Biology and Medicine, 2021, 130(05): 104212.

[34] Deng Z, Chen Q. Reinforcement learning of occupant behavior model for cross-building transfer learning to various HVAC control systems[J]. Energy and Buildings, 2021, 238: 110860.

[35] 蔡秋娜, 苏炳洪, 闫斌杰, 等. 基于参数迁移的节假日短期负荷预测方法[J]. 电气自动化, 2020, 42(04): 59-60+98.

中国知网 https://www.cnki.net

[36] 孙晓燕, 李家钊, 曾博, 等. 基于特征迁移学习的综合能源系统小样本日前电力负荷预测[J]. 控制理论与应用, 2021, 38(01): 63-72.
[37] 田晓. 电力负荷管理系统中的短期负荷预测技术的研究[D]. 东北大学, 2008.
[38] 吴京秋, 孙奇, 杨伟, 等. 基于 D-S 证据理论的短期负荷预测模型融合[J]. 电力自动化设备, 2009, 29(04): 66-70.
[39] 刘继胜. 基于人工神经网络的电力系统短期负荷预测的应用分析[D]. 华北电力大学（北京）, 2011.
[40] 谢燕琼. 电力系统中短期负荷预测的研究[J]. 大科技: 科技天地, 2011(12): 2.
[41] 廖旎焕, 胡智宏, 马莹莹,等. 电力系统短期负荷预测方法综述[J]. 电力系统保护与控制, 2011, 39(01): 147-152.
[42] 覃芳璐, 李滨, 吴茵. 基于气象灵敏度分析和特征日修正的短期日负荷曲线预测[J]. 广西电力, 2018, 41(03): 10-16.
[43] 唐俊熙, 曹华珍, 高崇, 等. 一种基于时间序列数据挖掘的用户负荷曲线分析方法[J]. 电力系统保护与控制, 2021, 49(05): 140-148.
[44] 包满. 基于 Elman 神经网络模型的短期电力负荷预测模型[J]. 电子设计工程, 2022, 30(01): 121-126.
[45] 王雁平, 乐春峡. 电力系统负荷建模的数据预处理技术[J]. 电网技术, 2007(S2): 292-294.
[46] 张国江, 邱家驹, 李继红. 基于人工神经网络的电力负荷坏数据辨识与调整[J]. 中国电机工程学报, 2001(08): 105-108+114.
[47] 张文哲, 陈刚, 吴迎霞. 基于小波理论对负荷预测中不良数据的处理[J]. 重庆大学学报(自然科学版), 2004(06): 77-81.
[48] 姚程文, 杨苹, 刘泽健. 基于 CNN-GRU 混合神经网络的负荷预测方法[J]. 电网技术, 2020, 44(09): 3416-3424.
[49] 王康. 基于改进 GRU 神经网络的电力系统短期负荷预测研究[D]. 青岛大学, 2021
[50] 戚海涛, 李涵. 一种神经网络的全局池化方法及众核系统: CN112446458A[P]. 2021.
[51] 王辉, 张健, 杭伟. 基于卷积神经网络的羚羊图像识别模型研究[J]. 电子技术与软件工程, 2021(17): 132-133.
[52] 王文卿, 撖奥洋, 于立涛, 等. 自编码器与 PSOA-CNN 结合的短期负荷预测模型[J]. 山东大学学报(理学版), 2019, 54(07): 50-56.
[53] 缪昭明, 袁宪锋, 张晖, 等. 基于 SE-CNN 的服务机器人运动系统云端故障诊断方法[J]. 机器人, 2021, 43(03): 10.
[54] D Kuang, Bang X . Predicting kinetic triplets using a 1d convolutional neural network[J]. Thermochimica Acta, 2018, 669.
[55] 张勇, 陶一凡, 巩敦卫. 迁移学习引导的变源域长短时记忆网络建筑负荷预测[J]. 控制与决策, 2021, 36(10): 2328-2338.

中国知网 https://www.cnki.net

[56] 凌禹. 基于深度神经网络的流量入侵检测模型研究[D]. 杭州电子科技大学, 2020.
[57] 李泽捷. 基于运营商大数据的用户移动性与行为分析应用[D]. 北京邮电大学, 2019.
[58] 杨宇慧. 基于强化学习与 LSTM 的短期电力负荷预测研究[D]. 内蒙古科技大学, 2020.
[59] 刘永雪, 李海明. 卷积神经网络的优化在车牌号识别上的运用[J]. 上海电力大学学报, 2020, 36(04): 351-356.
[60] 秦金泽. 深度学习和雷达散射截面关联的 SRA 数据生成研究[D]. 电子科技大学, 2020.
[61] 汪木兰, 徐开芸, 饶华球, 等. 基于改进型 BP 神经网络多关节机器人逆向运动学求解[J]. 南京航空航天大学学报, 2006(S1): 83-87.
[62] Wen X, Xu Z. Wind turbine fault diagnosis based on reliefF-PCA and DNN[J]. Expert Systems with Applications, 2021, 178(11): 115016.
[63] 王红斌, 沈强, 线岩团. 融合迁移学习的中文命名实体识别[J]. 小型微型计算机系统, 2017, 38(02): 346-351.
[64] 袁晨晖. 深度卷积神经网络的迁移学习方法研究与应用[D]. 南京邮电大学, 2020.
[65] 许至杰. 迁移学习理论与算法研究[D]. 华东师范大学, 2012.
[66] 黄霄汉. 基于深度领域适应的图像分类研究[D]. 中国矿业大学, 2020.
[67] 刘婧. 融合多视觉对象的行为识别研究[D]. 北京理工大学, 2015.
[68] 张琦. 基于迁移学习的单样本人脸识别[D]. 哈尔滨工程大学, 2016.
[69] 郑雪辉, 王士同. 基于迁移学习的径向基函数神经网络学习[J]. 计算机工程与应用, 2016, 52(05): 6-10+21.
[70] 梁立锋, 刘秀娟, 张宏兵, 等. 超参数对 GRU-CNN 混合深度学习弹性阻抗反演影响研究[J]. 物探与化探, 2021, 45(1): 7.
[71] 刘建恒. 基于深度学习的电网理论线损计算研究[D]. 燕山大学, 2020

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

致　谢

时间总是悄悄溜走，不会给我们过多时间留恋，从 2019 年秋入学到现在，我的求学生涯也似乎要画上一个句号了。一路上发生了许多事，遇到了许多人，交了很多朋友，受到了很多人的帮助，想谢谢他们，也不知道从何谢起，想对他们说点啥，也不知道怎么开口，借着论文完稿的机会，向他们表示我的感谢。

首先，我要感谢我的导师，姜建国教授。考研之后，机缘巧合之下在学校官网上看到了您的信息，后面拜入您的门下，成为您的学生。老师是一个老学究，这是他的自称，也是他的写照，在实验室三年，他用他的一言一行向我们展现了他的风骨，严谨治学、平善做人，对待学术，老师格外考究，对待我们，老师也总是那么亲近。在我的毕业论文上，老师总是不厌其烦地一次一次帮我修改，开题、中期、完稿，一路上老师总是全力支持我，在这向老师表示衷心的感谢。

然后，我要感谢我的实验室师兄、师弟、师妹。感谢师兄们带领着我们多次参加科技竞赛，十分感谢他们无私地提供学习经验，在我无助时伸出援助之手，在就业的方向上也提供了宝贵的建议。同时，感谢我的同门和舍友，感谢他们三年来对我学习和生活上的帮助，在论文过程中也是相互督促、鼓励和鞭策。

最后，我要感谢我的父母，二十多年的求学之路，他们是我坚实的后盾，无论是物质上，还是精神上，都是一如既往的支持我，让我能安心求学，一路走到现在。在此即将完成学业之际，我将端正态度，以积极向上的姿态迎接新的人生阶段，不断努力，继续挑战自我。

最后，万分感激在开题、中期和毕业答辩小组中的每位老师，感激你们对我的毕业论文提出的每一条宝贵的建议。

中国知网　https://www.cnki.net

艰苦创业 严谨治学

严谨朴实 勤奋创新



学校网址：http://www.nepu.edu.cn

中国知网 https://www.cnki.net