引用本文:郭浔,刘彦辰,吴会军. 基于深度迁移学习的跨建筑物类型的能耗预测[J]. 建筑节能(中英文),2026,54(3):10-15.
GUO Xun, LIU Yanchen, WU Huijun. Energy Consumption Prediction Across Building Types Based on Deep Transfer Learning[J]. Building Energy Efficiency,2026,54(3):10-15. (in Chinese)
doi:10.3969/j.issn.2096-9422.2026.03.002

基于深度迁移学习的跨建筑物类型的能耗预测*

郭　浔[a,b]，　刘彦辰[a,b△]，　吴会军[a,b]
(广州大学 a. 土木与交通工程学院，b. 广东省建筑热工与低碳控制工程技术研究中心，广州　510006)

摘要： 在实际生活中，新建的独立建筑和未安装先进楼宇自动化系统(BAS)的现有建筑，往往缺乏与目标建筑(即正在分析或优化能耗模式的特定建筑)相匹配的历史能耗数据，这将导致难以准确预测能耗表现或制定高效的节能策略的问题。针对这一问题，本文开发了基于迁移学习的一维卷积神经网络(1D CNN)模型和长短期记忆网络(LSTM)模型，用于提前一小时预测建筑能耗。在数据不足的情况下，采用开源数据集 Building Data Genome Project 验证了迁移学习在解决数据匮乏方面的可行性。结果表明，基于 CNN 模型的迁移学习平均提升预测精度 17.4%，基于 LSTM 模型的迁移学习平均提升预测精度 11.2%。此外，还分析了目标建筑的周期性、训练集目标域的数据量等因素对模型性能的影响。研究发现，增加目标域的可用数据量有助于提高跨建筑迁移学习的预测精度，而具有强周期性的目标建筑能耗更适合迁移学习。

关键词： 建筑能耗预测；　迁移学习；　长短期记忆网络；　卷积神经网络；　周期性
中图分类号： TU17　　**文献标志码：** A　　**文章编号：** 2096-9422(2026)03-0010-06

Energy Consumption Prediction Across Building Types Based on Deep Transfer Learning

GUO Xun[a,b], *LIU Yanchen*[a,b△], *WU Huijun*[a,b]
(a. School of Civil and Transportation Engineering, b. Guangdong Provincial Engineering Technology Research Center for Building Thermal Engineering and Low-Carbon Control, Guangzhou University, Guangdong 510006, China)

Abstract: *In practice, newly constructed standalone buildings and existing buildings without advanced Building Automation Systems (BAS) often lack historical energy consumption data that aligns with the target building (i.e., the specific building for which energy consumption patterns are being analyzed or optimized), making it challenging to accurately predict energy performance or formulate effective energy-saving strategies. To address this issue, this study developed a one-dimensional Convolutional Neural Network (1D CNN) model and a Long Short-Term Memory (LSTM) model based on transfer learning for one-hour-ahead building energy consumption prediction. Given limited data, the open-source dataset "Building Data Genome Project" was used to validate the feasibility of transfer learning in addressing data scarcity. Results showed that transfer learning based on the CNN model improved prediction accuracy by an average of 17.4%, while the LSTM model achieved an average improvement of 11.2%. Additionally, the study analyzed the impact of factors such as the periodicity of the target building's energy consumption and the amount of training data available in the target domain on model performance. It is found that increasing the available data volume for the target domain enhances cross-building transfer learning*

收稿日期:2024-11-13；　修回日期:2025-01-12
*基金项目:国家自然科学基金资助项目(52108074);国家自然科学基金资助项目(52361165624)

中国知网　https://www.cnki.net

prediction accuracy, and buildings with strong periodic energy consumption are more suitable for transfer learning.

Keywords: building energy consumption prediction; transfer learning; Long Short-Term Memory (LSTM); Convolutional Neural Network(CNN); periodicity

0 引言

在全球范围内,建筑能耗约占能源消耗的40%[1]。以我国建筑能耗为例,中国已成为仅次于美国的全球第二大能源消费国[2],占全国能源消费总量的30%。因此,建筑领域蕴藏着巨大的节能潜力。随着城市信息化和智能化建设的飞速发展,建立先进的建筑能源管理系统对提高建筑能源利用效率至关重要。在这一背景下,高效而准确的建筑能耗预测对于建筑能源管理系统的运行和优化具有关键性作用。

数据驱动方法是建筑能耗的主要预测方法之一[3-4],但所有数据驱动模型的构建都需要大量的历史数据。针对新建的独立建筑及未安装先进楼宇自动化系统(BAS)的现有建筑,在投入使用之前因为缺乏运营数据,数据驱动的方法可能无法有效发挥作用。

迁移学习可以应对在使用数据驱动模型进行能耗预测时可能遇到的历史数据不足的问题。迁移学习是一种机器学习技术,可以借助从其他信息丰富的建筑中提取的领域知识,以增强传统机器学习对缺乏建筑信息的问题的处理能力。

由于新建的独立建筑和未安装先进楼宇自动化系统(BAS)的现有建筑通常缺乏与目标建筑(即正在分析或优化能耗模式的特定建筑)相匹配的历史能耗数据,因此难以直接训练出高精度的预测模型。通过跨建筑类型的预测,模型可以利用现有建筑的能耗数据进行迁移学习,从而提高预测准确性。本研究验证了基于CNN迁移学习和基于LSTM迁移学习方法在跨建筑预测的可行性,并在一个开源基准数据集——建筑数据基因组项目Building Data Genome Project[5]上测试了迁移学习的实施效果。从该数据集中选取了200栋建筑的能耗数据分别用作源数据。研究进一步探讨了不同源建筑类型对具有不同能耗周期性的目标建筑迁移学习性能的影响,为选择适当的源建筑和源数据集进行建筑能耗预测提供了有益的指导。

1 方法

1.1 研究框架

为了探究跨建筑类型迁移学习的效果,共选择200座建筑物构成源建筑物池(办公室、小学、大学、宿舍和实验室各40座)。另外选取了3座不同能源消耗方式的商场作为目标建筑探究跨建筑类型迁移学习的效果。使用傅里叶定律判断3座商场的周期性以探究目标建筑周期性对迁移学习的影响。

如图1所示,研究方法由以下部分组成:①使用来自信息丰富的建筑物的数据集(即源数据集)来预训练基础模型;②使用来自信息贫乏建筑物的训练数据集(即目标训练数据集)对预训练模型进行微调;③使用来自信息贫乏建筑物的测试数据集(即目标测试数据集)来验证目标模型。

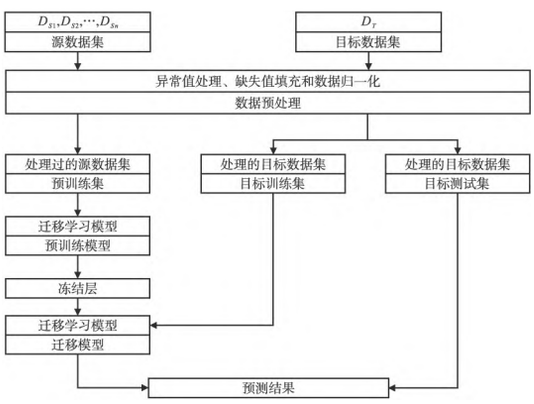


图1 研究概要

1.2 数据预处理

在本研究中,采用四分位法识别异常值,采用线性插值法补充异常值与缺失值,然后对能耗数据进行归一化。

最小-最大方法是机器学习和深度学习领域最有用的归一化方法之一[6]。它可以提高数据的一致性和可比性,其表达式见公式(1):

$$min-max=\frac{x-X_{min}}{X_{max}-X_{min}} \tag{1}$$

式中:x为目标特征的值;

X_{max}和X_{min}分别为该特征值的最大值和最小值。该方程限制了特征的值,使其在提交给模型之前位于0和1之间。

1.3 迁移学习

根据不同情况,迁移学习有常用的四种技术,包括模型迁移、实例迁移、特征迁移和关系迁移[7]。本研究采用模型迁移,因其更适合对模型进行微调。模型迁移的核心在于将预训练模型中的权重作为初始权重,从而帮助模型快速适应新任务。

图2展示了本研究中模型迁移的总体思路(以CNN为例)。首先,使用源建筑的能耗数据训练模型A(预训练模型)。然后,冻结模型A的卷积层和池化

中国知网 https://www.cnki.net

层的权重,仅微调全连接层的权重,使其适应目标训练集的数据分布差异。这样,模型 A 经过目标数据的微调后,转变为模型 B(迁移模型)。在此过程中,网络设置(如神经元数量和学习率)保持不变,相当于对模型 A 进行一次额外的训练。

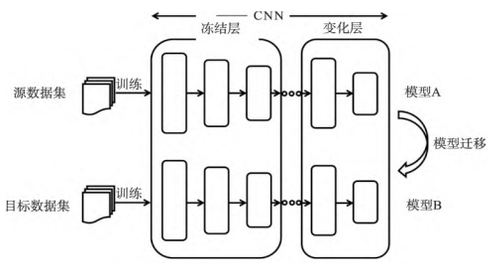


图 2　基于模型的迁移

1.4　傅里叶分析

傅里叶分析可用于将复杂的能耗时间序列分解为多个不同频率的正弦波,从而识别出建筑能耗中的周期性模式[8]。通过傅里叶变换,可以确定能耗在不同时间段内的主要周期,例如日周期、周周期等,其表达式见公式(2):

$$X(f) = \sum_{n=0}^{N-1} x[n] \cdot e^{-i2\pi fT \cdot n} \tag{2}$$

式中:$X(f)$ 为信号在频率 f 上的强度或幅值;

$x[n]$ 为时间序列中第 n 个采样点的值;

$e^{-i2\pi fT \cdot n}$ 为复指数项,表示信号在不同频率 f 下的振荡,其中 i 为虚数单位,$2\pi fTn$ 为相位变化。

1.5　评价指标

使用最终的模型对目标建筑未来一小时的能耗进行预测,并采用平均绝对百分比误差(Mean Absolute Percentage Error,MAPE)作为评价指标,表达式见公式(3)。由于建筑物之间的能耗水平差异较大,因此使用平均绝对误差(MAE)和均方根误差(RMSE)并不合适[9]。

$$MAPE = \frac{1}{N} \sum_{i=1}^{N} \frac{| y_i - \bar{y}_i |}{y_i} \tag{3}$$

式中:y_i 和 $\bar{y}_i$ 分别为预测值和实际值;

N 为样本总数。

与传统数据挖掘方法相比,性能改进率(PIR)用来表示迁移学习模型的性能改进程度[10],表达式见公式(4):

$$PIR = \frac{MAPE - MAPE_{TL}}{MAPE} \tag{4}$$

式中:$MAPE$ 为传统数据挖掘方法(CNN 或 LSTM)预测的 $MAPE$ 值;

$MAPE_{TL}$ 为基于 CNN 或 LSTM 迁移学习模型预测的 $MAPE$。

当 PIR > 0 时,表明使用迁移学习模型的预测结果有所改善。PIR 值越高,说明改进效果越明显。当 PIR < 0 时,表明迁移学习模型的预测结果比基线模型差。

2　案例分析

2.1　数据选取与分析

本研究的输入数据为一维时间序列的能耗数据,涵盖源建筑和目标建筑的时间范围均为 2 月 1 日 – 2 月 20 日,共计 20 天。源数据来自美国劳伦斯伯克利国家实验室建立的开源数据集 Building Data Genome Project[5],该数据集包含 507 座建筑的能耗信息,每栋建筑提供了三类数据:历史电表数据、建筑元数据(建筑类型、名称、位置和面积)及天气数据。本文从中选取 200 座建筑的能耗数据作为源数据集。此外,本文还选取了 3 座商场(下文分别用 A、B、C 指代)作为目标建筑,其能耗情况如图 3 所示,可以看出能耗主要集中在下午和晚上。

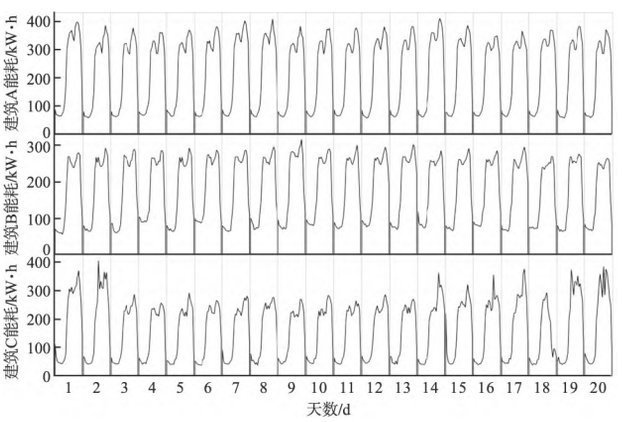


图 3　三座商场建筑能耗

为探究目标建筑的建筑能耗周期性对模型性能的影响,采用傅里叶分析方法计算的三座商场在周期对应频率为 0.041 7 时的日周期性幅度如图 4 所示,在该频率下,目标建筑 A 的幅度大于目标建筑 B,目标建筑 B 的幅度又大于目标建筑 C。

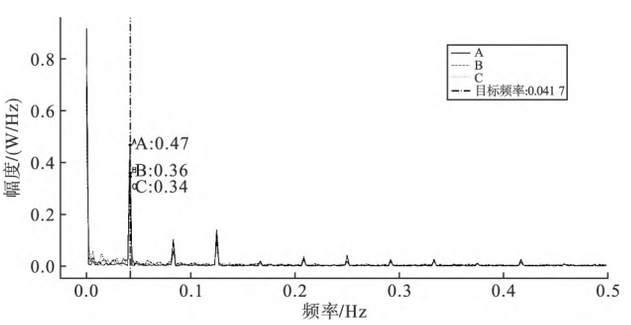


图 4　三座目标建筑能耗的傅里叶定律频谱图

2.2　方法设置

本研究的预测模型基于 Python 平台构建。根据 sklearn 机器学习库[11]和 Keras 神经网络库[12-13]作为模型模块并结合 NumPy、pandas 和 matplotlib 进行数

中国知网　https://www.cnki.net

据处理与可视化。模型参数设置如下:迭代轮次 100、单次训练样本为 512、学习率为 0.001。在学习率为 0.001~0.000 01 和迭代轮次为 1~100 的范围内进行了调优。模型的输入为一维时间序列能耗。所使用的 CNN 模型结构如表 1 所示,包含 4 个卷积层、4 个最大池化层和 3 个全连接层;LSTM 模型如表 2 所示,由 2 个 LSTM 层和 2 个全连接层组成。激活函数采用 ReLU,优化器为 Adam。

为了评估迁移学习对 CNN 和 LSTM 模型性能的影响,预训练源数据集、目标训练数据集和目标测试数据集的大小分别设定为 20 d、2 d 和 20 d。然后,将该方法与传统的数据挖掘方法进行对比。传统数据挖掘方法模拟在数据缺失的情况下,直接使用目标建筑的数据作为输入,通过深度神经网络预测能耗,将此预测结果作为基准,用于衡量迁移学习预测结果的正迁移或负迁移效果。

表 1　CNN 网络结构

层名	输出形状
输入层	(None,96,1)
卷积层,32 个滤波器,大小为(5, 1)	(None, 96, 32)
ReLU 激活,最大池化(3, 1)	(None, 32, 32)
卷积层,64 个滤波器,大小为(3, 1)	(None, 32, 64)
ReLU 激活,最大池化(3, 1)	(None, 11, 64)
卷积层,128 个滤波器,大小为(3, 1)	(None, 11, 128)
ReLU 激活,最大池化(3, 1)	(None, 3, 128)
卷积层,256 个滤波器,大小为(3, 1)	(None, 3, 256)
ReLU 激活,最大池化(3, 1)	(None, 1, 256)
展平层	(None,256)
全连接层,ReLU 激活	(None, 64)
全连接层,ReLU 激活	(None, 32)
线性层	(None, 1)

表 2　LSTM 网络结构

层名	输出形状
输入层	(None,96,1)
LSTM 层,64 个单元	(None, 96, 64)
LSTM 层,128 个单元	(None, 96, 128)
展平层	(None, 12288)
全连接层,64 个神经元,ReLU 激活	(None, 64)
全连接层,32 个神经元,ReLU 激活	(None, 32)
输出层,1 个神经元,线性激活	(None, 1)

3　结果和讨论

3.1　迁移学习效果

对于每个目标建筑,我们都计算了 200 个案例的平均模型性能,表 3 列出了使用 MAPE 的 200 栋源建筑(办公室、小学教室、大学教室、大学宿舍和大学实验室各 40 栋)与 3 栋目标建筑使用不同模型进行迁移的评估结果。由表 3 可知,大学宿舍和大学实验室作为源建筑时,预测精确度相比其他源建筑迁移学习之后效果最不明显,主要原因可能是实验室能耗过大,而宿舍能耗主要集中在中午和夜晚,这与商场能耗特征明显不符。为了更深入研究迁移学习的效果,以仅使用数据挖掘方法(即目标建筑两天能耗数据进行预测)所得结果作为基线值(见表 4),并绘制箱线图。在图 5 和图 6 中,箱型中的白线代表均值,红线表示基线值,低于红线的结果为正向迁移。可以看出,无论使用什么模型,迁移学习都能发挥作用。仅有少数源 – 目标对出现负向迁移:在使用 CNN 模型时,仅目标建筑 C – 大学实验室出现负向迁移;使用 LSTM 模型时,仅目标建筑 C – 大学宿舍出现负向迁移。由于目标建筑 C 的周期性较差,因此这加大了迁移学习预测的难度。在各模型 15 对源与目标建筑组合中,均仅出现一对负向迁移。这些结果表明,在可用训练数据有限的情况下,迁移学习在大多数源 – 目标组合中均能有效提升性能。在这种情况下,权重初始化带来的效果优于数据分布差异的影响。

3.2　不同模型迁移学习预测性能和改善情况

为了深入分析不同模型在迁移学习中的预测性能特点,以一对源 – 目标建筑为例,使用 CNN 模型进行迁移学习预测的 MAPE 为 0.059,使用 LSTM 模型进行迁移学习预测的 MAPE 为 0.0613。图 7 展示了 CNN 和 LSTM 模型的预测结果与真实值的对比。从图中可以看出,CNN 模型的预测结果与真实值更加契合,尤其在能耗预测的波峰和波谷部分,CNN 模型表现出更高的精确度。

图 8 和图 9 展示了迁移学习方法在使用 CNN 模型和 LSTM 模型时相较于传统数据挖掘方法的性能提升效果。对于周期性较强的目标建筑 A、B,迁移学习之后提升效果更加显著,整体 PIR 值更大。

表 3　不同源目标建筑 LSTM 模型和 CNN 模型 MAPE 结果对比

源建筑	目标建筑					
	建筑 A MAPE		建筑 B MAPE		建筑 C MAPE	
	LSTM	CNN	LSTM	CNN	LSTM	CNN
办公室	0.069	0.062	0.120 1	0.099 3	0.208	0.152
小学教室	0.064	0.062	0.111 8	0.096 2	0.196	0.148
大学教室	0.068	0.063	0.117 8	0.104 7	0.205	0.156
大学宿舍	0.069	0.065	0.129 5	0.118 0	0.207	0.169
大学实验室	0.064	0.064	0.122 2	0.118 3	0.224	0.202

中国知网　https://www.cnki.net

表 4　目标训练集(2 天)训练结果

模型	目标建筑	MAPE
CNN	建筑 A	0.081 3
	建筑 B	0.131 4
	建筑 C	0.176 9
LSTM	建筑 A	0.082 5
	建筑 B	0.132 3
	建筑 C	0.216 0

基于 CNN 的迁移模型,大部分预测能耗性能提高了 10%~20%,在 B 作为目标建筑,小学教室为源建筑时,PIR 值达到了最大,性能提升了 26%。仅有两对源 – 目标建筑提升效果低于 10%。除去负迁移结果,平均 PIR 值达到 17.4%。基于 LSTM 的迁移模型预测效果提升略低于 CNN,除去负迁移结果,平均 PIR 值达到 11.2%。

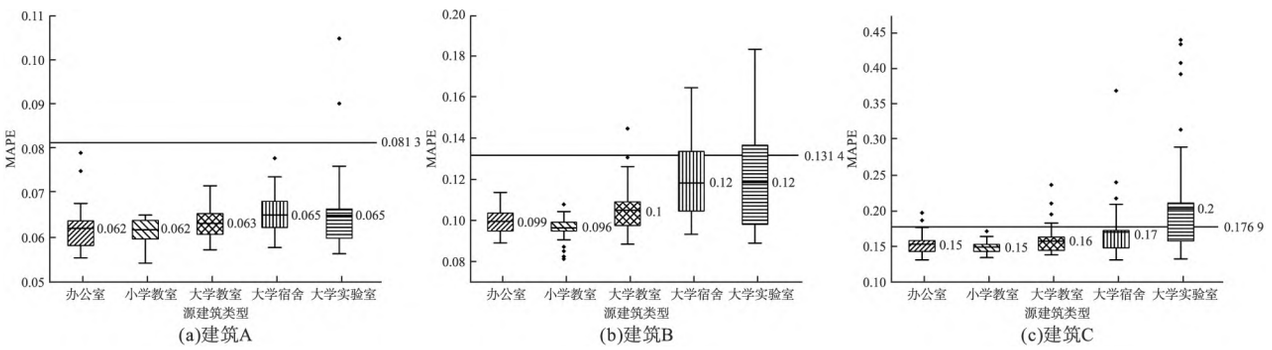


图 5　基于 CNN 在不同目标建筑跨建筑迁移性能

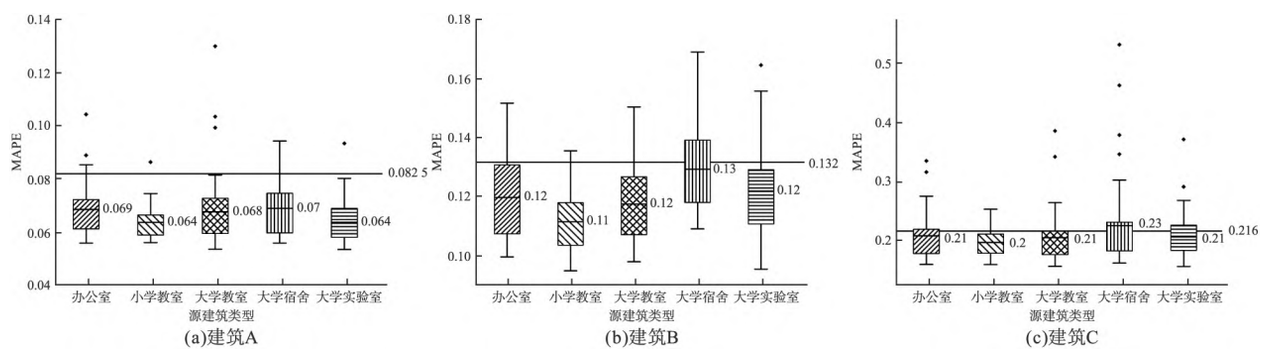


图 6　基于 LSTM 在不同目标建筑跨建筑迁移性能

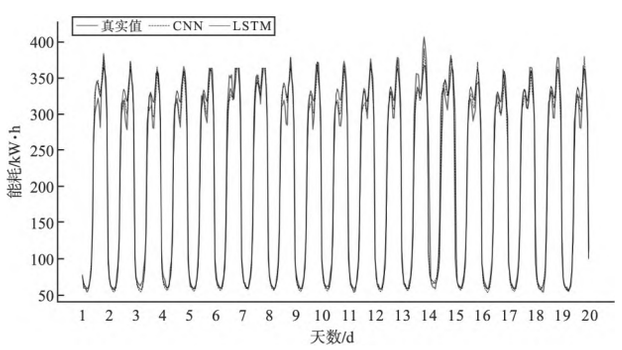


图 7　基于 CNN 和 LSTM 预测结果与真实值对比

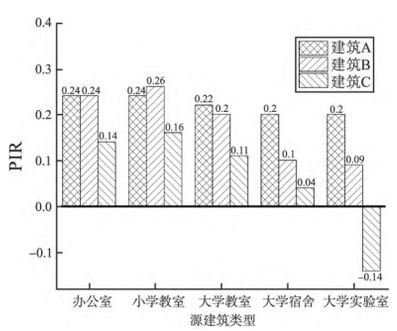


图 8　不同源 – 目标建筑 CNN 迁移学习相较数据挖掘方法的改善效果

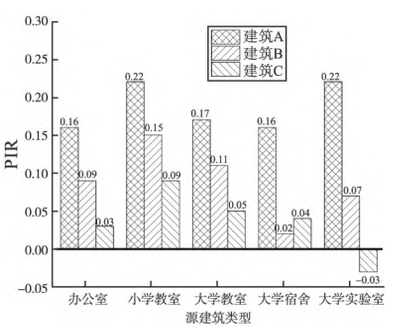


图 9　不同源 – 目标建筑 LSTM 迁移学习相较数据挖掘方法的改善效果

3.3　目标建筑可用数据集的影响

图 10 和图 11 展示了在不同源 – 目标建筑组合下,随着目标建筑训练数据量的增加,建筑能耗预测模型在训练过程中的平均绝对百分比误差(MAPE)的变化情况。在此实验中,源建筑的训练数据量固定为 20 d,而目标建筑的训练数据量逐日增加。

结果显示,随着目标建筑训练数据的增加,两种迁移学习模型的平均预测精度整体呈上升趋势,并最终趋于稳定。在基于 CNN 的迁移学习模型中,周期

中国知网　https://www.cnki.net

性较强的目标建筑 A 和目标建筑 B 的预测精度提升更为显著;随着目标建筑训练数据的增加,宿舍和实验室的预测精度与初中和办公室的预测精度之间的差异逐渐缩小。这表明,尽管源建筑与目标建筑存在较大的用途差异,但通过适当的微调时间,模型能够调整权重,减少对源建筑特征的过度依赖,逐步关注目标建筑的特征,最终减小了预测精确度的差异。而周期性较差的目标建筑 C,当目标数据天数增加至 5 d 后,预测结果反而出现上升的趋势。对于基于 LSTM 的迁移学习模型,尽管在目标训练数据集增加到一定天数时,部分源 – 目标建筑组合的预测精度有所下降,但整体平均精度仍呈上升趋势。

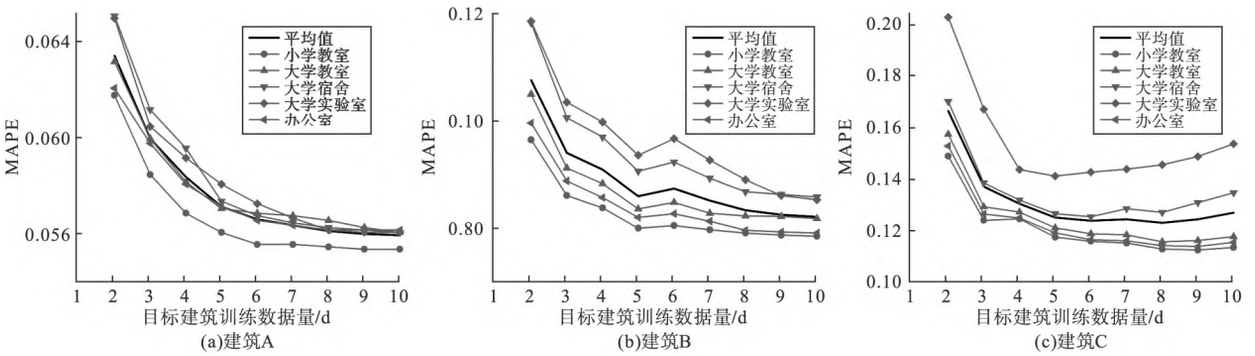


图 10　不同源 – 目标建筑基于 CNN 迁移学习随目标数据集变化的预测

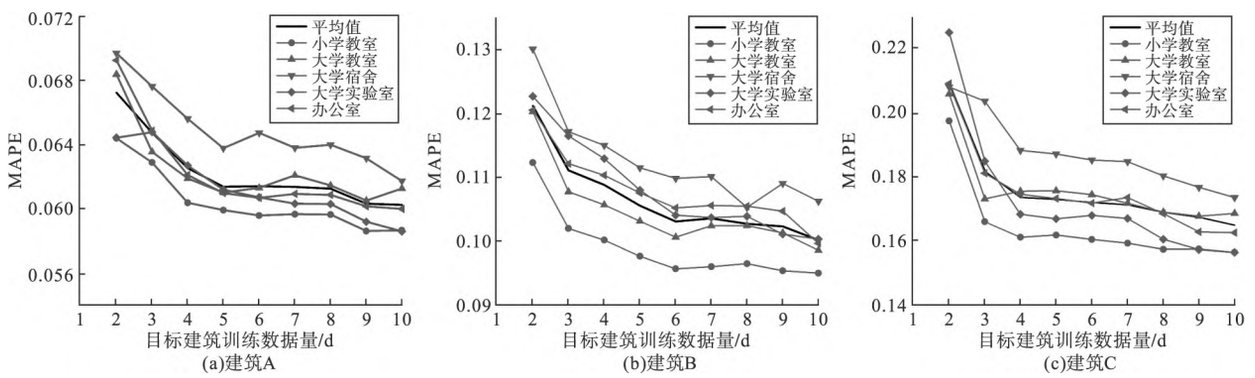


图 11　不同源 – 目标建筑基于 LSTM 迁移学习随目标数据集变化的预测结果

4　结论

针对现有的楼宇能源数据(BED)并不总是足以开发数据驱动的楼宇能源预测(BEP)模型或已有历史能耗数据的建筑类型未必与目标楼栋相同的问题,本文采用跨建筑迁移学习方法,借助来自其他建筑的数据,在可用数据有限的情况下提高目标建筑的能耗预测精度。本文使用 CNN 模型和 LSTM 模型,并利用大型公共基准数据集——建筑数据基因组项目中的数据作为源建筑,以 3 座商场作为目标建筑进行测试。研究系统分析并比较了不同目标建筑数据样本、不同源 – 目标建筑组合的迁移学习效果,以及目标建筑数据周期性对迁移学习的影响。总结如下:

(1)当可用的训练数据非常有限时,相比于传统数据挖掘方法,迁移学习可以提高预测的准确率。其中,基于 CNN 模型的迁移学习平均 PIR 为 17.4%,最大提升为 26%。基于 LSTM 模型的迁移学习平均 PIR 为 11.2%,最大提升为 22%。

(2)对于不同类型的源建筑和目标建筑使用迁移学习,周期性强的目标建筑 A 和目标建筑 B 迁移学习的效果更好,运用迁移学习后可以更大程度地降低错误学习的情况。

(3)随着目标建筑训练数据的增加,CNN 和 LSTM 模型的预测性能总体呈上升趋势,周期性强的建筑预测精度提升更加明显。

根据这项研究,迁移学习能够有效地解决已有建筑能耗数据与目标建筑数据不匹配的问题,从而实现更精准的能耗预测。然而,除了上述优点外,所提出的方法也存在一些局限性:①研究仅针对 5 种源建筑类型(办公室、小学教室、大学教室、大学宿舍和大学实验室)对商场能耗进行了预测,其他源建筑类型如住宅建筑和蓄冷式办公建筑未被纳入讨论,该类型建筑具有更强的个体化特征和能耗的随机性,可能对迁移学习模型提出更高的挑战;②所提出的迁移学习预测模型主要集中于短期能耗预测,对于长期能耗预测的分析尚未展开。因此,未来的研究将扩展源建筑类型的范围,并探索长期能耗预测的迁移学习模型,以进一步提高预测的准确性和适应性。

(下转第 20 页)

中国知网　https://www.cnki.net

息论坛,2011,26(3):32 -38.
[2]刘琪琛,雷景生,郝珈玮,等. 基于 Spark 平台和并行随机森林回归算法的短期电力负荷预测[J]. 电力建设,2017,38(10):84 -92.
[3]DUDEK G. An Artificial Immune System for Classification with Local Feature Selection[J]. IEEE transactions on evolutionary computation: A publication of the IEEE Neural Networks Council, 2012, 16(6): 847 -860.
[4]LAHOUAR A, HADJ S B H J. Day-ahead Load Forecast Using Random Forest and Expert Input Selection[J]. Energy Conversion and Management, 2015, 103(10): 1040 -1051.
[5]GONZALEZ A, VAZQUEZ D, LOPEZ A M, et al. On-Board Object Detection: Multicue, Multimodal, and Multiview Random Forest of Local Experts[J]. IEEE transactions on cybernetics, 2016, 47(11): 3980 -3990.
[6]马得银,孙波,刘澈. 基于天气信息的短期冷热电负荷联合预测方法[J]. 电网技术,2021,45(3):1015 -1022.
[7]孙庆凯,王小君,张义志,等. 基于 LSTM 和多任务学习的综合能源系统多元负荷预测[J]. 电力系统自动化,2021,45(5):63 -70.
[8]翟晶晶,吴晓蓓,王力立. 基于径向基函数神经网络的综合能源系统多元负荷短期预测[J]. 电力需求侧管理,2019,21(4):23 -27.
[9]秦承敏,于慧俐,王敬博. 基于阻容模型的寒冷地区建筑热负荷预测方法研究——以某办公建筑为例[J]. 建筑节能(中英文),2022,50(5):68 -72.
[10]黄恒笛. 基于机器学习的洗钱风险辨识方法研究[D]. 上海:东华大学,2023.
[11]张玲,王美萍,田琦,等. 基于卷积神经网络的换热站热负荷预测研究[J]. 建筑节能(中英文),2023,51(5):67 -72.
[12]赵秉文,李婉,金宇. 基于 PSO - LSSVM 的供热负荷预测研究[J]. 建筑节能(中英文),2021,49(6):46 -49.
[13]方勤健. 综合能源系统多元负荷短期预测与应用[D]. 大连:大连理工大学,2021.
[14]种道坤,周海珠,李晓萍,等. 北方城市集中供暖系统能耗与过量供热案例分析[J]. 建筑热能通风空调,2022,41(4):62 -66.
[15]ZHANG Y C, XIA J J, FANG H, et al. Field Tests on the Operational Energy Consumption of Chinese District Heating Systems and Evaluation of Typical Associated Problems[J]. Energy and Buildings, 2020, 224(10): 110269.

作者简介: 梁书奎(1996),男,辽宁沈阳人,供热、供燃气、通风及空调工程专业,硕士研究生,中级工程师,研究方向为建筑环境与能源应用工程(sk9337@qq.com)。

△**通信作者:** 张广秋(1994),女,黑龙江人,供热、供燃气、通风及空调工程专业,硕士研究生,中级工程师,研究方向为暖通空调(1971206558@qq.com)。

(上接第 15 页)

参考文献:

[1]中国建筑节能协会,重庆大学城乡建设与发展研究院. 中国建筑能耗与碳排放研究报告(2022)[R]. 建筑,2023,(2):57 -69.
[2]ZHANG Y, HE C Q, TANG B J, et al. China's Energy Consumption in the Building Sector: A Life Cycle Approach[J]. Energy and Buildings, 2015, 94(5): 240 -251.
[3]陈家乐,张芸芸,崔红伟. 基于 LSTM 神经网络的办公建筑逐日能耗预测研究[J]. 建筑节能(中英文),2024,52(9):74 -78.
[4]王曦,甘灵丽,王亮,等. 基于 LM - BP 神经网络的办公建筑逐时空调能耗预测[J]. 建筑节能(中英文),2024,52(1):58 -64.
[5]MILLER C, MEGGERS F. The Building Data Genome Project: An Open, Public Data Set from Non-residential Building Electrical Meters[J]. Energy Procedia, 2017, 122(9): 439 -444.
[6]GOODFELLOW I, BENGIO Y, COURVILLE A. Deep learning[M]. Cambridge, MA, USA: MIT Press, 2017.
[7]PAN J L, YANG Q. A Survey on Transfer Learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345 -1359.
[8]OZAKTAS H M, SUMBUL U. Interpolating Between Periodicity and Discreteness Through the Fractional Fourier Transform[J]. IEEE Transactions on Signal Processing: A Publication of the IEEE Signal Processing Society, 2006, 54(11): 4233 -4243.
[9]GAO Y, RUAN Y, Fang C, et al. Deep Learning and Transfer Learning Models of Energy Consumption Forecasting for a Building with Poor Information Data[J]. Energy and Buildings, 2020, 223(9): 110156.
[10]LI G N, WANG Z X, GAO J J, et al. Performance Assessment of Cross Office Building Energy Prediction in the Same Region Using the Domain Adversarial Transfer Learning Strategy[J]. Applied Thermal Engineering, 2024, 241(3): 122357.
[11]PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12(11): 2825 -2830.
[12]HORNIK K. The Comprehensive R Archive Network[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2012, 4(4): 394 -398.
[13]The R Core Team. R: A Language and Environment for Statistical Computing[M]. Vienna: R Foundation for Statistical Computing, 2008.

作者简介: 郭浔(2000),男,广东东莞人,人工环境工程专业,硕士研究生,研究方向为深度学习(916851826@qq.com)。

△**通信作者:** 刘彦辰(1988),女,河北衡水人,毕业于清华大学,建筑技术专业,博士,副教授,研究方向为绿色建筑与建筑节能(liuych@gzhu.edu.cn)。

中国知网 https://www.cnki.net