工程硕士专业学位论文

基于特征迁移学习与耦合关系挖掘的综合能源系统小样本日前负荷预测

Small-sample Day-ahead Load Forecasting of Integrated Energy System Based on Feature Transfer Learning and Coupling Relationship Mining

作　者：李家钊
导　师：孙晓燕 教授

中国矿业大学

二〇二一年六月

中国知网 https://www.cnki.net

中图分类号 TM714　　学校代码 10290

UDC 004.8　　密　　级 公开

中国矿业大学

工程硕士专业学位论文

基于特征迁移学习与耦合关系挖掘的综合能源系统小样本日前负荷预测

Small-sample Day-ahead Load Forecasting of Integrated Energy System Based on Feature Transfer Learning and Coupling Relationship Mining

作　　者 李家钊　　导　　师 孙晓燕

申请学位 工程硕士专业学位　　培养单位 信息与控制工程学院

学科专业 控制工程　　研究方向 综合能源系统负荷预测

答辩委员会主席 贾存良　　评 阅 人 盲审

二〇二一年六月

中国知网 https://www.cnki.net

致谢

三年的研究生时光匆匆而过，环顾四处，目之所及，皆为回忆，从文昌逸夫楼、教四楼到南湖博学楼、信控楼，仍记得落笔时手心里那牢牢攥住的汗珠，远眺时窗外那蔓延舒展的枝叶，归途时沿路那形形色色的车流，求知时桥上那熙熙攘攘的攒动，格物时窗台上那淡然静谧的一隅，纵然难舍季春不显桥的潺潺、鹿园的嬉闹，暑月李子的香甜、雨水的滂沱，玄月雾气的飞腾、叶落的萧瑟，暮冬乱琼碎玉的皑皑、酉时日暮的晚风习习.....此刻却也无言，倒不是矫揉造作，难书胸臆，而是能够真切感受到，对一路走来陪伴、照顾过我的人，心底里那升腾而起的感激。

首先我要感谢我的恩师孙晓燕教授，在三年的研究生生涯中，孙老师待人和蔼，体恤学生，平易近人的为人让我如沐春风，同时孙老师渊博的学术见地给予了我坚定的科研信心，严谨的治学态度和执行力要求鼓舞着我不畏艰难、勇往直前。得幸遇孙老师，从论文的选题到开题报告，到小论文逐字逐句的斟酌与修订，再到初稿的雏形以及多次修改后的定稿，都离不开孙老师的细心指导与帮助，感谢老师帮助语言表达能力不足的我理清我那些许混乱的研究思路，感谢老师在我遇到拒稿挫折时教会我不抛弃不放弃，感谢老师在我对职业规划产生迷茫时的鼓励。我将终生谨记孙老师的谆谆教诲，踏踏实实地走好每一步，迎接每一次人生最好的安排。在此，向最尊敬的导师孙晓燕教授致以最崇高的敬意与真挚的感谢。

感谢课题组的巩敦卫教授、张勇教授、郭一楠教授、姚香娟教授等诸位老师，对我的研究工作内容的指点与建议，并在每周的组会上通过广阔的学术视野为我指明前进的道路。

感谢陈杨师兄、满广义师兄、邵辉师兄、赵琳师姐、刘恋师姐、聂鑫师兄、耿聪师兄、李琪师姐给予的关怀与帮助，尤其感谢暴琳师姐、胡荷娟师姐在我求索途中耐心的答疑解惑；感谢上届毕业的胡尧师兄、李玉柱师兄、魏凌傲师兄的帮助，尤其感谢汪敬人师兄在生活、学习上的指导；感谢同窗好友纪南巡、王金磊、李祯其、马路遥、孙俊茹、陆子帅的相互督促与陪伴，祝他们以梦为马，仗剑天涯；感谢苏龙飞、乔娅利、陈巡、朱子意、李梓民、李浩、吴位东、汪鑫豪等师弟师妹的支持；感谢人生知己孙福远、朱江平学士、李中洋学士、李波硕士以及柏影硕士、陈鹏硕士、宋炜硕士三位知心舍友长久以来的包容与鼓励。

感谢我的老婆，陈冬淼女士，感谢她在我最无助的时候出现，为我遮风避雨；感谢她分享我所有的梦想与渴望，甘愿成为我最柔软的软肋；感谢她在生活上对我无微不至的照顾，陪我共同组建一个小家；感谢她对我天马行空想法的包容，在我求职、求学摇摆不定时给予我的信心与支持；更需感谢于二零二一年二月她与我定下誓约，决定相伴一生。水可移，山可撼，我对她的爱只增不减。

中国知网 https://www.cnki.net

感谢我的父母，一直在我的背后作为我最坚强的后盾，默默给予我支持，从来不求任何回报；感谢父母在我意志薄弱的时候，对我的鞭策与鼓励；感谢父母在我身体不适时，对我的悉心呵护与照顾；感谢父母奋其一生，只为给我更好的生活；感谢父母的白发，让我乱了分寸，决定尽快长大。感恩父母，我定努力工作，不负父母所望，做事有品行，做人有担当。

感谢仍奋斗在抗击疫情一线的医务工作者及工作人员，感谢你们的无私与守护，正是有你们这一群可爱的“逆行者”，才得以护国人安康，向你们表示衷心的感谢。

感谢中国矿业大学给予我宝贵的求学机会和良好的学习环境。

感谢于百忙之中参加本文审阅与答辩的各位专家和教授！

在此，谨向他们致以由衷的感谢和崇高的敬意！

承先辈之大志，亦不愿负了韶华。只盼自己永远谨记此份感恩，别了浮躁，把握年华。

中国知网 https://www.cnki.net

摘　要

基于历史数据和深度学习的负荷预测已广泛应用于以电能为中心的综合能源系统中以提高预测精度，然而当区域中出现新用户时，其历史负荷数据往往极少，深度学习难以适用；与此同时，对煤炭、石油、天然气等多种辅助能源的合理分配和利用是综合能源系统运行优化的关键，而多元负荷时序数据的特征识别度高低不一，预测难度也有所差异，新用户短周期内的综合预测精度难以提高。针对此，本文研究小样本数据驱动的综合能源系统日前负荷预测策略，研究内容如下：

（1）基于特征迁移学习的综合能源系统小样本日前电力负荷预测：首先，依据源域用户历史负荷数据，融合聚类算法和门控循环单元（Gated Recurrent Unit , GRU）网络构建源域数据的特征提取和分类模型；然后，利用该模型提取当前待预测目标域小样本的特征及其类别信息，进而给出基于特征相似度和时间遗忘因子的特征融合策略；最后，依据融合特征，给出基于迁移学习和特征输入的负荷预测。将所提算法应用于卡迪夫某区域的高中和住宅用电预测中，实验结果表明了该算法在综合能源系统小样本电力负荷预测中的有效性。

（2）基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测：首先，针对小样本多元历史负荷数据的特征提取难题，以本征模态函数中心频率近似修正的包络熵为适应度优化函数，构建基于粒子群进化优化算法（Particle Swarm Pptimization, PSO）的变分模态分解（Variational Mode Decomposition, VMD）机制；然后，根据分解所得的具有较高特征辨识度的本征模态函数，提出一种基于模态分量间瞬时频率相似度与迟滞因子的多元模态间耦合关系挖掘策略；最后，依据模态间的耦合关系构建多元共有模态分量及特有分量预测模型，完成多元数据的多模负荷预测。将所提算法应用在奥斯丁某区域的综合用能预测中，实验结果表明了算法可有效提高综合能源系统小样本日前多元负荷预测的精度。

本文研究着眼于解决综合能源系统小样本负荷预测中存在的多方面不足，首先，针对系统电力负荷预测问题，给出基于特征迁移学习及特征融合的预测模型框架，然后，面对系统多元负荷预测，考虑对分解出的模态分量进行共性探寻，提出了基于多元模态间耦合关系挖掘的多模预测策略，实验效果展现了本文算法的可行性与有效性。

该论文有图 20 幅，表 13 个，参考文献 105 篇。

关键词：综合能源系统；日前负荷预测；特征提取；迁移学习；变分模态分解

中国知网　https://www.cnki.net

Abstract

Deep learning-based load forecasting with large size of historical data has been successfully used in integrated energy systems to effectively improve the prediction accuracy. However, when new users join in the system, their historical load data are often very rare, and deep learning is no longer applicable. At the same time, the reasonable distribution and utilization of coal, oil, natural gas and other auxiliary energy is the key to the operation optimization of integrated energy system. The feature recognition degree of multiple load time series data is different, and the prediction difficulty is also different. It is difficult to improve the comprehensive prediction accuracy of new users in a short period. In view of this, this paper studies the prediction strategy of the integrated energy system based on small sample data, and the research contents are as follows:

(1) Small-sample Day-ahead Power Load Forecasting of Integrated Energy System Based on Feature Transfer Learning: Firstly, the feature extraction and classification models of source domain data are constructed through optimal clustering and Gated Recurrent Unit (GRU) training. Then, the trained GRU classification model is used to extract the features and category information of small samples in the target domain to be predicted. A feature fusion strategy based on feature similarity and time forgetting factor is proposed. Finally, according to the fusion characteristics, the load prediction based on transfer learning and feature input is given. The proposed algorithm is applied to the electricity load forecasting of high schools and buildings in Cardiff. The experimental results show the effectiveness of the algorithm in power load forecasting with small size of samples.

(2) Small-sample Day-ahead Multiple Load Forecasting of Integrated Energy System Based on Coupling Relation Mining: Firstly, in order to solve the problem of feature extraction of small sample in multiple historical load data, the Variational Mode Decomposition (VMD) mechanism based on Particle Swarm Optimization (PSO) is constructed by taking the envelope entropy of the approximate correction of the center frequency of the eigenmode function as the fitness optimization function. Then, according to the decomposed eigenmode function with high characteristic identification degree, a mining strategy based on instantaneous frequency similarity and hysteresis factor is proposed. Finally, according to the coupling relationship between modes, the prediction models of common mode components and unique components are constructed to complete the multi-mode load forecasting of

中国知网 https://www.cnki.net

multi-element data. The proposed algorithm is applied to the comprehensive energy consumption forecasting of a region in Austin, and the experimental results show that the algorithm can effectively improve the accuracy of small sample day ahead multiple load forecasting.

This paper focuses on solving load forecasting of integrated energy system with insufficient data. Firstly, this paper presents a forecasting model framework based on feature transfer learning and feature fusion for power system load forecasting. Then, in the face of system multi-modal load forecasting, a multi-mode forecasting strategy based on multi-modal coupling relationship mining is proposed. The experimental results show the feasibility and effectiveness of the algorithm.

This thesis contains 20 figures, 13 tables and 105 references.

Keywords: integrated energy system; day-ahead load forecasting; feature extraction; transfer learning; variational modal decomposition

中国知网 https://www.cnki.net

目 录

摘要 ..... **I**
目录 ..... **IV**
图清单 ..... **VIII**
表清单 ..... **X**
变量注释表 ..... **XI**
1 绪论 **1**
1.1 研究背景及意义 2
1.2 研究内容和方法 4
1.3 研究成果 6
1.4 本文结构 6
1.5 本章小结 7
2 负荷预测方法概述 **8**
2.1 机器学习相关技术 8
2.2 迁移学习相关技术 11
2.3 信号分解相关技术 13
2.4 粒子群优化算法 16
2.5 预测性能评价指标 17
2.6 本章小结 18
3 基于特征迁移学习的综合能源系统小样本日前电力负荷预测 **19**
3.1 研究背景 19
3.2 算法框架 21
3.3 基于 K-means 聚类的 GRU 隐特征提取 22
3.4 基于遗忘因子的特征融合迁移机制 23
3.5 基于特征迁移的 ELM 预测模型 25
3.6 算例分析 25
3.7 本章小结 34
4 基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测 **35**
4.1 研究背景 35
4.2 算法框架 38
4.3 基于 PSO 的 VMD 负荷分解 39
4.4 基于迟滞因子瞬时频率的耦合关系挖掘及结果预测 40

中国知网 https://www.cnki.net

4.5 算例分析.....42
4.6 本章小结.....53
5 总结与展望 54
5.1 本文工作及创新点.....54
5.2 下一步研究工作.....55
参考文献 56
作者简历 63

中国知网 https://www.cnki.net

Contents

Abstract ..... **II**

Contents ..... **VI**

List of Figures ..... **VIII**

List of Tables ..... **X**

List of Variables ..... **XI**

1 Introduction **1**

1.1 Research Background and Significance 2

1.2 Research Contents and Methods 4

1.3 Research Findings 6

1.4 Structure of This Thesis 6

1.5 Conclusions 7

2 Overview of Load Forecasting Methods **8**

2.1 Machine Learning 8

2.2 Transfer Learning 11

2.3 Signal Decomposition 13

2.4 Particle Swarm Optimization Algorithm 16

2.5 Prediction Performance Evaluation Index 17

2.6 Conclusions 18

3 Small-sample Day-ahead Power Load Forecasting of Integrated Energy System Based on Feature Transfer Learning **19**

3.1 Backgrounds 19

3.2 Algorithm Framework 21

3.3 GRU Hidden Feature Extraction Based on K-means Clustering 22

3.4 Feature Fusion Migration Mechanism Based on Forgetting Factor 23

3.5 ELM Prediction Model Based on Feature Transfer 25

3.6 Experimental Analysis 25

3.7 Conclusions 34

4 Small-sample Day-ahead Multiple Source Load Forecasting of Integrated Energy System Based on Coupling Relation Mining **35**

4.1 Backgrounds 35

4.2 Algorithm Framework 38

中国知网 https://www.cnki.net

4.3 Load Decomposition of VMD Based on PSO 39
4.4 Coupling Relation Mining and Result Prediction Based on Instantaneous Frequency of Hysteresis Factor 40
4.5 Experimental Analysis 42
4.6 Conclusions 53
5 Summary and Prospect 54
5.1 Achievements and Innovations 54
5.2 Future Research 55
References 56
Author's Resume 63

中国知网 https://www.cnki.net

图清单

图序号	图名称	页码
图 2-1	ELM 结构图	9
Figure 2-1	ELM structure diagram	9
图 2-2	GRU 结构图	10
Figure 2-2	GRU structure diagram	10
图 2-3	迁移学习分类	12
Figure 2-3	Classification of transfer learning	12
图 3-1	基于特征迁移学习的算法框架	22
Figure 3-1	Framework of the proposed algorithm	22
图 3-2	基于轮廓均值确定最优聚类数	26
Figure 3-2	Optimal clustering number based on silhouette-coefficient mean	26
图 3-3	日负荷曲线聚类结果	26
Figure 3-3	Clustering results of daily load curve	26
图 3-4	日负荷曲线聚类中心	26
Figure 3-4	Cluster centers of daily load curve	26
图 3-5	四种场景下负荷预测结果对比	30
Figure 3-5	Comparisons of load forecasting in four scenarios	30
图 3-6	基于轮廓均值确定最优聚类数	31
Figure 3-6	Optimal clustering number based on silhouette-coefficient mean	31
图 3-7	日负荷曲线聚类结果	31
Figure 3-7	Clustering results of daily load curve	31
图 3-8	日负荷曲线聚类中心	31
Figure 3-8	Cluster centers of daily load curve	31
图 3-9	两种场景下负荷预测结果对比	33
Figure 3-9	Comparisons of load forecasting in two scenarios	33
图 4-1	基于模态分量间耦合关系的算法框架	38
Figure 4-1	Framework of coupling relationship between components	38
图 4-2	数据集 **I** 的 VMD 分解	43
Figure 4-2	VMD decomposition of data set **I**	43
图 4-3	数据集 **I** 的 EMD 分解	44
Figure 4-3	EMD decomposition of data set **I**	44
图 4-4	数据集 **II** 的 VMD 分解	44
Figure 4-4	VMD decomposition of data set **II**	44
图 4-5	数据集 **II** 的 EMD 分解	45
Figure 4-5	EMD decomposition of data set **II**	45
图 4-6	数据集 **III** 的 VMD 分解	45
Figure 4-6	VMD decomposition of data set **III**	45
图 4-7	数据集 **III** 的 EMD 分解	46
Figure 4-7	EMD decomposition of data set **III**	46

中国知网 https://www.cnki.net

图 4-8	三组实验下的负荷预测结果对比	51
Figure 4-8	Comparison of load forecasting results in three groups	51

中国知网 https://www.cnki.net

表清单

表序号	表名称	页码
表 3-1	三种模型性能对比	27
Table 3-1	Performance comparison of three models	27
表 3-2	目标域聚类/分类效果	28
Table 3-2	Clustering/Classification comparison	28
表 3-3	6 种预测算法精度比较	30
Table 3-3	Forecasting accuracy of six methods	30
表 3-4	目标域聚类/分类效果	32
Table 3-4	Clustering/Classification comparison	32
表 3-5	6 种预测算法精度比较	33
Table 3-5	Forecasting accuracy of six methods	33
表 4-1	PSO 具体参数	43
Table 4-1	Specific parameters of PSO	43
表 4-2	VMD 参数寻优结果	43
Table 4-2	VMD parameter optimization results	43
表 4-3	模态分量中心频率	47
Table 4-3	Central frequency of modal component	47
表 4-4	耦合共有分量	47
Table 4-4	Coupling common component	47
表 4-5	耦合分量及特有分量的 GRU 参数	48
Table 4-5	GRU parameters of coupling component and special component	48
表 4-6	耦合分量及特有分量模型个数	48
Table 4-6	Number of coupled component and unique component models	48
表 4-7	实验硬件/软件环境	48
Table 4-7	Hardware / software environment of the experiment	48
表 4-8	4 种预测算法精度比较	52
Table 4-8	Accuracy comparison of four prediction algorithms	52

中国知网 https://www.cnki.net

变量注释表

X_j^{ELM}	ELM 输入变量
Y_j^{ELM}	ELM 输出变量
a_{input}	ELM 输入层节点数
L	ELM 隐含层节点数
a_{output}	ELM 输出层节点数
$g(\cdot)$	激活函数
μ_i	输入层与隐藏层间权值
b_i	输入层与隐藏层间偏置
β_i	隐含层与输出层间权重
r_t	GRU 重置门
z_t	GRU 更新门
h_t	t 时刻的状态信息
σ	sigmoid 激活函数
W_z	更新门权重
W_r	重置门权重
W	当前记忆权重
x_t	原始时序信号
$x_u(t)$	上包络线
$x_l(t)$	下包络线
m_1	包络线均值
IMF_{c_i}	本征模态分量
r_n	残余分量信号
u_k^{n+1}	VMD 分解 IMF 分量
ω_k	中心频率
∂_t	函数偏导
$\delta(t)$	单位脉冲函数
$\lambda(t)$	拉格朗日算子
α	二次惩罚因子
τ	步长
X_i	粒子位置
V_i	粒子速度
P_i	个体极值
P_g	全局极值
θ	惯性权重
c_1	学习因子

中国知网 https://www.cnki.net

c_2	学习因子
$\mathbf{x}_i$	第 i 个采样点负荷实际值
$\tilde{\mathbf{x}}_i$	第 i 个采样点负荷预测值
X_S	源域日负荷曲线数据集
$d_{\text{in}}(\mathbf{x}_{i.})$	第 i 天负荷数据到同类其他所有对象的平均距离
$d_{\text{ic}}(\mathbf{x}_{i.})$	第 i 天负荷数据其他类所有对象的平均距离的最小值
Sm	轮廓均值
X_{S}^{k}	源域第 k 类日负荷曲线样本集
F_{S}^{k}	源域第 k 类日负荷曲线隐特征集
X_T	目标域日负荷曲线集
F_T	目标域日负荷曲线隐特征集
F_T^k	目标域第 k 类日负荷曲线隐特征集
n_{T}^{k}	目标域第 k 类负荷数据集规模
$\mathbf{fc}_{n_{\text{T}}^{k}}^{k}$	目标域第 k 类最近日期负荷的隐特征集
df_i^k	余弦相似度
$\mathbf{fc}^k$	融合特征向量
$\mathbf{fc}_F^k$	含时间遗忘因子的融合特征向量
η_t	特征迁移阈值
F_{Ts}	迁移特征集
X_{Ts}	迁移样本集
F_{Tr}	学习样本训练集
X_{Tr}	学习特征训练集
E_p	包络熵
a_j	经 Hilbert 变换、求模后的包络信号
p_j	a_j 归一化后概率序列
F_ω	中心频率近似修正因子
$fitness$	分量中心频率近似修正的包络熵适应度函数
K_m	第 m 个粒子的模态函数个数
α_m	第 m 个粒子的二次惩罚因子
K_{gbest}	全局最优模态函数个数
α_{gbest}	全局最优二次惩罚因子
$Load_{multi}$	多元负荷曲线数据集
K_1	第一种能源的模态个数
K_2	第二种能源的模态个数
$\mathbf{load}_{\mathbf{ij}}^{\mathbf{1}}$	$Load_{multi}$ 的某种能源数据
$\mathbf{load}^1$	$\mathbf{load}_{\mathbf{ij}}^{\mathbf{1}}$ 的一维向量展开

中国知网 https://www.cnki.net

IMF_k^1	**load**[1] 对应的模态函数集
$Freq_k^1$	IMF_k^1 对应的瞬时频率集
$Freq_k^2$	IMF_k^2 对应的瞬时频率集
$c_{K_1\|K_2,j}$	$Freq_k^1$ 与 $Freq_k^2$ 的关系向量
C_{multi}	$c_{K_1\|K_2,j}$ 的关系向量集合
k_{multi}	C_{multi} 向量个数
T	迟滞因子
$c_{K_1\|K_2,j}^T$	考虑迟滞因子的关系向量
C_{multi}^T	$c_{K_1\|K_2,j}^T$ 的关系向量集合
k_{multi}^T	C_{multi}^T 向量个数
$C_{\max}$	多元负荷间的最值关系向量集合
$Avg_{\max}$	关系向量均值集合
$C_{coupling}$	耦合向量集
p	$C_{coupling}$ 中耦合向量个数
$IMF_{coupling}$	耦合共有分量
$input_1$	规模为第 1~24 个采样点的输入向量
$output_1$	规模为第 25 个采样点的输出向量
$input_2$	规模为第 2~25 个采样点的输入向量
$output_2$	规模为第 26 个采样点的输出向量
Input	训练集输入集
Output	训练集输出集
$pre_{coupling}^1$	类型 1 的耦合共性分量的预测结果
$pre_{coupling}^2$	类型 2 的耦合共性分量的预测结果
pre_{left}^1	类型 1 的剩余分量的预测结果
pre_{left}^2	类型 2 的剩余分量的预测结果

中国知网 https://www.cnki.net

1 绪论

1 Introduction

近代以来，由于全球人口数量、工业生产和经济总量的快速增长，与之相关的能源消耗总量呈阶梯式暴涨，导致煤、石油和天然气等非可再生化石资源日益枯竭[1, 2]，因此如何深度优化未来世界的能源结构成为国内外能源领域专家的研究热点[3]。随着国家能源生产战略的深入部署与能源消费结构的深刻变革，以能源互联网物理结构为载体的综合能源系统（Integrated Energy Systems，IES）[4, 5]，为提高清洁能源利用率，创建高性能、高安全性、智慧灵动的能源消纳方式等方面提供了重要指导。实践应用与理论指导同步，国内各地区响应国家节能减排号召，从可再生能源入网、降低不可再生利用比例、优化能源结构和多能耦合等多个角度建成各具特色的综合能源系统。而负荷的分析预测与控制管理，既是实现能源有序化管理的重要前提，又是综合能源系统中能源优化调度的基础部分[6]。负荷预测通常利用负荷历史数据与环境气候、经济等特征的相关性，通过数据挖掘、分析等方式探寻出负荷变化与相关因素之间的规律，实现对未来一段时间内的负荷时序曲线拟合。精准的负荷预测不仅是制定综合能源调度计划、控制设备启停的关键，而且对提高综合能源系统经济性、安全性具有重要的意义[7]。物联网的发展、移动互联网的提升及计算能力的飞跃进步等诸多因素，促成了大数据时代的来临，通过对能源大数据的挖掘，国内外学者们对综合能源负荷预测问题的研究在理论及实践应用上取得了颇多成果，例如提高了预测精度、改进了预测模型框架，根据预测结果制定了相应的调度计划。但在面临数据匮乏的新用户预测时，即用户采集到的的历史负荷样本较小（例如：仅有一个月的历史采样数据，甚至更小的样本），目前常用的预测方法解决此类小样本预测问题显得有些乏力，预测精度明显不足；另外，随着综合能源系统的逐步发展，部分学者开始在综合能源背景下以提高多元异质数据预测精度为目标进行探索性分析与研究，通过研究多能耦合方式深度分析多元负荷内联关系，进而达到提升预测精度的目的，但这一研究方向同样存在着用能数据获取困难等不足。因此，本文主要研究小样本下的综合能源系统负荷预测问题，针对电力负荷及多能负荷预测分别构建基于特征迁移融合和基于耦合关系求解的模型框架，从而提升小样本的负荷预测精度。

绪论的总体结构安排如下：1.1 节阐述研究背景及研究意义；1.2 节介绍研究内容和方法；1.3 节是研究成果的列举；1.4 节对论文整体结构进行阐述、1.5 节对绪论部分加以总结，为下一章的展开奠定基础。

中国知网 https://www.cnki.net

1.1 研究背景及意义（Research Background and Significance）

近年来，综合利用冷热电等多种能源，并考虑其相互转化和耦合关系的综合能源系统成为电力系统研究的重点内容之一。综合能源系统通过电力系统、热力系统及天然气管网等多种形式能源的协作互补，增强了系统整体的安全性和高效性，是提高不可再生能源利用率的重要手段与途径。为了高效、快捷地制定和调整综合能源系统调度优化，需要提前一天或多天对系统内多种类型能源的需求总量精准预测，从而为综合能源系统制定调度计划提供合理依据。因此，基于精准的日前负荷预测设计高效的综合能源管理是系统有效运行的关键。综合能源系统一般以电力能源和负荷为核心，并且日前电力负荷精准预测在电力系统调度与能量管理中至关重要，因此，对综合能源电力负荷的预测是基础。针对综合能源系统中电力系统短期负荷预测问题，常利用数据挖掘及智能优化算法对造成负荷波动的关键特征进行剖析，并使用经典预测方法、传统预测方法或智能预测方法来描述电力负荷如何随时间而变化，对未来耗电情况进行精准拟合。

传统线性回归方法依赖于过去的历史数据，也不具备非线性拟合能力；传统人工神经网络则存在拟合不足或过拟合的问题，而且短期负荷在受到天气、日期类型等环境因素的影响之下，往往会表现出随机性和不确定性的特征；而拥有较强的学习能力与处理非线性问题映射能力的机器学习等智能算法，能够较好的处理这类问题，且当前已有丰硕的研究成果[8-10]。Vermaak 和 Botha[11]首次将递归神经网络（Recurrent Neural Networks，RNN）应用于短期负荷预测，相较于正常的前馈网络，RNN 由于其出色的非线性动态特性，可以较好的捕获到负荷的动态行为特性。随着机器学习的发展，电力负荷预测的相关研究也紧随潮流同步演进，部分学者专家致力于研究准确度更高的预测模型；Shi Heng 等[12]提出一种新的基于池的深度递归神经网络（PDRNN）用于家庭负荷的预测，实现了在互联客户之间的信息共享；张宇帆等[13]通过随机搜索方法确定泛化能力最优的 LSTM 模型超参数，并通过隐层向量的可视化分析，展示了深度 LSTM 算法的抽象特征提取效果，也证实了 LSTM 算法的负荷数据特征学习以及捕捉动态特征的卓越能力；沈兆轩等[14]考虑到区域用户负荷数据的类型多样性，根据负荷数据与气温、风速、节假日等影响因素数据确定了聚类方法，然后将集成后的数据输入到 CNN 中提取特征，再将特征矩阵输入到 SVR 中进行负荷预测，对比实验表明在精确度与运行速度方面较经典 CNN、RNN 有所提升；Lulu Wen 等[15]针对住宅电力负荷需求预测问题，提出了一种基于 GRU 神经网络的 RNN 深度学习预测模型，有效提高了模型的自适应学习能力；易灵芝等[16]将进化优化算法思想融入 DBN 中，设计了一种基于遗传算法、进化策略的深度学习特征提取预测模型，增强对高维非线性电力负荷数据特征的提取效果，实验显示所提模型精度较

中国知网 https://www.cnki.net

SVM、ARIMA 等均有所显著提高；杨智宇等[17]在训练 DBN 模型时，以改进的 Nadam 算法作为梯度下降的优化方法，增强了模型的自适应性；孙海蓉等[18]将 DBN 与支撑向量机回归模型（ SVR） 结合，构造出由一种短时热网负荷预测模型，充分融合了 SVR 较好处理非线性数据与 DBN 深入挖掘数据本质特征的优点，经过与传统 SVR 的对比实验展现出其预测精度的优越性；Yi Wang 等[19]针对电力负荷概率预测的不确定因素，提出了一种基于生成对抗网络的残差场景生成方法，并从多个角度验证所提算法应对不同领域的有效性。

与传统电网的电力负荷相比，综合能源系统用能用户规模相对较小，单用户用能行为的变化会对系统整体电力负荷产生更加明显的影响；此外，系统中电热水冷气等多能协同互补，冷热电负荷相互耦合和影响，系统可进行能量梯级利用，进一步使得其电力负荷具有更大的波动性和随机性，导致综合能源系统电力负荷日前精准预测难度进一步增加[20]。显然，如何有效提取影响负荷波动的特征，并基于该特征实现对综合能源电力负荷的精准预测是上述研究思路的核心。并且，智能算法顺应大数据时代的发展，模型预测精度的提高需要与庞大的时序数据量紧密相连，但是当系统出现新增用户，即面临用户历史负荷数据样本量较少的情况时，可用信息受限，已有的算法并不适用，因此需要通过相似数据的迁移等手段丰富新用户特征属性，从而搭建更为可行有效的算法框架。

从当前情况可知，电力系统作为综合能源系统的主要构成部分，对系统的安全稳定运行有着举足轻重的作用，冷热电联产系统、天然气管网、风能及太阳能利用装置则与电力系统相互补充，用户耗能形式选择的多样性带动了区域综合能源系统保持灵活供需平衡的积极性与设备优化技术的发展，与此同时也对系统的需求侧管理提出了更高要求。因此，从负荷预测总体规划角度分析，深度揭示多元异质数据之间的耦合关系，是系统能流分配及建立系统优化模型的前提，也是为需求侧提供能源需求柔性解决方案的关键；从用户用能体验角度分析，个人需求侧行为由能源供应质量决定，耦合规律与供应质量、价格相互作用。而如何利用耦合关系促进综合能源系统整体预测精度的提升逐渐被国内外学者所关注。Swan 和 Ugursal[21]认为处理综合能源系统中多元数据可以从宏观与微观两个角度出发，宏观类负荷预测方法基于综合能源消费和宏观量等历史数据，利用统计学方法寻找内在关联；微观类方法常利用非聚合类模型，其着眼于单个用户的用能需求情况，以多用户总和方式得出预测结果，不同于宏观预测，该类方法善于从内部提炼能源消费特性，建模过程更为详细透彻。运用数据挖掘等信息技术对用户多元数据进行剖析、预测，是给用户提供优质有效的用能策略的关键步骤，而能源种类的多样性往往伴随着传感器类型、应用环境和采样周期的差异性，获取到的用户用能数据也具有量纲、时间及空间等的异质性。朱刘柱等[22]提出一种

中国知网 https://www.cnki.net

基于小波包分解的冷热电综合预测策略，通过对原始信号的有效分解、分析频段间互相关性等方法，实现了多能源数据间的有效耦合判别。栗然等[23]针对较小规模下的多负荷类型综合能源系统负荷预测，考虑到其波动性及能量耦合关系复杂的特点，构建了一个基于多能间时空耦合的预测框架。田浩含等[24]提出利用灰色关联度分析方法，对综合能源系统中冷热电多元负荷以及与环境因素间的耦合关系进行深入挖掘，同时利用 LSTM 作为负荷预测模型的算法支撑，并在模拟数据集上对所提算法的非线性多元负荷预测性能进行了验证。孙庆凯等[25]将 LSTM 神经网络作为共享层，以模拟多元数据间的耦合关系，从而提出一种基于共享机制的多任务学习多元负荷预测策略。

综上所述，综合能源系统作为一种高效利用能源的区域模式，不仅对节能减排、提升可再生能源利用率、协调能源调配具有非凡意义，而且也是支撑国家可持续发展战略的重要举措。综合能源系统的设备运行优化和运行方案的制定，与系统的能源需求总量息息相关，因此，负荷时序预测作为一种数据分析技术，如何通过精准把握用能趋势完成系统负荷预测变得至关重要。电力系统作为综合能源系统的重要组成部分，电力负荷的精准预测是系统运行灵活性与可靠性的重要保障，与此同时，电力系统与冷热电等多能系统相辅相成，多能流间交错纵横相互制约，因此多能间耦合特性的发掘也是提升综合负荷预测精度的关键一步。然而，正如上述利用智能算法进行负荷预测时，面临用户的时序数据样本量过少等问题，因此，本文着眼于综合能源系统中小样本用户的预测精度提升，从系统的电力预测和多能预测分别入手，开展了基于特征迁移的小样本日前电负荷预测，和基于耦合特性探索的小样本日前多元负荷预测研究，通过引入迁移学习、模态分解等方法对关键要点进行剖析，提升预测模型的精度，为处理该类问题提供了解决思路。

1.2 研究内容和方法（Research Contents and Methods）

根据 1.1 节描述的综合能源系统预测亟待解决的问题，本文针对小样本电力负荷预测及多元负荷预测问题分别构建了预测算法框架，因此本文的研究核心内容主要为两点：

（1）基于特征迁移学习的综合能源系统小样本日前电力负荷预测

当使用传统或智能时序预测方法，拟对用户电力负荷进行精准预测时，由于数据的波动性，常需要信息量庞大的数据集为支撑，以期从长久的历史负荷信息中获取相应的用户行为、用能趋势等特征，从而捕捉到时序变化。但当综合能源系统中新用户的历史负荷数据样本量极少时，短周期内的用户特征不明显、随机扰动影响大等因素，致使当前成熟的预测模型框架对小样本数据的处理和预测能力不足，难以建立起精准的负荷预测模型。针对此，研究内容（1）提出基于特

中国知网 https://www.cnki.net

征融合、迁移的综合能源系统小样本日前电力负荷预测，利用深度学习提取聚类后的源域特征，通过构造特征迁移标准，实现待预测小样本目标域的数据扩充，构建电力负荷预测模型。主要研究内容包括基于聚类算法及深度学习的隐特征提取、隐特征的融合迁移机制及预测模型的构建、实例的结果分析与结论。

研究内容具体来说，首先，选取与小样本待测用户具有相似用能属性的成熟用户作为源域的电力数据来源，将待测用户历史负荷数据作为目标域，利用K-means 聚类算法对源域的电力数据进行行为类别划分，并采用 GRU 神经网络提取聚类数据隐特征，作为用户行为的隐性表示；同时，将目标域数据带入以上聚类及特征提取模型，降低预测模型对原始数据的识别难度；接着，以含有时间遗忘因子的特征相似度作为目标域数据隐特征的融合依据，并通过融合特征实现源域、目标域间相似特征的样本迁移，从而精细化了电力负荷相似数据的选择、迁移过程，减少负迁移样本的混入；然后，以迁移所得特征、时序数据集训练极限学习机（Extreme Learning Machine, ELM）快速拟合模型，简化模型构造，提升预测效率，并输入融合特征得到预测结果；最后，在卡迪夫某区域的电力负荷数据集上进行算例检验，验证所提基于特征融合、迁移的电力预测算法的可行性与有效性。

（2）基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测

综合能源系统以电力系统为主导，冷、热、天然气及其他清洁能源为互补，多种能源梯级利用，研究内容（1）仅针对系统中小样本电力负荷进行精准预测的探讨，且需要获得与待测用户相似的成熟用户作为源域数据集支撑。而在综合能源实际运行过程中，电力系统与热力系统、天然气管网等存在紧密的耦合关系，因此短周期内的多元负荷数据，存在更为复杂多变的随机扰动，且相似功能熟悉的源域用户获取有人为影响因素偏差性，因此内容（1）中的模型无法适用。针对此，研究（2）提出基于信号分解及耦合关系发掘的综合能源系统小样本日前多元负荷预测策略，利用变分模态分解（VMD）对多元数据进行时序分量划分，通过构造分量间耦合关系评价指标，实现多元共有特性分量的发掘，构建多元负荷的多模预测模型。主要研究内容包括基于参数优化算法的原始信号变分模态分解、基于瞬时频率相似度的分量耦合关系挖掘机制、耦合共有分量及特有分量的组合预测模型构建和实例的结果分析与结论。

研究内容具体来说，首先，利用 VMD 对用户多元时序数据进行模态划分，获得固定个数的子序列模态分量，分量个数及惩罚函数值由粒子群优化算法（Particle Swarm Optimization, PSO）确定，同时为了避免模态混叠情况的出现，将分量中心频率近似修正的包络熵作为参数寻优的适应度函数，从而获得具有鲜明特征及规律性周期变化的分量子序列集，减少预测模型的建模难度；接着，构

中国知网 https://www.cnki.net

造基于分量间瞬时频率特征向量的迟滞相似判别公式，将相似度作为耦合关系衡量指标，实现多元间耦合关系的挖掘，与此同时，提取出多元耦合共有分量，将剩余分量作为各自特有分量，从而简化多元间耦合特征表示；然后，将共有分量以并行方式训练基于 GRU 的耦合共性预测模型，特有分量单独训练 GRU 预测模型，对各子序列分量预测结果进行累加求和，得出多元预测结果；最后，在奥斯丁某区域进行实例验证，通过与其他算法对比验证所提算法的优越性。

1.3 研究成果（Research Findings）

综合 1.2 节所述的研究内容及方法，本文取得以下研究成果：

（1）基于 *K* 均值聚类算法及 GRU 神经网络提取特征，构建遗忘因子与迁移学习相结合的特征融合迁移机制，搭建极限学习机预测模型。

首先，依据源域用户历史负荷数据，利用 *K* 均值（K-means）聚类算法对其进行类别划分，并利用该类别信息，训练门控循环单元（GRU）网络获得基于源域数据的特征提取和分类模型；然后，利用该模型进一步提取当前待预测目标域小样本的特征及其类别信息，给出基于特征相似度和时间遗忘因子的特征融合策略；最后，以融合特征为参考，从源域中选择特征与之相似的数据进行迁移，训练极限学习机（ELM），并将融合特征作为预测模型的输入，从而得到目标域预测结果，为实现小样本下的日前电力负荷精准预测提供了解决思路。

（2）基于粒子群进化优化算法的变分模态分解，提取特征分量，考虑分量瞬时频率相关性挖掘耦合共性关系，搭建耦合共有及特有分量组合预测模型。

首先，采用基于 PSO 算法的 VMD 分解策略对多元数据进行模态分量划分，其中，以分量中心频率修正的包络熵为适应度函数，用于确定 VMD 模态个数及惩罚函数值；然后，以分量瞬时频率相似度为耦合关系评价指标，求得多元子序列分量间共性分量，同时分离出特有分量；最后，基于共性分量及特有分量分别构建 GRU 预测模型，完成综合能源系统下的小样本日前多元多模预测。

1.4 本文结构（Structure of This Thesis）

本文主要研究内容为综合能源系统小样本日前电力负荷预测及多元负荷预测，共分为 5 个章节：第 1 章为绪论，介绍研究背景；机器学习、迁移学习、信号分解的相关工作以及粒子群优化算法和预测性能评价指标于第 2 章列出；第 3 章、第 4 章是本文的研究核心内容，分别为基于特征迁移学习的综合能源系统小样本日前电力负荷预测方法和基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测方法；第 5 章对全文研究进行整体概括、总结，并列出本文的创新点，同时根据现有研究的不足明确下一步研究的方向。

本文首先针对小样本电力负荷预测问题，利用聚类算法及深度学习提取源

中国知网 https://www.cnki.net

域、目标域数据的隐特征，结合特征融合与迁移学习知识实现从源域到目标域的样本扩充，并构建极限学习机预测模型；然后，在面对小样本多元负荷预测问题时，将多元非线性时序信号利用变分模态分解方法分解为若干平稳分量，并通过分量间耦合关系的计算推及出多元共有分量，训练多个 GRU 神经网络进行组合预测。各章概况如下所示：

第 1 章 绪论 阐述本文研究内容及意义，陈列研究内容和方法，展示本文研究成果。

第 2 章 负荷预测方法阐述 综述本文涉及的负荷预测相关研究方法，包括：机器学习相关技术、迁移学习相关技术、信号分解相关技术、粒子群优化算法以及预测性能评价指标，为后续的研究工作提供理论基础。

第 3 章 基于特征迁移学习的综合能源系统小样本日前电力负荷预测 首先，陈述章节研究背景；接着，给出算法框架结构；然后，阐明基于 K-means 聚类的 GRU 隐特征提取方法、基于遗忘因子的特征融合迁移机制的理论依据及实施步骤；最后，将算法应用于卡迪夫某区域的两个真实数据集中验证算法有效性。

第 4 章 基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测 首先，阐述章节研究背景；接着，给出算法框架结构；然后，阐明基于 PSO 的 VMD 负荷分解策略、基于迟滞因子瞬时频率的耦合关系挖掘及结果预测的理论依据及实施步骤；最后，将算法应用于奥斯丁的真实数据集中验证算法可行性。

第 5 章 总结与展望 对本文内容进行整体概括，列出创新之处，并通过陈述仍待解决的问题展望下一步研究工作。

1.5 本章小结（Conclusions）

本章介绍了全文研究背景、研究内容与方法，并列出了研究核心内容所得成果，旨在通过展示研究脉络，对后续章节内容的展开具有提纲挈领的作用。

第 2 章将介绍与本文研究工作相关的理论内容，包含：机器学习、迁移学习、和信号分解的相关技术、粒子群优化算法以及预测性能评价指标，为后续章节的开展提供研究基础。

中国知网 https://www.cnki.net

2 负荷预测方法概述

2 Overview of Load Forecasting Methods

前一章是关于综合能源负荷预测的研究背景与意义、本章核心研究内容和所取得的阶段性成果的整体介绍，第 2 章将针对本文所提的负荷预测算法中涉及的相关技术手段进行细致介绍，为第 3、4 章研究内容奠定理论基础。

本章段落结构如下：2.1 节介绍搭建预测模型时所涉及的机器学习相关知识；2.2 节介绍有关迁移学习的相关技术；2.3 节是时序信号分解方法的阐述；2.4 节是优化预测模型参数时所使用的粒子群优化算法；最后，对本章内容做出总结。

2.1 机器学习相关技术（Machine Learning）

作为人工智能领域最具智能特征且最重要的分支，机器学习交叉多领域学科知识，汇聚多种学习能力，不仅在知识系统中得到关注，也在自然语言处理、机器视觉、模式识别、知识图谱、时序预测等诸多领域中得到广泛应用，本节将从构造原理、工作过程、模型优点等角度介绍极限学习机及门控循环单元知识，为本文后续开展的模型研究内容夯实基础。

2.1.1 极限学习机

相较于通过误差反向传播（Back Propagation, BP）调整权重与偏置的神经网络，极限学习机（ELM）是针对单隐含层前馈神经网络设计的新算法，黄广斌等[26]研究证实了其隐含层参数不需要人为参与，隐含层权重与偏置依据任意连续的概率分布随机生成，学习过程只需求解隐含层与输出层的连接权重，且权重通过广义逆矩阵理论可得，学习参数从而简化，因此相较于支持向量机算法及 BP 算法，ELM 计算量更小，学习效率更高，泛化性能更优，可应用于需要快速拟合的回归问题。

颜宏文等[27]以历史天气、信息日期类别为决策树分类准则构建层次聚类方法，并利用气候及日属性信息实现相似日负荷数据的匹配，然后利用 ELM 完成最终预测，从而提出一种基于层次聚类和 ELM 的负荷预测模型。章婕[28]提出一种支持向量回归（Support Vector Regression, SVR）与 ELM 相组合的短期热负荷预测策略，充分地利用 ELM 的强容错性、简单运算等特点，运用 BP 神经网络从而实现权重的自学习调节。蒋建东等[29]对烟花算法的映射规则及变异规则进行优化，并以 ELM 权值与阈值为优化变量，实现了基于改进烟花算法的 ELM 短期预测模型的构建，并通过实验结果证明了所提算法的鲁棒性。Song Li[30]等则以改进的人工蜂群算法作为 ELM 参数优化途径，同时利用小波分析对原始序列

中国知网 https://www.cnki.net

的分解作用，实现了特征简化与模型优化的同步进行。张宁等[31]为了避免过学习现象的出现，改进了 ELM 神经网络中隐层节点的特征映射方式，采用核函数作为降低结构风险的映射手段，搭建了一个具有较强泛化能力的 ELM 预测模型。

ELM 网络结构图如图 2-1 所示：

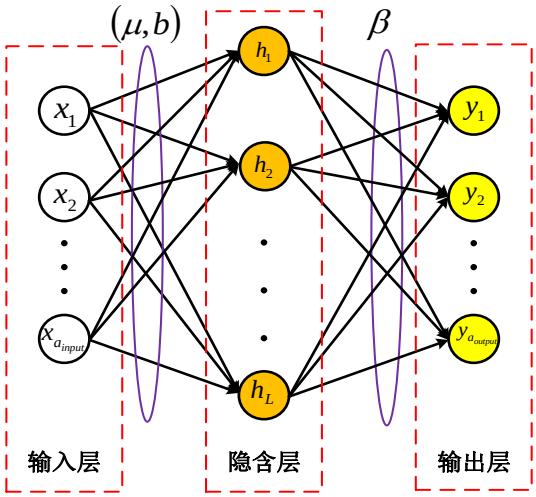


图 2-1 ELM 结构图

Figure 2-1 ELM structure diagram

当给出一组输入输出训练样本向量：$X_j^{ELM}=\left[x_{j1},x_{j2},...,x_{ja}\right]^T\in R^{a_{input}}$，$Y_j^{ELM}=\left[y_{j1},y_{j2},...,y_{jc}\right]^T\in R^{a_{output}}$，输入层有 a_{input} 个节点，输出层有 a_{output} 个节点，含有 L 个隐层节点的 ELM 数学模型为：

$$y=\sum_{i=1}^{L}g\left(\mu_i^T x+b_i\right)\cdot\beta_i \tag{2-1}$$

式中，$g(\cdot)$、μ_i 和 b_i 分别为第 i 个隐层节点的激活函数、连接权值及偏置，激活函数可选 *sigmoid* 函数、*gaussian* 函数等非线性分段连续函数，μ_i、b_i 随机生成；β_i 为隐含层与输出层之间的权重。

因此 ELM 的数学模型可以简化为：

$$Y=H\beta \tag{2-2}$$

$$H=\left[g\left(\mu_1^T x+b_1\right),g\left(\mu_2^T x+b_2\right)...,g\left(\mu_L^T x+b_L\right)\right] \tag{2-3}$$

式中，$\beta=\left[\beta_1,...,\beta_L\right]^T$，可以通过正则化最小均方误差解得[32]。

综上所述，ELM 算法简单、高效，隐层节点一旦确定后不再需要通过反向传播进行修正，即使在没有训练数据的情况下，也可以生成隐层参数，满足本文需要快速建立针对性特征、样本间联系的要求。

2.1.2 门控循环单元

循环神经网络（Recurrent Neural Network，RNN）由于其出色的非线性动态特性，可以较好的捕获到时间序列的动态行为特性，挖掘出短期、长期时序前后

中国知网 https://www.cnki.net

的依赖关系，但反向传播会存在梯度消失和梯度爆炸的可能，对此 LSTM 通过引入门控机制，通过添加遗忘门、输入门和输出门等多个参数，对信息进行过滤与储存，从而避免所有历史信息的清除，同时会保留部分的相关信息至下一神经元，有效的解决了反向传播时梯度的异常情况，但是网络性能的优化伴随着时间成本的增加。相较于 LSTM，GRU 通过精简门控单元个数达到提升收敛速度且不影响精度的效果。GRU 作为 LSTM 的改进版只有两个门控结构：重置门与更新门，它将遗忘门和输入门合并为重置门 r_t，只保留遗忘功能，控制上一时刻状态信息的遗忘程度，重置门的值越小，表明历史信息遗忘的比例越大，更新门 z_t 则决定前一时刻与当前时刻的信息结合程度，更新门的值越小，说明模型的输出更贴近前一时刻即上一隐层状态，同时配合合并细胞状态与隐藏状态达到简化模型结构的目的。

赵兵等[33]为了克服历史数据中动态变化的高维特征的提取难题，采用（Convolutional Neural Network, CNN）作为特征提取器，同时引入注意力机制（Attention）对关键信息进行加权保留，从而提出了一种基于掌握负荷时序数据周期性变化和高维动态特征提取的 CNN-GRU 模型。庄家懿等[34]则利用 CNN 与 GRU 的并行方式分别提取局部特征与时序特征，以拼接特征作为深度神经网络的输入，从而构建了一种并行的多模融合预测模型。Wenyi Wu 等[35]利用分类树对输入特征进行分组，并在考虑电价的影响下实现 GRU 预测模型的搭建。王康等[36]通过利用双向加权 GRU 实现对过去和未来信息的同时把控，并将 Bagging 算法作为训练的多个 GRU 模型集成策略，有效地提高了电力系统短期负荷预测的精度。Zhewen Niu 等[37]通过构建 GRU 编码-解码器实现了模块间隐藏信息的激活，同时融入 Attention 机制对影响风电预测的因素进行筛选，实现重要性特征选择，最终通过实验对比验证了所提算法在风电预测问题上的效率。

GRU 单元结构图及计算公式如下所示：

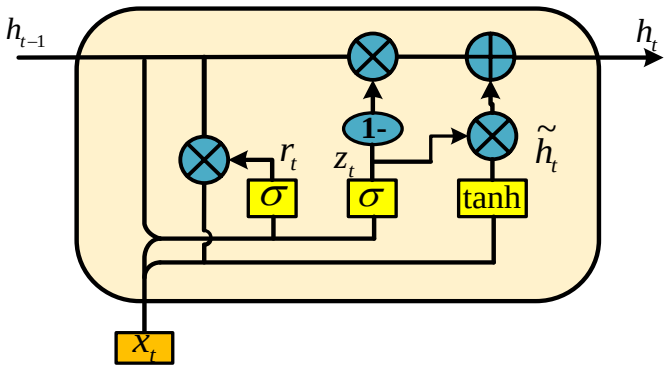


图 2-2 GRU 结构图

Figure 2-2 GRU structure diagram

$$z_t = \sigma\left(W_z \cdot \left[h_{t-1}, x_t\right]\right) \tag{2-4}$$

$$r_t = \sigma\left(W_r \cdot \left[h_{t-1}, x_t\right]\right) \tag{2-5}$$

中国知网 https://www.cnki.net

$$\tilde{h}_t = \tanh\left(W \cdot \left[r_t * h_{t-1}, x_t\right]\right) \quad (2\text{-}6)$$

$$h_t = \left(1 - z_t\right) * h_{t-1} + z_t * \tilde{h}_t \quad (2\text{-}7)$$

式中：h_t 表示当前时刻的状态信息，维度由隐层节点数决定；σ 是 *sigmoid* 激活函数；$[\cdot]$ 代表矩阵乘法；$[,]$ 表示左右变量的连接；$*$ 表示矩阵的哈达玛积；W_z、W_r、W 分别代表更新门、重置门与当前记忆三者的权重。

2.2 迁移学习相关技术（Transfer Learning）

随着以数据驱动技术为核心的机器学习的蓬勃发展，其在越来越多的领域中受到青睐。通过前期对各类用户数据的收集、筛选和整合，利用神经网络和知识图谱等技术手段，可以实现用户个人画像的细致把握，从而对用户进行高效、精准的个性化推荐；同时，机器学习也可以借助庞大的图片数据集、评价文本集，对信息进行特征提取，佐以分类算法，以达成图片的识别、虚假文本的鉴定；也可以根据已知的历史用能负荷数据，通过对前后用能趋势的有效捕捉，依据负荷需求变化及时做出调整，从而协调储能设备运行优化。但是，传统机器学习的核心是数据与特征的充分、合理利用，利用大量样本集进行迭代训练，从而训练出可行模型。而在实际操作中，往往会因为采集设备的缺乏、对数据的不敏感及个人隐私意识的加强等因素，致使可获取的样本数量不足，同时样本数据标注处理的高成本、低效率，也会使采集数据中的可用数据占比过少，难以支撑模型的构建，而迁移学习概念的提出、方法的使用，为构建强泛化性机器学习模型及提升传统机器学习的建模利用率提供了有力协助。刘世昌[38]对历史一周的数据进行多尺度分析，以挖掘子序列中的隐含信息，同时采用一种基于核岭回归的特征数据迁移方式，兼顾负荷数据相似性与差异性，实现了数据的充分利用，从而构建对电力负荷的精准预测模型。邓翱[39]通过在 EMD 分解算法中引入竞争迁移学习，在克服 EMD 边界效应的同时对各分量进行延拓，从而实现了对源任务的有效筛选，构建了基于最小二乘支持向量机（Least Square SVM, LSSVM）的短期负荷预测模型。Dengji Zhou 等[40]提出了一种基于双向生成对抗网络和转移学习的数据扩充机制，并将 BPNN、SVR 和 LSTM 作为扩充数据的预测模型选项，与此同时，对样本数量设置为期半年的动态滑动窗口来验证算法模型的优越性。

迁移学习是一种可以利用数据特征相关性，将已有的数据信息应用到另一个场景中解决问题的技术研究，在面对两个领域的输入特征空间、样本数据的分布有所差异的情况时，可以通过构造可用样本的筛选机制，完成域间信息传递，从而利用迁移信息对新数据建立模型。迁移学习的主要概念为：领域、任务，而领域则分为源域（Source Domain）与目标域（Target Domain），其中源域指已有数据、特征构成的样本空间集合，数据量足够大，是迁移学习的主体构造，目标域一般含有的特征信息量较少，样本标签也相对缺失不少。所以，根据源域与目

中国知网 https://www.cnki.net

标域特征空间差异性与样本分布的相关性，现有研究可细化为同构迁移学习和异构迁移学习；而根据源域、目标域间迁移的主体以及迁移所用方式，可将迁移学习的研究分为以下 4 种类型：基于实例迁移的研究、基于特征迁移的研究、基于模型迁移的研究和基于关系迁移的研究；与此同时，依据源域数量的多少，迁移学习亦可以划分成单源域及多源域的迁移策略研究。本小节主要介绍与本文研究相关的实例迁移及特征迁移。

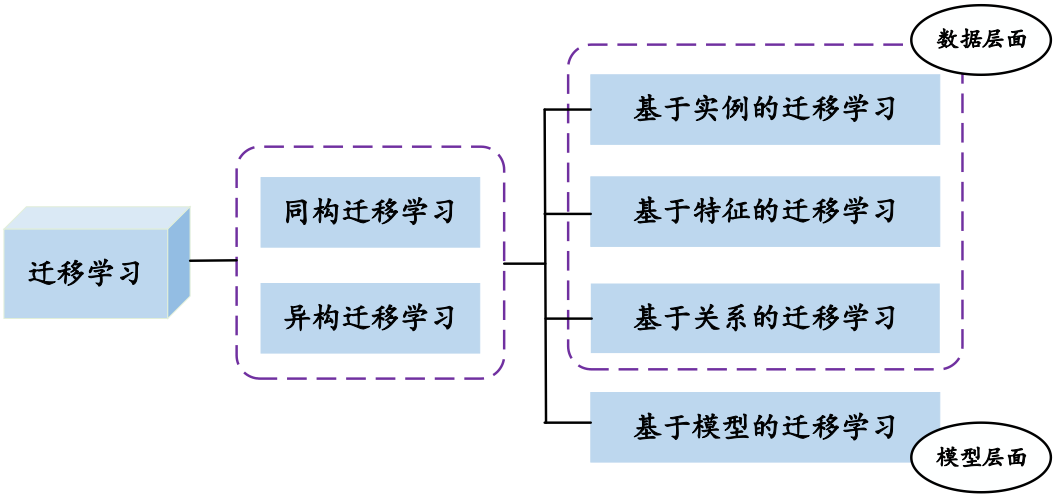


图 2-3 迁移学习分类

Figure 2-3 Classification of transfer learning

（1）基于实例的迁移学习

在对数据信息的实际应用中，源域数据结构往往较为复杂，因此需要对源域中的信息进行筛选、剔除后才能迁移至目标域，从而避免不相关的信息成分的误导与干扰，减少负迁移样本的出现。因此，为达到精准迁移的目的，实例迁移的方法首先要挑选与目标域样本共享特征的源域；然后，要对源域中已经有标记的样本，根据设定的度量标准进行权重的赋值，且相似度与权重赋值成正比关系；最后根据阈值筛选出合适数据，完成迁移。在面对源域、目标域信息分布有较大差异时，基于实例的迁移学习并不适用，且权重的赋值与相似关系度量标准的挑选往往依赖经验。Chang'an Yi 等[41]提出一种基于多分量马氏距离的迁移度量学习策略，通过对源域样本内在特征的抽取，摒弃传统样本标签的束缚，实现了对具有不同属性的源域、目标域样本共性关系的判断，从而剔除了无关的源域信息。

（2）基于特征的迁移学习

通过对源域及目标域共有特征表示的识别，使得域间边缘概率分布差异减弱，从而可以进行基于特征的域间迁移，而根据共有特征辨别方法的不同，特征表示法的迁移学习可以分为两类：隐含表征学习法和概率分布适配法，其中隐含表征学习法可以通过传统的机器学习算法对源域进行分类等操作，并提取特征，将分类器无法识别的目标域特有信息看做领域独享特征，而源域、目标域的共有

中国知网 https://www.cnki.net

信息可作为共享特征，然后信息融合技术将独享、共享特征进行聚合，形成与领域无关的特征表示[42-44]；概率分布适配法则通常会将源域、目标域进行特征变换操作，学习新的特征表示，其中特征变换的形式可以是源域数据的降维，也可以是源域数据的特征提取，然后再利用适宜的度量准则，最小化域间的分布差异。许华等[45]提出一种并联残差的对抗性域适应迁移算法，通过源域信号的调制识别辅助目标域信号特征的训练，从而克服信号样本的差异性。

2.3 信号分解相关技术（Signal Decomposition）

负荷数据受多种因素制约，致使用户负荷时序数据在不同的时间尺度上波动性有明显差异，而在面临处理非平稳时序信号的问题时，常将复杂多变的非线性原始信号通过一系列技术手段，分解为若干个波动规律的简单信号分量，并通过对各个子序列信号分量特征的研究，减少随机扰动的影响，优化原始信号使用效率。Chaodong Fan 等[46]为了便于深度置信网络（Deep Belief Network, DBN）捕捉负荷数据的前后联系，利用经验模态分解（Empirical Mode Decomposition, EMD）对原始数据进行模态划分，并分别预测，同时利用多目标优化算法对 DBN 进行参数优化，从而增强了模型的泛化能力。龚承柱等[47]提出一种基于 EMD 分解后相空间重构的 LSSVM 短期燃气负荷预测模型，将分解后的各分量经相空间重构后，采用优化算法参数优化的 LSSVM 进行回归预测。邓翱等[48]通过对 EMD 分解后分量多元特征相关性的分析，实现了对时标特性的挖掘并去除了部分干扰，从而完成对电力负荷内在变化规律的寻找，构建更精准的预测模型。魏骜等[49]则采用层标准化后的 LSTM 作为 EMD 分解分量的预测模型。Chengliang Xu 等[50]将变分模态分解及集成学习知识应用于地源热泵的能耗预测中，并在不同步长预测中通过与基于 EMD 分解的预测模型的结果对比，验证了所提算法的鲁棒性更优。Jyotirmayee Naik 等[51]提出一种基于 VMD 分解的多核正则化伪逆神经网络，并利用水循环优化算法进行参数优化，以此实现更为高效的风能预测，为风电场规划及经营难题提供了解决方案。陈锦鹏等[52]将完全集合经验模态分解方法分解出的高频分量再次利用 VMD 方法进行分解，对平稳分量及非平稳分量分别采取多元线性回归及深度双向长短期记忆神经网络进行预测，从而建立了一个基于冷、热、电的综合能源系统多元负荷预测模型。牛安敏等[53]利用 VMD 分解的分量样本熵作为降低任务量技术，并与泄露积分型回声状态网络相结合应用于短期电力负荷的多步预测中。

本节将具体介绍研究内容框架中涉及到的变分模态分解法及其对比的经验模态分解法，为之后的章节中模型的构建提供理论依据。

中国知网 https://www.cnki.net

2.3.1 经验模态分解

区别于传统小波分析需要提前选定小波基，谐波基函数需要给予先验性假设等情况，经验模态分解（EMD）能够自适应的将原始时序信号分解为若干个近似正交的本征模态函数（Intrinsic Mode Function, IMF）[54, 55]，每一个 IMF 子序列分量都包含了被分解信号的时变模态，且均满足以下两个约束条件：

（1）在子序列数据中，极大值点与极小值点个数总和需要与过零点相同，或数量相差 1 个，即要求时序信号拥有传统平稳高斯过程的类似分布。

（2）在子序列任意时间点，信号的局部极大值确定的上包络线与局部极小值确定的下包络线均值为零，即要求信号局部基于时间轴对称，避免非对称信号的瞬时频率波动。

因此，时序数据需要满足极大值、极小值的存在，且相邻极值的时间间隔是特征时间尺度的决定因素。而不断寻找满足以上约束条件的 IMF 分量的过程，就是经验模态分解的分量求解步骤，基本步骤如下所示：

（1）通过对原始时序信号 x_t 的搜寻，将全部的局部极大值点和局部极小值点找出；

（2）对（1）中的局部极大值点、极小值点，利用三次样条插值的方法拟合形成信号的上包络线 $x_u(t)$ 及下包络线 $x_l(t)$，同时，计算上、下包络线的均值 $m_1=\left(x_u(t)+x_l(t)\right)/2$；

（3）从原始信号中减去均值，并验证 $h_1=x(t)-m_1$ 是否满足 IMF 的两个约束条件，假如条件满足就得到第一个模态函数 $IMF_{c1}=h_1$，并跳转至步骤（4）；否则，对 h_1 重复步骤（1）至（3），再次进行信号的筛分，直至第 k 次的重复后得到符合 IMF 约束条件的信号 h_{1k}，从而得到 $IMF_{c1}=h_{1k}$；

（4）从原始信号剥离出步骤（3）所得模态函数，就可以得到残留信号 $r_1=x(t)-IMF_{c_1}$。r_1 重复进行步骤（1）至步骤（4）操作，得到下一个分量 IMF_{c2}，以此类推，直至最终的残留信号残值低于预设的阈值，或者其成为单调线性信号则停止全部的分解流程。

经过上述步骤的 EMD 信号分解过程，原始时序数据 x_t 分解为 n 个 IMF 模态分量与一个残余分量：

$$x(t)=\sum_{i=1}^{n} IMF_{c_i}+r_n \tag{2-8}$$

式中，r_n 作为残余分量信号，一般是原始信号的平均整体走势及均值信息的反应。

尽管 EMD 分解法不会受小波基函数选择及分解等级的影响，但原始信号出现一段高频小幅值噪音时，会致使不同时间尺度的相邻模态函数波形混叠，并作为一个模态分量剥离出原始信号，从而产生模态混叠现象。而实际采集到的时序

中国知网 https://www.cnki.net

数据中多多少少都会掺杂噪声或者间断信号，为解决此问题，专家学者后续又提出了附加均匀白噪声的集合经验模态分解[56]（Ensemble Empirical Mode Decomposition, EEMD），以及对 EEMD 改进的互补集合经验模态分解[57]（Complementary Ensemble Empirical Mode Decomposition, CEEMD）等算法。

2.3.2 变分模态分解

变分模态分解（VMD）作为一种处理信号与模态变分的方法，具有自适应特性[58, 59]，其自适应性表现根据确定的模态函数个数，在之后的分量求解与搜索中完成每个模态函数最佳中心频率 ω_k 和有限带宽的自适应匹配，从而实现 IMF 分量的有效分离、信号的频域划分、进而得到原始时序信号的有效分解成分，从而求得变分问题的最优解。VMD 通过演进的数学理论推导，有效地克服了 EMD 方法中的端点效应和模态混叠[60]，完成从高复杂度和强非线性的非平稳时间序列，到多个不同频率尺度且相对平稳的子序列的转换。变分模态问题的模型构造和求解步骤如下：

（1）构造变分问题模型

约束变分模型实质是搜寻出使得所有分量带宽之和最小的 K 个 IMF 分量。首先，将原始的实际输入信号 $x(t)$ 分解为 K 个有限带宽的 IMF 离散分量 $u_k(t)$；接着，分量 $u_k(t)$ 经过 Hibert 变换求得解析信号，并逐一预估各分量中心频率 ω_k；然后，运用 L2 范数平方对信号带宽进行估算；最后，在满足各分量 $u_k(t)$ 之和与原始信号 $x(t)$ 相等的约束条件下，构造出变分条件模型：

$$\begin{cases} \min\limits_{\{u_k\},\{\omega_k\}} \left\{ \sum\limits_{k=1}^{K} \left\| \partial_t \left[\left(\delta(t) + \dfrac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \\ s.t. \sum\limits_{k=1}^{K} u_k = x(t) \end{cases} \tag{2-9}$$

式中：∂_t 是求函数的偏导；$\delta(t)$ 为单位脉冲函数；$\{u_k\}=\{u_1,u_2,...,u_k\}$；$\{\omega_k\}=\{\omega_1,\omega_2,...,\omega_k\}$。

（2）求解变分问题

为求解上述变分模型，需要在约束性变分问题中加入拉格朗日算子 $\lambda(t)$ 和二次惩罚因子 α，转化约束性问题为非约束变分问题，构成的拉格朗日表达式为：

$$\begin{aligned} &L\left(\{u_k\},\{\omega_k\},\lambda\right)= \\ &\alpha \sum_k \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \\ &\left\| x(t) - \sum_{k=1}^{K} u_k(t) \right\|_2^2 + \left\langle \lambda(t), x(t) - \sum_{k=1}^{K} u_k(t) \right\rangle \end{aligned} \tag{2-10}$$

中国知网 https://www.cnki.net

通过引入交替方向乘子算法（Alternate Direction Method of Multipliers，ADMM）来求解上述非约束变分问题的增广拉格朗日表达式中的“鞍点”，期间采用傅立叶等距映射变换得到频域表达式，并通过不断迭代更新$\left\{\hat{u}_k^{n+1}\right\}$，$\left\{\hat{\omega}_k^{n+1}\right\}$，$\hat{\lambda}^{n+1}$这三个变量完成“鞍点”的探寻，以下是更新表达式：

$$\hat{u}_k^{n+1}(\omega)=\frac{\hat{x}(\omega)-\sum_{i<k}\hat{u}_i^{n+1}(\omega)-\sum_{i<k}\hat{u}_i^{n}(\omega)+\frac{\hat{\lambda}^{n}(\omega)}{2}}{1+2\alpha(\omega-\omega_k^{n})^2} \tag{2-11}$$

$$\omega_k^{n+1}=\frac{\int_0^{\infty}\omega\left|\hat{u}_k^{n+1}(\omega)\right|^2 d\omega}{\int_0^{\infty}\left|\hat{u}_k^{n+1}(\omega)\right|^2 d\omega},k\in\{1,2,...,K\} \tag{2-12}$$

$$\hat{\lambda}^{n+1}(\omega)=\hat{\lambda}^{n}(\omega)+\tau\left[\hat{x}(\omega)-\sum_k\hat{u}_k^{n+1}(\omega)\right] \tag{2-13}$$

式中：n 为迭代次数；$\hat{u}_k^{n+1}(\omega)$，$\hat{x}(\omega)$，$\hat{\lambda}^{n+1}(\omega)$ 分别对应u_k^{n+1}，$x(t)$，λ^{n+1}的傅里叶变换；τ 为步长。

模型停止迭代循环的条件是不断更新的分量中心频率与带宽满足$\sum_k\left\|\hat{u}_k^{n+1}-\hat{u}_k^{n}\right\|_2^2\Big/\left\|\hat{u}_k^{n}\right\|_2^2<\varepsilon$，而后求解得到的$\{\hat{u}_k(\omega)\}$通过傅里叶逆变换，最终得到时域的 IMF 分量$u_k(t)$。

2.4 粒子群优化算法（Particle Swarm Optimization Algorithm）

粒子群优化算法（PSO）作为一种基于仿生的进化计算技术[61]，起源于对鸟群、鱼群捕食的行为研究。粒子群优化算法的主要思想是，通过集群中个体成员间的协作和信息共享来寻找最优路径从而得到到达最佳目标的过程，因此常用于求解较为简单的多目标参数优化问题。Saadat Bahrami 等[62]提出一种基于小波变化过滤高频分量和 PSO 优化生成系数的灰色电力负荷预测模型。Yusha Hu 等[63]将遗传算法（Genetic Algorithm，GA）与 PSO 相结合共同作用于 BP 神经网络的权值、阈值参数优化中，构造了一个针对造纸厂非线性实时生产电力负荷数据的混合预测模型。Kun Xie 等[64]则在电力系统的负荷预测中，利用 PSO 实现 Elman 的网络最优学习率搜寻，但该策略具有较高的计算代价。魏腾飞等[65]提出了基于 PSO 参数优化的长短期记忆神经网络电能预测算法，并采用非线性递减法作为惯性权重的更新方式，以此增强 PSO 算法的寻优能力，与此同时增加自适应变异从而避免陷入局部最优。陈鸿琳等[66]则将考虑气象因子的纵向建模与考虑日类型的横向建模相融合，并以基于 PSO 的广义回归神经网络作为组合预测的模型，从而简化了模型结构，有效地提高了预测精度。本节将对 PSO 的算法原理进行简要介绍，与实例结合的算法流程将于第四章详细阐述。

中国知网 https://www.cnki.net

粒子群优化问题看成鸟群四处寻找食物的过程，当鸟被抽象为质量、体积微乎其微的点，就可以把解空间不断寻优的粒子当做鸟，空间内的最优解便是鸟寻找的食物最终位置。第 i 个粒子在 N 维空间的位置为 $X_i=\left(x_{i,1},x_{i,2},...,x_{i,N}\right)$，速度则为 $V_i=\left(v_{i,1},v_{i,2},...,v_{i,N}\right)$，其中 N 是解向量的维度，且每个粒子在空间内搜索时都会根据目标函数所决定的适应度值，来不断地与曾到达过的历史最优点 $P_i=\left(p_{i,1},p_{i,2},...,p_{i,N}\right)$ 作比较，除此之外每个粒子也会同全体粒子发现的最优点 $P_g=\left(p_{g,1},p_{g,2},...,p_{g,N}\right)$ 对比，从而在自我经验和全体经验的协助下不断更新位置，即调整粒子位置 X_i 与速度 V_i 的值，直到满足最优解或迭代次数阈值条件。

粒子的速度及位置更新规则为：

$$v_{i,n}=\theta v_{i,n}+c_1 rand_1\left(p_{i,n}-x_{i,n}\right)+c_2 rand_2\left(p_{g,n}-x_{i,n}\right) \tag{2-14}$$

$$x_{i,n}=x_{i,n}+v_{i,n} \tag{2-15}$$

式中，θ 是惯性权重，且通常为非负数，用于调节粒子速度变化速率从而改变粒子的寻优性能；c_1、c_2 成为学习因子，代表自我认知与社会认知的置信程度，是影响适应度函数收敛速度的重要因素；$rand_1$、$rand_2$ 取 0 到 1 之间的随机数。

2.5 预测性能评价指标（Prediction Performance Evaluation Index）

在验证时序数据的预测准确性的时候，常用的误差度量评价指标有：均方误差（Mean Square Error，MSE）、均方根误差（Root Mean Square Error，RMSE）、平均绝对误差（Mean Absolute Error，MAE）、平均绝对百分比误差（Mean Absolute Percentage Error，MAPE），计算公式如下：

$$MSE=\frac{1}{m}\sum_{i=1}^{m}\left(\mathbf{x}_i-\tilde{\mathbf{x}}_i\right)^2 \tag{2-16}$$

$$RMSE=\sqrt{\frac{1}{m}\sum_{i=1}^{m}\left(\mathbf{x}_i-\tilde{\mathbf{x}}_i\right)^2} \tag{2-17}$$

$$MAE=\frac{1}{m}\sum_{i=1}^{m}\left|\mathbf{x}_i-\tilde{\mathbf{x}}_i\right| \tag{2-18}$$

$$MAPE=\frac{1}{m}\sum_{i=1}^{m}\left|\frac{\mathbf{x}_i-\tilde{\mathbf{x}}_i}{\mathbf{x}_i}\right|\times 100\% \tag{2-19}$$

其中：$\mathbf{x}_i$ 为待预测天第 i 个采样点负荷实际值；$\tilde{\mathbf{x}}_i$ 为第 i 个采样点负荷预测值；m 为预测的采样点总数。以上四个指标值范围均在 $[0,+\infty)$，且值越接近零，表明误差值越小，即所提模型的预测精度越高。

在上述的四种度量方法，从所列公式中可以看出，MAE、MSE、RMSE 依赖于所用数据的量纲，其中，RMSE 与 MAE 具有类似性质，但 RMSE 的极端值敏感度较 MAE、MSE 低，可用于评估绝对误差；MAPE 作为相对误差度量指标，独立于数据量纲，从而衡量预测值与真实值间的偏差，因此当时序数据为非负数

中国知网 https://www.cnki.net

时，可以选择 MAPE 作为模型预测性能评估指标，综上所述，本文选取 RMSE、MAPE 作为所提出的预测模型的性能评价指标。

2.6 本章小结（Conclusions）

本章阐述了关于本文负荷预测所涉及到的相关工作，包含 ELM、GRU 机器学习模型的介绍、迁移学习知识的分类、信号分解技术的说明、粒子群优化算法的简要讲解以及模型预测性能评估指标等内容。

通过第 1 章分析可知，针对综合能源系统中的新用户电力负荷预测问题，面临着因历史负荷样本数据量过少，而无法直接通过基于大数据的深度学习模型实现精准预测的情况；且系统中电力系统与热电联产系统、天然气管网等交叉耦合，多种影响因素共同作用，致使多元负荷互相制衡，因此通过提取共性特征来获取耦合关系是提升多元负荷预测精度的关键。鉴于此，结合第 2 章所述相关工作，第 3、4 章将针对小样本下的电力负荷预测及多元负荷预测分别开展研究工作。

中国知网 https://www.cnki.net

3 基于特征迁移学习的综合能源系统小样本日前电力负荷预测

3 Small-sample Day-ahead Power Load Forecasting of Integrated Energy System Based on Feature Transfer Learning

基于前两章对综合能源系统电力负荷特性分析可知，在进行日前负荷预测时，已有研究常利用统计分析等方法对造成负荷波动的关键特征进行剖析，结合天气、环境、节假日等信息，采用与传统电网负荷预测相似算法，通过寻找历史相似日数据，使用经典预测方法或智能预测方法，实现对综合能源系统电力负荷的预测。但已有的电力负荷预测研究通常在数据量充足的前提下进行，往往并不适用于仅有少样本数据的新用户预测，针对此，本章提出一种基于基于特征迁移学习的综合能源系统小样本日前电力负荷预测方法。

首先，对源域用户历史用能数据进行用能行为的聚类、划分，构造基于源域数据的分类与特征提取模型，并提取目标域用户数据的类别及特征信息；然后，利用特征间余弦相似度公式，设计基于时间遗忘因子的待预测目标域小样本特征融合机制，以相似特征为媒介采用迁移学习扩充目标域样本；最后，利用迁移样本集训练极限学习机预测模型，提升小样本电力负荷数据的预测精度。算法应用于卡迪夫某区域的真实电力负荷时序数据中，验证模型的可行性与有效性。

本章结构如下：3.1 节是章节研究背景的介绍，阐述算法的设计依据及主要研究内容；3.2 节基于特征迁移学习的综合能源系统小样本日前电力负荷预测的算法框架；后续两节是框架的详细解读，其中，3.3 节介绍基于 K-means 聚类的 GRU 隐特征提取步骤，3.4 节说明如何构造基于遗忘因子的特征融合迁移机制；3.5、3.6 节是算法基于卡迪夫某区域真实数据的两个算例分析；3.7 节是对本章算法预测性能的总结与结论。

3.1 研究背景（Backgrounds）

随着深度学习在各领域的成功应用，针对综合能源系统电力负荷的强波动性和随机性，利用深度学习提取负荷波动特征的负荷预测方法由于自身的强学习能力和非线性映射能力，引起了诸多关注。Jatin Bedi 等[67]根据历史数据，提出了基于长短期记忆（long Short-term Memory, LSTM）网络的算法框架，将数据聚类应用于原始数据以获得关于季节的分段数据，实现基于移动窗口的自适应预

中国知网 https://www.cnki.net

测；Wang Yi 等[68]提出一种基于弹球损失的 LSTM 回归概率负荷预测模型，通过结合 LSTM 与分位数回归的优势，增强了负荷动态行为特性的捕获能力；陆继翔等[69]提出使用卷积神经网络提取历史负荷数据、气象数据、日期信息以及峰谷电价等数据的特征，采用 LSTM 网络进行短期负荷预测，有效提高了预测精度；而 Junhong Kim 等[70]基于 GoogLeNet 提出了一种提升 LSTM 网络隐层状态向量可信度和预测精度的递归初始卷积神经网络，并通过实验验证了特征提取的有效性；Mengmeng Cai 等[71]对 Binkowski M 提出的双通道门控 CNN 预测模型进行多组改进，并在与季节性自回归算法和门控 RNN 模型的对比中确定了性能最优的 GCNN24 模型；Aleksandra Dedinec 等[72]考虑电价激励措施因素的影响，建立了 DBN 短期负荷预测模型；Fu[73]将经验模态分解（EMD）和 DBN 结合，对负荷序列进行分解与分层训练操作，削弱了不确定性对预测精度的影响；而岳有军等[74]针对 EMD 模态混叠的优化问题进行研究，提出了集成自适应噪声的完全集合经验模态分解、样本熵和 DBN 的短期负荷预测框架，进一步提升了预测精度。基于深度学习提取综合能源电力负荷波动特征的预测方法虽然可以提高综合能源系统电力负荷预测精度，但是，已有研究通常建立在大规模历史数据基础上[75-77]，对于新接入系统的用户端，在历史样本规模极小时（仅有一个月历史负荷数据甚至更少）难以适用，目前相关研究较少。

虽然针对新用户接入综合能源系统电力负荷日前预测的相关研究较少，但是，考虑特定情况下用户历史数据欠缺的负荷预测，已有部分利用迁移学习实现相关预测的工作[78]。张乔榆等[79]提出一种面向节假日的样本迁移策略，通过迁移与节假日相似的休息日数据构建相关因素矢量，实现节假日特征属性的标记，有效提高了假日预测精度。王毅星[80]提出利用迁移学习和最大均值差异从源域中迁移与典型负荷曲线相似的用户数据，用于提高预测模型的泛化性。Mauro Ribeiro 等[81]针对目标建筑物数据量不足的情况，建立了基于季节和趋势调整的时间序列多特征回归预测模型；Fanyue Qian 等[82]将负荷模拟与迁移学习相结合改进了全年建筑物冷、热负荷的预测；Cheng Fan 等[83]为了验证迁移学习在短期建筑能源预测中的价值，在不同的学习场景下多次实验来调查不同实施策略下迁移学习的潜力；Wen Huang 等[84]将灰色关联和模糊聚类应用于相似日负荷集合的构建，并采用层次分析法完成预测模型的整合，提高模型的整体精度；Yulan Shen 等[85]考虑模型的时效性，通过寻找相似日的方式实现数据约简，建立了一种基于粒子群优化和深度信念网络（PSO-DBN）的短期负荷预测方法；Liao Xiaoqun 等[86]则以相关系数特征图为基础，进行相似日负荷样本的采集，并采用 XGBoost 模型提升了预测框架的有效性。已有基于迁移学习弥补数据不足的研究均直接通过衡量数据相似性进行迁移，忽略了电力负荷波动隐含的关键特征因素，往往导

中国知网 https://www.cnki.net

致迁移数据的噪声含量大，带来负面迁移，反而会降低预测模型的准确性；此外，已有研究没有从新接入用户的角度考虑，不能简单适用。

综上所述，考虑深度学习在综合能源系统电力负荷日前预测时，可更好地处理其更强的波动性和随机性，但对于新接入用户历史数据不足难以适用，而已有基于数据的迁移学习忽略了电力负荷波动性和随机性特征且未针对新接入用户的问题，本章提出基于特征提取和迁移的日前负荷精准预测算法。算法采用门控循环单元（GRU）提取负荷数据波动的隐含特征并进行融合，利用该融合特征集进行源域的样本迁移，以克服现有基于数据迁移学习导致的负迁移问题；然后在获得可信度高的训练样本后，构建基于极限学习机的负荷预测模型，实现新用户小样本下的综合能源系统日前电力负荷的精准预测。为此，研究基于源域和目标域的负荷数据隐特征获取机制、基于特征的迁移学习，以及高效的负荷预测模型构建。为了获得负荷数据的隐含特征，本章首先将聚类和分类相结合，构建面向负荷时序数据分类的 GRU 模型，以提取其隐含特征；对于待预测目标域数据，利用上述模型进行分类和特征提取后，对同类数据的隐含特征进行融合，给出基于融合特征的特征迁移策略；基于迁移特征对应负荷数据，采用极限学习机（ELM）进行时序数据的快速拟合，实现对新用户小样本情况下日前电力负荷的精准预测。

3.2 算法框架（Algorithm Framework）

随着专家学者们对电力负荷预测问题的深入研究，如今已有诸多如回归预测、趋势外推、神经网络等一系列非常成熟的算法框架[87]，这些算法的核心思想是：根据待预测日的天气、季节、节假日类型等人为选择的参考特征，从历史负荷中选择与这些特征变化相近的相似日负荷样本，利用这些数据构建相应预测方法的模型。对于电力负荷小样本问题，基于相似日数据迁移的迁移学习是主要解决方法，其核心仍是基于人为选择的参考特征，确定相似数据，迁移该数据至小样本集合中，利用含有大量迁移样本的集成数据集构建预测模型。

本章针对新接入用户历史数据极少的情况，考虑综合能源电力负荷更强的波动性和随机性特征，从利用深度学习模型提取丰富的隐含特征以进行相似特征数据迁移的角度给出本章算法架构，包括三个主要模块，如图 3-1 所示，分别是基于 K-means 聚类的 GRU 隐特征提取，基于遗忘因子的特征融合迁移机制和基于特征迁移的 ELM 预测模型。其中第一部分实现对负荷时序数据内在特征的提取，第二部分给出基于特征融合的特征迁移学习，最后完成基于特征迁移的日前负荷精准预测。各模块具体内容将在下一节给出。

中国知网 https://www.cnki.net

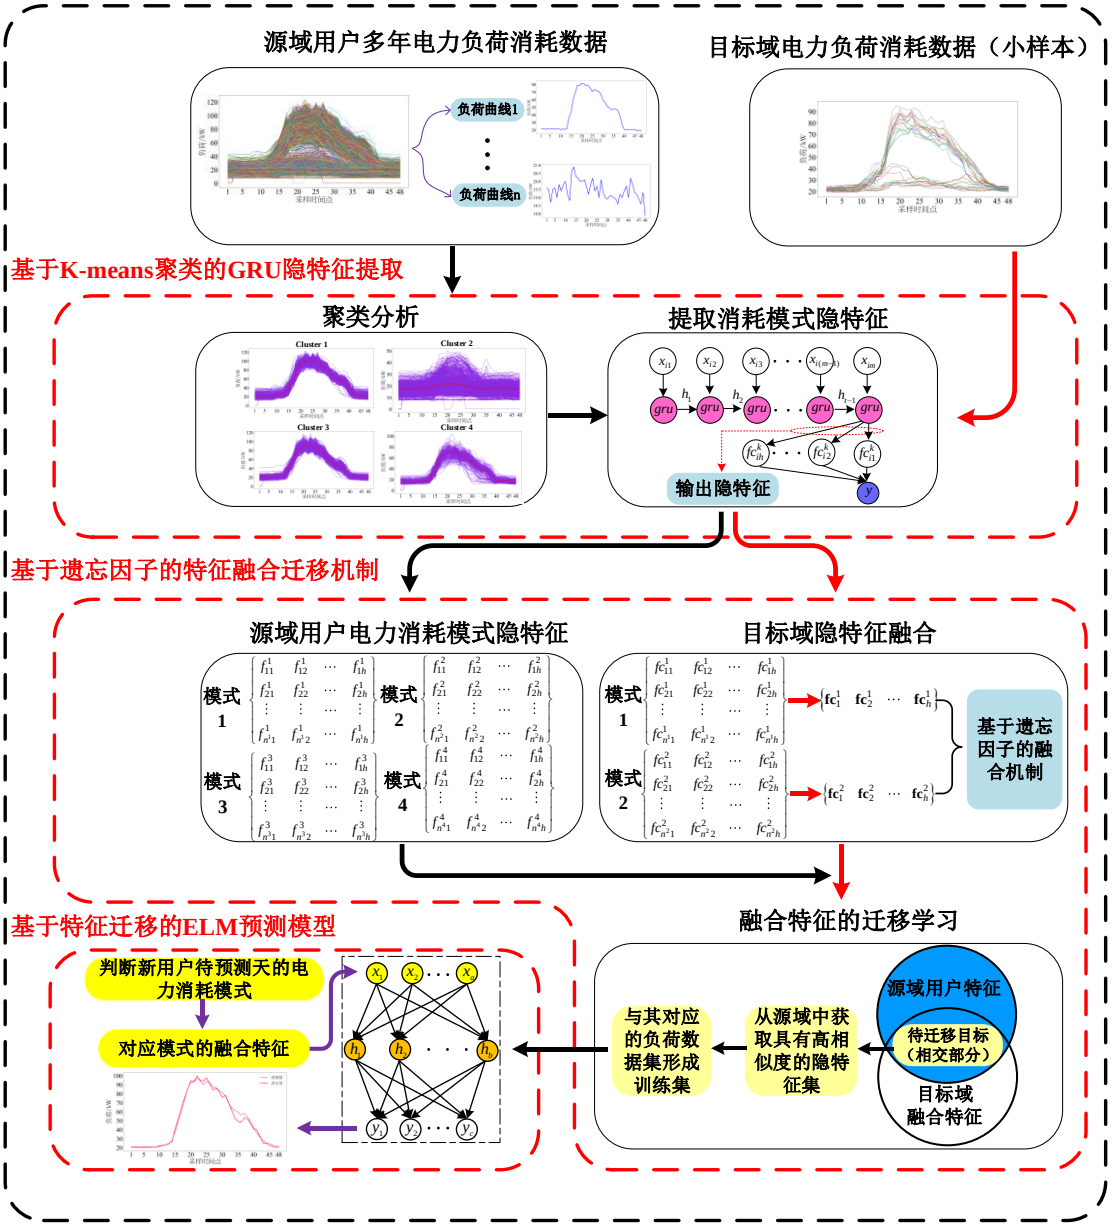


图 3-1 基于特征迁移学习的算法框架

Figure 3-1 Framework of the proposed algorithm

3.3 基于 K-means 聚类的 GRU 隐特征提取（GRU Hidden Feature Extraction Based on K-means Clustering）

用户负荷曲线为时序数据，其变化反映了用户的用能偏好以及前后相邻时间内的关联性，传统基于经验的人为特征筛选往往较主观，且所选择特征较粗略，难以体现隐藏在不同时间段内负荷数据变化的所有特征，而这些特征是负荷预测的关键因素。此外，当负荷数据严重不足时，选择具有相似隐含特征的时序数据对其进行扩充，将可有效避免传统迁移学习中的负样本问题，从而提高预测精度。为此，本章针对日负荷数据，提出一种基于 K-means 聚类和 GRU 时序数据分类模型的用户耗能行为隐特征提取策略。

中国知网 https://www.cnki.net

为了有效避免由于特征差异过大带来的负迁移，这里首先选择与目标域用户规模相近且用能相似的具有大量历史数据的用户作为源域，基于源域数据提取用能隐特征。借鉴深度学习进行特征提取然后再进行分类器构建的思路，当分类精度满足一定要求时，则分类器的输入即为提取的有效特征。电力负荷数据为时序数据，没有明显的类别标签，若采用分类策略提取其特征，则需首先添加类别标签。不难理解，对源域用户所有日负荷数据进行聚类，可获得具有明显类别差异的用能规律，然后为属于同一类变化特性的负荷数据添加相同标签，如记为类别1，2，3…，那么，电力负荷数据可转化为分类数据，进而可采用深度学习策略，设计基于该类别标签信息的 GRU 分类器，在分类器精度较高时，GRU 隐层单元的输出即为对应输入数据的特征。

记源域共有 n 天，每天 m 个数据采样点的日负荷曲线数据集为 $X_S=\left\{x_{ij}\,|\,i=1,2,...,n,\,j=1,2,...,m\right\}$，这里采用式（3-1）所示基于轮廓系数的 K-means 聚类策略，使用轮廓均值式（3-2）确定最优 K 值：

$$Sil(\mathbf{x}_{i.})=\frac{d_{\mathrm{ic}}(\mathbf{x}_{i.})-d_{\mathrm{in}}(\mathbf{x}_{i.})}{\max\{d_{\mathrm{ic}}(\mathbf{x}_{i.}),d_{\mathrm{in}}(\mathbf{x}_{i.})\}} \tag{3-1}$$

$$Sm=\frac{1}{n}\sum_{i=1}^{n}Sil(\mathbf{x}_{i.}) \tag{3-2}$$

其中：$d_{\mathrm{in}}(\mathbf{x}_{i.})$ 为第 i 天负荷数据 $\mathbf{x}_{i.}$ 到同类其他所有对象的平均距离；$d_{\mathrm{ic}}(\mathbf{x}_{i.})$ 为 $\mathbf{x}_{i.}$ 到其他类所有对象的平均距离的最小值；$Sm\in[-1,1]$，该值越大，表明类内距越小，类间距越大，聚类效果越好。最优聚类的类数选自 Sm 最大时对应的 K 值。

聚类后将 n 天数据分割为 K 类，设第 k 类有 n^k 个样本，其相应数据集为 $X_{\mathrm{S}}^{k}=\left\{\mathbf{x}_{i.}^{k}\,\middle|\,i=1,2,...,n^{k}\right\}$，此时将该类所有样本点的标签记为 k，那么，源域样本集则成为具有标签值的数据集 $X_{\mathrm{S}}=\left\{\left(\mathbf{x}_{i.}^{k},k\right)\middle|\,i=1,2,...,n,k=1,2,...,K\right\}$。基于该数据集，将各类每天的负荷数据输入 GRU 网络，对时序数据集进行分类，当分类测试精度较高时，则 GRU 网络的隐层节点输出即为隐特征，特征维度与隐层节点数相同记为 h。提取后第 k 类用电数据的隐特征集为 $F_{\mathrm{S}}^{k}=\left\{f_{ij}^{k}\,\middle|\,i=1,2,...,n^{k},\,j=1,2,...,h\right\}$。模型结构见图 3-1 中的“提取能源模式隐特征”，这里不再赘述。

3.4 基于遗忘因子的特征融合迁移机制（Feature Fusion Migration Mechanism Based on Forgetting Factor）

设目标域用户当前的小样本负荷数据集为 $X_{\mathrm{T}}=\left\{x_{ij}\,\middle|\,i=1,2,...,n_{\mathrm{T}},\,j=1,2,...,m\right\}$，这里假设 $n_{\mathrm{T}}\le 31$，即小样本数据。将 X_{T} 数据集的 $\mathbf{x}_{i.}$ 输入基于源域数据构建的 GRU 网络，则可获得该用户当前用电数据的

中国知网 https://www.cnki.net

隐特征，记为$F_{\mathrm{T}}=\left\{fc_{ij}\left|i=1,2,...,n_{\mathrm{T}},j=1,2,...,h\right.\right\}$，同时可得出$X_{\mathrm{T}}$的类别标签，为便于说明，记目标域第$k$类日负荷曲线数据集的特征集为$F_{\mathrm{T}}^{k}=\left\{fc_{ij}^{k}\left|i=1,2,...,n_{\mathrm{T}}^{k},j=1,2,...,h\right.\right\}$，$k$=1,2,…,$K$。其中，$n_{\mathrm{T}}^{k}$为目标域用户的第$k$类数据集规模，且依据用能日期排序。

进行负荷预测时，X_{T}所有数据均具有重要价值，但规模过小，为了提高模型训练精度，这里基于源域和目标域提取出的用户用电数据隐特征，给出一种基于目标域特征集成的迁移策略。X_{T}所有数据为时序数据，对于负荷预测，一般认为与当前待预测日期越近的数据价值越大。鉴于此，对于第k类特征集，该类最近日期的特征向量为$\mathbf{fc}_{n_{\mathrm{T}}^{k}}^{k}=\left\{fc_{n_{\mathrm{T}}^{k}j}^{k}\left|j=1,2,...,h\right.\right\}$，依据该特征向量，对用户各类特征融合，进而每类采用一个特征向量来表示，然后，从源域中迁移出与融合得到的各类特征向量相似的特征及其对应负荷数据。

首先，计算F_{T}^{k}中各特征$\mathbf{fc}_{i.}^{k}$与$\mathbf{fc}_{n_{\mathrm{T}}^{k}}^{k}$的余弦相似度$df_{i}^{k}$，如式（3-3）所示：

$$df_{i}^{k}=\frac{\sum_{j=1}^{h}fc_{ij}^{k}*fc_{n_{\mathrm{T}}^{k}j}^{k}}{\sqrt{\sum_{j=1}^{h}(fc_{ij}^{k})^{2}}*\sqrt{\sum_{j=1}^{h}(fc_{n_{\mathrm{T}}^{k}j}^{k})^{2}}} \tag{3-3}$$

余弦相似度越大，说明此负荷曲线特征与该类最近特征越相似，则其对特征融合贡献度越大。因此，基于上述余弦相似度，可得F_{T}^{k}融合特征向量为：

$$\mathbf{fc}^{k}=\frac{\sum_{i=1}^{n_{\mathrm{T}}^{k}}df_{i}^{k}\cdot\mathbf{fc}_{i.}^{k}}{\sum_{i=1}^{n_{\mathrm{T}}^{k}}df_{i}^{k}} \tag{3-4}$$

进一步的，考虑该类别中数据的时序关系，这里利用前 7 天数据，再次对其进行含时间遗忘因子的特征融合，如式（3-5）所示：

$$\mathbf{fc}_{\mathrm{F}}^{k}=\frac{(\sum_{i=1}^{7}s_{i}\cdot i/7\cdot\mathbf{fc}_{i.})+\mathbf{fc}^{k}}{(\sum_{i=1}^{7}s_{i}\cdot i/7)+1} \tag{3-5}$$

其中：$s_{i}\in\{0,1\}$，即当$\mathbf{fc}_{i.}\in F_{\mathrm{T}}^{k}$时，取值为 1，否则为 0。

最后，计算$\mathbf{fc}_{\mathrm{F}}^{k}$与源域特征集所有特征向量的余弦相似度，选择余弦大于设定阈值η_{t}的特征及其相应日负荷曲线数据，作为迁移对象，记为F_{Ts}与X_{Ts}。

中国知网 https://www.cnki.net

3.5 基于特征迁移的ELM预测模型（ELM Prediction Model Based on Feature Transfer）

记由 3.4 节获得的学习样本为 $X_{\mathrm{Tr}}=X_{\mathrm{T}}\cup X_{\mathrm{Ts}}$，其相应特征集合为 $F_{\mathrm{Tr}}=F_{\mathrm{T}}\cup F_{\mathrm{Ts}}$，采用 ELM 网络构建负荷预测模型，具体过程如下：

1） 确定输入输出以及网络结构：输入为特征集向量，输出为负荷集向量，则 ELM 网络输入节点数为 h（隐特征维度），输出节点数为 m（日负荷曲线采样点个数）。

2） 训练 ELM 网络：从学习样本集中随机选择 p 个样本作为训练集，其余为测试集；训练 ELM 网络，直至满足精度要求。

3） 负荷预测：根据新用户的小样本数据的聚类情况分析待预测日的电力消耗模式，将对应模式的融合特征 $\mathbf{fc}_{\mathrm{F}}^{k}$ 输入 ELM 模型，得到待预测天预测负荷值，完成预测。

3.6 算例分析（Experimental Analysis）

为了充分说明算法性能，将其应用于英国卡迪夫某区域综合能源系统的负荷预测中，考虑两类具有明显不同用能特征的负荷类型—高中和住宅。中学用能具有明显的节假日、季节等特性，且其用能高峰出现时段与住宅也明显不同，后续结合实验结果会给出具体分析。该实例提供了两所高中和两栋住宅楼的电力负荷数据，根据迁移学习源域和目标域应具有较高相似性，因此选择高中+高中，住宅楼+住宅楼的源域目标域方式。算例 1 中，高中 A 获得自 2012 年 4 月 2 日至 2018 年 12 月 31 日的历史电力日负荷数据，高中 B 为待预测小样本；算例 2 中，住宅楼 A 获得自 2014 年 7 月 3 日至 2018 年 12 月 31 日的历史电力日负荷数据，住宅楼 B 为待预测小样本。建筑日负荷采样点间隔均为半小时，因此每天有 48 个采样点数据，即 m=48。

3.6.1 算例 1—高中小样本预测

（一）基于轮廓均值的 K-means 聚类结果

为获取源域用户耗能模式的种类，首先采用 3.3 节方法对高中 A 的日负荷曲线进行聚类，选择类中心曲线作为典型日负荷的耗能模式，并进行详细分析。

首先，本章设定 K 值变化范围为 3 到 10，计算聚类的轮廓均值，以确定最优聚类数，结果如图 3-2 所示。由图 3-2 可知，K=4 时，轮廓均值最大，即聚类性能最优。相应的聚类结果如图 3-3 所示，类中心如图中虚线所示。将各类类中心曲线单独取出，结果如图 3-4 所示。

中国知网 https://www.cnki.net

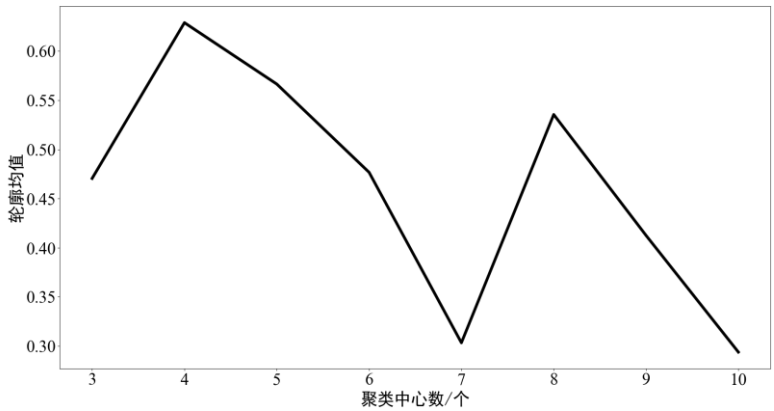
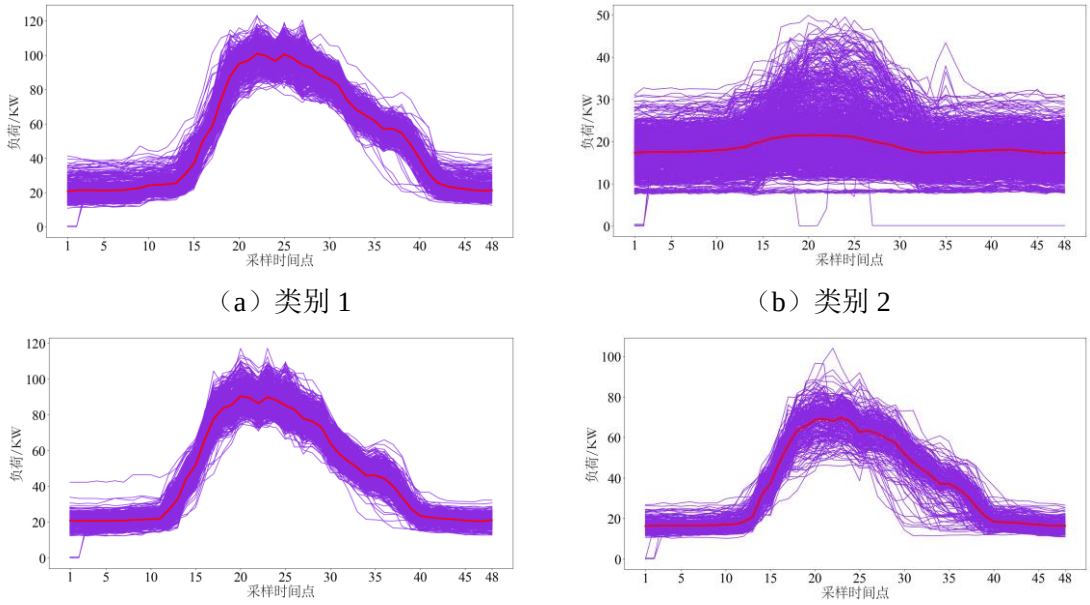


图 3-2 基于轮廓均值确定最优聚类数

Figure 3-2 Optimal clustering number based on silhouette-coefficient mean



（a）类别 1　　（b）类别 2

（c）类别 3　　（d）类别 4

图 3-3 日负荷曲线聚类结果

Figure 3-3 Clustering results of daily load curve

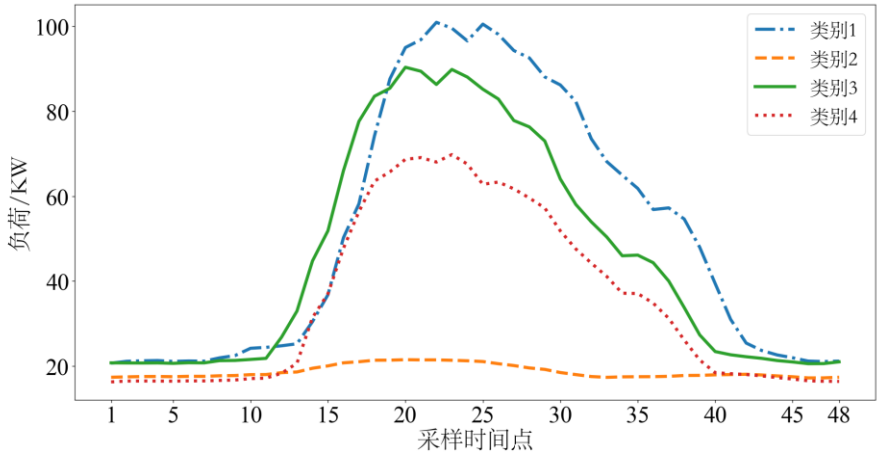


图 3-4 日负荷曲线聚类中心

Figure 3-4 Cluster centers of daily load curve

中国知网 https://www.cnki.net

从图 3-4 可以看出，所分析源域高中的负荷数据具有如下特点：（1）算例 1 集中于白天用电，日负荷峰值段分布在正午，且负荷曲线由中心向两侧按时间顺序呈递减趋势；（2）类型 1 有两峰一谷，峰值时间分别对应十点半与十二点，谷值时间为十一点半，整体负荷量较其他类别偏高；（3）类型 2 相较于另外三类波动幅度很小甚至无波动，而类型 3、4 的峰谷时间相同，且均较类型 1 提前一个小时，但是类型 3 比类型 4 耗能水平高；（4）进一步结合各类型负荷数据所属的年份、月份和工作日与否以及卡迪夫当地气候变化规律等信息，发现类型 1 多出现于较寒冷季节工作日，类型 2 则是节假日及周末的用电方式，类型 3、4 同属较温暖季节工作日，但所属年份不同。由上述分析可知，负荷具有不同的变化形式，进一步说明，依据简单的环境等特征迁移数据可能造成负迁移。

（二）基于 GRU 的隐特征提取

首先对源域高中 A 的 2012~2018 年日负荷数据进行归一化处理，然后从聚类后的数据集中分别选择 80 %的数据作为训练样本，训练单层 LSTM，双层 LSTM 和 GRU 网络，以说明本章选择 GRU 网络的合理性。网络结构参数设置如下：输入层节点数为日负荷曲线的采样点个数 48，隐含层节点数设为 15，输出层节点数由最终选定的聚类数 K 确定，这里为 4，学习率设定为 0.001，迭代 500 次。三类网络训练时间、损失函数（Loss）值，以及分类精度如表 3-1 所示。

表 3-1 三种模型性能对比

Table 3-1 Performance comparison of three models

网络	训练时间，min	Loss 值	分类精度，%
单层 LSTM	39.6	0.021	98.25
双层 LSTM	34.7	0.019	98.26
单层 GRU	22.5	0.023	98.29

由表 3-1 可知，三类网络分类精度和损失函数（Loss）值相近，但是 GRU 网络训练速度最快，可有效提高负荷预测的效率，因此，这里选择 GRU 网络进行特征提取是合理的。

（三） 多场景预测结果分析

为了充分说明本章所提基于特征迁移学习的预测算法的有效性，结合（一）中的实验结果，这里从高中 B 随机选择了 4 个月的数据，分别是：2018 年 11 月 4 日至 12 月 4 日（**I**）、2015 年 6 月 13 日至 7 月 13 日（**II**）、2013 年 5 月 18 日至 6 月 18 日（**III**），以及 2016 年 7 月 29 日至 2016 年 8 月 29 日（**IV**）各一个月的数据，分别针对这些数据预测其后续一日的电力负荷。

基于上述数据，首先分析这些数据 K-means 聚类和 GRU 分类结果的一致性，以进一步说明基于上述策略提取的目标域特征的可靠性；然后给出各场景下特征迁移后所获得的样本规模；最后比较本章算法分别利用式（3-5）和式（3-4）两

中国知网 https://www.cnki.net

种特征融合的迁移学习（**方法 1**，**方法 2**）、传统基于相似月份数据迁移的 GRU（**方法 3**）和 ELM（**方法 4**）算法，以及无数据迁移的 GRU（**方法 5**）和 ELM（**方法 6**）的预测结果，比较其 MAPE 和 RMSE 值，以说明本章算法预测的精准性。

1）上述四个月数据进行 K-means 聚类和基于 GRU 分类的实验结果如表 3-2 所示，其中，“待预测前日聚类/分类”指待预测日前一日数据的特性，该数据特征将对待预测日产生较大影响，因此，这里特别给出其特性。“分类准确率”为基于聚类结果的对比，统计分类和聚类数据完全一致的比例。

表 3-2 目标域聚类/分类效果

Table 3-2 Clustering/Classification comparison

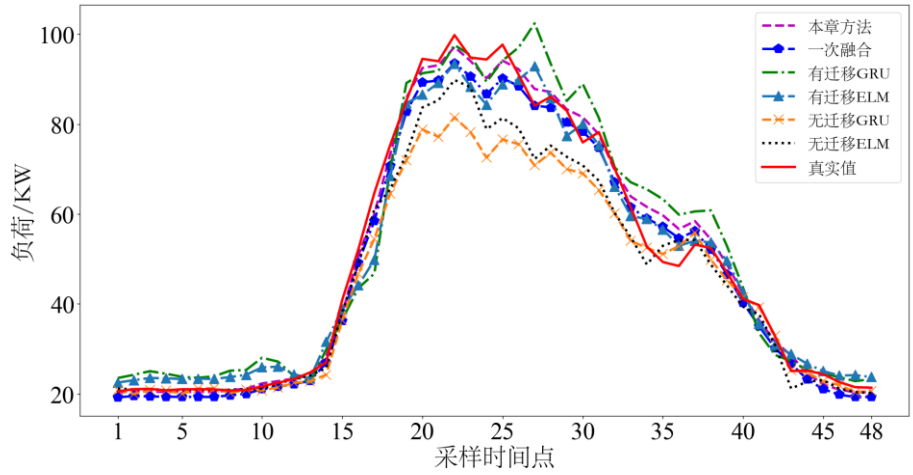
预测数据	*K*=4 时轮廓均值	待预测前日聚类	待预测前日分类	分类准确率
I	0.82	类型 1	类型 1	83.3%（25/30）
II	0.94	类型 3	类型 3	90%（27/30）
III	0.92	类型 4	类型 4	90.3%（28/31）
IV	1	类型 2	类型 2	100%（31/31）

由表 3-2 可知：（1）对于随机选择的 4 个月份的数据，在 *K*=4 时，其聚类轮廓均值皆较大，表明聚类效果优良；（2）待预测前日的聚类和分类结果一致，且分类与聚类数据的对比即分类准确率较高，说明基于源域构建的聚类和分类模型，对于目标域具有良好的适用性；（3）分类准确率较高，保证了基于分类的特征提取的可靠性，因此，基于 GRU 模型提取目标域特征是可行的。

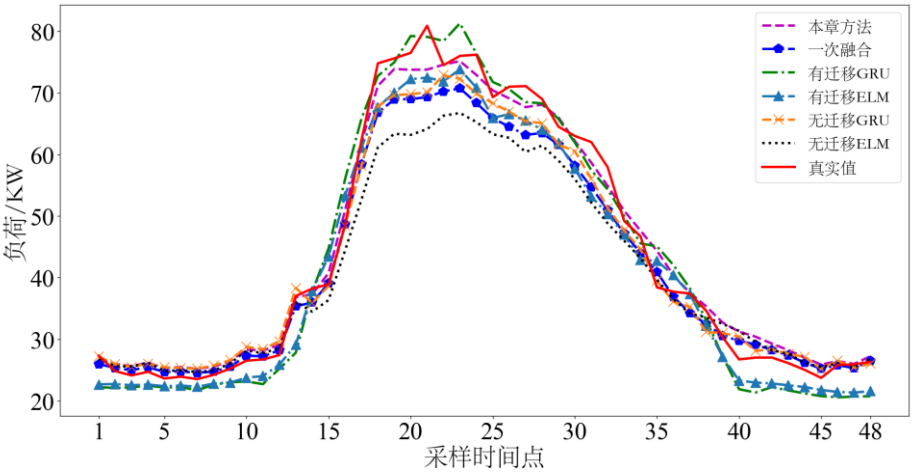
2）上述四个数据集，采用式（3-5）所示策略进行特征融合、迁移，余弦相似度阈值设定为 0.99，则四个数据集相应的迁移样本规模分别为 1344，805，421 和 943。

3）在此基础上，比较 6 种算法的预测结果。方法 3 至方法 6 均采用滑动窗口模式进行预测，这里设定时窗窗口长度为 7，即利用前 7 天的历史日负荷数据预测第 8 天，迭代循环；本章所提方法 1 和基于式（3-4）的方法 2，在进行预测时，以融合特征作为输入，网络输出为预测结果。算法预测日所得数据曲线如图 3-5 所示，其具体 MAPE 和 RMSE 结果如表 3-3 所示。

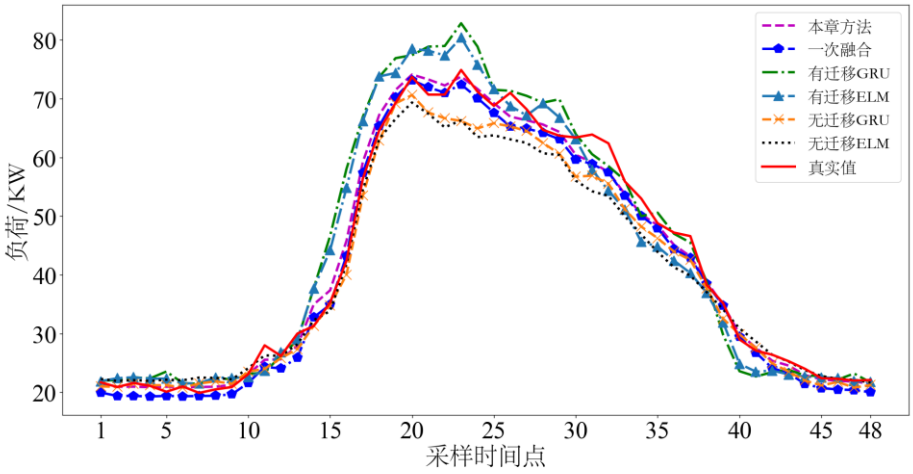
中国知网 https://www.cnki.net



（a）数据集 I 预测结果

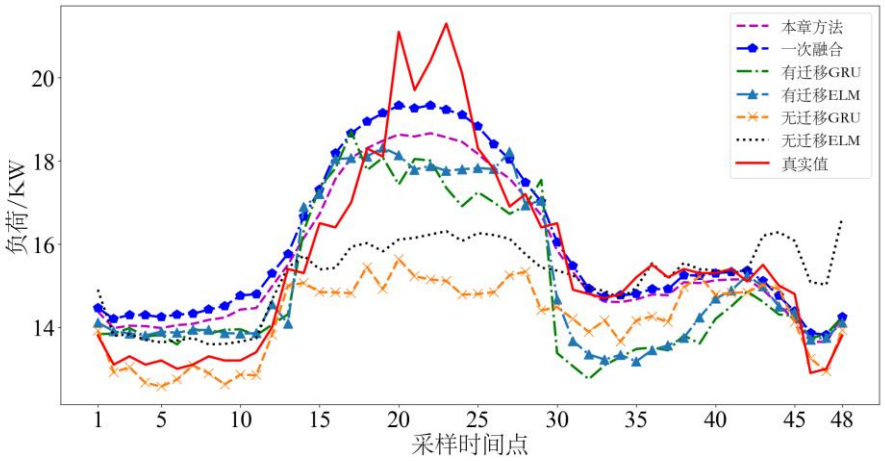


（b）数据集 II 预测结果



（c）数据集 III 预测结果

中国知网 https://www.cnki.net



（d）数据集 IV 预测结果

图 3-5 四种场景下负荷预测结果对比

Figure 3-5 Comparisons of load forecasting in four scenarios

表 3-3 6 种预测算法精度比较

Table 3-3 Forecasting accuracy of six methods

		本章方法	方法 2	方法 3	方法 4	方法 5	方法 6
I	MAPE	**4.49**	6.34	11.61	8.85	8.24	7.03
	RMSE	**3.10**	3.53	6.56	4.85	8.76	6.51
II	MAPE	**4.98**	5.57	9.22	9.05	5.75	8.26
	RMSE	**2.35**	4.02	3.74	4.17	3.45	6.09
III	MAPE	**3.38**	5.17	8.28	8.35	5.27	6.17
	RMSE	**1.95**	2.27	4.98	4.69	3.25	4.08
IV	MAPE	**4.43**	5.12	7.32	6.59	7.90	7.00
	RMSE	**0.90**	0.95	1.49	1.31	2.13	1.75

由图 3-5 和表 3-3 可知：

1）除场景 IV 外，本章所提算法与待预测日真实数据拟合度最高；

2）场景 IV 较其他场景属于低耗能水平，且节假日负荷峰值有更大的不确定性，因此，本章所提方法在场景 IV 拟合度有偏差且集中在峰值段，但是，结合表 3-3 最后两行数据可知，本章方法仍明显优于其他方法；

3）对于 4 种场景下的预测，本章所提算法的 MAPE 均未超过 5%，即本章所提算法精度不低于 95%，特别是对于场景 III，本章算法精度为 96.62%，比其他有数据迁移的 GRU（方法 3）和 ELM（方法 4）高出 4.90%和 4.97%；

4）比较本章方法和方法 2，即基于式（3-5）和式（3-4）两种特征融合的特征迁移和预测，发现方法 2 适用于对预测精度要求稍低的情况，同时考虑特征相似性和时间遗忘因子融合策略的算法预测精度更高；

5）比较基于传统相似日数据迁移策略，其用于 GRU 和 ELM 网络的拟合精度均相对较低，进一步说明传统数据迁移极有可能引入负迁移，从而影响负荷预测的精度。

中国知网 https://www.cnki.net

3.6.2 算例 2—住宅楼小样本预测

（一） 基于轮廓均值的 K-means 聚类结果

首先，同样采用 3.3 节方法对住宅楼 A 的日负荷曲线进行聚类，聚类的轮廓均值如图 3-6 所示，当 K=2 时均值最大，聚类效果如图 3-7，类中心曲线如图 3-8 所示。

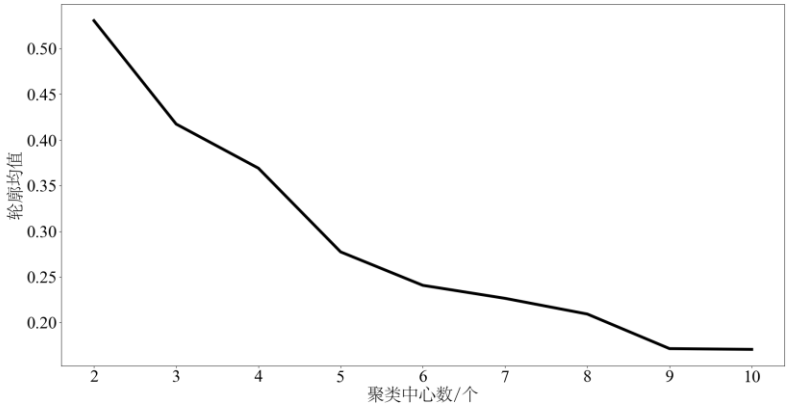
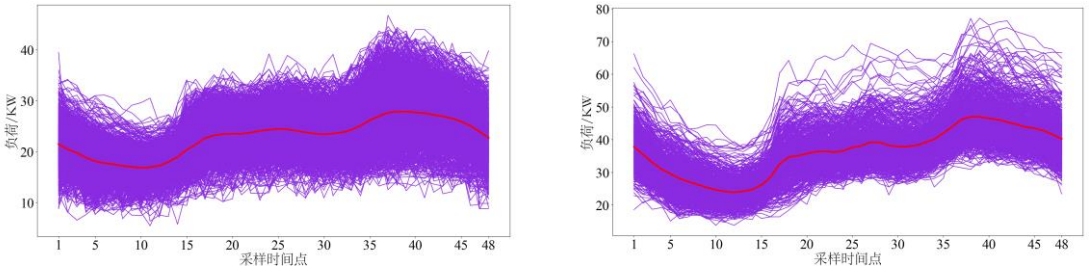


图 3-6 基于轮廓均值确定最优聚类数

Figure 3-6 Optimal clustering number based on silhouette-coefficient mean



（a） 类别 1　　（b） 类别 2

图 3-7 日负荷曲线聚类结果

Figure 3-7 Clustering results of daily load curve

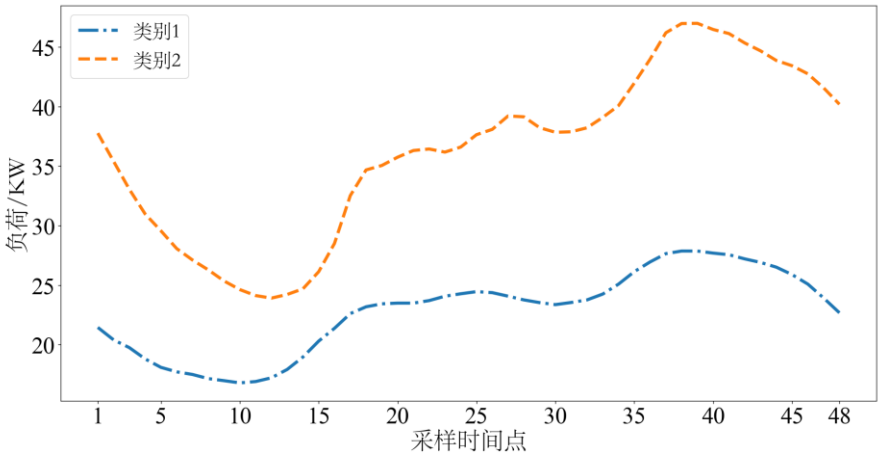


图 3-8 日负荷曲线聚类中心

Figure 3-8 Cluster centers of daily load curve

从图 3-8 可以看出，所分析源域的负荷数据具有如下特点：（1）类型 2 不

中国知网 https://www.cnki.net

仅日平均负荷明显高于类型 1，且负荷波动同样较大。（2）与算例 1 不同，算例 2 主要有两类具有明显不同的用能数据组成，日负荷峰值段分布在傍晚。算例 1 整体呈现单峰趋势，且峰值集中在正午时段，傍晚至次日凌晨耗能水平降至最低且平稳，所以算例 1 高中的建筑使用特性是聚焦于白天的学习、工作，属于公共建筑；算例 2 整体较平稳，峰值集中在傍晚时段，傍晚至次日凌晨耗能水平呈下降趋势，所以算例 2 住宅楼的建筑使用特性是解决日常的生活与休息，属于居住建筑，两者具有较大的差异性。

（二） 多场景预测结果分析

从住宅楼 B 随机选择了 2 个月的数据，分别是：2017 年 7 月 13 日至 8 月 13 日（**I**）、2016 年 4 月 17 日至 5 月 17 日（**II**）各一个月的数据，分别针对这些数据预测其后续一日的电力负荷。

1）上述两个月数据进行 K-means 聚类和基于 GRU 分类的实验结果如表 3-4 所示。

表 3-4 目标域聚类/分类效果

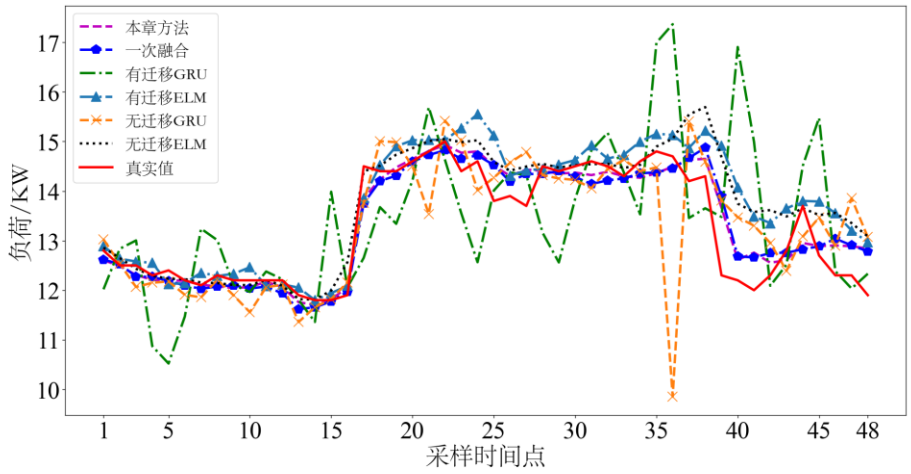
Table 3-4 Clustering/Classification comparison

预测数据	*K*=2 时轮廓均值	待预测前日聚类	待预测前日分类	分类准确率
I	——	类型 1	类型 1	100%（31/31）
II	——	类型 1	类型 1	100%（30/30）

由表 3-4 发现：对于随机选择的 2 个月份的数据，在 *K*=2 时，其聚类轮廓均值均无法求得，由式（3-1）的定义可知所选择月份负荷数据的聚类结果为单类型，也意味着目标域用户在长时间内耗能模式保持不变。

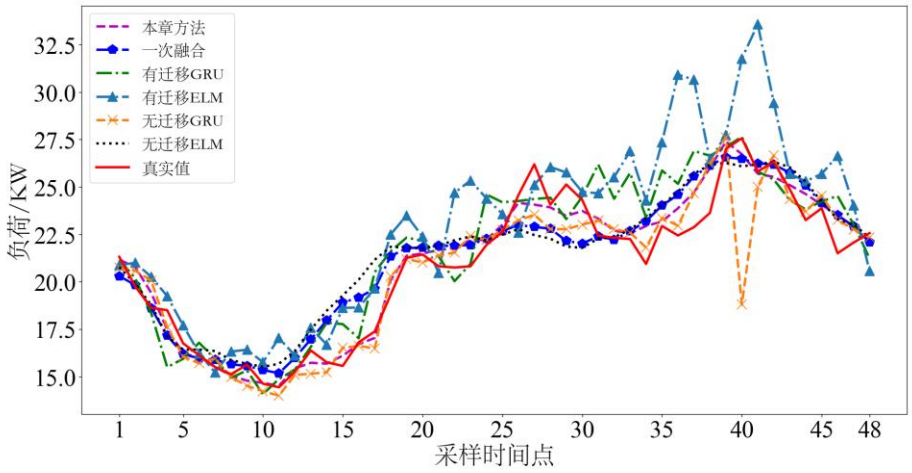
2）上述两个数据集，采用式（3-5）所示策略进行特征融合、迁移，余弦相似度阈值同样设定为 0.99，则两个数据集相应的迁移样本规模分别为 401 和 307。

3）与 3.6.1 节（三）相同，比较 6 种算法的预测结果，算法预测日所得数据曲线如图 3-9 所示，其具体 MAPE 和 RMSE 结果如表 3-5 所示。



（a）数据集 I 预测结果

中国知网 https://www.cnki.net



（b）数据集 II 预测结果

图 3-9 两种场景下负荷预测结果对比

Figure 3-9 Comparisons of load forecasting in two scenarios

表 3-5 6 种预测算法精度比较

Table 3-5 Forecasting accuracy of six methods

		本章方法	方法 2	方法 3	方法 4	方法 5	方法 6
I	MAPE	**2.18**	2.42	7.28	3.96	4.56	3.50
	RMSE	**0.40**	0.44	1.35	0.75	0.96	0.71
II	MAPE	**3.18**	5.58	6.21	11.03	4.55	6.64
	RMSE	**0.93**	1.48	1.74	3.04	1.63	1.73

由图 3-9 和表 3-5 可知：

1）对于住宅楼 2 种场景下的预测，本章所提算法与待预测日真实数据拟合度都为最高，且 MAPE 值均未超过 4%；

2）从场景 II 的对比中可知，在方法 2 预测精度表现不佳时，本章所提算法仍能保持高精度，证实了含时间遗忘因子的二次特征融合算法的稳定性；

3）如图 3-9 所示，目标域两种场景下的用户耗能模式明显属于不同类别，表 3-4 则显示两种场景属同一类，即目标域样本全部且仅属于源域样本中的某一类，结合实验结果分析可推得，目标域与源域年平均负荷有较大差距但用电行为相似，表明综合能源系统中功能相似的用能个体之间相似性与差异性并存，而实验结果表明所提算法可以很好的避开具有相似功能属性的个体间的差异性给预测结果带来的影响。

综合算例 1 和算例 2 结论可得：采用基于聚类的 GRU 特征提取机制可有效提取用户在不同时段的负荷变化特征；对目标域用户小样本数据进行分类后的特征融合，并基于该融合特征选择迁移数据的策略，有利于减少负迁移的影响，从图 3-4 与图 3-8、图 3-5 与图 3-9 的对比中不难看出，选择具有相似功能属性用能个体进行特征迁移是合理的，若将住宅数据迁移到高中，则意味着将具有明显 2

中国知网 https://www.cnki.net

类用能特性的数据迁移到 4 类用户中，根据迁移学习的研究结果，则极有可能带来负迁移；基于本章所提含时间遗忘因子的特征融合的负荷预测，可有效提高预测精度，说明了本章算法可有效解决小样本综合能源系统负荷日前预测问题。

3.7 本章小结（Conclusions）

针对综合能源系统新增用户仅拥有短周期历史负荷数据，难以进行精准负荷预测，本章提出一种基于特征迁移学习的小样本日前电力负荷预测方法。基于聚类方法，将源域用户负荷数据进行聚类，并采用聚类结果为其添加类别标签；进一步利用源域含标签分类数据，训练 GRU 神经网络，提取源域用户在各不同用电时段的特征，并将该模型应用于目标域小样本中，确定其类别和特征；对各类特征采用含时间遗忘因子的二次融合，然后，基于该融合特征实现特征迁移，并完成预测模型的构建。算法在卡迪夫某综合区域能源系统多所建筑的用电负荷日前预测中的应用证明了其有效性。所提算法并不局限于单个源域场景，可以推广至与新增用户即目标域用户具有相似功能属性的多个源域中应用，但并不适用于处理目标域与源域功能具有较大差异的情况；与此同时，本章所提算法，仅针对综合能源系统中的电力系统部分进行建模研究，还没有开展系统的多能预测问题研究。鉴于此，第 4 章将结合耦合关系进一步研究综合能源系统中的小样本多元负荷预测问题。

中国知网 https://www.cnki.net

4 基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测

4 Small-sample Day-ahead Multiple Source Load Forecasting of Integrated Energy System Based on Coupling Relation Mining

第 3 章给出了一种基于特征迁移学习的综合能源系统小样本日前电力负荷预测策略，在一定程度上提高了用户的负荷预测精度，然而该算法仅涉及到系统中电力负荷小样本数据的预测工作，并没有深入至多元数据预测问题的解决。不同于解决单一能耗的预测问题，在面对小样本多元数据预测情况时，既要考虑如何高效地处理非线性小样本数据的波动性，也要思考在多元数据特征识别度不一致时，是否可以通过负荷间耦合关系的挖掘来提高小样本多元综合预测精度。鉴于此，本章在第 3 章的研究背景及理论基础之上，深入开展系统中小样本用户多元数据间联系的探寻，提出一种基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测方法。

首先，将用户的小样本（仅有一个月甚至更少）历史多元非平稳数据进行 VMD 模态分解，其中所需指定的模态函数 K 及惩罚函数 α 值由 PSO 进化算法寻优确定，从而确保获得若干个平稳的时序模态分量，降低噪声的干扰与建模难度；然后，基于各分量瞬时频率构造耦合关系判定机制，通过求得多元数据分量间的耦合关系，挖掘出用户用能消耗间共有分量，并构建共有分量及剩余分量组合预测模型，最终完成预测；最后，在真实的综合能源系统数据集中进行算法性能测试并对结果进行分析，以验证本章节所提方法的有效性及优越性。

本章结构如下所示：4.1 节为本章节研究背景工作，着重介绍章节的主要研究工作内容；4.2 节介绍综合能源系统小样本日前多元负荷预测方法的算法整体框架；4.3 节为算法框架中基于 PSO 的 VMD 负荷分解的内容解读；4.4 节进一步陈述了在框架中将如何基于迟滞因子瞬时频率进行耦合关系的挖掘，给出了最终预测方案；4.5 节是所提算法应用于奥斯丁算例的实验结果分析，并于末尾给出本章节结论。

4.1 研究背景（Backgrounds）

综合能源系统框架以电力系统为主[88]，天然气网络、冷热管网等为辅，同时配置大量分布式能量采集、储存装置，区域可使用的能源种类众多[89, 90]，第 3

中国知网 https://www.cnki.net

章给出了在综合能源系统中电力负荷数据样本量较少情况下如何提升预测精度的处理策略，该算法的提出主要是为了扩充新增小样本用户数据量，便于从先验知识中获取整体变化趋势，达到增强新增用户负荷预测精度的目的。首先通过对源域数据的聚类提取出用户每类用能方式的隐特征，然后依据隐特征相似性利用迁移学习知识对目标域用户仅有的小样本历史负荷数据进行扩充，从而为目标域用户提供了负荷趋势借鉴，最后利用极限学习机完成预测任务。梳理第 3 章所提模型的流程，发现算法面临如下问题的解决：

（1）第 3 章仅仅涉及了综合能源系统下电负荷这一单品种能源的预测问题，没有考虑系统内其他种类能源的消耗，间接性的忽略了用户用能间的耦合作用，尽管电力系统仍是综合能源系统的主要供能单元，但日趋成熟的热网、天然气管网并网研究，风能、太阳能等清洁能源的延伸利用，使得用户可挑选的能源消耗方式越来越多，除电能外的供能方式势必会崛起，他能的供给对需求侧的影响也会日益加深，因此非但不能忽略多元间耦合对电力负荷预测精度的影响，更要着眼于如何挖掘综合能源系统中耦合关系，从而深度把握需求侧用能行为规律，协调系统能流分配，促进系统优化模型的发展，而多元间耦合关系的应用逐渐成为综合能源系统多元负荷预测关注的焦点。张涌新等[91]针对区域综合能源内多元负荷特性问题，制定不同负荷间的关联度指标评价标准从而得到其间关联规律，然后利用关联规律优化单独负荷预测，有效地增强了拥有多元用能数据系统的可预测性；赵峰等[92]为了可以更充分地发现冷热电负荷内在演化规律，通过结合混沌理论与 C-C 方法将多变量时间序列进行了相空间重构，并使用状态空间为相变量的卡尔曼滤波器自回归模型作为预测端；Bin Zhou 等[93]通过建立层次聚类框架构建了一个基于深度信念网络的综合能源净负荷预测模型；史佳琪等[94]将含有有效抽取隐含特征优势的 DBN 与多任务权值共享学习机制相结合，利用发掘出的不同能流间的转换特点及共享信息，对多元负荷进行多任务回归预测，并通过与单任务、有无监督学习等试验结果的对比展现该算法的优越性；Zhongfu Tan 等[95]将多任务学习与最小二乘支持向量机相结合，构建了蕴含多元负荷两两间耦合关系的综合预测模型；朱瑞金等[96]利用卷积神经网络作为编码器提取包含历史天然气负荷等输入变量的隐特征，再利用长短期记忆网络作为解码器映射，从而提出一种基于自动编码器的考虑天然气因素影响的电负荷预测模型；陈飞翔等[97]将影响建筑冷热负荷预测的因素划分为固定不变的自有属性与实时变动的运行属性，并以运行属性为基准，自有属性为修正，利用主元解耦简化两者复杂的耦合关系，最后实现典型建筑冷热负荷的快速预测；Shaomin Wang 等[98]考虑多元负荷间交叉耦合特性，提出利用耦合特征矩阵训练一个集编解码特征提取模型与梯度提升决策树于一体的预测模型。

中国知网 https://www.cnki.net

（2）另外，第 3 章在面对综合能源系统小样本日前电力负荷预测问题时，认为单一的短周期电力负荷非线性、不稳定数据，对未来趋势的把握不够，因此采用迁移学习的相关知识，在综合能源系统中借鉴其他具有相似属性的用户数据，并构建了一种基于遗忘因子的特征融合机制，从而使目标域小样本用户数据得以扩充，最终实现电力负荷预测精度的提升。但迁移策略的实现，需要源域与目标域的协同合作，即源域用户的用能行为、用能习惯要尽可能地与目标域用户相似，因此源域数据的准确获取是迁移策略奏效的关键，但因源域、目标域个性化差异而可能存在或多或少的误导性信息。为了尽可能地避免其他用户的影响，可以考虑将自身非线性、不平稳的多元时序数据进行信号分解，以削弱原始信号不确定性，降低预测难度，从而实现数据的充分利用，不再受限于其他数据。赵凤展等[99]利用变分模态分解将含波动细节的电力时序数据划分为具有更优规律性的变化特性各异的子序列，削弱了原始信号的非线性影响，并采用基于蝙蝠参数寻优算法的 LSSVM 模型进行预测；Yuanyuan Wang 等[100]提出利用自适应变分模态分解方法求解电力负荷的趋势分量及其他子序列，分别采用线性回归和 XGBoost 回归训练预测模型，并通过爱尔兰实例的验证验证了该综合预测方法的优越性能；刘强等[101] 将互补总体经验模态分解与随机森林相结合，并通过合并相似分量减少模型复杂度，建立了短期风电功率预测模型；Mohamed El-Hendawia 等[102]则采用小波变换分解与神经网络相集成的方式，对加拿大安大略省电力市场进行负荷预测；Zhenhai Guo 等[103]构造了一个基于经验模态分解的前馈神经网络风速预测模型，模型利用自相关系数来选择合适子序列作为输入变量，削弱残差等噪声序列的影响，有效地提高了强波动性风速序列的预测精度；邓带雨等[104]提出了基于 EEMD 分解、GRU 神经网络及多元线性回归的电力负荷预测模型构建方法，用于解决高频分量较多、周期性较弱的预测问题；Xueheng Qiu 等[105]针对短期电力负荷预测问题，提出了一种融合离散小波变换、EMD 分解以及随机矢量功能链接网络的混合增量学习策略，提高了预测的准确率与效率。

综上所述，在处理综合能源系统综合用能问题，面对多元负荷数据不足即小样本情况时，可以将原始信号通过降噪、模态分解等手段使其变得平稳，从而降低数据不足带来的波动性与不确定性；然后，依据用户自身短周期内多元间相互作用，探寻能流间的耦合关系，寻找用户用能行为下的多元负荷共性，从而提取出共有分量加强多元数据间联系，促进剩余特有分量与共有分量形成优势互补，提升整体预测精度。上述两点是综合能源系统小样本综合用能预测亟待解决的要点，为此，本章提出了对应的解决办法与策略，具体来说，首先，以中心频率修正的包络熵为目标函数，利用粒子群进化优化算法求得 VMD 模态函数 K 值及惩罚函数 α 值，从而采用 VMD 方法对多元负荷时序数据分别进行处理，生成多元

中国知网 https://www.cnki.net

数据的子序列模态分量集合，更彻底的开发小样本数据的潜能；然后，以分解出的分量瞬时频率为基础，构建多元分量间耦合关系判断公式，从而剥离共有分量与剩余特有分量；最后，利用 GRU 神经网络对共有分量模块及特有分量模块分别进行日前负荷预测，并将各分量的预测数值进行累加求和，获得最终预测结果。

4.2 算法框架（Algorithm Framework）

为克服综合能源系统新接入的小样本用户多元数据不足而导致的预测精度低或无法预测问题，考虑现有的曲线特征成分提取方法，降低序列非线性的影响，同时利用基于挖掘综合能源系统中用户电、热等多元数据间耦合关系的预测方法给出本章算法框架，框架三个模块分别为基于 PSO 的 VMD 负荷分解，基于迟滞因子瞬时频率的耦合关系挖掘和基于耦合关系的 GRU 预测模型。首先，采用 VMD 分解方法将特征复杂的多元序列分解为特征相对单一的子序列，实现负荷模态划分，然后分析多元模态子序列数据的具体特征得到多元数据间耦合关系，最后采用 GRU 模型分别对耦合共有分量及剩余分量进行分步预测。模型框图如图 4-1 所示。

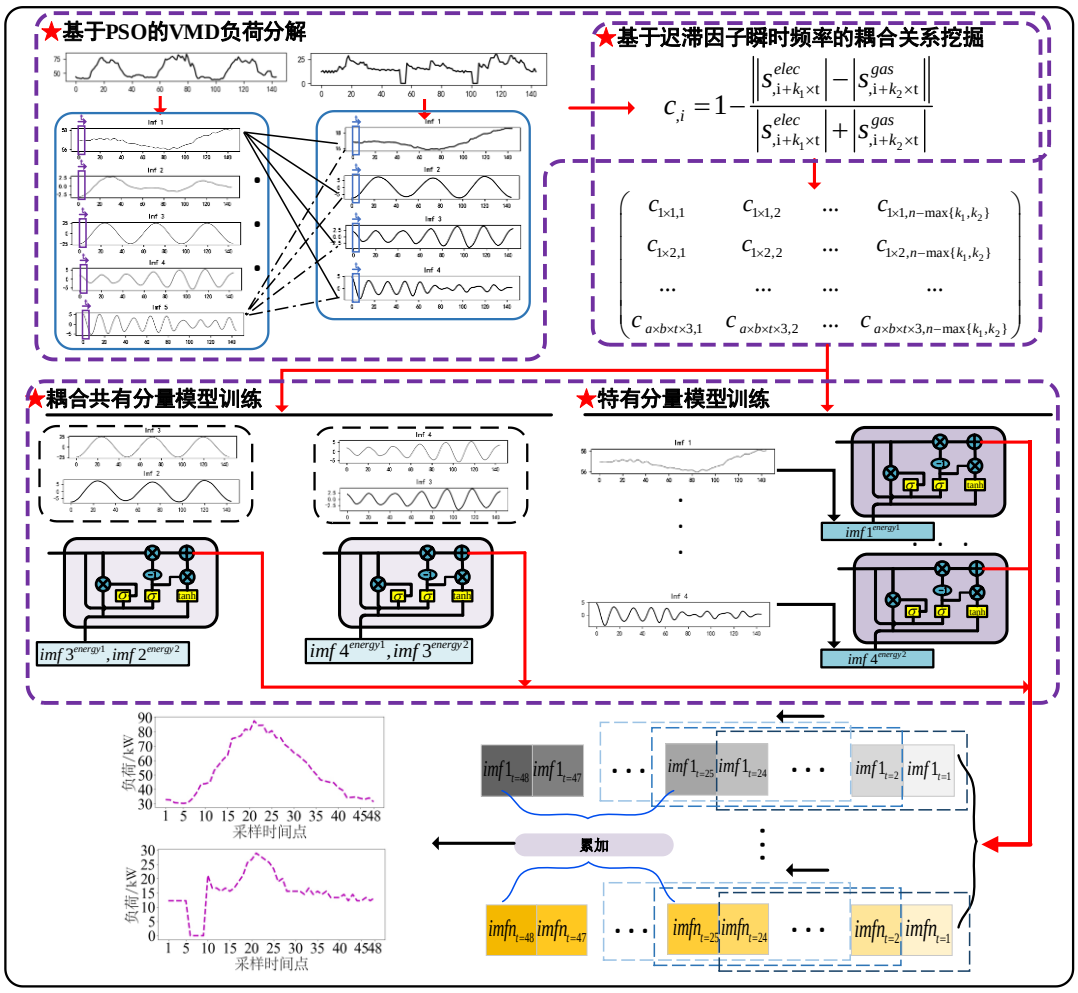


图 4-1 基于模态分量间耦合关系的算法框架

Figure 4-1 Framework of coupling relationship between components

中国知网 https://www.cnki.net

4.3 基于 PSO 的 VMD 负荷分解（Load Decomposition of VMD Based on PSO）

用户的负荷数据是用能行为结果的叠加，因此负荷数据既有随机性也有时序规律性，常用的直接预测方式往往会无法捕捉到负荷数据足够的规律性与错误理解数据的无序性，从而存在预测结果偏差较大的情况，但如果对负荷数据进行分解处理，则可以较为清晰地呈现出时序数据各子序列分量的变化特征，因此本节提出一种基于 PSO 的 VMD 负荷分解策略。

VMD 方法需要提前指定模态函数个数 K 及惩罚函数 α 参数（K 决定模态函数 IMF 的个数，α 决定分量的带宽），当 K 值过小时会出现欠分解，过大则会过分解，出现相邻模态分量中心频率相似的情况；α 过小时，低频分量信息过于冗杂，而过大则会使得分量丢失细节信息，各分量重新叠加后得到的时序数据与原始信号相差较大。因此，为避免人为干扰，本章采用 PSO 粒子群进化优化算法，并以各模态分量中心频率近似关系修正的包络熵作为适应度函数，从而选取合适的 K 与 α 值。原始负荷时序数据 $x(t)$ 经过 VMD 分解后，将得到的模态分量 $u_k(t)$ 进行 Hilbert 变换及求模操作，之后将包络信号归一化，从而可以得到一个概率序列 p_j，该序列的香农熵熵值就是包络熵，$u_k(t)$ 的包络熵 E_p 表示为：

$$\begin{cases} E_p = -\sum_{j=1}^{N} p_j \lg p_j \\ p_j = a(j) \Big/ \sum_{j=1}^{N} a(j) \end{cases} \tag{4-1}$$

式中：N 是分量 $u_k(t)$ 的维度；a_j 是 $u_k(t)$ 经过 Hilbert 变换及极值求模操作后得到的包络信号；p_j 是 a_j 归一化后的概率序列。

同时为了限制相邻模态分量中心频率的相似度，也为了避免求解耦合关系时出现一对多的情况，在包络熵的概念中引入中心频率近似修正因子 F_ω：

$$F_\omega = 1 - \frac{\left\| |\omega_k| - |\omega_{k-1}| \right\|}{|\omega_k| + |\omega_{k-1}|} \tag{4-2}$$

则分量中心频率近似修正的包络熵适应度函数表示成：

$$fitness = \min\left\{E_p^1, E_p^2, ..., E_p^K\right\} \cdot mean\left\{F_\omega^1, F_\omega^2, ..., F_\omega^{K-1}\right\} \tag{4-3}$$

因此，基于 PSO 的 VMD 多元负荷模态分解具体流程如下所示：

（1）初始化个数为 m 的粒子群，随机生成粒子位置（包含模态函数 K 值与惩罚函数 α 值）、速度等参数；

（2）局部最优值和全局最优值赋值为粒子初始位置；

（3）在不同的粒子位置 $[K_m, \alpha_m]$ 处进行 VMD 模态分解，并计算出该处的适

中国知网 https://www.cnki.net

应度函数值 *fitness*；

（4）根据步骤（3）中所得 *fitness* 函数值，与局部最优值以及种群的全局最优值依次进行比较，并判断是否需要更新，然后对粒子速度和位置进行更新；

（5）判断是否达到迭代次数阈值，若是则输出全局最优粒子位置 $\left[K_{gbest},\alpha_{gbest}\right]$ 与适应度值 $fitness_{gbest}$，算法结束；否则，跳转至步骤（3）。

4.4 基于迟滞因子瞬时频率的耦合关系挖掘及结果预测（Coupling Relation Mining and Result Prediction Based on Instantaneous Frequency of Hysteresis Factor）

综合能源系统中用户的用能类型选择常伴随供能方式的改变而做出调整，用户的多元负荷数据间或多或少的存在着互补关系，因此经 4.1 节分解后所得到的多元负荷模态分量间的联系会更为紧密，且对于小样本用户日前多元负荷预测而言，有限的用能数据间影响因素的捕捉对每个预测点都尤为重要，因此本节提出一种基于迟滞因子瞬时频率的耦合关系挖掘方法，通过构建多元数据分量间联系作为用户多种用能类型选择时的耦合关系，并推及至共有分量，达到密切追踪多元消耗间共性的目的，来弥补小样本多元负荷预测时因数据不足导致的无法预测或精度不高等缺陷。

该方法的主要思路是将某用户已知的 n 天，每天 m 个采样点的多元负荷曲线数据集 $Load_{multi}=\left\{load_{ij}^{z}\mid i=1,2,...,n,\ j=1,2,...,m,z=1,2,3\right\}$，分别经过 4.1 节的分解过程得到多元数据的多模态向量，构建一种基于瞬时频率的衡量多元用能数据模态间相关关系的耦合性计算公式，从而剥离出多元数据间具有耦合关系的模态分量，归一化后并行输入 GRU 神经网络中进行预测，而各类型用能数据剩余分量则作为特有分量单独进行预测，最后将各类型用能数据耦合分量预测结果与剩余特有分量预测结果累加并反归一化，从而得到考虑耦合关系影响下的最终预测结果。

具体流程如下所示：

（1）首先，将某类型特征复杂的用能时序数据转为一维向量，即 $\mathbf{load_{ij}^{1}}=\left\{load_{ij}^{1}\mid i=1,2,...,n,\ j=1,2,...,m\right\}$ 转换为 $\mathbf{load^{1}}=\left\{load_{s}^{1}\mid s=1,2,...,n*m\right\}$；然后，基于 4.1 节 PSO-VMD 的负荷模态分解策略，将其分解为特征单一的 K_1 个模态子序列分量 $IMF_{k}^{1}=\left\{dImf_{ks}^{1}\mid k=1,2,...,K_1,s=1,2,...,n*m\right\}$。

（2）分解后的模态序列是离散变量，无法直接求得各采样点的变化趋势，即无法求得导数，因此，利用 python 自带的库函数计算分解后的每个模态序列的瞬时频率序列，从而获得各个模态的瞬时频率向量 $Freq_{k}^{1}=\left\{dfreq_{ks}^{1}\mid k=1,2,...,K_1,s=1,2,...,n*m\right\}$。

中国知网 https://www.cnki.net

（3）将另一种类型的用能负荷数据带入步骤（1）中，进行迭代，对数据同样进行模态分解及瞬时频率求解操作，从而求得模态分量集、瞬时频率向量集：$IMF_k^2=\left\{dImf_{ks}^2\mid k=1,2,...,K_2\right\}$，$Freq_k^2=\left\{dfreq_{ks}^2\mid k=1,2,...,K_2\right\}$，$s=1,2,...,n*m$，其中$K_2$表示经 PSO 算法寻优后所得模态函数个数。

（4）采用排列组合的方式，依次求出两种能源负荷曲线各模态瞬时频率向量$Freq_{K_1}^1$、$Freq_{K_2}^1$间的关系向量，关系向量定义为：

$$c_{K_1|K_2,s}=1-\frac{\left\|dfreq_{K_1,s}^1\right|-\left|dfreq_{K_2,s}^1\right\|}{\left|dfreq_{K_1,s}^1\right|+\left|dfreq_{K_2,s}^1\right|} \tag{4-4}$$

得关系向量集为$C_{multi}=\left\{c_{k_{multi}s}\mid k_{multi}=1,2,...,K_1*K_2,s=1,2,...,n*m\right\}$。

（5）与此同时，考虑到在所选取的时间段内，用能切换间可能存在的迟滞性，取迟滞因子T的数值为 1 小时滑动窗口内的采样点个数，式（4-4）变形为：

$$c_{K_1|K_2,s}^T=1-\frac{\left\|dfreq_{K_1,s+t_1*T}^1\right|-\left|dfreq_{K_2,s+t_2*T}^1\right\|}{\left|dfreq_{K_1,s+t_1*T}^1\right|+\left|dfreq_{K_2,s+t_2*T}^1\right|} \tag{4-5}$$

式中：t_1、t_2可取 0 或 1，且不同时为 1，$s=1,2,...,n*m-\max\left\{t_1*T,t_2*T\right\}$。此时，可得每两条分量间则对应会有$T*3$条关系向量，因此向量集最终扩为$C_{multi}^T=\left\{c_{k_{multi}^Ts}\mid k_{multi}^T=1,2,...,K_1*K_2*T*3,s=1,2,...,n*m-\max\left\{t_1*T,t_2*T\right\}\right\}$。由此可看出，加入迟滞因子实质是在两种耗能曲线的相对平移过程中搜寻耦合关系。

（6）从$\left(K_1*K_2*T*3\right)$个关系向量中，选取满足阈值条件的向量作为耦合关系的表征向量，选取标准为：将引入分量间迟滞因子而产生的$\left(K_1*K_2*T*3\right)$条分量关系以$T*3$个为一组，划分为K_1*K_2组，求取每组中各向量的数值均值，比较各组间最大值，从而得到多元负荷间的最值关系向量集合：$C_{\max}=\left\{c_{k_{\max}s}\mid k_{\max}=1,2,...,K_1*K_2,s=1,2,...,n*m-\max\left\{t_1*T,t_2*T\right\}\right\}$，均值集合：$Avg_{\max}=\left\{avg_{k_{\max}}\mid k_{\max}=1,2,...,K_1*K_2\right\}$，$Avg_{\max}$第 95 个百分位数设为阈值，从而得到$C_{coupling}=\left\{c_{pj}\mid p\in1,2,...,\min\left\{K_1,K_2\right\},j=1,2,...,n*m-\max\left\{t_1*T,t_2*T\right\}\right\}$，将之定义为耦合向量集。

（7）从分量集合IMF_k^1、IMF_k^2中提取出与耦合向量集$C_{coupling}$形成映射关系的模态分量集$IMF_{coupling}=\left\{\left(dImf_{p_1s}^1,dImf_{p_2s}^2\right)\mid p_1\in1,2,...,K_1,p_2\in1,2,...,K_2\right\}$，$s=1,2,...,n*m$，将$IMF_{coupling}$定义为共有分量集合，而多元数据的异构性致使各类型耗能数据的量纲不同，因此需要对共有分量进行归一化操作，并以并行方式构成输入集，从而训练基于 GRU 的耦合共性模型，同时IMF_k^1、IMF_k^2中的剩余分量作为特性分量单独训练 GRU 预测模型，因此需要训练$\left(K_1+K_2-p\right)$个 GRU 神经网络模型，其中，构造的 GRU 神经网络以 24 个采样点为时间窗口向后滑动预测第 25 点的负荷值，即$input_1=\left\{load_1,load_2,...,load_{24}\right\}$，$output_1=\left\{load_{25}\right\}$，然后

中国知网 https://www.cnki.net

将第 25 点带进输入中构成新的 24 维输入矩阵来预测第 26 点，$input_2=\{load_2,load_3,...,load_{25}\}$，$output_2=\{load_{26}\}$，因此构成训练集 $\text{Input}=\{input_1,input_2,...,input_{(n-1)\times 24}\}$，$\text{Output}=\{output_1,output_2,...,output_{(n-1)\times 24}\}$。最后将耦合共性模型预测结果 $pre^1_{coupling}=\{value^1_{p_1s}\mid p_1\in 1,2,...,K_1\}$、$pre^2_{coupling}=\{value^2_{p_2s}\mid p_2\in 1,2,...,K_2\}$ 与剩余分量模型的预测值 $pre^1_{left}=\{value^1_{q_1s}\mid q_1\neq p_1,q_1=1,2,...,K_1\}$、$pre^2_{left}=\{value^2_{q_2s}\mid q_2\neq p_2,q_2=1,2,...,K_2\}$，$s=1,2,...,n*m$，根据分量对应的原始信号负荷类别进行累加并反归一化，从而完成多元负荷的多模预测。本章同样选取平均绝对百分比误差（mean absolute percentage error, MAPE）和均方根误差（root mean square error, RMSE）作为衡量算法性能的标准，两者数值越小代表算法性能越优。

4.5 算例分析（Experimental Analysis）

本章算例所用数据选自于奥斯丁某区域内的综合能源系统，数据集中包含了冷负荷、蒸汽负荷、电负荷等多元负荷时序数据，冷负荷单位为 tons，蒸汽负荷单位是 lbm，电负荷单位是 MW，有效数据的时间区间均为 2011 年 9 月 1 日至 2012 年 9 月 1 日，采样时间为 1 小时一次。为了验证本章所提算法的有效性，且本章研究仅限于求得两种耗能方式间的耦合关系，本章算例将从奥斯丁某区域所拥有数据集中随机抽取三组不同类型属性的 30 天小样本时序连续数据，即 n=30*24，分别是数据集 **I**：2011 年 10 月 1 日零点至 11 月 1 日零点冷负荷与蒸汽负荷数据，**II**：2012 年 4 月 8 日 8 点至 5 月 8 日 8 点冷负荷与电负荷数据，**III**：2012 年 8 月 10 日 8 点至 9 月 9 日 8 点蒸汽负荷与电负荷数据。

4.5.1 基于粒子群优化算法的 VMD 负荷分解

首先，根据 4.3 节的内容对随机挑选的三组实验数据进行 VMD 分解操作，其中 PSO 的各项具体参数如表 4-1 所示，K 值、α 值设定的选取范围分别为 2~10 与 100~1000，得到的 **I**、**II**、**III** 三组模态函数个数 K 值、惩罚函数 α 值的寻优结果对应于表 4-2。从表中可以看出，在三组实验中每种类型时序数据的模态个数寻优值，均逼近或取得提前设定的 K 值上限：10，由此可见如若不对惩罚函数 α 及中心频率等参数进行约束，在适应度函数的迭代计算中，K 值会越大，出现模态混叠的可能性会逐步降低，分解所得各模态分量的熵越小，分量也更加稳定，但会出现过分解现象；与此同时，惩罚函数 α 值在设定范围内均匀分布，说明该参数受 K 值与中心频率双重制约。为直观显示 EMD、VMD 两种分解策略分解后的分量间模态混叠情况，从而验证本章所提算法中采用 VMD 分解的有效性，现对 I、II、III 三组实验数据分别进行 EMD、VMD 分解对比实验，如图 4-2 至图 4-7 所示。

中国知网 https://www.cnki.net

表 4-1 PSO 具体参数

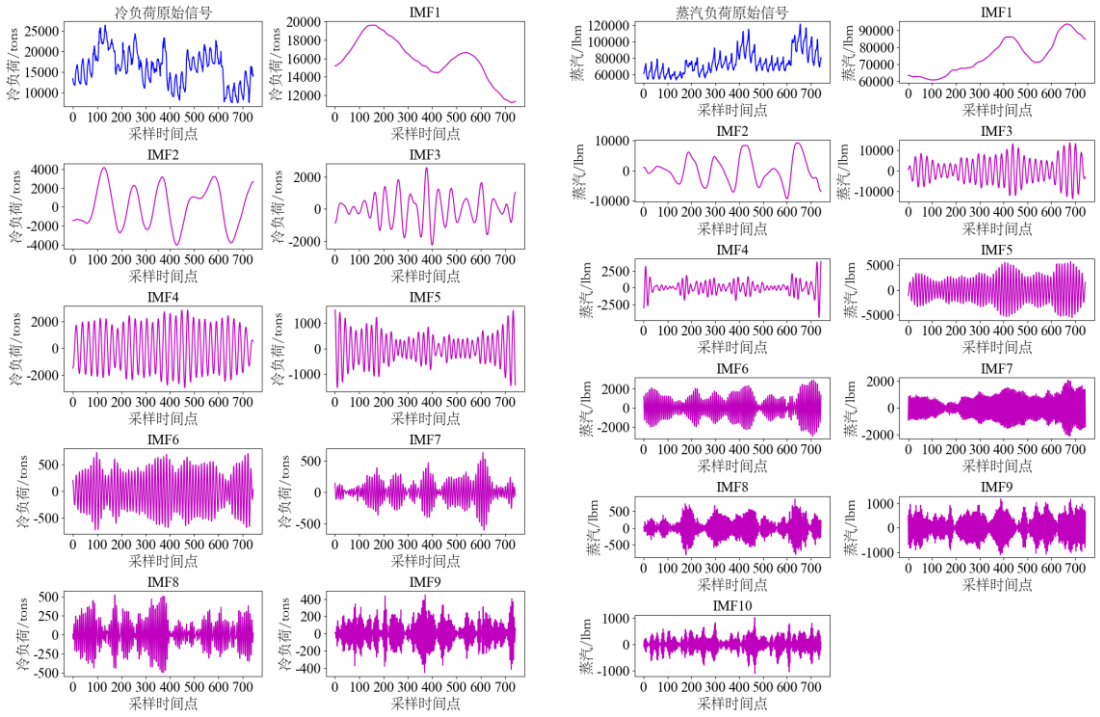
Table 4-1 Specific parameters of PSO

参数	取值
PSO 粒子个数	100
PSO 粒子维度	2
学习因子	$c_1 = c_2 = 2$
惯性权重	$\theta = 0.7$
迭代次数	100
最大速度	$V_{\max} = 2$

表 4-2 VMD 参数寻优结果

Table 4-2 VMD parameter optimization results

组别 \ 变量		模态分量个数 K	惩罚函数 α
I	冷负荷	9	945
	蒸汽负荷	10	498
II	冷负荷	10	915
	电负荷	9	343
III	蒸汽负荷	8	603
	电负荷	8	443

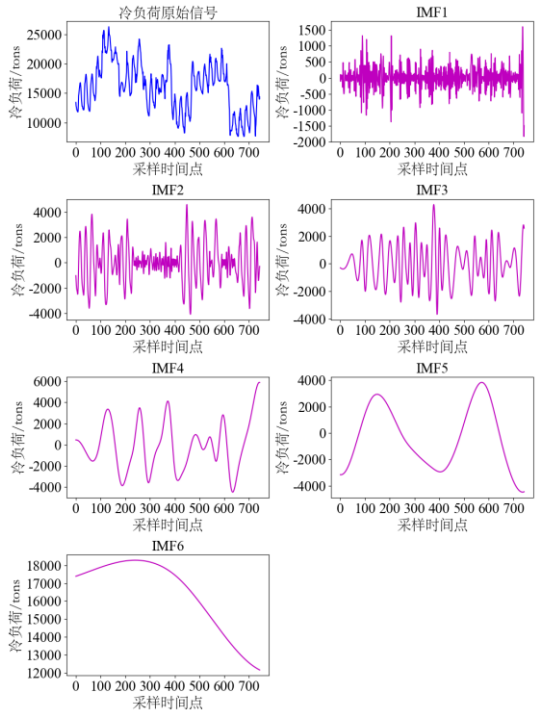


（a）冷负荷变分模态分解图　　（b）蒸汽负荷变分模态分解图

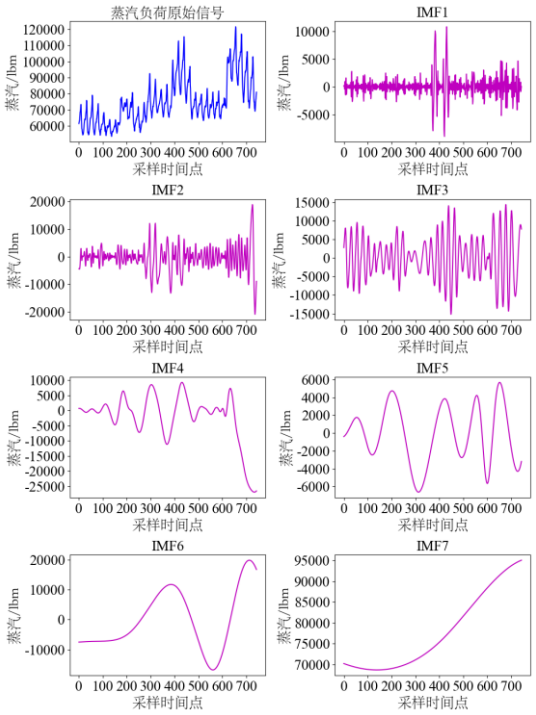
图 4-2 数据集 **I** 的 VMD 分解

Figure 4-2 VMD decomposition of data set **I**

中国知网 https://www.cnki.net



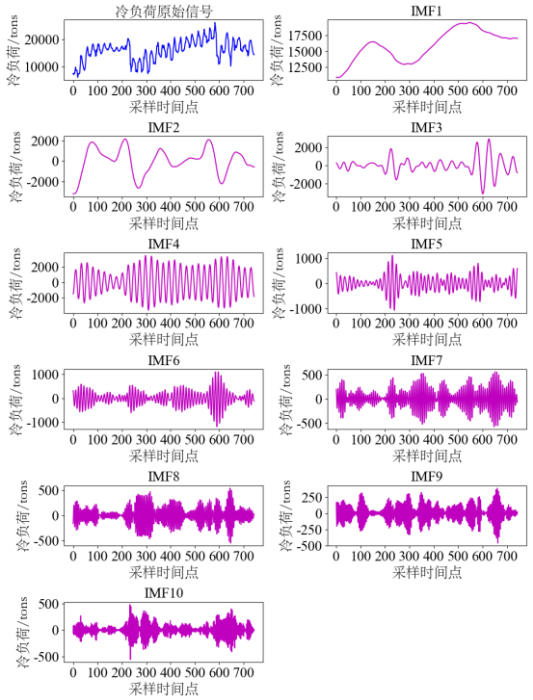
（a）冷负荷经验模态分解图



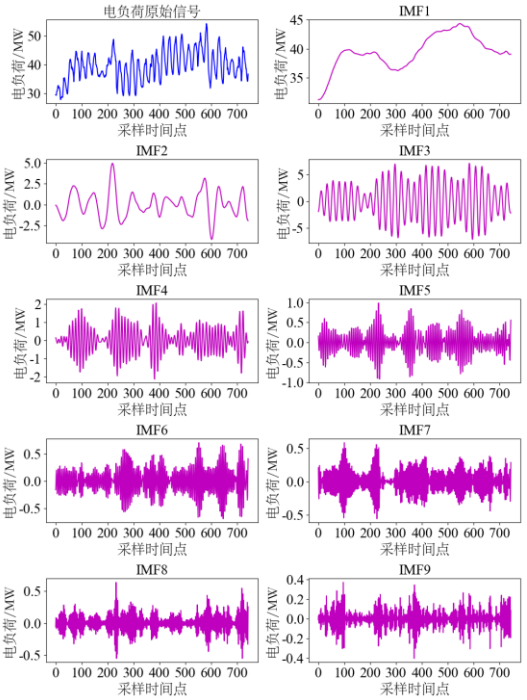
（b）蒸汽负荷经验模态分解图

图 4-3 数据集 **I** 的 EMD 分解

Figure 4-3 EMD decomposition of data set **I**



（a）冷负荷变分模态分解图

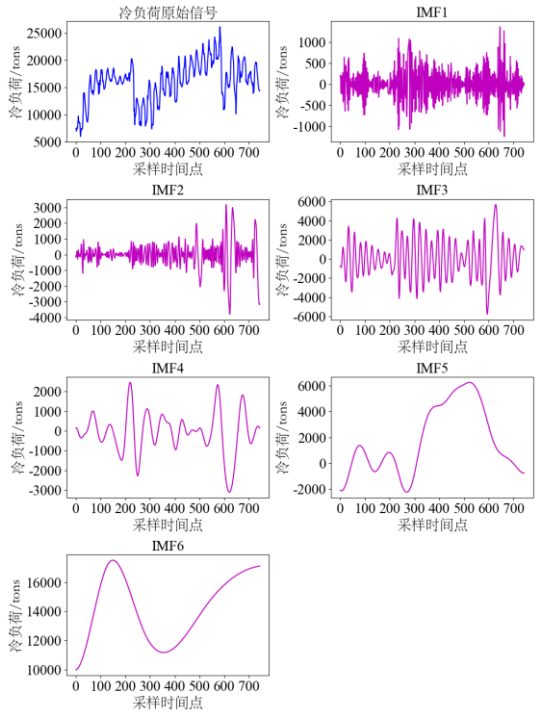


（b）电负荷变分模态分解图

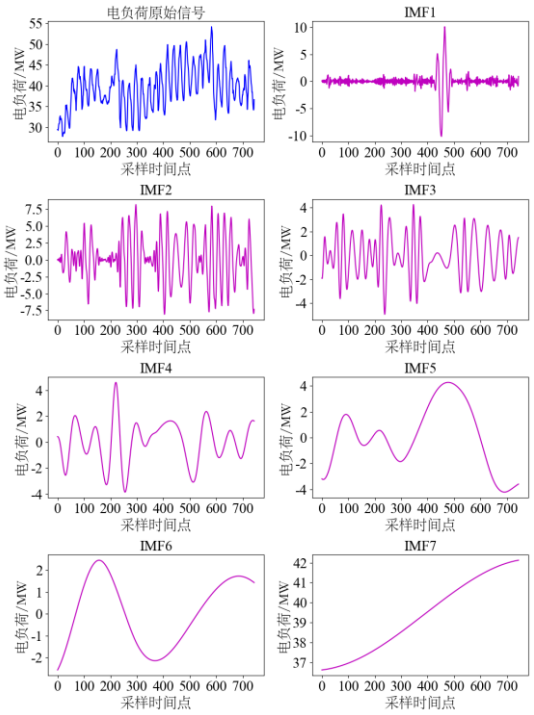
图 4-4 数据集 **II** 的 VMD 分解

Figure 4-4 VMD decomposition of data set **II**

中国知网 https://www.cnki.net



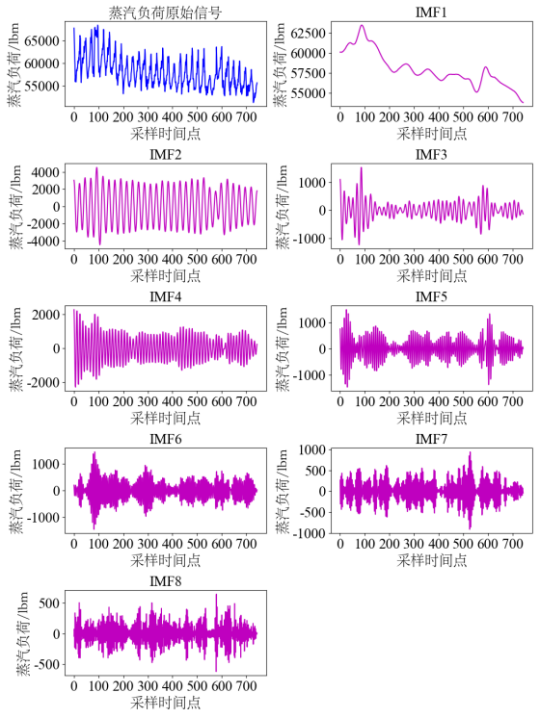
（a）冷负荷经验模态分解图



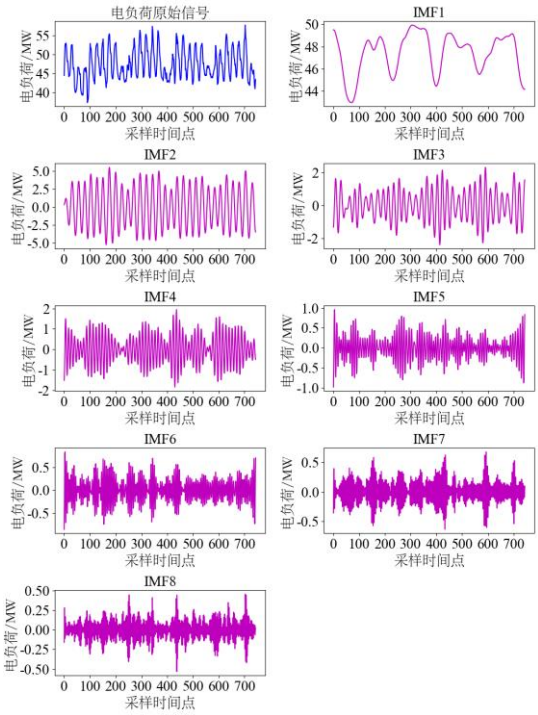
（b）电负荷经验模态分解图

图 4-5 数据集 **II** 的 EMD 分解

Figure 4-5 EMD decomposition of data set II



（a）蒸汽负荷变分模态分解图

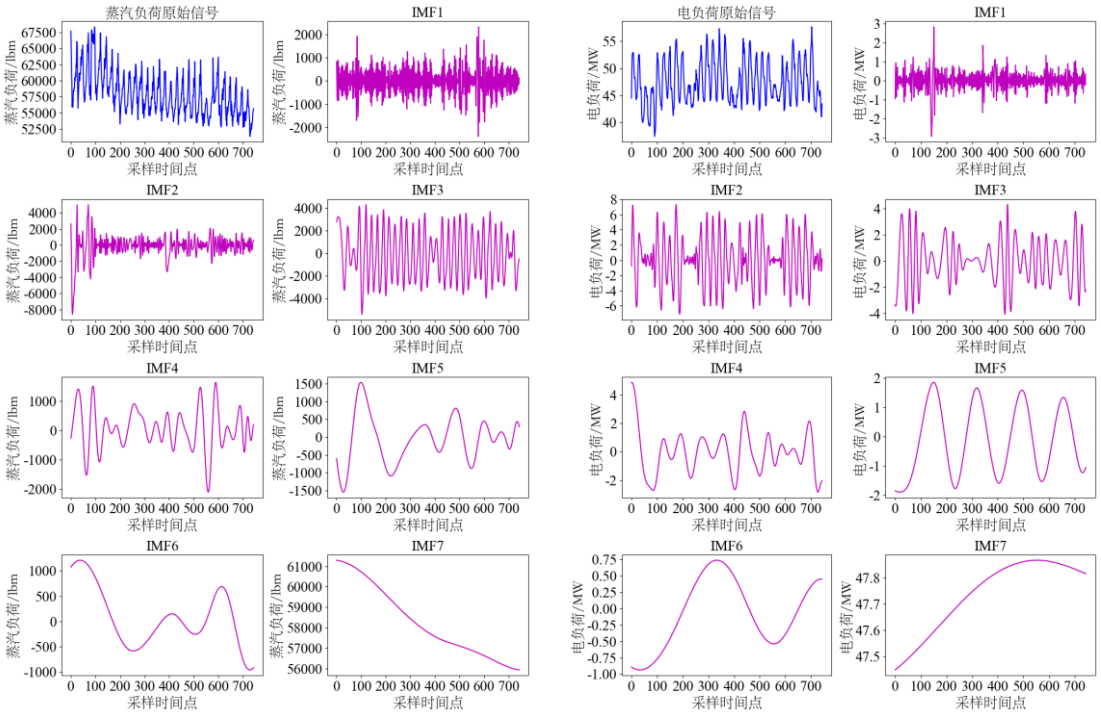


（b）电负荷变分模态分解图

图 4-6 数据集 **III** 的 VMD 分解

Figure 4-6 VMD decomposition of data set III

中国知网 https://www.cnki.net



（a）蒸汽负荷经验模态分解图　　（b）电负荷经验模态分解图

图 4-7 数据集 **III** 的 EMD 分解

Figure 4-7 EMD decomposition of data set **III**

三组实验原始信号经 VMD 分解后分量如图 4-2、图 4-4、图 4-6 所示，而图 4-3、图 4-5、图 4-7 则为 EMD 模态分解图，且各图中蓝色时序曲线为原始负荷曲线信号。

通过观察三组 VMD 分解图，分析可得，（1）第一个模态函数分量 IMF1 本质为原始信号减去其他各分量后剩余分量，变化幅度较为平缓，因此可以看成整体趋势分量，剩余各分解分量的中心频率呈明显递增关系，分解程度适中，且多元负荷数据经 VMD 分解所得的分量图组内有明显差异性，同时各分量均有较高的特征辨识度，证明了调参后的 VMD 分解策略在处理非平稳时序数据时的有效性，以及在分解具有不同特性的多元负荷时的强泛化性。（2）即使是小样本数据，且各组（a）、（b）分量图组间量纲也有所不同，但在大致观察下仍会发现有个别相似分量，而进一步证明分量的相似关系，则需要对归一化后的分量关系进行判断，即需要通过 VMD 的分解操作挖掘耦合关系从而寻找共有分量。

通过对比 VMD 与 EMD 分解图可知，EMD 确实存在比较严重的模态混叠现象，而基于 PSO 的 VMD 方法分离出的分量有明显的规律性与稳定性，因此并不需要多么复杂的神经网络，甚至是线性方程就可以得出估值，而且要避免日前负荷预测的累积误差需要对时间关系的捕捉更为敏锐，因此在这种情况下，可以选用 GRU 神经网络进行预测模型的构建，并且可以移植第 3 章构建好的 GRU 网络框架并在此基础上稍加更改。为了更为直观的呈现分量分解结果的优劣，对

中国知网 https://www.cnki.net

各分量的中心频率进行记录，三组数据各分量的中心频率如表 4-3 所示：

表 4-3 各分量中心频率

Table 4-3 Center frequency of each component

		Imf1	Imf 2	Imf 3	Imf 4	Imf 5	Imf 6	Imf 7	Imf 8	Imf 9	Imf 10
I	冷负荷	0.04	4.8	14.6	30.7	35.8	61.8	77.0	98.5	158.2	—
	蒸汽负荷	0.03	6.2	30.6	39.8	62.0	92.6	123.7	132.3	159.0	246.5
II	冷负荷	0.05	4.9	15.2	31.0	45.2	64.2	92.8	118.9	153.4	200.1
	电负荷	0.02	10.4	30.9	60.8	89.4	118.7	158.1	214.2	293.3	—
III	蒸汽负荷	0.01	30.8	40.7	62.0	91.1	124.9	183.3	286.1	—	—
	电负荷	0.01	30.4	35.4	60.7	81.7	116.7	160.3	237.5	—	—

通过对表 4-3 各分量中心频率数值信息的分析，发现经过 VMD 分解后的同种负荷各个相邻分量中心频率前后数值相差均较大，很少出现分解所得连续分量是相似分量的情况，即分解出的分量不存在过分解现象，也呼应了上述对分量分解图的分析结果，同时进一步验证了本章所提基于 PSO 的 VMD 分解机制的有效性。

4.5.2 基于迟滞因子瞬时频率的耦合关系挖掘

首先，将 4.5.1 节分解得到的多元模态分量带入 4.4 节耦合关系的解析式，分别求得数据集 **I**、**II** 和 **III** 中各模态分量间的关系向量，依据第 95 个百分位数确定了三组实验耦合关系的判别阈值分别为 0.858、0.873 和 0.897，并求得满足条件阈值的相应分量作为耦合关系下的共有分量，具体如表 4-4 所示。

表 4-4 耦合共有分量

Table 4-4 Coupling common component

数据集	耦合阈值	耦合共有分量
I	0.858	$IMF4_{1\sim743}^{冷}$ 与 $IMF3_{2\sim744}^{蒸汽}$，$IMF5_{1\sim744}^{冷}$ 与 $IMF4_{1\sim744}^{蒸汽}$，$IMF6_{1\sim743}^{冷}$ 与 $IMF5_{2\sim744}^{蒸汽}$，$IMF8_{1\sim743}^{冷}$ 与 $IMF6_{2\sim744}^{蒸汽}$，$IMF9_{1\sim743}^{冷}$ 与 $IMF9_{2\sim744}^{蒸汽}$
II	0.873	$IMF4_{2\sim744}^{冷}$ 与 $IMF3_{1\sim743}^{电}$，$IMF6_{1\sim743}^{冷}$ 与 $IMF5_{2\sim744}^{电}$，$IMF7_{2\sim744}^{冷}$ 与 $IMF6_{1\sim743}^{电}$，$IMF8_{2\sim744}^{冷}$ 与 $IMF7_{1\sim743}^{电}$，$IMF9_{2\sim744}^{冷}$ 与 $IMF9_{1\sim743}^{电}$，$IMF3_{1\sim743}^{蒸汽}$ 与 $IMF3_{2\sim744}^{电}$，$IMF5_{1\sim743}^{蒸汽}$ 与 $IMF5_{2\sim744}^{电}$，
III	0.897	$IMF6_{1\sim743}^{蒸汽}$ 与 $IMF6_{2\sim744}^{电}$，$IMF7_{1\sim743}^{蒸汽}$ 与 $IMF7_{2\sim744}^{电}$ $IMF8_{2\sim744}^{蒸汽}$ 与 $IMF8_{1\sim743}^{电}$

中国知网 https://www.cnki.net

从表 4-4 可以看出，基于迟滞因子的耦合关系求解策略分解得到的耦合共有分量大多数都包含有迟滞时间因子，且三组数据集的组内耦合分量的迟滞时间几乎一致，说明原始信号虽然经过了模态分量的划分，但分解出的模态子序列分量仍保持原始信号的时序特征。

数据集 **I**、**II** 和 **III** 在确定了耦合共有分量后，需要将耦合共有分量归一化后并将其以并行方式构造成维度为$((30*24),2)$的向量从而输入 GRU 神经网络中，同时剩余特有分量也需要各自训练 GRU 神经网络，其中三组实验需要训练的耦合共有分量 GRU 神经网络及剩余特有 GRU 神经网络模型参数及个数如表 4-5、表 4-6 所示。

表 4-5 耦合分量及特有分量 GRU 参数

Table 4-5 GRU parameters of coupling component and special component

参数	耦合共有分量	剩余特有分量
输入层节点数	24	24
隐含层第一层节点数	15	15
隐含层第二层节点数	10	—
输出层节点数	1	1
学习率	0.005	0.01
迭代次数	200	150
优化器	Adam	Adam

表 4-6 耦合分量及特有分量模型个数

Table 4-6 Number of coupled component and unique component models

数据集	耦合部分预测模型个数	剩余部分预测模型个数
I	5	14
II	5	14
III	5	11

本章实验运行硬件及软件环境如下：

表 4-7 实验硬件/软件环境

Table 4-7 Hardware / software environment of the experiment

硬件/软件	
操作系统	Windows 7
处理器	Intel(R) Core(TM) i7-7700
内存	16.0GB
编译环境	python3.7.4
编译器	pycharm 2019

4.5.3 结果分析

为了充分验证本章所提算法的可行性，将算法应用在奥斯丁某区域综合能源系统随机挑选出的 3 组实验数据集中，分别对应 4.5 节首段所述的 **I**、**II** 和 **III** 三组小样本（仅有 30 天的样本量）实验数据集，且维度均为 30*24，实验的目

中国知网 https://www.cnki.net

的是预测后续一天即 24 个采样时间点的负荷。

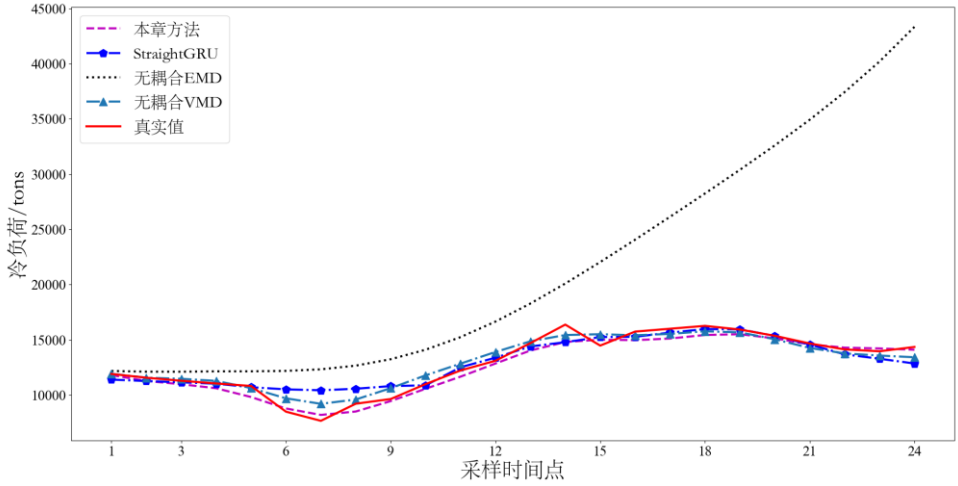
为了与本章算法可以进行多方面比较，同时兼顾验证算法各部分的有效性，本章选取三个对比算法进行比较：

1）利用传统的 GRU 神经网络直接预测（**方法 2**，记为 StraightGRU）：在不考虑模态分解及多元间耦合效应的小样本实验下，以 24 个采样点为时间滑动窗口，仅仅利用已知的 30 天历史数据构建 GRU 预测模型进行日前多元负荷预测，目的是检验简化的整体框架的效果，从而衡量构建复杂框架的必要性。

2）基于 EMD 分解的模态分量预测方法（**方法 3**，记为无耦合 EMD）：作为非平稳信号分解的主流代表方法，相较于 VMD 分解需要设定模态个数，EMD 对噪声的敏感程度和模态个数的自适应性使其避免了人为因素干扰，与本章算法的 VMD 分解部分形成对照，目的是对比不同的分解策略对预测精度的影响。

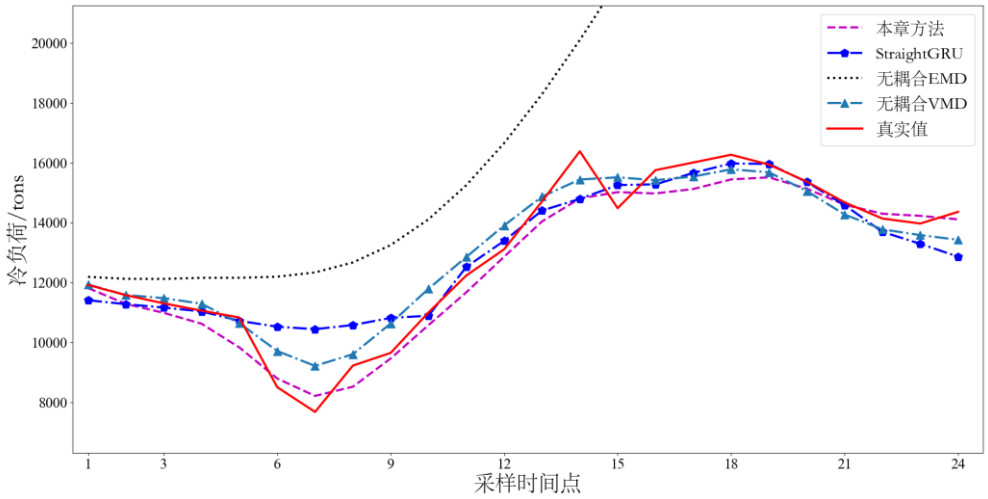
3）没有耦合关系挖掘进程的 VMD 方法（**方法 4**，记为无耦合 VMD）：在获得分解分量后，不对分量间联系做出判断，仅利用各分量的时序特征训练预测网络，与本章方法在求解耦合关系处形成对照，选取此对比算法的目的是探寻在小样本多元负荷预测中，耦合关系的判断以及耦合共有分量并行输入集的构造能否弥补小样本情况下的预测精度不高的不足。

本章算法及其他三种对比算法预测所得负荷曲线与真实值的比较结果如图 4-5 所示，其中，由于图 4-5（a）的方法 3（无耦合 EMD）的冷负荷预测结果与真实值偏差相较于其他三种算法过大，致使预测结果图无法显示与真实值的差值细节，考虑到 A 组冷负荷预测中方法 3 的参考价值较低，因此对其他三种方法进行细节放大，如图 4-5（a1）所示。四种算法在三组数据集下的性能表现的具体 MAPE 与 RMSE 结果如表 4-8 所示。

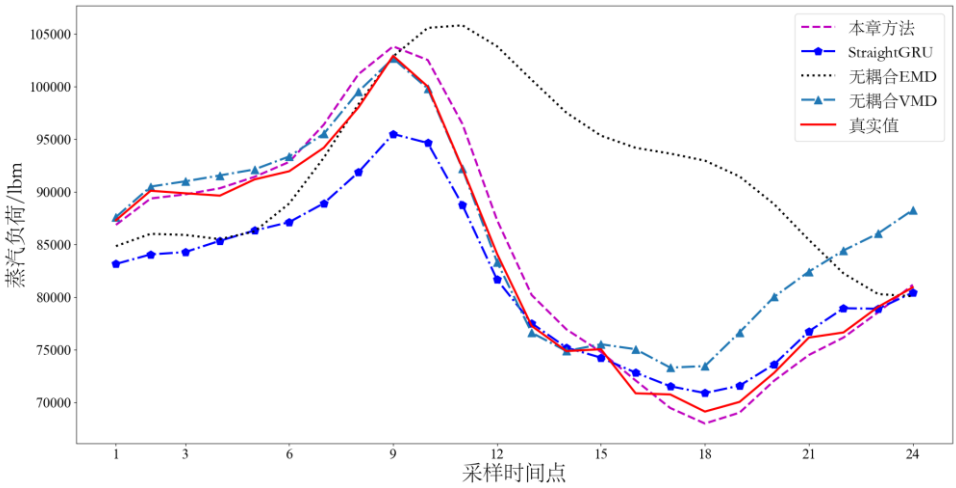


（a）数据集 **I**—冷负荷预测结果

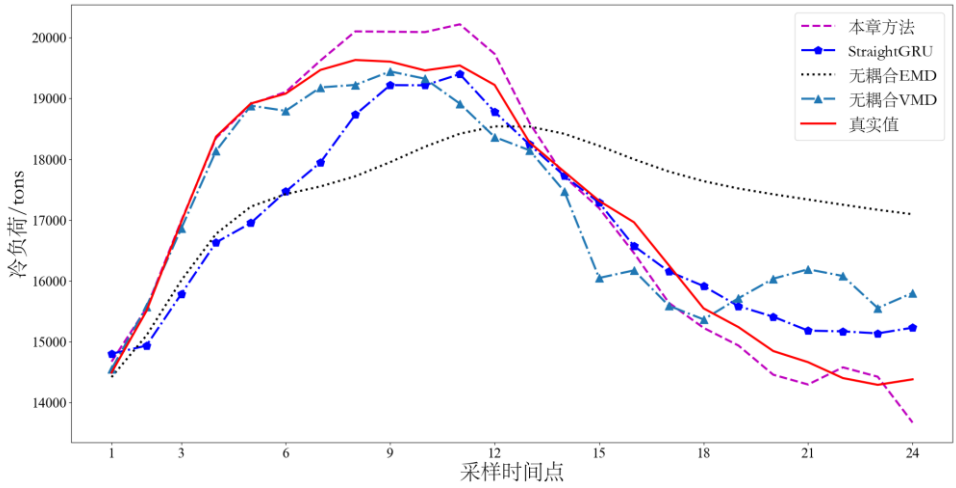
中国知网 https://www.cnki.net



（a-1）a 图细节放大

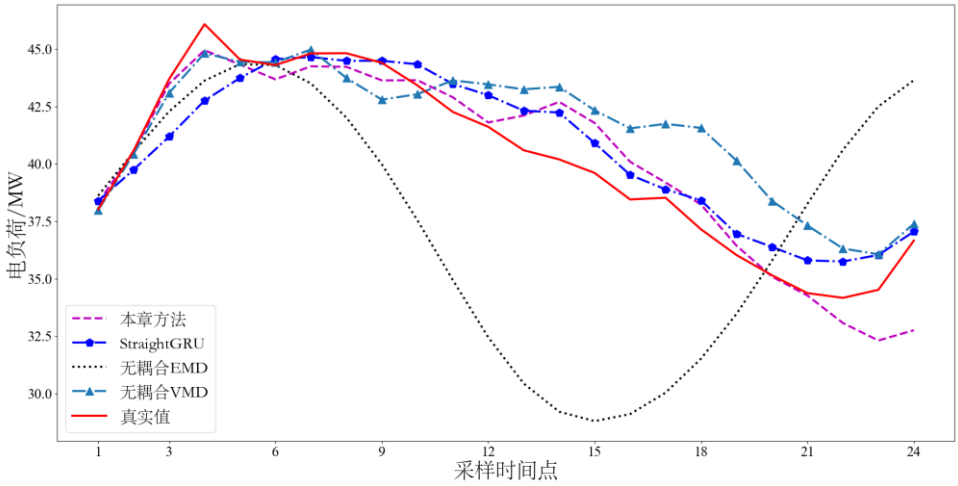


（b）数据集 **I**—蒸汽负荷预测结果

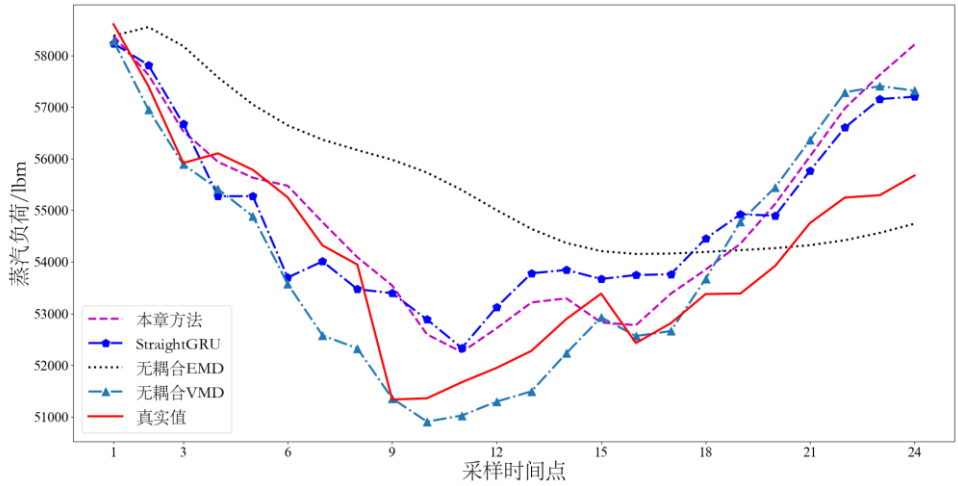


（c）数据集 **II**—冷负荷预测结果

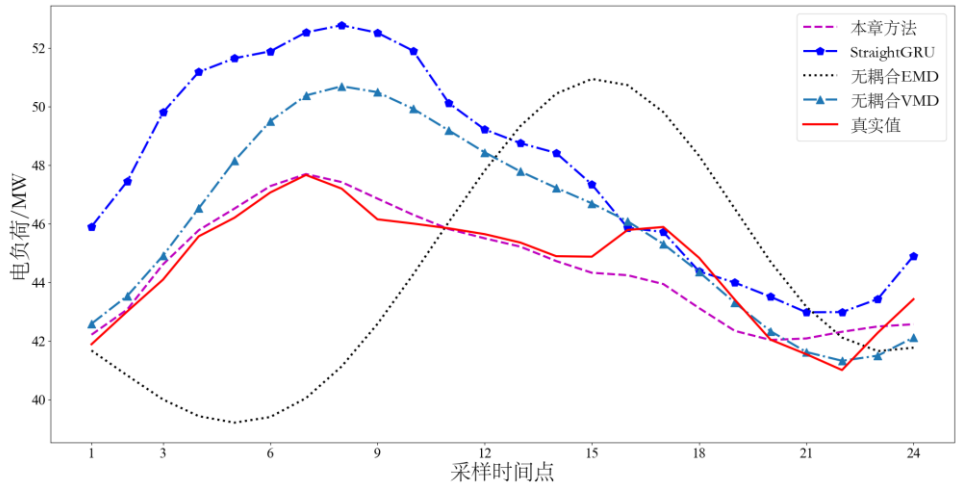
中国知网 https://www.cnki.net



（d）数据集 **II**—电负荷预测结果



（e）数据集 **III**—蒸汽负荷预测结果



（f）数据集 **III**—电负荷预测结果

图 4-8 三组实验下的负荷预测结果对比

Figure 4-8 Comparison of load forecasting results in three groups

中国知网 https://www.cnki.net

表 4-8 4 种预测算法精度比较

Table 4-8 Accuracy comparison of four prediction algorithms

			本章方法	方法 2	方法 3	方法 4
I	冷负荷	MAPE	**3.85**	6.03	61.63	4.70
		RMSE	**595.91**	958.13	12042.45	668.41
	蒸汽负荷	MAPE	**1.63**	3.35	13.83	3.50
		RMSE	**1756.26**	3736.45	13887.14	3840.20
II	冷负荷	MAPE	**1.79**	3.85	9.47	3.70
		RMSE	**378.23**	863.00	1761.21	785.48
	电负荷	MAPE	**2.45**	2.83	12.71	4.65
		RMSE	**1.33**	1.35	6.18	2.22
III	蒸汽负荷	MAPE	**1.57**	1.94	3.17	1.69
		RMSE	**1100.67**	1154.14	2063.80	1130.59
	电负荷	MAPE	**1.23**	7.27	8.02	3.54
		RMSE	**0.78**	3.85	4.29	2.07

由图 4-5 和表 4-8 可知，（1）相较于其他三种算法，本章所提算法在三组实验数据集上表现均为最优，除了在数据集 **I** 中对冷负荷曲线的预测误差略高，其余数据集的预测 MAPE 误差值均不超过 2.5%。（2）在数据集 **I**、**II**、**III** 中，方法 2 的表现相较于本章方法有可取之处，个别实验结果甚至逼近本章算法精度，在数据集 **II** 的电负荷及数据集 **III** 的蒸汽负荷预测实验中，两种算法的 MAPE、RMSE 预测误差值相差甚微，与此同时，方法 2 直接使用 GRU 神经网络完成小样本算例的预测，提高了求解速度，简化了算法框架，但从方法 2 整体预测精度的浮动幅度来看，其稳定性不高，处理各种场景的能力有明显差异，而本章算法则以付出些许的计算代价和框架复杂度来保障精度水准的平衡，实现了多元负荷的稳定精准预测。（3）对比本章所用算法与方法 4 在实例验证中的结果，发现在对应的每组多元预测实验中，本章算法预测精度较方法 4 均有所提升，MAPE 值提高 0.12%~2.31%，验证了求解分量间耦合关系从而找出共有分量对提高小样本多元预测精度的必要性。（4）方法 4 通过对原始非平稳负荷曲线的有效分解，析出若干带宽分明的分量，减小了噪声的不确定性，并通过与方法 2 的精度结果对比解释了进行分量分解操作的必要性。（5）方法 3 采用经典的 EMD 模态分解方法，各分解分量依次构造预测模型，从图表中不难看出，与采用 VMD 分解策略的方法 4 相比，EMD 的弊端即出现的模态混叠问题会造成各分量的无序性，增大时序预测的特征识别难度，预测误差不断累积，造成预测结果几乎没有参考价值，这也说明了选择适当的模态分解方法的重要性。（6）在数据集 **III** 电负荷的预测中，即（f）图所展示，本章算法捕捉到了时序特征的变化并及时做出调整，且在与其他算法的图表对比中，尤为突出的彰显了所提算法框架的应用优越性。

中国知网 https://www.cnki.net

4.6 本章小结（Conclusions）

本章在第三章的研究背景及理论基础上，将算法应用延伸至综合能源系统中的小样本多元负荷预测，并针对小样本及多元两个关键点进行问题的深入剖析，从而提出基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测方法。所提算法首先对原始多元负荷数据分别进行 VMD 分解，使用基于中心频率近似关系修正的包络熵，作为 VMD 模态分量个数 K 与惩罚函数 α 值的 PSO 寻优算法适应度函数，使得分解后得到的分量特征识别度更高；另外，以分量的瞬时频率相似度作为衡量多元间耦合程度的依据，构建了基于迟滞因子瞬时频率的耦合关系挖掘机制，并由满足阈值的耦合关系向量推及至耦合分量，将多元耦合分量以并行方式作为训练集训练耦合共有分量的预测模型，多元负荷剩余特有分量则各自训练模型，最后将同种能源的各分量预测曲线进行累加求和，完成预测模型的构建。算法在奥斯丁某综合能源系统的实例应用，证明了其在处理小样本多元日前负荷预测问题上的有效性。

第五章将对本文工作及创新点做出梳理与总结，并结合当前研究进展给出下一步研究工作的方向与展望。

中国知网 https://www.cnki.net

5 总结与展望

5 Summary and Prospect

本文针对当前综合能源系统负荷预测研究中，如何提升小样本电力负荷预测精度以及如何基于多元负荷间耦合关系的挖掘提升小样本综合预测精度等问题展开研究。首先，利用深度学习特征提取技术，构造源域与小样本目标域间的迁移媒介，并以目标域融合特征作为迁移信息载体，进行样本扩充从而实现小样本历史负荷数据下的电力负荷精准预测；然后，针对小样本多元负荷的特征识别难度相异性、趋势波动性，利用信号分解技术实现复杂非线性负荷曲线的多模态平稳分量分解，并提出基于模态分量间耦合关系的多元负荷时序数据的预测模型。

5.1 本文工作及创新点（Achievements and Innovations）

本小节将会介绍本文主要工作及创新点：

（1）基于特征迁移学习的综合能源系统小样本日前电力负荷预测

首先，利用 K-means 聚类算法对源域用户的历史电力负荷数据进行场景分类，并采用 GRU 神经网络提取类别信息特征，作为用户各场景下用能行为表达；然后，将待预测小样本数据带入该有监督深度学习模型，获取目标域用户行为分类及特征信息，同时依据特征余弦相似度构建了基于时间遗忘因子的目标域特征融合机制；最后，源域到目标域的样本扩充以融合特征作为迁移载体，并利用 ELM 神经网络实现特征、电力负荷间的数据拟合，从而完成目标域的小样本日前电力负荷预测。并通过在卡迪夫某区域的高中和住宅实例预测研究，说明所提算法的有效性。

该研究内容的主要创新点体现在，针对小样本下的日前电力负荷预测问题，通过 GRU 提取 K-means 聚类的时序数据中用户行为的隐特征表示；并构建一种特征融合机制用于凝聚目标域样本特征；从而基于融合特征的特征迁移构建预测模型，缓解了数据量较少时预测精度难以提高的问题。

（2）基于耦合关系挖掘的综合能源系统小样本日前多元负荷预测

首先，基于小样本多元历史负荷数据构建 VMD 变分模态分解机制，针对 VMD 模态个数及惩罚函数的参数选择问题，提出以模态分量中心频率近似修正包络熵为优化目标函数的 PSO-VMD 分解策略；然后，基于多元负荷间模态分量瞬时频率的相似度并佐以迟滞因子，对多元负荷的耦合关系进行挖掘；最后，利用耦合分量、特有分量训练多个 GRU 预测模型，从而完成小样本日前多元负荷的多模预测。通过对奥斯丁某区域的综合多元用能实例的预测研究，表明了所提算法在提高小样本日前多元负荷预测的可行性。

中国知网 https://www.cnki.net

该研究内容的主要创新点体现在，以中心频率修正的模态分量包络熵为参数优化适应度函数，提出一种基于 PSO 的 VMD 多元数据模态分量的分解策略用于获取平稳分量；制定了模态分量间耦合关系判定标准，并依据耦合关系构建了基于耦合分量、特有分量的多模预测模型，有效地提高了小样本多元负荷集中各类能源的日前预测精度。

5.2 下一步研究工作（Future Research）

本文针对小样本下的综合能源电力负荷及多元负荷预测分别开展了研究工作，已经在精度提升上取得了一定的成果，但仍存在一些不足之处需要改善。

（1）第 3 章针对小样本电力负荷日前预测的研究，借鉴了特征迁移学习的理念，但所提算法仅适用于单源域特征迁移，即没有设置多源域的挑选机制，下一阶段，将围绕如何解决综合区域中多源域小样本负荷预测问题开展工作。

（2）第 4 章的耦合关系求解机制的构建准则仍然相对粗糙，实例验证时仅针对多元负荷两两间进行耦合关系挖掘，所提算法框架应用于冷、电、蒸汽负荷三者的耦合预测时，实验结果并不理想，因此今后的工作将着重处理更为复杂的三种及三种以上类型能源间的耦合问题，以提升预测模型的普适性。

中国知网 https://www.cnki.net

参考文献

[1] 林伯强，李江龙. 基于随机动态递归的中国可再生能源政策量化评价[J]. 经济研究，2014，49(04)：89-103.

[2] 柯坚．全球气候变化背景下我国可再生能源发展的法律推进——以《可再生能源法》为中心的立法检视[J]．政法论丛，2015，(04)：75-83.

[3] 王毅，张宁，康重庆．能源互联网中能量枢纽的优化规划与运行研究综述及展望[J]．中国电机工程学报，2015，35(22)：5669-5681.

[4] 马钊，周孝信，尚宇炜，等. 未来配电系统形态及发展趋势[J]. 中国电机工程学报，2015，35(06)：1289-1298.

[5] 黄仁乐，蒲天骄，刘克文，等．城市能源互联网功能体系及应用方案设计[J]．电力系统自动化，2015，39(09)：26-33.

[6] 贾宏杰，王丹，徐宪东，等. 区域综合能源系统若干问题研究[J]. 电力系统自动化，2015，39(07)：198-207.

[7] 贾宏杰，穆云飞，余晓丹．对我国综合能源系统发展的思考[J]．电力建设，2015，36(01)：16-25.

[8] 宗文婷，卫志农，孙国强，等．基于改进高斯过程回归模型的短期负荷区间预测[J]．电力系统及其自动化学报，2017，29(08)：22-28.

[9] A. A, G. E. A Review of Deep Learning Methods Applied on Load Forecasting: 2017 16th IEEE International Conference on Machine Learning and Applications [C]. Mexico: IEEE, 2017: 511-516.

[10] TOKGOZ A, UNAL G. A RNN based time series approach for forecasting turkish electricity load: 2018 26th Signal Processing and Communications Applications Conference [C]. Turkey: IEEE, 2018: 1-4.

[11] J. V, E. C B. Recurrent neural networks for short-term load forecasting[J]. IEEE Transactions on Power Systems, 1998, 13(1): 126-132.

[12] H. S, M. X, R. L. Deep Learning for Household Load Forecasting-A Novel Pooling Deep RNN[J]. IEEE Transactions on Smart Grid, 2018, 9(5): 5271-5280.

[13] 张宇帆，艾芊，林琳，等. 基于深度长短时记忆网络的区域级超短期负荷预测方法[J]. 电网技术，2019，43(06)：1884-1892.

[14] 沈兆轩，袁三男．利用卷积神经网络支持向量回归机的地区负荷聚类集成预测[J]．电网技术，2020，44(06)：2237-2244.

[15] WEN L, ZHOU K, YANG S. Load demand forecasting of residential buildings using a deep learning model[J]. Electric Power Systems Research, 2020, 179: 106073.

[16] 易灵芝，常峰铭，龙谷宗，等．基于进化深度学习短期负荷预测的应用研究[J]．电力系

中国知网 https://www.cnki.net

统及其自动化学报，2020，32(03)：1-6.

[17] 杨智宇，刘俊勇，刘友波，等. 基于自适应深度信念网络的变电站负荷预测[J]. 中国电机工程学报，2019，39(14)：4049-4061.

[18] 孙海蓉，田瑶，谢碧霞. 基于深度学习的短时热网负荷预测[J]. 计算机仿真，2019，36(02)：79-82.

[19] WANG Y, HUG G, LIU Z, et al. Modeling load forecast uncertainty using generative adversarial networks[J]. Electric Power Systems Research, 2020, 189: 106732.

[20] 艾芊，郝然. 多能互补、集成优化能源系统关键技术及挑战[J]. 电力系统自动化，2018，42(04)：2-10.

[21] SWAN L G, UGURSAL V I. Modeling of end-use energy consumption in the residential sector: A review of modeling techniques[J]. Renewable and Sustainable Energy Reviews, 2009, 13(8): 1819-1835.

[22] 朱刘柱，王绪利，马静，等. 基于小波包分解与循环神经网络的综合能源系统短期负荷预测[J]. 电力建设，2020，41(12)：131-138.

[23] 栗然，孙帆，丁星，等. 考虑多能时空耦合的用户级综合能源系统超短期负荷预测方法[J]. 电网技术，2020，44(11)：4121-4134.

[24] 田浩含，撖奥洋，于立涛，等. 基于 GRA-LSTM 神经网络的区域综合能源系统多元负荷短期预测模型[J]. 广东电力，2020，33(05)：44-51.

[25] 孙庆凯，王小君，张义志，等. 基于 LSTM 和多任务学习的综合能源系统多元负荷预测[J]. 电力系统自动化，2021，45(05)：63-70.

[26] G. H, H. Z, X. D, et al. Extreme Learning Machine for Regression and Multiclass Classification[J]. IEEE Transactions on Systems, Man, and Cybernetics, 2012, 42(2): 513-529.

[27] 颜宏文，盛成功. 基于层次聚类和极限学习机的母线短期负荷预测[J]. 计算机应用，2018，38(08)：2437-2441.

[28] 章婕. 基于 BP 神经网络的短期供热负荷组合预测研究[D]. 大连：大连海事大学，2019.

[29] 蒋建东，石洋涛，燕跃豪，等. 基于改进烟花算法的极限学习机超短期负荷预测[J]. 郑州大学学报(理学版)，2020，52(04)：110-115.

[30] LI S, WANG P, GOEL L. Short-term load forecasting by wavelet transform and evolutionary extreme learning machine[J]. Electric Power Systems Research, 2015, 122: 96-103.

[31] 张宁，刘天键. 考虑影响因素的短期负荷预测核函数 ELM 方法[J]. 武汉大学学报(工学版)，2018，51(08)：703-707.

[32] 曹琦. 基于 DBN-ELM 的脑血管病复发预测系统的研究[D]. 北京：北京交通大学，2020.

[33] 赵兵，王增平，纪维佳，等. 基于注意力机制的 CNN-GRU 短期电力负荷预测方法[J]. 电网技术，2019，43(12)：4370-4376.

中国知网 https://www.cnki.net

[34] 庄家懿，杨国华，郑豪丰，等．并行多模型融合的混合神经网络超短期负荷预测[J]．电力建设，2020，41(10)：1-8．

[35] WU W, LIAO W, MIAO J, et al. Using Gated Recurrent Unit Network to Forecast Short-Term Load Considering Impact of Electricity Price[J]. Energy Procedia, 2019, 158: 3369-3374.

[36] 王康，张智晟，撖奥洋，等．基于 Bagging 的双向 GRU 集成神经网络短期负荷预测[J/OL]．电力系统及其自动化学报：1-8[2021-03-30]．https://doi.org/10.19635/j.cnki.csu-epsa.000591．

[37] NIU Z, YU Z, TANG W, et al. Wind power forecasting using attention-based gated recurrent unit network[J]. Energy, 2020, 196: 117081.

[38] 刘世昌．多尺度分析与数据互迁移相结合的短期电力负荷预测方法[D]．长沙：湖南大学，2017．

[39] 邓翱．基于竞争迁移学习 EMD 和 LSSVM 的短期电力负荷预测研究[D]．长沙：湖南大学，2017．

[40] ZHOU D, MA S, HAO J, et al. An electricity load forecasting model for Integrated Energy System based on BiGAN and transfer learning[J]. Energy Reports, 2020, 6: 3446-3461.

[41] YI C A, XU Y, YU H, et al. Multi-component transfer metric learning for handling unrelated source domain samples[J]. Knowledge-Based Systems, 2020, 203: 106132.

[42] 邵阳雪．基于深度学习和迁移学习的跨模态检索研究[D]．开封：河南大学，2020．

[43] 董晗．基于迁移学习的铁路场景异物侵限检测[D]．北京：北方工业大学，2020．

[44] 孙凌浩．基于跨语言迁移学习的实体关系抽取算法研究[D]．合肥：中国科学技术大学，2020．

[45] 许华，苟泽中，蒋磊，等．适用于样本分布差异的迁移学习调制识别算法[J/OL]．华中科技大学学报(自然科学版)：1-6[2021-03-27]．https://doi.org/10.13245/j.hust.210422．

[46] FAN C, DING C, ZHENG J, et al. Empirical Mode Decomposition based Multi-objective Deep Belief Network for short-term power load forecasting[J]. Neurocomputing, 2020, 388: 110-123.

[47] 龚承柱，李兰兰，杨娟，等. 基于 EMD-PSR-LSSVM 的城市燃气管网短期负荷预测[J]. 系统工程理论与实践，2014，34(11)：3001-3008．

[48] 邓翱，金敏．基于 EMD 的时标特征提取方法及其在短期电力负荷预测中的应用[J]．计算机应用研究，2018，35(10)：2952-2955．

[49] 魏骜，茅大钧，韩万里，等. 基于 EMD 和长短期记忆网络的短期电力负荷预测研究[J]. 热能动力工程，2020，35(04)：203-209．

[50] XU C, CHEN H, XUN W, et al. Modal decomposition based ensemble learning for ground

中国知网 https://www.cnki.net

source heat pump systems load forecasting[J]. Energy and Buildings, 2019, 194: 62-74.

[51] NAIK J, DASH S, DASH P K, et al. Short term wind power forecasting using hybrid variational mode decomposition and multi-kernel regularized pseudo inverse neural network[J]. Renewable Energy, 2018, 118: 180-212.

[52] 陈锦鹏，胡志坚，陈纬楠，等．二次模态分解组合 DBiLSTM-MLR 的综合能源系统负荷预测[J/OL]．电力系统自动化：1-15[2020-03-30]．http://kns.cnki.net/kcms/detail/32.1180.TP.20210304.1409.006.html．

[53] 牛安敏，张宏立，王聪．基于 VMD-Leaky-ESN 的电力系统短期负荷多步预测方法[J]．新疆大学学报(自然科学版)(中英文)，2020，37(04)：562-569．

[54] 黄炜平．基于 EMD 和 BoF 模型的时间序列数据挖掘及应用[D]．杭州：浙江大学，2018．

[55] 王志建，张炜健，刘士杰．基于 EMD-GRU 循环神经网络的转向交通流量组合预测[J]．工业控制计算机，2020，33(12)：73-76．

[56] 姜贵敏，陈志军，李笑竹，等．基于 EEMD-ACS-LSSVM 的短期风电功率预测[J]．太阳能学报，2020，41(05)：77-84．

[57] 梁雪峰．基于 CEEMD 和 AFPSO-LSSVM 的空间负荷预测方法研究[D]．吉林：东北电力大学，2020．

[58] 焦博隆，钟志贤，刘翊馨，等．基于蝙蝠算法优化的变分模态分解的转子裂纹检测方法[J]．振动与冲击，2020，39(06)：98-103．

[59] 潘震，黄国勇，吴漫．基于参数优化 VMD 和增强多尺度排列熵的单向阀故障诊断[J]．振动与冲击，2020，39(15)：118-125．

[60] 刘建昌，权贺，于霞，等．基于参数优化 VMD 和样本熵的滚动轴承故障诊断[J/OL]．自动化学报：1-12[2021-03-27]．https://doi.org/10.16383/j.aas.190345．

[61] 陈义刚．基于 PSO 优化神经网络的配电网单相接地故障选线研究[D]．徐州：中国矿业大学，2020．

[62] BAHRAMI S, HOOSHMAND R, PARASTEGARI M. Short term electric load forecasting by wavelet transform and grey model improved by PSO (particle swarm optimization) algorithm[J]. Energy, 2014, 72: 434-442.

[63] HU Y, LI J, HONG M, et al. Short term electric load forecasting model and its verification for process industrial enterprises based on hybrid GA-PSO-BPNN algorithm-A case study of papermaking process[J]. Energy, 2019, 170: 1215-1227.

[64] XIE K, YI H, HU G, et al. Short-term power load forecasting based on Elman neural network with particle swarm optimization[J]. Neurocomputing, 2020, 416: 136-142.

[65] 魏腾飞，潘庭龙．基于改进 PSO 优化 LSTM 网络的短期电力负荷预测[J/OL]．系统仿真学报：1-8[2021-03-30]. http://kns.cnki.net/kcms/detail/11.3092.V.20200910.1734.013.html．

中国知网 https://www.cnki.net

[66] 陈鸿琳，李欣然，冷华，等．运用 PSO 和 GRNN 的短期负荷二维组合预测[J]．电力系统及其自动化学报，2018，30(02)：85-89．

[67] BEDI J, TOSHNIWAL D. Deep learning framework to forecast electricity demand[J]. Applied Energy, 2019, 238: 1312-1326.

[68] WANG Y, GAN D, SUN M, et al. Probabilistic individual load forecasting using pinball loss guided LSTM[J]. Applied Energy, 2019, 235: 10-20.

[69] 陆继翔，张琪培，杨志宏，等．基于 CNN-LSTM 混合神经网络模型的短期负荷预测方法[J]．电力系统自动化，2019，43(08)：131-137．

[70] KIM J, MOON J, HWANG E, et al. Recurrent inception convolution neural network for multi short-term load forecasting[J]. Energy and Buildings, 2019, 194: 328-341.

[71] CAI M, PIPATTANASOMPORN M, RAHMAN S. Day-ahead building-level load forecasts using deep learning vs. traditional time-series techniques[J]. Applied Energy, 2019, 236: 1078-1088.

[72] DEDINEC A, FILIPOSKA S, DEDINEC A, et al. Deep belief network based electricity load forecasting: An analysis of Macedonian case[J]. Energy, 2016, 115: 1688-1700.

[73] FU G. Deep belief network based ensemble approach for cooling load forecasting of air-conditioning system[J]. Energy, 2018, 148: 269-282.

[74] 岳有军，刘英翰，赵辉，等．基于 CEEMDAN-SE 和 DBN 的短期电力负荷预测[J]．电测与仪表，2020，57(17)：59-65．

[75] BOURDEAU M, ZHAI X Q, NEFZAOUI E, et al. Modeling and forecasting building energy consumption: A review of data-driven techniques[J]. Sustainable Cities and Society, 2019, 48: 101533.

[76] KIM Y, SON H, KIM S. Short term electricity load forecasting for institutional buildings[J]. Energy Reports, 2019, 5: 1270-1280.

[77] WANG H, LEI Z, ZHANG X, et al. A review of deep learning for renewable energy forecasting[J]. Energy Conversion and Management, 2019, 198: 111799.

[78] 程乐峰，余涛，张孝顺，等．机器学习在能源与电力系统领域的应用和展望[J]．电力系统自动化，2019，43(01)：15-31．

[79] 张乔榆，蔡秋娜，刘思捷，等．基于样本扩展和特征标记的节假日短期负荷预测[J]．广东电力，2019，32(07)：67-74．

[80] 王毅星．基于深度学习和迁移学习的电力数据挖掘技术研究[D]．杭州：浙江大学，2019．

[81] RIBEIRO M, GROLINGER K, ELYAMANY H F, et al. Transfer learning with seasonal and trend adjustment for cross-building energy forecasting[J]. Energy and Buildings, 2018, 165: 352-363.

中国知网 https://www.cnki.net

[82] QIAN F, GAO W, YANG Y, et al. Potential analysis of the transfer learning model in short and medium-term forecasting of building HVAC energy consumption[J]. Energy, 2020, 193: 116724.

[83] FAN C, SUN Y, XIAO F, et al. Statistical investigations of transfer learning-based methodology for short-term building energy predictions[J]. Applied Energy, 2020, 262: 114499.

[84] HUANG W, ZHANG D, SONG Z, et al. Short-term load forecasting based on similar day approach and intelligent algorithm using analytic hierarchy process: 2019 IEEE 3rd Information Technology, Networking, Electronic and Automation Control Conference[C]. Chengdu: IEEE, 2019: 2507-2512.

[85] SHEN Y, ZHANG J, LIU J, et al. Short-term load forecasting of power system based on similar day method and PSO-DBN: 2018 2nd IEEE Conference on Energy Internet and Energy System Integration [C]. Beijing: IEEE, 2018: 1-6.

[86] LIAO X, CAO N, LI M, et al. Research on Short-Term Load Forecasting Using XGBoost Based on Similar Days: 2019 International Conference on Intelligent Transportation, Big Data & Smart City [C]. Changsha: IEEE, 2019: 675-678.

[87] 常峰铭．基于深度学习的智能电网短期电力负荷预测研究[D]．湘潭：湘潭大学，2019．

[88] 原凯，李敬如，宋毅，等．区域能源互联网综合评价技术综述与展望[J]．电力系统自动化，2019，43(14)：41-52．

[89] WANG K, QI X, LIU H. Photovoltaic power forecasting based LSTM-Convolutional Network[J]. Energy, 2019, 189: 116225.

[90] 王伟亮，王丹，贾宏杰，等．考虑天然气网络状态的电力－天然气区域综合能源系统稳态分析[J]．中国电机工程学报，2017，37(05)：1293-1305．

[91] 张涌新，沈弘，马静．综合能源系统负荷特性分析及应用研究[J]．电力建设，2018，39(09)：18-29．

[92] 赵峰，孙波，张承慧．基于多变量相空间重构和卡尔曼滤波的冷热电联供系统负荷预测方法[J]．中国电机工程学报，2016，36(02)：399-406．

[93] ZHOU B, MENG Y, HUANG W, et al. Multi-energy net load forecasting for integrated local energy systems with heterogeneous prosumers[J]. International Journal of Electrical Power & Energy Systems, 2021, 126: 106542.

[94] 史佳琪，谭涛，郭经，等．基于深度结构多任务学习的园区型综合能源系统多元负荷预测[J]．电网技术，2018，42(03)：698-707．

[95] TAN Z, DE G, LI M, et al. Combined electricity-heat-cooling-gas load forecasting model for integrated energy system based on multi-task learning and least square support vector

中国知网 https://www.cnki.net

machine[J]. Journal of Cleaner Production, 2020, 248: 119252.

[96] 朱瑞金，郭威麟，龚雪娇．考虑天然气和电负荷之间相关性的短期电负荷预测[J]．电力系统及其自动化学报，2019，31(08)：27-32．

[97] 陈飞翔，胥建群，王晨杨，等．能源互联网系统用户侧冷热负荷预测模型研究[J]．中国电机工程学报，2015，35(14)：3678-3684．

[98] WANG S, WANG S, CHEN H, et al. Multi-energy load forecasting for regional integrated energy systems considering temporal dynamic and coupling characteristics[J]. Energy, 2020, 195: 116964.

[99] 赵凤展，郝帅，张宇，等．基于变分模态分解-BA-LSSVM 算法的配电网短期负荷预测[J]．农业工程学报，2019，35(14)：190-197．

[100] WANG Y, SUN S, CHEN X, et al. Short-term load forecasting of industrial customers based on SVMD and XGBoost[J]. International Journal of Electrical Power & Energy Systems, 2021, 129: 106830.

[101] 刘强，胡志强，周宇，等．基于 CEEMD 和随机森林算法的短期风电功率预测[J]．智慧电力，2019，47(06)：71-76．

[102] EL-HENDAWI M, WANG Z. An ensemble method of full wavelet packet transform and neural network for short term electrical load forecasting[J]. Electric Power Systems Research, 2020, 182: 106265.

[103] GUO Z, ZHAO W, LU H, et al. Multi-step forecasting for wind speed using a modified EMD-based artificial neural network model[J]. Renewable Energy, 2012, 37(1): 241-249.

[104] 邓带雨，李坚，张真源，等．基于 EEMD-GRU-MLR 的短期电力负荷预测[J]．电网技术，2020，44(02)：593-602．

[105] XUEHENG Q, PONNUTHURAI N S, GEHAN A J A. Ensemble incremental learning Random Vector Functional Link network for short-term electric load forecasting[J]. Knowledge-Based Systems, 2018, 145: 182-196.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

学位论文原创性声明

本人郑重声明：所呈交的学位论文《基于特征迁移学习与耦合关系挖掘的综合能源系统小样本日前负荷预测》，是本人在导师指导下，在中国矿业大学攻读学位期间进行的研究工作所取得的成果。据我所知，除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

年　月　日

中国知网 https://www.cnki.net

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
综合能源系统;日前负荷预测;特征提取；迁移学习；变分模态分解	公开	TM714	004.8	无

学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*
中国矿业大学	10290	专业学位	工程硕士

论文题名*	并列题名	论文语种*
基于特征迁移学习与耦合关系挖掘的综合能源系统小样本日前负荷预测	无	中文

作者姓名*	李家钊	学号*	TS18060176P31
培养单位名称*	培养单位代码*	培养单位地址	邮编
中国矿业大学	10290	江苏省徐州市	221116
学科专业*	研究方向*	学制*	学位授予年*
控制工程	综合能源负荷预测	三年	2021
论文提交日期*	2021 年 6 月		
导师姓名*	孙晓燕	职称*	教授

评阅人	答辩委员会主席*	答辩委员会成员
盲评	贾存良	魏彬、朱美强、王晔枫

电子版论文提交格式　文本（√）　图像（　）　视频（　）　音频（　）　多媒体（　）　其他（　）

推荐格式：application/msword; application/pdf

电子版论文出版（发布）者	电子版论文出版（发布）地	权限声明

论文总页数*	65

注：共 33 项，其中带*为必填数据，共 22 项。

中国知网　https://www.cnki.net