基于自适应 Transformer 的短期负荷预测域适应方法

周 俊,马泽菊

(重庆电力高等专科学校,重庆 400053)

摘 要: 有效的 STLF 对于当今电力系统的平稳运行至关重要。然而,传统的预测方法往往无法应对电力消费数据中的复杂性、非线性和动态变化,特别是在处理具有不同数据分布的新区域时。为了克服这些限制,提出了针对 STLF 的 ATDA。ATDA 利用 Transformer 编码器有效的建模时间依赖性,并结合带有重要性加权的部分对抗域适应策略,解决源域和目标域之间的差异。通过优先考虑与目标域最相关的源样本,ATDA 最小化了负迁移并提高了预测精度。在来自国家电网公司的真实数据上进行的综合实验表明,ATDA 在预测性能上显著优于当前领先的模型。

关键词: 短期负荷预测; 域适应; Transformer; 对抗学习; 重要性加权
中图分类号: TP181 文献标识码: A 文章编号: 1008-8032(2025)01-0001-06

电力支撑着现代社会的方方面面,为住宅、商业、工业、医疗和交通等领域提供动力。目前,电网系统集成了更多的分布式能源(DERs),并面临日益复杂的消费模式,使电网管理变得更加具有挑战性。应对这些挑战的核心是精确的短期负荷预测(STLF),即预测未来几分钟到几天的电力需求。精确的 STLF 对于平衡供需、优化资源配置和最小化运营成本至关重要[1]。平均绝对百分比误差(MAPE)提高 1%,能显著降低发电成本0.1% ~ 0.3%[2],凸显了精确的 STLF 对财务和基础设施风险的影响。

开发精确的 STLF 须基于历史负荷数据,这对于训练模型识别消费模式至关重要。此过程包括纠正缺失值和异常数据,以确保数据集的完整性。此外,整合其他相关因素的数据,如历史天气状况和事件数据,可以提高模型的准确性。这些输入变量通常有显著的地域特征,且受限于可用的设备,因此,在模型设计时需要仔细考虑。然而,收集数据时可能会遇到不完整的数据集、异常值和超过 5% 的缺失值等问题,这可能会影响预测精度。研究人员正在不断探索解决方案来应对这些挑战,以确保即使在非理想的数据条件下,模型也能保持稳健性。

传统的 STLF 包括统计模型和基本的机器学习算法,往往无法捕捉电力消费的非线性和动态特性[3]。虽然深度学习模型,特别是长短期记忆(LSTM)网络模型,在建模时间依赖性方面有所改进[4],但它们在跨不同数据分布的不同域应用时,往往难以泛化,进而导致普遍存在域偏移问题。

基于 Transformer 的模型,因其能够处理长程依赖性和复杂的时间模式,而不依赖于循环结构[5],已成为强大的替代方案。例如,Informer 和 Autoformer 等模型已经在时间序列预测任务中设定了新的基准[6-7]。然而,这些先进的模型在处理来自不同地区或时间段的数据时,由于域偏移,仍可能遇到困难。

对可再生能源的日益重视增加了负荷预测的复杂性。太阳能和风能发电固有的随机性,对公用事业公司在匹配负荷与这些可再生能源的可变产出方面提出了重大挑战。在这种情况下,精确的预测对于确保电网稳定性和高效能源管理更加关键。

对更精确的 STLF 的追求,涉及细致的数据准备,多个影响因素的整合,以及能够解决电力消费数据中固有的非线性、动态和域特定挑战的先进机器学习技术的应用。随着能源格局因可再生能源集成的演变,稳健且精确的 STLF 的重要性将继续增长,为电力公司提供可观的经济和运营效益。

为了解决这些挑战,提出了一种名为自适应 Transformer 域适应(ATDA)的新模型,并用于 STLF。ATDA 将 Transformer 编码器用于特征提取,并结合了带有重要性加权的部分对抗域适应机制。该方法使模型能够专注于与目标域最相关的源域样本,减轻异常样本引起的负迁移。

收稿日期: 2024-10-18
基金项目: 重庆市教委科技项目(KJZD-K202102601)。
作者简介: 周 俊(1998-),助教,研究方向为大数据与机器学习; 马泽菊(1982-),副教授,研究方向为智能电网新技术。

中国知网 https://www.cnki.net

1 相关研究

1.1 负荷预测中的域适应

域适应旨在将知识从源域转移到目标域，以解决域偏移问题[8]。对抗域适应方法即利用对抗训练来学习域不变的特征[9]。然而，如果源域包含目标域中不具代表性的异常样本，这一方法可能会引起负迁移。

1.2 STLF

传统的STLF包括统计学方法，如自回归积分滑动平均(ARIMA)和线性回归[3]。这些模型在捕捉电力消费数据中固有的非线性数据和复杂模式方面存在局限性。

机器学习模型，特别是深度学习模型，如LSTM网络模型，已被用于更有效地建模时间依赖性[4,10]。将LSTM与注意力机制或自编码器结合的混合模型，进一步提高了预测性能[11]。

基于Transformer的模型已成为时间序列预测的强大工具，因为它们能够在无循环结构的情况下建模长程时间依赖性[5-7]。然而，当跨不同域应用时，由于分布差异，这些模型仍面临挑战。

2 方法

2.1 问题描述

设 $D_s=\{(x_i^s,y_i^s)\}_{i=1}^{n_s}$ 表示标记的源域数据，其中 $x_i^s\in\mathbf{R}^{T\times D}$ 是长度为 T 的特征向量序列，$y_i^s\in\mathbf{R}$ 是对应的负荷值。同样，设 $D_t=\{x_j^t\}_{j=1}^{n_t}$ 表示未标记的目标域数据。源域和目标域具有不同的数据分布，分别为 $p_s(x)$ 和 $p_t(x)$。

基于此训练一个预测模型 $C(F(x))$，使其能够准确预测目标域的负荷值，其中 F 是特征提取器，C 是回归模型。该模型面临的挑战在于解决 $p_s(x)$ 和 $p_t(x)$ 之间的域偏移。

2.2 ATDA

2.2.1 概述

本文所提出的ATDA包括以下组件。

特征提取器(F)：一个Transformer编码器，从输入序列中提取时间特征。

负荷预测器(C)：一个回归模型，基于提取的特征预测负荷。

域分类器(D)：一个分类器，区分源域和目标域的特征，以指导适应过程。

通过将Transformer编码器与部分对抗适应机制相结合，ATDA可有效地捕捉复杂的时间模式并减轻域偏移。

2.2.2 用于特征提取的Transformer编码器

Transformer编码器依赖于自注意力机制，可在无循环结构连接的情况下建模长程时间依赖性。Transformer编码器包含以下4个重要组成。

输入表示：给定输入序列 $x=[x_1,x_2,\cdots,x_T]$，其中每个 $x_t\in\mathbf{R}^D$，需首先应用位置编码以融入时间顺序(其中 $\boldsymbol{PE}t$ 是位置 t 的编码向量)：

$$\tilde{x}_t=x_t+\boldsymbol{PE}t \tag{1}$$

自注意力机制：Transformer编码器使用多头自注意力来捕捉依赖性(其中 $\boldsymbol{Q}$、$\boldsymbol{K}$ 和 $\boldsymbol{V}$ 分别是查询、键和值的矩阵)：

$$\text{Attention}(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V})=\text{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\mathrm{T}}}{\sqrt{d_k}}\right)\boldsymbol{V} \tag{2}$$

编码：通过自注意力和逐位置前馈网络的堆叠层，结合层归一化和残差连接，获得编码表示。

特征表示：最终的特征表示通过平均编码序列获得(其中 z_t 是Transformer编码器在每个时间戳 t 的结果)。

$$z=F(x)=\frac{1}{T}\sum_{t=1}^{T}z_t \tag{3}$$

2.2.3 带有重要性加权的部分对抗域适应机制

梯度反转层：结合域分类器和通用前馈模型，建立了基于对抗网络的域适应方法[8]。其总体概念是既能有效进行负荷预测，又能在源域和目标域之间具有不变性的特征。这是通过最小化源数据的负荷预测LSTM的损失，同时最大化域分类器的损失来实现的。本质上，基于对抗网络的域适应模型类似于原始的生成对抗网络(GAN)，其最小最大损失形式：

$$\begin{aligned}\min_{F_s,F_t}\max_{D}(D,F_s,F_t)=&E_{x\sim p_s(x)}[\log D(F_s(x))]\\&+E_{x\sim p_t(x)}[\log(1-D(F_t(x)))]\end{aligned} \tag{4}$$

式中：F_s 和 F_t 分别表示源数据和目标数据的LSTM特征提取器，且 F_s 和 F_t 共享相同的权重；D 是二分类域分类器，所有源数据样本被标记为1，而所有目标数据样本被标记为0。采用常规的对抗学习方法来训练源负荷预测模型$C(F_s(x))$，用于STLF任务，这包括学习源和目标特征提取器及负荷预测模型 C 的参数。

域分类器：域分类器 D 预测域标签 $d\in\{0,1\}$，域分类损失 L_D 计算方法如下：

$$\begin{aligned}L_D=&-E_{x\sim p_s(x)}[\log D(\text{GRL}(F(x)))]\\&-E_{x\sim p_t(x)}[\log(1-D(\text{GRL}(F(x))))]\end{aligned} \tag{5}$$

重要性加权 $w(x)$：为了减少异常源样本引起的负迁移，需计算重要性权重。具体而言，当域分类器 D 针对当前的LSTM特征提取器优化时，输出 $D^{(z)}$ 表示样本来自源域的概率。如果 $D^{(z)}\approx1$，则表明样本包含源域的显著特征，且这些特征在目

中国知网 https://www.cnki.net

标域中不太可能出现。因此，这些在源域中的异常样本在对抗域适应中应被赋予较低的权重。相反，如果 $D(z) \approx 0$，则表示样本包含域不变特征，但与源域存在较大差异。在这种情况下，应赋予这些样本更高的重要性权重，以增强对抗域适应的性能。因此，权重函数应与 $D(z)$ 成反比，这为定义源样本的重要性权重函数提供了合理性。重要性权重的计算方式如下：

$$w(x) = \frac{1 - D(F(x))}{E_{x \sim p_s(x)}[1 - D(F(x))]} \tag{6}$$

训练目标：训练特征提取器 F 和负荷预测器 C 的总损失为

$$L_{\text{total}} = E_{(x,y) \sim p_s(x,y)}[w(x) \mid C(F(x)) - y \mid^2] + \lambda L_D \tag{7}$$

式中，参数 λ 控制预测准确性和域适应之间的权衡。

ATDA 整体结构见图 1。梯形 F_s、F_t 分别表示源域和目标域的基于 Transformer 的特征提取器。梯形 D 表示负责区分源域和目标域特征的域分类器。梯形 D_0 表示重要性加权的域分类器，它调整源样本以使其与目标域对齐。矩形 GRL 表示梯度反转层[8]，它在反向传播过程中反转梯度，促进域不变特征的学习。

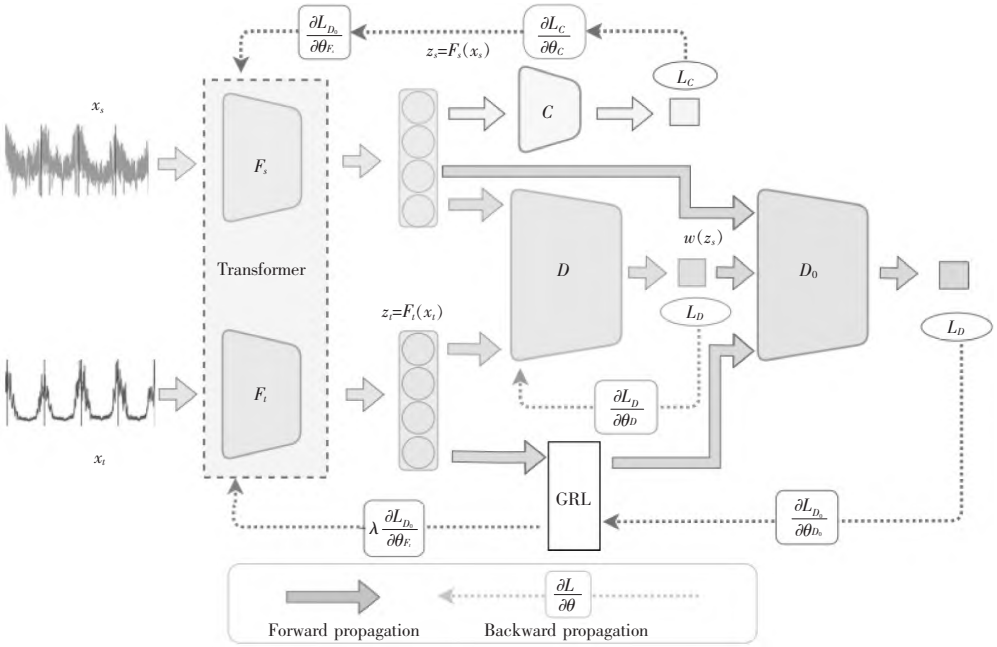


图 1　ATDA 整体结构

2.2.4　ATDA 训练算法

ATDA 训练算法见图 2。

Algorithm 1 ATDA 的训练算法

初始化 F、C 和 D 的参数
repeat
　从 $\mathcal{D}_s$ 中采样小批量 $\{(\mathbf{x}_i^s, y_i^s)\}_{i=1}^m$
　从 $\mathcal{D}_t$ 中采样小批量 $\{\mathbf{x}_j^t\}_{j=1}^n$
　通过最小化 $\mathcal{L}_D$ 更新 D：
　　计算 $D(\text{GRL}(F(\mathbf{x}_i^s)))$ 和 $D(\text{GRL}(F(\mathbf{x}_j^t)))$
　　计算 $\mathcal{L}_D$
　　使用梯度下降更新 D
　计算重要性权重：
　　对每个 $\mathbf{x}_i^s$，计算 $w(\mathbf{x}_i^s)$
　通过最小化 $\mathcal{L}_{\text{total}}$ 更新 F **和** C：
　　计算 $C(F(\mathbf{x}_i^s))$
　　计算 $\mathcal{L}_{\text{total}}$
　　使用梯度下降更新 F 和 C
until 收敛

图 2　ATDA 训练算法

2.3　理论分析

2.3.1　收敛性和误差界

将重要性加权与对抗训练相结合，可使 ATDA 专注于与目标域相似的源样本，从而减少域差异。这与域适应的理论基础一致[9]，其中目标误差由加权的源误差和域之间的差异界定。

2.3.2　计算复杂度

尽管 Transformer 编码器由于自注意力机制具有较高的计算复杂度，但其在建模长程依赖性和捕捉复杂模式方面的优势证明了其在 STLF 任务中的使用是合理的。

3　实验

3.1　数据来源

利用国家电网公司的真实数据集评估 ATDA。

SLF－A：来自某省的大规模数据集，包含多年

中国知网　https://www.cnki.net

的负荷数据。

SLF－B:来自某市的较小数据集,区域差异代表了不同的数据分布。

3.2 实验设置

3.2.1 数据预处理

使用最大最小归一化方式对负荷值进行处理。处理内容包括特征数据中的日期和季节等信息。

3.2.2 基准模型

将ATDA、ATDA(full)与以下模型进行比较。

LSTM:在源数据上训练的标准LSTM网络模型。

Informer:用于长序列预测的基于Transformer的模型。

Autoformer:具有自相关机制的高级Transformer模型。

CNN:卷积神经网络模型。

RNN:循环神经网络模型。

3.2.3 评估指标

使用的评估指标:平均绝对百分比误差(MAPE)、决定系数(R^2)、平均绝对误差(MAE)、均方根误差(RMSE)、平均绝对范围归一化误差(MARNE)。

3.2.4 超参数

Transformer模型参数包括4个注意力头,模型维度为64,还有2个编码器层。学习率设置为0.0001,λ设置为0.1。

3.3 讨论和结果

为了评估ATDA在解决域偏移和负迁移方面的效果,将LSTM、Informer、Autoformer等模型和ATDA进行了对比,并在SLF数据集上进行了完整的适应性实验。SLF－A表示模型在SLF－A(源域)上进行训练和评估的结果,以衡量其性能表现。而SLF－A→SLF－B则表示模型在SLF－A(源域)上训练,然后应用到SLF－B(目标域),以测试模型是否能有效应对域偏移问题,并最大限度地减少完全对抗性适应性带来的负迁移。实验结果见表1,从中可以得出以下结论。

1)相较于ATDA(full),ATDA更有效地解决了域偏移问题并减少了负迁移。ATDA在R^2、MAPE、MAE、RMSE和MARNE等评估指标上的表现均优于其他基线模型。ATDA与表现第二好的模型ATDA(full)相比,在R^2、MAPE、MAE、RMSE和MARNE等评估指标上,误差分别减少了0.13、2.3%、0.35、0.56和1.63%。这些结果突显了ATDA减轻完全对抗性域适应所引起的负迁移的能力。

2)当训练和测试数据相同时,Informer的性能最佳,但在SLF－B上表现下降。当在源数据SLF－A上训练并在SLF－A上测试时,Informer的R^2为0.61,MAPE为14.56%,MAE为0.36,RMSE为0.41,MARNE为8.06%。这些结果显示了Informer在较大数据集上的优势。然而,当将基于SLF－A训练的Informer应用于SLF－B时,其性能下降,R^2为－0.17,MAPE为36.79%,MAE为3.24,RMSE为4.74,MARNE为16.25%。这些差异表明SLF－A和SLF－B之间存在域偏移问题。

表1 ATDA和其他基线模型在STLF任务中的性能

Dataset	Metrics	LSTM	CNN	RNN	Informer	Autoformer	ATDA(full)	ATDA
SLF－A→SLF－B	R^2	－0.45	－0.78	0.70	－0.17	0.08	0.23	0.36
	MAPE/%	48.99	64.56	60.44	36.79	37.32	29.43	27.13
	MAE	6.13	10.36	8.71	3.24	3.04	1.54	1.19
	RMSE	6.72	11.67	8.73	4.74	4.08	2.37	1.81
	MARNE/%	24.64	34.66	30.44	16.25	15.91	15.72	14.09
SLA－A	R^2	－0.16	－0.26	－0.24	0.61	0.52	0.43	0.39
	MAPE/%	23.43	30.41	28.56	14.56	15.52	19.12	19.68
	MAE	0.63	2.55	2.13	0.36	0.35	0.51	0.56
	RMSE	0.74	3.43	3.41	0.41	0.47	0.57	0.62
	MARNE/%	14.35	19.62	17.72	8.06	8.64	11.92	12.36

3.4 结果可视化

图3为特征分布的t－SNE可视化,展示了ATDA如何对齐源域和目标域之间的特征分布。图3(a)显示了域适应之前的特征分布,其中源域特征和目标域特征之间有明显的分离,这表明存在显著的域偏移。如图3(b)所示,在应用ATDA后源域特征已有效地与目标域特征对齐,两个域之间的重叠明显增多。这种对齐表明ATDA使源域特征更加接近目标域特征,有效减少了域差异,从而提高了模型对新的、未见过的目标域数据的泛化能力。这个结果突显了ATDA通过聚焦于域不变特征来减轻负迁移并提高预测精度的能力。

中国知网 https://www.cnki.net

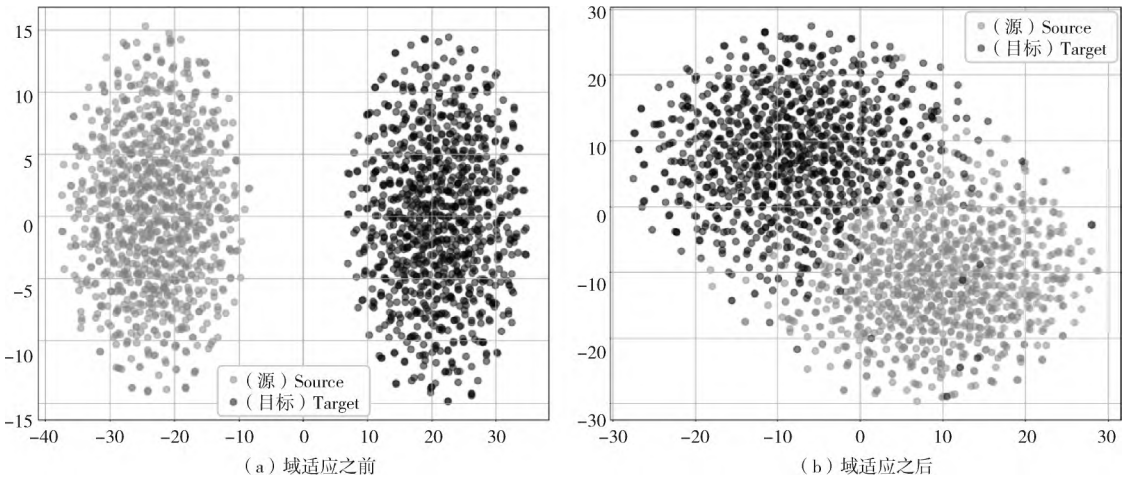


图 3　特征分布的 t－SNE 可视化

图 3 包含了数据集中随机 10 d 真实的功率消耗的预测结果，以及真实功率消耗与 3 个模型（LSTM、Autoformer、ATDA）的预测结果。

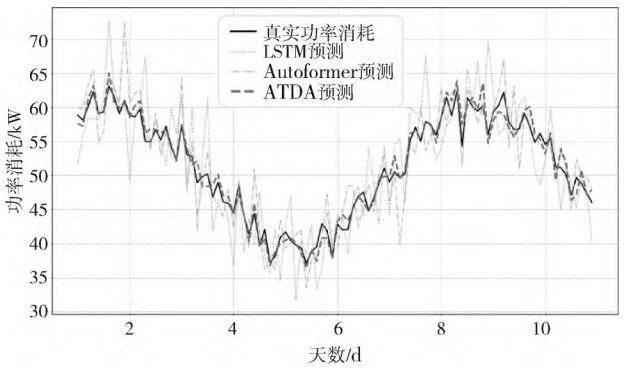


图 4　功率消耗预测与真实值对比

1）实线表示带有自然波动的真实功率消耗，使其更具动态性和现实感。

2）点虚线表示 LSTM 预测，显示出较高的偏差和噪声。

3）点线虚线表示 Autoformer 预测，虽然有一定改进，但仍存在一些波动。

4）粗虚线表示 ATDA 预测，与真实功率消耗非常接近，预测结果更加平滑且准确。

该图展示了 ATDA 在捕捉功率消耗的周期性模式和内在波动方面的有效性，在这一情境下优于其他模型。

4　总结

本文提出了用于 STLF 的 ATDA，它基于 Transformer 的特征提取并与部分对抗域适应相结合。理论分析和大量实验结果表明，ATDA 优于现有模型。ATDA 利用 Transformer 的强大建模能力来提取时间序列中的关键特征，并通过对抗训练机制，将源域和目标域之间的特征分布差异最小化。在此基础上，ATDA 进一步引入了重要性加权机制，选择性地适应那些与目标域特性相似的源域样本，有效减轻了域偏移问题对模型性能的影响。

从理论上看，ATDA 能够在保证模型稳定性的前提下，有效处理源域和目标域之间的分布差异，确保模型在不同环境下的鲁棒性和泛化能力。大量实验结果表明，ATDA 在多个真实世界的数据集上均表现出了显著的性能优势，相比于 STLF，不仅提高了预测准确性，还降低了模型对域偏移的敏感性。

未来，将在以下两个方向上进一步拓展 ATDA 的应用潜力。首先，整合更多样化的数据类型，如天气、社会经济等外部因素，以增强模型对复杂环境变化的适应性。此外，研究如何在更大的域偏移条件下扩展该模型，使其在更广泛的应用场景中保持同样的高效性和可靠性。通过这些改进，期望 ATDA 能够在智能电网和能源管理等领域中，发挥出更强的预测能力。

参考文献：

[1] 王栋. 电力系统负荷预测综述 [J]. 电气开关，2020，58（1）：6－8，20.

[2] GAO W，DARVISHANA，TOGHANI M，et al. Different states of multi-block based forecast engine for price and load prediction [J]. International Journal of Electrical power & Energy Systems，2019（104）：423－435.

[3] WEI N，LI C，PENG X，et al. Conventional models andartificial intelligence-based models for energy consumption forecasting：A review [J]. Journal of Petroleum Science and Engineering，2019（181）：106187.

[4] DUAN Y. A novel interval energy-forecasting method for sustainablebuilding management based on deep learning [J]. Sustainability，2022，14（14）：8584.

[5] VASWANIA，SHAZEERN，PARMARN，et al. Attention is all you need [C] //Advances in neural information processing systems，2017（30）：6000－6010.

中国知网　https://www.cnki.net

[6] ZHOU H,ZHANG S,PENG J,et al. Informer: Beyond efficient transformer for long sequence time-series forecasting [C] //AAAI conference on artificial intelligence, 2021,35(12):11106 - 11115.

[7] WU H,XU J,WANG J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting [J]. Neural information processing systems, 2021(34):22419 - 22430.

[8] GANIN Y,LEMPITSKY V. Unsupervised domain adaptation by back propagation [C] //International conference on machine learning. PMLR,2015:1180 - 1189.

[9] TZENG E,HOFFMAN J,SAENKO K,et al. Adversarial discriminative domain adaptation [C] //IEEE conference oncomputer vision and pattern recognition,2017:7167 - 7176.

[10] ZANG H,XU R,CHENG L,et al. Residential load forecasting based on LSTM fusing self-attention mechanism with pooling [J]. Energy, 2021(229):120682.

[11] FAZLIPOUR Z, MASHHOUR E, JOORABIAN M. A deep model for short term load forecasting applying a stacked autoencoder based on LSTM [J]. Applied Energy, 2022(326):120063.

A Study on the Domain Adaptation Method for Short-Term Load Forecasting Based on the Self-Adaptive Transformer

ZHOU Jun,MA Zeju

(Chongqing Electric Power College,Chongqing 400053,P. R. China)

Abstract: An effective STLF is essential for the smooth operation of the power system. However,traditional forecasting methods often fail to cope with the complexity,non-linearity and dynamic changes in electricity consumption data,especially when dealing with new domains with different data distributions. To overcome these limitations,this paper proposes an ATDA for the STLF,which uses the Transformer encoder to effectively model time dependence and resolve differences between source and target domains in combination with the partial adversarial domain adaptation strategy with importance weighting. By prioritizing source samples that are most relevant to the target domain,the ATDA minimizes negative migrations and improves the forecasting accuracy. Comprehensive experiments on real data from State Grid Corporation of China show that the ATDA significantly outperforms current leading models in forecasting performance.

Key words: short-term load forecasting; domain adaptation; Transformer; adversarial learning; STLF; importance weighting

中国知网 https://www.cnki.net