学号：2021110068　　密级：



东华理工大学

EAST CHINA UNIVERSITY OF TECHNOLOGY

硕士学位论文

（学术学位）

基于迁移学习和模糊系统的短期电力负荷预测方法研究

姓　　名：　李秋琰

专 业 名 称：　数学

研 究 方 向：　智能计算及应用

指 导 教 师：　颜七笙（教授）

培 养 学 院：　理学院

二〇二四年六月

中国知网　https://www.cnki.net



Dissertation for master's degree

Research on short-term power load forecasting method based on transfer learning and fuzzy system

A Dissertation Submitted to

East China University of Technology

In Fulfillment of the Requirement

For the Degree of

Master of Science

By

Qiuyan Li

Supervised by

Professor Qisheng Yan

East China University of Technology

June 2024

中国知网 https://www.cnki.net

东华理工大学硕士学位论文中文摘要首页用纸

毕业论文题目：基于迁移学习和模糊系统的短期电力负荷预测方法研究

数学 专业 2021 级硕士生姓名：李秋琰

指导教师（姓名、职称）：颜七笙 (教授)

摘 要

电力负荷预测是电力系统平稳、高效运行的基础。准确的电力负荷预测有利于保障电力系统的安全、节约资源、降低成本、进行电力管理和实施经济调度计划。由于在数据采样和储存过程中存在设备故障等问题，电力负荷数据易存在缺失值，导致传统电力负荷预测方法的预测精度较低。因此，本文基于迁移学习的思想，在 TSK 迁移模糊系统(TSK-TFS)的基础上结合变分模态分解(VMD)、迁移成分分析(TCA)和改进斑马优化算法(IZOA)提出了一种智能短期电力负荷预测模型(VMD-TCA-IZOA-TFS)。本文的主要研究内容和成果如下：

(1) 以欧洲两个城市的电力负荷和相关因素数据为基础，将其分为源域和目标域，其中目标域数据分为目标域训练数据和目标域测试数据，利用最小样本熵确定 VMD 分解序列的个数，并将源域和目标域进行分解得到若干子序列。

(2) 为了得到准确的电力负荷预测值，首先采用斑马优化算法(ZOA)对 TSK-TFS 模型的参数进行寻优，降低模型可调参数对预测性能的影响；其次将源域的子序列代入 TSK 模糊系统(TSK-FS)得到源域后件参数，将源域后件参数作为有效信息迁移至目标域的预测中，同时将目标域训练数据作为 TSK-FS 的输入并得到目标域后件参数；最后利用源域和目标域后件参数经过计算得到目标域测试数据子序列的预测值，将其叠加得到短期电力负荷的预测结果。仿真结果表明，相比于 TFS、FS 及其它组合模型，VMD-ZOA-TFS 模型的预测精度更高。

(3) 为了进一步提升模型的预测精度，首先采用莱维飞行策略和防御阶段切换概率调整对斑马优化算法(ZOA)进行改进，选取基准函数对 IZOA 进行测试并与 ZOA 算法和粒子群算法(PSO)进行对比，结果表明 IZOA 算法的收敛速度和搜索能力均优于 ZOA 算法和 PSO 算法；其次引入 TCA 减小源域和目标域距离的同时对数据进行降维；最后构建 VMD-TCA-IZOA-TFS 模型对短期电力负荷进行预测，同时构建基于 LSTM 与 VMD、TCA、IZOA 的组合模型进行对比实验。仿真结果表明，相比于 LSTM、VMD-ZOA-TFS 及其他组合模型，VMD-TCA-IZOA-TFS 短期电力负荷预测模型的预测精度得到进一步提高，除此之外，通过 DM 检验等方法进一步证实了该模型具有较优的预测性能。

中国知网 https://www.cnki.net

关键词：短期电力负荷预测，TSK 模糊系统，迁移学习，变分模态分解，迁移成分分析，改进斑马优化算法

中国知网 https://www.cnki.net

东华理工大学硕士学位论文英文摘要首页用纸

THESIS：Research on short-term power load forecasting method based on transfer learning and fuzzy system

SPECIALIZATION: Applied Mathematics
POSTGRADUATE: Qiuyan Li
MENTOR: Qisheng Yan(Professor)

ABSTRACT

Power load forecasting is the foundation for the stable and efficient operation of the power system. Accurate power load forecasting is beneficial for ensuring the safety of the power system, saving resources, reducing costs, conducting power management, and implementing economic dispatch plans. Due to equipment failures and other issues during data sampling and storage, power load data is prone to missing values, resulting in lower prediction accuracy of traditional power load prediction methods. Therefore, based on the idea of transfer learning, this article proposes an intelligent short-term power load forecasting model (VMD-TCA-IZOA-TFS) by combining Variational Mode Decomposition (VMD), Transfer Component Analysis (TCA), and Improved Zebra Optimization Algorithm (IZOA) on the basis of TSK Transfer Fuzzy System (TSK-TFS). The main research contents and achievements of this paper are as follows:

(1) Based on the electricity load and related factor data of two European cities, they are divided into source domain and target domain. The target domain data is divided into target domain training data and target domain testing data. The minimum sample entropy is used to determine the number of VMD decomposition sequences, and the source domain and target domain are decomposed to obtain several subsequences.

(2) In order to obtain accurate power load prediction values, firstly, the Zebra Optimization Algorithm (ZOA) is used to optimize the parameters of the TSK-TFS model, reducing the impact of adjustable parameters on prediction performance; Secondly, the subsequences of the source domain are substituted into the TSK fuzzy system (TSK-FS) to obtain the source domain consequent parameters. The source domain consequent parameters are transferred as effective information to the prediction of the target domain, and the target domain training data is used as input to TSK-FS to obtain the target domain consequent parameters; Finally, the predicted values of the test data subsequence in the target domain are calculated using the posterior parameters of source domain and the target domain, and they are superimposed to obtain the short-term power load prediction results. The simulation

中国知网 https://www.cnki.net

results show that compared to TFS, FS, and other combination models, the VMD-ZOA-TFS model has higher prediction accuracy.

(3) In order to further improve the prediction accuracy of the model, firstly, the Zebra Optimization Algorithm (ZOA) is improved using the Lévy flight strategy and defense phase switching probability adjustment. Benchmark functions are selected to test the IZOA and compared with the ZOA algorithm and Particle Swarm Optimization (PSO). The results show that the convergence speed and search ability of the IZOA algorithm are better than those of the ZOA and PSO algorithms; Secondly, TCA is introduced to reduce the distance between the source and target domains while reducing the dimensionality of the data; Finally, the VMD-TCA-IZOA-TFS model is constructed to predict short-term power load, and a combined model based on LSTM and VMD, TCA, and IZOA is constructed for comparative experiments. The simulation results show that compared to LSTM, VMD-ZOA-TFS, and other combination models, the prediction accuracy of the VMD-TCA-IZOA-TFS short-term power load prediction model is further improved. In addition, DM testing and other methods further confirm that the model has better predictive performance.

Keywords: Short-term power load forecasting, tsk fuzzy system, transfer learning, variational mode decomposition, transfer component analysis, improved zebra optimization algorithm

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究综述.....1
1.2.1 基于数学统计方法的电力负荷预测.....2
1.2.2 基于机器学习方法的电力负荷预测.....2
1.2.3 基于组合模型的电力负荷预测.....3
1.2.4 基于模糊系统的电力负荷预测.....4
1.3 研究内容及论文框架.....5
1.4 技术路线.....7
第 2 章 短期电力负荷预测及相关方法概述.....9
2.1 短期电力负荷分析.....9
2.1.1 短期电力负荷的特性.....9
2.1.2 短期电力负荷的影响因素.....11
2.1.3 短期电力负荷的步骤.....12
2.2 数据处理算法.....13
2.2.1 经验模态分解.....13
2.2.2 集合经验模态分解.....14
2.2.3 变分模态分解.....14
2.2.4 最小样本熵.....15
2.3 聚类算法.....16
2.3.1 模糊 C 均值聚类.....16
2.3.2 减法聚类.....17
2.4 迁移成分分析算法.....18
2.5 斑马优化算法.....19
2.6 模糊系统.....20
2.6.1 TSK 模糊系统.....21
2.6.2 TSK 迁移模糊系统.....24
2.7 长短期神经网络.....28
第 3 章 基于 VMD-ZOA-TFS 短期电力负荷预测方法研究.....31
3.1 电力负荷数据获取与预处理.....31
3.1.1 数据获取.....31
3.1.2 数据统计特征.....32
3.1.3 数据预处理.....32
3.2 评价指标.....33

中国知网 https://www.cnki.net

3.3 基本步骤与建模流程.....33
3.4 仿真实验.....34
3.5 模型对比与分析.....37
3.6 本章小结.....39
第 4 章 基于 VMD-TCA-IZOA-TFS 短期电力负荷预测方法研究 ..41
4.1 IZOA 算法及测试.....41
4.1.1 IZOA 算法.....41
4.1.2 IZOA 算法测试.....42
4.2 基本步骤与建模流程.....48
4.3 仿真实验.....49
4.3.1 对比实验 1.....49
4.3.2 对比实验 2.....51
4.4 模型验证.....53
4.4.1 DM 检验和 HLN 检验.....54
4.4.2 MCS 检验.....55
4.4.3 改善率.....57
4.5 本章小结.....58
第 5 章 总结与展望.....61
5.1 总结.....61
5.2 展望.....61
参考文献.....62

中国知网 https://www.cnki.net

附表

表 2.1 经典模糊系统对应的模糊规则 21
表 2.2 迁移学习分类 25
表 3.1 原始数据的统计特性 32
表 3.2 各个模型的统计指标值 39
表 4.1 测试函数 42
表 4.2 IZOA、ZOA 和 PSO 在目标函数上测试结果 44
表 4.3 对比实验 1 中模型的统计指标值 51
表 4.4 对比实验 2 中各个模型的统计指标值 52
表 4.5 各个模型的 DM 和 HLN 指标 55
表 4.6 各个模型的 MCS 检验 p 值 57
表 4.7 各个模型与 VMD-TCA-IZOA-TFS 的敏感度 58

插图

图 1.1 电力负荷预测分类 2
图 1.2 研究框架及技术路线 7
图 2.1 连续 3 日的电力负荷序列 9
图 2.2 连续两周的电力负荷序列 10
图 2.3 每个季节中某一日的电力负荷序列 10
图 2.4 连续 6 日的电力负荷序列 11
图 2.5 不同日期类型电力负荷序列 12
图 2.6 斑马优化算法流程图 20
图 2.7 模糊系统的结构 21
图 2.8 传统机器学习和迁移学习模型对比 25
图 2.9 LSTM 循环结构图 29
图 3.1 LV 电力负荷原始数据 31
图 3.2 EE 电力负荷原始数据 32
图 3.3 VMD-ZOA-TFS 模型流程图 34
图 3.4 不同分解个数对应的最小样本熵 35
图 3.5 VMD 电力负荷分解序列图 35
图 3.6 EEMD 电力负荷分解序列 36
图 3.7 VMD 分解的差值 36

中国知网 https://www.cnki.net

图 3.8 EEMD 分解的差值.....37
图 3.9 对比实验预测结果和误差箱线图.....38
图 4.1 莱维飞行策略与随机初始化种群.....41
图 4.2 基准函数和收敛迭代图.....48
图 4.3 VMD-TCA-IZOA-TFS 模型流程图.....49
图 4.4 各个模型的预测值与真实值对比图.....50
图 4.5 各个模型的误差箱线图.....50
图 4.6 VMD-TCA-IZOA-LSTM 模型的流程图.....52
图 4.7 各个模型的预测值与真实值的对比.....53
图 4.8 各个模型的误差箱线图.....53

专用术语注释表

缩略词	含义
ZOA	斑马优化算法
IZOA	改进斑马优化算法
TCA	迁移成分分析
TSK-TFS	0 阶 L2 型 TSK 迁移模糊系统
TSK-FS	0 阶 L2 型 TSK 模糊系统
EMD	经验模态分解
EEMD	集合经验模态分解
VMD	变分模态分解
FCM	模糊 C 均值聚类
LSTM	长短期神经网络
LV	拉托维亚
EE	爱沙尼亚
MAPE	平均绝对百分比误差
MAE	平均误差
RMSE	均方根误差

中国知网 https://www.cnki.net

第1章 绪论

1.1 研究背景及意义

随着经济的不断发展，人类生活水平不断提高、能源消耗不断增加，而传统化石能源消耗对环境产生消极影响,对人类的生存环境构成巨大的威胁。在此背景下，“双碳”政策应运而生，为响应号召，我国的能源供给和消耗逐渐从石油、煤炭等不可再生的化石能源转向太阳能、风能等可再生的新能源[1]，能源供给方式的转换使得电网结构以及运行方式逐渐多元化，且太阳能、风能易受到天气等多方面的影响，导致电力负荷波动越来越大，负荷特性越来越复杂，加大了电网调峰、调频和安全稳定运行的难度，这给电力负荷的预测带来了更大的挑战[2]。

电能是由其它形式的能量转化而来，后通过传输进入实际用电终端，从电能的产生、运输到使用均需要电力系统的参与，若电能不足，则会影响社会的正常运转；若电能过剩，则需要另外投入成本将其储存，因此需要均衡电能的需求和供给，以减少供需不均衡造成的电力浪费和电力不足。精准的电力负荷预测可以更好地控制电网中发电组的启动和停止，为转运业务中电力的容量提供依据，实现更准确地电力调度。同时精确的电力负荷预测值可以确定本地区需要投入的发电机组的数量，避免建立多余的发电组，因此有利于降低成本，制定合理的计划，进而安全、稳定和高效地运行电力系统。

此外，对电力负荷进行预测有利于降低发电产生的污染。据统计，截止 2023 年 11 月底，我国火力发电量占全国发电量的 69.4%，火力发电仍然占据主导地位，尽管在发电过程中会采取各种环保措施，但污染仍然是一个不可忽视的问题。精准的电力负荷预测可以让电力公司得到较为精确的电能数值，从而减少火电厂产生的污染。

随着人工智能理论和方法的发展，基于机器学习的电力负荷预测模型成为研究热点[3]，利用神经网络模型、智能优化算法和信号分解等方法融合而成的电力负荷预测模型取得了较好的预测效果[4-6]。依赖计算机读取和储存等功能，可以更加简捷地获取电力负荷和气象数据，这为模型的运行提供了数据支撑。然而面对数据缺失的情况下，传统电力负荷预测方法的预测性能有所下降，而迁移学习可以将历史场景的有效信息迁移至当前场景中，降低数据缺失对模型预测性能的影响。因此，构建一种基于迁移学习策略的电力负荷预测方法具有重要的研究价值和应用价值。

1.2 国内外研究综述

图 1.1 展示了电力负荷预测的分类，按照时间尺度电力负荷预测可分为长期、中期、短期和超短期四类[7]。长期是未来 5 年以上；中期是未来 1 至 5 年；短期是未来 1 年内；超短期是未来几分钟或几个小时。按照预测方法分类，电力负荷预测可以分为数学统计方法、机器学习方法和组合模型方法[8]。

中国知网 https://www.cnki.net

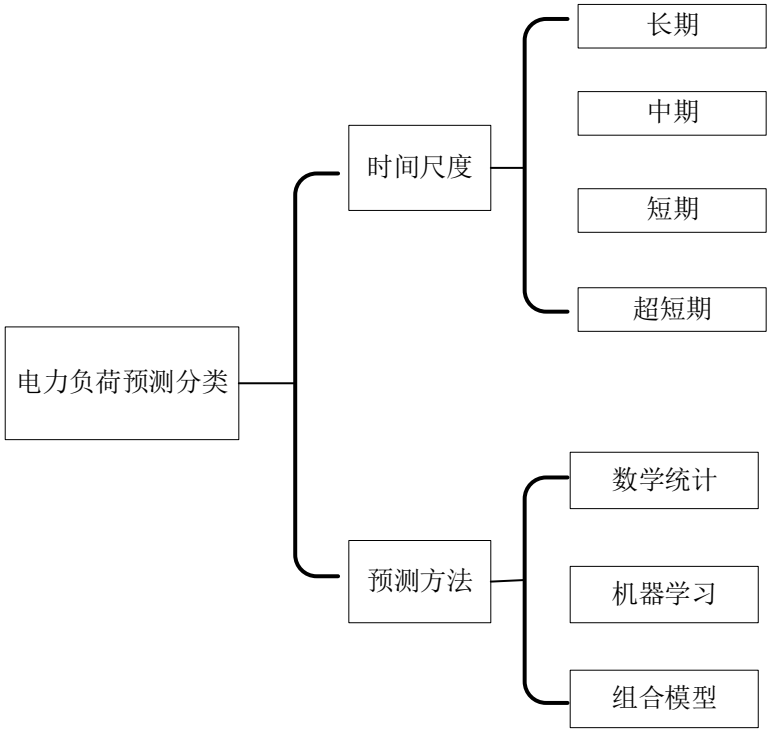


图 1.1 电力负荷预测分类

Figure 1.1 Classification of power load forecasting

1.2.1 基于数学统计方法的电力负荷预测

数学统计方法大多以基础数学工具为主，其中回归分析法是通过观察自变量和因变量之间的关系，建立两者之间的数学联系，从而将关系具体化，进而清晰地看出因变量受到自变量的影响情况[9]。文献[10]首先通过引入虚拟变量描述负荷日期因素上的变化规律；其次引入温度近因效应，即把滞后时温度和 24h 移动平均温度引入模型中；最后利用温度、日期因素与负荷的关系建立多元线性回归模型，仿真实验表明模型取得了较高的预测精度。文献[11]针对节假日数据量少且时间跨度大的问题，提出了针对不同节假日类型建立卡尔曼滤波的短期电力负荷预测模型。文献[12]首先对数据进行处理；其次利用密度聚类算法(Density-Based Spatial Clustering of Applications with Noise, DBSCAN)对负荷序列聚类并提出噪声点，利用自回归差分移动平均模型(Autoregressive Integrated Moving Average Model, ARIMA)分解负荷序列；最后重构分解序列并利用历史信息对未来进行预测。基于数学统计方法的电力负荷预测虽然结构简单，计算复杂度相对较低，但对于非线性和波动性较强的短期电力负荷序列拟合效果较差。

1.2.2 基于机器学习方法的电力负荷预测

随着人工智能的发展，机器学习方法逐渐成为研究热点。文献[13]利用最小二乘支持向量机(Least Squares Support Vector Machines, LS-SVM)对短期电力负荷进行预测，仿真结果表明该模型的预测精度较高。文献[14]首先利用时间序列编码的方法从训练集中选出与测试集相似的负荷数据；其次将选择出的负荷数据输入极限学习机(Extreme

中国知网 https://www.cnki.net

Learning Machine, ELM)中进行训练和预测；最后得到预测结果，实验结果显示该模型具有较高的预测精度和适应性。文献[15]针对负荷聚类需人工参与特征提取和负荷的非线性的问题，首先利用长短期神经网络(Long Short-Term Memory, LSTM)和自动编码器提取时序特征和非线性降维；其次利用 K 均值聚类算法(K-means Clustering Algorithm, KNN)对电力负荷序列聚类；最后训练模型得到预测结果。文献[16]利用门控循环单元(Gated Recurrent Unit, GRU)对短期电力负荷进行预测，并与循环神经网络(Recurrent Neural Network, RNN)进行对比，实验结果表明 GRU 模型的预测性能更优。基于机器学习方法虽然可以提升模型的预测性能以及运算速度，但模型中的可调参数仍会对模型的预测效果产生影响。

1.2.3 基于组合模型的电力负荷预测

针对神经网络中可调参数对模型预测性能的影响，文献[17]采用自适应柯西变异粒子群算法(Adaptive Cauchy Mutation Particle Swarm Optimization, ACMPSO)对 LSTM 中可调参数进行寻优，提高了模型的预测性能。文献[18]利用混沌函数改进鲸鱼优化算法(Chaos Whale Algorithm, CWOA)，然后利用混沌鲸鱼优化算法对 ELM 的参数寻优。文献[19]利用粒子群算法(Particle Swarm Optimization, PSO)对 LS-SVM 的参数寻优，与单个模型相比，利用优化算法对模型的可调参数进行寻优可以得到更高的预测精度。

针对负荷序列非线性对模型精度的影响，采取信号分解策略可以降低序列的非线性性，提高模型的预测性能。信号分解策略主要简述以下几种：

(1) 经验模态分解

经验模态分解(Empirical Mode Decomposition, EMD)以傅里叶变换为基础，根据数据自身的时间尺度特征进行信号分解，降低序列的非线性和非平稳性。文献[20]首先将预处理后的原始电力负荷数据利用 EMD 分解为若干子序列；其次将分解后的序列输入 LSTM 中进行预测，同时利用层标准化(Layer Normalization, LN)优化网络模型；最后将各分量预测结果叠加得到电力负荷预测值。文献[21]首先利用 EMD 将负荷序列分解为若干子序列；其次采用多尺度卷积神经网络(Convolutional Neural Network, CNN)结合 LSTM 建立模型并对子序列进行预测；最后将子序列的预测结果组合得到预测结果。

(2) 集合经验模态分解

集合经验模态分解(Ensemble Empirical Mode Decomposition, EEMD)是一种利用噪声辅助的数据分解方法，EEMD 有效地解决了 EMD 的混频现象。文献[22]针对负荷序列的非线性问题，首先利用 EEMD 将序列分解为高频、低频和随机分量；其次利用布谷鸟搜索(Cuckoo Search, CS)算法优化 LS-SVM 的关键参数，并利用 LS-SVM 对各分量进行预测；最后将预测结果相加即可得到短期电力负荷的预测值。文献[23]首先利用 EEMD 对原始电力负荷分解，引入排列熵(Permutation Entropy, PE)区分各个分量的复杂性，并重构具有相似熵的分量得到新的子序列；其次采用 Spearmann 秩相关系数确定新子序列的最优特征集，利用贝叶斯优化算法(Bayesian Optimization Algorithm, BOA)优化

中国知网 https://www.cnki.net

LSTM 中的超参数，并利用 LSTM 模型对新子序列进行预测；最后将各分量预测结果叠加得到电力负荷预测值，仿真实验表明经过分解后的电力负荷序列提升了模型的预测性能。

(3) 变分模态分解

变分模态分解(Variational Mode Decomposition, VMD)是一种自适应、完全非递归的信号分解方法，可以较好地抑制模态混叠现象。张未等[24]利用 VMD 将负荷数据分解，对各个子序列利用 LSTM 进行单特征预测，再将各个分量联合天气等特征数据利用轻量级梯度提升机(Light Gradient Boosting Machine, LightGBM)进行负荷预测，仿真实验结果表明经过 VMD 分解后得到的预测结果更精确。文献[25]利用 VMD 将电力负荷序列分解为若干子序列；其次使用极限梯度提升(eXtreme Gradient Boosting，XGBoost)、LSTM、支持向量机(Support Vector Machine, SVM)和 k 近邻作为基本模型对各分量进行预测；最后通过 Stacking 集成学习方法得到电力负荷的预测值，仿真实验表明该模型显著提高了预测精度。

针对数据量不足导致模型预测性能下降的问题，迁移学习可以较好地解决。迁移学习在 1995 年被提出，不同的学者对其表述不同，主要的表述有：学习引导学习、终身学习、知识迁移、归纳迁移、上下文敏感学习等[26]。迁移学习是将历史场景中的信息迁移至当前场景中，从而解决当前场景中的问题。针对电力负荷数据缺失的问题，迁移学习能够从源域数据中得到有效的信息，从而将其迁移至目标域数据中，有效地解决了目标域信息缺失的问题。针对目标域数据不足导致模型训练不充分的问题，欧阳福莲等[27]首先利用 CNN 提取特征；其次将特征作为双向长短期网络(Bidirectional Long Short-Term Memory, Bi-LSTM)的输入，并引入注意力机制调节权重，利用源域数据训练模型并保留每层最优的训练权重；最后利用目标域数据对模型进行微调并得到预测值。孙晓燕等[28]首先根据源域数据利用聚类算法和 GRU 构建提取特征和分类模型；其次利用该模型对目标域中小样本进行提取特征并分类，融合样本相似度和时间遗忘因子；最后根据融合特征和迁移学习策略对目标域中的电力负荷进行预测，仿真实验证实了迁移学习的有效性。姜建国等[29]利用参数迁移方法结合 1DCNN-LSTM 对短期电力负荷进行预测，仿真实验表明在数据缺失的情况下，迁移学习可以有效地提升模型的预测精度。文献[30]针对数据量不足的问题，提出了基于两层迁移学习的短期电力负荷预测模型，首先在内层引入潜在参数表示导致两个地域差异的潜在因素；其次将潜在参数作为额外输入，建立潜在参数辅助模型；最后利用数据集对潜在参数辅助模型的适应度，将变量权重分配给数据集。仿真实验表明，迁移学习策略提升了经典短期电力负荷预测模型的预测精度。

1.2.4 基于模糊系统的电力负荷预测

数学统计和机器学习方法已广泛应用于电力负荷预测，由于机器学习生成的模型是黑箱，很难对其进行解释，而模糊系统具有可解释性和很强的非线性逼近能力。I-型模糊集合(Type-l Fuzzy Set, T1-FS)[31]最早由 Zadeh 教授于 1965 年提出，模糊集合论的提

中国知网 https://www.cnki.net

出使计算机突破了无法处理模糊概念的禁锢。Zadeh 教授[32]于 1975 年提出 II-型模糊集合(Type-2 Fuzzy Set, T2-FS)的概念，增强了集合的模糊性，进而提高了处理不确定性问题的能力。由于模糊系统可以将复杂的模糊问题清晰化，其生成的模糊规则是可以被读懂的 IF-THEN 语句，因此模糊系统具有天然的可解释性。当数据缺失或数据定义不明确时，TSK 模糊系统可以较好地处理此类问题[33]。文献[34]和文献[35]利用 TSK 模糊系统对癫痫脑电信号进行识别。文献[36]利用 0 阶 TSK 模糊系统对不平衡数据进行分类。文献[37]利用区间二型 TSK 模糊逻辑算法结合高效数据融合技术，提升了数据在无线传感网中的传输效率。文献[38]利用 TSK 模糊系统结合功能连接之间的关联信息建立模型，仿真实验表明该模型可以很好地作为自闭症的辅助诊断。上述工作均基于 TSK 模糊系统建立模型，使模型具有可解释性且提升了预测的精度。

模糊系统在电力负荷预测方面得到了广泛应用。文献[39]利用模糊系统并结合相对湿度和温度数据对短期电力负荷进行预测，仿真实验表明利用模糊系统建立短期电力负荷预测模型预测效果较好。文献[40]首先利用小波变换对原始数据进行滤波处理；其次从滤波处理后的数据中提取周期和残差数据，利用函数加权单输入规则模块和模糊推理系统构建残差数据驱动的预测模型；最后将周期分量和残差分量的预测结果相结合得到最终的预测结果。

综上电力负荷预测模型的特点，电力负荷预测存在以下问题：

(1) 在电力负荷数据存在缺失的情况下，若直接进行预测会影响预测效果，迁移学习可以解决这一问题，而基于 TSK 迁移模糊系统对电力负荷预测的相关研究较少；

(2) 电力负荷序列具有随机性和非线性的特点使得预测难度增大；

(3) 在选择模型时，模型的可调参数会对预测精度产生影响；

(4) 智能优化算法的性能会影响对模型参数的寻优。

针对以上问题，迁移学习策略可以有效弥补数据缺失对预测结果的影响，迁移模糊系统具有强非线性逼近能力和较好的可解释性，同时 VMD 可以有效地降低序列的非线性和非平稳性，改进的斑马优化算法提高了全局收敛能力。在以上算法的基础上，本文提出了一种基于迁移学习和模糊系统的短期电力负荷预测方法。首先利用最小样本熵确定 VMD 分解的序列个数并对电力负荷序列分解，同时利用迁移成分分析算法对气象和日期因素进行降维，并使得源域和目标域之间的距离减小；其次，利用改进后的斑马优化算法对 TSK 迁移模糊系统的参数进行寻优，后对电力负荷序列进行预测；最后，将预测结果重组得到短期电力负荷序列的预测结果。仿真实验表明，该方法可以有效地提高模型的预测性能。

1.3 研究内容及论文框架

面对短期电力负荷预测中的问题，本文以欧洲两个城市的短期电力负荷数据集为基础，对短期电力负荷预测方法进行研究。

中国知网 https://www.cnki.net

首先利用 TSK-TFS 结合 VMD、ZOA 建立短期电力负荷模型，并利用 0 阶 L2 型 TSK 模糊系统(TSK-FS)结合 VMD 和 ZOA 建立对比模型；其次在 VMD-ZOA-TFS 模型的基础上，对 ZOA 进行改进，利用改进后的斑马优化算法(IZOA)对 TSK-TFS 的参数进行寻优，并结合迁移成分分析算法(TCA)，从而建立 VMD-TCA-IZOA-TFS 短期电力负荷模型，并进行短期电力负荷预测对比实验；最后综合所有的模型，对模型进行检验，验证模型的预测性能和稳健性。本文的具体研究内容如下：

(1) 基于 VMD-ZOA-TFS 短期电力负荷预测的方法研究

针对短期电力负荷数据具有非线性且存在缺失的问题，提出了一种基于 VMD-ZOA-TFS 短期电力负荷预测的方法。该方法的主要内容如下：首先利用 VMD 对短期电力负荷序列进行分解得到若干子序列，将天气和日期因素数据分别与分解得到的子序列相结合，并分为训练集和测试集；其次由于 TSK-TFS 存在可调参数，因此利用 ZOA 对 TSK-TFS 的参数进行寻优，并采用减法聚类算法得到聚类数；最后将训练集和测试集代入模型进行训练得到各个子序列的预测值，将其进行重组得到短期电力负荷的预测值。

(2) 基于 VMD-TCA-IZOA-TFS 短期电力负荷预测的方法研究

在 VMD-ZOA-TFS 短期电力负荷模型的基础上，首先对 ZOA 算法进行改进，改进策略主要包括引入莱维飞行对 ZOA 算法的种群进行初始化和在 ZOA 算法的防御阶段令切换概率服从正态分布两个方面，并利用基准函数对 IZOA、ZOA 和 PSO 算法进行测试，比较 IZOA 算法的收敛速度和寻优效果；其次引入 TCA 减小源域和目标域之间的分布差异，有利于提高迁移学习的效果，同时 TCA 降低了数据的维度，从而降低了模型计算的复杂度；最后利用 IZOA 算法和 TCA 建立 VMD-TCA-IZOA-TFS 短期电力负荷预测模型，利用统计指标验证模型的预测精度，同时利用模型检验方法验证模型的预测性能。

本文共分为五章，各章的主要内容分别为：

第一章为绪论，主要交代电力负荷预测的研究背景、意义和研究现状，说明论文的主要研究内容和章节分布。

第二章为短期电力负荷预测及相关方法概述，阐述了短期电力负荷的特性、短期电力负荷预测的特点和影响电力负荷的因素，同时对数据处理算法、聚类算法、TCA、ZOA、模糊系统和 LSTM 进行介绍。

第三章为基于 VMD-ZOA-TFS 短期电力负荷预测方法研究，首先讲明了数据来源、数据的统计特征、数据处理方法和模型的评价指标；其次建立 VMD-ZOA-TFS 短期电力负荷模型，并设置对比实验；最后代入数据进行仿真实验，得到预测结果并对其进行分析。

第四章为基于 VMD-TCA-IZOA-TFS 短期电力负荷预测方法研究，首先说明 ZOA 的改进策略，并利用基准函数对 IZOA 算法进行测试；其次在第三章模型的基础上结合以上两个算法建立 VMD-TCA-IZOA-TFS 短期电力负荷预测模型；最后利用第三章中的

中国知网 https://www.cnki.net

数据，检验模型的预测性能，同时基于 LSTM 建立对比模型，以验证 TSK 迁移模糊系统的预测性能。综合第三章和第四章中的模型，利用 DM 检验、HLN 检验、MCS 检验和改善率指标对模型进行验证，进一步检验模型之间预测性能的优劣。

第五章为总结与展望，对本文进行总结，说明本文得到的主要结论，并阐述本篇论文的不足和未来改进的方向。

1.4 技术路线

本文的研究框架及技术路线如图 1.2 所示。

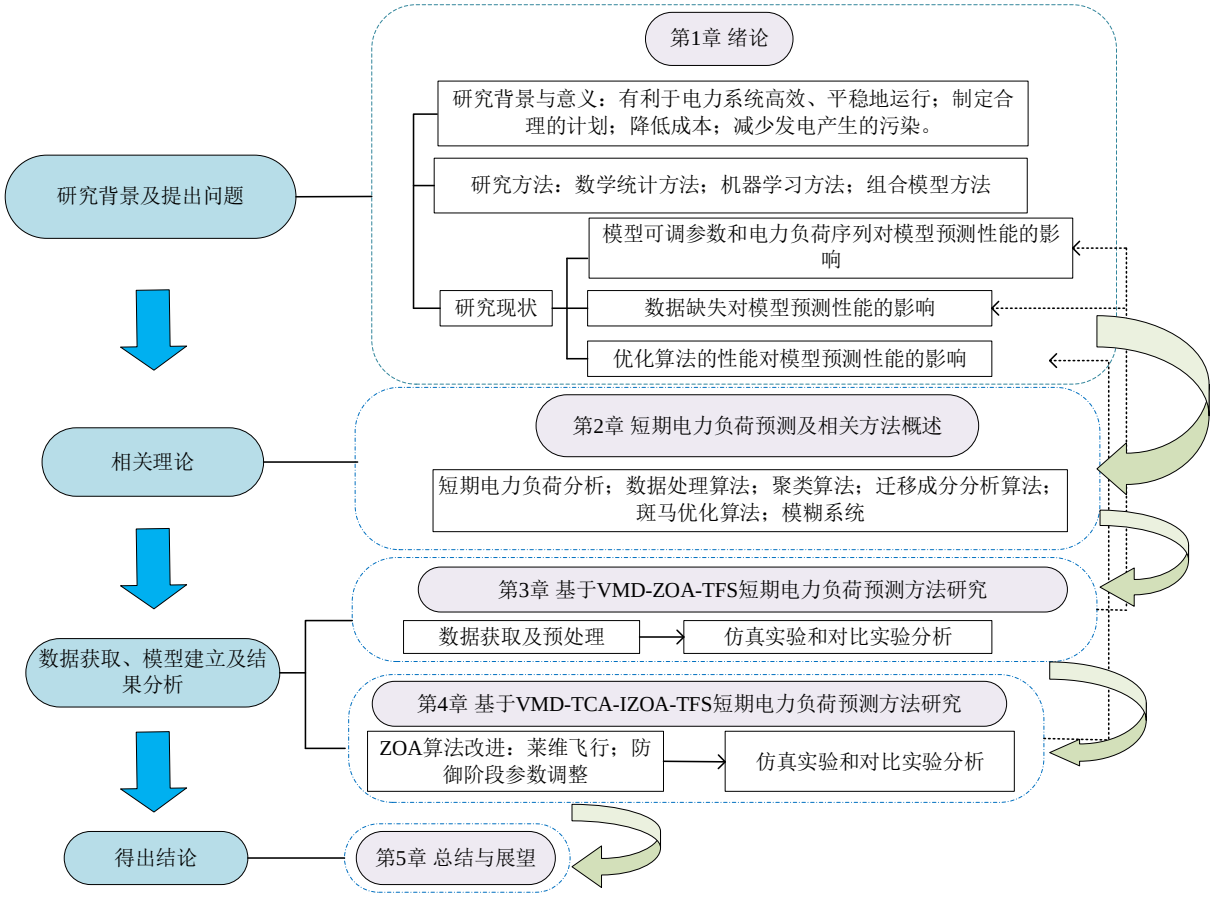


图 1.2 研究框架及技术路线

Figure 1.2 Research framework and technical roadmap

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第2章 短期电力负荷预测及相关方法概述

2.1 短期电力负荷分析

2.1.1 短期电力负荷的特性

短期电力负荷序列的变化趋势随着时间推移会表现出一定的特点，其中主要的特点包括周期性、随机性等。

(1) 周期性

周期性指在连续的时间段内，电力负荷序列的变化趋势大致相同。图 2.1 展示了拉托维亚地区 2018 年 4 月 3 日 0 点至 2018 年 4 月 5 日 23 点连续 3 日每一小时的电力负荷预测数据，从图中可以看出，3 日的电力负荷序列具有明显的周期性，每日的 6 点达到当日用电量的峰值，而波峰均出现在 6 点、10 点和 15 点，每日凌晨 0 点是当天用电量的最小值，且连续 3 日每日的电力负荷序列的变化趋势相同，因此电力负荷具有日周期性。

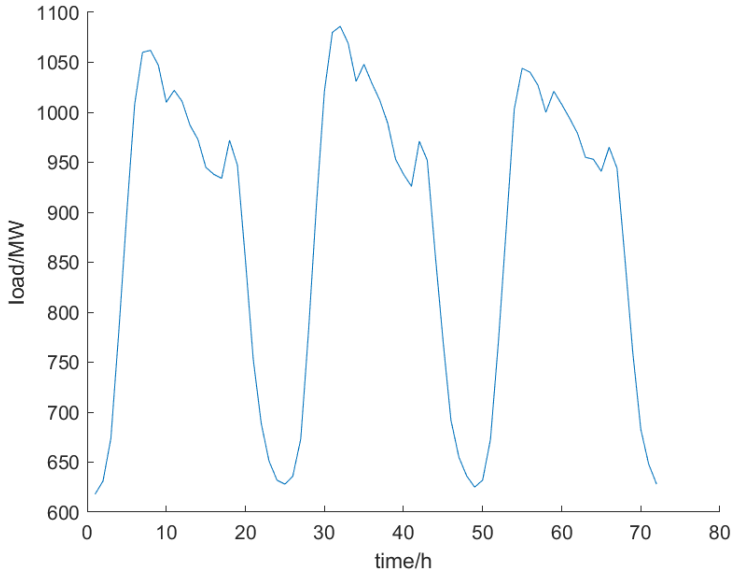


图 2.1 连续 3 日的电力负荷序列

Figure 2.1 Three consecutive days of power load sequence

图 2.2 展示了拉托维亚地区 2018 年 4 月 9 日 0 点至 2018 年 4 月 22 日 23 点连续两周每小时的电力负荷数据，从图中可以明显地看到每周中的周一至周五的变化趋势大致相同，周六周日的变化趋势大致相同且工作日的用电量明显高于休息日的用电量，这与人们的生产生活习惯相关。从图 2.2 中可以看出短期电力负荷具有周周期性。

中国知网 https://www.cnki.net

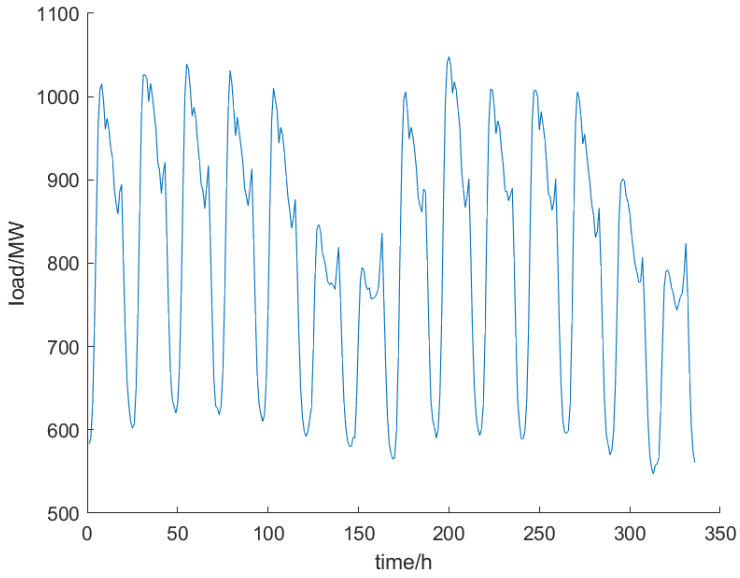


图 2.2 连续两周的电力负荷序列

Figure 2.2 Two consecutive weeks of power load sequence

图 2.3 展示了拉托维亚地区春季（2018 年 5 月 8 日）、夏季（2018 年 8 月 8 日）、秋季（2018 年 10 月 8 日）和冬季（2018 年 1 月 8 日）每小时短期电力负荷数据，从图中可以看出，秋季和春季的相似度最高，而冬季的用电量最大，夏季的用电量最小，因此得到电力负荷序列具有季周期性。

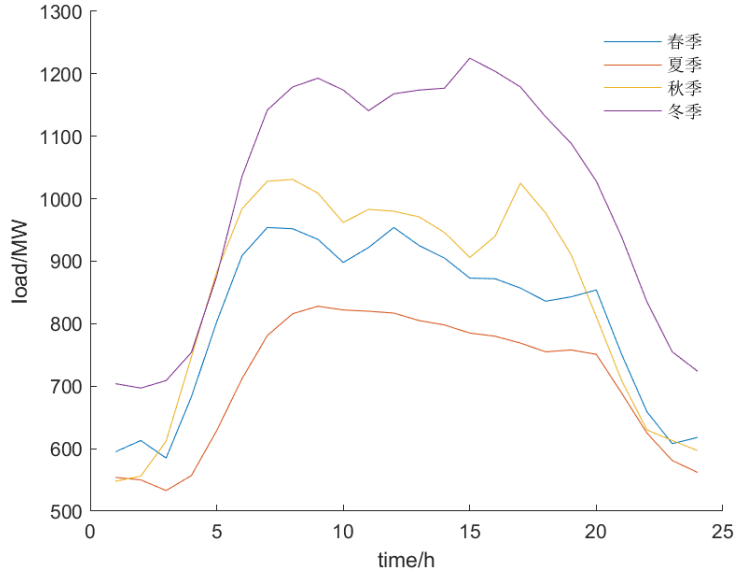


图 2.3 每个季节中某一日的电力负荷序列

Figure 2.3 The power load sequence for a certain day in each season

(2) 随机性

由于受到天气、日期以及电价等多种因素的影响，电力负荷序列具有随机性。图 2.4 展示了拉托维亚地区 2015 年 1 月 6 日 0 点到 2015 年 1 月 11 日 23 点连续 6 日每 1 小时的电力负荷变化趋势，其中第 6 日的电力负荷序列出现了与前 5 日不同的趋势，前

中国知网 https://www.cnki.net

5 日的电力负荷序列均有两个峰值，而第 6 日的电力负荷序列只有一个峰值，由此可以看出电力负荷序列具有随机性。

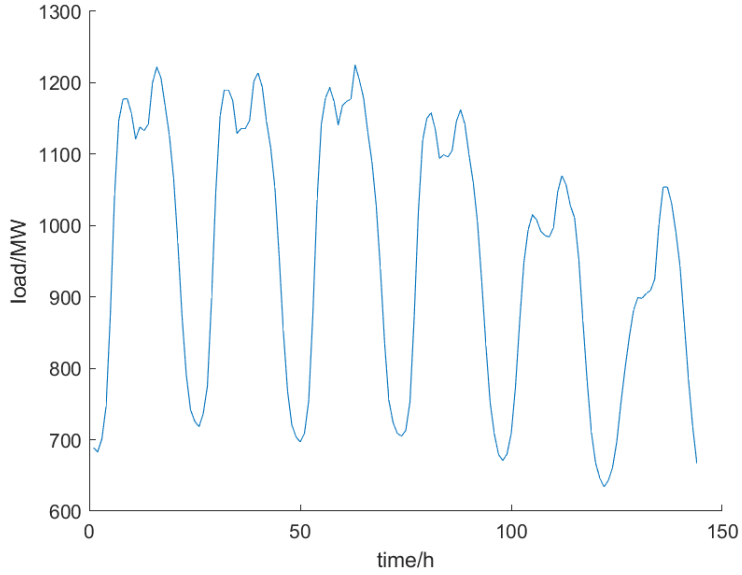


图 2.4 连续 6 日的电力负荷序列

Figure 2.4 Continuous 6-day power load sequence

根据短期电力负荷的特性结合预测模型可以得出电力负荷预测的特点主要包括条件性、时间性和多方案性[41]。

2.1.2 短期电力负荷的影响因素

短期电力负荷不仅与自身的历史数据相关，还与很多外在因素相关，其主要的影响因素有以下几种：

(1) 天气因素

天气是影响电力负荷的重要因素，主要包括温度、辐射等等。温度过高或过低时，人们通过开空调调节室内温度，这就会导致用电量会增加。在天气恶劣居民无法出行的情况下，会导致生活用电增加，而工业用电减少。

(2) 日期因素

日期因素首先考虑工作日、非工作日和节假日，相比于非工作日和节假日，工作日的电力负荷更大，这是因为在工作日人们从事生产劳动，机器等设备地运转需要电力支撑，所以用电量更大。图 2.5 展示了欧洲拉托维亚地区节假日（2015 年 12 月 25 日）、工作日（2015 年 12 月 23 日）和非工作日（2015 年 12 月 20 日）的电力负荷数据，从图 2.5 中可知，节假日的电力负荷低于非工作日的电力负荷低于工作日的电力负荷。因此可以看出日期因素影响电力负荷序列。

中国知网 https://www.cnki.net

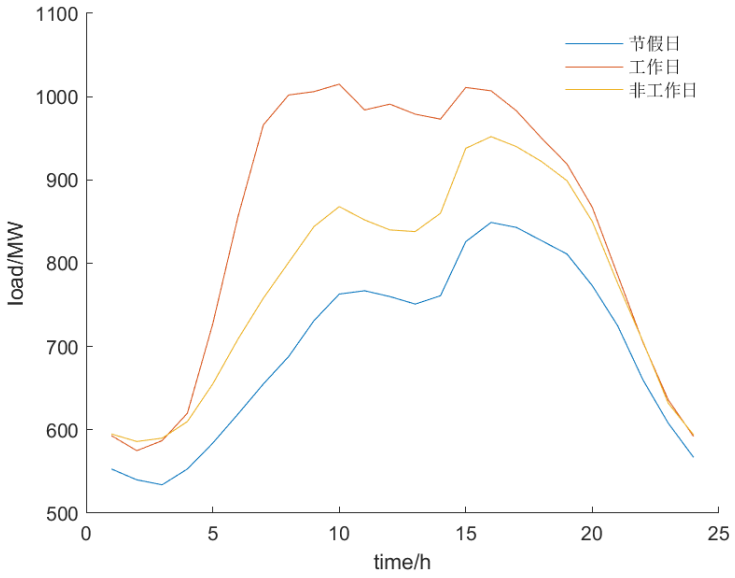


图 2.5 不同日期类型电力负荷序列

Figure 2.5 Power load sequences of different date types

(3) 电价因素

电价主要是对居民生活用电产生影响，电价高时，居民会减少用电，电价低时，居民就会增加用电。因此在电价较为便宜的时间段，居民使用电器会较少地考虑用电量，而在电价较为昂贵的时间段，居民则会将电价作为重要的考虑因素，进而减少用电。

(4) 其他因素

电力负荷除了会受到日期、天气和电价等因素的影响，一些突发事件也会对电力负荷产生影响。例如自然灾害、人为因素均会对电力负荷产生影响[42]。

综上所述，影响电力负荷的因素有很多，一些因素可以预见，而一些因素具有突发性无法预见，短期电力负荷预测即是通过可以预见和测量的因素，对未来几小时至几天的电力负荷进行预测。

2.1.3 短期电力负荷的步骤

短期电力负荷预测的一般步骤为[43]：

(1) 搜集和处理数据

进行短期电力负荷预测之前，需要确定预测地点以及该地点的电力负荷数据和天气等相关因素的数据，然后对得到的数据进行预处理，主要包括处理数据的异常值和对数据进行归一化等。

(2) 选择相关因素

提取与短期电力负荷相关的外部因素，例如温度等天气因素和日期因素，在进行因素选取时，需注意提取到的因素与电力负荷序列之间的关联性。

(3) 选择和建立模型

中国知网 https://www.cnki.net

根据前两步骤得到的数据信息结合实际情况，选择合适的模型进行预测，在单一模型预测性能较差时，一般会选择组合模型对短期电力负荷进行预测。

(4) 模型训练和验证

建立模型后，需将得到的数据信息代入模型，对模型进行训练同时利用评价指标评估模型的预测性能。

(5) 优化模型

根据指标结果对模型进行优化进一步提高模型的预测精度，优化模型的主要方法包括对模型的可调参数进行寻优、增加数据等，最终得到短期电力负荷的预测结果。

2.2 数据处理算法

2.2.1 经验模态分解

经验模态分解(EMD)[44]在 1998 年提出，可将非平稳数据平稳化，且具有数据驱动的自适应性，理论上适用于任何类型信号的分解。利用 EMD 可将原始信号分解为若干个本征模态函数 *IMF* 之和，降低原始信号的非平稳性和非线性，分解得到的 *IMF* 代表原始信号的频率分量，并从高频至低频依次排列。对于时间序列 $X(t)$，EMD 分解的步骤如下：

(1) 寻找 $X(t)$ 的所有极值点，利用三次样条曲线将极大值点连接构成上包络线，同样将极小值点连接构成下包络线，上包络线和下包络线包含所有数据点；

(2) 求出上包络线和下包络线的均值 $m_1(t)$，利用下式得到 $h_1(t)$：

$$h_1(t) = X(t) - m_1(t), \tag{2.1}$$

若 $h_1(t)$ 满足 *IMF* 条件，则将其作为 $X(t)$ 的第一个分量；

(3) 若 $h_1(t)$ 不满足 *IMF* 条件，则将 $h_1(t)$ 作为原始信号，重复步骤(1)和(2)，计算出 $m_1(t)$，后利用式(2.1)计算得到 $h_1(t)$，判断 $h_1(t)$ 是否满足 *IMF* 条件，若满足，则将其记作 $c_1(t)$，否则重复步骤(1)和(2)，直至满足条件为止；

(4) 将 $c_1(t)$ 从 $X(t)$ 中分离出得到 $r_1(t)$：

$$r_1(t) = X(t) - c_1(t), \tag{2.2}$$

将 $r_1(t)$ 作为原始信号，重复步骤(1)-(3)，循环 n 次，得到 $X(t)$ 的 n 个 *IMF* 分量；

(5) 若 $r_n(t)$ 为单调函数时，剩余的将其作为残差分量，则原始信号 $X(t)$ 表示为：

$$X(t) = \sum_{i=1}^{n} c_i(t) + r_n(t). \tag{2.3}$$

中国知网 https://www.cnki.net

2.2.2 集合经验模态分解

集合经验模态分解[45](EEMD)是一种叠加高斯白噪声的多次经验模态分解，有效抑制了 EMD 分解算法中模态混叠现象的产生。EEMD 算法的主要流程如下：

(1) 设定分解次数 Q；

(2) 将标准正态分布的白噪声 $n_i(t)$ 与原始信号 x_t 叠加，产生一个信号 $x_i(t)=x(t)+n_i(t)$；

(3) 对 $x_i(t)$ 进行 EMD 分解，得到模态函数 $IMFc_{i,j}(t)$ 和残差 $r_{i,j}(t)$；

(4) 重复步骤(2)和(3)一共 Q 次，每次分解加入随机白噪声得到 Q 组 IMF；

(5) 利用不相关序列的统计平均值为零的原理，将上述得到的 IMF 进行集合平均运算，得到 EEMD 分解的最终 IMF，即：

$$c_j(t)=\frac{1}{Q}\sum_{i=1}^{Q}c_{i,j}(t), \tag{2.4}$$

其中 $c_j(t)$ 为第 t 时刻第 j 个模态本征函数的值。

2.2.3 变分模态分解

变分模态分解(VMD)[46]是一种自适应、完全非递归的信号分解方法，克服了 EMD 方法中存在的端点效应和模态分量混叠问题，且 VMD 的分解序列个数可以指定，适用于非平稳性的序列。VMD 将每个 IMF 定义为调幅调频函数，即：

$$u_k(t)=A_k(t)\cos(\phi_k(t)), \tag{2.5}$$

其中 u_k 为各模态函数，$A_k(t)$ 为 u_k 的包络幅值，$\phi_k(t)$ 为瞬时相位，$k=1,2,\cdots,K$，K 为模态分解数，首先对 $u_k(t)$ 做希尔伯特变换得到其分析信号，同时计算器单边谱，即：

$$\left[\left(\delta(t)+\frac{j}{\pi t}\right)*u_k(t)\right]\cdot e^{-j\omega_k t}, \tag{2.6}$$

其中 ω_k 为各模态中心频率，计算解调梯度的平方范数 L^2，并计算每个分量的带宽，构造如下变分问题，即：

$$\begin{cases}\min\limits_{\{u_k\},\{\omega_k\}}\{\sum\limits_{k=1}^{K}\|\partial_t[(\delta(t)+\frac{j}{\pi t})\bullet u_k(t)]e^{-j\omega_k t}\|_2^2\}\\ s.t.\ \sum\limits_{k=1}^{K}u_k=f(t)\end{cases}, \tag{2.7}$$

其中 $f(t)$ 为原始信号，其次对变分问题求解，引入拉格朗日乘子 λ 和二次惩罚项得到求解公式：

中国知网 https://www.cnki.net

$$L(\{u_k\},\{\omega_k\},\lambda)=\alpha\sum_{k=1}^{K}\| \partial_t[(\delta(t)+\frac{j}{\pi t})\bullet u_k(t)]e^{-j\omega_k t}\|_2^2+ \\ \| f(t)-\sum_{k=1}^{K}u_k(t)\|_2^2+\left\langle \lambda(t), f(t)-\sum_{k=1}^{K}u_k(t)\right\rangle \tag{2.8}$$

其中α为惩罚项，最后对变分问题求解上式的鞍点可得：

$$\hat{u}_k^{n+1}(\omega)=\frac{\hat{f}(\omega)-\sum_{i\neq k}\hat{u}_i(\omega)+\hat{\lambda}(\omega)/2}{1+2\alpha(\omega-\omega_k)^2}, \tag{2.9}$$

$$\omega_k^{n+1}=\frac{\int_0^\infty \omega|\hat{u}_k(\omega)|^2\,d\omega}{\int_0^\infty|\hat{u}_k(\omega)|^2\,d\omega}, \tag{2.10}$$

$$\hat{\lambda}^{n+1}(\omega)=\hat{\lambda}^n(\omega)+\tau(\hat{f}(\omega)-\sum_{k=1}^{K}\hat{u}_k^{n+1}(\omega)). \tag{2.11}$$

VMD 的具体流程如下：

(1) 初始化$\{\hat{u}_k^1\}$、$\{\omega_k^1\}$和$\hat{\lambda}^1$；

(2) 利用式(2.9)和式(2.10)更新$\hat{u}_k^{n+1}(\omega)$和ω_k^{n+1}；

(3) 利用式(2.11)更新拉格朗日乘子$\hat{\lambda}^{n+1}(\omega)$；

(4) 当满足式(2.12)时，则求解完成，否则返回步骤(2)继续求解。

$$\sum_{k=1}^{K}\|\hat{u}_k^{n+1}-\hat{u}_k^n\|_2^2/\|\hat{u}_k^n\|_2^2<\varepsilon. \tag{2.12}$$

2.2.4 最小样本熵

由于变分模态分解的分解个数可以随机选定，样本熵[47]可以测量时间序列的复杂度，且样本熵具有一致性，为了得到更有效的分解成分，利用最小样本熵确定 VMD 的分解序列个数，最小样本熵的计算步骤如下：

(1) 将时间序列$X=\{x_1,x_2,\cdots,x_N\}$构成l维矢量，即：

$$X_i=\{x_i,x_{i+1},\cdots,x_{i+l-1}\},i=1,2,\cdots,N-l+1. \tag{2.13}$$

(2) 定义距离$dist(X_i,X_j)$为：

$$dist(X_i,X_j)=\max_{k\in(0,l-1)}|x_{i+k}-x_{j+k}|. \tag{2.14}$$

(3) 给定阈值r，统计$dist(X_i,X_j)<r$的数量并计算矢量总个数$N-l$的比值，即：

$$B_i^l(r)=\frac{num\{dist(X_i,X_j)<r\}}{N-l}. \tag{2.15}$$

(4) 对所有由式(2.15)得到的结果求平均，即：

中国知网 https://www.cnki.net

$$B^l(r)=\frac{1}{N-l+1}\sum_{i=1}^{N-l+1}B_i^l(r), \tag{2.16}$$

则样本熵的估计值为：

$$Sampen(l,r,N)=-\ln(\frac{B^{l+1}(r)}{B^l(r)}), \tag{2.17}$$

则对于 VMD 分解不同的分解数 k，计算最小样本熵为：

$$Sampen_{\min}=\min_k Sampen(l,r,N). \tag{2.18}$$

利用上式即可得出最小样本熵趋于稳定对应的 k 即为 VMD 的分解序列数。

2.3 聚类算法

2.3.1 模糊 C 均值聚类

模糊 C 均值聚类(Fuzzy C-Means, FCM)[48]是一种软聚类方法，适用于处理具有不完整或模糊数据的数据集，具有较好的收敛性且复杂度低，但存在迭代过程中易陷入局部最小、对初始值较敏感的问题。此算法由 Bezdek 教授提出。FCM 通过优化目标函数得到每个样本点对类中心的隶属度，根据隶属度对样本点进行分类，其目标函数和约束条件为：

$$\begin{aligned} &J(\mathrm{U},\mathrm{V})=\sum_{i=1}^{N}\sum_{j=1}^{C}\mu_{ij}^m\left\|x_i-v_j\right\|^2 \\ &s.t.\ \ \mu_{ij}\in[0,1]且\sum_{j=1}^{C}\mu_{ij}=1\quad 1\le i\le N \end{aligned}, \tag{2.19}$$

其中，N 为样本数，C 为聚类中心数，μ_{ij} 为样本 x_i 对聚类中心 v_j 的隶属度，x_i 为第 i 个样本，v_j 为第 j 个聚类中心，m 为聚类的簇数且 $m>1$，当 $m\to1$，μ_{ij} 趋于精确，当 $m\to\infty$，μ_{ij} 趋于模糊。根据拉格朗日条件极值的优化理论可得：

$$v_j=\frac{\sum_{i=1}^{N}\mu_{ij}^m x_i}{\sum_{i=1}^{N}\mu_{ij}^m}, \tag{2.20}$$

$$\mu_{ij}=\sum_{k=1}^{C}\left[\frac{\left\|x_i-v_j\right\|^2}{\left\|x_i-v_k\right\|^2}\right]^{-\frac{1}{m-1}}. \tag{2.21}$$

根据式(2.20)和(2.21)经过迭代即可得到最优的隶属度矩阵 U ,后对隶属度矩阵 U 去模糊化得到样本的空间划分矩阵，从而获取每个样本 x_i 对应的类标签。经典 FCM 算法的具体步骤如下：

中国知网 https://www.cnki.net

(1) 输入C,m，最大迭代数L，数据集X，迭代终止条件ε；

(2) 初始化随机产生中心点集V,随机产生归一化的模糊隶属度矩阵U,计算当前目标函数J^0；

(3) 根据式(2.20)更新中心点v_j，根据式(2.21)更新隶属度μ_{ij}；

(4) $k=k+1$，计算当前目标函数J^k，如果$\left\|J^k-J^{k-1}\right\|<\varepsilon$或者$k>L$，跳出循环，否则，回到步骤(2)；

(5) 输出各类的聚类中心点v和各个样本的模糊隶属度μ_{ij}，最终得到目标域类中心点V和隶属度矩阵U。

2.3.2 减法聚类

减法聚类算法[49]是一种无监督学习方法，不需要提前规定聚类数，根据样本数据即可确定聚类中心和聚类中心的个数，减法聚类是一种密度聚类算法，此算法将所有的数据点作为聚类中心，根据密度指标选择最大的样本点作为聚类中心，后将此样本点去掉，选择剩余样本中密度指标最大的样本点，以此类推，最终根据迭代终止条件得到聚类中心。减法聚类算法的具体步骤如下：

(1) 设待分类的数据为$X=(x_1,x_2,\cdots,x_n)\in R^{m\times n}$，每个数据点均为候选的聚类中心，定义数据点$x_i$的密度指标为：

$$D_i=\sum_{j=1}^{n}\exp(-\frac{\|x_i-x_j\|^2}{(r_a/2)^2}), \tag{2.22}$$

其中r_a为常数；

(2) 定义密度指数最大的数据点为聚类中心c_k，其密度指标为D_{c_k}，此时$k=1$，每个数据点的密度指标更新公式为：

$$D_i=D_i-D_{c_k}\sum_{j=1}^{n}\exp(-\frac{\|x_i-x_j\|^2}{(r_b/2)^2}), \tag{2.23}$$

其中r_b为常数，常数r_b通常大于常数r_a，一般取$r_b=(1.2\sim1.5)r_a$；

(3) 根据修正后的样本数据点密度指标，令$D_{\max}=\max(D_i)$，确定出下一个聚类中心c_{k+1}，重复步骤(2)对数据点的密度指标更新；

(4) 不断迭代计算修正后的密度指标最大值$D_{\max}$使其满足：

$$\frac{D_{\max}}{D_{c_1}}<\delta, \tag{2.24}$$

其中$\delta\in(0,1)$，则迭代结束，得出最终聚类个数M。

中国知网 https://www.cnki.net

2.4 迁移成分分析算法

迁移成分分析(Transfer Component Analysis, TCA)[50]在不改变数据结构和域间分布变化的情况下，能够减小源域数据和目标域数据之间差异，使得不同域之间的差异在映射后的子空间中降低，且可以将数据进行降维。假设存在一个特征映射 ϕ，使得 $P(\phi(X_s)) \approx P(\phi(X_t))$，迁移成分分析将最大均值差异(Maximize Mean Discrepancy, MMD)作为度量准则，使不同域之间的分布差异最小化，最大均值差异的计算公式为：

$$D(X_s, X_t) = \| \frac{1}{n_1} \sum_{i=1}^{n_1} \phi(x_i) - \frac{1}{n_2} \sum_{j=1}^{n_2} \phi(x_j) \|_H^2 , \tag{2.25}$$

其中 X_s 为源域数据，X_t 为目标域数据，n_1 和 n_2 分别为源域和目标域的样本个数，$\|\cdot\|_H$ 为再生核希尔伯特空间范数，利用核矩阵 K 和度量矩阵 L 可将最大均值差异计算公式转化为：

$$D(X_s, X_t) = tr(KL) . \tag{2.26}$$

其中

$$K = \begin{bmatrix} K_{s,s} & K_{s,t} \\ K_{t,s} & K_{t,t} \end{bmatrix} \in R^{(n_1+n_2)\times(n_1+n_2)} , \tag{2.27}$$

$$L_{i,j} = \begin{cases} \frac{1}{n_1^2}, & x_i, x_j \in D_s , \\ \frac{1}{n_2^2}, & x_i, x_j \in D_t , \\ -\frac{1}{n_1 n_2}, & else, \end{cases} \tag{2.28}$$

对式(2.27)中的矩阵 K 规格减小,得到 $\tilde{K}$：

$$\tilde{K} = (KK^{-1/2}\tilde{W})(\tilde{W}^T K^{-1/2} K) = KWW^T K , \tag{2.29}$$

其中 $\tilde{W} \in R^{(n_1+n_2)\times m}$，$W = K^{-1/2}\tilde{W}$，将距离公式转化为：

$$D(X_s, X_t) = tr(W^T KLKW) . \tag{2.30}$$

将式(2.30)代入式(2.25)中，得到 TCA 的目标函数为：

$$\begin{aligned} &\min_W \ tr(W^T KLKW) + \mu tr(W^T W) \\ &s.t. \ \ W^T KHKW = I_m \end{aligned} , \tag{2.31}$$

其中 $H = I_{n_1+n_2} - 1/(n_1+n_2) 11^T$，$I$ 为单位矩阵，1为 n_1+n_2 行的全 1 列向量，μ 为权衡因子，$tr(W^T W)$ 为正则项。

中国知网 https://www.cnki.net

2.5 斑马优化算法

斑马优化算法(Zebra Optimization Algorithm, ZOA)[51]通过模拟斑马的觅食行为和针对捕食者的防御行为进行寻优，ZOA 算法的寻优能力强，收敛速度较快。

ZOA 主要分为三个阶段，首先初始化寻优空间的斑马种群 X：

$$X=\{X_i\}_{i=1,\cdots,N}=\{x_{i,j}\}_{j=1,\cdots,m}, x_{i,j}=lb_j+r(ub_j-lb_j), \tag{2.32}$$

其中 X_i 为第 i 个斑马的值，$x_{i,j}$ 为第 i 个斑马的第 j 维度值，第 i 个斑马对应的目标函数值为 F_i，斑马 lb_j 为寻优下界，ub_j 为寻优上界，r 为[0,1]之间的随机数。

其次是斑马的觅食阶段，位置更新的公式为：

$$x_{i,j}^{new,P1}=x_{i,j}+r(PZ_j-I\times x_{i,j}), \tag{2.33}$$

$$X_i=\begin{cases}X_i^{new,P1}, & F_i^{new,P1}<F_i,\\ X_i, & else,\end{cases} \tag{2.34}$$

其中 $X_i^{new,P1}$ 为第 i 个斑马在觅食阶段的值，$x_{i,j}^{new,P1}$ 为第 i 个斑马在觅食阶段第 j 维度值，r 为[0,1]之间的随机数，I 为属于集合{1,2}的随机值，PZ_j 为先锋斑马的第 j 维度值，$F_i^{new,P1}$ 为第 i 个斑马在觅食阶段的目标函数值。

最后是斑马针对捕食者的防御阶段，斑马的防御策略根据捕食者的分为两种，S1:若捕食者为狮子，斑马选择逃跑战略即 $P_S\le 0.5$ 对应的函数式；S2:若捕食者为其他的动物，则斑马采取攻击捕食者的策略即 $else$ 对应的函数式。位置更新的公式为：

$$x_{i,j}^{new,P2}=\begin{cases}x_{i,j}+R(2r-1)(1-\dfrac{t}{T})x_{i,j}, & P_s\le 0.5,\\ x_{i,j}+r(AZ_j-I\cdot x_{i,j}), & else,\end{cases} \tag{2.35}$$

$$X_i=\begin{cases}X_i^{new,P2}, & F_i^{new,P2}<F_i,\\ X_i, & else,\end{cases} \tag{2.36}$$

其中 $X_i^{new,P2}$ 为第 i 个斑马在防御阶段的值，$x_{i,j}^{new,P2}$ 为第 i 个斑马在防御阶段第 j 维度值，AZ_j 为被攻击斑马的第 j 维度值，$F_i^{new,P2}$ 为第 i 个斑马在防御阶段的目标函数值，t 为迭代次数，T 为最大迭代次数，R 为 0.01，$P_s\in[0,1]$ 为在两种策略中的选择一种策略的概率。

ZOA 算法步骤如下：

(1) 设置参数种群数量 N、种群维度 m 和最大迭代数 T，创建初始种群；

(2) 根据目标函数计算适应度值，更新先锋斑马；

(3) 根据式(2.33)计算斑马的位置，并更新斑马的位置；

中国知网 https://www.cnki.net

(4) 随机生成 *Ps* 并选择防御策略；根据防御策略更新斑马在防御阶段的位置，保留当前最优解；

(5) 判断是否达到最大迭代次数，若是，则输出最优解，否则，返回步骤(2)。

图 2.6 展示了斑马优化算法的流程图：

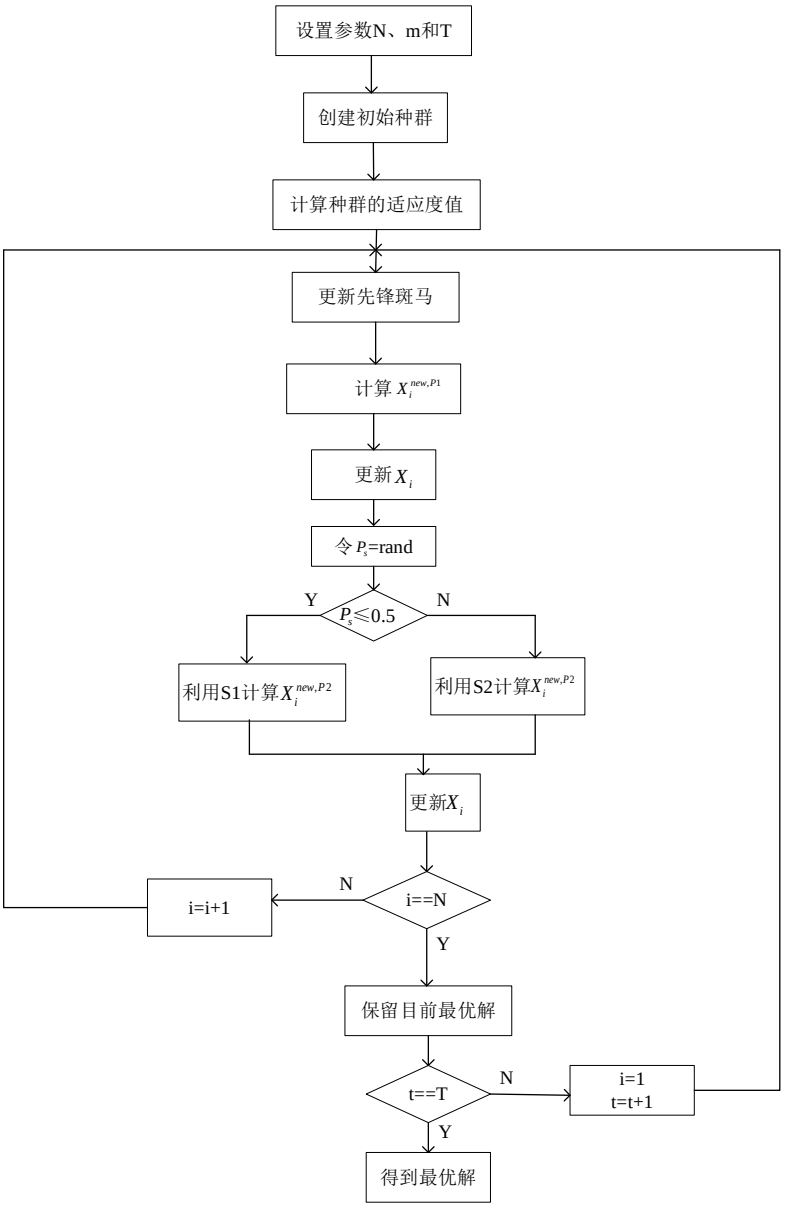


图 2.6 斑马优化算法流程图

Figure 2.6 Zebra optimization algorithm flowchart

2.6 模糊系统

模糊系统是一种基于规则或知识的系统，其通过“IF-THEN”规则组成知识库，并利用此规则表示连续隶属函数并对所描述的句子做“IF-THEN”形式地陈述，经典的模糊系统框架由模糊器、模糊规则库、模糊推理机和解模糊器四部分组成。模糊系统的具体结构如图 2.7 所示：

中国知网 https://www.cnki.net

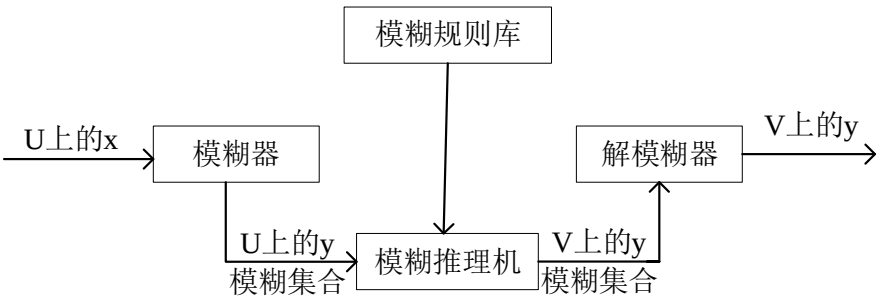


图 2.7 模糊系统的结构

Figure 2.7 The structure of fuzzy system

其中，模糊器是将输入变量模糊化，即将其转化为模糊集，计算每个变量隶属于模糊集的隶属度，模糊器包括单值模糊器、高斯模糊器和三角模糊器。模糊规则库由模糊规则 IF-THEN 组成。模糊推理机按照模糊规则库中的规则计算得到模糊输出结果。解模糊器是将每一条规则的输出去模糊化。

模糊系统根据构建机制或者规则表达不同，通常可以分为 TSK 模糊系统、ML 模糊系统模型和 GFM 模糊系统。以上 3 种模糊系统的模糊规则如下表 2.1 所示，在以下 3 种模糊系统中，TSK 模糊系统的输出较为简洁且可以将问题转化为线性回归问题或二次规划问题进行求解。本文围绕 TSK 模糊系统进行建模，因此简要说明经典 TSK 模糊系统和训练方式。

表 2.1 经典模糊系统对应的模糊规则

经典模糊系统	相关模型的模糊规则
TSK 模糊系统	IF $x_1 \text{ is } A_1^k \wedge x_2 \text{ is } A_2^k \wedge \cdots \wedge x_d \text{ is } A_d^k$ THEN y^k is $f^k(x), k=1,\cdots,K$
ML 模糊系统	IF $x_1 \text{ is } A_1^k \wedge x_2 \text{ is } A_2^k \wedge \cdots \wedge x_d \text{ is } A_d^k$ THEN y^k is $B^k(b_k, v_k), k=1,\cdots,K$
GFM 模糊系统	IF $x_1 \text{ is } A_1^k \wedge x_2 \text{ is } A_2^k \wedge \cdots \wedge x_d \text{ is } A_d^k$ THEN y^k is $B^k(f^k(x), v_k), k=1,\cdots,K$

2.6.1 TSK 模糊系统

TSK 模糊系统具有较强的非线性逼近能力，广泛应用于预测和分类问题中。TSK 模糊系统的第 k 条推理规则为：

$$\begin{aligned} &\text{IF } x_1 \text{ is } A_1^k \wedge x_2 \text{ is } A_2^k \wedge \cdots \wedge x_d \text{ is } A_d^k, \\ &\text{Then } f^k(x) = p_0^k + p_1^k x_1 + p_2^k x_2 + \cdots + p_d^k x_d, k = 1,2,\cdots,K. \end{aligned} \tag{2.37}$$

其中推理规则对应的输入向量为 $x=[x_1, x_2, \cdots, x_d]^T$，将输入空间 $A^k \subset R^d$ 映射至输出空间 $f^k(x) \subset R$， A_i^k 为第 i 维输入在第 k 条模糊规则中对应的模糊子集，$\wedge$ 表示模糊合取，

中国知网 https://www.cnki.net

经过乘法合取、析取等运算，再对输出结果去模糊化，即可得到 TSK 模糊系统的输出为：

$$y^0=\sum_{k=1}^{K}\frac{\mu^k(x)}{\sum_{k'=1}^{K}\mu^{k'}(x)}f^k(x)=\sum_{k=1}^{K}\tilde{\mu}^k(x)f^k(x), \tag{2.38}$$

其中

$$\mu^k(x)=\prod_{i=1}^{d}\mu_{A_i^k}(x_i), \tag{2.39}$$

$$\tilde{\mu}^k(x)=\frac{\mu^k(x)}{\sum_{k'=1}^{K}\mu^{k'}(x)}. \tag{2.40}$$

若采用高斯函数作为隶属度函数，则式(2.39)中的 $\mu_{A_i^k}(x_i)$ 可表示为：

$$\mu_{A_i^k}(x_i)=\exp\left(\frac{-(x_i-c_i^k)^2}{2\delta_i^k}\right). \tag{2.41}$$

采用 FCM 算法获取参数 c_i^k 和 δ_i^k，公式表示为：

$$c_i^k=\sum_{j=1}^{N}\mu_{jk}x_{ji}/\sum_{j=1}^{N}\mu_{jk}, \tag{2.42}$$

$$\delta_i^k=h\sum_{j=1}^{N}\mu_{jk}(x_{ji}-c_i^k)^2/\sum_{j=1}^{N}\mu_{jk}. \tag{2.43}$$

其中 μ_{jk} 为输入向量 $x_j=[x_{j1},x_{j2},\cdots,x_{jd}]^T$ 隶属于第 k 类的隶属度，h 为尺度参数。根据文献[46]的策略，令：

$$x_e=(1,x^T)^T, \tag{2.44}$$

$$\tilde{x}^k=\tilde{u}^k(x)x_e, \tag{2.45}$$

$$x_g=((\tilde{x}^1)^T,(\tilde{x}^2)^T,\cdots,(\tilde{x}^K)^T)^T, \tag{2.46}$$

$$p^k=(p_0^k,p_1^k,\cdots,p_d^k)^T, \tag{2.47}$$

$$p_g=((p^1)^T,(p^2)^T,\cdots,(p^K)^T)^T. \tag{2.48}$$

则 TSK 输出可表示为：

$$y^0=p_g^Tx_g. \tag{2.49}$$

中国知网 https://www.cnki.net

综上所述，TSK 模糊系统将参数学习问题转化为线性回归问题。

TSK 模糊系统可应用于回归问题，将 TSK 模糊系统应用于回归问题是指优化 TSK-FS 的后件参数，根据文献[52]采用 $\varepsilon-$不敏感损失函数构造优化目标函数，目标函数的公式如下：

$$\min_{p_g} L=\sum_{i=1}^{N}\left|y_i^0-y_i\right|_{\varepsilon}=\sum_{i=1}^{N}\left|p_g^T x_{gi}-y_i\right|_{\varepsilon}, \tag{2.50}$$

其中 $|*|_{\varepsilon}$ 为不敏感损失量。若引入 L2 范式的惩罚项 ξ_i^+ 和 ξ_i^-，则式(2.50)可等价为：

$$\begin{aligned}&\min_{p_g,\xi^+,\xi^-} L(p_g,\xi^+,\xi^-)=\sum_{i=1}^{N}((\xi_i^+)^2+(\xi_i^-)^2)\\ &s.t.\begin{cases}y_i-p_g^T x_{gi}<\varepsilon+\xi_i^+\\ p_g^T x_{gi}-y_i<\varepsilon+\xi_i^-\end{cases},\forall i\end{aligned}. \tag{2.51}$$

根据 L2-SVR[53]的学习机理，Deng Z H 等[52]将结构风险项引入目标函数中，进而将式(2.51)改写为：

$$\begin{aligned}&\min_{p_g,\xi^+,\xi^-,\varepsilon} L(p_g,\xi^+,\xi^-,\varepsilon)=\frac{1}{\tau}\cdot\frac{1}{N}\sum_{i=1}^{N}((\xi_i^+)^2+(\xi_i^-)^2)+\frac{1}{2}(p_g^T p_g)+\frac{2}{\tau}\cdot\varepsilon\\ &s.t.\begin{cases}y_i-p_g^T x_{gi}<\varepsilon+\xi_i^+\\ p_g^T x_{gi}-y_i<\varepsilon+\xi_i^-\end{cases},\forall i\end{aligned}. \tag{2.52}$$

针对式(2.52)，利用优化学习理论求解其对偶问题，进而可以将其表示为以下二次规划问题：

$$\begin{aligned}\max_{\lambda^+,\lambda^-}\ &-\sum_{i=1}^{N}\sum_{j=1}^{N}(\lambda_i^+-\lambda_i^-)(\lambda_j^+-\lambda_j^-)x_{gi}^T x_{gj}-\sum_{i=1}^{N}\frac{N\tau}{2}(\lambda_i^+)^2-\sum_{i=1}^{N}\frac{N\tau}{2}(\lambda_i^-)^2+\\ &\sum_{i=1}^{N}\lambda_i^+\cdot y_i\cdot\tau-\sum_{i=1}^{N}\lambda_i^-\cdot y_i\cdot\tau\\ s.t.\ \ &\sum_{i=1}^{N}(\lambda_i^+-\lambda_i^-)=1,\lambda_i^+,\lambda_i^-\geq 0\qquad\forall i.\end{aligned}. \tag{2.53}$$

令：

$$\tilde{\alpha}=(\tilde{\alpha}_1,\tilde{\alpha}_2,\cdots,\tilde{\alpha}_{2N})^T=((\lambda^+)^T,(\lambda^-)^T)^T, \tag{2.54}$$

$$z_i=\begin{cases}x_{gi}, & i=1,2,\cdots,N,\\ -x_{g(i-N)}, & i=N+1,N+2,\cdots,2N,\end{cases} \tag{2.55}$$

$$\beta=(\tau y^T,-\tau y^T)^T,\ y=(y_1,y_2,\cdots,y_N)^T. \tag{2.56}$$

利用式(2.54)-(2.56)，则可以将式(2.53)简化为：

中国知网 https://www.cnki.net

$$\begin{aligned} &\arg\max_{\tilde{\alpha}} \ -\tilde{\alpha}^T\tilde{K}\tilde{\alpha}+\tilde{\alpha}^T\beta \\ &s.t. \ \ \tilde{\alpha}^T 1=1, \ \ \alpha_i \geq 0 \ \ \forall i \end{aligned}, \tag{2.57}$$

其中 $\tilde{K}=[\tilde{k}_{ij}]_{2N\times 2N}$，$\tilde{k}_{ij}=z_i^T z_i+N\tau\delta_{ij}/2$ 为核矩阵，$\delta_{ij}=\begin{cases}1, & i=j\\ 0, & i\neq j\end{cases}$。

通过求解式(2.57)，即可得到式(2.52)的最优解，根据对偶理论，原优化问题中各参数的最优解可表示为：

$$p_g=\frac{2}{\tau}\sum_{i=1}^{N}(\lambda_i^+-\lambda_i^-)x_{gi}, \tag{2.58}$$

$$\xi_i^+=N\lambda_i^+, \tag{2.59}$$

$$\xi_i^-=N\lambda_i^-, \tag{2.60}$$

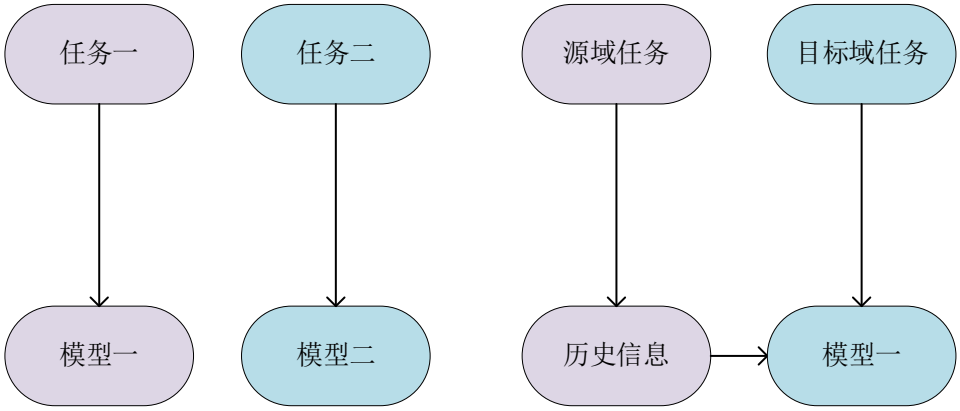
$$\begin{aligned} \varepsilon=&\sum_{i=1}^{N}(\lambda_i^+-\lambda_i^-)y_i-\frac{N}{2}\sum_{i=1}^{N}((\lambda_i^+)^2-(\lambda_i^-)^2)-\\ &\frac{1}{\tau}\sum_{i=1}^{N}\sum_{j=1}^{N}(\lambda_i^+-\lambda_i^-)(\lambda_j^+-\lambda_j^-)\cdot x_{gi}^T x_{gj} \end{aligned}. \tag{2.61}$$

2.6.2 TSK 迁移模糊系统

基于 2.6.1 中 0 阶 L2 型 TSK 模糊系统及其在回归问题中的应用，将迁移学习的思想引入 TSK 模糊系统中，构建 0 阶 L2 型 TSK 迁移模糊系统。

迁移学习是机器学习中的一种，迁移学习将基于任务 A 得到的模型使用在任务 B，即从历史任务中得到知识并将其迁移至新任务的学习中。迁移学习的研究对象为域和任务，其中，域是由数据特征和特征分布组成，其包括源域和目标域，历史任务对应的领域为源域，新任务对应的领域为目标域；任务由目标函数和学习结果组成。迁移学习和传统机器学习的区别主要表现在数据分布、数据标签和建模，其中在数据分布方面，迁移学习训练集和测试集数据不需要同分布而传统机器学习需要数据同分布。在数据标签方面，迁移学习不需要足够的数据标签而传统机器学习需要足够的数据标签。在建模方面，迁移学习可以重用之前的模型而传统机器学习是针对每个任务分别建模。机器学习模型和迁移学习模型的对比如图 2.8 所示，在传统机器学习中，任务一和任务二分别训练得到模型一和模型二。在迁移学习中，利用源域任务得到历史信息，进而利用历史信息和目标域任务训练得到模型一。

中国知网 https://www.cnki.net



(a) 机器学习　　(b) 迁移学习

图 2.8 传统机器学习和迁移学习模型对比

Figure 2.8 Comparison of traditional machine learning and transfer learning models

迁移学习根据迁移情景可以分为归纳式迁移学习、直推式学习和无监督学习，迁移学习分类的具体内容如表 2.2 所示：

表 2.2 迁移学习分类

迁移学习分类	源域和目标域的关系	源任务和目标任务的关系	源域标签	目标域标签	学习场景
归纳式迁移学习	相同/不同	不同但相关	有标签/无标签	有标签/无标签	回归和分类
直推式学习	不同但相关	相同	有标签	无标签	回归和分类
无监督学习	不同但相关	不同但相关	无标签	无标签	聚类和降维

迁移学习按照基本方法分为四种[54]，分别是基于样本、模型、特征和关系迁移，具体内容如下：

(1) 基于样本的迁移学习

基于样本的迁移学习方法假设源域中的一些数据与目标域中的数据有共同特征，该方法根据一定的权重生成规则，通过对数据样本重用进行迁移学习，在迁移学习的过程中，通过对源域中的样本重新加权，选择出与目标域相似度较高的数据进行训练学习。

(2) 基于特征的迁移学习

基于特征的迁移学习方法假设源域和目标域仅有一些交叉特征。该方法通过将源域和目标域的特征变换至相同的空间，并最小化源域和目标域之间的距离进行迁移学习。

(3) 基于模型的迁移学习

基于模型的迁移学习方法假设源域和目标域可以共享模型的参数，该方法根据源域训练得到的模型运用至目标域中，同时根据目标域数据对模型进行调整。

(4) 基于关系的迁移学习

基于关系的迁移学习方法假设源域和目标域相似且存在某种关系。该方法利用源域中的数据训练逻辑关系网络并将其运用至目标域中。

中国知网 https://www.cnki.net

迁移学习按照特征空间分类可以分为同构和异构迁移学习。同构迁移学习为源域和目标域的特征空间相同，异构迁移学习为源域和目标域的特征空间不同。

利用迁移学习策略可以有效地解决由于数据缺失导致模型预测性能降低的问题，将迁移学习策略引入 0 阶 L2 型 TSK 模糊系统中，在数据存在缺失时可以提高模型预测的准确性，根据文献[26]可知 0 阶 L2 型 TSK 迁移模糊系统将有用的信息描述为后件参数 p_g，对于在历史场景中训练得到 p_g 可作为有效信息迁移至当前场景中。为了达到迁移学习的目的，引入迁移机制并构造目标函数，具体公式如下：

$$\min_{p_g,\xi^+,\xi^-,\varepsilon} \tilde{L}(p_g,\xi^+,\xi^-,\varepsilon)=\Theta_c(p_g,\xi^+,\xi^-,\varepsilon)+\lambda\Theta_h(p_g,p_{g_0})$$
$$s.t.\begin{cases} y_i-p_g^T x_{gi}<\varepsilon+\xi_i^+ \\ p_g^T x_{gi}-y_i<\varepsilon+\xi_i^- \end{cases},\forall i \quad , \tag{2.62}$$

$$\Theta_c(p_g,\xi^+,\xi^-,\varepsilon)=\frac{1}{N\tau}\sum_{i=1}^{N}[(\xi_i^+)^2+(\xi_i^-)^2]+\frac{1}{2}(p_g^T p_g)+\frac{2}{\tau}\cdot\varepsilon\,, \tag{2.63}$$

$$\Theta_h(p_g,\xi^+,\xi^-,\varepsilon)=(p_g-p_{g_0})^T(p_g-p_{g_0}), \tag{2.64}$$

其中 Θ_c 为利用当前场景数据对模型训练学习，Θ_h 为利用历史场景迁移学习，λ 为平衡当前场景和历史场景的参数。$\sum_{k=1}^{K}\mu^k(x)\neq 0$，则最小值问题式(2.62)的拉格朗日函数为：

$$L(p_g,\xi^+,\xi^-,\alpha,\alpha^*)=\frac{1}{\tau}\cdot\frac{1}{N}\sum_{i=1}^{N}((\xi_i^+)^2+(\xi_i^-)^2)+\frac{1}{2}(p_g^T p_g)+\frac{2}{\tau}\cdot\varepsilon+$$
$$\lambda(p_g-p_{g_0})^T(p_g-p_{g_0})+\sum_{i=1}^{N}\alpha_i(y_i-p_g^T x_{gi}-\varepsilon-\xi_i^+)+\sum_{i=1}^{N}\alpha_i^*(p_g^T x_{gi}-y_i-\varepsilon-\xi_i^-) \quad , \tag{2.65}$$

其中 α,α^* 为拉格朗日乘子，且 $\alpha\geq 0,\alpha^*\geq 0$，根据对偶理论可得：

$$\frac{\partial L}{\partial p_g}=(1+2\lambda)p_g-2\lambda p_{g_0}-\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)x_{gi}=0\,, \tag{2.66}$$

$$\frac{\partial L}{\partial \xi_i^+}=\frac{2}{N\tau}\xi_i^+-\alpha_i=0\,, \tag{2.67}$$

$$\frac{\partial L}{\partial \xi_i^-}=\frac{2}{N\tau}\xi_i^--\alpha_i^*=0\,, \tag{2.68}$$

$$\frac{\partial L}{\partial \varepsilon}=\frac{2}{\tau}-\sum_{i=1}^{N}\alpha_i-\sum_{i=1}^{N}\alpha_i^*=0\,. \tag{2.69}$$

将式(2.66)-(2.69)代入式(2.65)，得到式(2.62)的对偶问题：

$$\arg\max_{\alpha_i,\alpha_i^*}\ \frac{1}{(1+2\lambda)}p_{g_0}^T p_{g_0}-\frac{2\lambda}{(1+2\lambda)}p_{g_0}^T\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)x_{gi}-\frac{1}{2(1+2\lambda)}\sum_{i=1}^{N}\sum_{j=1}^{N}(\alpha_i-\alpha_i^*)(\alpha_j-\alpha_j^*)x_{gi}^T x_{gj}-$$
$$\frac{N\tau}{4}\sum_{i=1}^{N}((\alpha_i)^2+(\alpha_i^*)^2)+\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)y_i \quad ,(2.70)$$

中国知网 https://www.cnki.net

又因为 $p_{g_0}^T p_{g_0}/(1+2\lambda)$ 为常数项，不影响上述对偶问题的求解，因此可将式(2.70)转化为：

$$\begin{aligned}\underset{\alpha_i,\alpha_i^*}{\arg\max}\quad & -\frac{2\lambda}{(1+2\lambda)}p_{g_0}^T\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)x_{gi}-\frac{1}{2(1+2\lambda)}\sum_{i=1}^{N}\sum_{j=1}^{N}(\alpha_i-\alpha_i^*)(\alpha_j-\alpha_j^*)x_{gi}^T x_{gj}- \\ & \frac{N\tau}{4}\sum_{i=1}^{N}((\alpha_i)^2+(\alpha_i^*)^2)+\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)y_i \qquad . \quad (2.71)\\ s.t.\quad & \alpha\geq 0,\alpha^*\geq 0 \quad \sum_{i=1}^{N}(\alpha_i+\alpha_i^*)=\frac{2}{\tau}\end{aligned}$$

令

$$\tilde{\alpha}=(\tilde{\alpha}_1,\tilde{\alpha}_2,\cdots,\tilde{\alpha}_N,\tilde{\alpha}_1^*,\tilde{\alpha}_2^*,\cdots,\tilde{\alpha}_N^*)=((\alpha)^T,(\alpha^*)^T)^T, \tag{2.72}$$

$$z_i=\begin{cases}x_{gi}, & i=1,2,\cdots,N,\\ -x_{g(i-N)}, & i=N+1,N+2,\cdots,2N,\end{cases} \tag{2.73}$$

$$\beta=(-\frac{2\lambda}{(1+2\lambda)}x_g p_{g_0}^T+y^T,\frac{2\lambda}{(1+2\lambda)}x_g p_{g_0}^T-y^T)^T, \tag{2.74}$$

其中 $y=(y_1,y_2,\cdots,y_N)^T$,则(2.71)式可转化为矩阵形式：

$$\begin{aligned}&\arg\max \quad -\tilde{\alpha}^T\tilde{K}\tilde{\alpha}+\tilde{\alpha}^T\beta\\ &s.t. \quad \tilde{\alpha}^T 1=1,\alpha_i\geq 0 \ \ \forall i\end{aligned}, \tag{2.75}$$

其中

$$\tilde{K}=[\tilde{k}_{ij}]_{2N\times 2N},\tilde{k}_{ij}=\frac{2\lambda}{1+2\lambda}z_i^T z_i+\frac{N\tau}{4}\delta_{ij}, \tag{2.76}$$

$$\delta_{ij}=\begin{cases}1, & i=j,\\ 0, & i\neq j.\end{cases} \tag{2.77}$$

根据文献[26]可知设 $\tilde{\alpha}=(\tilde{\alpha}_1,\tilde{\alpha}_2,\cdots,\tilde{\alpha}_N,\tilde{\alpha}_1^*,\tilde{\alpha}_2^*,\cdots,\tilde{\alpha}_N^*)^T$ 为对偶问题(2.75)的解，则原始问题对于 p_g 的求解即为全局最优解，并表示为：

$$p_g=\frac{2\lambda}{1+2\lambda}p_{g_0}+\frac{1}{1+2\lambda}\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)x_{gi}, \tag{2.78}$$

其中 α_i 和 α_i^* 为对偶问题的解， p_{g_0} 为迁移原始场景中的后件参数， $2\lambda p_{g_0}/(1+2\lambda)$ 为从历史场景中学习到的信息， $\sum_{i=1}^{N}(\alpha_i-\alpha_i^*)x_{gi}/(1+2\lambda)$ 为从当前场景中学习到的信息。根据上述理论，TSK-TFS 模型的训练步骤如下：

(1) 设置前件参数模糊规则数和正则参数分别是 K_h 和 τ_h；

(2) 利用 FCM 算法得到历史场景的系统前件参数，进而得到对应于回归模型的数据集 $D_h=\{x_{gi},y_i\},i=1,2,\cdots,N$；

(3) 利用式(2.53)求解拉格朗日乘子 λ_h^+ 和 λ_h^-；

(4) 根据步骤(3)得到的 λ_h^+ 和 λ_h^-，进而得到 p_h；

中国知网 https://www.cnki.net

(5) 设置模糊规则数、正则参数和平衡参数分别为$K=K_h$、τ和λ，令$p_{g_0}=p_h$；

(6) 继承历史场景的前件参数，并利用前件参数和式(2.44）得到数据集$D_c=\{x_{gi},y_i\}$，进而利用式(2.75)求解得到拉格朗日乘子α和α^*；

(7) 根据得到的α和α^*，利用式(2.78)得到p_g；

(8) 根据得到的后件参数和继承的前件参数生成 L2 型 TSK 迁移模糊系统。

2.7 长短期神经网络

长短期神经网络(LSTM)是特殊的 RNN，克服了 RNN 的梯度消失问题，能更好地捕捉长期依赖关系，适合处理时间序列数据，但 LSTM 的计算复杂度较高且需要大量的数据进行训练。LSTM 主要包括三个门，分别为遗忘门f_t、输入门i_t和输出门o_t，三个门的作用分别为：输入门控制当前时刻的候选状态$\tilde{C}_t$需要保存的信息；遗忘门控制上一时刻的内部状态C_{t-1}需要遗忘的信息；输出门控制当前时刻的内部状态C_t有多少信息需要输出到外部状态h_t。LSTM 模型中主要计算公式有：

$$\tilde{C}_t=\tanh(W_c\cdot[h_{t-1},x_t]+b_c), \tag{2.79}$$

$$i_t=\sigma\left(W_i\cdot[h_{t-1},x_t]+b_i\right), \tag{2.80}$$

$$f_t=\sigma(W_f\cdot[h_{t-1},x_t]+b_f), \tag{2.81}$$

$$C_t=f_tC_{t-1}+i_t\times\tilde{C}_t, \tag{2.82}$$

$$o_t=\sigma(W_o\cdot[h_{t-1},x_t]+b_o), \tag{2.83}$$

$$h_t=o_t\tanh(C_t), \tag{2.84}$$

其中$\sigma(\cdot)$和 tanh 分别 sigmoid 函数和双曲线正切函数，具体公式为：

$$\sigma(x)=\frac{1}{1+e^{-x}}, \tag{2.85}$$

$$\tanh(x)=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}, \tag{2.86}$$

其中式(2.85)的输出区间为(0，1)，x_t为当前时刻的输入，h_{t-1}为上一时刻的外部状态，h_t为每个存储块的激活向量，C_t为每个单元的激活向量，W_c、W_i、W_f和W_o为权重矩阵，b_c、b_i、b_f和b_o分别为系统状态、输入门、遗忘门和输出门的偏置参数。LSTM 的循环单元结构如图 2.9 所示：

中国知网 https://www.cnki.net

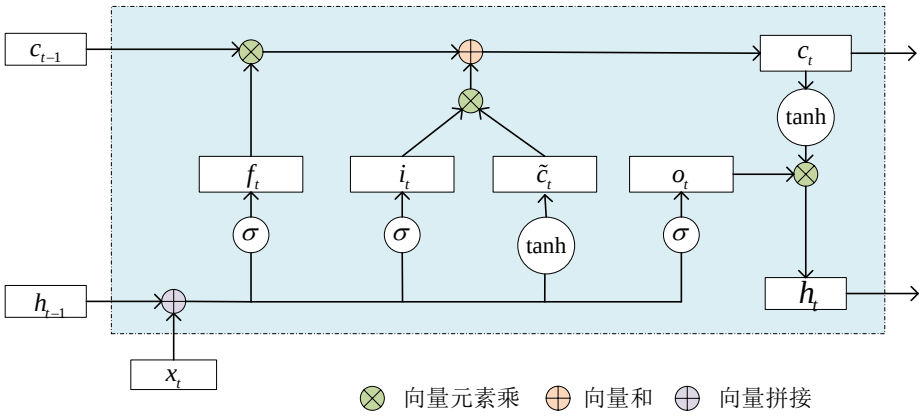


图 2.9 LSTM 循环结构图

Figure 2.9 LSTM loop structure diagram

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第3章 基于 VMD-ZOA-TFS 短期电力负荷预测方法研究

在了解电力负荷数据的特点、电力负荷预测的特性和相关方法后，本章基于 TSK 迁移模糊系统进行建模，针对 TSK-TFS 的可调参数，使用 ZOA 算法进行寻优，并采用减法聚类算法计算聚类个数，同时针对电力负荷序列的非线性和非平稳性，利用 VMD 分解将其分解为若干子序列。本章采用以上算法构建 VMD-ZOA-TFS 短期电力负荷预测模型，同时为了探讨迁移学习策略对短期电力负荷预测的影响，建立以 TSK-FS 为基础的短期电力负荷模型作为对比模型。

3.1 电力负荷数据获取与预处理

3.1.1 数据获取

本文的数据来源于欧洲国家的电力负荷数据集(https://data.open-power-system-data.org/)，电力负荷数据的颗粒度为一个小时，本文选取拉托维亚 2018 年 4 月 1 日至 2018 年 5 月 31 日和爱沙尼亚 2018 年 4 月 4 日至 2018 年 4 月 18 日的短期电力负荷数据，其中爱沙尼亚在时间段 4 月 9 日 12 时至 4 月 10 日 5 时存在数据缺失。本文将拉托维亚地区的数据作为源域，将爱沙尼亚地区的数据作为目标域，选取的天气因素包括气温、直接辐射和散射辐射，日期因素包括第几个小时、一周中的第几天、是否为休息日（休息日为 1，非休息日为 0）。将数据划分为训练集和测试集，其中训练集为源域数据和目标域中 2018 年 4 月 4 日至 2018 年 4 月 11 日的数据，测试集为爱沙尼亚 2018 年 4 月 12 日至 2018 年 4 月 18 日的数据。图 3.1 为拉托维亚电力负荷原始数据，图 3.2 为爱沙尼亚电力负荷原始数据，图中展示了爱沙尼亚电力负荷的缺失值。

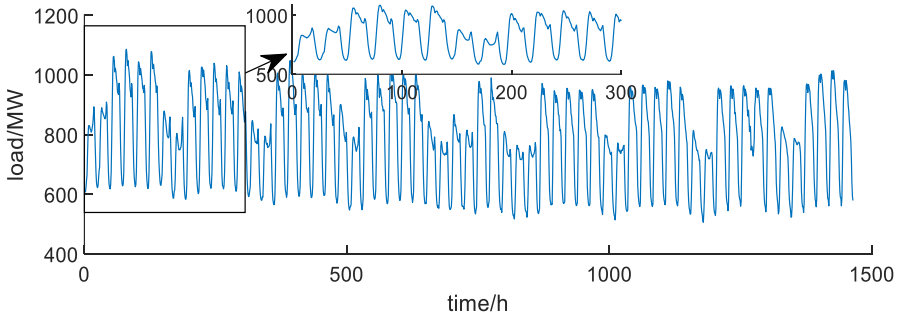


图 3.1 LV 电力负荷原始数据

Figure 3.1 LV power load raw data

中国知网 https://www.cnki.net

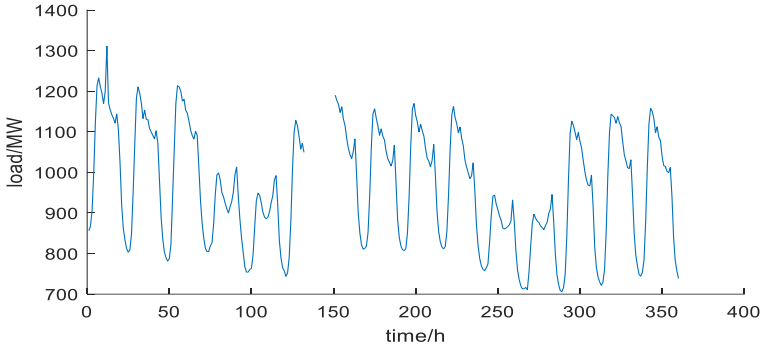


图 3.2 EE 电力负荷原始数据

Figure 3.2 EE power load raw data

3.1.2 数据统计特征

表 3.1 所示为拉托维亚（源域数据）和爱沙尼亚（目标域数据）的最大值、最小值、均值、标准差、偏度和峰度。

表 3.1 原始数据的统计特性

统计值	爱沙尼亚	拉托维亚
最大值	1086	1310.9
最小值	506	706.1
均值	783.6052	974.2717
标准差	144.5863	145.5383
偏度	-0.11715	0.050736
峰度	1.849546	1.921538

3.1.3 数据预处理

对短期电力负荷进行预测的过程中，电力负荷数据可能会存在异常值，而数据中的异常值对模型的预测结果会产生不利影响，因此需要对此类型的数据进行处理。常用的异常值处理方法主要有删除异常值、替换异常值、插值处理、离群点检测和基于规则的方法等。

在进行电力负荷预测时，会利用多个影响因素包括天气和日期因素，由于各个因素的量纲不一致，会影响预测结果，因此在进行预测前需要对数据做归一化处理，将数据映射至区间[0,1]，公式如下：

$$x_{ij} = \frac{x_{ij}^{'} - x_{\min}}{x_{\max} - x_{\min}}, \tag{3.1}$$

其中 $X = \{x_{ij}^{'}\}$ 为原始数据，$x_{\max}$ 和 $x_{\min}$ 分别为 $x_{ij}^{'}$ 所在列的最大值和最小值，x_{ij} 为归一化后的数据。

中国知网 https://www.cnki.net

3.2 评价指标

本文采用平均绝对百分误差(Mean Absolute Percentage Error, MAPE)、平均误差(Mean Absolute Error, MAE)和均方根误差(Root Mean Squared Error, RMSE)对模型预测精度进行评估。具体公式为：

$$MAPE=\frac{1}{N}\sum_{i=1}^{N}\frac{|y_i-\hat{y}_i|}{y_i}\times 100\%, \tag{3.2}$$

$$MAE=\frac{1}{N}\sum_{i=1}^{N}|y_i-\hat{y}_i|, \tag{3.3}$$

$$RMSE=\sqrt{\frac{\sum_{i=1}^{N}(y_i-\hat{y}_i)^2}{N}}, \tag{3.4}$$

其中 y_i 为第 i 个时刻的电力负荷的真实值，$\hat{y}_i$ 为第 i 个时刻的电力负荷的预测值，N 为测试集中样本的总个数，以上 3 个指标的值越小，则表明模型的预测性能越优。

3.3 基本步骤与建模流程

基于迁移模糊系统建立短期电力负荷模型，令源域的数据为 $D_h=[X_h,Y_h]$，$X_h=[X_{h1},X_{h2}\cdots,X_{h6}]$，目标域的数据为 $D_m=[X_m,Y_m]$，$X_m=[X_{m1},X_{m2}\cdots,X_{m6}]$，VMD-ZOA-TFS 模型的步骤如下：

(1) 首先利用最小样本熵确定 VMD 分解的序列数 $K=7$，后将短期电力负荷原始信号 $Y=[Y_h,Y_m]$ 进行 VMD 分解为 7 个子序列得到 $Y'=[Y'_{h1},Y'_{m1};Y'_{h2},Y'_{m2};\cdots;Y'_{hK},Y'_{m7}]$，选取 3 个天气因素和 3 个日期因素即 $X=[X_h,X_m]$；

(2) 利用 Y' 和 X' 分别利用减法聚类算法得到聚类个数 $M=[M_1,M_2\cdots,M_7]$；

(3) 将 Y' 和 X' 划分为训练集和测试集；

(4) 根据步骤(3)中的训练集数据并利用 ZOA 算法对 TSK-TFS 的参数 τ 和 λ 进行寻优；

(5) 将最优参数代入 TSK-TFS 中，将步骤(4)中训练集代入 TSK-TFS 模型中，保留后件参数 p_{g_0} 和 p_g；

(6) 继承后件参数 p_{g_0} 和 p_g 并对步骤(4)中测试集进行预测得到各个子序列的预测值；

(7) 将各个子序列的预测值重组叠加，即可得到测试集的短期电力负荷预测值。图 3.3 展示了 VMD-ZOA-TFS 模型的流程图，一共分为 4 个部分：第一部分对数据进行处理，即利用 VMD 对短期电力负荷数据进行分解；第二部分根据第一部分处理得到的数据采用减法聚类得到聚类数，得到的聚类数为 TSK 模糊系统的前件参数 M；第三部分

中国知网 https://www.cnki.net

利用斑马优化算法对 TSK 模糊迁移系统中的参数寻优；第四部分利用第二和三部分得到的参数和第一部分得到的数据，采用迁移学习的策略对测试集进行预测。

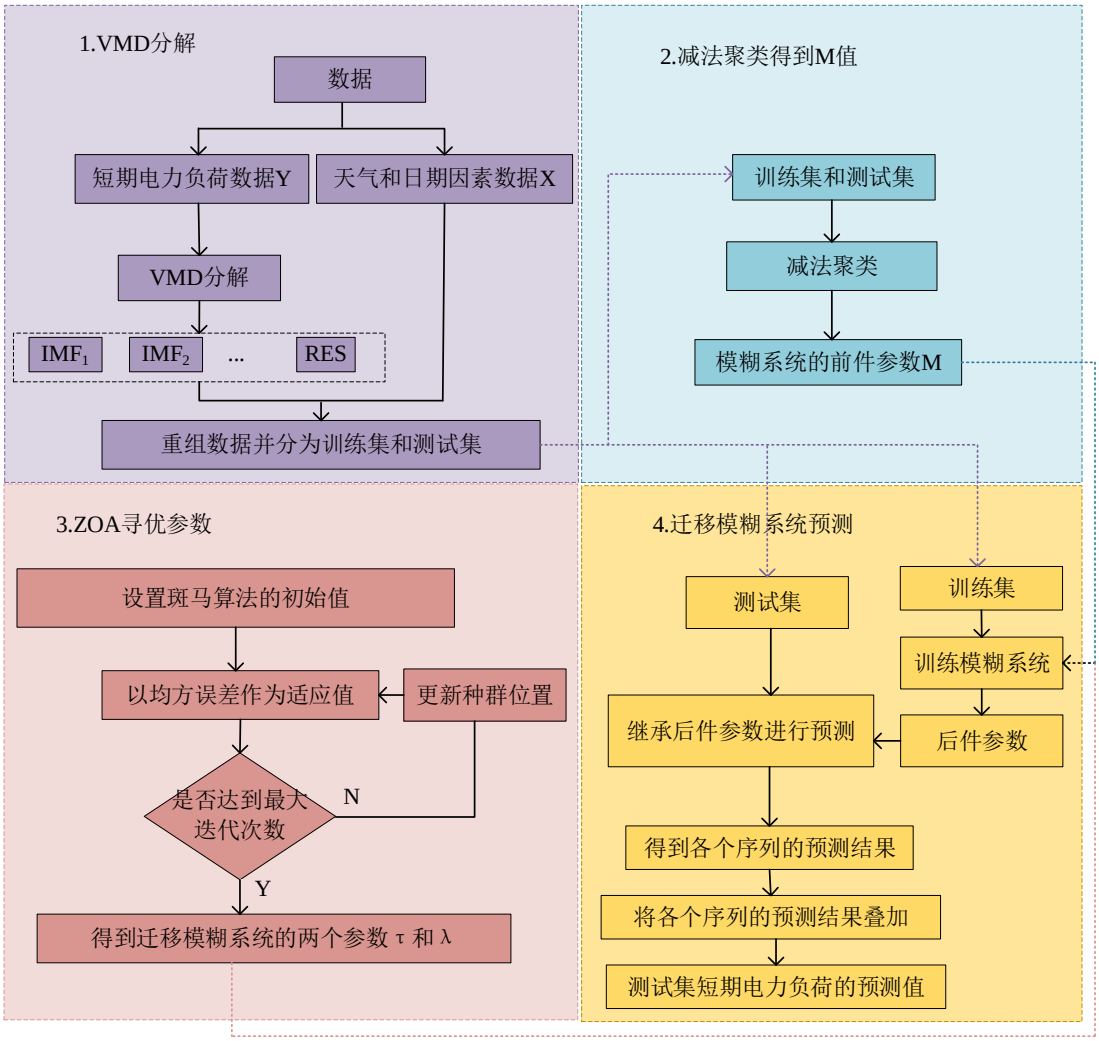


图 3.3 VMD-ZOA-TFS 模型流程图

Figure 3.3 VMD-ZOA-TFS model flowchart

3.4 仿真实验

在 MATLAB2021a 环境下，基于电力负荷数据对模型进行仿真实验，并对预测结果进行分析。

由于 VMD 的分解序列个数可以人为设定，而分解个数影响 VMD 对电力负荷序列的分解效果，因此借助样本熵确定分解个数。样本熵可以计算时间序列的复杂度，因此利用最小样本熵就可以找到最优的分解个数，根据最优分解个数可以有效地对电力负荷序列进行分解，图 3.4 展示了 VMD 的分解个数对应的最小样本熵：

中国知网 https://www.cnki.net

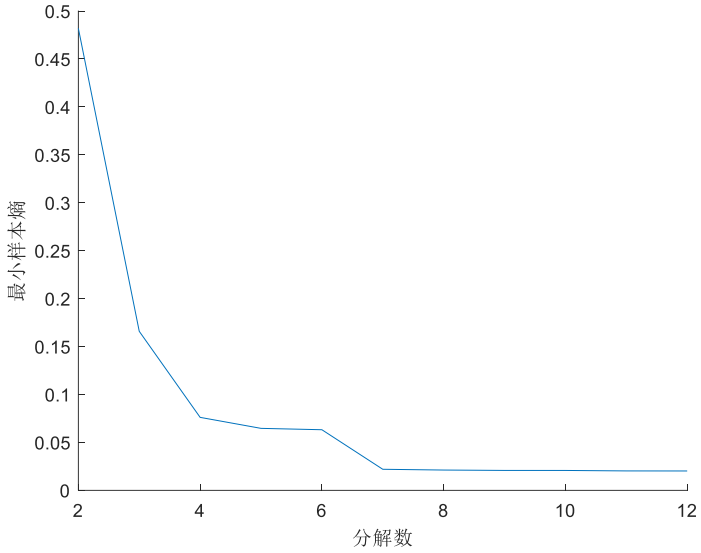


图 3.4 不同分解个数对应的最小样本熵

Figure 3.4 The minimum sample entropy corresponding to different decomposition numbers

从图 3.4 可知，当分解个数达到 7 时，对应的最小样本熵趋于稳定，说明当分解数大于 7 时，对应的最小样本熵基本保持不变，因此选取 VMD 分解序列的个数为 7。VMD 短期电力负荷分解序列如图 3.5 所示，为了验证 VMD 的分解效果，采用 EEMD 对短期电力负荷序列分解，EEMD 将短期电力负荷分解为 11 个子序列，分解序列如图 3.6 所示。

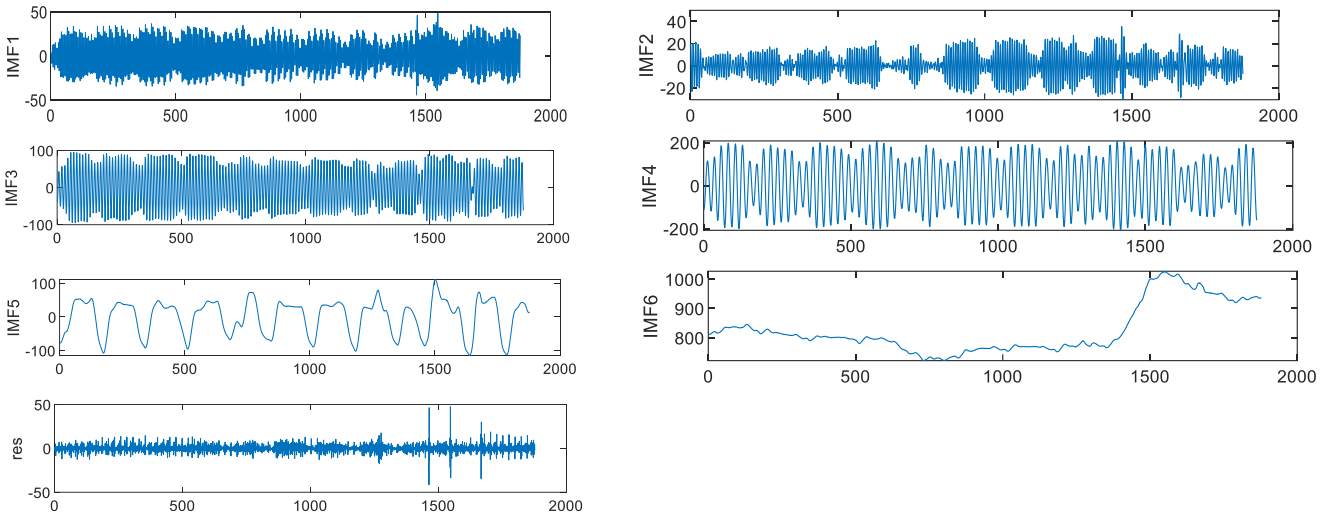


图 3.5 VMD 电力负荷分解序列图

Figure 3.5 VMD power load decomposition sequence

中国知网 https://www.cnki.net

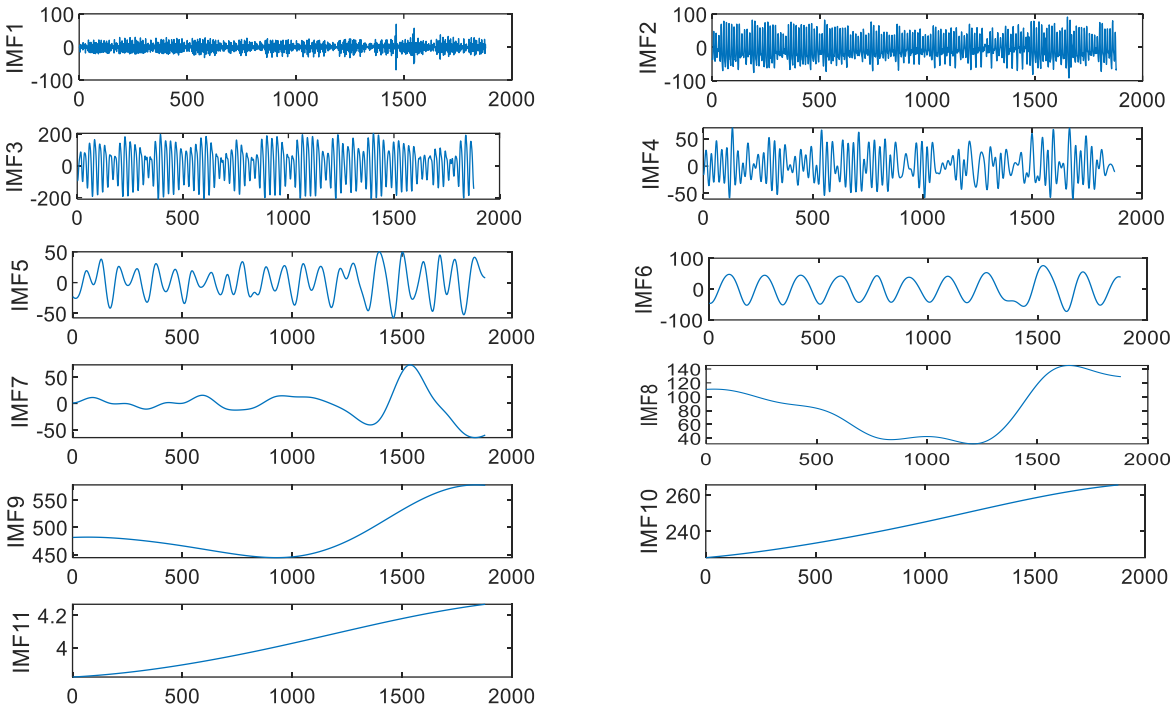


图 3.6 EEMD 电力负荷分解序列

Figure 3.6 EEMD power load decomposition sequence

图 3.7 和 3.8 展示了 VMD 分解和 EEMD 分解的子序列之和与原始信号的差值，从两个图中可以看出 VMD 分解对应差值绝对值的最大值约为 $5.8*10^{-12}$，EEMD 分解对应的差值绝对值的最大值约为 2，因此利用 VMD 对电力负荷序列进行分解得到的差值远远小于 EEMD 分解得到的差值，所以利用 VMD 可以更准确地分解电力负荷序列。

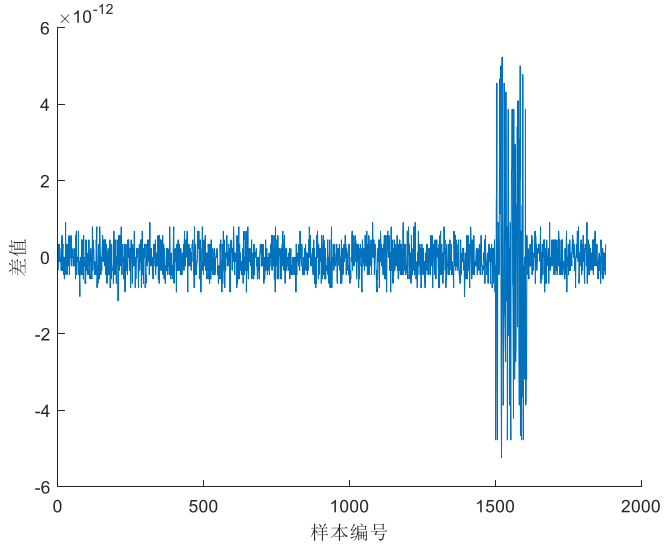


图 3.7 VMD 分解的差值

Figure 3.7 Difference in VMD decomposition

中国知网 https://www.cnki.net

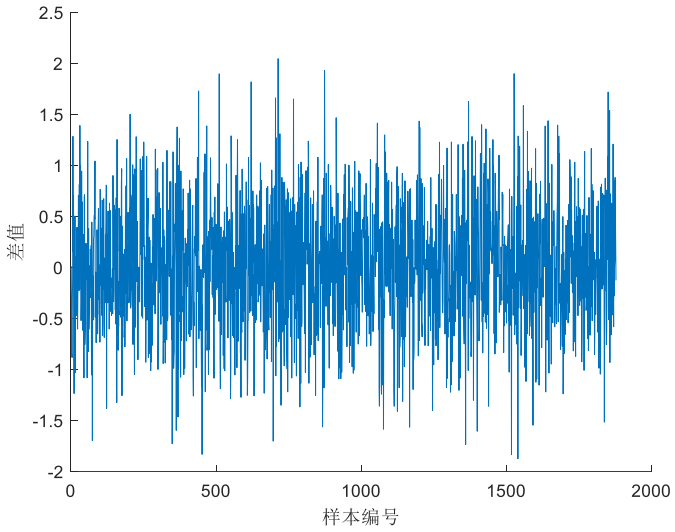
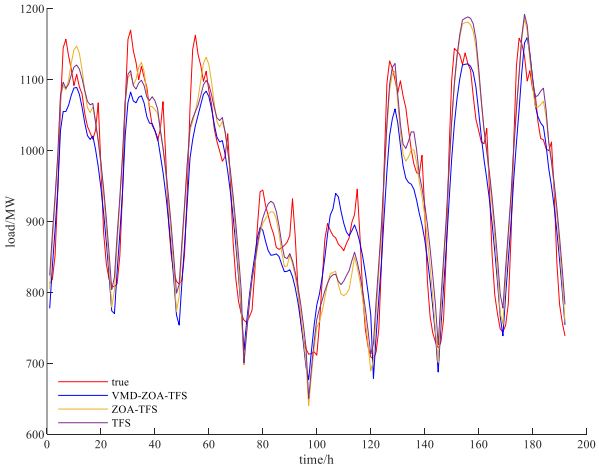


图 3.8 EEMD 分解的差值

Figure 3.8 Difference in EEMD decomposition

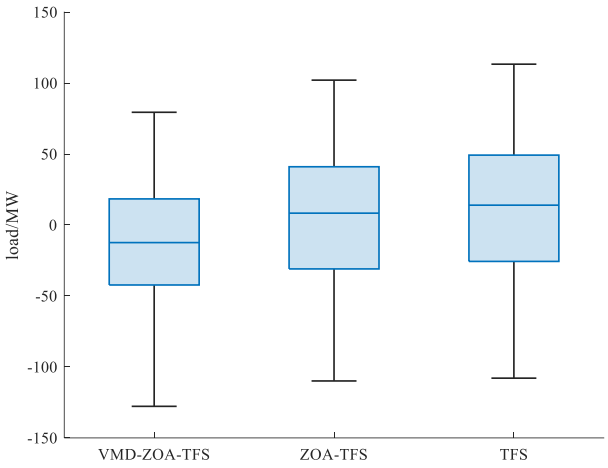
3.5 模型对比与分析

为了验证 VMD-ZOA-TFS 短期电力负荷预测模型的预测性能，设计对比实验 1,其中对比模型包括 ZOA-TFS 和 TFS，为了比较迁移学习策略对预测结果的影响，设计对比实验 2，其中对比模型为 VMD-ZOA-FS、ZOA-FS 和 FS，仿真实验结果如图 3.9 所示，其中图 3.9(a)和 3.9(c)分别为对比实验 1 和对比实验 2 的预测值与真实值的对比图，图 3.9(b)和图 3.9(d)分别为对比实验 1 和对比实验 2 误差的箱型图，从图 3.9(a)和 3.9(b)可以看出 VMD-ZOA-TFS 短期电力负荷模型的预测精度更高，且其误差的均值更接近于 0，同时误差值更集中在 0 附近。

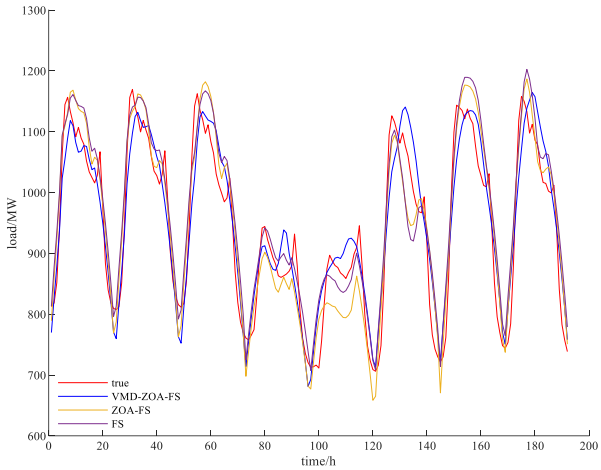


(a) 对比实验 1 预测值与真实值

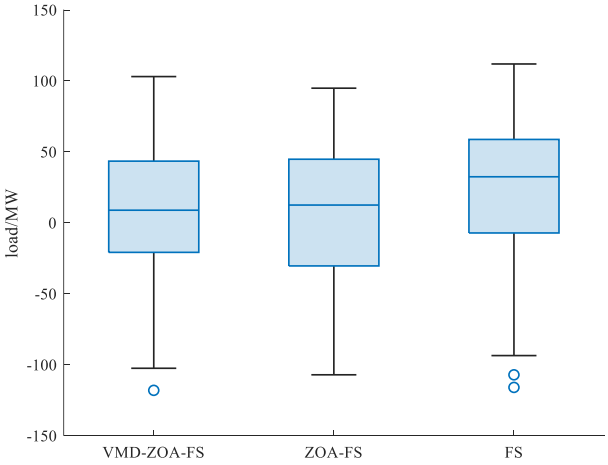
中国知网 https://www.cnki.net



(b) 对比实验 1 误差箱线图



(c) 对比实验 2 预测值与真实值



(d) 对比实验 2 误差箱线图

图 3.9 对比实验预测结果和误差箱线图

Figure 3.9 Compare the predicted results of the model with the error box-plot

中国知网 https://www.cnki.net

表 3.2 展示了各个模型的统计指标值，从表中可以看出，采用迁移学习策略时，在 ZOA-TFS 的基础上，使用 VMD 分解得到模型的 MAPE 比不使用分解算法所得模型的 MAPE 低 0.19%。ZOA-TFS 模型的 MAPE 较 TFS 模型低 0.34%。使用迁移学习策略的 TFS 模型的 MAPE 较 FS 低 0.13%。ZOA-TFS 模型的 MAPE 比 ZOA-FS 低 0.23%。VMD-ZOA-TFS 模型的 MAPE 比 VMD-ZOA-FS 低 0.09%。综上所述，使用迁移策略、斑马优化算法和 VMD 分解可以提高模型的预测性能，使得模型的预测精度更高。

表 3.2 各个模型的统计指标值

模型	MAPE	MAE	RMSE
VMD-ZOA-TFS	**4.05**	**38.49**	48.67
ZOA-TFS	4.24	39.34	**46.92**
TFS	4.58	41.94	49.88
VMD-ZOA-FS	4.14	38.53	46.95
ZOA-FS	4.47	41.21	47.84
FS	4.71	43.20	50.02

3.6 本章小结

本章根据第二章中的算法构建基于 TSK 迁移模糊系统的短期电力负荷模型，并构建基于 TSK-FS 短期电力负荷预测方法作为对比模型。将数据代入模型进行仿真实验，仿真实验结果表明本章提出的 VMD-ZOA-TFS 短期电力负荷模型的预测性能更优。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第4章 基于 VMD-TCA-IZOA-TFS 短期电力负荷预测方法研究

在第三章的基础上，本章对 ZOA 算法进行改进，提高 ZOA 算法的性能。同时考虑到源域数据和目标域数据之间的分布差异，利用 TCA 减小源域和目标域之间的距离，同时降低相关因素数据的维度。本章将探讨引入 IZOA 和 TCA 对模型预测精度的影响，同时为了探讨 TSK 迁移模糊系统对短期电力负荷预测性能的影响，选取传统机器学习中的 LSTM 为代表验证 TSK 迁移模糊系统的预测性能。

4.1 IZOA 算法及测试

4.1.1 IZOA 算法

基于 ZOA 算法，为了更好地得到优化算法的寻优结果，本文引入莱维飞行对 ZOA 算法的种群初始化，在防御阶段利用正态分布数生成两种策略的切换概率对防御策略进行选择。改进策略如下：

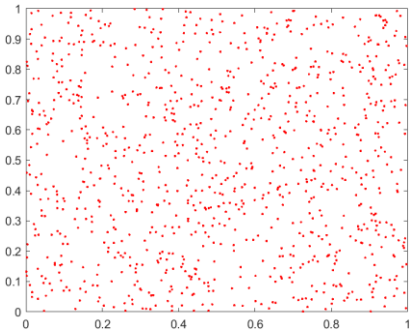
(1) 智能优化算法的收敛速度和全局搜索能力均会受到初始种群的影响，利用莱维飞行初始化斑马种群的寻优空间，使得寻优空间中初始种群的分布更具有随机性，增加全局搜索能力，莱维飞行的计算公式为：

$$s=\frac{u}{|v|^{1/\beta}}, \tag{4.1}$$

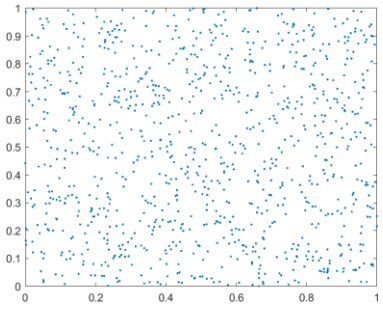
其中 $u\sim N(0,\sigma^2), v\sim N(0,1), \sigma=\left\{\frac{\Gamma(1+\beta)\sin(\frac{\pi\beta}{2})}{\beta\Gamma(\frac{1+\beta}{2})2^{\frac{\beta-1}{2}}}\right\}^{\frac{1}{\beta}}$ ，β 为莱维分布参数，通常取 1.5，则初始化种群为：

$$x_{i,j}=lb_j+(s_{i,j}-[s_{i,j}])(ub_j-lb_j), i=1,2,\cdots,n,\ j=1,2,\cdots,m, \tag{4.2}$$

其中 $s_{i,j}$ 为莱维飞行生成的步长，[·] 为取整符号。图 4.1 展示了两种策略初始化种群的散点图。



(a) 莱维飞行初始化种群



(b) 随机初始化种群

图 4.1 莱维飞行策略与随机初始化种群

Figure 4.1 Lévy flight strategy and randomly initialized population

中国知网 https://www.cnki.net

(2) 对防御阶段中两种策略的切换概率进行改进，由于两种策略分别是针对狮子与其他捕食者，而遇见其它捕食者的概率比遇见狮子的概率更大，因此设置 $P_S \sim N(0,1)$，为了使切换概率处于[0,1]，令：

$$P_S = \begin{cases} 1, & P_S \geq 1, \\ 0, & P_S \leq 0, \\ P_S, & else, \end{cases} \tag{4.3}$$

将式(2.35)改为：

$$x_{i,j}^{new,P2} = \begin{cases} x_{i,j} + R(2r-1)(1-\dfrac{t}{T})x_{i,j}, & P_s > 0.5, \\ x_{i,j} + r(AZ_j - I \cdot x_{i,j}), & else. \end{cases} \tag{4.4}$$

根据上述改进策略，IZOA 算法的步骤如下：

(1) 设置初始值种群数、种群维度和最大迭代数分别为 n , m 和 T ；

(2) 利用式(4.2)生成初始种群，计算种群的适应度值；

(3) 更新先锋斑马的位置，利用式(2.33)计算其他斑马的位置并进行更新；

(4) 根据式(4.3)生成 P_s，并根据式(4.4)选择更新位置的策略并更新斑马的位置，保留最优解；

(5) 判断是否达到最大迭代数，若是则输出最优解，否则返回步骤(3)。

4.1.2 IZOA 算法测试

4.1.2.1 基准函数

为了检验 IZOA 算法的收敛速度和稳定性，利用文献[51]中的单峰目标函数(F1-F7)、多峰目标函数(F8-F13)和固定维的多峰目标函数(F14-F23)测试 IZOA 算法的性能，表 4.1 展示了基准函数以及函数自变量的取值范围、维数和函数的最优值。

表 4.1 测试函数

函数	范围	维数	最优值
$F_1(X) = \sum_{i=1}^{m} x_i^2$	[-100,100]	30	0
$F_2(X) = \sum_{i=1}^{m} \lvert x_i \rvert + \prod_{i=1}^{m} \lvert x_i \rvert$	[-10,10]	30	0
$F_3(X) = \sum_{i=1}^{m} (\sum_{j=1}^{i} x_j)^2$	[-100,100]	30	0
$F_4(X) = \max\{\lvert x_i \rvert\}, 1 \leq i \leq m$	[-100,100]	30	0
$F_5(X) = \sum_{i=1}^{m-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$	[-30,30]	30	0
$F_6(X) = \sum_{i=1}^{m} (\lfloor x_i + 0.5 \rfloor)^2$	[-100,100]	30	0

中国知网 https://www.cnki.net

表 4.1 测试函数（续）

$F_7(X)=\sum_{i=1}^{m} ix_i^4+r$	[-1.28,1.28]	30	0
$F_8(X)=\sum_{i=1}^{m} -x_i\sin\left(\sqrt{\lvert x_i\rvert}\right)$	[-500,500]	30	-12569
$F_9(X)=\sum_{i=1}^{m}[x_i^2-10\cos(2\pi x_i)+10]$	[-5.12,5.12]	30	0
$F_{10}(X)=-20\exp\left(-0.2\sqrt{\frac{1}{m}\sum_{i=1}^{m}x_i^2}\right)-\exp\left(\frac{1}{m}\sum_{i=1}^{m}\cos(2\pi x_i)\right)+20+e$	[-32,32]	30	0
$F_{11}(X)=\frac{1}{4000}\sum_{i=1}^{m}x_i^2-\prod_{i=1}^{m}\cos\left(\frac{x_i}{\sqrt{i}}\right)+1$	[-600,600]	30	0
$F_{12}(X)=\frac{\pi}{m}\{10\sin^2(\pi y_1)+\sum_{i=1}^{m}(y_i-1)^2[1+10\sin^2(\pi y_{i+1})]+(y_n-1)^2\}+\sum_{i=1}^{m}u(x_i,10,100,4).where$ $y_i=1+\frac{x_i+1}{4}, u(x_i,a,i,n)=\begin{cases}k(x_i-a)^n, & x_i>a;\\ 0, & -a\le x_i\le a;\\ k(-x_i-a)^n, & x_i<-a.\end{cases}$	[-50,50]	30	0
$F_{13}(X)=0.1\{\sin^2(3\pi x_1)+\sum_{i=1}^{m}(x_i-1)^2[1+\sin^2(3\pi x_i+1)]+(x_n-1)^2[1+\sin^2(2\pi x_m)]\}+\sum_{i=1}^{m}u(x_i,5,100,4),$ $where\ u(x_i,a,i,n)=\begin{cases}k(x_i-a)^n, & x_i>a;\\ 0, & -a\le x_i\le a;\\ k(-x_i-a)^n, & x_i<-a.\end{cases}$	[-50,50]	30	0
$F_{14}(X)=\left(\frac{1}{500}+\sum_{j=1}^{25}\frac{1}{j+\sum_{i=1}^{2}(x_i-a_{ij})^6}\right)^{-1}$	[-65.63,65.63]	2	0.998
$F_{15}(X)=\sum_{i=1}^{11}\left[a_i-\frac{x_1(b_i^2+b_ix_2)}{b_i^2+b_ix_3+x_4}\right]^2$	[-5,5]	4	0.0003
$F_{16}(X)=4x_1^2-2.1x_1^4+\frac{1}{3}x_1^6+x_1x_2-4x_2^2+4x_2^4$	[-5,5]	2	-1.0316

中国知网 https://www.cnki.net

表 4.1 测试函数（续）

$F_{17}(X)=\left(x_2-\frac{5.1}{4\pi^2}x_1^2+\frac{5}{\pi}x_1-6\right)^2+10\left(1-\frac{1}{8\pi}\right)\cos x_1+10$	[-5,10]×[0,15]	2	0.398
$F_{18}(X)=[1+(x_1+x_2+1)^2(19-14x_1+3x_1^2-14x_2+6x_1x_2+3x_2^2)]$ $[30+(2x_1-3x_2)^2(18-32x_1+12x_1^2+48x_2-36x_1x_2+27x_2^2)]$	[-5,5]	2	3
$F_{19}(X)=-\sum_{i=1}^{4}c_i\exp(-\sum_{j=1}^{3}a_{ij}(x_j-p_{ij})^2)$	[0,1]	3	-3.86
$F_{20}(X)=-\sum_{i=1}^{4}c_i\exp(-\sum_{j=1}^{6}a_{ij}(x_j-p_{ij})^2)$	[0,1]	6	-3.22
$F_{21}(X)=-\sum_{i=1}^{5}[(X-a_i)\cdot(X-a_i)^T+6c_i]^{-1}$	[0,10]	4	-10.153
$F_{22}(X)=-\sum_{i=1}^{7}[(X-a_i)\cdot(X-a_i)^T+6c_i]^{-1}$	[0,10]	4	-10.429
$F_{23}(X)=-\sum_{i=1}^{10}[(X-a_i)\cdot(X-a_i)^T+6c_i]^{-1}$	[0,10]	4	-10.536

4.1.2.2 测试结果

对 IZOA 算法的性能进行验证，将其与 ZOA 算法和 PSO 算法作对比，算法的参数设置如下：

(1) 设置 IZOA 算法和 ZOA 算法的种群数为 30，最大迭代数为 500;

(2) 设置 PSO 算法的种群数为 30，最大迭代数为 500，学习因子设置为 1.5 和 2，选定 30 次测试结果的均值和标准差作为评价指标，测试结果如表 4.2 所示，从表 4.2 中可以看到 IZOA 在求解目标函数 F1-F4、F7、F12、F14 和 F19-F22 具有较好的效果；在 F6、F9-F11 上与 ZOA 效果相同而 PSO 效果较差；在 F16-F17 上均值相同，标准差较大；在 F5 上标准差较小，而均值较大；在 F13 上 IZOA 的均值较小，标准差较大；F8、F15、F18 和 F23 上 IZOA 得到的均值和方差更大。

表 4.2 IZOA、ZOA 和 PSO 在目标函数上测试结果

函数		IZOA	ZOA	PSO
F1	均值	**9.22E-268**	1.37E-240	0.024817
	标准差	**0**	0	0.055927
F2	均值	**9.87E-140**	2.02E-130	0.333026
	标准差	**4.06E-139**	6.88E-130	0.285142

中国知网 https://www.cnki.net

表 4.2 IZOA、ZOA 和 PSO 在目标函数上测试结果（续）

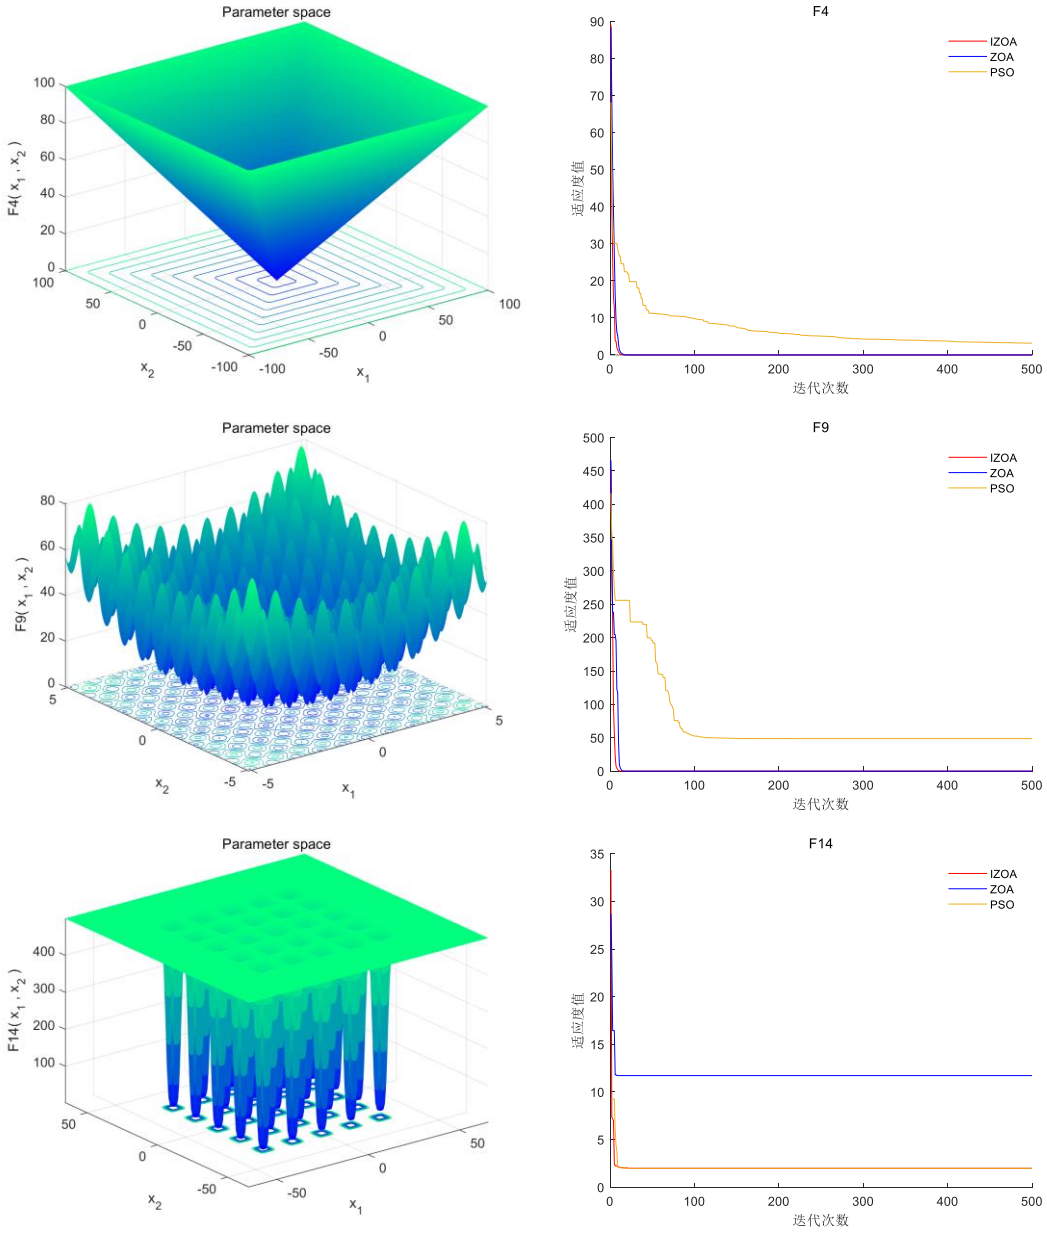
F3	均值	**4.77E-166**	1.08E-156	0.015140
	标准差	**0**	4.74E-156	3.127654
F4	均值	**2.59E-120**	1.08E-113	0.033273
	标准差	**1.20E-119**	4.57E-113	1.440303
F5	均值	28.61344755	**28.52672286**	113.1357
	标准差	**0.255728231**	0.350826085	89.05912
F6	均值	**0**	**0**	27.76667
	标准差	**0**	**0**	23.35289
F7	均值	**9.61E-05**	0.00013911	0.04773
	标准差	**6.25E-05**	0.000100813	0.017453
F8	均值	-6402.759364	**-6423.67752**	-6486.47
	标准差	828.1037256	**693.9883429**	909.3869
F9	均值	**0**	**0**	55.38875
	标准差	**0**	**0**	12.67008
F10	均值	**8.88E-16**	**8.88E-16**	1.976292
	标准差	**0**	**0**	0.715075
F11	均值	**0**	**0**	0.09606
	标准差	**0**	**0**	0.159514
F12	均值	**0.234824864**	0.239447723	0.548658
	标准差	**0.106168095**	0.127572208	0.622292
F13	均值	**2.428783623**	2.460148924	1.20335
	标准差	0.218364855	**0.199971367**	1.34666
F14	均值	**3.756360188**	4.536016787	5.662878
	标准差	**2.765724455**	3.35399463	4.383336
F15	均值	0.00176706	**0.000998883**	0.000549
	标准差	0.005064112	0.003657687	**0.000392**
F16	均值	**-1.03163**	**-1.03163**	**-1.03163**
	标准差	2.24E-09	2.25E-09	**6.18E-16**
F17	均值	**0.397887**	**0.397887**	**0.397887**
	标准差	2.10E-07	3.13E-07	**0**
F18	均值	4.800019143	5.700012161	**3**
	标准差	6.850114354	8.238467453	**1.62E-15**
F19	均值	**-3.861776593**	-3.78464901	-3.81125
	标准差	**0.001058617**	0.23559438	0.196121
F20	均值	**-3.30293092**	-3.2904824	-3.26255
	标准差	**0.045990378**	0.066301856	0.060463

中国知网 https://www.cnki.net

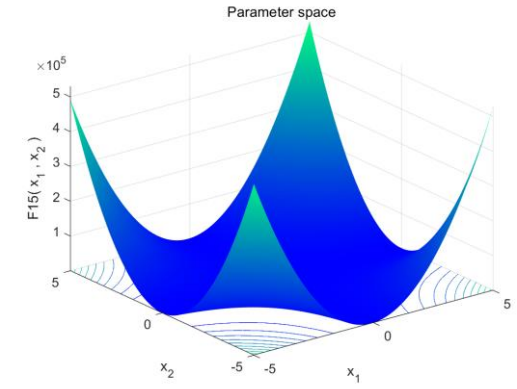
表 4.2 IZOA、ZOA 和 PSO 在目标函数上测试结果（续）

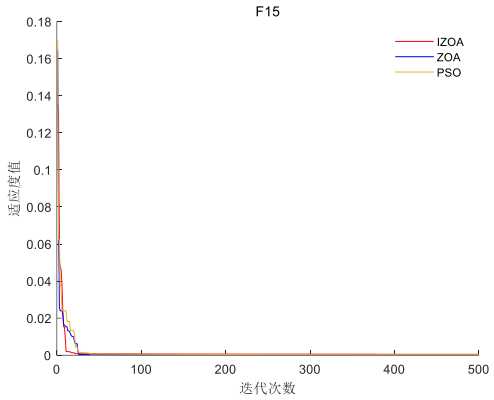
F21	均值	**-9.981233067**	-9.64283446	-5.74461
	标准差	**0.930406462**	1.555359299	3.68735
F22	均值	**-9.339401578**	-8.80810259	-6.40465
	标准差	**2.162217334**	2.477339729	3.621374
F23	均值	-9.454671198	**-9.99549495**	-4.61364
	标准差	2.200079619	**1.650078432**	3.34666

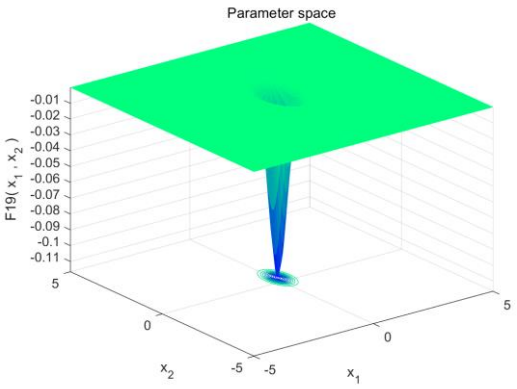
图 4.2 展示了 3 种算法在基准函数 F4、F9、F14、F15、F19、F20、F21 和 F22 上的收敛曲线以及在以上基准函数二维情况下的函数图像，从图 4.1 中展示的三种优化算法的收敛曲线可以直观地看出 IZOA 可以较快地收敛至最优值。

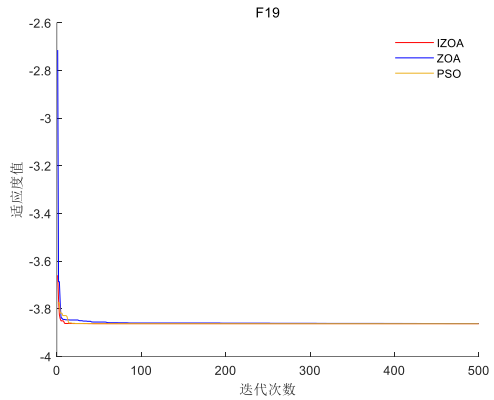


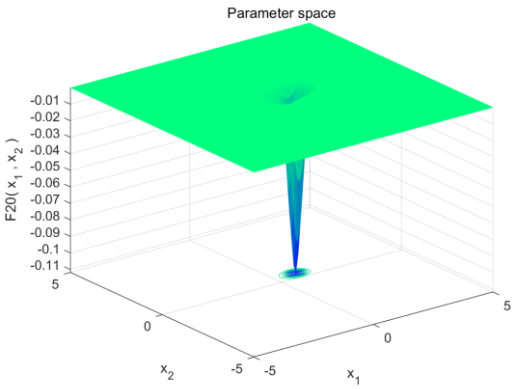
中国知网 https://www.cnki.net

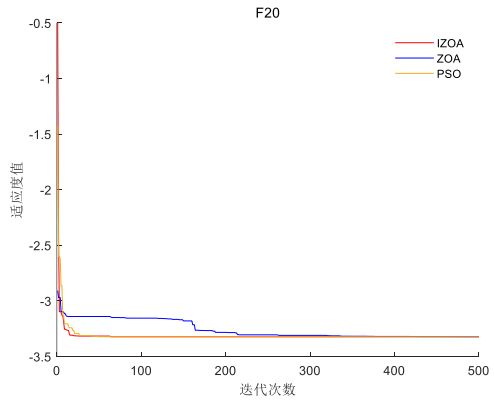


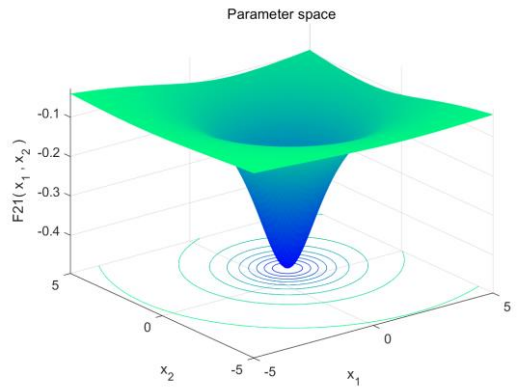


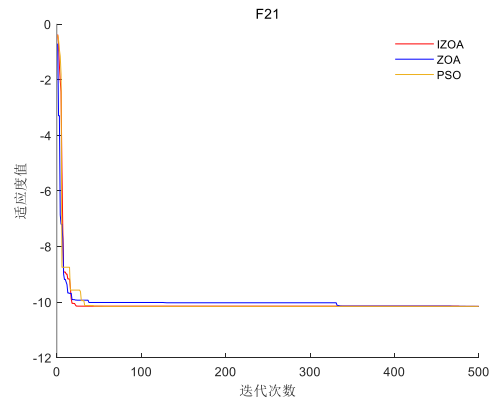












中国知网 https://www.cnki.net

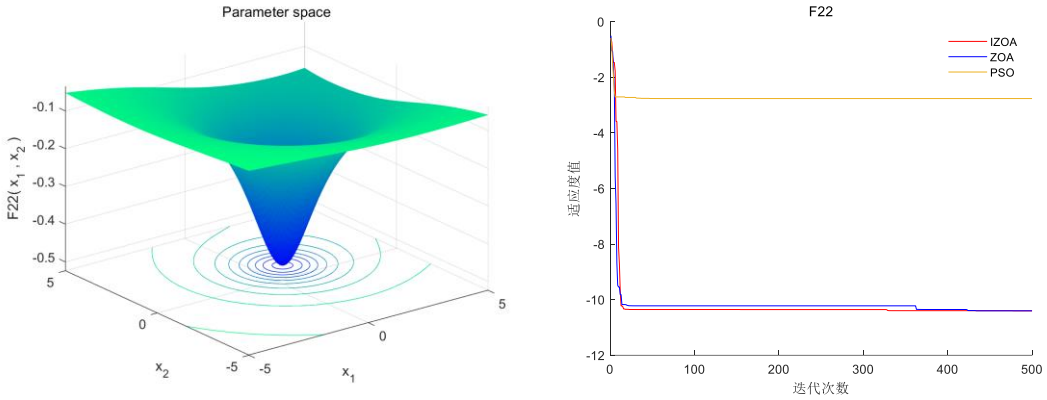


图 4.2 基准函数和收敛迭代图

Figure 4.2 Benchmark function and convergence iteration diagram

4.2 基本步骤与建模流程

令源域数据 $D_h=[X_h,Y_h]$，其中 $X_h=[X_{h1},X_{h2}\cdots,X_{h6}]$，目标域数据 $D_m=[X_m,Y_m]$，其中 $X_m=[X_{m1},X_{m2}\cdots,X_{m6}]$，VMD-TCA-IZOA-TFS 短期电力负荷预测模型的具体步骤如下：

(1) 首先利用最小样本熵确定 VMD 分解的序列数 $K=7$，后将短期电力负荷原始信号 $Y=[Y_h,Y_m]$ 进行 VMD 分解为 K 个子序列得到 $Y^{'}=[Y_{h1}^{'},Y_{m1}^{'};Y_{h2}^{'},Y_{m2}^{'}\cdots;Y_{hK}^{'},Y_{m7}^{'}]$，选取 3 个天气因素和 3 个日期因素即 $X=[X_h,X_m]$；

(2) 利用 TCA 将原始数据中源域和目标域的天气因素和日期因素进行降维并将两个域之间的距离减小得到 $X^{'}=[X_h^{'},X_m^{'}]$ 为 3 维数据；

(3) 利用 $Y^{'}$ 和 $X^{'}$ 分别利用减法聚类算法得到聚类个数 $M=[M_1,M_2\cdots,M_7]$；

(4) 将 $Y^{'}$ 和 $X^{'}$ 划分为训练集和测试集；

(5) 根据步骤(1)和步骤(2)中的数据并利用 IZOA 对 TSK-TFS 的参数 τ 和 λ 进行寻优；

(6) 将最优参数代入 TSK-TFS 中，利用步骤(4)中的训练集对 TSK-TFS 进行训练，保留后件参数 p_{g_0} 和 p_g；

(7) 继承后件参数 p_{g_0} 和 p_g 并对步骤(4)中测试集进行预测；

(8) 将得到的各个预测值序列重组叠加，即可得到测试集上短期电力负荷的预测值。

VMD-TCA-IZOA-TFS 短期电力负荷预测模型的流程如图 4.3 所示，流程图共分为四个部分：第一部分为对数据进行处理，即利用 VMD 分解对短期电力负荷数据进行分解，利用 TCA 对天气和日期因素降维，同时减小源域和目标域之间的距离；第二部分根据第一部分处理得到的数据采用减法聚类得到聚类数，即 TSK-FS 的前件参数 M；第三部分为利用 IZOA 算法对 TSK-TFS 中的参数进行寻优；第四部分是利用前三部分得到的数据和参数，利用 TSK-TFS 对短期电力负荷序列进行训练和预测。

中国知网 https://www.cnki.net

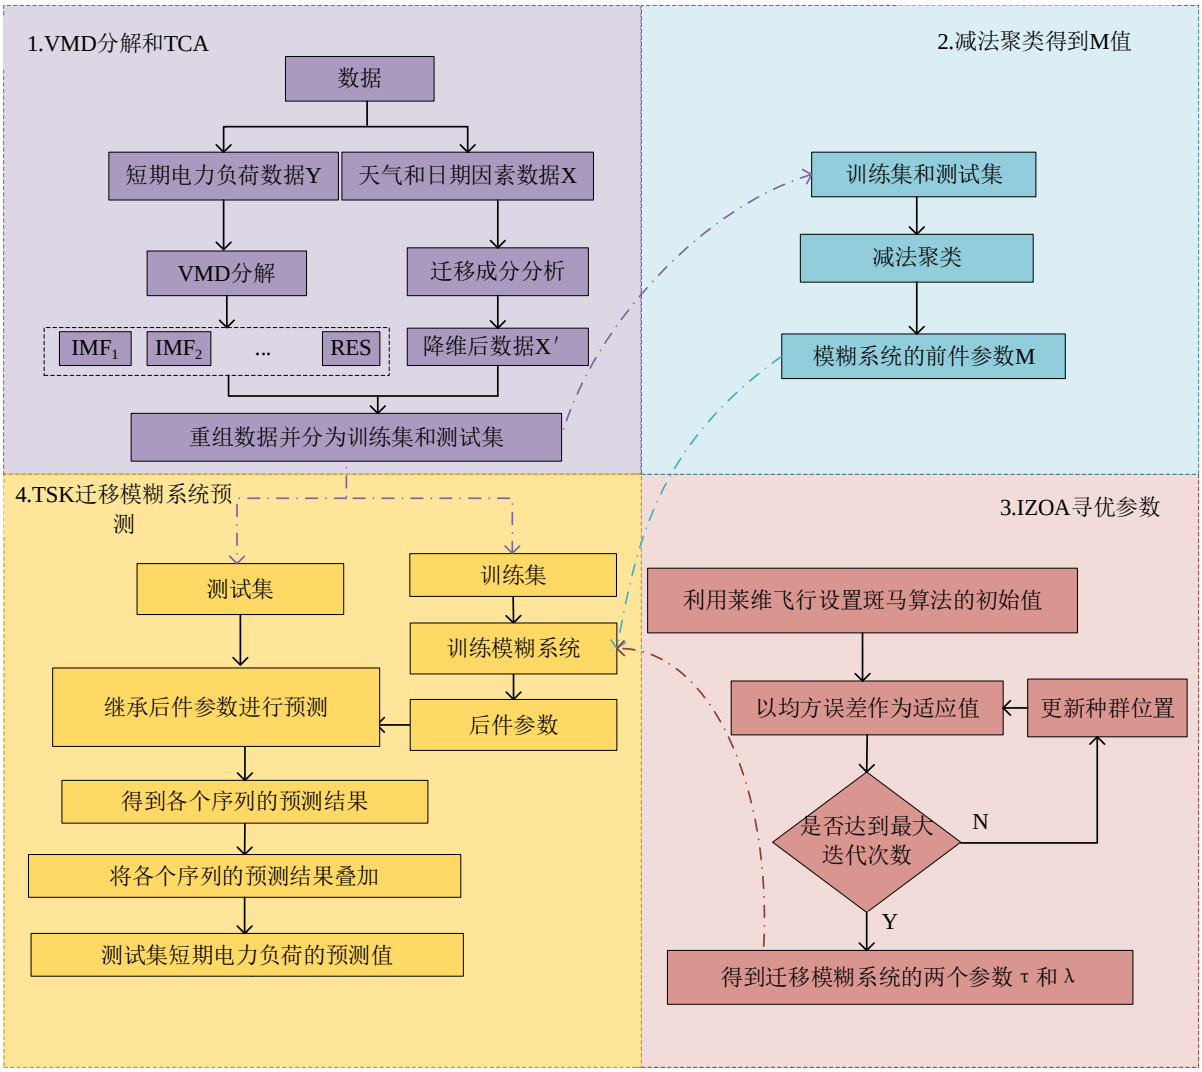


图 4.3 VMD-TCA-IZOA-TFS 模型流程图

Figure 4.3 VMD-TCA-IZOA-TFS model flowchart

4.3 仿真实验

4.3.1 对比实验 1

为验证 VMD-TCA-IZOA-TFS 模型的预测性能，利用第三章中的数据，并构建如下对比模型，分别为 VMD-TCA-ZOA-TFS、VMD-TCA-PSO-TFS、EEMD-TCA-ZOA-TFS、TCA-IZOA-TFS、TCA-ZOA-TFS 和 VMD-TCA-TFS。图 4.4 展示了 VMD-TCA-IZOA-TFS 短期电力负荷模型和上述对比模型预测值与真实值的对比，图 4.5 展示了 VMD-TCA-IZOA-TFS 与对比模型误差的箱线图，从图 4.5 中可以看出 VMD-TCA-IZOA-TFS 模型误差箱线图的线须之间距离最小，且误差的中位数更接近于 0，说明此模型的误差集中在 0 附近。

中国知网 https://www.cnki.net

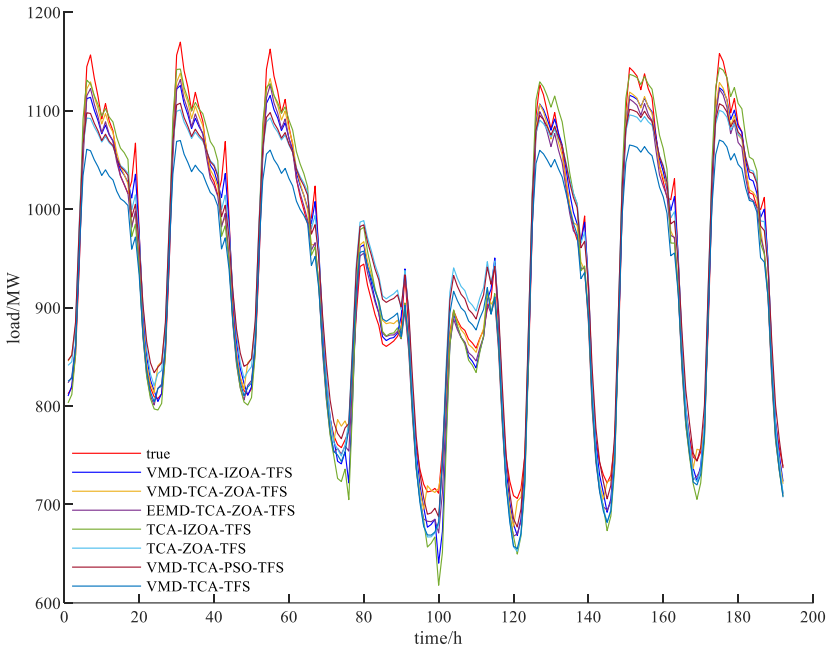


图 4.4 各个模型的预测值与真实值对比图

Figure 4.4 Comparison chart between predicted values and actual values of various models

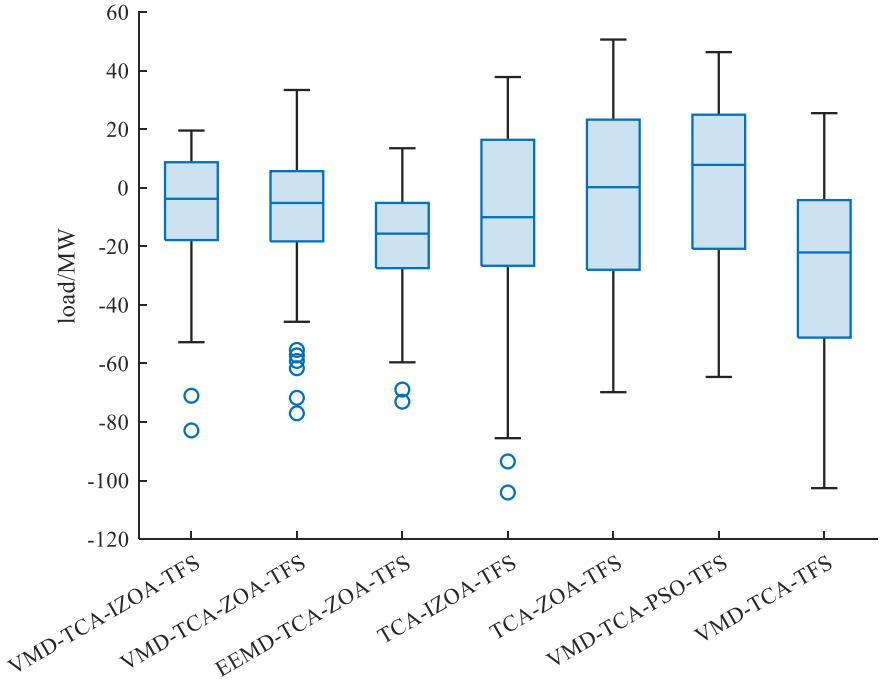


图 4.5 各个模型的误差箱线图

Figure 4.5 Error box-plots for each model

表 4.3 展示了上述各个模型的统计指标值。从表中可以看出 VMD-TCA-IZOA-TFS 模型的统计指标均较小，进一步说明模型的预测精度更高。从表中可得 TCA-ZOA-TFS 模型的 MAPE 比 VMD-TCA-TFS 模型低 0.53%；TCA-IZOA-TFS 模型的 MAPE 比

中国知网 https://www.cnki.net

TCA-ZOA-TFS 模型低 0.19%；在 TCA-ZOA-TFS 模型的基础上，采用 VMD 分解比 EEMD 分解所得模型的 MAPE 低 0.34%；而在 VMD-TCA-TFS 模型的基础上，利用 IZOA 所得模型的 MAPE 比采用 ZOA 和 PSO 所得模型的 MAPE 分别低 0.11%和 0.98%。综上所述，采用 VMD、TCA、IZOA 与 TSK-TFS 结合，提高了模型对短期电力负荷预测的精度。

表 4.3 对比实验 1 中模型的统计指标值

模型	MAPE	MAE	RMSE
VMD-TCA-IZOA-TFS	**1.61**	**14.81**	**19.12**
VMD-TCA-ZOA-TFS	1.72	16.17	21.07
VMD-TCA-PSO-TFS	2.59	24.50	28.49
EEMD-TCA-ZOA-TFS	2.06	19.05	23.27
TCA-IZOA-TFS	2.70	24.36	30.10
TCA-ZOA-TFS	2.89	26.93	31.48
VMD-TCA-TFS	3.42	33.67	42.30

4.3.2 对比实验 2

为了验证 TSK 迁移模糊系统的预测性能，利用 LSTM 作为对比模型，基于 LSTM，分别构建对比模型 VMD-TCA-IZOA-LSTM、VMD-TCA-ZOA-LSTM、VMD-IZOA-LSTM、VMD-ZOA-LSTM、IZOA-LSTM、ZOA-LSTM 和 LSTM，其中前两个模型结合迁移学习策略利用源域数据作为训练集的一部分，将源域信息迁移至目标域中，后 5 个模型利用目标域数据进行训练和预测，并利用第三章中的数据进行仿真实验。

若令源域数据 $D_h=[X_h,Y_h]$，$X_h=[X_{h1},X_{h2}\cdots,X_{h6}]$，目标域数据为 $D_m=[X_m,Y_m]$，$X_m=[X_{m1},X_{m2}\cdots,X_{m6}]$，则 VMD-TCA-IZOA-LSTM 短期电力负荷预测模型的步骤为：

(1) 利用最小样本熵确定 VMD 分解的序列数 $K=7$，利用 VMD 分解对电力负荷序列 $Y=[Y_h,Y_m]$ 进行分解，得到 7 个子序列即 $Y'=[Y'_{h1},Y'_{m1};Y'_{h2},Y'_{m2};\cdots;Y'_{hK},Y'_{m7}]$，选取 3 个天气因素和 3 个日期因素即 $X=[X_h,X_m]$；

(2) 利用 TCA 将原始数据中源域和目标域的天气因素和日期因素进行降维并将两个域之间的距离减小得到 $X'=[X'_h,X'_m]$ 为 3 维数据；

(3) 将步骤(1)和(2)得到的 X' 和 Y' 进行组合，得到 7 个数据组，将其分为训练集和测试集，利用 IZOA 算法对 LSTM 的参数进行寻优；

(4) 利用训练集训练 LSTM，后将测试集代入模型进行预测得到预测结果，将得到的预测结果进行叠加得到最终的预测结果。

VMD-TCA-IZOA-LSTM 模型的流程如图 4.6 所示，首先对电力负荷序列进行 VMD 分解，对天气和日期因素进行 TCA 处理，将分解得到的 K 组数据分别于 TCA 处理到的数据重组得到一共 K 组数据；其次利用 IZOA 对 LSTM 的参数进行寻优；最后将得到的 K 组数据分别代入 LSTM 中进行训练和预测，预测得到 K 个预测结果，将 K 个预测

中国知网 https://www.cnki.net

结果进行叠加得到最终的短期电力负荷的预测值。

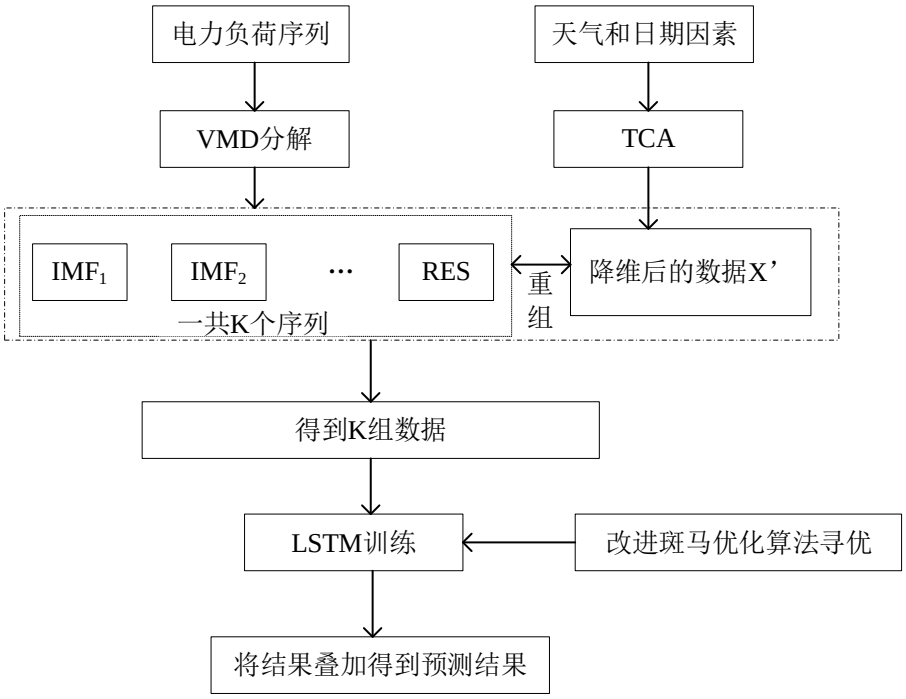


图 4.6 VMD-TCA-IZOA-LSTM 模型的流程图

Figure 4.6 Flowchart of VMD-TCA-IZOA-LSTM model

表 4.4 展示了 7 个模型的统计指标值，从表中数据可知，在未迁移的情况下，分别采用 ZOA 和 IZOA 与 LSTM 结合所得到模型的 MAPE 比 LSTM 模型低 0.26%和 1.11%。在 ZOA-LSTM 的基础上，利用 VMD 结合使得模型的 MAPE 进一步降低 1.22%。在 IZOA-LSTM 的基础上，利用 VMD 结合使得模型的 MAPE 进一步降低 0.42%。在利用源域数据迁移的情况下，利用 IZOA 得到的模型比 ZOA 得到模型的 MAPE 低 0.24%。综上所述，VMD-TCA-IZOA-LSTM 模型的预测精度更高。而 VMD-TCA-IZOA-LSTM 模型与 4.3.1 中表 4.3 展示的结果相比可知，基于 TSK 迁移模糊系统的短期电力负荷模型预测性能更优。

表 4.4 对比实验 2 中各个模型的统计指标值

模型	MAPE	MAE	RMSE
VMD-TCA-IZOA-LSTM	**4.17**	**38.63**	**49.49**
VMD-TCA-ZOA-LSTM	4.41	41.66	55.94
VMD-IZOA-LSTM	4.44	41.58	56.61
VMD-ZOA-LSTM	4.49	40.72	50.40
IZOA-LSTM	4.86	44.14	59.45
ZOA-LSTM	5.71	49.55	65.89
LSTM	5.97	53.90	73.42

图 4.7 展示了上述 7 个模型的预测值与真实值的对比，图 4.8 展示了上述 7 个模型的误差箱线图，从箱线图中可以看出，VMD-TCA-IZOA-LSTM 模型误差的均值更接近 0，且误差值更集中在 0 附近。

中国知网 https://www.cnki.net

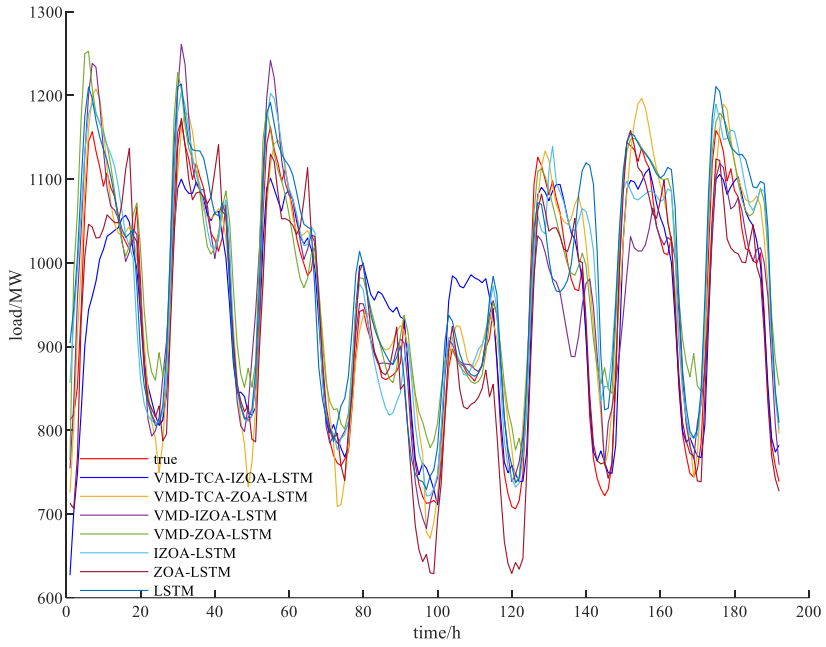


图 4.7 各个模型的预测值与真实值的对比

Figure 4.7 Comparison chart between predicted values and actual values of various models

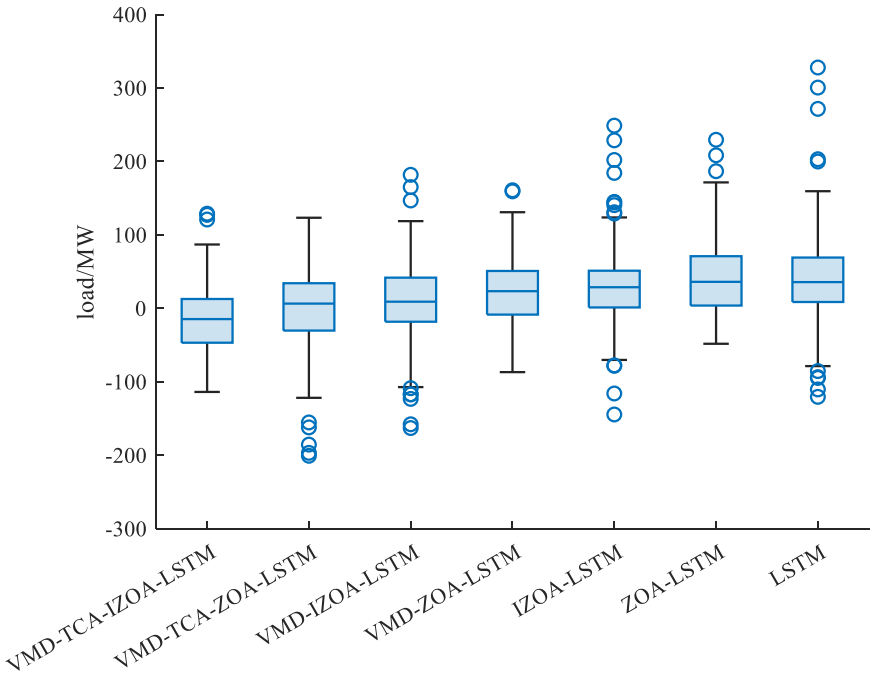


图 4.8 各个模型的误差箱线图

Figure 4.8 Error box-plots for each model

4.4 模型验证

第三章和第四章中利用了平均绝对百分误差、平均误差以及均方根误差对模型的预

中国知网 https://www.cnki.net

测精度进行评估，本节利用 DM 检验、HLN 检验、MCS 检验和敏感度验证模型的预测性能和稳健性。

4.4.1 DM 检验和 HLN 检验

DM 检验[55]是用来检验两个模型的预测效果是否存在显著差异，假定短期电力负荷数据为 $y=\{y_1,y_2,\cdots,y_n\}$，两个预测模型的预测值分别为 $\hat{y}_1=\{\hat{y}_{11},\hat{y}_{12},\cdots,\hat{y}_{1n}\}$，$\hat{y}_2=\{\hat{y}_{21},\hat{y}_{22},\cdots,\hat{y}_{2n}\}$，则两个预测模型的误差为：

$$e_{it}=y_t-\hat{y}_{it} \qquad t=1,2,\cdots,n \quad i=1,2. \tag{4.5}$$

设损失函数为：

$$h_{it}=h(e_{it}). \tag{4.6}$$

原假设 $H_0:E(d_t)=0$,表明两个模型的预测能力相同，备择假设 $H_1:E(d_t)\neq 0$，表明两个模型的预测性能显著不同。其中 $d_t=h_{1t}-h_{2t}$ 为两个模型之间的损失差，DM 检验的统计量构造步骤如下：

$$\sqrt{n}(\bar{d}-u)\xrightarrow{d}N(0,2\pi f_d(0)), \tag{4.7}$$

$$\bar{d}=\frac{1}{n}\sum_{t=1}^{n}d_t, \tag{4.8}$$

$$f_d(0)=\frac{1}{2\pi}\sum_{t=-\infty}^{+\infty}r_d(\tau), \tag{4.9}$$

$$r_d(\tau)=E[(d_t-u)(d_{t-\tau}-u)], \tag{4.10}$$

$$u=E[d_t], \tag{4.11}$$

其中 $\bar{d}$ 为样本平均损失差，u 为总体平均损失差，$f_d(0)$ 为损失差为 0 时的谱线密度。则根据以上式子，构造 DM 检验的统计量为：

$$DM=\frac{\bar{d}}{\sqrt{2\pi\hat{f}_d(0)/n}}, \tag{4.12}$$

其中 $DM\sim N(0,1)$，$\hat{f}_d(0)$ 为 $f_d(0)$ 的一致估计，若 $|DM|>a$，则认为两个预测模型的预测性能存在显著差异，其中 a 是标准正态分布的双尾临界值。若 $DM>0$，则模型 2 的预测性能更好。

HLN 检验[56]可以对两个模型的预测性能进行比较，HLN 指标在 DM 指标的基础上进行拓展，HLN 指标为：

$$HLN=DM\sqrt{[n+1-2h+h(h-1)]/n}, \tag{4.13}$$

其中 $h=n^{1/3}+1$，由于 $HLN\sim T(n-1)$，则若 $|HLN|>b$，则认为两个预测模型的预测性能存在显著差异，其中 b 是 T 分布的双尾临界值。由于测试集的个数为 192，所以 $h=7$，综合第三章和第四章的模型，可以得到对比模型与 VMD-TCA-IZOA-TFS 短期电力负荷模型之间的 *DM* 指标和 *HLN* 指标，结果如表 4.5 所示。

中国知网 https://www.cnki.net

表 4.5 各个模型的 *DM* 和 *HLN* 指标

模型	*DM*	*HLN*
VMD-TCA-ZOA-TFS	2.2276	2.3899
EEMD-TCA-ZOA-TFS	2.5161	2.6994
TCA-IZOA-TFS	3.6054	3.8682
TCA-ZOA-TFS	7.1958	7.7201
VMD-TCA-PSO-TFS	5.3073	5.6940
VMD-TCA-TFS	6.0574	6.4988
VMD-ZOA-TFS	5.1115	5.4840
ZOA-TFS	6.4908	6.9638
TFS	4.4637	4.7889
VMD-ZOA-FS	4.1143	4.4141
ZOA-FS	6.1429	6.5905
FS	6.9719	7.4799
VMD-TCA-IZOA-LSTM	5.5876	5.9948
VMD-TCA-ZOA-LSTM	4.4307	4.7535
VMD-IZOA-LSTM	2.9602	3.1759
VMD-ZOA-LSTM	2.7671	2.9687
IZOA-LSTM	3.6154	3.8789
ZOA-LSTM	4.4496	4.7739
LSTM	2.7918	2.9953

从表 4.5 中得出，以上结果在 5%的显著水平下均拒绝原假设，因此本文提出的 VMD-TCA-IZOA-TFS 短期电力负荷模型与对比模型的预测性能均显著不同，且 *DM* 指标和 *HLN* 指标均大于 0，所以 VMD-TCA-IZOA-TFS 短期电力负荷模型比其它模型的预测性能更优。

4.4.2 MCS 检验

DM 检验和 HLN 检验只能同时对两个模型的预测性能进行对比，无法对多个模型同时进行对比，Hansen 在 2011 年提出模型可信集检验[57](Model Confidence Set, MCS)，MCS 检验能够对同时对多个模型的预测性能进行对比，MCS 检验的原理如下：

MCS 检验是从一组模型集 $M_0=\{m_1,m_2,\cdots,m_l\}$ 中，在给定显著性水平的情况下，选出一个较小的模型集，称为优秀模型集（SSM）$\hat{M}^*_{1-\alpha}=\{m^*_1,m^*_2,\cdots,m^*_{l^*}\}$，维度 $l^*<l$，SSM 中包含了置信水平 $1-\alpha$ 下预测性能较优的模型。设模型的误差为：

$$e_{i,t}=e(y_t,\hat{y}_{i,t}) \quad i=1,2,\cdots,l, \quad t=1,2,\cdots,n, \tag{4.14}$$

其中 $e_{i,t}$ 第 i 个模型 t 时刻的损失差，$e(\cdot)$ 为损失函数，y_t 为 t 时刻的真实值，$\hat{y}_{i,t}$ 为第 i 个模型 t 时刻的预测值。定义模型 i 与模型 j 在时刻 t 之间的相对损失差异为 $\varepsilon_{ij,t}$，模型 i 在

中国知网 https://www.cnki.net

时刻t对于其余模型的平均损失差异为$\varepsilon_{i.,t}$：

$$\varepsilon_{ij,t}=e_{i,t}-e_{j,t},\quad i,j=1,2,\cdots,l,\quad t=1,2,\cdots,n, \tag{4.15}$$

$$\varepsilon_{i.,t}=\frac{\sum_{j\in M_0\setminus\{m_i\}}\varepsilon_{ij,t}}{l-1},\quad i=1,2,\cdots,l. \tag{4.16}$$

对于给定的一组模型M，平等预测能力假设(EPA)可表述为：

$$H_{0,M}:c_{i,j}=0\quad \forall i,j=1,2,\cdots,l,$$

$$H_{A,M}:c_{i,j}\neq 0\quad \exists i,j=1,2,\cdots,l,$$

其中

$$c_{ij}=E(\varepsilon_{ij}). \tag{4.17}$$

假设c_{ij}有限且与时间无关。Hansen 等利用统计量检验 EPA 中的不等式，统计量定义如下：

$$t_{i,j}=\frac{\bar{\varepsilon}_{ij}}{\sqrt{\widehat{\mathrm{var}}(\bar{\varepsilon}_{ij})}}, \tag{4.18}$$

其中$i,j\in M$，$\bar{\varepsilon}_{ij}$为模型i和模型j之间的相对平均损失差异，$\widehat{var}(\bar{\varepsilon}_{ij})$为$\widehat{var}(\varepsilon_{ij})$的自举估计(bootstrap)，即通过块引导，块长度p为通过ε_{ij}拟合项上的 AR(p)过程中得到的最大有效参数。EPA 零假设可映射至统计检验中，具体如下：

$$T_M=\max_{i,j\in M}|t_{i,j}|. \tag{4.19}$$

上述统计量越大，则预测模型不具有平等的预测能力，即拒绝原假设。本文利用 bootstrap 计算得到统计量对应的P值，利用统计检验的一致性消除规则，进而消除预测能力较差的模型，定义如下：

$$\varphi_M=\arg\max\left\{\sup\frac{\bar{\varepsilon}_{ij}}{\sqrt{\widehat{var}(\bar{\varepsilon}_{ij})}}\right\}. \tag{4.20}$$

MCS 检验为顺序检验，每一步骤均会删除预测性能最差的模型，直至 SSA 中的模型均接受零假设，若P值越大，则表示越不能拒绝原假设，则表明模型的预测性能更优。设定模拟次数为 10000 次，bootstrap block 的长度为 2，取损失函数为 MAE 和 RMSE，计算统计量，进而得到 MCS 检验的P值，结果如表 4.6 所示：

中国知网 https://www.cnki.net

表 4.6 各个模型的 MCS 检验 P 值

MCS	MAE	RMSE
VMD-TCA-IZOA-TFS	**1**	**1**
VMD-TCA-ZOA-TFS	0.012	0.0175
EEMD-TCA-ZOA-TFS	0.012	0.0175
TCA-IZOA-TFS	0	0.0019
TCA-ZOA-TFS	0	0.0002
VMD-TCA-PSO-TFS	0	0.0019
VMD-TCA-TFS	0	0.0004
VMD-ZOA-TFS	0	0
ZOA-TFS	0	0
TFS	0	0
VMD-ZOA-FS	0	0
ZOA-FS	0	0
FS	0	0
VMD-TCA-IZOA-LSTM	0	0.0002
VMD-TCA-ZOA-LSTM	0	0.0151
VMD-IZOA-LSTM	0	0.0045
VMD-ZOA-LSTM	0	0.0022
IZOA-LSTM	0	0.0172
ZOA-LSTM	0	0.0052
LSTM	0	0.0175

在显著性水平为 5%的情况下，若 P 小于 0.05，则代表模型的预测性能较差，在进行检验时会被消除，若 P 值大于 0.05 时，则代表模型的预测性能较优。从表 4.6 中可以看出，VMD-TCA-IZOA-TFS 的 MCS 检验的 P 值为 1，其余模型均小于 0.05，说明只有 VMD-TCA-IZOA-TFS 模型没有被消除，其余模型均被消除，即 SSM 中只包含 VMD-TCA-IZOA-TFS 模型。综上所述，VMD-TCA-IZOA-TFS 短期电力负荷模型有更优的预测性能。

4.4.3 改善率

为了定量地分析本文提出的 VMD-TCA-IZOA-TFS 短期电力负荷模型与对比模型的预测性能差异，利用指标改善率(IR_j)，其定义为：

$$IR_1 = \frac{MAPE_i - MAPE_0}{MAPE_i} \times 100\%, i = 1, 2, \cdots, 19, \tag{4.21}$$

$$IR_2 = \frac{MAE_i - MAE_0}{MAE_i} \times 100\%, i = 1, 2, \cdots, 19, \tag{4.22}$$

中国知网 https://www.cnki.net

$$IR_3 = \frac{RMSE_i - RMSE_0}{RMSE_i} \times 100\%, i = 1,2,\cdots,19, \tag{4.23}$$

其中 $MAPE_i$、MAE_i 和 $RMSE_i$ 为本文作为对比模型的 $MAPE$、MAE 和 $RMSE$，$MAPE_0$、MAE_0 和 $RMSE_0$ 为本文提出的 VMD-TCA-IZOA-TFS 模型的 $MAPE$、MAE 和 $RMSE$，IR_j 结果如表 4.7 所示：

表 4.7 各个模型与 VMD-TCA-IZOA-TFS 的改善率

模型	IR_1	IR_2	IR_3
VMD-TCA-ZOA-TFS	0.0686	0.0843	0.0921
VMD-TCA-PSO-TFS	0.3792	0.3955	0.3288
EEMD-TCA-ZOA-TFS	0.2183	0.2223	0.1782
TCA-IZOA-TFS	0.4057	0.3920	0.3647
TCA-ZOA-TFS	0.4438	0.4499	0.3925
VMD-TCA-TFS	0.5302	0.5601	0.5479
VMD-ZOA-TFS	0.6025	0.6152	0.6072
ZOA-TFS	0.6215	0.6235	0.5924
TFS	0.6496	0.6468	0.6166
VMD-ZOA-FS	0.6116	0.6155	0.5927
ZOA-FS	0.6402	0.6405	0.6002
FS	0.6588	0.6571	0.6251
VMD-TCA-IZOA-LSTM	0.6151	0.6166	0.6135
VMD-TCA-ZOA-LSTM	0.6358	0.6444	0.6581
VMD-IZOA-LSTM	0.6378	0.6438	0.6622
VMD-ZOA-LSTM	0.6419	0.6362	0.6205
IZOA-LSTM	0.6692	0.6645	0.6783
ZOA-LSTM	0.7189	0.7011	0.7097
LSTM	0.7311	0.7252	0.7395

从表 4.7 中可以看出 IR_1、IR_2 和 IR_3 的范围分别是[0.0686 0.7311]、[0.0843 0.7252]和[0.0912 0.7395]，其中 VMD-TCA-IZOA-TFS 模型较 LSTM 较大地改善了模型的 $MAPE$、MAE 和 $RMSE$，而相比于 VMD-TCA-ZOA-TFS 模型，VMD-TCA-IZOA-TFS 模型对 3 个统计指标改善较小。从表 4.7 可以得出 VMD-TCA-IZOA-TFS 短期电力负荷模型相较于对比模型预测精度更高、性能更优。

4.5 本章小结

本章对 ZOA 算法进行改进，并对其进行测试以检验 IZOA 算法的性能，引入 TCA 建立 VMD-TCA-IZOA-TFS 短期电力负荷预测模型，同时为了验证 TSK-TFS 的电力负荷预测性能，建立以 LSTM 为基础的短期电力负荷模型。利用第三章中的数据进行仿真实验，仿真结果表明 VMD-TCA-IZOA-TFS 短期电力负荷组合模型的预测精度更高。综合第三章和第四章中的模型，对其进行模型检验，检验方法包括 DM 检验、HLN 检

中国知网 https://www.cnki.net

验、MCS 检验和敏感度检验，结果表明，VMD-TCA-IZOA-TFS 短期电力负荷模型较对比模型预测精度更高，预测性能更优。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第5章 总结与展望

5.1 总结

为了提高短期电力负荷的预测精度，本文利用 VMD、TCA、IZOA 和 TSK-TFS 构建 VMD-TCA-IZOA-TFS 短期电力负荷预测模型，利用欧洲两个城市的短期电力负荷数据进行仿真实验，并对预测结果进行分析，同时利用模型检验的方法评估模型的预测性能和稳健性。本文的工作主要包括：

(1) 利用最小样本熵确定 VMD 分解序列的个数，保证 VMD 对电力负荷序列的有效分解，降低了电力负荷序列的非线性和非平稳性。利用 TCA 算法处理天气和日期因素序列，减小了源域和目标域之间距离，同时将天气和日期因素降维，降低了模型计算的复杂度。

(2) 对 ZOA 算法进行改进，改进内容为：利用莱维飞行初始化 ZOA 算法的种群，对防御阶段的切换概率进行改进使其服从正态分布，并利用基准函数对 IZOA 进行测试，测试结果表明 IZOA 提升了算法的搜索能力，同时提高了优化算法的收敛速度。利用 IZOA 对 TSK-TFS 的可调参数寻优，避免盲目设置参数，提高模型的预测精度。

(3) 对于目标域数据缺失的问题，采用迁移学习策略，将源域中的有效信息迁移至目标域中，解决目标域数据存在缺失而导致模型精度下降的问题。

(4) 将 IZOA、VMD、TCA 和 TSK 迁移模糊系统相结合，构建 VMD-TCA-IZOA-TFS 短期电力负荷预测模型，并选取对比模型，利用 *MAPE* 、*MAE* 和 *RMSE* 三种误差指标评估模型的预测精度，仿真实验表明，相比于对比模型，VMD-TCA-IZOA-TFS 模型的预测精度更高。同时利用 DM 检验、HLN 检验、MCS 检验和敏感度对模型的预测性能进行对比，仿真结果也证实了 VMD-TCA-IZOA-TFS 模型有更优的预测性能。

5.2 展望

本文提出的 VMD-TCA-IZOA-TFS 短期电力负荷组合预测组合预测模型虽然从指标值和模型检验中均证实其具有较优的预测性能，但仍存在不足，主要体现在以下方面：

(1) 在选取电力负荷的影响因素时，只选取了天气和日期因素，而影响电力负荷的因素有很多，本文并未选取到所有影响因素，这可能会导致模型的预测精度有所下降。

(2) 根据短期电力负荷的特点可知其具有周期性，本文在建立模型的过程中未考虑电力负荷序列的周期性，未来将进一步分析周期性对模型的影响。

(3) 本文所建立的模型是针对短期电力负荷进行预测，未来可对模型进行改进，讨论其对中期和长期电力负荷的预测精度。

中国知网 https://www.cnki.net

参考文献

[1] Fan C D, Nie S H, Xiao L Y, et al. A multi-stage ensemble model for power load forecasting based on decomposition, error factors, and multi-objective optimization algorithm[J]. International Journal of Electrical Power and Energy Systems, 2024, 155(PB): 109620.

[2] Han X S, Shi Y, Tong R J, et al. Research on short-term load forecasting of power system based on IWOA-KELM[J]. Energy Reports, 2023, 9(S10): 238-246.

[3] 董添. 基于深度学习的电力负荷模式识别与预测方法研究[D]. 长春: 吉林大学, 2022.

[4] 曾林俊, 许加柱, 王家禹, 等. 考虑区间构造的改进极限学习机短期电力负荷区间预测[J]. 电网技术, 2022, 46(07): 2555-2563.

[5] 李艳波, 尹镨, 陈俊硕, 等. 结合改进残差网络和 Bi-LSTM 的短期电力负荷预测[J]. 哈尔滨工业大学学报, 2023, 55(08): 79-86.

[6] 徐岩, 向益锋, 马天祥. 基于粒子群算法优化参数的 VMD-GRU 短期电力负荷预测模型[J]. 华北电力大学学报(自然科学版), 2023, 50(01): 38-47.

[7] 汤贤振. 基于改进神经网络算法的短期电力负荷预测研究[D].长沙: 中南大学, 2023.

[8] 黄睿, 朱玲俐, 高峰, 等. 基于变分模态分解的卷积长短时记忆网络短期电力负荷预测方法[J]. 现代电力, 2024, 41(01): 97-105.

[9] 向益锋. 基于深度学习的电力系统短期负荷预测研究[D]. 保定: 华北电力大学, 2022.

[10] 王宝财. 基于温度近因效应的多元线性回归电力负荷预测[J]. 水电能源科学, 2018, 36(10): 201-205.

[11] 陈培垠, 方彦军. 基于卡尔曼滤波预测节假日逐点增长率的电力系统短期负荷预测[J]. 武汉大学学报(工学版), 2020, 53(02): 139-144.

[12] 刘亚辉, 韩明轩, 郭俊岑, 等. 基于密度聚类与 ARIMA 模型短期电力负荷预测[J]. 北京信息科技大学学报(自然科学版), 2019, 34(05): 84-87.

[13] 刘静. 最小二乘 SVM 在电力推进船舶电力负荷短期预测的应用[J]. 舰船科学技术, 2021, 43(24): 61-63.

[14] 王伟, 杨辉华, 刘振丙, 等. 基于极限学习机的短期电力负荷预测[J]. 计算机仿真, 2014, 31(04): 137-141.

[15] 庞传军, 余建明, 冯长有, 等. 基于 LSTM 自动编码器的电力负荷聚类建模及特性分析[J]. 电力系统自动化, 2020, 44(23): 57-63.

[16] 王悦如, 王盛宇. 基于 GRU 神经网络的电力负荷预测[J]. 电工技术, 2022(10): 123-125+129.

中国知网 https://www.cnki.net

[17]魏腾飞, 潘庭龙. 基于改进 PSO 优化 LSTM 网络的短期电力负荷预测[J]. 系统仿真学报, 2021, 33(08): 1866-1874.

[18]吴飞, 李霆, 张航, 等. 基于 CWOA-ELM 的短期电力负荷预测研究[J]. 电子测量技术, 2020, 43(04): 88-92.

[19]刘岩, 彭鑫霞, 郑思达. 基于改进 LS-SVM 的短期电力负荷预测方法研究[J]. 电测与仪表, 2021, 58(05): 176-181.

[20]魏骜, 茅大钧, 韩万里, 等. 基于 EMD 和长短期记忆网络的短期电力负荷预测研究[J]. 热能动力工程, 2020, 35(04): 203-209.

[21]Lotfipoor A, Patidar S, Jenkins D P. Deep neural network with empirical mode decomposition and Bayesian optimisation for residential load forecasting[J]. Expert Systems with Applications, 2024, 237: 121355.

[22]雷炳银, 王子驰, 苏雨晴, 等. 基于 EEMD-CS-LSSVM 的短期负荷预测方法研究[J]. 电力系统及其自动化学报, 2021, 33(09): 117-122.

[23]Yue W M, Liu Q R, Ruan Y J, et al. A prediction approach with mode decomposition-recombination technique for short-term load forecasting[J]. Sustainable Cities and Society, 2022, 85: 104034.

[24]张未, 余成波, 王士彬, 等. 基于 VMD-LSTM-LightGBM 的多特征短期电力负荷预测[J]. 南方电网技术, 2023, 17(02): 74-81.

[25]Zhang Q, Wu J J, Ma Y, et al. Short-term load forecasting method with variational mode decomposition and stacking model fusion[J]. Sustainable Energy, Grids and Networks, 2022, 30: 100622.

[26]蒋亦樟. 多视角和迁移学习识别方法和智能建模研究[D]. 无锡: 江南大学, 2016.

[27]欧阳福莲, 王俊, 周杭霞. 基于改进迁移学习和多尺度 CNN-BiLSTM-Attention 的短期电力负荷预测方法[J]. 电力系统保护与控制, 2023, 51(02): 132-140.

[28]孙晓燕, 李家钊, 曾博, 等. 基于特征迁移学习的综合能源系统小样本日前电力负荷预测[J]. 控制理论与应用, 2021, 38(01): 63-72.

[29]姜建国, 万成德, 陈鹏, 等. 基于 1DCNN-LSTM 和迁移学习的短期电力负荷预测[J]. 吉林大学学报(信息科学版), 2023, 41(01): 124-130.

[30]Cai L, Gu J, Jin Z J. Two-layer transfer-learning-based architecture for short-term load forecasting[J]. IEEE Transactions on Industrial Informatics, 2019, 16(3): 1722-1732.

[31]Zadeh L A. Fuzzy sets[J]. Information and Control, 1965, 8(3): 338-353.

[32]Zadeh L A. The concept of a linguistic variable and its application to approximate reasoning-I[J]. Information Sciences, 1975, 8(3): 199-249.

[33]王士同, 谢润山, 周尔昊. 可解释的深度 TSK 模糊系统综述[J]. 数据采集与处理, 2022, 37(05): 935-951.

中国知网 https://www.cnki.net

[34]Cheng Z H, Zhou G H. Domain-adaptive tsk fuzzy system based on multisource data fusion for epileptic EEG signal classification[J]. Journal of Mechanics in Medicine and Biology, 2023, 23(09): 234009.

[35]杜轻, 辛守庭, 雷新宇, 等. 基于脑网络和 TSK 模糊系统的癫痫脑电识别[J]. 计算机工程与应用, 2020, 56(02): 133-140.

[36]Zhang Y P, Wang G J, Huang X Y, et al. TSK fuzzy system fusion at sensitivity-ensemble-level for imbalanced data classification[J]. Information Fusion, 2023, 92: 350-362.

[37]卢伟, 吴延军, 苗丹, 等. 基于 TSK 模糊系统的非均匀分簇算法在无线传感网中的应用[J]. 计算机测量与控制, 2023, 31(12): 258-264.

[38]张春香, 王骏, 张嘉旭, 等. 面向自闭症辅助诊断的联合组稀疏 TSK 建模方法[J]. 计算机科学与探索, 2020, 14(12): 2083-2093.

[39]Mukhopadhyay P, Mitra G, Banerjee S, et al. Electricity load forecasting using fuzzy logic: Short term load forecasting factoring weather parameter[C]. 2017 7th International Conference on Power Systems (ICPS). IEEE, 2017: 812-819.

[40]Li C D, Tang M J, Zhang G Q, et al. A hybrid short-term building electrical load forecasting model combining the periodic pattern, fuzzy system, and wavelet transform[J]. International Journal of Fuzzy Systems, 2020, 22: 156-171.

[41]邓永生, 焦丰顺, 张瑞锋, 等. 配电网规划中电力负荷预测方法研究综述[J]. 电器与能效管理技术, 2019(14): 1-7.

[42]钱育树, 孔钰婷, 黄聪. 电力负荷预测研究综述[J]. 四川电力技术, 2023, 46(04): 37-43+58.

[43]范杏蕊. 基于深度学习的短期电力负荷预测研究[D]. 北京: 华北电力大学(北京), 2023.

[44]Huang N E, Shen Z, Long S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings of the Royal Society of London. Series A: mathematical, physical and engineering sciences, 1998, 454(1971): 903-995.

[45]Wu Z, Huang N E. Ensemble empirical mode decomposition: a noise-assisted data analysis method[J]. Advances in Adaptive Data Analysis, 2009, 1(01): 1-41.

[46]Dragomiretskiy K, Zosso D. Variational mode decomposition[J]. IEEE Transactions on Signal Processing, 2013, 62(3): 531-544.

[47]Richman J S, Moorman J R. Physiological time-series analysis using approximate entropy and sample entropy[J]. American Journal of Physiology-Heart and Circulatory Physiology, 2000, 278(6): H2039-H2049.

[48]Bezdek J C. Pattern recognition with fuzzy objective function algorithms[M]. New York: Plenum Press, 1981.

中国知网 https://www.cnki.net

[49] CHIU S L. Fuzzy model identification based on cluster estimation[J]. Journal of Intelligent and Fuzzy Systems, 1994, 2(3): 267-278.

[50] Pan S J, Tsang I W, Kwok J T, et al. Domain adaptation via transfer component analysis[J]. IEEE Transactions on Neural Networks, 2010, 22(2): 199-210.

[51] Trojovská E, Dehghani M, Trojovský P. Zebra optimization algorithm: A new bio-inspired optimization algorithm for solving optimization algorithm[J]. IEEE Access, 2022, 10: 49445-49473.

[52] Deng Z H, Choi K S, Chung F L, et al. Scalable TSK fuzzy modeling for very large datasets using minimal-enclosing-ball approximation[J]. IEEE Transactions on Fuzzy Systems, 2011, 19(2): 210-226.

[53] Tsang I W, Kwok J T, Zurada J M. Generalized core vector machines[J]. IEEE Transactions on Neural Networks, 2006, 17(5): 1126-1140.

[54] Pan S J, Yang Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359.

[55] Diebold F X, Mariano R S. Comparing predictive accuracy[J]. Journal of Business & Economic Statistics, 1995, 13(3): 253-263.

[56] Harvey D, Leybourne S, Newbold P. Testing the equality of prediction mean squared errors[J]. International Journal of Forecasting, 1997, 13(2): 281-291.

[57] Hansen P R, Lunde A, Nason J M. The model confidence set[J]. Econometrica, 2011, 79(2): 453-497.

中国知网 https://www.cnki.net