DOI:10.14188/j.1671-8844.2024-06-014
文章编号:1671-8844(2024)06-0812-09

基于迁移学习的CNN-GRU短期电力负荷预测方法

程明[1],翟金星[1],马骏[1],鲁丽波[1],金恩淑[2]

(1. 国家电投内蒙古能源有限公司通辽霍林河坑口发电有限责任公司,内蒙古 通辽 029200; 2. 东北电力大学电气工程学院,吉林 吉林 132012)

摘要: 随着信息化时代的到来,数据驱动的机器学习已成为主流的短期电力负荷预测方法,但此类方法对数据具有很强的依赖性。为改善这一不足,提出了一种基于迁移学习的卷积神经网络(convolutional neural network,CNN)和门控循环单元(gated recurrent unit,GRU)的混合预测模型。以东北某2个地区的电力负荷数据集为例进行预测分析。结果表明,所提方法可有效提高数据稀缺情况下短期电力负荷预测的准确性和可靠性。

关键词: 电力负荷预测;卷积神经网络;迁移学习;门控循环单元
中图分类号: TM 715　**文献标志码:** A

Transfer learning based CNN-GRU short-term power load forecasting method

CHENG Ming[1], ZHAI Jinxing[1], MA Jun[1], LU Libo[1], JIN Enshu[2]

(1. Tongliao Huolinhe Pithead Power Generation Co., Ltd., State Power Investment Inner Mongolia Energy Co., Ltd., Tongliao 029200, China;
2. School of Electrical Engineering, Northeast Electric Power University, Jilin 132012, China)

Abstract: With the advent of the information era, data-driven machine learning has become a mainstream short-term power load forecasting method, but such method is highly dependent on data. In order to improve this deficiency, this paper proposes a hybrid prediction model based on convolutional neural network (CNN) and gated recurrent unit (GRU) of transfer learning. Two power load data sets A and B in northeast China are taken as examples to forecast and analyze the short-term power load, the results show that the proposed method can effectively improve the accuracy and reliability of short-term power load forecasting in the case of data scarcity.

Key words: power load forecasting; convolutional neural network; transfer learning; gated recurrent unit

短期电力负荷预测对电力系统的安全和经济运行具有重要意义[1]。一方面,它能为电网的发电计划、经济调度、负荷管理和安全分析等提供贴合实际的预测曲线;另一方面,它也能为电力市场中发电和购电双方的交易活动提供更有效的决策参考。电力负荷每天起伏波动,负荷数据不仅具有趋势性、周期性和季节性等时间变化特征,而且对季节、天气、温度和节假日等不确定因素敏感,这增加了负荷预测的难度。随着电力市场的不断发展,业内对短期电力负荷预测的精确度提出了更高要求,这不仅需要加强对负荷侧数据的管理,而且要采用先进技术和方法来提高预测精度,以此提升电力系统的稳定性

收稿日期: 2023-11-08
作者简介: 程明(1982-),男,高级工程师,主要从事电力企业管理和设备技术研究,E-mail:vinmvinm@sina.com。
通讯作者: 马骏(1982-),男,高级工程师,主要从事电力系统科技信息化建设研究,E-mail:majun523@163.com。
基金项目: 国家电投集团科研基金项目(编号:KY-C-2022-XT36)。

本文引用格式: 程明,翟金星,马骏,等.基于迁移学习的CNN-GRU短期电力负荷预测方法[J].武汉大学学报(工学版),2024,57(6):812-820.

Citation: CHENG Ming, ZHAI Jinxing, MA Jun, et al. Transfer learning based CNN-GRU short-term power load forecasting method[J]. Engineering Journal of Wuhan University, 2024, 57(6):812-820.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

和可靠性，同时提高能源效率和经济效益。

当前短期电力负荷预测主要分为传统统计预测和以人工神经网络（artificial neural network，ANN）为代表的机器学习预测两大类。传统的统计预测法主要包括负荷峰值模型、时间序列模型、多元线性回归模型等，这些模型通过分析历史负荷数据内在的变化趋势来探究负荷的时间变化特征。虽然这种方法能够有效处理并分析平稳时间序列，但当考虑到需求侧的工业用电、商业用电、民用用电以及气象变化等因素叠加带来的非线性变化时，此类方法的准确性将大幅降低[2]。

随着人工智能技术的迅速发展以及电力系统负荷侧数据的爆发式增长，基于数据驱动的人工智能方法逐步被应用到负荷预测领域。人工智能常用的方法有模糊推理、支持向量机和ANN等，这些方法虽然能够较好地处理非线性问题，但是模糊推理不能开展自学习[3]，支持向量机在处理大规模数据方面存在困难[4]，早期的ANN难以学习序列数据的相关性[5]。近年来，随着大数据与高性能计算机的出现，ANN的自学习性能不断增强，它提供了处理数据不确定性的方法，可以处理包含复杂性和不确定性的数据，从而提高预测的准确性和可解释性。ANN对数据规模有一定的要求，当数据规模较小时，预测模型的优化性能也会受到影响，从而导致预测得不到预期结果[6]。随着ANN深度学习的不断发展，各种新型预测方法不断涌现，为研究人员解决短期电力负荷预测问题提供了新的思路。文献[7]提出了一种用于家庭负荷预测的新型循环神经网络（recurrent neural network，RNN），与传统的ANN相比，RNN具有记忆功能，可以处理和预测非线性时间序列数据。然而，它在训练过程中容易出现梯度递减，因此不擅长处理长期时间序列问题。长短期记忆（long short term memory，LSTM）网络是一种特殊的循环神经网络，相比传统的RNN，它能更准确地学习时间序列中的长期依赖性关系，解决了需要人工提取时序特征的问题，但该方法收敛速度较慢[8]。门控循环单元（gated recurrent unit，GRU）是在LSTM的基础上改进优化的神经网络，它具有更快的收敛速度，并具有与LSTM相近的准确率[9]。GRU网络适合处理时间序列数据，然而，由于短期电力负荷对季节、天气、系统事故等不确定性因素比较敏感，因此会降低GRU的预测精度。文献[10]和文献[11]分别运用CNN（convolutional neural network）-LSTM和CNN-GRU混合模型进行负荷预测，这2个模型可以有效提高负荷预测的准确性，但需要通过大量数据进行自学习。文献[12]研究了极端温度气象日母线日前负荷预测。尽管电力系统当下正处于一个数据爆发式增长的时代，但由于电网运营的各端均采取数据保密措施，因此开展负荷预测仍然受到数据稀缺的限制。

迁移学习（transform learning，TL）是机器深度学习的一个分支，它将在一个领域（源域）中学习到的知识和经验运用到另一个领域（目标域）的学习任务中，能够在数据较少的情况下获得更好的学习效果[13]。

本文提出了一种基于迁移学习的CNN-GRU短期电力负荷预测方法。该方法针对负荷数据稀缺的实际问题，运用迁移学习原理，将CNN-GRU预测混合模型在源域（或其他领域）中所学习到的知识和经验应用于短期电力负荷预测目标域，有效提升了在数据较少条件下CNN-GRU预测混合模型的学习效果，提高了模型对短期电力负荷预测的准确性。将本文方法应用于东北某2个地区的短期电力负荷预测。结果表明，本文所提出的混合预测模型可以有效提高数据稀缺条件下短期电力负荷预测的准确性和可靠性。

1　预测模型描述

1.1　基于迁移学习的CNN-GRU预测模型结构简介

图1为基于迁移学习的CNN-GRU混合预测模型构架。本文提出的负荷预测模型主要包括数据处理、CNN-GRU混合模型和基于参数的迁移学习3大模块。其中，CNN-GRU由CNN模型结构（包括输入层、卷积层和最大池化层）和GRU模型结构（包括输入层、GRU层、全连接层和回归输出层（图1中的“标签”代表回归输出层））混合组成。

1.2　预测特征集构建及输入向量筛选

1.2.1　构建预测特征集

预测特征集是指在机器学习中从原始数据中提取出的一组具有代表性的特征集，旨在提高模型的泛化能力和预测精度。预测特征集合理与否对预测模型的准确度和收敛性有较大影响。影响短期电力负荷的因素众多，且各个因素的影响程度各异。本预测模型充分考虑了影响小时级短期电力负荷的先验信息，从中选取日期、时间序列和天气这3大影响因素构建预测特征集，每个影响因素的特征和特征值的设定如表1所示。

表1中，日期因素设有季节、月、小时、星期、工作时间和节假日等6维特征向量，天气因素设有温度、天气描述、风速和湿度等4维特征向量，时序序列则选取预测目标前48个相近负荷形成48维特征向量，

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

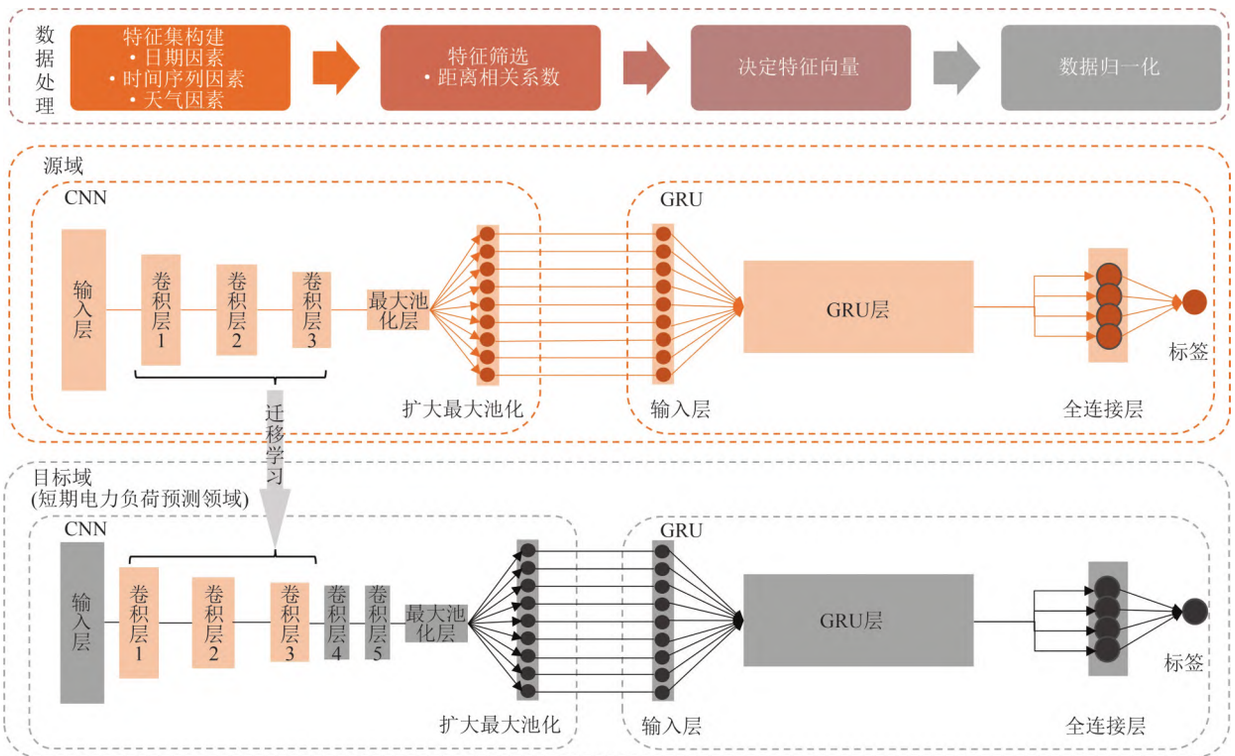


图 1　基于迁移学习的 CNN-GRU 混合预测模型构架

Fig.1　Framework of CNN-GRU hybrid prediction model based on transfer learning

表 1　预测因素特征集

Table 1　Feature set of predictive factors

因素	因素特征	因素描述
日期	季节(Season)	1 a为一个周期,1/4周期代表一个季节
	月(M_y)	1 a为一个周期,1/12周期代表一个月
	小时(Hourday)	1 d为一个周期,1/24周期代表1 h
	星期(工作日为W_d,休息日为Weekend)	周一～周五为工作日,用1表示;周六和周日为休息日,用－1表示
	工作时间(W_h)	上午8:00～下午5:00为工作时间,用1表示;其他时间用－1表示
	节假日(Holiday)	节假日用1表示,非节假日用－1表示
时间序列	滞后1～滞后48	滞后1表示将整体负荷值延迟1 h,滞后2表示将延迟整体负荷值2 h,以此类推
天气	温度(Temper)	每小时的温度,单位为℃
	天气描述(W_des)	晴朗记为1,散云记为2,碎云记为3,少云记为4,阴云记为5,小雨记为6,细雨记为7,中雨记为8,冻雨记为9,大雨记为10,小雪记为11,中雪记为12,大雪记为13,薄雾记为14,雾记为15,雾霾记为16,临近雷暴记为17
	风速(W_s)	每小时风的速度,单位为m/s
	湿度(Humi)	每小时的大气干燥度,单位为%

从而形成共58维特征向量作为候选输入向量。

1.2.2　筛选特征向量

上述的58维特征向量对电力负荷的影响强度各不相同,并非所有特征向量都与负荷密切相关。若在建模时直接考虑所有特征向量,所建模型将受高方差影响,可能出现过度拟合或大幅增加模型训练时间的问题。因此,本文使用距离相关系数(distance correlation,DC)来度量每个特征向量与系统负荷之间的相关性[14]。向量间距离相关系数能够衡量2个任意维度的成对随机向量之间的依赖性,其定义如下:

$$\mathrm{dCor}(\boldsymbol{X}^k,Y)=\frac{\mathrm{dCov}^2(\boldsymbol{X}^k,Y)}{\sqrt{\mathrm{dVar}(\boldsymbol{X}^k)\mathrm{dVar}(Y)}} \tag{1}$$

式中:$\boldsymbol{X}^k$为第k维特征向量;Y为输出标签,此处表示电力负荷;$\mathrm{dVar}(\boldsymbol{X}^k)$和$\mathrm{dVar}(Y)$分别为$\boldsymbol{X}^k$和$Y$的距离方差;$\mathrm{dCov}(\boldsymbol{X}^k,Y)$为第$k$维特征向量与输出

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

标签 Y 之间的距离协方差；dCor($\boldsymbol{X}^k$, Y)为第 k 维特征向量与输出标签 Y 之间的距离相关系数。当dCor($\boldsymbol{X}^k$, Y)=0时，两者无相关；当dCor($\boldsymbol{X}^k$, Y)=1时，两者具有强相关。

为筛选特征向量，采用下式对第 k 维特征向量进行筛选，即：

$$\boldsymbol{V}^k=\begin{cases}\mathrm{dCor}(\boldsymbol{X}^k,Y)\geqslant\omega,\ \boldsymbol{V}^k=1\\ \mathrm{dCor}(\boldsymbol{X}^k,Y)<\omega,\ \boldsymbol{V}^k=0\end{cases}\tag{2}$$

式中：$\boldsymbol{V}^k$ 为第 k 维特征向量的筛选判别值，是布尔值；ω 为筛选阈值。当距离相关系数的绝对值大于阈值 ω 时，$\boldsymbol{V}^k$ 的值为1，则第 k 维度特征量被保留；当距离相关系数的绝对值小于阈值 ω 时，则第 k 维特征向量被删除。新特征向量筛选结束后，统一进行规范化处理。

1.3　基于参数迁移学习的CNN-GRU混合预测模型

1.3.1　CNN-GRU混合模型

随着深度学习的兴起和计算能力的提升，CNN得到了深入研究和广泛应用，其模型也在不断演变和发展。CNN不仅可以有效提取时序数据的局部特征，而且可以减少模型参数量、降低计算复杂度和训练时间[15]。另一方面，GRU是一种新型循环神经网络，相比LSTM网络结构，GRU简化了内部单元结构，使其可以更好地控制状态向量的更新和输出，从而提取出时序数据的重要信息，同时过滤掉冗余信息，最终提高模型的精度和效率[16]。所以，本文利用CNN-GRU混合模型进行负荷预测可有效提高负荷预测的准确性。

在深度学习中，训练数据越多，模型的准确性越高。当训练样本数量较少时，为避免过度拟合，过去只能采用简单神经网络，但这样会降低预测准确度。针对训练数据的稀缺性约束，可依赖高精度预测模型来弥补数据不足。因此，本文提出了一种基于参数迁移学习的CNN-GRU混合模型。

1.3.2　基于参数迁移学习的混合负荷预测模型

1）迁移学习

迁移学习是一种将在一个任务上学习到的知识和经验应用到另一个相关任务中的方法，旨在提高模型在新任务上的性能。与传统机器学习不同，迁移学习不需要大量数据作为前提，同时还能提高模型的准确性[17]。迁移学习将问题领域分为源域和目标域，其中源域是指已训练好的模型或知识所基于的数据集，是知识迁移的源头；目标域是具有较少数据集的知识域，是需要应用迁移学习的知识或经验来解决的新问题。源域和目标域相互依存，共同决定了迁移学习的效果和价值。

迁移学习按学习内容可划分为基于实例的迁移学习、基于特征的迁移学习、基于关系的迁移学习和基于参数的迁移学习。其中，基于参数的迁移学习相比其他3种迁移学习具有更强的可迁移性。它将源域的模型参数直接运用到目标域，避免了目标域模型的重新训练，从而减少了时间和计算成本。本文采用基于参数的迁移学习来构建混合预测模型。

2）源域CNN-GRU结构

如图1所示，在本混合预测模型中，CNN由输入层、3个卷积层、最大池化层等5个层次组成；GRU由输入层、GRU层、全连接层和回归输出层等4个层次组成。在CNN-GRU架构下，预测模型首先对源域数据进行特征筛选和规范化处理，然后将其输入到输入层。接着，使用卷积层和最大池化层对时序数据进行特征提取和构建，从而得到时序数据的特征向量。最后，将扩展后的时序特征向量作为GRU的输入，以完成对序列数据的建模和处理。

在模型训练过程中，将给予充分时间完成算法收敛，每次训练不断改善损失函数，使模型参数最终达到最优。

3）参数迁移策略和目标域CNN-GRU

在现实中，源域和目标域之间在数据集和相似性方面存在一定差异，因此，当目标域数据集规模较小时，直接迁移使用源领域模型容易造成目标域模型过度拟合。

为避免发生迁移学习后的过度拟合，本预测模型将参数迁移场景划分为如表2所示的4个转移条件，以支持源域和目标域之间的参数迁移决策。对于CNN-GRU预测模型，初始层用于提取边缘特征，随着层数的增加，冗余特征将被去除，模型可以逐渐学习到更复杂的特征，从而提高模型的准确性。因此，当目标域的数据集规模较小且与源域相似度较高时，只需迁移学习模型的最后几层，以防出现过度拟合；当目标数据集较小且与源域数据集相似度较低时，只需迁移学习模型的前几层，以防止过拟合；当目标数据集很大且与源域数据集的相似度很高时，则需迁移除全连接层以外的所有层，以防止过度拟合；当目标数据集很大且与源域数据集的相似度很低时，如果用预训练的权重来初始化整个目标模型的权重，只会加快训练速度，不一定能提高模型的精度，所以没有必要使用迁移学习。

为判别源域和目标域特征数据集之间的相似性程度，本文采用马氏距离(Mahalanobis distance，MD)方法来衡量数据集间的相似度[18-19]，其计算公式为

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

$$MD=(Z-\mu)^{T}I^{-1}(Z-\mu) \tag{3}$$

式中:Z为数据向量;μ为独立变量的平均值向量;I为独立变量的反协方差矩阵。根据式(3)计算2个数据集之间的MD可判断出两数据集间的相似度关系,并根据表2的迁移策略,设定迁移学习的条件。

表2 迁移学习条件的分类

Table 2 Classification of transfer learning conditions

相似性程度	迁移内容	
	数据集规模小	数据集规模大
高	只迁移学习模型的最后几层	迁移除全连接层以外的所有层
低	只迁移学习模型的前几层	不需要迁移学习

在本文模型中,数据集A和数据集B之间的马氏距离为40.84,表明2个数据集的相似性较低。因此,本预测模型在建立网络模型时,将源域卷积层设为3层结构,目标域卷积层设为5层结构。迁移学习只迁移学习模型的前3层,目标域模型的卷积层4和5的初始化参数随机生成。

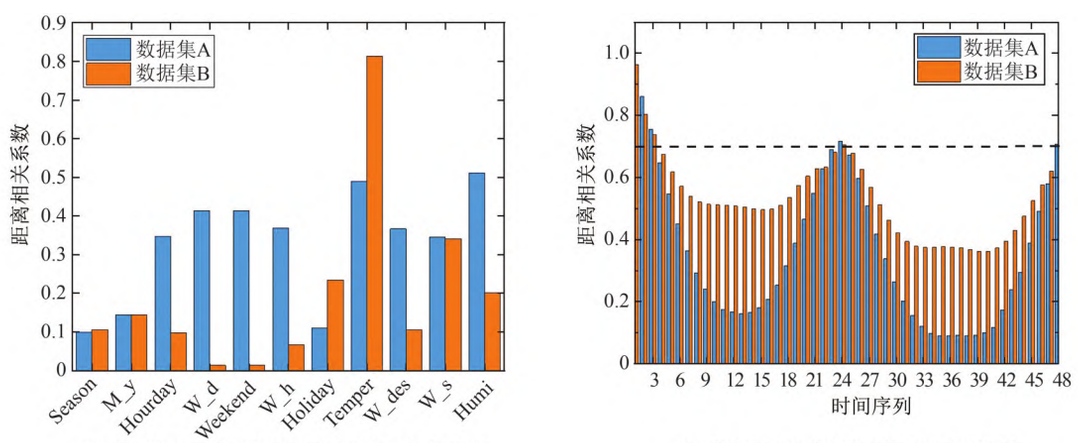
2 算例分析

为验证本预测模型实验的有效性,本文采用数据集A、B进行验证。数据集A为我国东北某地区2018—2022年5 a内每小时的电力负荷数据,数据集B则为另一地区2022年度内每小时的电力负荷数据。数据集A将2018—2021年的数据作为训练数据,将2022年数据作为测试数据。在本文中,将数据量较大的数据集A作为源域,将数据量较小的数据集B作为目标域。

根据表1列出的特征集,对数据集A、B分别进行特征提取及筛选,图2为计算表1所列各特征的距离相关系数。其中,蓝色条和橙色条分别表示数据集A和数据集B的结果;黑色虚线对应ω值,当ω被设置为0.7(普遍认为强相关的值为0.7~1.0)时,根据式(2),选择超过黑色虚线的特征作为源域和目标域预测模型的最终输入特征。

经过计算,最终将DC大于ω的特征向量(即图中柱状部分超出虚线的特征向量)予以保留。数据集A(源域)的最终输入特征为:时间序列中数据集A的滞后1、2、3、24、48特征向量。数据集B(目标域)的最终输入特征为:温度和时间序列中数据集B的滞后1、2、3、24、48特征向量。

源域和目标域的CNN-GRU混合模型的结构层如表3所示。在设置了目标域的初始模型后,使用目标域的训练样本对模型的内部参数进行微调,以提高目标域模型的可靠性。



(a) 数据集A及数据集B的日期因素及气候因素

(b) 数据集A及数据集B的时间序列因素

图2 数据集A及数据集B的特征选择

Fig.2 Feature selection of dataset A and dataset B

2.1 不同机器学习方法对数据集A的预测对比分析

本文分别采用反向传播BP(back propagation)、线性回归LR(linear regression)、LSTM、GRU、CNN、CNN-LSTM、CNN-GRU等模型对数据集A进行拟合,采用平均绝对误差(mean absolute error,MAE)、均方根误差(root mean square error,RMSE)、平均绝对百分比误差(mean absolute percentage error,MAPE)来评价预测结果,其计算公式分别为[20]

$$MAE=\frac{1}{N}\sum_{i=1}^{N}|y_i-\hat{y}_i| \tag{4}$$

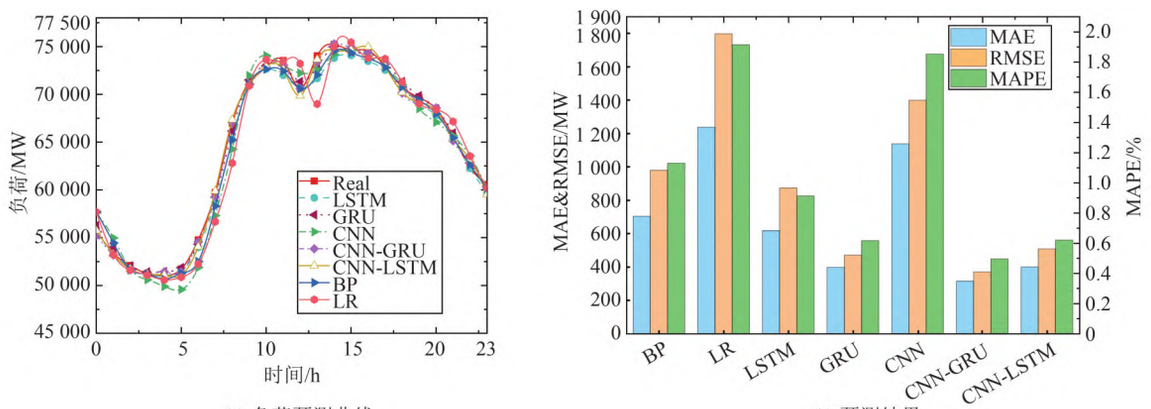
$$RMSE=\sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i-\hat{y}_i)^2} \tag{5}$$

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$\mathrm{MAPE}=\frac{100}{N}\sum_{i=1}^{N}\left|\frac{y_i-\hat{y}_i}{y_i}\right| \tag{6}$$

式中：$\hat{y}_i$为预测值；y_i为实际值；N为样本总数。

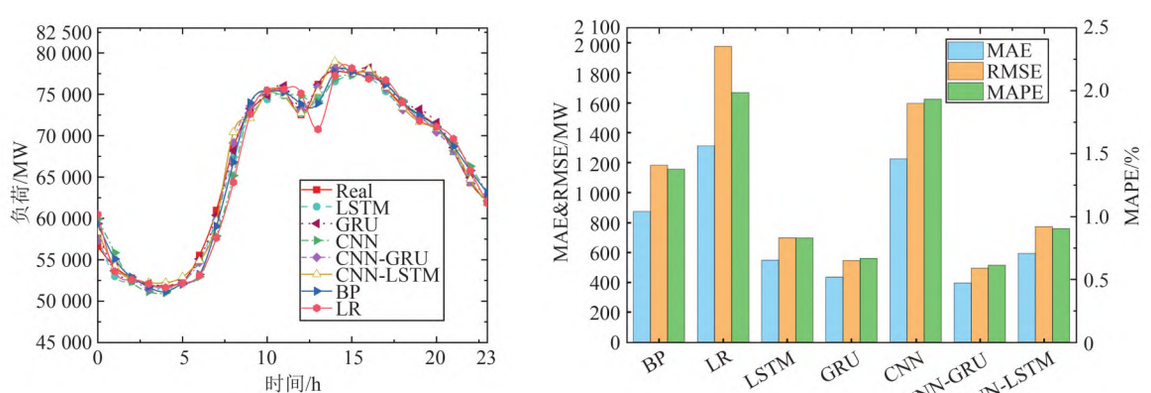
图3、4分别为工作日和周末的电力负荷预测概况和预测结果。由于一年中工作日的数量远多于周末的数量，因此工作日模型的预测精度高于周末的预测精度。通过进一步的对比可以看出，在不同模型中，CNN-GRU模型的负荷预测曲线与实际负荷曲线的拟合程度最高，模型的评价指标值最低；回归模型的负荷预测曲线与实际负荷曲线拟合程度最小，模型的评价指标值最高。因此，回归模型的准确率最低，而CNN-GRU模型的准确率最高。在此前提下，本文选择CNN-GRU模型作为迁移学习模型的源域和目标域模型。具体数据如表4所示。



(a) 负荷预测曲线　　(b) 预测结果

图3　数据集A不同模型下的工作日负荷预测曲线及预测结果分析

Fig.3　Analysis of workday load forecast curves and results under different models in dataset A



(a) 负荷预测曲线　　(b) 预测结果

图4　数据集A不同模型下的周末负荷预测曲线及预测结果分析

Fig.4　Analysis of workday load forecast curves and results under different models of dataset A

2.2　基于参数迁移学习的CNN-GRU混合模型对数据集B的性能分析

基于2.1节中的研究内容，采用CNN-GRU混合模型分别作为迁移学习的源域模型和目标域模型来分析数据集B，进而微调目标域模型中的参数。

图5、6分别为数据集B在不同模型下对工作日和周末负荷的预测概况和预测结果。与对数据集A的研究类似，预测模型在工作日的准确率高于节假日和周末，图中Proposed表示本文中所提出的预测方法。由于数据集B的训练数据较少，整体训练模型的准确率远低于数据集A，与实际负荷曲线的拟合程度也相对较低。对比图3、4中的7个模型可以看出，CNN-GRU预测模型的准确率仍然很高。尽管如此，本文所提出的方法可以进一步降低CNN-GRU模型的评估指标。由表5数据可知，在工作日，与CNN-GRU模型相比，本文方法的MAE、RMSE和MAPE分别降低了5.94%、14.2%和11.5%；在周末，与CNN-GRU模型相比，本文方法的MAE、RMSE和MAPE分别降低了2.7%、22.7%和16.2%。由此可知，本文提出的模型可以解决由于数据不足导致的模型精度低的问题。

图7为不同模型的训练时间，其中黑色折线和

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

表 3 CNN-GRU 混合模型层结构

Table 3 CNN-GRU hybrid model layer structure

网络模型	层	激活形态	
		源域特征向量	目标域特征向量
CNN	输入层	(None,1,6,1)	(None,1,7,1)
	卷积层 1	(None,1,2,8)	
	卷积层 2	(None,1,2,16)	
	卷积层 3	(None,1,2,16)	
	卷积层 4	—	(None,1,2,64)
	卷积层 5	—	(None,1,2,128)
	最大池化层	(None,1,2)	—
GRU	输入层	(None,16)	(None,128)
	GRU 层	(None,20)	(None,20)
	全连接层	(1)	(1)

红色折线分别表示数据集 A 和数据集 B 的训练时间。由图可知由于数据集 A 的数据量比数据集 B 大,因此训练模型所需的时间也相对较长,但前 7 个模型的训练时间的变化趋势基本相同。图中 BP、LR、LSTM、GRU、CNN 都是单一模型,训练模型时间较短。而 CNN-GRU 和 CNN-LSTM 都是混合模型,训练模型时间较长。在这 7 个模型中,由于 LSTM 模型参数较多,收敛速度较慢,且 CNN-LSTM 是混合模型,因此训练模型时间最长;LR 模型最简单,是单一模型,因此训练模型时间最短。本文所提出的方法与 CNN-GRU 模型的时间相似。

结合图 5~7 可知,本文所提出的方法不仅能够提高负荷预测的精确度,而且不会增加训练时间,由此证明了本文所提出预测方法的有效性。

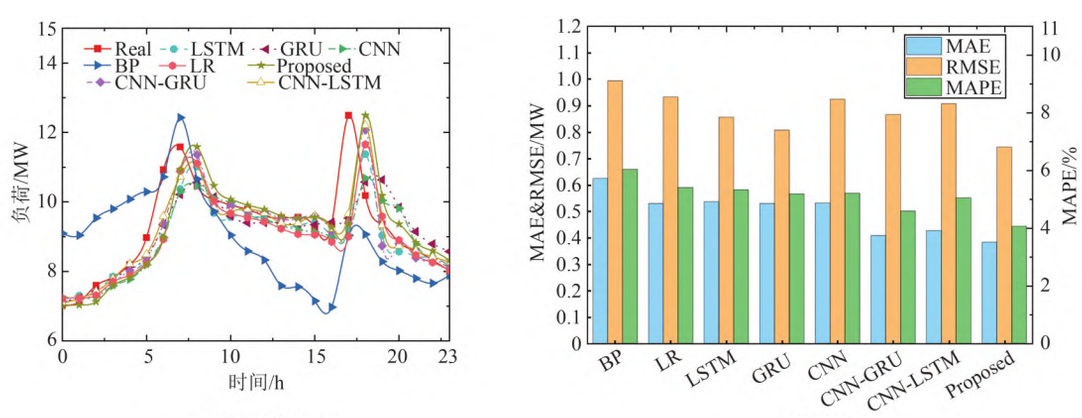
3 结论

针对缺少数据情况下的短期电力负荷预测精度低的问题,本文提出了一种基于迁移学习方法的 CNN-GRU 混合预测模型。该模型通过迁移学习,将源域 CNN-GRU 模型的学习结果迁移到目标域中,提升了模型的整体预测性能。在 2.1 节中,本文使用 BP、LR、LSTM、GRU、CNN、CNN-LSTM 和 CNN-GRU 模型对数据集 A 进行拟合。结果表明,CNN-GRU 混合模型的预测精度最高。因此,本文选择 CNN-GRU 混合模型作为迁移模型的对象。在 2.2 节中,本文将之前训练的 CNN-GRU 混合模型中的部分 CNN 模型参数转移到新的 CNN-GRU 混合模型中以拟合数据集 B,并与 BP、LR、LSTM、GRU、CNN、CNN-LSTM

表 4 数据集 A 应用不同模型误差值汇总

Table 4 Summary of error values of different models applied to dataset

模型	MAE/MW		RMSE/MW		MAPE/%	
	工作日	周末	工作日	周末	工作日	周末
BP	702.857 98	871.915 86	979.072 48	1 181.305 04	1.128 52	1.374 86
LR	1 236.825 18	1 309.824 99	1 797.664 28	1 976.009 14	1.914 34	1.984 66
LSTM	616.406 63	547.099 71	873.230 72	696.149 60	0.912 08	0.827 87
GRU	396.341 39	433.437 25	469.711 92	544.452 01	0.614 96	0.666 22
CNN	1 137.371 88	1 223.816 21	1 398.745 20	1 594.183 24	1.851 74	1.932 29
CNN-LSTM	398.794 63	592.103 09	506.763 21	771.337 69	0.618 45	0.902 78
CNN-GRU	312.815 92	394.943 64	368.858 29	493.631 75	0.493 89	0.611 38

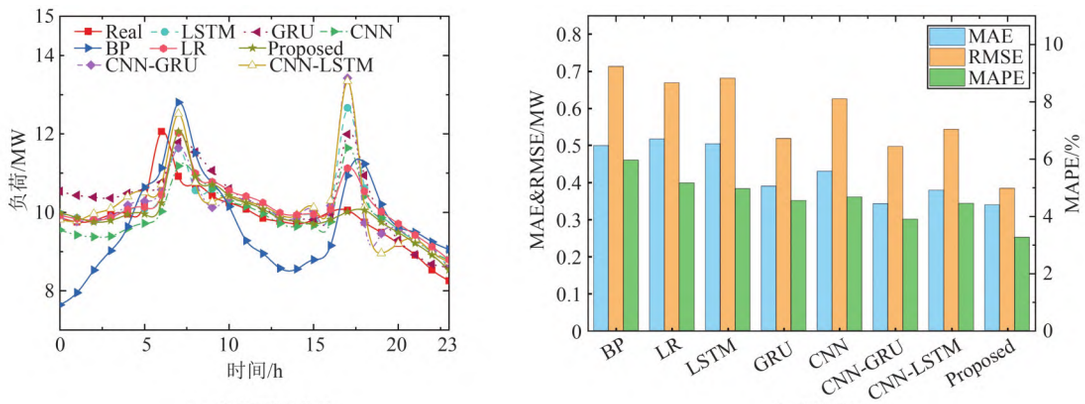


(a) 负荷预测曲线 (b) 预测结果

图 5 数据集 B 不同模型下的工作日负荷预测曲线及预测结果分析

Fig.5 Analysis of workday load forecast curves and results under different models of dataset B

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net



(a) 负荷预测曲线　　(b) 预测结果

图 6　数据集 B 不同模型下的周末负荷预测曲线及预测结果分析

Fig.6　Analysis of weekend load prediction curves and results under different models of dataset B

表 5　数据集 B 应用不同模型误差值汇总

Table 5　Summary of error values of different models applied to dataset B

模型	MAE/MW		RMSE/MW		MAPE/%	
	工作日	周末	工作日	周末	工作日	周末
BP	0.624 21	0.499 54	0.993 78	0.713 20	6.037 72	5.960 99
LR	0.529 19	0.517 37	0.932 49	0.668 98	5.401 73	5.162 86
LSTM	0.536 13	0.504 34	0.855 83	0.681 55	5.325 41	4.964 20
GRU	0.529 00	0.390 25	0.806 94	0.518 80	5.184 90	4.545 60
CNN	0.531 19	0.430 24	0.924 15	0.625 58	5.209 91	4.669 50
CNN-LSTM	0.426 81	0.379 14	0.907 44	0.543 49	5.046 36	4.446 77
CNN-GRU	0.407 64	0.342 71	0.866 02	0.497 04	4.589 23	3.892 66
Proposed	0.383 44	0.333 45	0.742 80	0.384 14	4.062 00	3.262 00

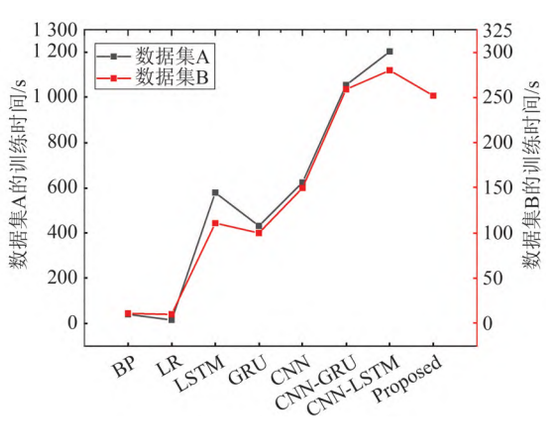


图 7　数据集 A 及数据集 B 的不同训练模型时长情况

Fig.7　Different training model durations of dataset A and dataset B

和CNN-GRU模型进行对比分析。结合表5和图7可知，在不增加训练时长的前提下，本文方法能够大幅提升预测精确度，由此证明了方法的有效性。

正如前文所述，迁移学习具有一定的局限性。当目标数据集规模大且源数据相似度低时，迁移学习可能不适用。因此，接下来作者会继续研究与其他负荷预测方法的结合，进一步提高预测模型的普适性和数据处理的能力。横坐标中的BP、LR、LSTM、GRU、CNN都是单一模型，因此训练速度更快。其中，LR模型是最简单的单一模型，所以训练模型的时间最短。而CNN-GRU和CNN-LSTM都是混合模型，所以模型训练的时间更长。在单一模型中，LSTM的模型训练时间长，是因为模型中的参数较多，因此CNN-LSTM混合模型的训练时间比CNN-GRU长，而本文所提出的模型相较于CNN-GRU模型的训练速度更快。

参考文献：

[1] 张一举. 电力负荷短期预测的分析与研究[D]. 西安：西安理工大学，2019.
ZHANG Yiju. Analysis and research on short-term forecast of power system load[D]. Xi′an: Xi′an University of Technology, 2019.

[2] 崔杨，朱晗，王议坚，等. 基于CNN-SAEDN-Res的短期电力负荷预测方法[J]. 电力自动化设备，2024，44(4): 164-170.
CUI Yang, ZHU Han, WANG Yijian, et al. Short-term power load forecasting method based on CNN-

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

SAEDN-Res[J]. Electric Power Automation Equipment, 2024, 44(4): 164-170.

[3] YING L C, PAN M C. Using adaptive network based fuzzy inference system to forecast regional electricity loads[J]. Energy Conversion and Management, 2008, 49(2): 205-211.

[4] 吴倩红, 高军, 侯广松, 等. 实现影响因素多源异构融合的短期负荷预测支持向量机算法[J]. 电力系统自动化, 2016, 40(15): 67-72,92.
WU Qianhong, GAO Jun, HOU Guangsong, et al. Short-term load forecasting support vector machine algorithm based on multi-source heterogeneous fusion of load factors[J]. Automation of Electric Power Systems, 2016, 40(15): 67-72,92.

[5] 廖旎焕, 胡智宏, 马莹莹, 等. 电力系统短期负荷预测方法综述[J]. 电力系统保护与控制, 2011, 39(1): 147-152.
LIAO Nihuan, HU Zhihong, MA Yingying, et al. Review of the short-term load forecasting methods of electric power system[J]. Power System Protection and Control, 2011, 39(1): 147-152.

[6] 焦李成, 杨淑媛, 刘芳, 等. 神经网络七十年: 回顾与展望[J]. 计算机学报, 2016, 39(8): 1697-1716.
JIAO Licheng, YANG Shuyuan, LIU Fang, et al. Seventy years beyond neural networks: retrospect and prospect[J]. Chinese Journal of Computers, 2016, 39(8): 1697-1716.

[7] SHI H, XU M H, LI R. Deep learning for household load forecasting—a novel pooling deep RNN[J]. IEEE Transactions on Smart Grid, 2018, 9(5): 5271-5280.

[8] 杨丽,吴雨茜,王俊丽,等. 循环神经网络研究综述[J]. 计算机应用,2018,38(S2):1-6,26.
YANG Li, WU Yuxi, WANG Junli, et al. Research on recurrent neural network[J]. Journal of Computer Applications, 2018, 38(S2): 1-6,26.

[9] 王增平,赵兵,纪维佳,等. 基于GRU-NN模型的短期负荷预测方法[J]. 电力系统自动化,2019,43(5):53-58.
WANG Zengping, ZHAO Bing, JI Weijia, et al. Short-term load forecasting method based on GRU-NN model [J]. Automation of Electric Power Systems, 2019, 43(5): 53-58.

[10] 陆继翔, 张琪培, 杨志宏, 等. 基于CNN-LSTM混合神经网络模型的短期负荷预测方法[J]. 电力系统自动化, 2019, 43(8): 131-137.
LU Jixiang, ZHANG Qipei, YANG Zhihong, et al. Short-term load forecasting method based on CNN-LSTM hybrid neural network model[J]. Automation of Electric Power Systems, 2019, 43(8): 131-137.

[11] SAJJAD M, AHMAD KHAN Z, ULLAH A, et al. A novel CNN-GRU-based hybrid approach for short-term residential load forecasting[J]. IEEE Access, 2020, 8: 143759-143768.

[12] 胡乾坤,黄南天. 极端温度气象日母线日前负荷预测[J]. 东北电力大学学报,2023,43(1):55-61.
HU Qiankun, HUANG Nantian. Day-ahead bus load forecasting in the extreme temperature meteorological days[J]. Journal of Northeast Electric Power University, 2023, 43(1): 55-61.

[13] 庄福振,罗平,何清,等. 迁移学习研究进展[J]. 软件学报, 2015,26(1):26-39.
ZHUANG Fuzhen, LUO Ping, HE Qing, et al. Survey on transfer learning research[J]. Journal of Software, 2015, 26(1): 26-39.

[14] EDELMANN D, MÓRI T F, SZÉKELY G J. On relationships between the Pearson and the distance correlation coefficients[J]. Statistics & Probability Letters, 2021, 169: 108960.

[15] 崔明勇,董文韬,卢志刚. 基于密度聚类模态分解的卷积神经网络和长短期记忆网络短期风电功率预测[J/OL]. 现代电力:1-11[2023-10-12]. https://doi.org/10.19725/j.cnki.1007-2322.2022.0337.
Cui Mingyong, Dong Wentao, Lu Zhigang. Short-term wind power prediction based on density clustering modal decomposition with convolutional neural network and long-short-term memory network[J/OL]. Modern Electric Power: 1-11[2023-10-12]. https://doi.org/10.19725/j.cnki.1007-2322.2022.0337.

[16] 姚程文,杨苹,刘泽健. 基于CNN-GRU混合神经网络的负荷预测方法[J]. 电网技术,2020,44(9):3416-3424.
YAO Chengwen, YANG Ping, LIU Zejian. Load forecasting method based on CNN-GRU hybrid neural network[J]. Power System Technology, 2020, 44(9): 3416-3424.

[17] 龙明盛.迁移学习问题与方法研究[D].北京:清华大学,2014.
LONG Mingsheng. Transfer learning: problems and methods[D]. Beijing: Tsinghua University, 2014.

[18] 郭靖. 对K-means聚类算法欧氏距离加权系数的研究[J]. 网络安全技术与应用,2016(10):74-75.
GUO Jing. Research on Euclidean distance weighting coefficient of K-means clustering algorithm[J]. Network Security Technology & Application, 2016(10): 74-75.

[19] 管河山, 姜青山, 王声瑞. 基于点分布特征的多元时间序列模式匹配方法[J]. 软件学报, 2009, 20(1): 67-79.
GUAN Heshan, JIANG Qingshan, WANG Shengrui. Pattern matching method based on point distribution for multivariate time series[J]. Journal of Software, 2009, 20(1): 67-79.

[20] FAN C, SUN Y J, XIAO F, et al. Statistical investigations of transfer learning-based methodology for short-term building energy predictions[J]. Applied Energy, 2020, 262: 114499.

(编辑:高映月)

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net