基于迁移学习的电力区域负荷预测模型构建方法

曲　畅[1]　陈祉丞[2]　宋诗雨[1]
（1. 国网大连供电公司　2. 国网大连市沙河口区供电公司）

摘　要：为解决电力区域负荷预测中因数据样本不足导致的预测精度下降问题，本文提出了一种基于迁移学习的负荷预测模型构建方法。以分层级迁移机制为核心，结合多尺度 CNN-BiLSTM-Attention 网络结构，通过对源域数据进行拟合优度划分与层级匹配，实现不同区域间特征知识的有效迁移。同时，采用 TrAdaBoost. R2 算法实现跨区域数据的互迁移，进一步提升了模型在目标区域上的学习效果。在实际电网数据集上的实验结果表明，本文方法在预测准确率和预测效率方面均显著优于传统深度学习模型与双残差网络模型，尤其在小样本、区域差异显著的场景下具有较强的适应性与推广性。

关键词：迁移学习；电力区域；负荷预测；预测模型

0　引言

电力负荷预测是电力系统运行与调度的重要基础，预测精度的高低直接影响到系统调度效率和运行成本。传统的负荷预测方法主要以时间序列模型为代表，如自回归移动平均模型（ARMA）等，这类方法依赖于负荷数据的线性趋势与周期性规律，模型结构简单、计算效率高，但在面对节假日、天气波动等非线性影响因素时预测效果不佳[1]。为解决线性模型难以建模复杂非线性关系的问题，近年来兴起了支持向量回归（SVR）、随机森林、极限学习机（ELM）等机器学习方法。这些非线性建模工具在提升预测精度方面具有一定优势，然而其在处理高维特征、数据冗余、样本依赖性等方面仍存在不足，特别是在小样本或异构数据背景下，模型训练效果受到限制[2-3]。

迁移学习作为一种能够利用已有模型知识迁移以辅助目标任务建模的方法，近年来被逐渐引入负荷预测研究中[4-5]。它通过从数据充分的源区域提取知识，迁移到目标区域，从而在数据样本有限的情况下实现模型训练的优化。为此，本文提出一种基于分层级迁移学习的电力区域负荷预测模型构建方法，并通过实验对模型性能进行了验证。

1　电力区域负荷分层级迁移学习

不同电力区域因气候条件、产业结构、居民用电行为等存在显著差异，导致其负荷数据呈现出高度非平稳性和区域异构性。尤其在数据样本稀缺或质量不高的区域，依赖本地数据训练深度模型往往无法获得理想的预测精度。为缓解该问题，本文提出一种基于分层级迁移学习的电力区域负荷预测方法，通过分层次、递进式的方式应用于目标区域，提升模型在小样本条件下的表现能力。

迁移学习的核心在于将源域的知识迁移到目标域，以弥补目标区域样本不足的问题。设源域负荷数据为 $X=\{x_i\}_{i=1}^{N}$，目标域数据为 $\{y_j\}_{j=1}^{M}$，其中 $N\gg M$。首先在目标域数据 Y 上对基础模型 M 进行初步训练，获得一组初始化参数权重 W_0：

$$W_0=\arg\min_W L(Y,M(W)) \tag{1}$$

式中，L 为损失函数。模型由多尺度 CNN、BiLSTM与注意力机制共同构成，用于捕捉电力负荷的局部峰值、周期性波动与时序相关性。

随后，将源域数据 X 输入模型 $M(W_0)$，对每个时间窗口片段计算其拟合优度 R^2：

$$R^2=1-\frac{\sum_t (y_t-\hat{y}_t)^2}{\sum_t (y_t-\bar{y})^2} \tag{2}$$

式中，$\hat{y}_t$ 为模型预测值；y_t 为实际负荷值；$\bar{y}$ 为样本均值。该指标衡量源域数据与目标区域负荷行为的相似性，数值越高表示越具迁移价值[6]。根据 R^2 从低到高将数据划分为 L 组。划分过程如下：

$$\begin{aligned} &X\rightarrow\{X_1,X_2,\cdots,X_L\}\\ &\text{with } R^2(X_1)<R^2(X_2)<\cdots<R^2(X_L)\end{aligned} \tag{3}$$

分层训练过程采用逐层解冻机制。设当前训练层为第 i 层，对应输入数据为 X_i，训练策略流程如图 1 所示。

中国知网　https://www.cnki.net

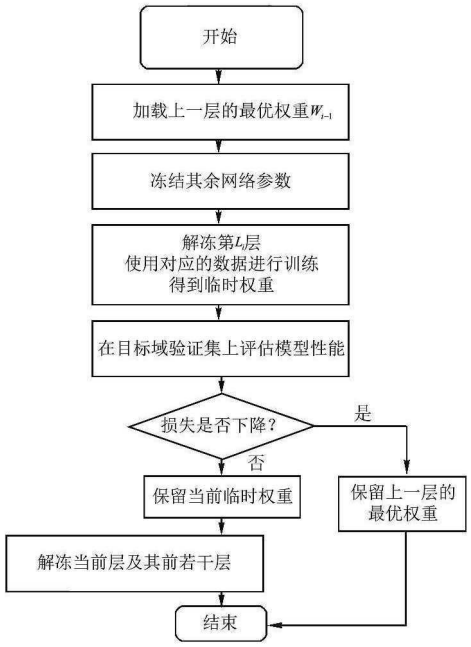


图1　训练策略流程

根据图1可知，首先加载上一层最优权重 W_{i-1}，冻结其余网络参数。

接着解冻第 i 层，用数据 X_i 训练得到临时权重 W_{tmp}：

$$W_{\text{tmp}} = \arg\min_W L(X_i, M(W_{i-1}, F_i)) \tag{4}$$

式中，F_i 为当前解冻的第 i 层参数；

然后在目标域验证集 T 上评估模型性能，若有损失下降，即：

$$L(T, M(W_{\text{tmp}})) < L(T, M(W_{i-1})) \tag{5}$$

则保留 $W_i = W_{\text{tmp}}$，并依次解冻当前层及其前若干层，进行多层协同训练以进一步优化模型性能。

若当前层性能未提升，则保留上一层最优权重 W_{i-1}，并跳过该层[7]。

完成分层迁移后，冻结除全连接层外的全部网络参数，使用目标区域数据对输出层进行微调，微调过程如公式（6）所示：

$$W_{\text{end}} = \arg\min_{W_f} L(Y, M(W_L \cup W_f)) \tag{6}$$

式中，W_L 为最终迁移得到的网络结构权重；W_f 为输出层参数。此阶段采用较小学习率，避免过拟合。

2　基于迁移学习的电力区域负荷预测模型

为解决小样本区域电力负荷数据建模难、模型泛化能力弱的问题，本文在分层级迁移学习框架基础上，进一步设计了集成数据互迁移与深度神经网络融合结构的电力区域负荷预测模型。利用不同区域间的潜在负荷结构相似性，通过高相关源任务数据的迁移辅助，实现目标区域的精确建模。

2.1　数据互迁移

在电力系统中，不同区域的负荷序列虽然受制于地理、气象及行为模式等多种差异因素，但由于用户行为存在规律性（如季节性与周期性），区域间也存在大量隐含的结构共性。这些共性可被提取并迁移，提升小样本区域的建模效率。本文以任务间相似性为筛选依据，引入相关系数作为度量指标，从候选源区域中筛选出与目标区域负荷模式相近的数据子集。

设电力区域任务集合为 $T = \{T_1, T_2, \cdots, T_M\}$，其中 T_{target} 为目标区域任务。对于任意两个任务，其输入特征向量为 $\boldsymbol{X}_i$ 与 $\boldsymbol{X}_j$，其相似性定义为：

$$\text{Sim}(T_i, T_j) = \rho_{X_i, X_j} \tag{7}$$

式中，ρ_{X_i, X_j} 为皮尔逊相关系数。计算某一候选源任务与目标任务集合的平均相似性，计算公式如下：

$$\text{Sim}(T_i, T_{\text{target}}) = \frac{1}{n}\sum_{j=1}^{n} \text{Sim}(T_i, T_j) \tag{8}$$

式中，n 目标任务集合中包含的区域数量。当 $\text{Sim}(T_i, T_{\text{target}}) > \lambda$（阈值）时，即认为该任务具备有效迁移性[8]。该筛选过程有效避免了无关数据带来的负迁移风险。

考虑到电力负荷的周期性特征（如周一至周日负荷规律显著不同），本文引入按星期分类的建模思想，将负荷数据划分为7个子任务。对每一类（如周三）构建对应预测模型时，将其余六类中与之相似的数据作为迁移源，实现周期性结构的知识互补。这种“日内异构建模+异周迁移”的方式，既保留了负荷模式的时间差异，又提高了跨周期泛化能力。

迁移建模基于 TrAdaBoost. R2 框架实现，其本质是对样本误差加权调节。初始化样本权重为：

$$w_i^{(1)} = \frac{1}{n+m}, \quad i = 1, 2, \cdots, n+m \tag{9}$$

在每一轮迭代中，基学习器基于当前权重训练，计算误差并归一化为：

$$\begin{cases} e_{t,i} = \dfrac{|y_i - h_t(x_i)|}{D_t} \\ D_t = \max_j |y_j - h_t(x_j)| \end{cases} \tag{10}$$

对源域与目标域分别采用不同的权重更新策略，误差越大，其在源域中的权重将衰减，从而减少迁移干扰。

2.2　预测模型

本文采用多尺度 CNN-BiLSTM-Attention 网络构建预测模型。多尺度卷积模块用于提取不同时间感知尺度下的局部负荷特征；BiLSTM 模块捕捉时间序列中的双向动态依赖；注意力机制进一步增强关键时间片段对最终预测结果的影响权重。该结构不仅具备较强的非线性建模能力，同时对复杂时间结构具有良好的适应性。

设输入负荷序列为 $x = \{x_t\}_{t=1}^{T}$，通过多尺度卷积层提取不同尺度下的局部特征，再经过 BiLSTM 层进

中国知网 https://www.cnki.net

一步捕获长时间序列中的依赖关系。模型的输出经过ReLU激活函数处理后，得到预测结果。

将其并行拼接后输入BiLSTM层，生成双向上下文向量：

$$h_t = [\overrightarrow{h_t}; \overleftarrow{h_t}] \tag{11}$$

最后通过注意力机制对各时刻特征加权，计算预测输出：

$$\begin{cases} y = \sum_{t=1}^{T} \alpha_t h_t \\ \alpha_t = \dfrac{\exp(h_t^T \boldsymbol{W}_\alpha)}{\sum_{t=1}^{T} \exp(h_t^T \boldsymbol{W}_\alpha)} \end{cases} \tag{12}$$

式中，α_t为注意力权重；$\boldsymbol{W}_\alpha$为可学习参数矩阵。

通过深度结构提高模型的非线性拟合能力，使不同区域间的迁移知识能够通过网络结构进行充分融合与表达。

3 实验研究

为了验证本文提出的基于迁移学习的电力区域负荷预测模型构建方法的实际应用效果，本文选取了中国东南部地区某省电网多个地市级调度区域的实际负荷数据作为实验基础，涵盖典型的一二线城市、县级区域和风光资源分布明显的边缘区域，充分体现区域之间在气候条件、用电结构、负荷曲线形态等方面的差异。为贴合数据不均衡与小样本问题，实验设定一个数据稀缺的区域作为目标区域，其他区域作为候选源域，借助迁移学习框架构建目标区域的短期负荷预测模型。

为提高实验的验证结果，同时选用传统的基于深度学习的电力区域负荷预测模型构建方法和基于级联MCNN-MMLP双残差网络的电力区域负荷预测模型构建方法进行实验对比，分析预测准确率和预测时间。

得到的预测准确率实验结果如图2所示。

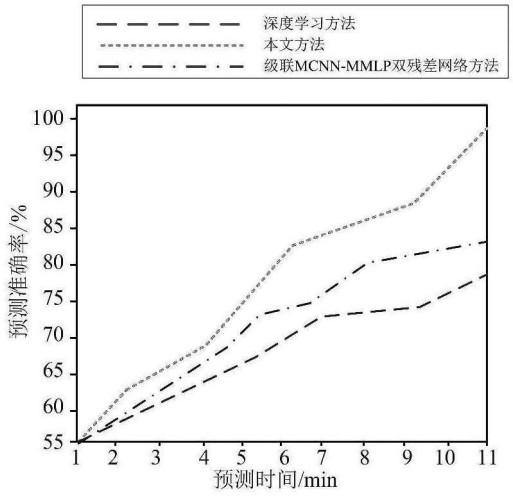


图2 预测准确率实验结果

根据图2可知，随着预测时间的增加，三种方法的预测准确率都在不断增加，但是本文提出的基于迁移学习的电力区域负荷预测模型构建方法的预测准确率明显高于传统方法，当预测时间达到11min时，本文方法的准确率已经达到95%以上，而传统的基于级联MCNN-MMLP双残差网络的电力区域负荷预测模型构建方法准确率为82%，基于深度学习的电力区域负荷预测模型构建方法准确率为78%。造成这种现象的原因主要在于迁移学习机制在小样本条件下的显著优势。传统的基于深度学习和MCNN-MMLP模型均依赖于大规模目标区域数据的充分训练，在目标区域历史负荷数据稀缺的情形下，模型容易陷入过拟合或特征学习不充分，导致预测精度偏低。而本文提出的方法通过分层级迁移策略有效引入与目标区域具有高相似度的源区域数据，使得模型在初始阶段即可获得较强的泛化能力，从而实现更快的收敛速度和更高的预测精度。

预测时间实验结果如下表所示。

表 预测时间实验结果

实验次数	预测时间/min		
	深度学习方法	双残差网络方法	本文方法
1	9.85	10.44	1.21
2	9.03	11.06	1.58
3	9.37	10.58	1.44
4	9.40	11.55	1.58
5	9.21	10.96	1.20
6	9.05	10.85	1.42
7	9.58	11.05	1.39
8	9.23	10.58	1.48
9	9.44	10.44	1.75
10	9.25	10.95	1.86

根据上表可知，在10次实验中，本文所提出的基于迁移学习的电力区域负荷预测模型在预测时间方面显著优于对比的两种传统方法。统计结果显示，本文方法的平均预测时间仅为1.49min，远低于传统深度学习方法的9.34min和基于级联MCNN-MMLP双残差网络方法的10.85min。其中，本文方法在最短时间内完成预测的实验为第1次（1.21min），最长预测时间为第10次（1.86min），整体波动幅度较小，表现出良好的稳定性。造成这一差异的主要原因在于本文引入的分层级迁移学习机制在模型初始化阶段便提供了较为优质的参数权重，大幅减少了模型在目标区域上训练与调优的迭代次数。

中国知网 https://www.cnki.net

综合来看，本文模型不仅在预测准确率方面表现优越，在预测效率上也展现出极强的实用性，尤其适用于区域间差异大、样本不足、对实时响应要求较高的电力调度场景，具备良好的工程应用价值。

4 结束语

本文围绕电力区域负荷预测中面临的数据稀缺与区域异构问题，提出了一种基于迁移学习的负荷预测模型构建方法。通过构建分层级迁移结构，有效实现了源域负荷特征向目标域的逐层传递，提升了模型在小样本条件下的训练效果与预测精度。同时，结合TrAdaBoost. R2 算法实现跨区域数据的互迁移，进一步优化了模型对负荷时序特征的学习能力。实验结果验证了所提方法在预测准确率与效率方面均优于现有主流方法，特别适用于电力系统中区域负荷差异明显、历史数据不足的调度场景。

未来工作可进一步考虑引入多源多任务联合迁移机制，结合区域用能行为建模、碳排放约束等外部因素，构建更具泛化能力与应用深度的智能电力负荷预测框架，为实现智慧电网调度与负荷动态管理提供理论与技术支撑。

参考文献

[1] 欧阳福莲，王俊，周杭霞. 基于改进迁移学习和多尺度CNN-BiLSTM-Attention的短期电力负荷预测方法［J］. 电力系统保护与控制，2023，51（2）：132-140.

[2] 张志霞，谢宝强. 基于FCGA-LSTM与迁移学习的天然气负荷预测［J］. 计算机与现代化，2023（7）：7-12.

[3] 冯舒宜，钱东. 基于迁移学习和LSTM网络的光伏系统负荷预测［J］. 微型电脑应用，2024，40（6）：168-171.

[4] 钟文潇，安兴伟，刘畅，等. 基于迁移学习Boosting的跨时间脑力负荷识别研究［J］. 载人航天，2024，30（3）：312-319.

[5] 章家义，龚圣辉，聂堃. 基于GRU门控单元网络的电力负荷预测研究［J］. 粘接，2024，51（4）：145-148.

[6] 余凯峰，吐松江·卡日，张紫薇，等. 基于级联MCNN-MMLP双残差网络的短期负荷预测［J］. 电力系统保护与控制，2025，53（2）：151-162.

[7] 卢俊菠，刘俊峰，罗燕，等. 基于改进WGAN考虑特征分布相似性的小样本负荷预测方法［J］. 控制理论与应用，2024，41（4）：597-608.

[8] 李吉峰，潘峰，王延勃，等. 考虑联络线负荷匹配特性的供电分区深度迁移学习负荷预测［J］. 电气应用，2023，42（9）：24-32.

（收稿日期:2025-06-25）

（上接第392页）

由图3可知，所提检修方法修复所需的平均间隔时间较小，本文方法运用载波相位差分技术定位流动站坐标，将调整出的流动站坐标与预设的故障位置进行对比验证。再利用无人机设备，运用LAMBDA算法解算故障发生点整周模糊度，输出固定解确定最终故障位置，迅速得到高精度位置信息。综上所述，该运维检测方法修复性最好，平均修复时间小于1h，检修效率高。

3 结束语

为实现变电站电气设备智能化运维，提出物联网技术支持下变电站电气设备全生命周期运维检修研究。该方法基于设备状态和诊断结果，结合电力系统的运行需求，制定了一套个性化的运维检修方案，打破了传统定期检修和故障检修的局限，实现了运维检修工作的精准化。在未来，变电站的电气设备全生命周期运维检修可以结合智能算法投入实际的应用，实现电力系统与其他信息系统的深度融合。

参考文献

[1] 王金龙. 带电检测技术下的配网电力设备运维检修［J］. 自动化应用，2024，65（8）：145-146，149.

[2] 鲍眺，卢雷. 基于群体智能算法的电力设备现场智能化运维检修研究［J］. 无线互联科技，2024，21（19）：43-45.

[3] 陈泊远，刘宏杰. 基于红外成像技术的配电网输电线路检修运维方法［J］. 电工技术，2024（5）：114-116，121.

[4] 何东升，吕佳毅. 基于智能监测的110kV移相变压器运维检修技术分析［J］. 电子技术，2024，53（11）：90-91.

[5] 胡昇. 变电运维中的设备状态检修策略分析［J］. 集成电路应用，2025，42（4）：324-325.

[6] 袁超，吴健，施皓天. 泛在物联网下10kV配网架空线路运维检修技术研究［J］. 电气技术与经济，2024（9）：81-83，86.

[7] 梅萧. 电力系统电气二次设备检修技术分析［J］. 锅炉制造，2025（3）：60-61，64.

（收稿日期:2025-06-24）

中国知网 https://www.cnki.net