小样本条件下基于特征迁移学习的负荷预测算法

李步新，曹 阳
（国网江苏综合能源服务有限公司，江苏 南京 210000）

摘要：针对电力现货市场交易需要高精度的负荷预测技术作为支撑，而已有的传统预测算法所需数据样本规模过大，且精度和效率较低的问题，文中提出了一种小样本条件下基于特征迁移学习的负荷预测算法。该算法通过互补集合经验模态分解(CEEMD)对负荷数据进行分析，从而降低了数据的波动性和随机性。在卷积神经网络(CNN)和长短期记忆网络(LSTM)构建的并行数据特征提取模块中，引入麻雀搜索算法(SSA)进行超参数优化，利用改进后的门控循环单元(GRU)实现负荷预测。以采集到的某地区小样本负荷数据集进行的可行性验证结果表明，所提算法的MAE、RMSE、MAPE分别为152.62 MW、172.54 MW和0.432%，与传统预测算法相比预测误差更小、鲁棒性更优，能够满足电力系统的数据处理工程需要。

关键词：负荷预测；集合经验模态分解；麻雀搜索算法；卷积神经网络；改进门控循环单元；长短期记忆网络

中图分类号：TM715 **文献标识码：**A **文章编号：**1674-6236(2026)14-0105-05

DOI：10.14022/j.issn1674-6236.2026.14.020

Load forecasting algorithm based on feature transfer learning under small sample conditions

LI Buxin, CAO Yang
(*State Grid Jiangsu Comprehensive Energy Services Co., Ltd., Nanjing* 210000, *China*)

Abstract: Aiming at the problem that power spot market transactions need high-precision load forecasting technology as a support, and the existing traditional forecasting algorithms need large data samples with low accuracy and efficiency, this paper proposes a load forecasting algorithm based on feature transfer learning under the condition of small samples. The algorithm analyzes the load data through the Complete Ensemble Empirical Mode Decomposition(CEEMD), thus reducing the volatility and randomness of the data. In the parallel data feature extraction module constructed by Convolutional Neural Network(CNN) and Long Short-Term Memory(LSTM) network, Sparrow Search Algorithm(SSA) is introduced for hyperparameter optimization, and finally the improved Gated Recurrent Unit(GRU) is used to realize load forecasting. The feasibility verification results based on the collected small sample load data sets in a region show that the MAE, RMSE and MAPE of the proposed algorithm are 152.62 MW, 172.54 MW and 0.432%, respectively. Compared with the traditional prediction algorithm, the prediction error is smaller and the robustness is better, which can meet the needs of power system data processing engineering.

Keywords: load forecasting; Ensemble Empirical Mode Decomposition; Sparrow Search Algorithm; Convolutional Neural Network; improved Gated Recurrent Unit; Long Short-Term Memory network

收稿日期：2025-05-16 **稿件编号：**202505153

基金项目：国网江苏综合能源科技项目(JS230088600)

作者简介：李步新(1979—)，男，江苏武进人，工程师。研究方向：电力系统及其自动化。

中国知网 https://www.cnki.net

随着新能源发电的兴起，新能源渗透率持续提升，对电力现货市场精准交易与调度提出更高要求，因此需要高精度的电力负荷预测来提供调度支持[1-3]。众多学者针对负荷预测进行了广泛研究，并取得了一定的研究成果。文献[4]利用长短期记忆网络(Long Short-Term Memory, LSTM)进行负荷预测，相比于传统预测算法有效提高了预测精度。文献[5]在单一LSTM网络的基础上，增加了卷积神经网络(Convolutional Neural Network, CNN)特征提取模块，通过提取数据特征，提高了负荷预测精度。文献[6]利用EMD算法对原始数据进行了分解，并利用LSTM进行预测，提高了预测精度。

上述研究在融合特征提取和数据预处理模块的基础上，虽然提高了负荷预测精度，但都需要大规模的已标记数据集作为模型训练基础，而特定场景标注样本获取成本高。为进一步提高负荷预测精度，文中提出了一种小样本条件下基于特征迁移学习的负荷预测算法，并构建了预测模型。首先，利用互补集合经验模态分解算法(Complete Ensemble Empirical Mode Decomposition, CEEMD)对负荷数据进行分解，降低数据的波动性和随机性，从数据角度提高预测精度；其次，基于CNN、LSTM构建特征提取模块，利用CNN提取数据空间特征，LSTM提取数据时序特征，实现数据特征深度挖掘；然后，在传统门控循环单元(Gated Recurrent Unit, GRU)中引入注意力机制(Attention)，进一步提高预测精度；最后，为了解决人工难以选取最优参数的问题，利用麻雀搜索算法(Sparrow Search Algorithm, SSA)对预测模型的超参数进行选取。

1 负荷预测算法设计

1.1 数据预处理

电力负荷数据因为应用场景不同，会存在一定的随机性和波动性，通常采用分解算法来降低其带来的波动影响。CEEMD算法在集合经验模态分解算法(Ensemble Empirical Mode Decomposition, EEMD)基础上进行改进，引入了正负相反的辅助噪声来解决传统分解算法所存在的模态混叠和计算效率低的问题[7-9]。CEEMD无需先验参数设定，因此该文采用CEEMD进行原始负荷数据预处理。具体算法步骤如下：

1)在用于预测研究的负荷数据序列 F 中加入 n 对正负相反、均值为0的随机高斯白噪声序列 l，得到 $2n$ 组负荷时间序列：

$$F=\{f_0^+,f_0^-,f_1^+,f_1^-,\cdots,f_{n-1}^+,f_{n-1}^-\} \tag{1}$$

式中，$f_i^+=f_i+l_i^+$；$f_i^-=f_i+l_i^-$，$i\in(0,n)$。

2)通过CEEMD算法对时间序列进行分解得到IMF分量，并利用式(2)得到一个新的时间序列：

$$g_i=f_i-n_i \tag{2}$$

3)判断步骤2)得到的 g_i 是否达到终止条件。若符合条件，g_i 即为Res分量；若不符合条件，则将 g_i 序列继续重复步骤2)的计算，直至符合终止条件为止。

4)将所有时间序列均采用步骤2)和步骤3)进行分解，直至得到IMF和Res分量。其对应的公式，分别如式(3)和式(4)所示：

$$\mathrm{IMF}=\begin{bmatrix} l_{0,0}^+ & l_{0,1}^+ & \cdots & l_{0,l-1}^+ & l_{0,l}^+ \\ l_{0,0}^- & l_{0,1}^- & \cdots & l_{0,l-1}^- & l_{0,l}^- \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ l_{k,0}^+ & l_{k,1}^+ & \cdots & l_{k,l-1}^+ & l_{k,l}^+ \\ l_{k,0}^- & l_{k,1}^- & \cdots & l_{k,l-1}^- & l_{k,l}^- \end{bmatrix} \tag{3}$$

$$\mathrm{Res}=\begin{bmatrix} g_0^+ \\ g_0^- \\ \vdots \\ g_k^+ \\ g_k^- \end{bmatrix} \tag{4}$$

5) l 组IMF分量和Res分量分别如下：

$$\mathrm{IMF}_j=\frac{1}{2k}\sum_{i=0}^{k}(l_{i,j}^+ + l_{i,j}^-) \tag{5}$$

$$\mathrm{Res}=\frac{1}{2k}\sum_{i=0}^{k}(g_i^+ + g_i^-) \tag{6}$$

式中，IMF_j 是第 j 个IMF分量，$j\in(0,l)$，最终原始负荷数据可以分解为如下形式：

$$F=\sum_{j=0}^{l}\mathrm{IMF}_j+\mathrm{Res} \tag{7}$$

利用CEEMD对原始负荷数据进行分解所得到的分量中，有部分分量具有相似度，而将相似分量进行合并重构可以提高预测模型的预测效率。样本熵(Sample Entropy, SE)是用来评价时间序列数据复杂度的常见算法[10-11]。研究中利用SE对CEEMD算法得到的分量进行分析，可以减少分量数目，提高预测模型的学习和预测效率，其原理为：

$$S_{\mathrm{SE}}(a,b,r)=-\ln\frac{F^{a+b}-r}{F^a+r} \tag{8}$$

中国知网 https://www.cnki.net

在实际应用中,a和b的数值一般取1或2;r取时间序列标准差的0.10~0.25。此次研究过程中,a为2,b为1,r为0.2。

1.2　预测模型设计

在时间序列的预测过程中,为了充分挖掘数据特征,通常在预测模型中融合数据特征提取模块。本次设计基于CNN和LSTM网络来构建特征提取模块。

CNN能够对负荷数据的空间特征进行有效提取[12],此次采用一元CNN作为局部特征提取模块。而LSTM是对RNN的一种优化算法,其在一定程度上解决了传统RNN存在的梯度爆炸问题。该网络因为自身的长期记忆能力能够有效提取数据的时序特征,因此文中将其作为时序特征提取模块。

GRU网络[13-14]是在LSTM网络基础上改进的一种神经网络,其不仅能够解决RNN网络的梯度问题,还可以减少时间成本,提高预测效率。因此,该文设计采用GRU网络作为负荷数据预测模块。但是随着负荷数据时间序列过长,GRU网络会发生信息丢失的问题,此次还通过引入Attention机制[15-16]对GRU网络进行优化,在GRU激活层后接入Attention机制,构建出了AGRU(Attention GRU)预测模块。最后,依据权重分配原则计算出不同特征向量对应的概率,通过不断迭代优化后输出特征值较高的数据。

融合CNN、LSTM特征并行提取模块的AGRU负荷预测模型包含了较多的超参数,因此超参数的选取对于负荷预测的精度至关重要,且需要一定的先验信息。SSA算法是根据麻雀觅食原理设计出的一种智能寻优算法,其具有收敛速度快、寻优准确的优点。为了提升模型泛化能力,设计采用SSA算法对预测模型的超参数进行智能选取,解决了人工选择存在个体差异、导致无法选取最优值的问题。

SSA-GRU/LSTM-AGRU预测模型的结构如图1所示,其相应的运算步骤如下:

1)负荷数据预处理。首先,利用CEEMD将负荷数据分解为n个IMF分量和1个Res分量;其次,利用SE算法对分解得到的n+1个分量进行评估,重新构造出m个分量。

2)数据归一化处理。为了提高预测模型的学习效率,利用式(9)对数据进行归一化处理,使运算数值被控制在[0,1]的区间内:

$$x_r=\frac{x-x_{\min}}{x_{\max}-x_{\min}} \tag{9}$$

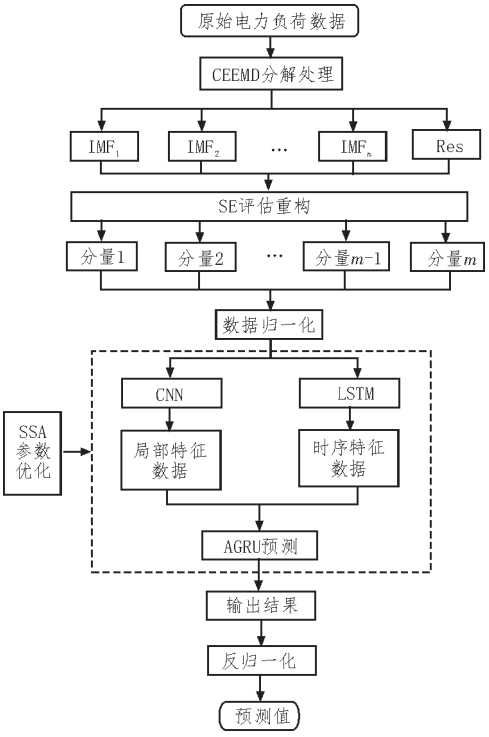


图1　SSA-GRU/LSTM-AGRU预测模型结构图

式中,x_r是经过归一化后的原始负荷数据值;$x_{\max}$、$x_{\min}$分别为原始负荷数据中的最大值和最小值。

3)预测负荷数据。先将归一化后的数据分别输入到CNN、LSTM特征提取模块中,分别提取负荷数据的局部特征和时序特征;其次,将提取到的特征数据输入到AGRU模型中进行预测,并采用SSA对GRU/LSTM-AGRU的神经元个数、层数与学习率值进行智能寻优。

4)获取预测得到的负荷数据。由于预测模型直接输出的结果是去量纲的归一化数据,为得到最终的负荷数据,还需要经过反归一化处理,如下:

$$\hat{y}_{\text{rnor}}=(y_{\max}-y_{\min})\hat{y}+y_{\min} \tag{10}$$

式中,$\hat{y}_{\text{rnor}}$是最终所需的负荷值;$y_{\max}$、$y_{\min}$分别是负荷数据集中的最大值与最小值;$\hat{y}$为预测模型直接输出的无量纲值。

小样本条件下基于特征迁移学习的负荷预测算法的总体流程如图2所示。

首先,将自建的负荷数据集按照7:2:1的比例划分为训练集、验证集和测试集。其次,利用训练集、验证集数据对该文所设计的CEEMD-SE-SSA-GRU/LSTM-AGRU预测模型进行学习训练,并根据预测阈值进行评估。当预测结果低于该阈值时,表明预测模型训练完毕,再利用测试集数据进行性能验证。

中国知网　https://www.cnki.net

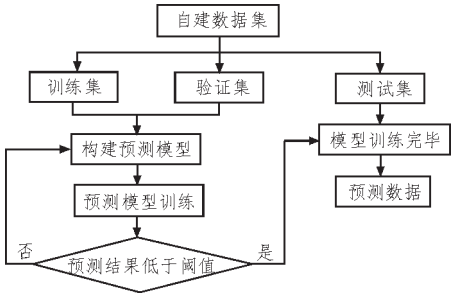


图2　负荷预测算法的总体流程

2　评价指标

在风电功率、负荷、光伏发电功率等时间序列预测中，对于模型的预测效果通常采用MAE、RMSE、MAPE进行评估。在该文负荷预测算法研究中，同样利用这3个指标对所提模型的预测性能进行分析评价，其计算公式如下：

$$\mathrm{MAE}=\frac{1}{n}\sum_{i=1}^{n}\left|y_i-\hat{y}_i\right| \tag{11}$$

$$\mathrm{RMSE}=\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2} \tag{12}$$

$$\mathrm{MAPE}=\frac{1}{n}\sum_{i=1}^{n}\frac{\left|y_i-\hat{y}_i\right|}{y_i}\times 100\% \tag{13}$$

式中，$\hat{y}_i$为预测数据；y_i为真实数据。

3　算例分析

实验采集了某地区的真实负荷数据对所提负荷预测算法进行验证测试，样本量为30户，满足小样本的场景设定。负荷数据时间跨度为2024年11月19日—2024年12月26日，采样间隔15 min，数据特征包含用户名称、用户户号以及11月19日—12月26日各个用户所需的总电量。硬件实验平台：Intel Core i7-3260M CPU、16 GB RAM、NVIDIA GT820M GPU。软件实验平台采用Jupyter Notebook。

首先，利用CEEMD和SE算法对原始负荷数据进行分解与重构，具体结果如表1所示。原始负荷数据分解后共得到9个IMF分量和一个Res分量。由表1可知，IMF7与IMF8复杂度相近，IMF9和Res分量较为接近，因此可以将其分别重构为一个分量。最终，将原本的10个分量重构为8个。

其次，对所提模型的预测性能进行验证，将其与传统的SSA-LSTM(方案1)、SSA-GRU(方案2)、SSA-CNN-LSTM(方案3)、SSA-CNN-GRU(方案4)预测模型进行对比，验证分解的可行性。将重构后的8个分量负荷数据分别输入到上述5个模型中进行学习训练与预测，所得到的具体实验结果如表2所示。

表1　各个分量SE值

分量	SE值	分量	SE值
IMF1	0.344 52	IMF6	0.076 52
IMF2	0.317 24	IMF7	0.006 52
IMF3	0.243 28	IMF8	0.004 28
IMF4	0.190 23	IMF9	0.000 32
IMF5	0.112 56	Res	0.000 24

表2　各预测算法的预测结果对比

模型	评价指标		
	RMSE/MW	MAE/MW	MAPE(%)
SSA-LSTM	377.51	330.64	0.983
SSA-GRU	355.54	326.54	0.974
SSA-CNN-LSTM	262.54	184.52	0.686
SSA-CNN-GRU	251.62	176.48	0.652
该文模型	172.54	152.62	0.432

从表2中可以看出，方案2的改进结果优于方案1。分别将方案1和方案3、方案2与方案4进行对比可以发现，相比于单一的预测模型，融合了特征提取模块的模型预测精度更高。而相比之下该文所提模型的预测精度最高，这是由于其两种特征提取模块是并行的，相比于方案3与方案4先提取数据空间特征后再提取时序特征而言，效率更高且所获取的特征信息更多。

表3所示为5种同类型的改进预测模型学习训练和预测所需要的时间，通过数据对比可以发现，该文模型不仅性能更优，所用时间也为最短，证明了融合改进的正确性和有效性。

表3　各算法的时间成本统计

模型	训练时间/s	预测时间/s
SSA-LSTM	511.64	2.62
SSA-GRU	467.28	2.24
SSA-CNN-LSTM	419.62	1.08
SSA-CNN-GRU	336.52	1.24
该文预测算法	257.24	0.38

4　结束语

为进一步提高负荷预测精度，该文提出一种面向小样本场景，基于特征迁移学习的负荷预测算法，并通过融合分解算法、深度学习算法、智能优化算法构建了预测模型。由理论分析可知，该模型首先基于CEEMD和SE算法的数据预处理模块，可以降低

中国知网　https://www.cnki.net

负荷数据的随机性,并为预测模型提供高质量数据,大幅提高了预测模型的预测精度。其次,CNN和LSTM的并行特征提取模块实现了数据局部特征与时序特征的同时提取,能够保留更多数据特征,从而提高预测精度。最后,融合了Attention机制的GRU网络,能有效解决关键数据丢失的问题,进一步提高预测的精度和效率。实验结果显示,所提算法的MAE、RMSE、MAPE分别为152.62 MW、172.54 MW、0.432%,与传统预测算法相比,该文所提负荷预测算法预测精度最高,鲁棒性更强,所用时间最短,可满足电力现货市场实际工程需求。

然而,此次研究仅与单一分解算法进行了比较,在未来可以针对多种分解算法进行对比研究,探究不同分解算法的实验效果。

参考文献:

[1] 陈胜,刘鹏飞,王平,等.基于LSTM人工神经网络的电力系统负荷预测方法[J].沈阳工业大学学报,2024,46(1):66-71.

[2] 陈曦,张玲华.基于VMD和优化组合模型的电力负荷预测方法研究[J].电子设计工程,2025,33(5):8-12,17.

[3] 高典,张菁.基于CEEMD-ITSA-BiLSTM组合模型的短期负荷预测[J].电子科技,2024,37(4):30-37.

[4] 史静,李冰洁,李泽森,等.基于改进LSTM的电力系统多层级负荷预测方法研究[J].电力需求侧管理,2025,27(2):62-67.

[5] 张运长,蒋昕潼,郑涛,等.基于CNN-LSTM的电力储能系统地区短期负荷预测研究[J].电子设计工程,2025,33(7):131-135.

[6] 王荣茂,谢宁,于海洋,等.基于EMD-LSTM模型的台区负荷短期预测方法[J].实验室研究与探索,2022,41(1):62-66,79.

[7] 梁亚峰,马立红,邱剑洪,等.基于CEEMD-LSTM光伏短期功率预测[J].科学技术与工程,2024,24(13):5396-5405.

[8] 杨国华,祁鑫,贾睿,等.基于CEEMD-SE的CNN&LSTM-GRU短期风电功率预测[J].中国电力,2024,57(2):55-61.

[9] 江永鑫,陈丽安,郭梦倩,等.基于改进CEEMD和RF的低压串联故障电弧识别方法[J].电力系统保护与控制,2024,52(1):97-108.

[10] 李彦阳,罗伟.基于符号变量矩阵的改进样本熵算法[J].科学技术与工程,2025,25(5):1913-1919.

[11] 李惟嘉,申晓红,李亚安.一种无偏差的多通道多尺度样本熵算法[J].物理学报,2024,73(11):10-19.

[12] 葛众,隆交凤,李健,等.结合CNN与软共享机制的综合能源系统多元负荷预测[J].电力建设,2024,45(12):162-173.

[13] 吴永洪,张智斌.基于贝叶斯优化的CNN-GRU短期电力负荷预测[J].现代电子技术,2023,46(20):125-129.

[14] 柳天虹,齐胜利,裔扬,等.基于分位数回归的改进权重GRU风电功率区间预测[J].太阳能学报,2024,45(12):291-298.

[15] 黄开远,罗娜.基于Attention机制改进TimeGAN的小样本时间序列预测方法[J].华东理工大学学报(自然科学版),2023,49(6):890-899.

[16] 马佳成,王晓霞,杨迪.基于Attention机制的TCN-LSTM非侵入式负荷分解[J].电力信息与通信技术,2023,21(8):43-51.

(上接第104页)

[10] 许烽,陆翌,黄晓明,等.基于无变压器型电压源换流器的柔性多状态开关零序抑制策略[J].电力系统自动化,2023,47(14):124-129.

[11] 郑旭,关钦月,徐敬友,等.考虑分布式能源集群暂态过电压抑制的交直流混联电网无功优化方法[J].可再生能源,2023,41(8):1089-1094.

[12] 逄思敏,刘其辉,石子敬,等.考虑线路序阻抗耦合的风电并网系统电压不平衡机理及抑制方法研究[J].电网技术,2024,48(2):552-563.

[13] 尹寒航,周小平,陈燕东,等.计及电网侧储能交互作用的MIDC后续换相失败机理分析及抑制策略[J].高电压技术,2024,50(7):2820-2832.

[14] 李智,刘明波,刘辉,等.电压控制型虚拟同步发电机的高频谐振特性分析与抑制策略[J].华南理工大学学报(自然科学版),2024,52(2):50-61.

[15] 李书亚,解绍锋,马智泉.孤岛运行方式下柔性直流配网高次谐波谐振及抑制措施研究[J].电力电容器与无功补偿,2023,44(5):81-88.

[16] 许爱德,孙景浩,冷冰,等.基于改进型转矩分配函数的开关磁阻电机转矩与峰值电流优化研究[J].电机与控制学报,2024,28(5):119-129.

中国知网　https://www.cnki.net