DOI:10.20222/j.cnki.cn61-1124/tm.20260709.005

面向数据稀缺场景的充电站迁移学习短期负荷预测方法

张艳辉[1*]，王明浩[2]，梁金连[1,2]，赵天任[1]，梁舒展[3]，张超华[3]，刁镜霖[2]
（1.中国科学院，深圳先进技术研究院，广东 深圳 517085；
2.澳门大学，科技学院电机与电脑工程系，澳门 999078；
3.深圳市科华恒盛科技有限公司，广东 深圳 518077）

摘要：针对充电站历史数据稀缺、小样本条件下短期负荷预测精度不足的问题，本文提出一种融合迁移学习（transfer learning, TL）与张量乘积注意力机制（tensor product attention, TPA）-极端梯度提升（extreme gradient boosting, XGBoost）-长短期记忆网络（long short-term memory, LSTM）的混合预测模型。首先，基于皮尔逊相关系数筛选相似源站数据，预训练LSTM并迁移其权重至目标模型进行微调；其次，引入TPA，对时序、气象等多源特征进行动态加权，生成增强特征集；最后，构建XGBoost-LSTM级联框架，利用XGBoost挖掘特征非线性关系，优化LSTM的输入与预测性能。基于30个实际充电站的实验表明，该模型在数据完整场景下均方根误差（root mean square error, RMSE）为8.3%，在小样本数据的充电站中，基于完整数据的相似场站的TL使预测误差较基线模型降低1.8%。该方法有效提升了小样本下的预测精度，为充电站规划与调度提供了技术支撑。

关键词：充电站；迁移学习；时间序列；负荷预测；注意力机制
中图分类号：TM715 **文献标识码**：A **文章编号**：1000-100X（2026）07-0139-09

A Transfer Learning-based Short-term Load Forecasting Method for Charging Stations in Data-scarce Scenarios

Zhang Yanhui[1*], Wang Minghao[2], Liang Jinlian[1,2], Zhao Tianren[1], Liang Shuzhan[3], Zhang Chaohua[3], Diao Jinglin[2]
(1. *Shenzhen Institutes of Advanced Technology, Chinese Academy of Sciences, Shenzhen* 517085, *China*;
2. *Department of Electrical and Computer Engineering, Faculty of Science and Technology, University of Macau, Macau* 999078, *China*;
3. *Shenzhen Kehua Hengsheng Technology Co., Ltd., Shenzhen* 518077, *China*)

Abstract: To address the issue of insufficient short-term forecasting accuracy under the conditions of scarce historical data and small samples for charging stations, this paper proposes a hybrid prediction model integrating transfer learning (TL) and tensor product attention(TPA)-extreme gradient boosting(XGBoost)-long short-term memory(LSTM). Firstly, similar source station data are screened based on the Pearson correlation coefficient, and an LSTM is pre-trained with its weights transferred and fine-tuned in the target model. Secondly, the TPA is introduced to dynamically weight multi-source features such as temporal and meteorological data, generating an enhanced feature set. Finally, a cascaded XGBoost-LSTM framework is constructed, leveraging XGBoost to mine nonlinear relationships among features, thereby optimizing the input quality and prediction performance of LSTM. Experiments based on 30 actual charging stations show that the model achieves an root mean square error(RMSE) of 8.3% in data-sufficient scenarios, and in data-missing scenarios, the TL strategy reduces the prediction error by 1.8% compared to the baseline model. This method effectively improves forecasting accuracy under small-sample conditions, providing technical support for the planning and scheduling of charging stations.

Keywords: charging station; transfer learning; time series; load prediction; attention mechanism

1 引 言

随着中国双碳战略的持续推进，电动汽车作为交通领域脱碳的关键载体，其规模化接入正深刻改变配电网的负荷结构。充电负荷的精准预测是配电网源荷互动、有序充电调度的核心前提，更是充电站规划选址、容量配置、电网扩容改

收稿日期：2025-12-17 定稿日期：2026-05-26

中国知网 https://www.cnki.net

造的重要数据支撑，直接关系到新型电力系统的安全稳定运行与能源利用效率。因此，实现充电站负荷的短期精准预测，已成为支撑新型电力系统源荷互动与智能化调度的迫切且关键的技术需求。

为提升充电站规划布局预测精度，学术界与工程界已开展了广泛研究。早期，以广义加法模型（generalized additive model, GAM）和季节性自回归综合移动平均模型（seasonal autoregressive integrated moving average, SARIMA）为代表的统计模型，因其模型简单、解释性强而得到应用[1-2]。然而，充电站负荷受用户行为、交通流、电价政策等多重复杂因素耦合影响，呈现出强非线性特征，传统统计模型难以充分捕捉其动态特性，预测精度受限。为此，以LSTM[3-4]、Transformer[5-6]等为代表的深度学习模型，凭借其强大的非线性拟合与时序特征提取能力，成为当前研究的主流，并在各类预测任务中展现出卓越性能[7-11]。同时，为融合不同模型的优势，混合模型策略也备受关注，如结合XGBoost的特征选择能力与深度学习模型的时序建模能力，已成为提升预测鲁棒性的重要途径[12-14]。

深度学习模型的性能高度依赖于大量、高质量的历史数据进行驱动训练，但在充电站的实际工程应用中，大量新建或偏远场站普遍面临历史数据稀缺、样本不完整甚至缺失的问题。这直接导致模型在这些数据受限场景下出现过拟合、泛化能力急剧下降，严重制约了先进算法的落地应用。

为解决此难题，学者们开始探索TL技术，通过将数据丰富的源域知识迁移至数据稀缺的目标域，有效提升了小样本场景下的预测性能[15-17]。TL能够有效实施的核心理论前提在于源域与目标域的数据分布具备一定相似性，或特征空间存在关联性，只有当源域与目标域之间共享相似的潜在规律、数据分布差异较小时，从源域学习到的知识才能被有效迁移并提升目标域模型性能，否则易出现负迁移现象，导致预测效果下降。文献[15]采取峰值聚类的方式选取源域对建筑的负荷进行预测；文献[16]采用数据特征值的巴氏距离方式选取源域数据集；文献[17]采取保留同期建造、类型相近的专家经验源域数据集进行预测。

综上所述，目前现有研究主要在两方面存在不足：多数混合模型设计未充分适配充电站数据稀缺的核心痛点[18-25]。TL应用未充分考虑源域与目标域的相似性，知识复用效率低。

对此，本文提出一种融合TL与TPA-XGBoost-LSTM的混合预测模型。核心技术创新点如下：①提出TPA-XGBoost特征增强模型：将TPA与XGBoost深度融合，实现对时序、气象、日期类型等多源特征的动态加权，解决了传统XGBoost特征建模静态化、长程时序依赖捕捉不足的缺陷，为小样本场景提供了高质量的非线性特征表征；②提出充电站跨场站精准TL策略：突破传统TL“无差别迁移”的局限，以皮尔逊相关系数量化筛选与目标场站负荷特征高度相似的源域，结合LSTM分层权重迁移与小样本微调，从数据层和模型层双重保证跨场站知识迁移的有效性，解决了小样本场景下模型泛化能力差的问题；③适配小样本场景的级联预测框架：构建TPA-XGBoost特征优化→微调后LSTM时序拟合的级联架构，让非线性特征挖掘为时序拟合提供精准输入，实现两种模型的优势深度互补，充分适配充电站小样本场景下特征信息少、时序数据稀缺的痛点。

2 基础理论方法

2.1 融合TPA的XGBoost

XGBoost作为一种高效的集成学习范式[26]，已被广泛应用于处理时间序列数据的非平稳性和多模态特征，该方法通过迭代优化弱学习器，构建强预测器，实现对复杂非线性关系的鲁棒建模，从而提升短期和中长期负荷预测性能。传统XGBoost通过贪心分裂挖掘特征的非线性关联，但在负荷预测任务中，存在两个核心局限：①对时序特征的长程依赖捕捉不足（如日内负荷峰谷的时序关联性、跨日负荷的周期规律）；②对多源特征的动态权重分配能力缺失（如气温、日期类型等特征在不同时段对负荷的影响程度存在差异）。为解决上述问题，本文引入TPA对XGBoost进行改进，构建TPA-XGBoost模型。

给定训练数据集 $D = \{(x_i, y_i)\}_{i=1}^{N}$，其中，$x_i$ 为电力负荷的特征向量；y_i 为目标负荷值，对于每个样本 $\boldsymbol{X} \in \mathbf{R}^{d \times T \times C}$ 均可生成一个动态的特征权

中国知网 https://www.cnki.net

重向量，用于捕获特征间的动态关系，本文为每个特征类型和时间步生成查询 $\boldsymbol{Q}$、键 $\boldsymbol{K}$ 和值 $\boldsymbol{V}$ 向量矩阵[27]，进行张量乘积注意力计算如下所示：

$$\text{Attention}(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}) = \text{Softmax}\left(\frac{\boldsymbol{Q}\otimes\boldsymbol{K}^{\mathrm{T}}}{\sqrt{d_k}}\right)\otimes\boldsymbol{V} \quad (1)$$

式中：$F(\boldsymbol{M}) = X_{\mathrm{w}} \times W_M(\boldsymbol{M}=\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V})$；$\otimes$ 为广义的张量乘积运算。

利用 TPA 模块将原始特征 x_i 得到注意力增强的特征 $\tilde{x}_l$，该方法输入树模型之前，显式地放大了关键特征的权重，抑制了噪声或无关特征。将增强后的特征 $\tilde{x}_l$ 通过 XGBoost 模型中的 K 棵回归树的加性组合形式表示预测输出如下所示：

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\hat{x}_i),\quad f_k \in F \quad (2)$$

式中：F 为所有可能的回归树集合；f_k 为第 K 棵树的结构与叶节点权值。

模型的优化目标函数可表示为

$$L(\phi) = \sum_{i=1}^{N} l(y_i,\hat{y}_i) + \sum_{k=1}^{K}\Omega(f_k) + \lambda_{\mathrm{att}}\|\alpha\|_F^2 \quad (3)$$

式中：$l(\cdot)$ 为样本损失函数（如平方误差损失）；$\Omega(f_k)$ 为结构正则化项，$\Omega(f_k) = \gamma T + \frac{1}{2}\lambda\|\omega\|^2$，$T$ 为叶节点数，ω 为叶节点权重，γ 和 λ 为正则化系数；λ_{att} 为注意力权重的正则化系数；$\|\alpha\|_F^2$ 为注意力权重矩阵的 Frobenius 范数，用以平衡特征增强效果，防止过拟合并提高模型的泛化能力。

通过最小化上述近似目标，XGBoost 在特征空间中寻找最优划分，从而生成一棵新的弱学习器（即回归树），并叠加至现有模型中[28]。

2.2　长短期记忆网络

LSTM 是一种特殊类型的循环神经网络（recurrent neural network, RNN）[29]，它通过引入门的机制来控制特征的保留和遗忘，从而实现对长期依赖的时间序列信息的学习。LSTM 的门机构可分为遗忘门、输入门和输出门，LSTM 的作用机理为

$$\begin{cases} f_t = \sigma(\boldsymbol{W}_{\mathrm{f}}[h_{t-1},x_t] + b_{\mathrm{f}}) \\ i_t = \sigma(\boldsymbol{W}_{\mathrm{i}}[h_{t-1},x_t] + b_{\mathrm{i}}) \\ o_t = \sigma(\boldsymbol{W}_{\mathrm{o}}[h_{t-1},x_t] + b_{\mathrm{o}}) \\ C_t = f_t\odot C_{t-1} + i_t\odot\tanh(\boldsymbol{W}_{\mathrm{C}}[h_{t-1},x_t] + b_{\mathrm{C}}) \\ h_t = o_t\odot\tanh(C_t) \end{cases} \quad (4)$$

式中：f_t 为遗忘门函数；C_t 为输入门函数；h_t 为输出门函数；$\boldsymbol{W}_{\mathrm{o}}$ 为对应函数的权重矩阵；b 对应函数的偏差项。

2.3　迁移学习

TL 是一种通过应用从一个任务中学到的知识或模型来解决另一个相关任务的机器学习方法。其核心思想是利用源域中已学习到的知识来提升目标域中模型的学习效率与预测性能。在 TL 中，数据域、任务和边际概率被用来描述 TL，数据域 D 包含源域、目标域两部分，特征空间 X 和边际概率分布 $P(X)$ 如式（5）所示：

$$D = \{X, P(X)\} \quad (5)$$

另一方面，任务 T 也包含源域、目标域两部分，特征空间 γ 和目标函数 $f(\cdot)$，$f(\cdot)$ 是从训练样本集学习得到，如下所示：

$$T = \{\gamma, f(\cdot)\} \quad (6)$$

对于电力负荷预测任务，TL 的引入能够有效缓解数据稀缺与模型泛化不足的问题。在部分场站缺乏完整历史负荷数据的情况下，可利用数据丰富场站的已训练模型或中间特征表示，快速适应新场景的预测任务，实现跨场站负荷预测或跨区域负荷迁移建模。

上述基础理论为本文所提混合预测模型提供了核心算法支撑。为清晰展示各模块协同工作机制，如图 1 所示，给出了面向数据稀缺场景的充电站跨场站短期负荷预测方法整体框架。框架通过跨场站知识迁移、多模态特征增强与时序建模的深度融合，解决充电站负荷在实际应用场景中存在的样本数据匮乏问题。通过输入目标充电站小样本数据、数据完备的源充电站数据，以及时序负荷、气象、日期类型、场站场景等多维特征；选取与目标场站负荷规律高度匹配的源站作为有效迁移对象。随后在筛选得到的相似源站上预训练 LSTM，将预训练得到的底层时序特征权重迁移至目标模型，并利用目标场站有限数据进行轻量化微调，快速适配目标场景。通过 TPA 对多源输入特征进行动态加权，再经 XGBoost 深度挖掘特征间非线性关联，生成高质量增强特征集。最后将增强特征输入经迁移与微调优化后的 LSTM，充分捕捉负荷长期时序依赖与波动规律，完成充电站短期负荷精准预测。

中国知网　https://www.cnki.net

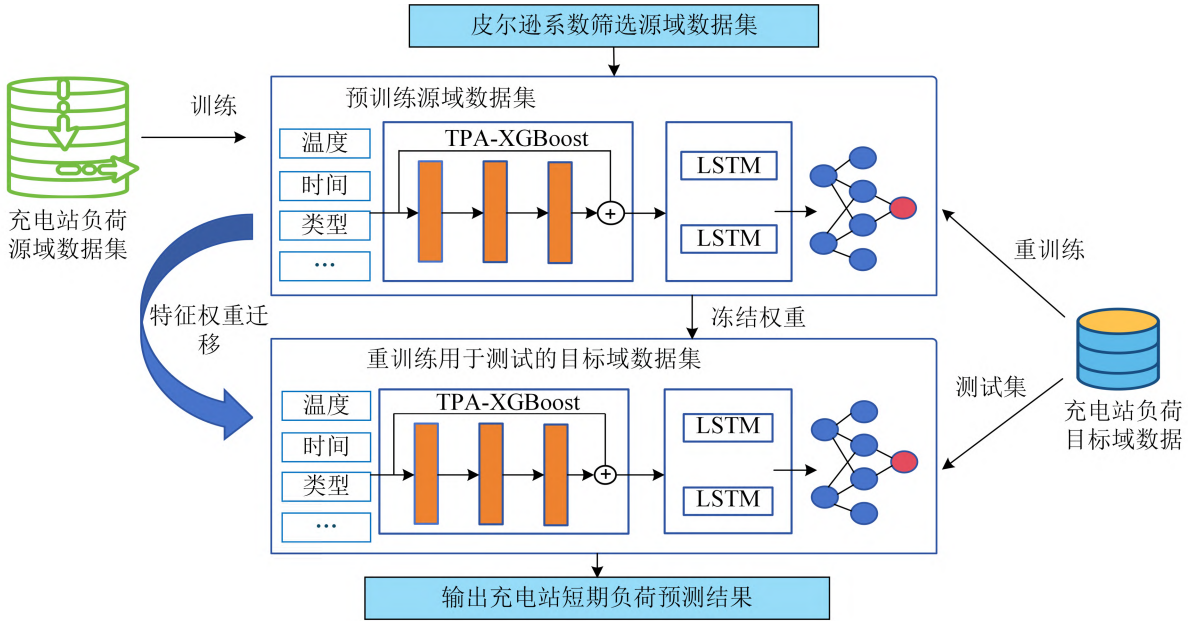


图 1 所提方法的整体框架

Fig. 1 Overall framework of the proposed approach

3 预测流程及评价指标

3.1 预测流程

如图 2 所示，本文使用基于 TL 的场站负荷预测方法，通过结合 TPA-XGBoost 和 LSTM 模型，先收集目标站数据与完整充电站数据，通过皮尔逊相关系数筛选与目标场站高度相关的源域，确保迁移知识的有效性，此处阈值取 0.7；其次，在源域上预训练 LSTM，并将其底层权重迁移至目标模型进行微调，实现跨场景时序知识的高效复用；随后，引入 TPA 增强 XGBoost 的特征建模能力：利用 TPA 对多源输入特征（时序负荷、气象、日期类型等）进行动态加权，自适应聚焦关键时段与核心影响因子，生成增强特征集；最后，构建 TPA-XGBoost 特征优化，微调后 LSTM 时序拟合的级联预测框架，该框架首先利用 TPA-XGBoost 挖掘特征间的非线性关联并优化输入表征，进而通过微调后的 LSTM 捕捉负荷的长期时序依赖，两者协同实现高精度预测。经预处理后用皮尔逊相关系数筛选 3 个相似源站；在源站数据上预训练 LSTM，迁移权重至目标模型；通过 TPA 对多源特征动态加权，再经 XGBoost 挖掘非线性关系生成增强特征；用目标站少量数据微调 LSTM，捕捉时序依赖；最后输出负荷预测结果。

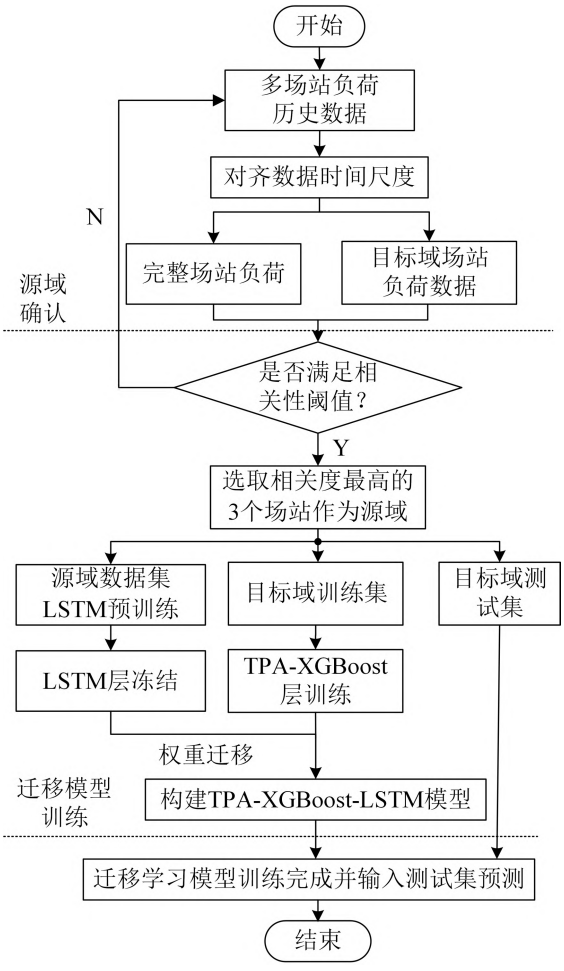


图 2 TL-TPA-XGBoost-LSTM 模型流程图

Fig. 2 Flowchart of TL-TPA-XGBoost-LSTM model

3.2 评价指标

本文使用两个常用指标评估混合模型的性

中国知网 https://www.cnki.net

能：RMSE 和决定系数（R-square, RS）。指标的定义如式（7）、（8）所示：

$$\mathrm{RMSE}=\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2} \tag{7}$$

$$R^2=1-\frac{\sum_{i=1}^{n}(\hat{y}_i-y_i)^2}{\sum_{i=1}^{n}(\bar{y}_i-y_i)^2} \tag{8}$$

4　实验分析

4.1　数据集介绍

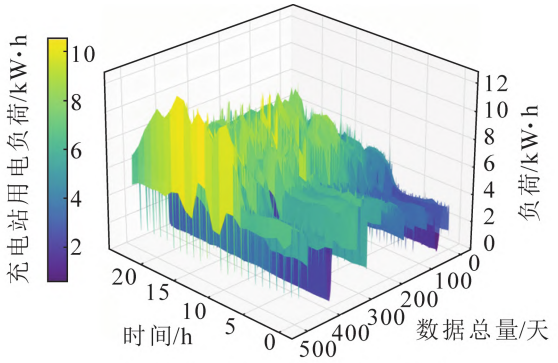
本实验收集了来自广东省 30 个场站历史电力负荷数据，用于构建和验证所提出的负荷预测模型。实验数据集已在 IEEE Dataport 平台开源共享，可通过 DOI：10.21227/9avf-qp24 获取，便于后续研究复现与对比验证。如表 1 所示，数据集覆盖区域为深圳、惠州、东莞及广州地区，充电站分布场景包含工业园区、小区住宅和商场，时间范围为 2024 年 1 月至 2025 年 5 月，时间分辨率为 1 h。其中具备完整数据的充电站为 26 个，只有 2025 年数据的充电站为 4 个。

表 1　数据集说明

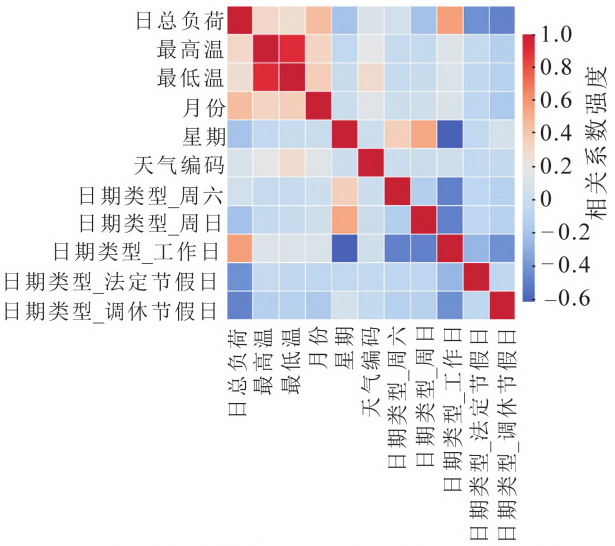
Table 1　Dataset description

数据名称	广东省 30 个场站电力负荷数据
数据来源	电网机构实际提供
时间跨度	2024 年 1 月至 2025 年 5 月
时间分辨率	每 1 h 负荷记录
数据格式	xlsx 文本
总数据量	262 800

如图 3（a）所示，展示了针对深圳的某一场站在 2024 年全年 24 h 负荷数据（00：00~23：00）的负荷分布情况，可以明显观察到负荷在不同季节和月份间的波动趋势。对应收集了场站相应的气象信息，如最高气温、最低气温和天气状况及日期类型（法定节假日、调休节假日、工作日、周六、周日 5 种类型），对应场站分类有酒店、小区、工业园。图 3（b）通过相关性展示了总负荷与各输入特征（如气温、日期类型等）之间的相关性强度。可见，最高气温和最低气温与负荷呈现较强的正相关，尤其是在极端天气条件下；日期类型也与负荷高度相关，工作日的负荷普遍高于周末和节假日，符合实际用电行为规律。因此建立能够捕捉特征相关性的时间序列预测模型框架，捕捉电力负荷变化的复杂规律。



(a)深圳1号充电站的负荷分布



(b)深圳1号充电站总负荷与输入特征相关性图

图 3　电力负荷数据分析

Fig. 3　Power load data analysis

4.2　TPA-XGBoost-LSTM 模型预测实验

首先建立适配充电站短期负荷预测的最优模型。在模型训练中负荷数据在时间上的序列划分如图 4 所示，其展示了充电站在 500 天的日平均负荷分布情况，阴影部分表示当天每小时的最大最小负荷值分布。在 5 组完整场站数据集上将每个场站 2024 年 1 月至 2025 年 3 月的数据作为训练集，2025 年 4 月的数据作为验证集，2025 年 5 月数据作为测试集。

为构建最优的负荷预测混合模型架构，建立 LSTM、XGBoost、XGBoost-LSTM、LSTM-Transform、LightGBM-LSTM 和 TPA-XGBoost-LSTM 共 6 组基准模型。通过系统性的实验及文献调研确定了对应模型的超参数设置如表 2、表 3 所示。

中国知网　https://www.cnki.net

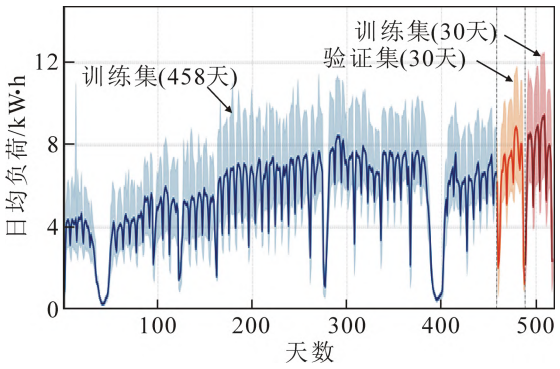


图4 充电站负荷时序数据的训练集测试集划分

Fig. 4 Training and test set partitioning of charging station load time series data

表2 决策树模型的超参数设置

Table 2 Hyperparameter settings of the decision tree model

基准模型	决策树数量	决策树深度	L_1正则化	L_2正则化
XGBoost	1 000	6	0.1	1
XGBoost-LSTM	1 000	6	0.1	1
LSTM-Transformer	1 000	6	0.1	1
LightGBM-LSTM	1 000	6	0.1	1
TPA-XGBoost-LSTM	1 000	6	0.1	1

表3 神经网络模型的超参数设置

Table 3 Hyperparameter settings of neural network models

基准模型	网络层数	隐藏层节点数	优化器	损失函数	初始学习率
LSTM	5	64	Adam	RMSE	0.05
XGBoost-LSTM	7	64	Adam	RMSE	0.05
LSTM-Transformer	12	64	Adam	RMSE	0.05
LightGBM-LSTM	7	64	Adam	RMSE	0.05
TPA-XGBoost-LSTM	9	64	Adam	RMSE	0.05

图5与表4分别给出了6种对比模型及所提模型在测试集上的负荷预测曲线与定量精度指标。由图5可见，TPA-XGBoost-LSTM模型预测曲线与实际充电负荷时序变化趋势高度吻合，在负荷峰谷、波动节点及短时突变位置的拟合精度显著优于其余模型，可精准跟踪充电负荷的非线性波动与日内时序特性。结合表4的RMSE结果可知，本文所提混合模型在5组完整数据场站的测试集上均取得最低预测误差，综合性能优于单一LSTM、XGBoost、XGBoost-LSTM、LSTM-Transformer及LightGBM-LSTM模型。对比表明，LSTM-Transformer在充电站负荷预测场景中表现欠佳，主要原因在于充电负荷具有强非线性、高随机性与局

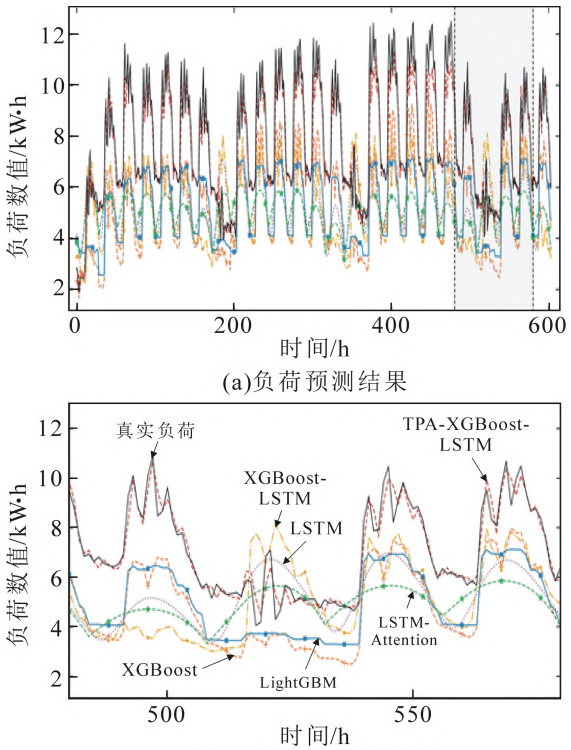


图5 6个基准模型及所提模型在深圳1充电站数据的负荷预测结果

Fig. 5 Load prediction results of six baseline models and proposed model on data of shenzhen No.1 charging station

表4 6种基准模型及所提模型在5个完整数据充电站预测结果的RMSE

Table 4 RMSE of prediction results for 6 baseline models and proposed model at 5 complete data charging stations

基准预测模型	1号RMSE	2号RMSE	3号RMSE	4号RMSE	5号RMSE
LSTM	0.118 9	0.137 5	0.132 3	0.115 4	0.114 1
XGBoost	0.100 8	0.116 1	0.109 1	0.103 9	0.104 5
XGBoost-LSTM	0.092 7	0.110 8	0.105 5	0.100 3	0.096 9
LSTM-Transformer	0.149 7	0.142 5	0.155 0	0.140 0	0.124 0
LightGBM-LSTM	0.095 3	0.110 6	0.105 3	0.102 4	0.100 3
TPA-XGBoost-LSTM	0.084 6	0.100 9	0.091 7	0.099 2	0.088 7

中国知网 https://www.cnki.net

部敏感特性，Transformer 架构在处理该类时序数据时易产生冗余特征干扰，造成关键时序细节丢失与模型负优化。本文所提方法将 TPA 与 XGBoost 深度融合，实现对时序、气象、日期类型等多源特征的动态加权与自适应强化，有效克服传统 XGBoost 特征建模静态化、关键因子表征不足的缺陷，特征表达能力显著优于无注意力机制的 LightGBM-LSTM 模型。在此基础上，引入 LSTM 对增强特征进行长程时序依赖建模，充分发挥其在时序序列长期依赖学习上的优势，弥补梯度提升树模型对时序连续性刻画能力不足的短板。定量对比结果显示，所提模型较 LightGBM-LSTM 平均误差降低 8.3%，较单一 XGBoost 降低 13.0%，充分验证了 TPA-XGBoost 特征增强与 LSTM 时序拟合级联架构的有效性，可显著提升充电站短期负荷预测的精度与鲁棒性。

4.3　TL-TPA-XGBoost-LSTM 模型预测实验

对于不完整的充电站数据只收集到 2025 年 2 月末（为中国春节后）至 5 月不足 3 个月的数据，使得长期的趋势信息缺失，导致预测精度降低。

为实现数据稀缺场景下跨场站知识的有效迁移，本文基于皮尔逊相关系数结合多维度特征信息，定量计算目标充电站与各源域场站负荷序列的时序相似性，相关度对比结果如图 6 所示。

此处统计显著性 $p < 0.001$ 证明相关性不是随机误差，结果可信。经统计显著性检验验证，所得相关系数可有效排除随机误差干扰，具备可靠的相似性判别效力。计算结果表明，有 3 个源域场站与目标场站的负荷变化趋势高度契合，相关系数均大于 0.7，满足 TL 对源-域相似性的基本要求，可作为最优迁移源域。为此，本文选取相关性最高的前 3 个场站（N=3）构建 TL 源域数据集，并采用上述源场站 2024 年全年完整数据预训练，以充分学习负荷波动规律与时序依赖特性。模型测试阶段，以目标充电站最后 3 天负荷数据作为测试集，用以评估小样本场景下预测性能。

相应预测结果如表 5 与图 7 所示。由实验结果可见，引入 TL 的 TL-TPA-XGBoost-LSTM 模型相较未引入迁移的基准模型，RMSE 降低 1.8%，预测曲线与实际负荷的贴合度更高，在峰谷跟踪与波动拟合方面表现更优。上述结果表明，基于高相关源域的权重迁移与微调策略能够显著提升

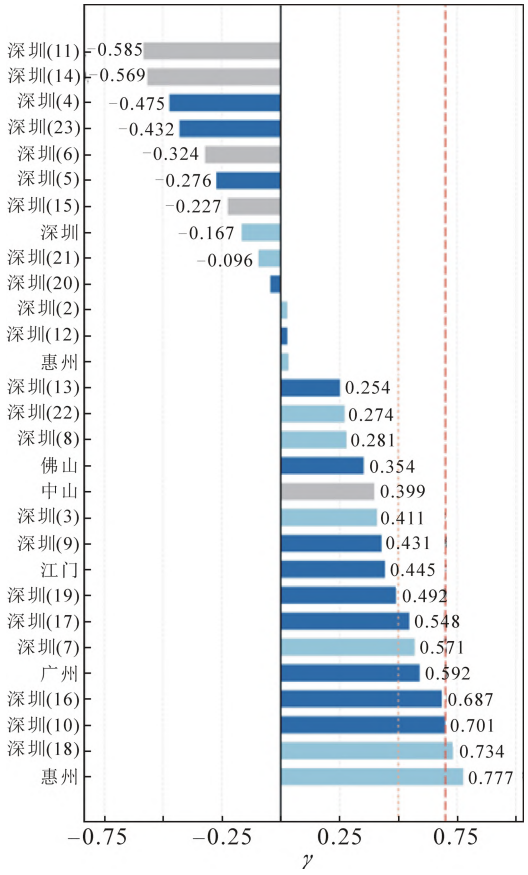


图 6　目标域与其他充电站皮尔逊相关系数对照图

Fig. 6 Comparison of pearson correlation coefficients between target station and other charging stations

表 5　TL 模型与未 TL 预测结果

Table 5 Predictions results of TL model and non-TL

预测模型	RMSE	R^2
非 TL 模型	0.111 0	0.582 0
TL 模型	0.099 0	0.696 7

小样本场景下模型的泛化能力与预测精度，验证了本文所提跨场站 TL 策略的有效性与实用性。从图 7 和表 5 的预测显示 TL-XGBoost-LSTM 相比基准模型 RMSE 降低 1.8%，并且在拟合度上也更加趋于实际情况。

5　结　论

本文研究了数据稀缺场景下充电站选址负荷预测的高精度预测方法。研究工作首先深入剖析了充电站负荷的强非线性与随机性特征，并指出了传统预测模型与单一深度学习模型在应对多场景、小样本数据时的局限性。为解决此核心挑战，本文提出了一种融合 TL 与 TPA-XGBoost-

中国知网　https://www.cnki.net

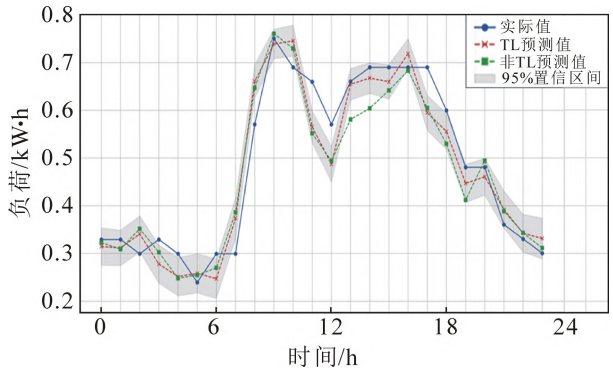


图7 TL模型与未TL预测结果

Fig. 7 Prediction results of TL model and non-TL

LSTM的混合预测模型，旨在通过跨场景知识迁移与多模型优势互补，提升充电站负荷预测模型的精度与泛化能力。结果表明：在数据完整场景下，所提模型的均方根误差低至8.3%，展现了卓越的预测精度。更重要的是，在数据缺失的不完整场景中，TL策略的引入使模型预测误差相较于基础混合模型进一步降低了1.8%，显著提升了模型在数据受限条件下的泛化能力与鲁棒性。

通过负荷预测的研究还可以在未来明确不同充电选址位置的负荷需求规模，为选址决策提供数据支撑，即基于预测的负荷数据判断充电场站的服务潜力、供电压力等。

参考文献

[1] Monika Z, Florian Z. Efficient Mid-term Forecasting of Hourly Electricity Load Using Generalized Additive Models[J]. Applied Energy, 2025, 388: 125444.

[2] Royal E, Soutir B, Newman A, et al. A Statistical Framework for District Energy Long-term Electric Load Forecasting[J]. Applied Energy, 2025, 384: 125445.

[3] Ma K, Nie X F, Yang J, et al. A Power Load Forecasting Method in Port Based on VMD-ICSS-hybrid Neural Network[J]. Applied Energy, 2025, 377: 124246.

[4] Dong X Z, Luo Y Q, Yuan S, et al. Building Electricity Load Forecasting Based on Spatiotemporal Correlation and Electricity Consumption Behavior Information[J]. Applied Energy, 2025, 377: 124580.

[5] Tang Z, Ji T Y, Kang J, et al. Learning Global and Local Features of Power Load Series Through Transformer and 2D-CNN: An Image-based Multi-step Forecasting Approach Incorporating Phase Space Reconstruction[J]. Applied Energy, 2025, 378: 124786.

[6] Yang Y, Gao Y C, Zhou H, et al. Multi-granularity Autoformer for Long-term Deterministic and Probabilistic Power Load Forecasting[J]. Neural Networks, 2025, 188: 107493.

[7] Wang C, Zhao H S, Liu Y, et al. Minute-level Ultra-short-term Power Load Forecasting Based on Time Series Data Features[J]. Applied Energy, 2024, 372: 123801.

[8] 陈宇轩，谢海鹏，许若一，等. 基于可解释多模态增强的电力负荷预测方法[J/OL]. 电力系统自动化，1-25[2026-03-25]. https://link. cnki. net/urlid/32.1180. tp. 20260401.1119.004.
Chen Yuxuan, Xie Haipeng, Xu Ruoyi, et al. Power Load Forecasting Method Based on Interpretable Multi-modal Enhancement[J/OL]. Automation of Electric Power Systems, 1-25[2026-03-25]. https://link. cnki. net/urlid/32.1180.tp.20260401.1119.004.

[9] 马 勇，黄 涛. 基于组合式神经网络的综合电力负荷预测方法[J]. 电子设计工程，2026，34(7)：89-93.
Ma Yong, Huang Tao. Comprehensive Electric Load Forecasting Method Based on Composite Neural Network[J]. Electronic Design Engineering, 2026, 34(7): 89-93.

[10] 陈金海，李海吉. 采用深度长短记忆预测方法的电力负荷预测[J]. 工业控制计算机，2026，39(3)：149-150.
Chen Jinhai, Li Haiji. Electric Load Forecasting Using Deep Long Short-term Memory Prediction Method[J]. Industrial Control Computer, 2026, 39(3): 149-150.

[11] Xiao W J, Mo L, Xu Z X, et al. A Hybrid Electric Load Forecasting Model Based on Decomposition Considering Fisher Information[J]. Applied Energy, 2024, 364: 123149.

[12] Chen J L, Zhang C, Li X, et al. An Integrative Approach to Enhance Load Forecasting Accuracy in Power Systems Based on Multivariate Feature Selection and Selective Stacking Ensemble modeling[J]. Energy, 2025, 326: 136337.

[13] Gong J Q, Qu Z G, Zhu Z L, et al. Ensemble Models of TCN-LSTM-LightGBM Based on Ensemble Learning Methods for Short-term Electrical Load Forecasting[J]. Energy, 2025, 318: 134757.

[14] Wang G J, Han L C, Zhang X Y, et al. Electrical Load Forecasting Based on Variable T-distribution and Dual Attention Mechanism[J]. Energy, 2023, 283: 128569.

[15] Li K J, Zhou S Y, Zhao M T, et al. Short-term Building Electrical Load Prediction by Peak Data Clustering and Transfer Learning Strategy[J]. Energies, 2025, 18: 686.

[16] Sarita S, Mamta D, Shilpi T, et al. A Transfer Learning-based Hybrid Model with LightGBM for Smart Grid Short-term Energy Load Prediction[J]. Energy Exploration & Exploitation, 2024, 42(5): 1853-1876.

中国知网 https://www.cnki.net

[17] Qian F Y, Ruan Y J, Lu H M, et al. Enhancing Source Domain Availability Through Data and Feature Transfer Learning for Building Power Load Forecasting[J]. Building Simulation, 2024, 17: 625-638.

[18] Jiang Z X, Zhang L L, Ji T Y. NSDAR: A Neural Network-based Model for Similar Day Screening and Electric Load Forecasting[J]. Applied Energy, 2023, 349: 121647.

[19] Osaka R, Zhang T, Zhang X, et al. Highly Accurate Peak and Valley Prediction Short-term Net Load Forecasting Approach Based on Decomposition for Power Systems with High PV Penetration[J]. Applied Energy, 2023, 333: 120641.

[20] Lucas B S M, Aquila G, Victor A D, et al. Short-term Load Forecasting Using Neural Networks and Global Climate Models: An Application to a Large-scale Electrical Power System[J]. Applied Energy, 2023, 348: 121439.

[21] Omar B, Maher D, Amayri M, et al. Transformer-based Deep Probabilistic Network for Load Forecasting[J]. Engineering Applications of Artificial Intelligence, 2025, 152: 110781.

[22] Bashiri B N, Fezzi C, Ravazzolo F. Incorporating Air Temperature into Mid-term Electricity Load Forecasting Models Using Time-series Regressions and Neural Networks[J]. Energy, 2023, 278: 127831.

[23] Wang J J, Huang W Y, Ding Y P, et al. Forecasting the Electric Power Load Based on a Novel Prediction Model Coupled with Accumulative Time-delay Effects and Periodic Fluctuation Characteristics[J]. Energy, 2025, 317: 134518.

[24] Hosein E, Imani M, Parsa Moghaddam M P. A Deep Residual Network Integrating Entropy-based Wavelet Packet Ensemble Model for Short-term Electrical Load Forecasting[J]. Energy, 2025, 314: 134168.

[25] Wang Y, Li H, Jahanger A, et al. A Novel Ensemble Electricity Load Forecasting System Based on a Decomposition-selection-optimization Strategy[J]. Energy, 2024, 312: 133524.

[26] 王　栋，丁　波，赵　超，等. 基于 VMD-EMD 分解和 XGBoost 的汽车充电负荷预测及响应能力研究[J]. 自动化与仪器仪表，2026，40(3)：91-95.
Wang Dong, Ding Bo, Zhao Chao, et al. Electric Vehicle Charging Load Forecasting and Response Capability Based on VMD-EMD Decomposition and XGBoost[J]. Automation & Instrumentation, 2026, 40(3): 91-95.

[27] 梅通达，司占军，张滢雪. 基于 IWOA 的 CNN-BiLSTM-TPA 模型的短期电力负荷预测研究[J]. 印刷与数字媒体技术研究，2025，30(1)：179-187.
Mei Tongda, Si Zhanjun, Zhang Yingxue. Research on Short-term Electric Load Forecasting Using IWOA CNN-BiLSTM-TPA Model[J]. Printing and Digital Media Technology Study, 2025, 30(1): 179-187.

[28] 李延珍，王海鑫，杨子豪，等. 基于非侵入式负荷分解的家庭负荷两阶段超短期负荷预测模型[J]. 电工技术学报，2024，39(11)：3379-3391.
Li Yanzhen, Wang Haixin, Yang Zihao, et al. Two-stage Ultra-short-term Load Forecasting Model of Household Appliances Based on Non-intrusive Load Disaggregation[J]. Transactions of China Electrotechnical Society, 2024, 39(11): 3379-3391.

[29] 谷　卫，徐　龙，唐　飞，等. 基于 LSTM-TSLightGBM 可变权重组合模型的短期电力负荷预测[J]. 河北电力技术，2026，45(1)：26-33.
Gu Wei, Xu Long, Tang Fei, et al. Short Term Power Load Forecasting Based on LSTM-TSLightGBM Variable Weight Combination Model[J]. Heibei Electric Power, 2026, 45(1): 26-33.



张艳辉

作者简介：

张艳辉（1984-），男，博士研究生，副研究员，研究方向为电池储能及超充桩，zhangyh@siat.ac.cn（通信作者）。

中国知网　https://www.cnki.net